



ΔΗΜΟΚΡΙΤΕΙΟ  
ΠΑΝΕΠΙΣΤΗΜΙΟ  
ΘΡΑΚΗΣ

ΤΜΗΜΑ  
ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ  
& ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

---

# Αποτίμηση της συνεισφοράς χρηστών στην ομοσπονδιακή μάθηση

*Evaluation of User Contributions in Federated Learning*

---

## Διπλωματική Εργασία

Δημήτριος Αναστασούδης

AEM: 58085

Επιβλέπων:

Πάυλος Εφραιμίδης

Algorithms & Privacy Research Unit (Euclid)

Ξάνθη, 2026

# Ευχαριστίες

Η εκπόνηση της παρούσας διπλωματικής εργασίας δε θα ήταν εφικτή χωρίς την ουσιαστική υποστήριξη ανθρώπων που βρίσκονταν δίπλα μου καθ' όλη τη διάρκεια των σπουδών μου. Πρωτίστως, θα ήθελα να εκφράσω τη βαθύτατη ευγνωμοσύνη μου στους γονείς μου, για την αμέριστη αγάπη, υπομονή και ηθική στήριξη που μου πρόσφεραν σε κάθε βήμα αυτής της πορείας. Η εμπιστοσύνη τους στις ικανότητές μου και η αδιάλειπτη παρουσία τους αποτέλεσαν το σταθερό σημείο αναφοράς που μου επέτρεψε να ολοκληρώσω τις σπουδές μου με αφοσίωση και επιμονή. Τους ευχαριστώ από καρδιάς.

Ιδιαίτερες ευχαριστίες οφείλω στον επιβλέποντα καθηγητή μου, κ. Παύλο Εφραιμίδη, Καθηγητή του Τμήματος Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών του Δ.Π.Θ. και επικεφαλής του Algorithms & Privacy Research Unit (Euclid), για την επιστημονική καθοδήγηση, την άρτια εποπτεία και τις εύστοχες παρατηρήσεις που διαμόρφωσαν καθοριστικά την κατεύθυνση και την ποιότητα της εργασίας. Παράλληλα, θερμές ευχαριστίες εκφράζω και στον Δρ. Νικόλαο Παυλίδη, μέλος της ίδιας ερευνητικής ομάδας, για την πολύτιμη τεχνική βοήθεια, τις γόνιμες συζητήσεις και τη διάθεση του ερευνητικού υλικού που διευκόλυνε σημαντικά την υλοποίηση του πειραματικού μέρους της εργασίας.

Τέλος, εκφράζω την εκτίμησή μου στο Δημοκρίτειο Πανεπιστήμιο Θράκης και στο Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, για το ακαδημαϊκό περιβάλλον, τις ευκαιρίες και τις γνώσεις που μου έδωσαν στη διάρκεια των σπουδών μου.

## Περίληψη

Η εργασία αντιμετωπίζει ένα πρόβλημα ταξινόμησης, την αναγνώριση ανθρώπινης δραστηριότητας από τους αισθητήρες ενός έξυπνου κινητού τηλεφώνου. Κάθε sample περιγράφει 2,56 δευτερόλεπτα κίνησης με 561 χαρακτηριστικά. Το μοντέλο αναγνωρίζει ποια από τις έξι δραστηριότητες εκτελείται. Επειδή τα δεδομένα αυτά είναι προσωπικά, η εκπαίδευση γίνεται με ομοσπονδιακή μάθηση, όπου τα δεδομένα μένουν στη συσκευή και ο εξυπηρετητής (*server*) δεν μπορεί να κρίνει τι προσέφερε ο καθένας. Σε αυτό το πρόβλημα δίνει λύση η παρούσα εργασία, αποτιμώντας τη συνεισφορά των χρηστών.

Στο σύνολο δεδομένων UCI HAR, οι 21 εθελοντές του συνόλου εκπαίδευσης καταχωρούνται ως οι συμμετέχοντες της ομοσπονδίας και 9 άλλοι άνθρωποι προορίζονται αποκλειστικά για την αξιολόγηση. Μετά από ελέγχους ακεραιότητας των δεδομένων, το ίδιο απλό νευρωνικό δίκτυο εκπαιδεύεται με τρεις τοπολογίες μάθησης σε 20 επαναλήψεις. Η ορθότητα (*accuracy*) της κεντρικής ανέρχεται σε 94,94%, της ομοσπονδιακής σε 94,11% και της ατομικής σε 75,81%, οπότε η αποκέντρωση κοστίζει 0,83 ποσοστιαίες μονάδες, ενώ η συνεργασία κερδίζει 18,30.

Η συνεισφορά αποτιμάται με το Shapley value, σε παίγνιο ανά γύρο, όπου ως αξία μιας ομάδας συμμετεχόντων ορίζεται η ορθότητα του μοντέλου που θα έβγαине μόνο από τις ενημερώσεις της. Τα μοντέλα αυτά ανασυντίθενται από αποθηκευμένες ενημερώσεις, χωρίς επανεκπαίδευση. Δύο ανεξάρτητοι εκτιμητές, ο KernelSHAP και μια παραλλαγή του GTG-Shapley, συμφωνούν σχεδόν πλήρως στην κατάταξη.

Εννέα από τους 21 συμμετέχοντες παίρνουν αρνητική τιμή, δηλαδή η ενημέρωσή τους, κατά μέσο όρο στους γύρους, κάνει το κοινό μοντέλο χειρότερο για τα άτομα της αξιολόγησης. Το εύρημα αντέχει τέσσερις ελέγχους. Κανένα απλό στατιστικό των δεδομένων δεν το προβλέπει πλήρως.

Σε ένα δεύτερο παίγνιο, όπου κάθε ομάδα αποτιμάται με επανεκπαίδευση από τα δεδομένα της, κανείς δε βγαίνει αρνητικός και οι δύο κατατάξεις συμφωνούν ασθενώς. Επομένως, η αρνητική τιμή μετρά την ενημέρωση και όχι τα δεδομένα. Για την ομάδα των εννέα, εμφανίζεται μόνο αφού το μοντέλο ξεπεράσει το 90%, κυρίως στο σύνορο καθιστής και όρθιας στάσης και απέναντι σε συγκεκριμένα άτομα της αξιολόγησης. Το σύνορο αυτό δίνει το 49,1% των σφαλμάτων. Όταν οι αρνητικοί εντοπίζονται με βάση έξι από τα εννέα άτομα της αξιολόγησης και αφαιρούνται, το μοντέλο βελτιώνεται για τα άλλα τρία σε μία μόνο από τις τρεις διαιρέσεις. Η αφαίρεσή τους, επομένως, δεν έχει νόημα και μένουν στην ομοσπονδία.

Η συνεισφορά όλων γίνεται μερίδια με δύο πολιτικές που κρατούν την κατάταξη, την αφινική μετατόπιση και την εκθετική κατανομή, από τις οποίες η δεύτερη δίνει θετικό μερίδιο σε όλους.

**Λέξεις-κλειδιά:** ομοσπονδιακή μάθηση, αναγνώριση ανθρώπινης δραστηριότητας, ταξινόμηση, Shapley value, KernelSHAP, αποτίμηση συνεισφοράς, αποτίμηση δεδομένων, UCI HAR

# Abstract

This thesis addresses a classification problem, human activity recognition from the sensors of a smartphone. Each sample describes 2.56 seconds of movement through 561 features, and the model recognizes which of six activities is being performed. Because such data are personal, training uses federated learning, where the data stay on the device and the server cannot judge what each participant contributed. The thesis responds to this problem by evaluating the contribution of the users.

On the UCI HAR dataset, the 21 volunteers of the training split become the participants of the federation and 9 other people are kept solely for evaluation. After integrity checks on the data, the same simple neural network is trained under three learning topologies over 20 repetitions. Centralized training reaches 94.94% accuracy, federated training 94.11% and individual training 75.81%, so decentralization costs 0.83 percentage points while collaboration gains 18.30.

Contribution is evaluated with the Shapley value, in a per-round game where the value of a group of participants is the accuracy of the model that their updates alone would produce. These models are rebuilt from stored updates, without retraining. Two independent estimators, KernelSHAP and a variant of GTG-Shapley, agree almost fully on the ranking.

Nine of the 21 participants receive a negative value, meaning that, on average over the rounds, their update makes the shared model worse for the evaluation subjects. The finding survives four checks, and no simple statistic of the data fully predicts it.

In a second game, where each group is valued by retraining on its own data, no participant is negative and the two rankings agree only weakly. The negative value therefore measures the update rather than the data. For the group of nine, it appears only after the model passes 90%, mainly at the boundary between sitting and standing, which accounts for 49.1% of the errors, and it is concentrated on particular evaluation subjects. When the negative participants are identified with six of the nine evaluation subjects and removed, the model improves for the other three in only one of the three splits. Removing them therefore does not make sense. They remain in the federation, and the contribution of all participants is turned into shares with two policies that keep the ranking, an affine shift and an exponential distribution, the second of which gives every participant a positive share.

**Keywords:** federated learning, human activity recognition, classification, Shapley value, KernelSHAP, contribution evaluation, data valuation, UCI HAR

# Περιεχόμενα

|                                                                         |           |
|-------------------------------------------------------------------------|-----------|
| <b>Ευχαριστίες</b>                                                      | <b>2</b>  |
| <b>Περίληψη</b>                                                         | <b>3</b>  |
| <b>Abstract</b>                                                         | <b>5</b>  |
| <b>Κατάλογος Σχημάτων</b>                                               | <b>10</b> |
| <b>Κατάλογος Πινάκων</b>                                                | <b>12</b> |
| <b>Κατάλογος Συντομογραφιών</b>                                         | <b>14</b> |
| <b>1 Εισαγωγή</b>                                                       | <b>15</b> |
| 1.1 Αναγνώριση Δραστηριότητας, Ιδιωτικότητα και Ομοσπονδιακή Μάθηση . . | 15        |
| 1.2 Το Πρόβλημα της Αποτίμησης της Συνεισφοράς . . . . .                | 16        |
| 1.3 Ερευνητικά Ερωτήματα . . . . .                                      | 16        |
| 1.4 Συνεισφορά της Εργασίας . . . . .                                   | 17        |
| 1.5 Διάρθρωση της Εργασίας . . . . .                                    | 17        |
| <b>2 Θεωρητικό Υπόβαθρο</b>                                             | <b>19</b> |
| 2.1 Πολυεπίπεδα Δίκτυα Εμπρόσθιας Τροφοδότησης . . . . .                | 19        |
| 2.1.1 Δομή, εκπαίδευση και κανονικοποίηση . . . . .                     | 19        |
| 2.1.2 Μετρικές αξιολόγησης ταξινόμησης . . . . .                        | 20        |
| 2.1.3 Μέτρα συσχέτισης και συμφωνίας κατάταξης . . . . .                | 22        |
| 2.2 Ομοσπονδιακή Μάθηση . . . . .                                       | 24        |
| 2.2.1 Αρχιτεκτονική εξυπηρετητή και συμμετεχόντων . . . . .             | 24        |

|          |                                                               |           |
|----------|---------------------------------------------------------------|-----------|
| 2.2.2    | Ο αλγόριθμος FedAvg . . . . .                                 | 25        |
| 2.2.3    | Ετερογένεια και client drift . . . . .                        | 26        |
| 2.2.4    | Εγγυήσεις και όρια ιδιωτικότητας . . . . .                    | 26        |
| 2.3      | Συνεργατικά Παίγνια και Αποτίμηση Συνεισφοράς . . . . .       | 27        |
| 2.3.1    | Συνεργατικά παίγνια και χαρακτηριστική συνάρτηση . . . . .    | 27        |
| 2.3.2    | Το Shapley value και τα τρία αξιώματα . . . . .               | 28        |
| 2.3.3    | Υπολογιστική πολυπλοκότητα και εκτιμητές . . . . .            | 29        |
| 2.3.4    | Shapley value, SHAP και συνάρτηση αξίας . . . . .             | 30        |
| 2.3.5    | Κίνητρα συμμετοχής στην ομοσπονδιακή μάθηση . . . . .         | 32        |
| 2.4      | Σχετική Βιβλιογραφία και Τοποθέτηση της Εργασίας . . . . .    | 33        |
| 2.4.1    | Ομοσπονδιακή μάθηση για αναγνώριση δραστηριότητας . . . . .   | 33        |
| 2.4.2    | Αποτίμηση συνεισφοράς στην ομοσπονδιακή μάθηση . . . . .      | 33        |
| 2.4.3    | Το κενό της βιβλιογραφίας που καλύπτει η εργασία . . . . .    | 33        |
| <b>3</b> | <b>Δεδομένα, Έλεγχοι και Προεπεξεργασία</b>                   | <b>35</b> |
| 3.1      | Το Σύνολο Δεδομένων UCI HAR . . . . .                         | 35        |
| 3.2      | Από τα Σήματα των Αισθητήρων στα 561 Χαρακτηριστικά . . . . . | 36        |
| 3.3      | Έλεγχοι Ακεραιότητας των Δεδομένων . . . . .                  | 39        |
| 3.3.1    | Διαρροή προεπεξεργασίας στην πηγή . . . . .                   | 40        |
| 3.3.2    | Διπλότυπες στήλες . . . . .                                   | 41        |
| 3.3.3    | Επικάλυψη διαδοχικών samples . . . . .                        | 42        |
| 3.3.4    | Ανίχνευση ακραίων τιμών . . . . .                             | 43        |
| 3.4      | Διερευνητική Ανάλυση Δεδομένων . . . . .                      | 43        |
| 3.4.1    | Ισορροπία κλάσεων . . . . .                                   | 43        |
| 3.4.2    | Κατάτμηση σε συμμετέχοντες και ετερογένεια . . . . .          | 44        |
| 3.4.3    | Διαχωρισσιμότητα κλάσεων . . . . .                            | 46        |
| 3.5      | Προεπεξεργασία και Πρωτόκολλο Διαχωρισμού . . . . .           | 48        |

|          |                                                              |           |
|----------|--------------------------------------------------------------|-----------|
| <b>4</b> | <b>Υλοποίηση και Σύγκριση των Τοπολογιών Μάθησης</b>         | <b>50</b> |
| 4.1      | Οργάνωση του Λογισμικού . . . . .                            | 50        |
| 4.2      | Αρχιτεκτονική και Υπερπαράμετροι του Δικτύου . . . . .       | 51        |
| 4.3      | Οι Τρεις Τοπολογίες Μάθησης . . . . .                        | 52        |
| 4.3.1    | Κεντρική εκπαίδευση . . . . .                                | 52        |
| 4.3.2    | Ομοσπονδιακή εκπαίδευση με FedAvg . . . . .                  | 53        |
| 4.3.3    | Ατομική εκπαίδευση . . . . .                                 | 54        |
| 4.4      | Πειραματικό Πρωτόκολλο και Μετρήσεις . . . . .               | 54        |
| 4.5      | Σύγκριση του Δικτύου με Απλούστερα Μοντέλα . . . . .         | 56        |
| 4.6      | Σύγκριση των Τριών Τοπολογιών . . . . .                      | 58        |
| 4.6.1    | Κόστος της αποκέντρωσης και όφελος της συνεργασίας . . . . . | 59        |
| 4.6.2    | Διασπορά της ατομικής επίδοσης μεταξύ ανθρώπων . . . . .     | 59        |
| 4.6.3    | Τοπικές εποχές έναντι γύρων συνάθροισης . . . . .            | 61        |
| 4.7      | Ανάλυση Σφαλμάτων . . . . .                                  | 62        |
| <b>5</b> | <b>Αποτίμηση της Συνεισφοράς των Συμμετεχόντων</b>           | <b>64</b> |
| 5.1      | Το Παίγνιο ανά Γύρο Εκπαίδευσης . . . . .                    | 65        |
| 5.2      | Οι Δύο Εκτιμητές . . . . .                                   | 68        |
| 5.2.1    | KernelSHAP . . . . .                                         | 68        |
| 5.2.2    | GTG-Shapley . . . . .                                        | 69        |
| 5.2.3    | Κοινή συνάρτηση αξίας . . . . .                              | 70        |
| 5.2.4    | Καθοδηγούμενη δειγματοληψία μεταθέσεων . . . . .             | 71        |
| 5.2.5    | Επαλήθευση με πλήρη απαρίθμηση . . . . .                     | 75        |
| 5.3      | Αποτελέσματα της Αποτίμησης . . . . .                        | 76        |
| 5.3.1    | Η κατανομή των τιμών . . . . .                               | 76        |
| 5.3.2    | Συμφωνία εκτιμητών και σταθερότητα . . . . .                 | 77        |
| 5.3.3    | Υπολογιστικό κόστος . . . . .                                | 79        |
| 5.4      | Έλεγχοι των Αρνητικών Τιμών . . . . .                        | 80        |

|          |                                                                  |            |
|----------|------------------------------------------------------------------|------------|
| 5.5      | Μεγέθη που Σχετίζονται με τη Συνεισφορά . . . . .                | 82         |
| 5.5.1    | Όγκος δεδομένων, ετικέτες και ατομική επίδοση . . . . .          | 82         |
| 5.5.2    | Απόσταση κατανομής χαρακτηριστικών . . . . .                     | 82         |
| 5.5.3    | Κατεύθυνση της ενημέρωσης . . . . .                              | 84         |
| 5.6      | Επαλήθευση με Δεύτερο Παίγνιο στην Κεντρική Εκπαίδευση . . . . . | 85         |
| 5.6.1    | Ορισμός του παιχνίτου . . . . .                                  | 86         |
| 5.6.2    | Αποτελέσματα . . . . .                                           | 87         |
| 5.6.3    | Ακρίβεια της εκτίμησης . . . . .                                 | 89         |
| 5.6.4    | Συμπέρασμα . . . . .                                             | 89         |
| 5.7      | Ανάλυση Αστοχίας . . . . .                                       | 91         |
| 5.7.1    | Η αρνητική τιμή ανά γύρο . . . . .                               | 91         |
| 5.7.2    | Η αρνητική τιμή ανά δραστηριότητα . . . . .                      | 93         |
| 5.7.3    | Η αρνητική τιμή ανά άτομο της αξιολόγησης . . . . .              | 96         |
| 5.7.4    | Το πείραμα αφαίρεσης . . . . .                                   | 98         |
| 5.7.5    | Αποτελέσματα της αφαίρεσης . . . . .                             | 100        |
| 5.7.6    | Συμπέρασμα . . . . .                                             | 102        |
| 5.8      | Μερίδια Ανταμοιβής . . . . .                                     | 103        |
| 5.8.1    | Πολιτικές μεριδίων . . . . .                                     | 103        |
| 5.8.2    | Αφινική μετατόπιση και εκθετική κατανομή . . . . .               | 104        |
| 5.8.3    | Συνεισφορά και μερίδιο κάθε συμμετέχοντα . . . . .               | 106        |
| <b>6</b> | <b>Συμπεράσματα και Μελλοντική Εργασία</b>                       | <b>108</b> |
| 6.1      | Απαντήσεις στα Ερευνητικά Ερωτήματα . . . . .                    | 108        |
| 6.2      | Περιορισμοί της Εργασίας . . . . .                               | 111        |
| 6.3      | Κατευθύνσεις για Μελλοντική Εργασία . . . . .                    | 112        |
|          | <b>Βιβλιογραφία</b>                                              | <b>114</b> |

## Κατάλογος Σχημάτων

|                                                                  |    |
|------------------------------------------------------------------|----|
| 2.1 Ένας γύρος του FedAvg . . . . .                              | 25 |
| 2.2 Το Shapley value ως μέσος όρος σειρών άφιξης . . . . .       | 29 |
| 3.1 Από τα σήματα στα χαρακτηριστικά . . . . .                   | 37 |
| 3.2 Κατανομή δραστηριοτήτων ανά συμμετέχοντα . . . . .           | 45 |
| 3.3 Διαχωριστικότητα των έξι δραστηριοτήτων . . . . .            | 47 |
| 3.4 Κίνηση έναντι βαρύτητας ανά δραστηριότητα . . . . .          | 48 |
| 3.5 Ο αγωγός από τους εθελοντές στους συμμετέχοντες . . . . .    | 49 |
| 4.1 Η οργάνωση του λογισμικού . . . . .                          | 51 |
| 4.2 Το δίκτυο ANN απέναντι στη λογιστική παλινδρόμηση . . . . .  | 57 |
| 4.3 Καμπύλες μάθησης . . . . .                                   | 60 |
| 4.4 Οι τρεις τοπολογίες και η διασπορά μεταξύ ανθρώπων . . . . . | 60 |
| 4.5 Τοπικές εποχές έναντι γύρων . . . . .                        | 61 |
| 4.6 Πίνακας σύγκρισης της ομοσπονδιακής τοπολογίας . . . . .     | 62 |
| 5.1 Πώς αποτιμάται ένας συνασπισμός . . . . .                    | 66 |
| 5.2 Η ροή της αποτίμησης στο ομοσπονδιακό παίγνιο . . . . .      | 72 |
| 5.3 Συνεισφορά ανά συμμετέχοντα . . . . .                        | 77 |
| 5.4 Συμφωνία εκτιμητών και ο όγκος ως υποκατάστατο . . . . .     | 78 |
| 5.5 Σύγκλιση των εκτιμητών ανά γύρο . . . . .                    | 79 |
| 5.6 Τα δύο παίγνια . . . . .                                     | 86 |
| 5.7 Η ροή της αποτίμησης στο παίγνιο επανεκπαίδευσης . . . . .   | 88 |

|      |                                                            |     |
|------|------------------------------------------------------------|-----|
| 5.8  | Η κατάταξη στα δύο παίγνια . . . . .                       | 88  |
| 5.9  | Πότε εμφανίζεται η αρνητική συνεισφορά . . . . .           | 92  |
| 5.10 | Συνεισφορά ανά δραστηριότητα . . . . .                     | 95  |
| 5.11 | Η μήτρα συνεισφοράς ανά άτομο αξιολόγησης . . . . .        | 97  |
| 5.12 | Ο σχεδιασμός που αποφεύγει την κυκλικότητα . . . . .       | 99  |
| 5.13 | Αφαίρεση των αρνητικών συμμετεχόντων . . . . .             | 100 |
| 5.14 | Καμπύλες αφαίρεσης από τα δύο άκρα της κατάταξης . . . . . | 102 |
| 5.15 | Μερίδια ανά πολιτική . . . . .                             | 104 |

## Κατάλογος Πινάκων

|      |                                                                  |     |
|------|------------------------------------------------------------------|-----|
| 2.1  | Τα μέτρα συσχέτισης και συμφωνίας κατάταξης . . . . .            | 24  |
| 3.1  | Πώς διαβάζεται το όνομα ενός χαρακτηριστικού . . . . .           | 38  |
| 3.2  | Τρεις γραμμές του συνόλου εκπαίδευσης . . . . .                  | 39  |
| 3.3  | Η κλίμακα των δεδομένων πριν και μετά την τυπικοποίηση . . . . . | 41  |
| 4.1  | Το δίκτυο ANN απέναντι σε τρία απλούστερα μοντέλα . . . . .      | 56  |
| 4.2  | Σύγκριση των τριών τοπολογιών μάθησης . . . . .                  | 58  |
| 5.1  | Το SHAP απέναντι στην αποτίμηση αυτής της εργασίας . . . . .     | 68  |
| 5.2  | Τυχαία έναντι καθοδηγούμενης δειγματοληψίας μεταθέσεων . . . . . | 74  |
| 5.3  | Σύγκριση του KernelSHAP με το ακριβές Shapley . . . . .          | 76  |
| 5.4  | Οι τρεις εκτιμητές στα 20 seeds . . . . .                        | 78  |
| 5.5  | Τα μεγέθη που σχετίζονται με τη συνεισφορά . . . . .             | 85  |
| 5.6  | Τα δύο παίγνια με μια ματιά . . . . .                            | 90  |
| 5.7  | Η μήτρα ανά δραστηριότητα σε αριθμούς . . . . .                  | 95  |
| 5.8  | Αφαίρεση των αρνητικών συμμετεχόντων . . . . .                   | 101 |
| 5.9  | Πολιτικές κατανομής μεριδίων . . . . .                           | 103 |
| 5.10 | Συνεισφορά και μερίδια ανά συμμετέχοντα . . . . .                | 107 |

# Κατάλογος Συντομογραφιών

| Συντομογραφία                       | Ανάπτυξη                                              | Απόδοση στα ελληνικά                                                                         |
|-------------------------------------|-------------------------------------------------------|----------------------------------------------------------------------------------------------|
| <b>Adam</b>                         | Adaptive Moment Estimation                            | ο βελτιστοποιητής της εκπαίδευσης                                                            |
| <b>ANN</b>                          | Artificial Neural Network                             | τεχνητό νευρωνικό δίκτυο                                                                     |
| <b>CPU</b>                          | Central Processing Unit                               | κεντρική μονάδα επεξεργασίας                                                                 |
| <b>F1</b>                           | F1-score                                              | αρμονικός μέσος ακρίβειας και ανάκλησης<br>(το macro-F1 είναι ο μέσος όρος του στις κλάσεις) |
| <b>FedAvg</b>                       | Federated Averaging                                   | ο αλγόριθμος συνάθροισης των ενημερώσεων                                                     |
| <b>FL</b>                           | Federated Learning                                    | ομοσπονδιακή μάθηση                                                                          |
| <b>GTG</b>                          | Guided Truncation Gradient (GTG-Shapley)              | εκτιμητής των τιμών Shapley με αποκοπή                                                       |
| <b>GTG-Tib</b>                      | GTG-Shapley with within- and between-round truncation | η παραλλαγή του GTG-Shapley χωρίς την καθοδηγούμενη δειγματοληψία                            |
| <b>HAR</b>                          | Human Activity Recognition                            | αναγνώριση ανθρώπινης δραστηριότητας                                                         |
| <b>IID</b>                          | Independent and Identically Distributed               | ανεξάρτητα και ισόνομα κατανεμημένα                                                          |
| <b>MLP</b>                          | Multilayer Perceptron                                 | δίκτυο εμπρόσθιας τροφοδότησης                                                               |
| <b>MR</b>                           | Multi-Round (evaluation)                              | αποτίμηση ανά γύρο και άθροισμα των γύρων                                                    |
| <b>PCA</b>                          | Principal Component Analysis                          | ανάλυση κύριων συνιστωσών                                                                    |
| <b>ReLU</b>                         | Rectified Linear Unit                                 | συνάρτηση ενεργοποίησης που μηδενίζει τις αρνητικές τιμές                                    |
| <b>SHA-256</b>                      | Secure Hash Algorithm, 256 bit                        | συνάρτηση κατακερματισμού (αθροίσματα ελέγχου)                                               |
| <b>SHAP</b>                         | SHapley Additive exPlanations                         | μέθοδος ερμηνείας με τιμές Shapley και η βιβλιοθήκη shap που την υλοποιεί                    |
| <b>SVM</b>                          | Support Vector Machine                                | μηχανή διανυσμάτων υποστήριξης                                                               |
| <b>TV</b>                           | Total Variation (distance)                            | απόσταση ολικής μεταβολής                                                                    |
| <b>UCI</b>                          | University of California, Irvine                      | το αποθετήριο του συνόλου δεδομένων τυπική απόκλιση                                          |
| <b>τ.α.</b>                         |                                                       |                                                                                              |
| Ετικέτες δραστηριοτήτων στα σχήματα |                                                       |                                                                                              |
| <b>WALK</b>                         | WALKING                                               | βάδισμα                                                                                      |
| <b>W.UP</b>                         | WALKING_UPSTAIRS                                      | ανάβαση σκάλας                                                                               |
| <b>W.DOWN</b>                       | WALKING_DOWNSTAIRS                                    | κατάβαση σκάλας                                                                              |
| <b>SIT</b>                          | SITTING                                               | καθιστή στάση                                                                                |
| <b>STAND</b>                        | STANDING                                              | όρθια στάση                                                                                  |
| <b>LAY</b>                          | LAYING                                                | κατάκλιση                                                                                    |

# Κεφάλαιο 1

## Εισαγωγή

### 1.1 Αναγνώριση Δραστηριότητας, Ιδιωτικότητα και Ομοσπονδιακή Μάθηση

Η αναγνώριση ανθρώπινης δραστηριότητας (*Human Activity Recognition*, HAR) από αισθητήρες κινητών συσκευών είναι σήμερα ένα ώριμο πεδίο. Το επιταχυνσιόμετρο και το γυροσκόπιο ενός συνηθισμένου έξυπνου κινητού τηλεφώνου αρκούν, για να διακριθούν βασικές δραστηριότητες, όπως το βάδισμα, η ανάβαση σκάλας ή η καθιστή στάση [1]. Η βιβλιογραφία διαθέτει, επίσης, τόσο καθιερωμένα σύνολα δεδομένων όσο και εκτενείς ανασκοπήσεις των μεθόδων που χρησιμοποιούνται [1], [2]. Οι εφαρμογές εκτείνονται από τα έξυπνα σπίτια και την υγειονομική περίθαλψη μέχρι τη βιομηχανική παραγωγή [2].

Η ίδια η φύση αυτών των δεδομένων, όμως, δημιουργεί ένα πρόβλημα που δε λύνεται με καλύτερο μοντέλο. Ένα ίχνος επιτάχυνσης δεν είναι ανώνυμο αλλά καταγράφει πότε κινείται κανείς, πόσο συχνά σηκώνεται και με τι ρυθμό περπατά. Η κλασική συνταγή της μηχανικής μάθησης, δηλαδή η συγκέντρωση όλων των δεδομένων σε έναν εξυπηρετητή και η εκπαίδευση εκεί, απαιτεί ακριβώς τη μεταφορά αυτής της πληροφορίας έξω από τη συσκευή του χρήστη. Οι McMahan et al. επισημαίνουν ρητά το εμπόδιο, σημειώνοντας ότι τα δεδομένα αυτά είναι συχνά ευαίσθητα ως προς την ιδιωτικότητα, μεγάλα σε όγκο ή και τα δύο, πράγμα που μπορεί να καθιστά απαγορευτική την καταγραφή τους σε κέντρο δεδομένων και την εκεί εκπαίδευση [3].

Η ομοσπονδιακή μάθηση (*Federated Learning*, FL) προτάθηκε ως απάντηση σε αυτό ακριβώς το εμπόδιο. Αντί να ταξιδεύουν τα δεδομένα προς το μοντέλο, ταξιδεύει το μοντέλο προς τα δεδομένα. Κάθε συμμετέχων εκπαιδεύει τοπικά ένα αντίγραφο, στέλνει πίσω μόνο την ενημέρωση των παραμέτρων και στη συνέχεια ένας εξυπηρετητής συνθέτει τις ενημερώσεις σε ένα κοινό μοντέλο [3]. Το πεδίο έχει έκτοτε ωριμάσει σε αυτόνομη ερευνητική κατεύθυνση, με καταγεγραμμένες τις ανοιχτές του προκλήσεις σε ετερογένεια, επικοινωνία και ιδιωτικότητα [4]. Η παρούσα εργασία τοποθετείται σε αυτό το πλαίσιο, με τα υποκείμενα ενός συνόλου δεδομένων HAR στον ρόλο των συμμετεχόντων.

## 1.2 Το Πρόβλημα της Αποτίμησης της Συνεισφοράς

Η αποκέντρωση λύνει ένα πρόβλημα και δημιουργεί ένα δεύτερο. Όταν ο εξυπηρετητής δε βλέπει ποτέ τα δεδομένα, δεν μπορεί και να τα κρίνει. Δεν ξέρει ποιος συνεισέφερε πληροφορία που βελτίωσε πραγματικά το κοινό μοντέλο, ποιος επανέλαβε ό,τι υπήρχε ήδη και ποιος το τράβηξε προς λάθος κατεύθυνση. Το μόνο που βλέπει είναι ένα διάνυσμα παραμέτρων ανά γύρο.

Αυτό δεν είναι απλώς ένα λογιστικό κενό. Η συμμετοχή σε μια ομοσπονδία έχει κόστος για τον συμμετέχοντα, σε ενέργεια, σε υπολογιστικούς πόρους, σε εύρος ζώνης και στον χρόνο κατά τον οποίο η συσκευή απασχολείται. Η βιβλιογραφία των μηχανισμών κινήτρων ξεκινά από την παρατήρηση ότι, χωρίς κάποια μορφή αποζημίωσης ή αναγνώρισης, οι κάτοχοι δεδομένων δεν έχουν λόγο να συμμετέχουν και η επίδοση του συστήματος υποβαθμίζεται όταν οι πόροι δεν επαρκούν [5]. Κάθε τέτοιος μηχανισμός, όποια μορφή και αν πάρει, προϋποθέτει ένα μέτρο, δηλαδή κάποιον τρόπο να αποδοθεί σε κάθε συμμετέχοντα ένας αριθμός που να αντιστοιχεί στη συνεισφορά του. Μια δεύτερη ανασκόπηση καταγράφει ως τέτοια μέτρα τον όγκο δεδομένων, τους διαθέσιμους υπολογιστικούς πόρους και το Shapley value [6].

Αντικείμενο της εργασίας είναι αυτό το μέτρο, όχι ο μηχανισμός που θα χτιζόταν πάνω του. Συγκεκριμένα, η εργασία εξετάζει αν η συνεισφορά κάθε συμμετέχοντα σε μια ομοσπονδιακή εκπαίδευση HAR μπορεί να αποτιμηθεί, με μια θεμελιωμένη έννοια της θεωρίας συνεργατικών παιγνίων, σε υπολογιστικό κόστος που να επιτρέπει την πραγματική εκτέλεση. Εξετάζει, επίσης, τι λέει το αποτέλεσμα για τους ίδιους τους ανθρώπους πίσω από τα δεδομένα.

## 1.3 Ερευνητικά Ερωτήματα

Η εργασία οργανώνεται γύρω από τρία ερωτήματα, καθένα από τα οποία απαντάται ρητά στην Ενότητα 6.1.

1. **Τι κοστίζει η ομοσπονδιακή εκπαίδευση σε ορθότητα;** Η σύγκριση γίνεται με δύο σημεία αναφοράς. Το πρώτο είναι η κεντρική εκπαίδευση, όπου όλα τα δεδομένα είναι διαθέσιμα μαζί. Το δεύτερο είναι η ατομική εκπαίδευση, όπου κάθε συμμετέχων μένει μόνος με τα δικά του. Οι τρεις αυτές ρυθμίσεις ονομάζονται στο εξής *τοπολογίες μάθησης*.
2. **Αποτιμάται η συνεισφορά κάθε συμμετέχοντα με Shapley σε ρεαλιστικό υπολογιστικό κόστος;** Ο ακριβής υπολογισμός είναι εκθετικός ως προς το πλήθος των παικτών. Το ερώτημα είναι αν οι διαθέσιμοι εκτιμητές δίνουν σταθερό και επαληθεύσιμο αποτέλεσμα στο μέγεθος παιγνίου της εργασίας.

3. **Τι σημαίνει αρνητική συνεισφορά;** Το ερώτημα έχει δύο μέρη. Το πρώτο είναι *τι ξεχωρίζει* τους συμμετέχοντες που λαμβάνουν αρνητική τιμή. Το δεύτερο, το οποίο είναι και το κρισιμότερο για κάθε πρακτική χρήση, είναι αν η τιμή αυτή είναι *αξιοποιήσιμη*. Με άλλα λόγια, το δεύτερο μέρος διερευνά αν η αρνητική συνεισφορά αποτυπώνει ιδιότητα των δεδομένων ενός ανθρώπου, η οποία μεταφέρεται εκτός του συνόλου στο οποίο μετρήθηκε, ή ιδιότητα του τρόπου με τον οποίο οι ενημερώσεις συναθροίζονται.

## 1.4 Συνεισφορά της Εργασίας

Η εργασία συνεισφέρει σε δύο σημεία.

1. **Μια ελεγχόμενη σύγκριση τριών τοπολογιών μάθησης.** Η κεντρική, η ομοσπονδιακή και η ατομική εκπαίδευση συγκρίνονται, ενώ όλες οι υπόλοιπες επιλογές μένουν κοινές, δηλαδή το ίδιο μοντέλο, ο ίδιος βρόχος εκπαίδευσης και το ίδιο σύνολο αξιολόγησης. Έτσι, κάθε διαφορά μπορεί να αποδοθεί στον τρόπο εκπαίδευσης. Η σύγκριση δείχνει τι κοστίζει η αποκέντρωση και τι κερδίζει κάθε συμμετέχων από τη συνεργασία. Τα αποτελέσματα παρουσιάζονται στο Κεφάλαιο 4.
2. **Η αποτίμηση της συνεισφοράς κάθε συμμετέχοντα και η ανάλυση των αρνητικών τιμών.** Η συνεισφορά αποτιμάται με το Shapley value, με δύο ανεξάρτητους εκτιμητές που ελέγχονται μεταξύ τους και απέναντι στον ορισμό. Όπου η συνεισφορά βγαίνει αρνητική, ελέγχεται πρώτα ότι το γεγονός αυτό δεν οφείλεται σε σφάλμα εκτίμησης. Στη συνέχεια, ένα δεύτερο παίγνιο επαληθεύει αν η αρνητική συνεισφορά πηγάζει από τα δεδομένα των συμμετεχόντων ή από τη συνάθροιση των ενημερώσεων. Η ανάλυση αστοχίας (*failure analysis*) εξετάζει έπειτα πότε και πού εμφανίζεται η αρνητική τιμή και αν μπορεί να χρησιμοποιηθεί ως κριτήριο απόφασης. Τα αποτελέσματα παρουσιάζονται στο Κεφάλαιο 5.

## 1.5 Διάρθρωση της Εργασίας

Η διάρθρωση ακολουθεί τον οδηγό συγγραφής της ερευνητικής μονάδας Euclid [7]. Στο Κεφάλαιο 2 αναπτύσσεται το υπόβαθρο της εργασίας, δηλαδή τα πολυεπίπεδα δίκτυα εμπρόσθιας τροφοδότησης, οι μετρικές αξιολόγησης, τα μέτρα συσχέτισης, η ομοσπονδιακή μάθηση, ο FedAvg και η θεωρία συνεργατικών παιγνίων, πάνω στην οποία εδράζεται η αποτίμηση συνεισφοράς. Στο τέλος του κεφαλαίου παρουσιάζονται η σχετική βιβλιογραφία και τα σημεία διαφοροποίησης της εργασίας από αυτήν.

Στο Κεφάλαιο 3 εισάγεται η έννοια της αναγνώρισης δραστηριότητας από αισθητήρες και παρουσιάζονται το σύνολο δεδομένων, οι έλεγχοι ακεραιότητας, η διερευνητική ανάλυση και το πρωτόκολλο προεπεξεργασίας. Στο Κεφάλαιο 4 περιγράφονται η υλοποίηση, το μοντέλο και το πειραματικό πρωτόκολλο, συγκρίνονται οι τρεις τοπολογίες μάθησης και αναλύονται τα σφάλματα του μοντέλου. Στο Κεφάλαιο 5 αναπτύσσεται η αποτίμηση συνεισφοράς. Αρχικά ορίζεται το παίγνιο και παρουσιάζονται οι εκτιμητές. Έπονται οι αρνητικές τιμές και η ανάλυσή τους, ενώ στο τέλος υπολογίζονται τα μερίδια ανταμοιβής. Το Κεφάλαιο 6 αποτελεί σύνοψη, στην οποία δηλώνονται οι περιορισμοί και προτείνονται κατευθύνσεις συνέχειας.

## Κεφάλαιο 2

### Θεωρητικό Υπόβαθρο

Το κεφάλαιο αυτό εστιάζει αποκλειστικά στο θεωρητικό υπόβαθρο που χρειάζεται η υπόλοιπη εργασία. Ξεκινά παρουσιάζοντας το είδος του νευρωνικού δικτύου που χρησιμοποιείται, τις μετρικές με τις οποίες αποτιμάται και τα μέτρα συσχέτισης της ανάλυσης, συνεχίζει με την ομοσπονδιακή μάθηση και καταλήγει στη θεωρία των συνεργατικών παιγνίων, στην οποία θεμελιώνεται το μέτρο συνεισφοράς του Κεφαλαίου 5. Στην τελευταία ενότητα παρουσιάζονται η σχετική βιβλιογραφία και τα σημεία διαφοροποίησης της εργασίας από αυτήν.

#### 2.1 Πολυεπίπεδα Δίκτυα Εμπρόσθιας Τροφοδότησης

##### 2.1.1 Δομή, εκπαίδευση και κανονικοποίηση

Ένα πολυεπίπεδο δίκτυο εμπρόσθιας τροφοδότησης (*multilayer perceptron*, MLP) μετατρέπει ένα διάνυσμα εισόδου σε μια πρόβλεψη μέσα από διαδοχικά επίπεδα. Κάθε επίπεδο παίρνει την έξοδο του προηγούμενου, σχηματίζει σταθμισμένα αθροίσματά της και εφαρμόζει στο αποτέλεσμα μια μη γραμμική συνάρτηση ενεργοποίησης. Τα βάρη αυτών των αθροισμάτων είναι οι παράμετροι που μαθαίνει το δίκτυο. Η μη γραμμικότητα είναι απαραίτητη, γιατί χωρίς αυτήν πολλά επίπεδα στη σειρά θα ισοδυναμούσαν με ένα μόνο γραμμικό επίπεδο. Μια συνηθισμένη επιλογή είναι η ReLU, που μηδενίζει τις αρνητικές τιμές και αφήνει τις θετικές ανέπαφες [8].

Σε πρόβλημα ταξινόμησης, το τελευταίο επίπεδο δίνει μία τιμή για κάθε κλάση και η συνάρτηση *softmax* τις μετατρέπει σε πιθανότητες που αθροίζονται στη μονάδα. Η εκπαίδευση προσαρμόζει τα βάρη, ώστε να μεγιστοποιείται η πιθανότητα σωστής κλάσης, ελαχιστοποιώντας τη διασταυρούμενη εντροπία (*cross-entropy*) [8]. Για να γίνει αυτό, υπολογίζεται πώς μεταβάλλεται το σφάλμα ως προς κάθε βάρος με οπισθοδιάδοση (*back-propagation*), από την έξοδο προς την είσοδο [8]. Στη συνέχεια, τα βάρη μετακινούνται λίγο προς την κατεύθυνση που μειώνει το σφάλμα. Ο αλγόριθμος Adam, που χρησιμοποιείται σε αυτήν την εργασία, προσαρμόζει το μέγεθος αυτού του βήματος, χωριστά για κάθε παράμετρο [9].

Ένα δίκτυο με πολλές παραμέτρους μπορεί να απομνημονεύσει τα δεδομένα εκπαίδευσης, αντί να μάθει κάτι που γενικεύεται. Μια απλή άμυνα είναι το *dropout*, που κατά την εκπαίδευση απενεργοποιεί τυχαία ένα μέρος των μονάδων σε κάθε πέρασμα, ώστε καμία να μη στηρίζεται υπερβολικά σε συγκεκριμένες άλλες [10]. Κατά την αξιολόγηση, χρησιμοποιείται ολόκληρο το δίκτυο. Η αρχιτεκτονική που χρησιμοποιείται και οι τιμές των παραμέτρων της δίνονται στην Ενότητα 4.2.

### 2.1.2 Μετρικές αξιολόγησης ταξινόμησης

Η βάση κάθε μετρικής ταξινόμησης είναι ο *πίνακας σύγχυσης* (*confusion matrix*)  $C$ , όπου το στοιχείο  $C_{ij}$  μετράει πόσα samples πραγματικής κλάσης  $i$  ταξινομήθηκαν ως κλάση  $j$  [11]. Τα διαγώνια στοιχεία είναι οι σωστές προβλέψεις και όλα τα υπόλοιπα είναι λάθη. Η θέση κάθε λάθους αποτυπώνει ποιο ακριβώς ζεύγος κλάσεων συγχέεται και γι' αυτό ο πίνακας αυτός διαβάζεται και ανεξάρτητα, όχι μόνο μέσα από τις παραγόμενες μετρικές ταξινόμησης.

Η *ορθότητα* (*accuracy*) είναι το κλάσμα των σωστών προβλέψεων προς το σύνολο:

$$\text{Acc} = \frac{\sum_{i=1}^K C_{ii}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}, \quad (2.1)$$

όπου  $K$  το πλήθος των κλάσεων. Κινείται στο  $[0, 1]$  και όσο μεγαλύτερη τόσο καλύτερα. Το μειονέκτημά της είναι το γεγονός ότι μετράει samples και όχι κλάσεις, οπότε μια κλάση με λίγα samples μπορεί να ταξινομείται συστηματικά λάθος, χωρίς η ορθότητα να το επισημάνει.

Για να αναδειχθεί τι συμβαίνει σε κάθε κλάση χωριστά, χρησιμοποιούνται δύο μεγέθη. Η *ακρίβεια* (*precision*) της κλάσης  $i$  είναι το ποσοστό των προβλέψεων υπέρ της  $i$  που ήταν σωστές. Η *ανάκληση* (*recall*) είναι το ποσοστό των samples της  $i$  που βρέθηκαν:

$$P_i = \frac{C_{ii}}{\sum_{j=1}^K C_{ji}}, \quad R_i = \frac{C_{ii}}{\sum_{j=1}^K C_{ij}}. \quad (2.2)$$

Και τα δύο έχουν στον αριθμητή τις σωστές προβλέψεις της κλάσης ( $C_{ii}$ ) και διαφέρουν μόνο στον παρονομαστή. Η ακρίβεια διαιρεί με το άθροισμα της στήλης  $i$ , δηλαδή με όσα samples το μοντέλο *ονόμασε*  $i$ . Επομένως, «τιμωρεί» τους ψευδείς συναγερμούς. Η ανάκληση διαιρεί με το άθροισμα της γραμμής  $i$ , δηλαδή με όσα samples *ήταν*  $i$ . Έτσι, «τιμωρεί» τις παραλείψεις. Ένα μοντέλο που σπάνια προβλέπει την κλάση  $i$  μπορεί να έχει υψηλή ακρίβεια και χαμηλή ανάκληση, ενώ ένα μοντέλο που την προβλέπει πολύ συχνά μπορεί να έχει χαμηλή ακρίβεια και υψηλή ανάκληση.

Το *F1-score* ενώνει τα δύο σε έναν αριθμό, ως αρμονικό τους μέσο:

$$F_{1,i} = \frac{2 P_i R_i}{P_i + R_i}. \quad (2.3)$$

Ο αρμονικός μέσος προτιμάται από τον αριθμητικό, γιατί καθορίζεται κυρίως από τον μικρότερο από τους δύο όρους. Με ακρίβεια 100% και ανάκληση 10%, για παράδειγμα, ο αριθμητικός μέσος θα ήταν 55%, ενώ το F1 είναι περίπου 18%. Μια κλάση δε σημειώνει, επομένως, καλό F1, αν αποτυγχάνει σε ένα από τα δύο. Το *macro-F1* είναι ο απλός μέσος όρος των  $F_{1,i}$  της Εξίσωσης (2.3) πάνω στις  $K$  κλάσεις [12],

$$F_1^M = \frac{1}{K} \sum_{i=1}^K F_{1,i}, \quad (2.4)$$

οπότε κάθε κλάση μετράει το ίδιο, ανεξάρτητα από το πόσα samples έχει [11].

Στη συγκεκριμένη εργασία, κύρια μετρική είναι η ορθότητα. Το macro-F1 αναφέρεται δίπλα της για δύο λόγους. Ο πρώτος είναι ότι μια υψηλή ορθότητα μπορεί να κρύβει μια κλάση που ταξινομείται συστηματικά λάθος, ενώ το macro-F1 θα την έδειχνε. Όταν οι δύο μετρικές δίνουν σχεδόν την ίδια τιμή, αυτό είναι ένδειξη ότι καμία κλάση δε μένει πίσω. Όταν αποκλίνουν, η απόκλιση δείχνει ότι κάποια κλάση υστερεί. Ο δεύτερος λόγος αφορά την αποτίμηση της συνεισφοράς, όπου η συνάρτηση αξίας είναι η ίδια μια μετρική. Οι Sokolova και Lapalme ονομάζουν μια μετρική αμετάβλητη, ως προς μια αλλαγή του πίνακα σύγχυσης, όταν η τιμή της δεν τροποποιείται, δηλαδή όταν *δεν ανιχνεύει* την αλλαγή [11]. Η ορθότητα είναι αμετάβλητη σε ανακατανομές μεταξύ κλάσεων, ενώ η ακρίβεια, η ανάκληση και το F1 είναι ευαίσθητα στην ασυμμετρία της ταξινόμησης [11]. Γι' αυτό η αποτίμηση επαναλαμβάνεται και με το macro-F1, ώστε να φανεί αν τα συμπεράσματα εξαρτώνται από την επιλογή της μετρικής (Κεφάλαιο 5).

Ο υπολογισμός των μετρικών στην υλοποίηση γίνεται με τη βιβλιοθήκη scikit-learn [13].

### 2.1.3 Μέτρα συσχέτισης και συμφωνίας κατάταξης

Τα μέτρα συσχέτισης συγκρίνουν δύο σειρές μετρήσεων  $x_1, \dots, x_m$  και  $y_1, \dots, y_m$ , όπου το  $x_i$  και το  $y_i$  αφορούν το ίδιο αντικείμενο  $i$ . Οι τρεις συντελεστές που ακολουθούν μετρούν, ο καθένας με διαφορετικό κριτήριο, πόσο κινούνται μαζί οι δύο σειρές και παίρνουν τιμές από  $-1$  έως  $+1$ . Η τιμή  $r$  συνοδεύει έναν συντελεστή και δείχνει αν η σχέση που μετρήθηκε θα μπορούσε να οφείλεται σε τύχη.

Ο συντελεστής *Pearson*  $r$  μετρά πόσο κοντά σε μια ευθεία βρίσκονται τα σημεία  $(x_i, y_i)$ , δηλαδή αν οι τιμές της μίας σειράς μεταβάλλονται αναλογικά με τις τιμές της άλλης. Ορίζεται ως

$$r = \frac{\sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^m (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^m (y_i - \bar{y})^2}}, \quad (2.5)$$

όπου  $\bar{x}$  και  $\bar{y}$  οι μέσοι όροι των δύο σειρών. Ο αριθμητής αθροίζει γινόμενα αποκλίσεων από τον μέσο όρο. Ένας όρος του είναι θετικός, όταν το  $x_i$  και το  $y_i$  βρίσκονται από την ίδια πλευρά του μέσου όρου τους. Όταν βρίσκονται από αντίθετες πλευρές, είναι αρνητικός. Ο παρονομαστής διαιρεί με το μέγεθος των αποκλίσεων, ώστε το  $r$  να μην εξαρτάται από τις μονάδες μέτρησης. Στο  $+1$  όλα τα σημεία πέφτουν πάνω σε μια ανοδική ευθεία, στο  $-1$  πάνω σε μια καθοδική και στο  $0$  δεν υπάρχει γραμμική σχέση. Για τις σειρές  $x = (1, 2, 3, 4)$  και  $y = (2, 4, 6, 8)$ , για παράδειγμα,  $r = 1$ , αφού κάθε  $y_i$  είναι διπλάσιο του  $x_i$ . Το τετράγωνο  $r^2$  είναι το ποσοστό της διακύμανσης της μίας σειράς που εξηγεί η γραμμική σχέση με την άλλη. Με  $r = 0,5$  εξηγείται το 25% της διακύμανσης και το 75% μένει ανεξήγητο.

Ο συντελεστής *Spearman*  $\rho$  μετρά αν η μία σειρά ανεβαίνει κάθε φορά που ανεβαίνει η άλλη, ακόμη κι αν η σχέση τους δεν είναι ευθεία. Κάθε τιμή αντικαθίσταται από τη θέση της μέσα στη σειρά της (1 για τη μικρότερη, 2 για την επόμενη κ.ο.κ.) και η Εξίσωση (2.5) εφαρμόζεται στις θέσεις. Όταν δεν υπάρχουν ίσες τιμές, το αποτέλεσμα γράφεται ως

$$\rho = 1 - \frac{6 \sum_{i=1}^m d_i^2}{m(m^2 - 1)}, \quad (2.6)$$

όπου  $d_i$  η διαφορά των θέσεων του αντικειμένου  $i$  στις δύο σειρές. Όταν οι θέσεις ταυτίζονται, όλα τα  $d_i$  είναι μηδέν και  $\rho = 1$ . Ο αριθμητής μεγαλώνει όσο απομακρύνονται οι θέσεις και ο παρονομαστής είναι τέτοιος, ώστε  $\rho = -1$ , όταν η μία σειρά είναι η αντίστροφη της άλλης. Για τις σειρές  $x = (1, 2, 3, 4)$  και  $y = (1, 2, 4, 16)$ , το  $y$  ανεβαίνει πάντα μαζί με το  $x$  και μάλιστα όλο και πιο απότομα. Οι θέσεις είναι ίδιες και στις δύο σειρές, οπότε  $\rho = 1$ , ενώ  $r \approx 0,87$ , αφού τα σημεία δε βρίσκονται σε ευθεία.

Ο συντελεστής *Kendall*  $\tau$  μετρά συμφωνία κατάταξης και όχι τιμών. Εξετάζει όλα τα ζεύγη αντικειμένων. Ένα ζεύγος είναι *σύμφωνο*, όταν οι δύο σειρές βάζουν τα δύο αντικείμενα με την ίδια σειρά. Αν τα βάζουν με αντίθετη σειρά, είναι *ασύμφωνο*. Ο συντελεστής ορίζεται ως

$$\tau = \frac{(\text{σύμφωνα}) - (\text{ασύμφωνα})}{\binom{m}{2}}, \quad (2.7)$$

όπου  $\binom{m}{2} = m(m-1)/2$  το πλήθος των ζευγών. Ένα ζεύγος με ίσες τιμές σε μία από τις δύο σειρές δεν είναι ούτε σύμφωνο ούτε ασύμφωνο. Η τιμή κινείται από  $-1$ , όταν η μία κατάταξη είναι η αντίστροφη της άλλης, έως  $+1$ , όταν οι δύο κατατάξεις ταυτίζονται. Στο  $0$  τα σύμφωνα και τα ασύμφωνα ζεύγη είναι ισάριθμα. Όταν δεν υπάρχουν ίσες τιμές, το  $(1 + \tau)/2$  είναι το ποσοστό των σύμφωνων ζευγών, οπότε ένα  $\tau = 0,9$  σημαίνει ότι το 95% των ζευγών έχει την ίδια σειρά και στις δύο κατατάξεις. Αν, για παράδειγμα, δύο κριτές κατατάσσουν τρεις υποψηφίους ως (A, B, Γ) και (A, Γ, B), από τα τρία ζεύγη τα δύο είναι σύμφωνα (A με B και A με Γ) και το ένα ασύμφωνο (B με Γ), οπότε  $\tau = (2 - 1)/3 \approx 0,33$ . Όσο μεγαλώνει το  $m$ , τόσο λιγότερο μετρά κάθε ασύμφωνο ζεύγος. Με  $m = 21$  υπάρχουν  $\binom{21}{2} = 210$  ζεύγη και κάθε ασύμφωνο ζεύγος μειώνει το  $\tau$  κατά  $2/210 \approx 0,0095$  από το  $+1$ .

Η τιμή  $p$  συνοδεύει έναν συντελεστή  $c$ , δηλαδή ένα  $r$ , ένα  $\rho$  ή ένα  $\tau$ . Είναι η πιθανότητα να μετρηθεί συσχέτιση τουλάχιστον τόσο ισχυρή όσο η μετρημένη, αν οι δύο σειρές δεν είχαν στην πραγματικότητα καμία σχέση,

$$p = \Pr(|c_0| \geq |c|), \quad (2.8)$$

όπου  $c_0$  ο ίδιος συντελεστής για δύο ανεξάρτητες σειρές με το ίδιο πλήθος  $m$ . Μικρό  $p$  σημαίνει ότι μια τέτοια συσχέτιση δύσκολα θα προέκυπτε από τύχη. Συνήθως, ως όριο στατιστικής σημαντικότητας θεωρείται το  $p < 0,05$ , δηλαδή λιγότερο από μία πιθανότητα στις είκοσι. Το πόσο ισχυρή πρέπει να είναι μια συσχέτιση για να περάσει το όριο εξαρτάται από το  $m$ . Με  $m = 21$  χρειάζεται  $|r|$  μεγαλύτερο από 0,43 περίπου, ενώ με  $m = 100$  αρκεί  $|r|$  μεγαλύτερο από 0,20. Το  $p$  δεν είναι, επομένως, μέτρο της έντασης της σχέσης. Ούτε αποδεικνύει αιτία, αφού δύο σειρές μπορεί να κινούνται μαζί, επειδή εξαρτώνται και οι δύο από κάτι τρίτο.

Ο Πίνακας 2.1 συνοψίζει τα τέσσερα μεγέθη. Ποια τιμή είναι καλή εξαρτάται από το ερώτημα. Όταν δύο μέθοδοι μετρούν το ίδιο πράγμα, όπως δύο κριτές που βαθμολογούν τους ίδιους υποψηφίους, αναμένεται τιμή κοντά στο  $+1$  και στους τρεις συντελεστές. Από αυτούς, ο *Kendall* είναι ο αυστηρότερος, γιατί μετρά κάθε ζεύγος που αλλάζει σειρά, ακόμη κι αν οι δύο τιμές του είναι σχεδόν ίσες. Όταν ελέγχεται αν ένα μέγεθος εξηγεί ένα άλλο, ζητείται συντελεστής μακριά από το  $0$  μαζί με  $p < 0,05$ . Ένας συντελεστής κοντά στο  $0$  ή ένα  $p$  πάνω από το όριο σημαίνει ότι τα δεδομένα δε στηρίζουν την εξήγηση. Τα μεγέθη διαβάζονται, τέλος, μαζί. Ένα υψηλό  $r$  με χαμηλότερο  $\tau$ , για παράδειγμα, σημαίνει ότι οι τιμές συμφωνούν συνολικά, αλλά η σειρά αλλάζει ανάμεσα σε αντικείμενα με κοντινές τιμές.

| Μέγεθος         | Τι μετρά                                                             | Εύρος     | Πώς διαβάζεται μια τιμή                                                                      |
|-----------------|----------------------------------------------------------------------|-----------|----------------------------------------------------------------------------------------------|
| Pearson $r$     | πόσο κοντά σε μια ευθεία βρίσκονται τα ζεύγη τιμών                   | -1 έως +1 | το $r^2$ είναι το ποσοστό της διακύμανσης που εξηγεί η γραμμική σχέση ( $r = 0,5$ δίνει 25%) |
| Spearman $\rho$ | αν η μία σειρά ανεβαίνει όταν ανεβαίνει η άλλη                       | -1 έως +1 | +1 όταν οι θέσεις ταυτίζονται, όποιο κι αν είναι το σχήμα της σχέσης                         |
| Kendall $\tau$  | πόσα ζεύγη αντικειμένων έχουν την ίδια σειρά και στις δύο κατατάξεις | -1 έως +1 | το $(1 + \tau)/2$ είναι το ποσοστό των σύμφωνων ζευγών ( $\tau = 0,9$ δίνει 95%)             |
| Τιμή $p$        | αν η μετρημένη συσχέτιση θα μπορούσε να οφείλεται σε τύχη            | 0 έως 1   | κάτω από 0,05 η συσχέτιση θεωρείται στατιστικά σημαντική                                     |

**Πίνακας 2.1.** Οι τρεις συντελεστές και η τιμή  $p$ . Οι συντελεστές είναι +1 σε πλήρη συμφωνία, -1 σε πλήρη αντιστροφή και 0 όταν δεν υπάρχει σχέση του είδους που μετρά ο καθένας.

## 2.2 Ομοσπονδιακή Μάθηση

### 2.2.1 Αρχιτεκτονική εξυπηρετητή και συμμετεχόντων

Στην ομοσπονδιακή μάθηση ένα κοινό μοντέλο εκπαιδεύεται από πολλούς συμμετέχοντες (*clients*) υπό τον συντονισμό ενός εξυπηρετητή, χωρίς τα δεδομένα εκπαίδευσης να φύγουν ποτέ από τη συσκευή στην οποία παρήχθησαν [3]. Ο εξυπηρετητής κρατά το τρέχον καθολικό μοντέλο και, σε κάθε γύρο, το στέλνει στους επιλεγμένους clients. Κάθε client εκπαιδεύει τοπικά για έναν συμφωνημένο αριθμό βημάτων και επιστρέφει τις ενημερωμένες παραμέτρους. Ο εξυπηρετητής τις συναθροίζει και ο γύρος κλείνει.

Η ρύθμιση αυτή φέρνει τρία χαρακτηριστικά που δεν εμφανίζονται στην κατακεντρωμένη εκπαίδευση μέσα σε κέντρο δεδομένων. Τα δεδομένα δεν είναι ισόνομα κατακεντρωμένα (*non-IID*), γιατί αντανακλούν τη συμπεριφορά συγκεκριμένων ανθρώπων. Δεν είναι ισομεγέθη, γιατί κανείς δεν ελέγχει πόσα samples θα παράγει ο καθένας. Τέλος, το πλήθος των συμμετεχόντων μπορεί να είναι πολύ μεγαλύτερο από τον μέσο αριθμό samples ανά συμμετέχοντα [3].

Η βιβλιογραφία διακρίνει δύο βασικές ρυθμίσεις. Η *cross-device* αφορά πολύ μεγάλο πλήθος αναξιόπιστων συσκευών, ενώ η *cross-silo* λίγους σταθερούς οργανισμούς [4]. Η παρούσα εργασία βρίσκεται ανάμεσα στις δύο. Ως προς τη μηχανική, μοιάζει με τη δεύτερη, με λίγους συμμετέχοντες, όλους διαθέσιμους σε κάθε γύρο, ενώ ως προς τη σημασιολογία ακολουθεί την πρώτη, αφού κάθε client είναι ένα άτομο και όχι ένας οργανισμός. Η ακριβής ρύθμιση περιγράφεται στα Κεφάλαια 3 και 4.

### 2.2.2 Ο αλγόριθμος FedAvg

Ο βασικός αλγόριθμος της ομοσπονδιακής μάθησης είναι ο *Federated Averaging* (FedAvg). Ο στόχος που ελαχιστοποιείται είναι ο σταθμισμένος μέσος των τοπικών συναρτήσεων κόστους:

$$f(\mathbf{w}) = \sum_{k=1}^K \frac{n_k}{n} F_k(\mathbf{w}), \quad n = \sum_{k=1}^K n_k, \quad (2.9)$$


όπου  $K$  το πλήθος των clients,  $n_k$  το πλήθος samples του client  $k$ ,  $n$  το συνολικό πλήθος και  $F_k$  το μέσο κόστος του  $k$  πάνω στα δικά του δεδομένα [3]. Τα βάρη  $n_k/n$  δεν είναι σχεδιαστική επιλογή αλλά συνέπεια του ορισμού, γιατί, αν συγκεντρώνονταν όλα τα δεδομένα, το μέσο κόστος θα ήταν ακριβώς αυτή η έκφραση.

Σε κάθε γύρο  $t$ , κάθε επιλεγμένος client ξεκινά από το καθολικό μοντέλο  $\mathbf{w}_t$ , εκτελεί  $E$  τοπικές εποχές (πλήρη περάσματα πάνω στα τοπικά δεδομένα) με μέγεθος παρτίδας  $B$  και παράγει  $\mathbf{w}_{t+1}^k$ . Ο εξυπηρετητής συνθέτει:

$$\mathbf{w}_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{n_{S_t}} \mathbf{w}_{t+1}^k, \quad (2.10)$$

όπου  $S_t$  το σύνολο των συμμετεχόντων του γύρου και  $n_{S_t} = \sum_{k \in S_t} n_k$  το πλήθος των samples τους [3]. Ο αλγόριθμος ελέγχεται από τρεις παραμέτρους, δηλαδή το κλάσμα  $C$  των clients που υπολογίζουν σε κάθε γύρο, τον αριθμό  $E$  των τοπικών περασμάτων πάνω στα δεδομένα τους και το μέγεθος παρτίδας  $B$  [3]. Η επιλογή τους στην παρούσα εργασία τεκμηριώνεται στις Ενότητες 4.2 και 4.3.2. Το  $E$  ελέγχεται, επιπλέον, εμπειρικά στην Ενότητα 4.6.3.

Το Σχήμα 2.1 συνοψίζει τον γύρο.



**Σχήμα 2.1.** Ένας γύρος. Ο εξυπηρετητής εκπέμπει το καθολικό μοντέλο, κάθε συσκευή το εκπαιδεύει  $E$  εποχές πάνω στα δικά της δεδομένα και επιστρέφει μόνο τις παραμέτρους. Τα δεδομένα δε βγαίνουν ποτέ από το πλαίσιο της συσκευής. Ο σταθμισμένος μέσος δίνει το μοντέλο του επόμενου γύρου.

Μεταξύ εξυπηρετητή και clients κινούνται μόνο παράμετροι μοντέλου, δηλαδή ένα διάνυσμα σταθερού μεγέθους ανεξάρτητο από το πλήθος των τοπικών samples. Αυτό είναι ταυτόχρονα το πλεονέκτημα επικοινωνίας του σχήματος και ο λόγος για τον οποίο ο εξυπηρετητής δεν έχει καμία άμεση πρόσβαση στην ποιότητα των δεδομένων, πρόβλημα που πραγματεύεται το Κεφάλαιο 5.

### 2.2.3 Ετερογένεια και client drift

Η ετερογένεια σε ένα ομοσπονδιακό σύστημα έχει δύο ανεξάρτητες όψεις. Η *ετερογένεια συστημάτων* αφορά τις διαφορές στους πόρους των συσκευών. Η *στατιστική ετερογένεια* αναφέρεται στις διαφορές στις κατανομές των δεδομένων τους [14]. Η παρούσα εργασία εκτελείται σε ομοιόμορφο υλικό, οπότε η πρώτη δεν εμφανίζεται. Η δεύτερη είναι το αντικείμενο.

Όταν οι τοπικές κατανομές διαφέρουν, τα τοπικά ελάχιστα των  $F_k$  δε συμπίπτουν. Κάθε client, εκτελώντας πολλά τοπικά βήματα, κινείται προς το δικό του ελάχιστο και όχι προς το ελάχιστο της Εξίσωσης (2.9). Οι Karimireddy et al. ονομάζουν το φαινόμενο *client drift* και το περιγράφουν ως απόκλιση που εισάγεται στις ενημερώσεις κάθε client, με αποτέλεσμα αργή και ασταθή σύγκλιση [15]. Ο μέσος όρος πολλών ενημερώσεων που δείχνουν προς διαφορετικές κατευθύνσεις είναι μικρότερος σε μέτρο και όχι απαραίτητα σωστός σε κατεύθυνση.

Δύο σημεία αυτής της ανάλυσης χρησιμοποιούνται αργότερα. Πρώτον, η απόκλιση *επιμένει* ακόμη και όταν χρησιμοποιούνται παράγωγοι πλήρους παρτίδας και όταν όλοι οι clients συμμετέχουν σε κάθε γύρο της εκπαίδευσης [15]. Αυτό σημαίνει ότι η πλήρης συμμετοχή δεν κρύβει το φαινόμενο αλλά το απομονώνει, κάτι που αξιοποιείται στον σχεδιασμό της Ενότητας 4.3.2. Δεύτερον, όσο περισσότερα τοπικά βήματα μεσολαβούν μεταξύ δύο συναθροίσεων, τόσο μεγαλύτερη είναι η απόκλιση [15], πράγμα που ελέγχεται εμπειρικά στην Ενότητα 4.6.3. Το φαινόμενο επανέρχεται και στο Κεφάλαιο 5, στην ερμηνεία της συνεισφοράς των συμμετεχόντων.

### 2.2.4 Εγγυήσεις και όρια ιδιωτικότητας

Η ομοσπονδιακή μάθηση περιορίζει την έκθεση των δεδομένων, αλλά δεν την εξαλείφει. Η αρχή της ελαχιστοποίησης δεδομένων ικανοποιείται από το γεγονός ότι τα ακατέργαστα δεδομένα δε φεύγουν ποτέ από τη συσκευή, όμως οι ίδιες οι ενημερώσεις παραμέτρων φέρουν πληροφορία για τα δεδομένα που τις παρήγαγαν. Η ανασκόπηση του πεδίου δηλώνει ρητά ότι τα χαρακτηριστικά αυτά προσφέρουν σημαντικές πρακτικές βελτιώσεις ιδιωτικότητας έναντι της συγκέντρωσης όλων των δεδομένων, αλλά δεν αποτελούν εγγύηση [4].

Οι τυπικές εγγυήσεις απαιτούν πρόσθετους μηχανισμούς. Η διαφορική ιδιωτικότητα (*differential privacy*) επιτυγχάνεται με ψαλίδισμα της συνεισφοράς κάθε παραδείγματος και προσθήκη βαθμονομημένου θορύβου στις παραγώγους πριν από την ενημέρωση [16]. Η ασφαλής συνάθροιση (*secure aggregation*) επιτρέπει στον εξυπηρετητή να μάθει μόνο το άθροισμα των ενημερώσεων και όχι τους επιμέρους όρους [4].

Καμία από τις δύο δεν υλοποιείται στην παρούσα εργασία και αυτό δηλώνεται ως όριο. Ο λόγος είναι το γεγονός ότι και οι δύο παρεμβαίνουν στις ίδιες τις ενημερώσεις, αφού ο θόρυβος της διαφορικής ιδιωτικότητας αλλάζει τα  $w_{t+1}^k$  και η ασφαλής συνάθροιση τα κρύβει από τον εξυπηρετητή. Η αποτίμηση συνεισφοράς του Κεφαλαίου 5 στηρίζεται ακριβώς στο να είναι οι επιμέρους ενημερώσεις ορατές και ανασυνθέσιμες. Η αλληλεπίδραση των δύο απαιτήσεων είναι ανοιχτό ζήτημα και σημειώνεται στην Ενότητα 6.3.

## 2.3 Συνεργατικά Παίγνια και Αποτίμηση Συνεισφοράς

### 2.3.1 Συνεργατικά παίγνια και χαρακτηριστική συνάρτηση

Ένα συνεργατικό παίγνιο ορίζεται από ένα πεπερασμένο σύνολο παικτών  $N$  και μια *χαρακτηριστική συνάρτηση*  $v$ , η οποία αποδίδει σε κάθε υποσύνολο  $S \subseteq N$  έναν πραγματικό αριθμό  $v(S)$ , δηλαδή την αξία που μπορεί να εξασφαλίσει ο συνασπισμός  $S$  δρώντας μόνος του. Στον κλασικό ορισμό, ο κενός συνασπισμός δεν αξίζει τίποτα ( $v(\emptyset) = 0$ ) και η ένωση δύο ξένων συνασπισμών δεν αξίζει λιγότερο από το άθροισμά τους,  $v(S \cup T) \geq v(S) + v(T)$  για  $S \cap T = \emptyset$  [17].

Το ερώτημα που θέτει η θεωρία είναι ερώτημα κατανομής. Δεδομένης της  $v$ , ζητείται να εντοπιστεί πώς μοιράζεται η συνολική αξία  $v(N)$  στους επιμέρους παίκτες με τρόπο που να μπορεί να υπερασπιστεί κανείς. Η απάντηση δεν είναι προφανής, γιατί η αξία ενός παίκτη εξαρτάται από το σύνολο στο οποίο συγκαταλέγεται. Ο ίδιος παίκτης μπορεί να είναι αναντικατάστατος σε έναν μικρό συνασπισμό και περιττός σε έναν μεγάλο που ήδη περιέχει κάποιον με πανομοιότυπα χαρακτηριστικά.

### 2.3.2 Το Shapley value και τα τρία αξιώματα

Ο Shapley προσέγγισε το πρόβλημα αξιωματικά. Αντί να προτείνει έναν τύπο και να τον δικαιολογήσει, διατύπωσε ιδιότητες που οφείλει να έχει κάθε λογική κατανομή και έδειξε ότι τις ικανοποιεί μία μοναδική συνάρτηση. Τα αξιώματα είναι **τρία** [17]:

1. **Συμμετρία.** Η κατανομή δεν εξαρτάται από τα ονόματα των παικτών. Αν μια μετάθεση των παικτών αφήνει τη  $v$  αναλλοίωτη, μεταθέτει αντίστοιχα και τις τιμές.
2. **Αποδοτικότητα.** Το άθροισμα των τιμών ισούται με τη συνολική αξία,  $\sum_{i \in N} \varphi_i = v(N)$ . Τίποτα δε χάνεται και τίποτα δε δημιουργείται κατά τη διανομή.
3. **Νόμος της άθροισης.** Η κατανομή είναι προσθετική ως προς το παίγνιο, δηλαδή  $\varphi[v + w] = \varphi[v] + \varphi[w]$ . Αν δύο παίγνια παίζονται μαζί, οι τιμές προστίθενται.

Η ιδιότητα του *μηδενικού παίκτη*, δηλαδή ότι όποιος δεν προσθέτει τίποτα σε κανέναν συνασπισμό παίρνει μηδέν, δεν είναι αξίωμα αλλά αποδεικνύεται ως Λήμμα 1 [17]. Το ίδιο ισχύει για τον *dummy* παίκτη, ο οποίος παίρνει ακριβώς  $v(\{i\})$ . Η ιδιότητα αυτή προκύπτει ως Πόρισμα 1 [17]. Η διάκριση έχει σημασία για τη σωστή παρουσίαση, γιατί πρόκειται για τρία αξιώματα από τα οποία παράγονται οι υπόλοιπες ιδιότητες και όχι για τέσσερα ισότιμα αξιώματα.

Η μοναδική συνάρτηση που τα ικανοποιεί δίνεται από το θεώρημα [17]:

$$\varphi_i[v] = \sum_{S \subseteq N, i \in S} \gamma_n(s) [v(S) - v(S \setminus \{i\})], \quad \gamma_n(s) = \frac{(s-1)!(n-s)!}{n!}, \quad (2.11)$$

όπου  $n = |N|$  το πλήθος των παικτών,  $s = |S|$  το μέγεθος του συνασπισμού και ο όρος  $v(S) - v(S \setminus \{i\})$  η *οριακή συνεισφορά* του  $i$  στον  $S$ , δηλαδή η προσαύξηση της αξίας, λόγω της προσθήκης του.

Ο συντελεστής  $\gamma_n(s)$  χρήζει επεξήγησης, γιατί εκεί εντοπίζεται όλη η ουσία. Έστω ότι οι  $n$  παίκτες μπαίνουν στο δωμάτιο ένας ένας, με τυχαία σειρά. Ο καθένας πιστώνεται το ποσό αύξησης της αξίας τη στιγμή της εισόδου του. Υπάρχουν  $n!$  σειρές. Ο παίκτης  $i$  βρίσκεται μπροστά του ακριβώς το σύνολο  $S \setminus \{i\}$ , όταν οι  $s-1$  προηγούμενοι είναι αυτοί, με οποιαδήποτε σειρά μεταξύ τους  $((s-1)!$  τρόποι) και οι υπόλοιποι  $n-s$  ακολουθούν, επίσης με οποιαδήποτε σειρά  $((n-s)!$  τρόποι). Άρα το  $\gamma_n(s)$  είναι η *πιθανότητα* να συμβεί αυτό σε τυχαία σειρά. Το Shapley value είναι, λοιπόν, η *αναμενόμενη οριακή συνεισφορά* του παίκτη σε τυχαία σειρά άφιξης.

Ένα παράδειγμα με τρεις παίκτες κάνει τον τύπο εύληπτο (Σχήμα 2.2). Έστω ότι κανένας παίκτης μόνος του δεν αξίζει τίποτα,  $v(\{1\}) = v(\{2\}) = v(\{3\}) = 0$ , ότι οι παίκτες 1 και 2

μαζί παράγουν  $v(\{1, 2\}) = 6$ , ότι ο 3 δε βοηθά κανέναν,  $v(\{1, 3\}) = v(\{2, 3\}) = 0$  και ότι  $v(\{1, 2, 3\}) = 6$ . Απαριθμώντας και τις  $3! = 6$  σειρές άφιξης, ο παίκτης 1 έχει μη μηδενική οριακή συνεισφορά στις σειρές  $(2, 1, 3)$ ,  $(2, 3, 1)$  και  $(3, 2, 1)$ , δηλαδή σε όσες φτάνει αφού έχει ήδη φτάσει ο 2. Σε καθεμιά από αυτές συνεισφέρει 6. Άρα  $\varphi_1 = 3 \cdot 6/6 = 3$ . Συμμετρικά  $\varphi_2 = 3$ . Ο παίκτης 3 συνεισφέρει 0 σε κάθε σειρά, άρα  $\varphi_3 = 0$ , όπως προβλέπει το Λήμμα 1. Το άθροισμα  $3 + 3 + 0 = 6$  ισούται με  $v(N)$ , όπως απαιτεί το Αξίωμα 2.

| σειρά άφιξης | οριακή συνεισφορά του 1 |
|--------------|-------------------------|
| <b>1</b> 2 3 | 0                       |
| <b>1</b> 3 2 | 0                       |
| 2 <b>1</b> 3 | 6                       |
| 2 3 <b>1</b> | 6                       |
| 3 <b>1</b> 2 | 0                       |
| 3 2 <b>1</b> | 6                       |

$$\varphi_1 = \frac{0 + 0 + 6 + 6 + 0 + 6}{6} = 3$$

**Σχήμα 2.2.** Το παράδειγμα των τριών παικτών, απαριθμημένο. Κάθε γραμμή είναι μία από τις  $3! = 6$  σειρές άφιξης. Ο παίκτης 1 πιστώνεται το ποσό αύξησης της αξίας τη στιγμή της εισόδου του, δηλαδή 6 μόνο όταν ο παίκτης 2 έχει ήδη φτάσει. Η θέση του παίκτη 1 είναι επισημασμένη σε κάθε σειρά. Το  $\varphi_1$  είναι ο μέσος όρος της δεξιάς στήλης.

Το παράδειγμα αναδεικνύει και γιατί το Shapley value δεν ταυτίζεται με απλούστερα μέτρα. Το πιο προφανές εναλλακτικό είναι η αφαίρεση ενός παίκτη από το πλήρες σύνολο (*leave-one-out*),  $v(N) - v(N \setminus \{i\})$ . Εδώ δίνει  $6 - 0 = 6$  για τον παίκτη 1, το ίδιο για τον 2 και  $6 - 6 = 0$  για τον 3. Οι δύο πρώτοι παίρνουν ο καθένας ολόκληρη τη συνολική αξία και το άθροισμα γίνεται 12, ενώ υπάρχουν μόνο 6, για να μοιραστούν. Η αιτία είναι το γεγονός ότι, όταν δύο παίκτες είναι αλληλοσυμπληρωματικοί, καθένας φαίνεται αναντικατάστατος, αν κριθεί μόνο στο πλήρες σύνολο. Το Shapley value αποφεύγει τη διπλή μέτρηση, επειδή σταθμίζει τη συνεισφορά σε *όλους* τους ενδιαμέσους συνασπισμούς. Γι' αυτό ικανοποιεί την αποδοτικότητα εξ ορισμού.

### 2.3.3 Υπολογιστική πολυπλοκότητα και εκτιμητές

Η Εξίσωση (2.11) αθροίζει πάνω σε όλα τα υποσύνολα, άρα απαιτεί  $2^n$  αποτιμήσεις της  $v$ . Ήδη για είκοσι παίκτες αυτό ξεπερνά το ένα εκατομμύριο συνασπισμούς και, αν κάθε αποτίμηση σημαίνει εκπαίδευση ενός μοντέλου, το κόστος καθίσταται απαγορευτικό. Το ίδιο εμπόδιο εμφανίζεται σε κάθε εφαρμογή του Shapley στη μηχανική μάθηση, όπου κάθε κάτοχος δεδομένων μοντελοποιείται ως παίκτης σε συνασπιστικό παίγνιο [18].

Υπάρχουν δύο οικογένειες προσεγγίσεων. Η πρώτη εκμεταλλεύεται την ερμηνεία του Shapley ως αναμενόμενης τιμής και δειγματοληπτεί μεταθέσεις. Επιλέγονται τυχαίες σειρές και σε κάθε μία υπολογίζεται η οριακή συνεισφορά κάθε παίκτη. Ο μέσος όρος συγκλίνει στο  $\varphi_i$ . Ο αλγόριθμος *Truncated Monte Carlo Shapley* προσθέτει αποκοπή. Όταν η αξία ενός μεγάλου συνασπισμού έχει πλησιάσει αρκετά τη  $v(N)$ , οι υπόλοιπες οριακές συνεισφορές της σειράς θεωρούνται αμελητέες και δεν υπολογίζονται [19]. Ο βρόχος του αλγορίθμου, μάλιστα, τερματίζει με *κριτήριο σύγκλισης* και όχι με προκαθορισμένο πλήθος δειγμάτων, οπότε ο έλεγχος σύγκλισης είναι μέρος του αλγορίθμου και όχι προαιρετική προσθήκη [19].

Η δεύτερη οικογένεια διατυπώνει το πρόβλημα ως σταθμισμένη γραμμική παλινδρόμηση. Ο KernelSHAP δειγματοληπτεί συνασπισμούς, τους σταθμίζει με τον *πυρήνα Shapley*

$$\pi(S) = \frac{n-1}{\binom{n}{s} s (n-s)}, \quad (2.12)$$

όπου, όπως στην Εξίσωση (2.11),  $n$  το πλήθος των παικτών και  $s = |S|$  το μέγεθος του δειγματοληπτημένου συνασπισμού. Στη συνέχεια, ο KernelSHAP λύνει ένα πρόβλημα ελαχίστων τετραγώνων, του οποίου οι συντελεστές είναι τα Shapley values [20]. Ο πυρήνας δίνει πολύ μεγάλο βάρος στους πολύ μικρούς και πολύ μεγάλους συνασπισμούς, ενώ τα δύο άκρα  $s \in \{0, n\}$  παίρνουν άπειρο βάρος και επιβάλλουν ως περιορισμούς την  $v(\emptyset)$  και την αποδοτικότητα [20].

Η διασπορά του εκτιμητή αυτού φθίνει αντιστρόφως ανάλογα με το πλήθος των δειγματοληπτημένων συνασπισμών, αποδεδειγμένα για μια αμερόληπτη παραλλαγή του και εμπειρικά για την αρχική μορφή. Η ιδιότητα αυτή επιτρέπει έναν ρητό κανόνα τερματισμού. Το δειγματοληπτικό σφάλμα παρακολουθείται και ο αλγόριθμος σταματά, όταν αυτό πέσει κάτω από ένα κατώφλι που ορίζεται ως μικρό ποσοστό του εύρους των εκτιμώμενων τιμών [21].

### 2.3.4 Shapley value, SHAP και συνάρτηση αξίας

Τρεις όροι μοιάζουν και πρέπει να κρατηθούν χωριστά.

- Το **Shapley value** είναι η έννοια της θεωρίας παιγνίων της Ενότητας 2.3.2, δηλαδή ένας κανόνας που μοιράζει την αξία *οποιουδήποτε* συνεργατικού παιγνίου στους παίκτες του.
- Το **SHAP** είναι μέθοδος ερμηνείας μοντέλων. Εφαρμόζει τον κανόνα σε ένα *συγκεκριμένο* παίγνιο, όπου παίκτες είναι τα χαρακτηριστικά μίας εισόδου  $x$  και αξία ενός συνασπισμού  $S$  είναι η αναμενόμενη έξοδος του μοντέλου, όταν είναι γνωστά μόνο τα χαρακτηριστικά του  $S$  [20].

- Ο **KernelSHAP** είναι αλγόριθμος *εκτίμησης*, η σταθμισμένη παλινδρόμηση της Ενότητας 2.3.3. Προτάθηκε στο ίδιο άρθρο με το SHAP αλλά ορίζεται για οποιαδήποτε συνάρτηση  $v$ , που δίνει μία τιμή σε κάθε συνασπισμό, όχι μόνο για το παίγνιο του SHAP [21].

Το SHAP εξηγεί πόσο ένα χαρακτηριστικό επηρεάζει την *έξοδο* του μοντέλου, χωρίς να χρειάζεται να ξέρει αν η πρόβλεψη είναι σωστή. Για να μετρηθεί πόσο κάτι βελτιώνει την *ορθότητα*, χρειάζεται συνάρτηση αξίας που συγκρίνει τις προβλέψεις με τις αληθινές ετικέτες, όπως η τιμή της συνάρτησης κόστους (*loss*) του μοντέλου πάνω σε ένα σύνολο δεδομένων [21]. Την ίδια διάκριση κάνει και η ταξινόμηση των μεθόδων εξήγησης, ανάμεσα σε μεθόδους που εξηγούν μία πρόβλεψη και σε μεθόδους που εξηγούν το κόστος σε επίπεδο συνόλου δεδομένων [22].

Η παρούσα εργασία χρησιμοποιεί τον κανόνα και τον εκτιμητή αλλά όχι το παίγνιο του SHAP. Ορίζει δικό της παίγνιο, με παίκτες τους συμμετέχοντες της ομοσπονδίας, γιατί σκοπός της είναι η αποτίμηση της συνεισφοράς τους και όχι η ερμηνεία των προβλέψεων. Η συνάρτηση αξίας μετρά επίδοση με τις αληθινές ετικέτες. Κύρια μετρική είναι η ορθότητα. Ο ακριβής ορισμός του παιγνίου και ο τρόπος με τον οποίο χρησιμοποιείται ο εκτιμητής δίνονται στο Κεφάλαιο 5.

Η επιλογή της συνάρτησης αξίας δεν είναι τεχνική λεπτομέρεια. Τα αξιώματα εγγυώνται ότι η κατανομή μιας *δεδομένης* συνολικής αξίας είναι μοναδική αλλά η τιμή που αποδίδεται σε έναν παίκτη ορίζεται *ως προς* τη συνάρτηση αξίας. Στη διατύπωση του Data Shapley, η συνάρτηση αυτή περιλαμβάνει ρητά τον αλγόριθμο μάθησης και τη μετρική αξιολόγησης [23]. Μια άλλη μετρική, ένα άλλο σύνολο αξιολόγησης ή μια συνάρτηση αξίας που δε χρησιμοποιεί καθόλου δεδομένα αξιολόγησης, όπως η ομοιότητα των ενημερώσεων των συμμετεχόντων [24], ορίζουν άλλο παίγνιο και επομένως δίνουν άλλο  $\varphi$ . Τα αξιώματα δε λένε τίποτα για το πώς σχετίζονται οι τιμές δύο τέτοιων παιγνίων.

Από αυτό προκύπτουν τρία όρια, καταγεγραμμένα στη βιβλιογραφία.

Πρώτον, οι τιμές ισχύουν μόνο για τα σημεία του συνόλου στο οποίο υπολογίστηκαν. Το Data Shapley αποτιμά κάθε σημείο ως μέλος ενός συγκεκριμένου συνόλου εκπαίδευσης και δε δίνει τρόπο να κριθεί ένα σημείο εκτός αυτού. Η τιμή ενός σημείου μπορεί, μάλιστα, να μην έχει νόημα, αν το σημείο μεταφερθεί σε άλλο σύνολο [23]. Ο λόγος φαίνεται ήδη στην Ενότητα 2.3.1. Ένα σημείο που είναι περιττό ανάμεσα σε πολλά παρόμοιά του μπορεί να είναι πολύτιμο σε ένα σύνολο όπου αυτά λείπουν. Στην εργασία, η τιμή ενός συμμετέχοντα αφορά, επομένως, τη συγκεκριμένη ομοσπονδία και δε μεταφέρεται αυτούσια σε άλλη.

Δεύτερον, οι τιμές αλλάζουν από εκτέλεση σε εκτέλεση. Η αξία ενός συνασπισμού μετριέται εκπαιδευοντας ένα μοντέλο. Η στοχαστική βελτιστοποίηση, όμως, δε δίνει το ίδιο μοντέλο σε κάθε εκτέλεση, αφού αλλάζουν η τυχαία αρχικοποίηση και η επιλογή των παρτίδων.

Ο θόρυβος που προκύπτει μπορεί να είναι μεγαλύτερος από τις ίδιες τις τιμές, οπότε δύο εκτελέσεις του ίδιου αλγορίθμου αποτίμησης δίνουν διαφορετικές κατατάξεις και ο εντοπισμός δεδομένων χαμηλής ποιότητας από τις τιμές δυσκολεύει [25]. Στην εργασία, η σταθερότητα των τιμών ελέγχεται σε πολλές επαναλήψεις (Ενότητα 5.3.2).

Τρίτον, μια επιλογή δεδομένων με βάση το Data Shapley, δηλαδή η διατήρηση των σημείων με υψηλή τιμή και η απόρριψη όσων έχουν χαμηλή, δεν εγγυάται αποτέλεσμα καλύτερο από μια τυχαία επιλογή. Εγγύηση υπάρχει μόνο όταν η συνάρτηση χρησιμότητας ικανοποιεί πρόσθετες συνθήκες [26]. Ο λόγος είναι το γεγονός ότι διαφορετικές συναρτήσεις χρησιμότητας μπορεί να δίνουν ακριβώς τις ίδιες τιμές Shapley, οπότε οι τιμές μόνες τους δεν αρκούν για να κριθεί ποιο υποσύνολο δεδομένων είναι καλύτερο [26]. Αν, μάλιστα, η επιλογή ελεγχθεί στο ίδιο σύνολο με το οποίο υπολογίστηκαν οι τιμές, όπως κάνει η ίδια μελέτη για να ευθυγραμμιστεί με τη θεωρητική της ανάλυση [26], ο έλεγχος κινδυνεύει να είναι κυκλικός. Οι τιμές μετρούν ακριβώς πόσο βοήθησε κάθε σημείο σε αυτό το σύνολο, οπότε ένα καλό αποτέλεσμα εκεί είναι εν μέρει αναμενόμενο και δε δείχνει ότι η επιλογή θα βοηθούσε και σε νέα δεδομένα.

Γι' αυτό, στην εργασία η αποτίμηση αντιμετωπίζεται ως *μέτρηση* του τι συνέβη σε μια συγκεκριμένη εκπαίδευση, απέναντι σε ένα συγκεκριμένο σύνολο αξιολόγησης. Το αν μπορεί να χρησιμοποιηθεί και ως *κριτήριο απόφασης* ελέγχεται χωριστά στο Κεφάλαιο 5, με αφαίρεση συμμετεχόντων που κρίνεται σε άλλα άτομα από εκείνα με τα οποία εντοπίστηκαν.

### 2.3.5 Κίνητρα συμμετοχής στην ομοσπονδιακή μάθηση

Η συμμετοχή σε μια ομοσπονδία δεν είναι δωρεάν. Η τοπική εκπαίδευση καταναλώνει υπολογιστικούς πόρους, ενέργεια και εύρος ζώνης. Η βιβλιογραφία των μηχανισμών κινήτρων ξεκινά από την παραδοχή ότι οι κάτοχοι δεδομένων είναι ορθολογικοί και μπορεί να μην είναι πρόθυμοι να συμμετάσχουν εξαιτίας αυτής ακριβώς της κατανάλωσης [6]. Χωρίς κάποια μορφή οικονομικής αποζημίωσης, οι ιδιοτελείς συσκευές δεν έχουν λόγο να προσφέρουν [27].

Στην κατεύθυνση αυτή εμφανίζεται και το πρόβλημα του *free-riding*, όπου ένας συμμετέχων μπορεί να επωφεληθεί από το κοινό μοντέλο χωρίς να συνεισφέρει ουσιαστικά [28]. Επιπροσθέτως, χωρίς μέτρο συνεισφοράς, κανείς δεν μπορεί να τον ξεχωρίσει. Οι ανασκοπήσεις του πεδίου καταγράφουν το φάσμα των σχημάτων που έχουν προταθεί, από θεωρία συμβολαίων και δημοπρασίες μέχρι παίγνια Stackelberg, καθώς και τις ιδιότητες που τους ζητούνται [5], [6].

Τέσσερα κίνητρα εξετάζονται εδώ. Το πρώτο είναι η *αποκέντρωση* ως αξία καθαυτή, αφού τα ακατέργαστα δεδομένα δε φεύγουν από τη συσκευή, πράγμα που μειώνει την επιφάνεια

έκθεσης [3], [4]. Το δεύτερο είναι το *μερίδιο ανταμοιβής*, όποια μορφή και αν πάρει. Το τρίτο είναι η *αναγνώριση της συνεισφοράς* ανεξάρτητα από πληρωμή. Το τέταρτο είναι το γεγονός ότι ο συμμετέχων παίρνει *καλύτερο μοντέλο από ό,τι θα είχε μόνος του*. Το τελευταίο μετριέται άμεσα σε αυτήν την εργασία και ποσοτικοποιείται στην Ενότητα 4.6.2.

## 2.4 Σχετική Βιβλιογραφία και Τοποθέτηση της Εργασίας

### 2.4.1 Ομοσπονδιακή μάθηση για αναγνώριση δραστηριότητας

Ο συνδυασμός ομοσπονδιακής μάθησης και αναγνώρισης δραστηριότητας έχει προφανές κίνητρο, αφού τα δεδομένα κίνησης παράγονται ήδη κατανεμημένα και σε προσωπικές συσκευές. Οι Sozinov et al. εκπαιδύσαν μοντέλα αναγνώρισης δραστηριότητας ομοσπονδιακά και αναφέρουν ορθότητα έως 89% έναντι 93% της κεντρικής εκπαίδευσης, μελετώντας παράλληλα και την επίδραση συμμετεχόντων με αλλοιωμένα δεδομένα [29]. Η ομοσπονδιακή εκπαίδευση υστερεί εκεί ελαφρώς, χωρίς η διαφορά να ακυρώνει τη χρησιμότητα του σχήματος. Η σύγκριση με τα αποτελέσματα αυτής της εργασίας γίνεται στην Ενότητα 4.6.1 και είναι μόνο ποιοτική, αφού τα σύνολα δεδομένων και τα μοντέλα διαφέρουν.

### 2.4.2 Αποτίμηση συνεισφοράς στην ομοσπονδιακή μάθηση

Η γραμμή εργασιών που αποτιμά δεδομένα με Shapley ξεκινά έξω από το FL. Το *Data Shapley* ορίζει την αξία ενός σημείου δεδομένων ως το Shapley value σε παίγνιο, όπου η συνάρτηση αξίας είναι η επίδοση του εκπαιδευμένου μοντέλου. Προτείνει, επίσης, εκτιμητές, για να γίνει υπολογισμός [19]. Παράλληλη εργασία μελετά πώς η αποτίμηση κλιμακώνεται σε μεγάλα σύνολα [18]. Και οι δύο μοιράζονται το ίδιο εμπόδιο, αφού κάθε αποτίμηση της  $v$  απαιτεί εκπαίδευση.

Στο ομοσπονδιακό πλαίσιο, σημαντική είναι η παρατήρηση ότι η εκπαίδευση δε χρειάζεται να επαναληφθεί. Το GTG-Shapley *ανασυνθέτει* τα ομοσπονδιακά μοντέλα από τις αποθηκευμένες ενημερώσεις παραμέτρων, αντί να εκπαιδεύει ξανά με διαφορετικούς συνδυασμούς συμμετεχόντων [30]. Αυτό μετατρέπει το κόστος από εκπαιδεύσεις σε αποτιμήσεις και είναι η τεχνική στην οποία στηρίζεται και η υλοποίηση της εργασίας (Ενότητα 5.1).

### 2.4.3 Το κενό της βιβλιογραφίας που καλύπτει η εργασία

Τα συστατικά που χρησιμοποιεί η εργασία υπάρχουν όλα στη βιβλιογραφία. Το Shapley value ως μέτρο αξίας δεδομένων [19] και ως μέτρο συνεισφοράς στο FL [30] είναι καθιε-

ρωμένο. Το ίδιο ισχύει για τον KernelSHAP ως εκτιμητή [20] και για την ανασύνθεση από αποθηκευμένες ενημερώσεις [30]. Η αντιμετώπιση των αρνητικών τιμών με αφινική μετατόπιση είναι δημοσιευμένη [28].

Αυτό που δεν εντοπίστηκε σε δημοσιευμένη εργασία, μετά από τρεις γύρους αναζήτησης, είναι ο *συνδυασμός*, δηλαδή η χρήση του KernelSHAP της βιβλιοθήκης `shap` με παίκτες τους συμμετέχοντες ενός ομοσπονδιακού συστήματος, παράλληλα με έναν δεύτερο εκτιμητή που βλέπει ακριβώς την ίδια συνάρτηση αξίας, ώστε η συμφωνία τους να ελέγχει ότι η κατάταξη δεν είναι παρενέργεια του αλγορίθμου. Ο συνδυασμός αυτός δηλώνεται ως συνεισφορά της εργασίας και όχι ως δάνειο.

Η εργασία εξετάζει, επίσης, γιατί κάποιοι συμμετέχοντες λαμβάνουν χαμηλή ή αρνητική τιμή. Η βιβλιογραφία συνδέει, συνήθως, τη χαμηλή τιμή με την ετερογένεια των ετικετών. Οι *Mavericks* είναι συμμετέχοντες που κατέχουν αποκλειστικά μία ή περισσότερες κλάσεις και η επίδοση του μοντέλου υποβαθμίζεται χωρίς αυτούς [31]. Παρόλα αυτά, το Shapley value τους υποτιμά συστηματικά, με τιμή χαμηλότερη από εκείνη ενός μέσου συμμετέχοντα στο πρώτο στάδιο της εκπαίδευσης [32]. Το αν η χαμηλή ή αρνητική τιμή οφείλεται πάντα σε τέτοια ασυμμετρία ετικετών ή και σε άλλες μορφές ετερογένειας εξετάζεται στο Κεφάλαιο 5.

## Κεφάλαιο 3

# Δεδομένα, Έλεγχοι και Προεπεξεργασία

Το κεφάλαιο αυτό παρουσιάζει τα δεδομένα της εργασίας. Ξεκινά από το πώς καταγράφεται η ανθρώπινη δραστηριότητα με αισθητήρες κινητών συσκευών και ορίζει το πρόβλημα ταξινόμησης που λύνει το μοντέλο. Έπειτα, εξηγεί πώς προκύπτουν τα χαρακτηριστικά που δέχεται το μοντέλο ως είσοδο. Περιγράφει, επίσης, τους ελέγχους που έγιναν πριν χρησιμοποιηθεί το σύνολο, καθώς και τη διερευνητική ανάλυση. Κλείνει με την προεπεξεργασία και τον διαχωρισμό των δεδομένων.

### 3.1 Το Σύνολο Δεδομένων UCI HAR

Η αναγνώριση δραστηριότητας από φορητούς αισθητήρες στηρίζεται κυρίως σε δύο όργανα. Το *επιταχυνσιόμετρο* μετρά γραμμική επιτάχυνση σε τρεις άξονες, με συχνότητες δειγματοληψίας από δεκάδες έως εκατοντάδες Hz. Τοποθετείται συνήθως στη μέση, στον καρπό ή στον αστράγαλο. Το *γυροσκόπιο* μετρά προσανατολισμό και γωνιακή ταχύτητα [2]. Τα δύο μαζί περιγράφουν ικανοποιητικά την κίνηση, ώστε να ξεχωρίζουν δραστηριότητες που διαφέρουν είτε στον ρυθμό, είτε στη στάση του σώματος.

Το *Human Activity Recognition Using Smartphones* (UCI HAR) είναι δημόσιο σύνολο δεδομένων αυτού του τύπου, που συλλέχθηκε από 30 εθελοντές ηλικίας 19 έως 48 ετών. Κάθε εθελοντής φορούσε ένα Samsung Galaxy S II στη μέση και εκτέλεσε ένα πρωτόκολλο έξι δραστηριοτήτων, δύο φορές [1]. Οι δραστηριότητες είναι το βάδισμα, η ανάβαση σκάλας, η κατάβαση σκάλας, η καθιστή στάση, η όρθια στάση και η κατάκλιση [1]. Στα αρχεία του συνόλου φέρουν τα ονόματα WALKING, WALKING\_UPSTAIRS, WALKING\_DOWNSTAIRS, SITTING, STANDING και LAYING, με τα οποία αναφέρονται και στα επόμενα κεφάλαια. Στα σχήματα συντομεύονται σε WALK, W.UP, W.DOWN, SIT, STAND και LAY. Χωρίζονται φυσικά σε δύο ομάδες. Στις τρεις *δυναμικές* το σώμα μετακινείται, ενώ στις τρεις *στατικές* είναι ακίνητο σε κάποια στάση. Καταγράφηκαν το τριαξονικό επιταχυνσιόμετρο και το τριαξονικό γυροσκόπιο στα 50 Hz. Το πείραμα βιντεοσκοπήθηκε και οι ετικέτες, δηλαδή ποια δραστηριότητα εκτελούνταν κάθε στιγμή, μπήκαν με το χέρι από το βίντεο [33].

Πάνω σε αυτά τα δεδομένα, η εργασία λύνει ένα πρόβλημα ταξινόμησης (*classification*) σε έξι κλάσεις. Η καταγραφή κάθε εθελοντή κόβεται σε σύντομα κομμάτια σταθερής διάρκειας, τα *samples*. Κάθε *sample* έχει ως ετικέτα τη δραστηριότητα που εκτελούσε ο εθελοντής εκείνη τη στιγμή. Το μοντέλο δέχεται την περιγραφή ενός *sample* και απαντά ποια από τις έξι δραστηριότητες είναι. Κάθε *sample* κρίνεται μόνο του, χωρίς να λαμβάνονται υπόψη τα προηγούμενα ή τα επόμενα. Από τι αποτελείται η περιγραφή ενός *sample*, δηλαδή η είσοδος του μοντέλου, εξηγεί η Ενότητα 3.2. Το σύνολο έχει συνολικά 10.299 *samples*, από τα οποία 7.352 στο σύνολο εκπαίδευσης και 2.947 στο σύνολο ελέγχου.


Ο διαχωρισμός εκπαίδευσης και ελέγχου είναι κρίσιμο σημείο και δηλώνεται από τους δημιουργούς. Το 70% των εθελοντών επιλέχθηκε για την παραγωγή των δεδομένων εκπαίδευσης και το 30% για τα δεδομένα ελέγχου [33]. Ο διαχωρισμός είναι δηλαδή ανά άτομο και όχι ανά *sample*, με 21 ανθρώπους στο σύνολο εκπαίδευσης και 9 στο σύνολο ελέγχου, χωρίς κανένα άτομο να εμφανίζεται και στα δύο. Αυτό είναι το πιο σημαντικό δομικό χαρακτηριστικό του συνόλου για τους σκοπούς της εργασίας, γιατί καθιστά την αξιολόγηση *subject-independent*, δηλαδή το μοντέλο κρίνεται πάντα σε ανθρώπους που δεν έχει ξαναδεί.

Στην ομοσπονδιακή ρύθμιση της εργασίας, οι 21 εθελοντές του συνόλου εκπαίδευσης γίνονται οι 21 συμμετέχοντες, ένας ανά άτομο. Στα σχήματα και στους πίνακες, οι συμμετέχοντες (*clients*) αριθμούνται από 0 έως 20, κατά αύξοντα αριθμό εθελοντή. Η αντιστοιχία των δύο αριθμήσεων δίνεται στον Πίνακα 5.10. Τα μεγέθη τους κυμαίνονται από 281 έως 409 *samples*, με μέσο όρο 350 και συντελεστή μεταβλητότητας 0,099. Ο συντελεστής αυτός είναι η τυπική απόκλιση των μεγεθών διαιρεμένη με τον μέσο όρο τους, οπότε η τυπική απόκλιση είναι περίπου το 10% του μέσου μεγέθους και η ομοσπονδία είναι ισορροπημένη ως προς τον όγκο. Οι 9 εθελοντές του συνόλου ελέγχου δε γίνονται ποτέ συμμετέχοντες και τα δεδομένα τους δεν εισέρχονται ποτέ σε καμία εκπαίδευση.

## 3.2 Από τα Σήματα των Αισθητήρων στα 561 Χαρακτηριστικά

Το μοντέλο δε βλέπει τα σήματα των αισθητήρων. Βλέπει 561 αριθμούς ανά *sample*, τα *χαρακτηριστικά* (*features*), που υπολόγισαν οι δημιουργοί του συνόλου από τα σήματα σε τέσσερα βήματα [1]. Το Σχήμα 3.1 τα δείχνει συνοπτικά.

Στο πρώτο βήμα, τα σήματα του επιταχυνσιόμετρου και του γυροσκοπίου φιλτράρονται, ώστε να αφαιρεθεί ο θόρυβος. Έπειτα, το σήμα του επιταχυνσιόμετρου χωρίζεται σε δύο συνιστώσες. Η μία είναι η επιτάχυνση της βαρύτητας, ένα σχεδόν σταθερό διάνυσμα που δείχνει προς τα κάτω και του οποίου η κατεύθυνση στο σύστημα συντεταγμένων της συσκευής κωδικοποιεί τον προσανατολισμό της. Η άλλη είναι η επιτάχυνση του σώματος, δηλαδή η



**Σχήμα 3.1.** Τα τέσσερα βήματα με τα οποία οι δημιουργοί του συνόλου μετέτρεψαν τα σήματα των αισθητήρων σε 561 χαρακτηριστικά ανά sample. Το μοντέλο της εργασίας βλέπει μόνο το αποτέλεσμα του τελευταίου βήματος.

πραγματική κίνηση. Ο διαχωρισμός έγινε με βαθυπερατό φίλτρο, αφού η βαρύτητα είναι η συνιστώσα πολύ χαμηλής συχνότητας [1]. Γι' αυτό τα ονόματα πολλών χαρακτηριστικών ξεκινούν από `tBodyAcc` ή από `tGravityAcc`. Η διάκριση των δύο αποδεικνύεται ουσιώδης στην Ενότητα 3.4.3.

Στο δεύτερο βήμα, υπολογίζονται από αυτά νέα σήματα. Η παράγωγος ως προς τον χρόνο δίνει πόσο απότομα αλλάζει η κίνηση (*Jerk*). Το μέτρο του διανύσματος των τριών αξόνων δίνει την ένταση της κίνησης ανεξάρτητα από την κατεύθυνσή της (*Magnitude*) [1].

Στο τρίτο βήμα, κάθε σήμα κόβεται σε samples των 2,56 δευτερολέπτων, δηλαδή 128 μετρήσεων, με επικάλυψη 50% μεταξύ διαδοχικών. Η διάρκεια επιλέχθηκε, ώστε κάθε sample να περιέχει τουλάχιστον έναν πλήρη κύκλο βαδίσματος, δηλαδή δύο βήματα, ακόμη και για άνθρωπο που περπατά αργά [1]. Μέσα σε κάθε sample υπολογίζεται και ο μετασχηματισμός Fourier ορισμένων σημάτων, ο οποίος δείχνει με ποιους ρυθμούς επαναλαμβάνεται η κίνηση. Προκύπτουν, έτσι, 17 σήματα, στο πεδίο του χρόνου και στο πεδίο της συχνότητας [1].

Στο τέταρτο βήμα, κάθε σήμα κάθε sample συνοψίζεται με ένα σύνολο *τελεστών*, δηλαδή συναρτήσεων που παίρνουν τις τιμές του σήματος μέσα στο sample και δίνουν έναν ή λίγους αριθμούς, όπως η μέση τιμή, η τυπική απόκλιση ή η ενέργεια. Κάθε συνδυασμός σήματος, άξονα και τελεστή δίνει ένα χαρακτηριστικό και συνολικά προκύπτουν 561 [1]. Από αυτά, τα 265 υπολογίζονται στο πεδίο του χρόνου, τα 289 στο πεδίο της συχνότητας και τα 7 είναι γωνίες μεταξύ διανυσμάτων. Τέλος, κάθε στήλη κλιμακώθηκε στο διάστημα  $[-1, 1]$  [33], βήμα που εξετάζεται ξανά στην Ενότητα 3.3.1.

Το όνομα κάθε χαρακτηριστικού περιγράφει ακριβώς αυτά τα βήματα. Ο Πίνακας 3.1 δίνει τα μέρη του. Για παράδειγμα, το `tBodyAccMag-mean()` είναι η μέση τιμή (`mean()`) του μέτρου (`Mag`) της επιτάχυνσης του σώματος (`BodyAcc`) στο πεδίο του χρόνου (`t`). Αντίστοιχα, το `tGravityAcc-mean() - Y` είναι η μέση τιμή της βαρύτητας, στον άξονα *Y* της συσκευής.

Το σύνολο διανέμεται ως αρχεία κειμένου με την ίδια σειρά γραμμών, όπου κάθε γραμμή αντιστοιχεί σε ένα sample [33]. Η γραμμή *n* του `X_train.txt` περιέχει τα 561 χαρακτηριστικά του sample *n*, δηλαδή το διάνυσμα εισόδου  $\mathbf{x}_n \in \mathbb{R}^{561}$ . Η ίδια γραμμή του `y_train.txt` περιέχει την ετικέτα  $y_n \in \{1, \dots, 6\}$ , δηλαδή τον κωδικό της δραστηριότητας. Στην ίδια γραμμή του `subject_train.txt` βρίσκεται ο αριθμός του εθελοντή, από

| Μέρη του ονόματος      |                                                                                              |
|------------------------|----------------------------------------------------------------------------------------------|
| t, f                   | πεδίο του χρόνου ή της συχνότητας (μετά τον μετασχηματισμό Fourier)                          |
| Body, Gravity          | κίνηση του σώματος ή βαρύτητα                                                                |
| Acc, Gyro              | επιταχυνσιόμετρο ή γυροσκόπιο                                                                |
| Jerk                   | ρυθμός μεταβολής του σήματος (παράγωγος ως προς τον χρόνο)                                   |
| Mag                    | μέτρο του διανύσματος των τριών αξόνων                                                       |
| -X, -Y, -Z             | άξονας της συσκευής                                                                          |
| Τελεστές               |                                                                                              |
| mean(), std()          | μέση τιμή, τυπική απόκλιση                                                                   |
| mad()                  | διάμεση απόλυτη απόκλιση                                                                     |
| max(), min()           | μέγιστη και ελάχιστη τιμή                                                                    |
| iqr()                  | ενδοτεταρτημοριακό εύρος                                                                     |
| sma()                  | <i>signal magnitude area</i> , μέτρο της συνολικής έντασης του σήματος                       |
| energy()               | άθροισμα τετραγώνων διά το πλήθος των τιμών                                                  |
| entropy()              | εντροπία του σήματος                                                                         |
| arCoeff()              | συντελεστές αυτοπαλινδρόμησης, δηλαδή πόσο εξαρτάται κάθε τιμή από τις τέσσερις προηγούμενες |
| correlation()          | συσχέτιση μεταξύ δύο αξόνων του ίδιου σήματος                                                |
| maxInds()              | η συχνότητα με το μεγαλύτερο πλάτος                                                          |
| meanFreq()             | σταθμισμένη μέση συχνότητα                                                                   |
| skewness(), kurtosis() | ασυμμετρία και κύρτωση του φάσματος                                                          |
| bandsEnergy()          | ενέργεια σε ζώνες συχνοτήτων                                                                 |
| angle()                | γωνία μεταξύ δύο διανυσμάτων, για παράδειγμα της μέσης βαρύτητας με έναν άξονα               |

**Πίνακας 3.1.** Τα μέρη του ονόματος ενός χαρακτηριστικού και οι τελεστές που εφαρμόζονται στα σήματα, κατά την τεκμηρίωση του συνόλου [33] και τον κατάλογο των δημιουργών [1].

1 έως 30. Τα αρχεία του συνόλου ελέγχου έχουν την ίδια μορφή. Ο Πίνακας 3.2 δείχνει τρεις γραμμές του ίδιου εθελοντή.

| $x_1$               | $x_{42}$               | $x_{201}$           | $y$ | εθελοντής     |
|---------------------|------------------------|---------------------|-----|---------------|
| tBodyAcc-mean () -X | tGravityAcc-mean () -Y | tBodyAccMag-mean () | ... |               |
| 0,2820              | -0,2459                | -0,2246             | ... | 1 (WALKING) 1 |
| 0,1445              | 0,0425                 | -0,5544             | ... | 4 (SITTING) 1 |
| 0,4035              | 0,7747                 | -0,9051             | ... | 6 (LAYING) 1  |

**Πίνακας 3.2.** Τρεις γραμμές του συνόλου εκπαίδευσης, όλες του εθελοντή 1 (γραμμές 79, 28 και 52 των αρχείων), με τρία από τα 561 χαρακτηριστικά στην κλίμακα της πηγής. Η στήλη  $y$  είναι η ετικέτα που πρέπει να προβλέψει το μοντέλο. Ο αριθμός του εθελοντή δε δίνεται στο μοντέλο.

Στις τρεις αυτές γραμμές φαίνονται, ήδη, διαφορές μεταξύ των δραστηριοτήτων. Το μέτρο της επιτάχυνσης του σώματος ( $x_{201}$ ) είναι μεγαλύτερο στο βάδισμα από ό,τι στις δύο στάσεις. Η βαρύτητα στον άξονα  $Y$  ( $x_{42}$ ) παίρνει πολύ διαφορετική τιμή στην κατάκλιση. Η Ενότητα 3.4.3 δείχνει ότι το ίδιο ισχύει σε όλο το σύνολο.

Με αυτούς τους συμβολισμούς, το πρόβλημα ταξινόμησης της Ενότητας 3.1 είναι να μάθει το μοντέλο, από τα ζεύγη  $(\mathbf{x}_n, y_n)$  του συνόλου εκπαίδευσης, μια συνάρτηση  $f$  που να αντιστοιχίζει κάθε διάνυσμα  $\mathbf{x}$  σε μία από τις έξι δραστηριότητες. Το μοντέλο κρίνεται από το πόσο συχνά ισχύει  $f(\mathbf{x}_n) = y_n$  στο σύνολο ελέγχου, δηλαδή από την ορθότητα της Εξίσωσης (2.1). Ο αριθμός του εθελοντή δε δίνεται ποτέ στο μοντέλο. Χρησιμοποιείται μόνο για να οριστεί σε ποιον συμμετέχοντα ανήκει κάθε sample και ποια samples ανήκουν στο σύνολο ελέγχου.

Εκτός από τον πίνακα των χαρακτηριστικών, το σύνολο περιέχει και τον φάκελο *Inertial Signals*, με τα σήματα κάθε sample ως 128 διαδοχικές μετρήσεις σε εννέα κανάλια, δηλαδή τρεις άξονες για τη συνολική επιτάχυνση, την επιτάχυνση του σώματος και τη γωνιακή ταχύτητα [33]. Τέτοια σήματα είναι η είσοδος των μεθόδων βαθιάς μάθησης, οι οποίες μαθαίνουν μόνες τους τα χαρακτηριστικά, αντί να τα δέχονται έτοιμα [34]. Η εργασία επέλεξε από την αρχή ένα απλό πολυεπίπεδο δίκτυο (Ενότητα 2.1), για το οποίο φυσική είσοδος είναι ένα διάνυσμα, όπως το  $\mathbf{x}_n$ . Έτσι, ο φάκελος αυτός δε χρησιμοποιήθηκε.

### 3.3 Έλεγχοι Ακεραιότητας των Δεδομένων

Πριν χρησιμοποιηθεί το σύνολο, ελέγχθηκε. Δεν υπάρχουν ελλείπουσες τιμές ούτε άπειρα σε κανένα από τα δύο υποσύνολα, καμία στήλη δεν είναι σταθερή και καμία γραμμή του συνόλου ελέγχου δεν επαναλαμβάνεται στο σύνολο εκπαίδευσης (0 από 2.947, έλεγχος

πάνω στα 561 χαρακτηριστικά). Οι υπόλοιποι έλεγχοι αφορούν την κλιμάκωση της πηγής, τις στήλες που επαναλαμβάνονται, την επικάλυψη διαδοχικών samples και τις ακραίες τιμές. Περιγράφονται στις επόμενες υποενότητες.

### 3.3.1 Διαρροή προεπεξεργασίας στην πηγή

Όπως αναφέρθηκε στην Ενότητα 3.2, οι δημιουργοί κλιμάκωσαν κάθε στήλη του πίνακα στο διάστημα  $[-1, 1]$ . Η συνήθης μέθοδος για κάτι τέτοιο είναι η κλιμάκωση *min-max*,

$$x' = 2 \frac{x - m}{M - m} - 1, \quad (3.1)$$

όπου  $m$  και  $M$  η ελάχιστη και η μέγιστη τιμή της στήλης. Η τιμή  $m$  γίνεται  $-1$ , η  $M$  γίνεται  $+1$  και όλες οι υπόλοιπες πέφτουν ανάμεσα. Το γεγονός ότι κάθε στήλη του πίνακα φτάνει ακριβώς το  $-1$  και το  $+1$  δείχνει κλιμάκωση αυτού του τύπου.

Το ερώτημα είναι από ποια δεδομένα υπολογίστηκαν τα  $m$  και  $M$ . Ο κανόνας είναι ότι κάθε παράμετρος προεπεξεργασίας υπολογίζεται μόνο από το σύνολο εκπαίδευσης, γιατί το σύνολο ελέγχου παριστάνει ανθρώπους που το μοντέλο δεν έχει δει. Αν τα  $m$  και  $M$  υπολογιστούν και από το σύνολο ελέγχου, τότε η πληροφορία από αυτό περνά στις τιμές που βλέπει το μοντέλο κατά την εκπαίδευση. Η βιβλιογραφία ονομάζει την περίπτωση [L1.2] *Pre-processing on training and test set*, δηλαδή χρήση ολόκληρου του συνόλου δεδομένων για βήματα προεπεξεργασίας [35].

Αν τα  $m$  και  $M$  είχαν υπολογιστεί μόνο από το σύνολο εκπαίδευσης, οι τιμές  $-1$  και  $+1$  θα εμφανίζονταν μόνο σε samples του συνόλου εκπαίδευσης. Ο έλεγχος των αρχείων δείχνει ότι και οι 561 στήλες φτάνουν ακριβώς το  $-1$  και το  $+1$ , όταν τα δύο σύνολα θεωρηθούν μαζί. Επιπλέον, σε **109 στήλες** το  $+1$  και σε **95 στήλες** το  $-1$  το δίνει sample του συνόλου ελέγχου. Επομένως, τα  $m$  και  $M$  υπολογίστηκαν και από τα δεδομένα του συνόλου ελέγχου.

Η εργασία δε χρησιμοποιεί τις τιμές, όπως δίνονται, αλλά τις τυπικοποιεί ξανά με μέσο  $\mu$  και τυπική απόκλιση  $\sigma$  υπολογισμένα μόνο από το σύνολο εκπαίδευσης (Εξίσωση (3.4), Ενότητα 3.5) και αυτό αρκεί για να εξαφανιστεί η διαρροή. Η *min-max* της Εξίσωσης (3.1) απλώς μετατοπίζει και τεντώνει κάθε στήλη, δηλαδή  $x' = ax + b$  με  $a > 0$ . Μετά από αυτήν την αλλαγή, ο μέσος της στήλης γίνεται  $a\mu + b$  και η τυπική της απόκλιση  $a\sigma$ , οπότε η τυπικοποίηση δίνει

$$\frac{x' - (a\mu + b)}{a\sigma} = \frac{ax + b - a\mu - b}{a\sigma} = \frac{x - \mu}{\sigma}. \quad (3.2)$$

Τα  $a$  και  $b$ , δηλαδή το μόνο σημείο, όπου μπήκε το σύνολο ελέγχου, απαλείφονται και το αποτέλεσμα είναι το ίδιο, σαν να μην είχε γίνει καμία *min-max*. Ένας αριθμητικός έλεγχος, με

τυχαίες στήλες και τυχαία μετατόπιση και τέντωμα στην καθεμία πριν από την τυπικοποίηση, δίνει διαφορά το μέγιστο  $2,7 \cdot 10^{-15}$ , δηλαδή μόνο στρογγυλοποίηση.

Το αποτέλεσμα φαίνεται και στα ίδια τα δεδομένα, στον Πίνακα 3.3. Στην κλίμακα της πηγής, τόσο το σύνολο εκπαίδευσης όσο και το σύνολο ελέγχου εκτείνονται ακριβώς από  $-1$  έως  $+1$ , αφού η κλιμάκωση έγινε πάνω στην ένωσή τους. Μετά την τυπικοποίηση της εργασίας, το σύνολο εκπαίδευσης έχει μέσο 0 και τυπική απόκλιση 1, με διαφορά μόνο στο πέμπτο δεκαδικό από την αριθμητική απλής ακρίβειας. Αυτό περιμένει κανείς, αφού τα  $\mu$  και  $\sigma$  υπολογίστηκαν ακριβώς από αυτό. Το σύνολο ελέγχου έχει μέσο  $-0,01111$  και τυπική απόκλιση 0,92136, δηλαδή κοντά αλλά όχι ακριβώς 0 και 1, όπως αναμένεται για ανθρώπους που δε συμμετείχαν στον υπολογισμό. Το εύρος δεν περιορίζεται πλέον στο  $[-1, 1]$ , γιατί η τυπικοποίηση μετρά κάθε τιμή σε τυπικές αποκλίσεις από τον μέσο και οι ακραίες τιμές της Ενότητας 3.3.4 απέχουν από αυτόν πολλές τυπικές αποκλίσεις.

|                 | Κλίμακα της πηγής |         | Μετά την τυπικοποίηση |          |
|-----------------|-------------------|---------|-----------------------|----------|
|                 | εκπαίδευση        | έλεγχος | εκπαίδευση            | έλεγχος  |
| Μέσος όρος      | -0,5084           | -0,5093 | +0,00002              | -0,01111 |
| Τυπική απόκλιση | 0,2837            | 0,2667  | 1,00000               | 0,92136  |
| Ελάχιστη τιμή   | -1                | -1      | -24,07                | -12,33   |
| Μέγιστη τιμή    | +1                | +1      | +34,19                | +19,43   |

**Πίνακας 3.3.** Μέσος όρος όλων των τιμών, μέση τυπική απόκλιση των 561 στηλών και εύρος, στο σύνολο εκπαίδευσης και στο σύνολο ελέγχου. Στην πηγή τα δύο σύνολα μοιράζονται την ίδια κλιμάκωση. Μετά την τυπικοποίηση μόνο το σύνολο εκπαίδευσης έχει μέσο 0 και τυπική απόκλιση 1, γιατί μόνο από αυτό υπολογίστηκαν τα  $\mu$  και  $\sigma$ .

Αν τα  $\mu$  και  $\sigma$  είχαν υπολογιστεί από την ένωση των δύο συνόλων, δηλαδή με το ίδιο λάθος που έκανε η πηγή, το σύνολο εκπαίδευσης δε θα είχε μέσο 0 και τυπική απόκλιση 1 αλλά  $+0,0035$  και  $1,021$  αντιστοίχως. Οι τιμές του πίνακα αποδεικνύουν, επομένως, ότι η τυπικοποίηση δεν είδε το σύνολο ελέγχου. Η Εξίσωση (3.2), εξάλλου, δείχνει ότι η κλιμάκωση της πηγής απαλείφεται. Τα δύο μαζί σημαίνουν ότι στα δεδομένα που βλέπει το μοντέλο δεν έχει μείνει διαρροή. Προϋπόθεση αναγκαία είναι η τυπικοποίηση να εφαρμόζεται πάντα, αφού ένα πείραμα χωρίς αυτήν θα κληρονομούσε τη διαρροή της πηγής.

### 3.3.2 Διπλότυπες στήλες

Η σύγκριση κάθε στήλης με κάθε άλλη βρήκε 21 στήλες που είναι ακριβή αντίγραφα άλλων. Οι 8 από αυτές εξηγούνται εύκολα. Σε κάθε σήμα μέτρου (Mag) το `mean()` ταυτίζεται με το `sma()`, γιατί το μέτρο δεν παίρνει ποτέ αρνητικές τιμές και ο μέσος όρος των απόλυτων τιμών του συμπίπτει με τον απλό μέσο όρο. Οι άλλες 13 δεν εξηγούνται το ίδιο

εύκολα. Ολόκληρη η οικογένεια `tGravityAccMag` είναι ίδια με την `tBodyAccMag`, ενώ η βαρύτητα και η κίνηση του σώματος είναι διαφορετικά μεγέθη, με συσχέτιση Pearson (Εξίσωση (2.5)) μόλις  $r = 0,026$  στον άξονα  $X$ . Το πιθανότερο είναι ότι πρόκειται για σφάλμα κατά την κατασκευή του πίνακα.

Για την εργασία οι στήλες αυτές δεν έχουν ουσιαστική συνέπεια. Δεν προσθέτουν πληροφορία, απλώς δίνουν στο δίκτυο 21 εισόδους που επαναλαμβάνουν άλλες και κρατήθηκαν, ώστε η είσοδος να είναι ακριβώς ο δημοσιευμένος πίνακας. Θα είχαν σημασία μόνο σε ανάλυση της σημαντικότητας κάθε χαρακτηριστικού, όπου δύο ίδιες στήλες μοιράζονται τη σημαντικότητά τους. Τέτοια ανάλυση, όμως, δε γίνεται σε αυτήν την εργασία.

Κάτι ανάλογο ισχύει για τα ονόματα των χαρακτηριστικών `bandsEnergy()`. Σε αυτά, 42 ονόματα εμφανίζονται τρεις φορές, μία για κάθε άξονα, χωρίς ο άξονας να γράφεται στο όνομα, οπότε 126 στήλες έχουν ονόματα που επαναλαμβάνονται, ενώ οι τιμές τους διαφέρουν. Ούτε αυτό επηρεάζει την εργασία, αφού το μοντέλο δε βλέπει ονόματα. Για να μπορεί, πάντως, κάθε στήλη να αναφερθεί χωριστά, η υλοποίηση δίνει σε καθεμία μοναδικό όνομα στο αρχείο `feature_names.csv`.

### 3.3.3 Επικάλυψη διαδοχικών samples

Τα samples κατασκευάστηκαν με επικάλυψη 50%, δηλαδή κάθε sample μοιράζεται τα μισά του δεδομένα με το προηγούμενο και τα άλλα μισά με το επόμενο. Ο έλεγχος στα ακατέργαστα αρχεία επιβεβαιώνει ότι 6.752 από τα 7.072 ελεγμένα διαδοχικά ζεύγη παρουσιάζουν ακριβή επικάλυψη, δηλαδή 95,5%.

Η συνέπεια είναι ότι τα samples *δεν είναι ανεξάρτητα*. Δύο διαδοχικά samples του ίδιου ανθρώπου στην ίδια δραστηριότητα είναι σχεδόν το ίδιο δεδομένο. Αυτός ο τύπος διαρροής καταγράφεται, επίσης, στη βιβλιογραφία ως *[L3.2] Nonindependence between train and test samples* [35]. Στον επίσημο διαχωρισμό εκπαίδευσης και ελέγχου δεν εκδηλώνεται, επειδή αυτός είναι ανά άτομο και δύο διαδοχικά samples ανήκουν πάντα στον ίδιο άνθρωπο.

Εκδηλώνεται, όμως, σε κάθε *εσωτερικό* διαχωρισμό. Αν τα samples ενός συμμετέχοντα χωριστούν τυχαία σε εκπαίδευση και επικύρωση, τα δύο μέρη θα περιέχουν επικαλυπτόμενα ζεύγη και η επικύρωση θα είναι αισιόδοξη. Η βιβλιογραφία το διατυπώνει ρητά για τα πρωτόκολλα HAR, σημειώνοντας ότι ένα τέτοιο σχήμα είναι έντονα μεροληπτικό, επειδή ένα sample  $i$  και το  $i + 1$  μπορούν να βρεθούν σε διαφορετικά τμήματα [36]. Επιπλέον, το φαινομενικό όφελος της επικάλυψης εξαφανίζεται, όταν η αξιολόγηση γίνεται σε επίπεδο ατόμου [37]. Η υλοποίηση δεν κάνει κανέναν τέτοιο εσωτερικό διαχωρισμό (Ενότητα 3.5), οπότε το φαινόμενο δεν αγγίζει τις μετρήσεις της εργασίας.

### 3.3.4 Ανίχνευση ακραίων τιμών

Έγινε, επίσης, ανίχνευση ακραίων τιμών (*outlier detection*). Μια τιμή θεωρήθηκε ακραία, όταν απέχει περισσότερο από τρεις τυπικές αποκλίσεις από τον μέσο της στήλης της, δηλαδή όταν  $|\tilde{x}_j| > 3$  στην τυπικοποιημένη κλίμακα της Εξίσωσης (3.4). Για σύγκριση σε πίνακα ίδιου μεγέθους με τυχαίες τιμές από κανονική κατανομή, ακραίες είναι περίπου το 0,27% των τιμών και καμία γραμμή δεν έχει πάνω από 8. Στο σύνολο εκπαίδευσης, ακραίες είναι το 0,98% των τιμών. Επιπλέον, 449 samples, δηλαδή το 6,11%, έχουν ταυτόχρονα 21 ή περισσότερες τέτοιες τιμές. Στο σύνολο ελέγχου, το αντίστοιχο ποσοστό είναι 4,28%.

Τα samples αυτά δεν είναι σκόρπια. Συγκεντρώνονται στις δυναμικές δραστηριότητες, κυρίως στην κατάβαση σκάλας, όπου είναι το 22,5% των samples της, ενώ στην όρθια στάση δεν υπάρχει κανένα. Συγκεντρώνονται, επίσης, σε λίγους ανθρώπους, αφού τρεις από τους 21 συμμετέχοντες έχουν το 55,9% από αυτά.

Κανένα sample και κανέναν συμμετέχων δεν αφαιρέθηκε, για τρεις λόγους. Πρώτον, οι τιμές αυτές δε μοιάζουν με σφάλματα μέτρησης αλλά με το ίδιο το φαινόμενο. Τα σφάλματα μέτρησης θα ήταν σκόρπια σε όλα τα δεδομένα, ενώ η κατάβαση σκάλας παράγει πραγματικά απότομες επιταχύνσεις και κάποιοι άνθρωποι κινούνται πιο απότομα από άλλους. Δεύτερον, ένα κατώφλι αφαίρεσης θα έκοβε κυρίως μία δραστηριότητα και συγκεκριμένους ανθρώπους, δηλαδή ακριβώς τις διαφορές μεταξύ συμμετεχόντων που θέλει να μετρήσει η αποτίμηση της συνεισφοράς (Κεφάλαιο 5). Αν κάποιος συμμετέχων βλάπτει το μοντέλο, αυτό πρέπει να το δείξει η αποτίμηση και όχι να αποφασιστεί εκ των προτέρων. Ούτε υπάρχει συμμετέχων που να αποτελείται, κυρίως, από τέτοια samples, αφού ακόμη και στους δύο με το υψηλότερο ποσοστό είναι περίπου το 26% των δεδομένων τους. Τρίτον, όλες οι συγκρίσεις της εργασίας γίνονται πάνω στα ίδια ακριβώς δεδομένα, οπότε ό,τι προσθέτουν τα samples αυτά, το προσθέτουν εξίσου σε κάθε τοπολογία.

## 3.4 Διερευνητική Ανάλυση Δεδομένων

Η διερευνητική ανάλυση εξετάζει τρία πράγματα, πόσο ισορροπημένες είναι οι κλάσεις, πόσο διαφέρουν οι συμμετέχοντες μεταξύ τους και πόσο καθαρά ξεχωρίζουν οι δραστηριότητες στον χώρο των χαρακτηριστικών.

### 3.4.1 Ισορροπία κλάσεων

Οι έξι δραστηριότητες εκπροσωπούνται σχεδόν εξίσου. Στο σύνολο εκπαίδευσης η πολυπληθέστερη κλάση (LAYING, 1.407 samples) είναι μόλις 1,43 φορές η λιγότερο πολυπλη-

θής (WALKING\_DOWNSTAIRS, 986). Η κανονικοποιημένη εντροπία της κατανομής είναι 0,9956, όπου το 1 αντιστοιχεί σε τέλεια ισορροπία.

Η εντροπία αυτή ορίζεται ως  $H / \log K$ , όπου  $H = - \sum_k p_k \log p_k$  η εντροπία Shannon της κατανομής των κλάσεων,  $p_k$  το ποσοστό της κλάσης  $k$  και  $K = 6$ . Η διαίρεση με  $\log K$  φέρνει τη μετρική στο  $[0, 1]$ , ανεξάρτητα από το πλήθος των κλάσεων. Τιμή 0,9956 σημαίνει ότι η απόσταση από την ομοιόμορφη κατανομή είναι αμελητέα.

Η πρακτική συνέπεια είναι ότι δεν εφαρμόζεται καμία επαναδειγματοληψία, ούτε στάθμιση κλάσεων και ότι η ορθότητα και το macro-F1 αναμένεται να κινούνται μαζί, πράγμα που επιβεβαιώνεται στην Ενότητα 4.6.

### 3.4.2 Κατάτμηση σε συμμετέχοντες και ετερογένεια

Η κατάτμηση σε συμμετέχοντες δεν είναι τεχνητή, αφού κάθε ένας από τους 21 συμμετέχοντες είναι ένας από τους 21 εθελοντές του συνόλου εκπαίδευσης. Δε γίνεται καμία συνθετική κατασκευή non-IID κατανομών, κάτι που είναι συνήθης πρακτική στη βιβλιογραφία του FL [4].


Το ερώτημα είναι πόσο ετερογενής είναι αυτή η φυσική κατάτμηση. Η μορφή ετερογένειας που εξετάζεται εδώ είναι η *λοξότητα κατανομής ετικετών* (*label distribution skew*), δηλαδή το πόσο διαφέρουν οι περιθώριες κατανομές  $P_i(y)$  μεταξύ συμμετεχόντων, ακόμη και όταν η  $P(x | y)$  είναι κοινή [4]. Ποσοτικοποιείται με την απόσταση ολικής μεταβολής (*total variation*) της κατανομής κάθε συμμετέχοντα από τη συνολική:

$$\text{TV}(p_i, \bar{p}) = \frac{1}{2} \sum_{k=1}^K |p_{i,k} - \bar{p}_k|, \quad (3.3)$$

όπου  $p_{i,k}$  το ποσοστό της κλάσης  $k$  στα δεδομένα του συμμετέχοντα  $i$  και  $\bar{p}_k$  το αντίστοιχο ποσοστό στο σύνολο. Ο συντελεστής  $\frac{1}{2}$  υπάρχει, ώστε η μετρική να κινείται στο  $[0, 1]$ , αφού το άθροισμα των απόλυτων διαφορών δύο κατανομών δεν ξεπερνά ποτέ το 2. Τιμή 0 σημαίνει ταυτόσημες κατανομές και τιμή 1 σημαίνει ότι οι δύο κατανομές δεν έχουν καμία κοινή κλάση.

Στα δεδομένα της εργασίας, η διάμεση τιμή είναι 0,0423 και η μέγιστη 0,1209, ενώ δεν υπάρχει κανένα ζεύγος συμμετέχοντα και κλάσης που να λείπει, αφού κάθε συμμετέχων έχει samples και από τις έξι δραστηριότητες. Το Σχήμα 3.2 το δείχνει ανά συμμετέχοντα.

Με αυτά τα νούμερα η ομοσπονδία είναι *σχεδόν IID ως προς τις ετικέτες*. Αυτό δεν είναι αδυναμία του πειράματος αλλά ιδιότητα του συνόλου. Η συνέπειά της για τη σύγκριση των τοπολογιών συζητείται στην Ενότητα 4.6.1. Η ετερογένεια αυτού του συνόλου δεδομένων



**Σχήμα 3.2.** Πάνω: η σύνθεση των δεδομένων κάθε συμμετέχοντα ανά δραστηριότητα. Κάτω: η απόσταση ολικής μεταβολής της κατανομής του καθενός από τη συνολική. Καμία κλάση δε λείπει από κανέναν. Η διάμεση απόσταση είναι 0,0423.

δε βρίσκεται στο *τι* κάνει ο καθένας αλλά στο *πώς* το κάνει, αφού όλοι εκτέλεσαν το ίδιο πρωτόκολλο. Ενυπάρχει, δηλαδή, στη μορφή του σήματος, όχι στις ετικέτες. Το Κεφάλαιο 5 βρίσκει εκεί μια ασθενή σχέση με την αρνητική συνεισφορά, ενώ με τις ετικέτες καμία.


### 3.4.3 Διαχωρισιμότητα κλάσεων

Πριν από οποιαδήποτε εκπαίδευση, αξίζει να φανεί πόσο δύσκολο είναι το πρόβλημα, δηλαδή αν τα samples των έξι δραστηριοτήτων σχηματίζουν χωριστές ομάδες στον χώρο των 561 χαρακτηριστικών. Ένας χώρος 561 διαστάσεων δε σχεδιάζεται απευθείας, γι' αυτό χρησιμοποιείται η ανάλυση κύριων συνιστωσών (*Principal Component Analysis*, PCA). Η PCA βρίσκει τις κατευθύνσεις του χώρου κατά μήκος των οποίων τα samples διαφέρουν περισσότερο μεταξύ τους. Η πρώτη κύρια συνιστώσα είναι η κατεύθυνση της μεγαλύτερης διακύμανσης. Η δεύτερη είναι η κατεύθυνση της μεγαλύτερης διακύμανσης που απομένει, κάθετη στην πρώτη. Αν κάθε sample προβληθεί στις δύο πρώτες, προκύπτει μια εικόνα δύο διαστάσεων που κρατά όσο το δυνατόν περισσότερη από τη διαφοροποίηση των samples. Εδώ η PCA εφαρμόστηκε στα 7.352 samples του συνόλου εκπαίδευσης, μετά την τυπικοποίηση της Ενότητας 3.5, χωρίς τις ετικέτες, οι οποίες χρησιμοποιούνται μόνο για το χρώμα των σημείων. Οι δύο πρώτες συνιστώσες κρατούν μαζί το 57,4% της διακύμανσης και η πρώτη μόνη της το 50,8%.

Η προβολή δείχνει καθαρά τη δομή του προβλήματος (Σχήμα 3.3). Οι τρεις δυναμικές δραστηριότητες σχηματίζουν μια περιοχή και οι τρεις στατικές μια άλλη, με σαφή διαχωρισμό μεταξύ των δύο ομάδων. Μέσα σε κάθε ομάδα, όμως, οι δραστηριότητες επικαλύπτονται.

Το φαινόμενο ποσοτικοποιείται με τον συντελεστή σιλουέτας (*silhouette*), ο οποίος για κάθε σημείο συγκρίνει τη μέση απόσταση από τα σημεία της δικής του ομάδας με τη μέση απόσταση από τα σημεία της κοντινότερης ξένης ομάδας και κινείται στο  $[-1, 1]$ . Τιμές κοντά στο 1 σημαίνουν συμπαγείς και καλά διαχωρισμένες ομάδες, ενώ τιμές κοντά στο 0 σημαίνουν επικαλυπτόμενες. Με τις έξι δραστηριότητες ως ομάδες, η τιμή είναι 0,031 στον πλήρη χώρο, δηλαδή πρακτικά μηδενική. Με δύο μόνο ομάδες, δυναμικές έναντι στατικών, ανεβαίνει στο 0,396.


Η αντίθεση των δύο αριθμών είναι το ουσιαστικό εύρημα και προαναγγέλλει την ανάλυση σφαλμάτων της Ενότητας 4.7, γιατί δείχνει ότι το πρόβλημα δεν είναι η εύκολη διάκριση κίνησης από ακινησία αλλά η διάκριση μέσα σε κάθε ομάδα. Ο χαμηλός συντελεστής σιλουέτας των έξι κλάσεων δε σημαίνει απαραίτητα ότι το πρόβλημα είναι δύσκολο για έναν ταξινομητή. Ο συντελεστής μετρά μόνο αποστάσεις, ενώ ένας ταξινομητής μπορεί να μάθει σύνορα ανάμεσα σε ομάδες που δεν είναι συμπαγείς.



**Σχήμα 3.3.** Προβολή στις δύο πρώτες κύριες συνιστώσες. Ο διαχωρισμός των δυναμικών από τις στατικές δραστηριότητες είναι καθαρός, ενώ μέσα σε κάθε ομάδα οι κλάσεις επικαλύπτονται.

Η αιτία φαίνεται στο Σχήμα 3.4, με δύο από τα έτοιμα χαρακτηριστικά. Το μέτρο της επιτάχυνσης του σώματος χωρίζει τις δυναμικές από τις στατικές δραστηριότητες αλλά μέσα στις στατικές σχεδόν δεν αλλάζει. Και οι τρεις στάσεις είναι ακίνητες, άρα η συνιστώσα κίνησης είναι σχεδόν μηδενική και ό,τι απομένει για να τις ξεχωρίσει είναι η κλίση του κορμού, δηλαδή η κατεύθυνση της βαρύτητας ως προς τη συσκευή. Η κατάκλιση ξεχωρίζει καθαρά, γιατί εκεί αλλάζει ο προσανατολισμός ολόκληρου του κορμού. Η καθιστή και η όρθια στάση διαφέρουν πολύ λιγότερο και με επικάλυψη, αφού η κλίση της μέσης ανάμεσά τους είναι μικρή και διαφέρει από άνθρωπο σε άνθρωπο.

Οι δημιουργοί του συνόλου καταγράφουν την ίδια επικάλυψη και την αποδίδουν στη φυσική θέση της συσκευής πάνω στο σώμα [1]. Το ίδιο ζεύγος επανέρχεται στην ανάλυση σφαλμάτων της Ενότητας 4.7.



**Σχήμα 3.4.** Δύο από τα 561 χαρακτηριστικά, στο σύνολο εκπαίδευσης και σε τυπικοποιημένη κλίμακα (Ενότητα 3.5). Αριστερά, το μέσο μέτρο της επιτάχυνσης του σώματος ( $tBodyAccMag-mean()$ ) χωρίζει τις δυναμικές από τις στατικές δραστηριότητες. Δεξιά, η μέση συνιστώσα της βαρύτητας στον άξονα  $Y$  ( $tGravityAcc-mean() - Y$ ) ξεχωρίζει την κατάκλιση και, με επικάλυψη, την καθιστή από την όρθια στάση. Τα κουτιά περιέχουν το μεσαίο μισό των samples κάθε δραστηριότητας, η γραμμή μέσα τους είναι η διάμεσος. Οι κεραίες φτάνουν έως 1,5 φορές το ενδοτεταρτημοριακό εύρος. Οι ακραίες τιμές πέρα από αυτό (Ενότητα 3.3.4) δε σχεδιάζονται.

### 3.5 Προεπεξεργασία και Πρωτόκολλο Διαχωρισμού

Η προεπεξεργασία περιλαμβάνει ένα μόνο βήμα, την τυπικοποίηση  $z$ -score ανά χαρακτηριστικό,

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j}, \quad (3.4)$$


όπου  $\mu_j$  και  $\sigma_j$  ο μέσος και η τυπική απόκλιση της στήλης  $j$  υπολογισμένα αποκλειστικά από το σύνολο εκπαίδευσης. Οι λόγοι αναπτύχθηκαν στην Ενότητα 3.3.1. Το βήμα ακυρώνει τη διαρροή της πηγής και ταυτόχρονα φέρνει όλα τα χαρακτηριστικά σε συγκρίσιμη κλίμακα, πράγμα που διευκολύνει την εκπαίδευση.

Ο διαχωρισμός γίνεται σε δύο επίπεδα, το καθένα με δικό του σκοπό. Το Σχήμα 3.5 τα δείχνει μαζί με το σημείο όπου υπολογίζονται οι παράμετροι της τυπικοποίησης.

Το πρώτο είναι ο *διαχωρισμός ατόμων*. Οι 21 εθελοντές του επίσημου συνόλου εκπαίδευσης γίνονται οι συμμετέχοντες και οι 9 του συνόλου ελέγχου παραμένουν αποκλειστικά για αξιολόγηση. Κανένα άτομο δεν εμφανίζεται και στις δύο πλευρές, οπότε κάθε αξιολόγηση γίνεται σε ανθρώπους των οποίων τα δεδομένα δε χρησιμοποιήθηκαν ποτέ στην εκπαίδευση.

Το δεύτερο είναι η *κατάτμηση σε συμμετέχοντες*, η οποία συμπίπτει με το πρώτο, αφού αντιστοιχεί ένας συμμετέχων σε κάθε άτομο, χωρίς τυχαίο μοίρασμα samples. Η επιλογή αυτή είναι ουσιώδης για το Κεφάλαιο 5, γιατί κάνει την ερώτηση «πόσο συνεισέφερε ο συμ-

μετέχων  $i$ » ταυτόσημη με την ερώτηση «πόσο συνεισέφερε αυτός ο άνθρωπος». Με τυχαίο μοίρασμα η ερώτηση θα έχανε το νόημά της.



**Σχήμα 3.5.** Ο χωρισμός είναι δοσμένος από την πηγή και είναι ανά άτομο, οπότε κανένας άνθρωπος δεν εμφανίζεται και στα δύο σύνολα. Οι παράμετροι της τυτικοποίησης υπολογίζονται αποκλειστικά από τα 21 άτομα της εκπαίδευσης και έπειτα εφαρμόζονται και στα εννέα του ελέγχου.

Δε γίνεται κανένας εσωτερικός διαχωρισμός μέσα στους συμμετέχοντες. Η εργασία δε χρησιμοποιεί σύνολο επικύρωσης και κάθε συμμετέχων εκπαιδεύεται σε όλα τα samples του.

## Κεφάλαιο 4

# Υλοποίηση και Σύγκριση των Τοπολογιών Μάθησης

Το κεφάλαιο περιγράφει το λογισμικό, το μοντέλο και τις τρεις τοπολογίες μάθησης. Στη συνέχεια, τις συγκρίνει. Απαντά έτσι στο πρώτο ερευνητικό ερώτημα, δηλαδή στο τι κοστίζει η ομοσπονδιακή εκπαίδευση σε ορθότητα σε σχέση, αφενός, με την κεντρική και, αφετέρου, με την ατομική. Η αρχή που διέπει την υλοποίηση είναι ότι κάθε διαφορά μεταξύ των τοπολογιών πρέπει να είναι *σκόπιμη* και οτιδήποτε δεν είναι σκόπιμο μοιράζεται.


Μετά την υλοποίηση, περιγράφεται το πειραματικό πρωτόκολλο. Ακολουθεί ένας έλεγχος για το αν το δίκτυο ταιριάζει στο πρόβλημα, με σύγκριση απέναντι σε απλούστερα μοντέλα. Έπειτα, συγκρίνονται οι τρεις τοπολογίες. Το κεφάλαιο κλείνει με την ανάλυση των σφαλμάτων του μοντέλου, η οποία οδηγεί στο Κεφάλαιο 5.

### 4.1 Οργάνωση του Λογισμικού

Η υλοποίηση είναι γραμμένη σε Python. Τα δίκτυα υλοποιούνται με τη βιβλιοθήκη PyTorch [38], οι μετρικές με το scikit-learn [13] (Ενότητα 2.1.2) και ο KernelSHAP με τη βιβλιοθήκη shap [20] (Ενότητα 5.2.1). Τα αποτελέσματα αναπαράγονται με τις εκδόσεις των βιβλιοθηκών που δηλώνει το αρχείο απαιτήσεων του κώδικα.

Η οργάνωση σε υπομονάδες ακολουθεί το σχήμα ενός υπάρχοντος αποθετηρίου αναφοράς για ομοσπονδιακή μάθηση [39], με έναν φάκελο ανά ρόλο (Σχήμα 4.1). Ο φάκελος `dataset` αφορά τη φόρτωση και την προεπεξεργασία και ο `common` ό,τι μοιράζονται όλες οι τοπολογίες. Υπάρχει επίσης από ένας φάκελος για κάθε τοπολογία (`centralized`, `federated`, `local_only`). Η αποτίμηση της συνεισφοράς του Κεφαλαίου 5 έχει δικό της φάκελο (`contribution`). Η ροή της δίνεται στα Σχήματα 5.2 και 5.7.

Η κρίσιμη απόφαση βρίσκεται στο τι περιέχει το `common`, δηλαδή *μία* αρχιτεκτονική μοντέλου, *ένας* βρόχος εκπαίδευσης και *μία* υλοποίηση μετρικών, τα οποία «καλούν» και οι τρεις τοπολογίες. Ο λόγος είναι μεθοδολογικός. Αν ο κεντρικός και ο ομοσπονδιακός κώδι-



**Σχήμα 4.1.** Ένας φάκελος ανά ρόλο. Ό,τι πρέπει να είναι κοινό ζει στο `common` και «καλείται» από τις τρεις τοπολογίες, ώστε καμία διαφορά μεταξύ τους να μην οφείλεται σε αποκλίνοντα αντίγραφα κώδικα. Η αποτίμηση συνεισφοράς διαβάζει τις ενημερώσεις της ομοσπονδιακής και, για το δεύτερο παίγνιο, καλεί την κεντρική εκπαίδευση.

κας είχαν ο καθένας το δικό του αντίγραφο του βρόχου εκπαίδευσης, τα δύο αντίγραφα θα απέκλιναν και τότε η σύγκριση «κεντρική έναντι ομοσπονδιακής» θα μετρούσε τη διαφορά των αντιγράφων και όχι τη διαφορά των τοπολογιών.

Δύο αποφάσεις της ομοσπονδιακής εκπαίδευσης έχουν δικό τους αρχείο στον φάκελο `federated/fl/`. Το `selectors.py` αποφασίζει ποιοι συμμετέχουν σε κάθε γύρο και ο φάκελος `aggregation/` πώς ενώνονται οι ενημερώσεις τους. Στα κύρια πειράματα συμμετέχουν όλοι, ενώ στο πείραμα αφαίρεσης της Ενότητας 5.7.4 όλοι εκτός από μια λίστα συμμετεχόντων.

Η είσοδος δεδομένων είναι ενοποιημένη σε δύο επίπεδα. Τα ακατέργαστα αρχεία διαβάζονται μία φορά, τυπικοποιούνται και γράφονται στον δίσκο ως παραδοτέο σύνολο μαζί με αρχείο προέλευσης. Από εκεί και πέρα, κάθε πείραμα φορτώνει το παραδοτέο. Κάθε φόρτωση επαληθεύει αθροίσματα ελέγχου SHA-256 σε 26 αρχεία πηγής και 9 αρχεία εξόδου και, αν κάποιο αρχείο έχει αλλάξει, σταματά, αντί να προχωρήσει με άγνωστα δεδομένα. Κάθε αρχείο αποτελεσμάτων κρατά επιπλέον το αποτύπωμα των δεδομένων από τα οποία παρήχθη. Ο έλεγχος έχει σημασία για τα πειράματα του Κεφαλαίου 5, που διαρκούν ώρες και διαβάζουν το ίδιο παραδοτέο με τα κύρια πειράματα. Αν το σύνολο άλλαζε ανάμεσα σε δύο εκτελέσεις, τα δύο αποτελέσματα θα έπαυαν να είναι συγκρίσιμα χωρίς κανένα ορατό σημάδι.

## 4.2 Αρχιτεκτονική και Υπερπαράμετροι του Δικτύου

Το μοντέλο είναι ένα απλό τεχνητό νευρωνικό δίκτυο (*Artificial Neural Network*, ANN), συγκεκριμένα ένα πολυεπίπεδο δίκτυο εμπρόσθιας τροφοδότησης (Ενότητα 2.1) με δύο κρυφά επίπεδα, διαστάσεων  $561 \rightarrow 256 \rightarrow 128 \rightarrow 6$ , με ReLU και dropout μετά από κάθε κρυφό επίπεδο και γραμμικό επίπεδο εξόδου έξι μονάδων. Στο εξής αναφέρεται ως «το

δίκτυο» και, όπου συγκρίνεται με άλλα μοντέλα, ως «δίκτυο ANN», όπως και στα σχήματα. Το συνολικό πλήθος εκπαιδευσιμων παραμέτρων είναι  $(561 \cdot 256 + 256) + (256 \cdot 128 + 128) + (128 \cdot 6 + 6) = 177.542$ .

Το πλήρως συνδεδεμένο δίκτυο επιλέχθηκε ως η απλούστερη αρχιτεκτονική που ταιριάζει στην αναπαράσταση. Ο άξονας της εισόδου δεν είναι ούτε χρόνος, ούτε χώρος αλλά δείκτης χαρακτηριστικού. Μια συνέλιξη πάνω του θα υπέθετε ότι γειτονικοί δείκτες είναι σχετικοί, υπόθεση που δεν ισχύει, αφού το χαρακτηριστικό υπ' αριθμόν 40, μια συσχέτιση αξόνων της επιτάχυνσης του σώματος, δεν έχει καμία φυσική γειτνίαση με το 41, τη μέση τιμή της βαρύτητας. Το πλήρως συνδεδεμένο δίκτυο δεν κάνει τέτοια υπόθεση.

Οι υπερπαραμέτροι δηλώνονται ως *σταθερές, χωρίς αναζήτηση*. Αυτό είναι περιορισμός και καταγράφεται ως τέτοιος στην Ενότητα 6.2, αλλά δύο από τις τιμές δεν είναι αυθαίρετες. Ο ρυθμός μάθησης  $10^{-3}$  του Adam είναι ακριβώς η προτεινόμενη προεπιλογή του αρχικού άρθρου, το οποίο αναφέρει ότι καλές προεπιλεγμένες ρυθμίσεις για τα προβλήματα που δοκιμάστηκαν είναι  $\alpha = 0,001$  [9]. Το dropout 0,3 αντιστοιχεί σε πιθανότητα διατήρησης  $p = 0,7$ , αφού η υλοποίηση του PyTorch παραμετροποιείται με την πιθανότητα απόρριψης. Το αρχικό άρθρο δείχνει ότι το σφάλμα είναι επίπεδο για  $0,4 \leq p \leq 0,8$  [10]. Η τιμή βρίσκεται, δηλαδή, μέσα στο επίπεδο τμήμα της καμπύλης. Δε βελτιστοποιήθηκε αλλά ούτε επιλέχθηκε τυχαία.

Οι υπόλοιπες σταθερές είναι το μέγεθος παρτίδας 64, η διασταυρούμενη εντροπία ως συνάρτηση κόστους, ο Adam ως βελτιστοποιητής και οι διαστάσεις των κρυφών επιπέδων 256 και 128.

## 4.3 Οι Τρεις Τοπολογίες Μάθησης

### 4.3.1 Κεντρική εκπαίδευση

Η κεντρική τοπολογία είναι το άνω όριο αναφοράς. Όλα τα δεδομένα των 21 συμμετεχόντων συγκεντρώνονται σε ένα σύνολο 7.352 samples και εκπαιδεύεται ένα μοντέλο για 100 εποχές. Δεν υπάρχει έννοια συμμετέχοντα σε αυτή τη ρύθμιση. Η αξιολόγηση γίνεται στο κοινό σύνολο ελέγχου των 2.947 samples.

Η εκπαίδευση γίνεται με την ίδια συνάρτηση που χρησιμοποιεί κάθε συμμετέχων στην ομοσπονδιακή τοπολογία, με το ίδιο μέγεθος παρτίδας, τον ίδιο βελτιστοποιητή και τον ίδιο ρυθμό μάθησης (Ενότητα 4.2). Οι δύο τοπολογίες διαφέρουν, επομένως, στο πού βρίσκονται τα δεδομένα και στο πώς ενώνονται οι ενημερώσεις, όχι στον βρόχο εκπαίδευσης. Η διαφορά αυτή έχει συνέπεια. Εδώ τα samples ανακατεύονται σε κάθε εποχή, οπότε κάθε παρτίδα περιέχει samples πολλών ανθρώπων και κάθε βήμα του βελτιστοποιητή βλέπει ένα μείγμα του πληθυσμού. Στην ομοσπονδιακή τοπολογία, αντίθετα, κάθε τοπική ενημέρωση

προέρχεται από έναν μόνο χρήστη και το μείγμα σχηματίζεται μόνο στη συνάθροιση. Από αυτή τη διαφορά προκύπτει το *client drift* της Ενότητας 2.2.3, όταν τα δεδομένα των ανθρώπων διαφέρουν μεταξύ τους.

Ο χαρακτηρισμός «άνω όριο» περιγράφει ρόλο αναφοράς, όχι εγγύηση. Τίποτα δεν αποκλείει την ομοσπονδιακή τοπολογία να φτάσει ή να ξεπεράσει την κεντρική σε κάποιο seed, δηλαδή σε κάποια επανάληψη με άλλη τιμή εκκίνησης της γεννήτριας τυχαίων αριθμών.

### 4.3.2 Ομοσπονδιακή εκπαίδευση με FedAvg

Η ομοσπονδιακή τοπολογία υλοποιεί τον FedAvg κατά το πρότυπο του αρχικού άρθρου [3]. Σε κάθε γύρο, ο εξυπηρετητής στέλνει τις τρέχουσες παραμέτρους σε όλους τους συμμετέχοντες, ο καθένας εκπαιδεύει για μία τοπική εποχή πάνω στα δικά του δεδομένα και ο εξυπηρετητής συναθροίζει με βάρη ανάλογα του πλήθους samples κάθε συμμετέχοντα, σύμφωνα με την Εξίσωση (2.10).

Χρησιμοποιείται *πλήρης συμμετοχή*, που σημαίνει ότι και οι 21 συμμετέχοντες εκπαιδεύουν και στέλνουν ενημέρωση σε κάθε γύρο ( $C = 1$ ). Η επιλογή αυτή δεν είναι απλοποίηση που κρύβει τα δύσκολα. Αντιθέτως, όπως αναφέρθηκε στην Ενότητα 2.2.3, η απόκλιση των συμμετεχόντων επιμένει ακόμη και όταν συμμετέχουν όλοι σε κάθε γύρο [15], οπότε η πλήρης συμμετοχή *απομονώνει* το φαινόμενο, αντί να το συγκαλύπτει. Υπάρχει και μια δεύτερη, πρακτική συνέπεια, που αφορά άμεσα το Κεφάλαιο 5. Όταν όλοι συμμετέχουν πάντα, το παίγνιο κάθε γύρου έχει πάντα τους ίδιους 21 παίκτες και οι τιμές είναι αθροίσιμες στους γύρους, χωρίς διόρθωση για διαφορετική συχνότητα συμμετοχής.

Δύο σημεία της υλοποίησης αξίζει να δηλωθούν, επειδή διαφέρουν από προφανείς εναλλακτικές. Πρώτον, κάθε συμμετέχων κρατά *ανεξάρτητο αντίγραφο* του μοντέλου. Σε υλοποιήσεις, όπου όλοι οι συμμετέχοντες μοιράζονται το ίδιο αντικείμενο δικτύου, η «ομοσπονδία» εκφυλίζεται σε σειριακή εκπαίδευση, όπου ο καθένας συνεχίζει από εκεί που σταμάτησε ο προηγούμενος, πράγμα που αλλάζει εντελώς τη σημασιολογία του αλγορίθμου. Δεύτερον, οι εσωτερικές καταστάσεις του Adam κάθε συμμετέχοντα *διατηρούνται* μεταξύ γύρων. Αυτό είναι σχεδιαστική επιλογή και όχι το μόνο δυνατό, αφού η εναλλακτική θα ήταν ο μηδενισμός τους σε κάθε γύρο. Δηλώνεται εδώ, ώστε το πείραμα να είναι αναπαραγώγιμο.

### 4.3.3 Ατομική εκπαίδευση

Η ατομική τοπολογία είναι το κάτω όριο αναφοράς και απαντά στο ερώτημα «τι θα είχε ο καθένας, αν έμενε μόνος». Κάθε ένας από τους 21 συμμετέχοντες εκπαιδεύει δικό του μοντέλο αποκλειστικά στα δικά του δεδομένα, για 100 εποχές και χωρίς καμία επικοινωνία. Αξιολογείται στο *ίδιο* κοινό σύνολο ελέγχου των 2.947 samples με τις άλλες δύο τοπολογίες.

Η ταύτιση του συνόλου αξιολόγησης είναι αυτό που κάνει τη σύγκριση έγκυρη. Αν κάθε συμμετέχων αξιολογούνταν σε δικό του κρατημένο τμήμα, οι αριθμοί δε θα ήταν συγκρίσιμοι μεταξύ τους, ούτε με τις άλλες τοπολογίες, γιατί το καθένα θα ήταν διαφορετικής δυσκολίας. Επειδή κάθε συμμετέχων εκπαιδεύεται και αξιολογείται σε 20 διαφορετικές αρχικοποιήσεις, η τοπολογία αυτή παράγει  $21 \times 20 = 420$  εκτελέσεις.

## 4.4 Πειραματικό Πρωτόκολλο και Μετρήσεις

Όλα τα πειράματα εκτελούνται με 20 διαφορετικά seeds (0 έως 19) και αναφέρονται ως μέσος όρος με την τυπική απόκλισή τους. Ο υπολογισμός γίνεται σε CPU, ώστε τα αποτελέσματα να είναι ντετερμινιστικά και αναπαραγώγιμα. Ο υπολογιστικός προϋπολογισμός είναι *σταθερός και αντιστοιχισμένος*, με 100 εποχές για την κεντρική και την ατομική τοπολογία και 100 γύρους επί μία τοπική εποχή για την ομοσπονδιακή. Δε χρησιμοποιείται σύνολο επικύρωσης και δεν εφαρμόζεται πρόωρος τερματισμός, οπότε κάθε τοπολογία εκπαιδεύεται για ολόκληρο τον προϋπολογισμό.

Όλες οι μετρήσεις γίνονται στο κοινό σύνολο ελέγχου των 2.947 samples, τα οποία προέρχονται από 9 ανθρώπους που δεν εμφανίζονται ποτέ στην εκπαίδευση. Η αξιολόγηση είναι επομένως *subject-independent*, το πρωτόκολλο δηλαδή που η βιβλιογραφία των μεθόδων αναγνώρισης δραστηριότητας θεωρεί μη παραπλανητικό [36], [37]. Αναφέρονται δύο μετρικές, η ορθότητα (Εξίσωση (2.1)) και το macro-F1 (Εξίσωση (2.4)), για λόγους που εξηγούνται στην Ενότητα 2.1.2. Επειδή οι έξι κλάσεις είναι σχεδόν ισορροπημένες (Ενότητα 3.4.1), οι δύο αναμένεται να κινούνται μαζί και αναφέρονται και οι δύο ακριβώς για να φαίνεται ότι όντως κινούνται.

**Η τυπική απόκλιση μεταξύ seeds.** Η τιμή που ακολουθεί το  $\pm$  είναι η **τυπική απόκλιση μεταξύ των 20 εκτελέσεων**. Μετράει δηλαδή πόσο κουνιέται το αποτέλεσμα, όταν αλλάζουν οι τυχαίες αρχικές τιμές των παραμέτρων του δικτύου (η αρχικοποίηση των βαρών), η τυχαία σειρά με την οποία τα samples μοιράζονται σε παρτίδες των 64 σε κάθε εποχή και οι μονάδες που απενεργοποιεί τυχαία το dropout, ενώ τα δεδομένα μένουν ίδια. Δεν είναι διάστημα εμπιστοσύνης και δε λέει πόσο θα άλλαζε το αποτέλεσμα σε άλλους ανθρώπους. Η διάκριση είναι

ουσιώδης, γιατί το σύνολο ελέγχου περιέχει 2.947 samples αλλά μόνο 9 ανεξάρτητα άτομα. Τα samples του ίδιου ατόμου είναι, επιπλέον, συσχετισμένα, τόσο επειδή προέρχονται από τον ίδιο άνθρωπο, όσο και επειδή επικαλύπτονται κατά 50% (Ενότητα 3.3.3). Ένα διάστημα εμπιστοσύνης που θα υπολόγιζε τα 2.947 samples ως ανεξάρτητα θα ήταν πολύ στενότερο από το πραγματικό. Η αβεβαιότητα γενίκευσης σε νέους ανθρώπους δεν ποσοτικοποιείται εδώ και δηλώνεται ως περιορισμός στην Ενότητα 6.2.

**Η τελική τιμή και όχι η καλύτερη.** Όλα τα νούμερα που ακολουθούν είναι η επίδοση στο τέλος του προϋπολογισμού, δηλαδή στην εποχή ή στον γύρο 100. Δεν είναι **ποτέ** η καλύτερη τιμή που εμφανίστηκε κατά τη διάρκεια. Η διάκριση δεν είναι τυπική, αφού στην ομοσπονδιακή τοπολογία η καλύτερη τιμή κάθε seed εμφανίζεται σε διαφορετικό γύρο (από τον 33ο έως τον 89ο) και κατά μέσο όρο είναι 94,50, δηλαδή σχεδόν 0,40 μονάδες πάνω από την τελική. Η αναφορά της θα ήταν, όμως, επιλογή πάνω στο σύνολο ελέγχου, αφού το «ποιος γύρος ήταν ο καλύτερος» καθορίζεται από 100 αξιολογήσεις σε αυτό ακριβώς το σύνολο. Η τελική τιμή είναι η μόνη που δεν εμπεριέχει τέτοια επιλογή.

**Ζευγαρωτή σύγκριση ανά seed.** Η σύγκριση μεταξύ τοπολογιών γίνεται πάντα *ζευγαρωτά*. Για κάθε seed  $s$  υπολογίζεται η διαφορά των δύο τοπολογιών. Αναφέρεται ο μέσος όρος των διαφορών μαζί με το πλήθος των seeds στα οποία η διαφορά έχει το ίδιο πρόσημο. Αυτό είναι πιο πληροφοριακό από τη σύγκριση δύο ανεξάρτητων μέσων όρων, γιατί απομονώνει τη μεταβλητότητα που οφείλεται στην αρχικοποίηση. Δεν αναφέρεται στατιστικό έλεγχο υπόθεσης, γιατί οι 20 εκτελέσεις δεν είναι ανεξάρτητα δείγματα από πληθυσμό ατόμων αλλά επαναλήψεις πάνω στα ίδια δεδομένα.

**Συγκρίσιμα μόνο τα αντιστοιχισμένα αποτελέσματα.** Κατά την ανάπτυξη, βρέθηκε ότι ίδιο seed και ίδιο πλήθος εποχών αλλά με διαφορετικά σημεία ενδιάμεσης αξιολόγησης δίνουν διαφορετικό αποτέλεσμα, επειδή η αξιολόγηση καταναλώνει τυχαιότητα και μετακινεί τη γεννήτρια. Δύο αριθμοί είναι επομένως συγκρίσιμοι, μόνο αν παρήχθησαν από ταυτόσημη ρύθμιση, κανόνας που εφαρμόζεται σε όλες τις συγκρίσεις της εργασίας. Για τον ίδιο λόγο, κάθε αριθμός του κειμένου καταγράφεται σε μητρώο μαζί με το αποθηκευμένο αποτέλεσμα από το οποίο προέρχεται. Ένας αυτόματος έλεγχος εντοπίζει κάθε αριθμό χωρίς δηλωμένη προέλευση. Η προσέγγιση αυτή απαντά στην καταγεγραμμένη διαπίστωση ότι η διαρροή και τα προβλήματα αναπαραγωγιμότητας έχουν οδηγήσει σε υπερβολικά αισιόδοξα συμπεράσματα σε δημοσιεύσεις δεκαεπτά επιστημονικών πεδίων [35].

## 4.5 Σύγκριση του Δικτύου με Απλούστερα Μοντέλα


Πριν συγκριθούν οι τρεις τοπολογίες μεταξύ τους, χρειάζεται να είναι γνωστό πόση από την επίδοση οφείλεται στο *μοντέλο*. Όλες οι συγκρίσεις που ακολουθούν κρατούν την αρχιτεκτονική σταθερή, οπότε, αν το συγκεκριμένο δίκτυο ANN ήταν υπερβολικά ισχυρό ή υπερβολικά αδύναμο για το πρόβλημα, η επιλογή θα μετέφερε συστηματικό σφάλμα σε κάθε επόμενο νούμερο.

Για τον σκοπό αυτό, εκπαιδεύτηκαν κεντρικά, εκτός από το δίκτυο ANN, τρία απλούστερα μοντέλα, συγκεκριμένα η **λογιστική παλινδρόμηση**, μια **γραμμική μηχανή διανυσμάτων υποστήριξης** (*Support Vector Machine*, SVM) και ένα **Random Forest**. Η λογιστική παλινδρόμηση είναι το *ίδιο* μοντέλο χωρίς τα κρυφά επίπεδα, δηλαδή ένα μοναδικό γραμμικό επίπεδο  $561 \rightarrow 6$  με 3.372 παραμέτρους έναντι των 177.542 του δικτύου ANN. Εκπαιδεύεται με τον ίδιο βρόχο και τον ίδιο βελτιστοποιητή. Το SVM και το Random Forest προέρχονται από τη βιβλιοθήκη scikit-learn [13] και εκτελούνται με τις προεπιλεγμένες ρυθμίσεις της. Και τα τέσσερα βλέπουν τα ίδια 20 seeds και το ίδιο σύνολο ελέγχου. Κανένα δε ρυθμίστηκε, ώστε η σύγκριση να μη μετράει τη διαφορά στην προσπάθεια ρύθμισης. Τα αποτελέσματα δίνονται στον Πίνακα 4.1.

| Μοντέλο                                                        | Παράμετροι | Ορθότητα (%)     | macro-F1 (%)     |
|----------------------------------------------------------------|------------|------------------|------------------|
| Δίκτυο ANN $561 \rightarrow 256 \rightarrow 128 \rightarrow 6$ | 177.542    | $94,94 \pm 0,65$ | $94,88 \pm 0,67$ |
| Λογιστική παλινδρόμηση $561 \rightarrow 6$                     | 3.372      | $94,84 \pm 0,29$ | $94,86 \pm 0,29$ |
| Γραμμικό SVM                                                   | 3.372      | $96,17 \pm 0,00$ | $96,22 \pm 0,00$ |
| Random Forest                                                  | 100 δέντρα | $92,63 \pm 0,23$ | $92,43 \pm 0,23$ |

**Πίνακας 4.1.** Κεντρική εκπαίδευση, 20 seeds, κοινό σύνολο ελέγχου. Το  $\pm$  είναι τυπική απόκλιση μεταξύ seeds. Κανένα μοντέλο δε ρυθμίστηκε. Το γραμμικό SVM δίνει την ίδια πρόβλεψη σε όλα τα seeds, γι' αυτό η τυπική απόκλισή του είναι μηδέν.

**Ισοπαλία με τη λογιστική παλινδρόμηση.** Η διαφορά των 0,10 μονάδων από το δίκτυο ANN δεν αντέχει τον ζευγαρωτό έλεγχο. Η τυπική απόκλιση της διαφοράς ανά seed είναι 0,71 μονάδες, το εύρος της πάει από  $-1,19$  έως  $+1,59$  και το δίκτυο ANN υπερτερεί σε **12 από τα 20 seeds** (Σχήμα 4.2). Με το κριτήριο της σταθερότητας του προσήμου, που εφαρμόζεται σε κάθε σύγκριση αυτού του κεφαλαίου, τα δύο μοντέλα **δεν ξεχωρίζουν με συνέπεια**. Η λογιστική παλινδρόμηση θα μπορούσε, επίσης, να μπει στην ομοσπονδία χωρίς καμία αλλαγή, αφού εκπαιδεύεται με τον ίδιο βρόχο. Ο λόγος που δεν επιλέχθηκε, λοιπόν, δεν είναι ότι υστερεί. Δεν έδωσε, όμως, και λόγο να εγκαταλειφθεί η αρχική σχεδίαση, αφού η ισοπαλία σημαίνει ότι η επιλογή του δικτύου δεν κοστίζει ορθότητα.



**Σχήμα 4.2.** Αριστερά: η διαφορά των δύο μοντέλων στο ίδιο seed, ταξινομημένη. Σε οκτώ από τα 20 seeds είναι αρνητική. Δεξιά: τα δύο μοντέλα στον ίδιο άξονα, ένα σημείο ανά seed. Η διαγώνιος είναι η ισοπαλία. Τα σημεία πέφτουν και στις δύο πλευρές της.

Το αποτέλεσμα αυτό αφορά τα δεδομένα και όχι το δίκτυο. Τα 561 χαρακτηριστικά δεν είναι ακατέργαστο σήμα αλλά στατιστικά μεγέθη υπολογισμένα από ειδικούς πάνω στο σήμα, στο πεδίο του χρόνου και της συχνότητας [1], δηλαδή ένα μεγάλο μέρος της εργασίας που θα ανέθετε κανείς σε κρυφά επίπεδα έχει ήδη γίνει, πριν φτάσουν τα δεδομένα στο μοντέλο. Όταν αυτό συμβαίνει, οι κλάσεις γίνονται σε μεγάλο βαθμό γραμμικά διαχωρίσιμες και η πρόσθετη χωρητικότητα δεν έχει πού να αποδώσει. Η παρατήρηση ότι σε πινακοειδή δεδομένα τα νευρωνικά δίκτυα δεν έχουν αυτονόητο προβάδισμα είναι καταγεγραμμένη κανονικότητα και όχι ιδιαιτερότητα αυτού του συνόλου [40].

**Το γραμμικό SVM, υψηλότερο αλλά εκτός ομοσπονδίας.** Το SVM δίνει τη μεγαλύτερη ορθότητα, 96,17%, κατά μέσο όρο 1,23 μονάδες πάνω από το δίκτυο ANN και πάνω από αυτό και στα 20 seeds. Η υπεροχή αφορά τα εννέα άτομα του συνόλου ελέγχου και δεν είναι γνωστό αν μεταφέρεται σε άλλους ανθρώπους (Ενότητα 4.4). Ο λόγος που δεν υιοθετείται είναι ο τρόπος εκπαίδευσής του. Ο επιλυτής του, το LibLinear [13], παίρνει ολόκληρο το σύνολο εκπαίδευσης σε μία κλήση και επιστρέφει μία λύση, γι' αυτό και η πρόβλεψη είναι ίδια σε όλα τα seeds. Με τις προεπιλογές, μάλιστα, σταματά στο όριο των 1.000 επαναλήψεων, χωρίς να δηλώσει σύγκλιση. Ο FedAvg, αντίθετα, συνδυάζει τοπική στοχαστική κατάβαση κλίσης σε κάθε συμμετέχοντα με μέσο όρο των μοντέλων στον εξυπηρετητή [3]. Για να μπει στην ομοσπονδία, το SVM θα έπρεπε να ξαναγραφτεί ως μοντέλο που εκπαιδεύεται με βήματα κλίσης πάνω στη δική του συνάρτηση κόστους. Αυτό γίνεται αλλά είναι άλλη διαδικασία εκπαίδευσης και δεν είναι αυτός ο σκοπός της εργασίας.

**Το Random Forest, χαμηλότερο και χωρίς παραμέτρους για μέσο όρο.** Το Random Forest είναι το ασθενέστερο από τα τέσσερα, κατά μέσο όρο 2,3 μονάδες κάτω από το δίκτυο ANN και κάτω από αυτό και στα 20 seeds. Η βιβλιογραφία βρίσκει τα δέντρα ισχυρότερα

σε πινακοειδή δεδομένα μεσαίου μεγέθους, με ρυθμισμένες υπερπαραμέτρους [40], ενώ εδώ, με τις προεπιλογές, έρχεται τελευταίο. Έχει επιπλέον δομικό εμπόδιο. Ο FedAvg ενώνει τα μοντέλα των συμμετεχόντων με σταθμισμένο μέσο όρο των παραμέτρων τους [3], ενώ ένα σύνολο δέντρων αποφάσεων δεν έχει διάνυσμα παραμέτρων πάνω στο οποίο να οριστεί μέσος όρος. Χωρίς ενημέρωση παραμέτρων ανά συμμετέχοντα, δεν ορίζεται ούτε το παίγνιο του Κεφαλαίου 5.

**Ο λόγος που κρατιέται το δίκτυο.** Ο λόγος δεν είναι ότι ταξινομεί καλύτερα, αφού το SVM το ξεπερνά στο σύνολο ελέγχου και η λογιστική παλινδρόμηση το φτάνει. Το ερώτημα της εργασίας, όμως, δεν είναι ποιος ταξινομητής πετυχαίνει τη μεγαλύτερη ορθότητα. Και οι τρεις τοπολογίες, όπως και ολόκληρο το παίγνιο του Κεφαλαίου 5, απαιτούν μοντέλο που εκπαιδεύεται με βήματα κλίσης και παράγει *ενημέρωση παραμέτρων ανά συμμετέχοντα*, την οποία ο FedAvg συνενώνει με σταθμισμένο μέσο όρο [3]. Από τα τέσσερα μοντέλα, όπως εκπαιδεύτηκαν εδώ, το κάνουν μόνο το δίκτυο ANN και η λογιστική παλινδρόμηση. Αυτά τα δύο δεν ξεχωρίζουν σε ορθότητα. Κρατήθηκε το δίκτυο, που ήταν η αρχική σχεδίαση της εργασίας. Είναι και μία από τις μορφές μοντέλου με τις οποίες παρουσιάστηκε ο ίδιος ο FedAvg, ένα πολυεπίπεδο δίκτυο με δύο κρυφά επίπεδα και ενεργοποίηση ReLU [3].

Το εύρημα καταγράφεται, πάντως, ως αποτέλεσμα και επανέρχεται στους περιορισμούς (Ενότητα 6.2). Για αυτό το πρόβλημα, με αυτήν την αναπαράσταση, ένα μοντέλο με περίπου 53 φορές λιγότερες παραμέτρους θα αρκούσε.

## 4.6 Σύγκριση των Τριών Τοπολογιών

Ο Πίνακας 4.2 συνοψίζει το βασικό αποτέλεσμα της σύγκρισης.

| Τοπολογία μάθησης             | Ορθότητα (%)     | macro-F1 (%)     | Εκτελέσεις |
|-------------------------------|------------------|------------------|------------|
| Κεντρική (100 εποχές)         | 94,94 $\pm$ 0,65 | 94,88 $\pm$ 0,67 | 20         |
| Ομοσπονδιακή (100 $\times$ 1) | 94,11 $\pm$ 0,18 | 94,14 $\pm$ 0,18 | 20         |
| Ατομική (100 εποχές)          | 75,81 $\pm$ 5,14 | 74,86 $\pm$ 5,84 | 420        |

**Πίνακας 4.2.** Οι τρεις τοπολογίες μάθησης, 20 seeds, κοινό σύνολο ελέγχου 2.947 samples. Το  $\pm$  είναι τυπική απόκλιση μεταξύ εκτελέσεων.

### 4.6.1 Κόστος της αποκέντρωσης και όφελος της συνεργασίας

Το πρώτο εύρημα είναι ότι **το κόστος της αποκέντρωσης είναι μικρό**. Η ζευγαρωτή διαφορά κεντρικής μείον ομοσπονδιακής είναι  $+0,83$  μονάδες, με θετικό πρόσημο σε 17 από τα 20 seeds. Η ομοσπονδιακή τοπολογία φτάνει, δηλαδή, περίπου το 99,1% της επίδοσης που θα είχε η συγκέντρωση όλων των δεδομένων, χωρίς κανένα δεδομένο να φύγει από τη συσκευή του.

Η ερμηνεία πρέπει να είναι προσεκτική. Το αποτέλεσμα αυτό *αναμένεται* σε αυτή τη ρύθμιση και δεν πρέπει να παρουσιαστεί ως έκπληξη, γιατί, όπως έδειξε η Ενότητα 3.4.2, οι συμμετέχοντες είναι σχεδόν IID ως προς τις ετικέτες, με διάμεση απόσταση ολικής μεταβολής 0,0423 και καμία κλάση να λείπει από κανέναν. Ο FedAvg δυσκολεύεται, όταν οι κατανομές ετικετών αποκλίνουν έντονα [15], πράγμα που εδώ δε συμβαίνει. Ένα αντίστοιχο πείραμα με συνθετικά κατασκευασμένη λοξότητα ετικετών θα αναμενόταν να δώσει μεγαλύτερο χάσμα.

Το δεύτερο εύρημα είναι ότι **το όφελος της συνεργασίας είναι μεγάλο**. Η ομοσπονδιακή τοπολογία ξεπερνά την ατομική κατά 18,30 μονάδες. Ένας συμμετέχων που μένει μόνος με τα δικά του 281 έως 409 samples φτάνει κατά μέσο όρο 75,81, ενώ συμμετέχοντας στην ομοσπονδία παίρνει μοντέλο με 94,11.


Η σύγκριση με τη βιβλιογραφία γίνεται μόνο ποιοτικά και αφορά το κόστος της αποκέντρωσης. Οι Sozinov et al. αναφέρουν 89% για την ομοσπονδιακή έναντι 93% για την κεντρική εκπαίδευση [29] αλλά σε διαφορετικό σύνολο δεδομένων και με διαφορετικά μοντέλα, οπότε οι αριθμοί δεν είναι αντιστοιχίσιμοι. Ό,τι συμφωνεί είναι το πρόσημο του χάσματος, δηλαδή ότι η ομοσπονδιακή εκπαίδευση υστερεί λίγο.

Το Σχήμα 4.3 δείχνει πώς φτάνουν εκεί οι δύο συλλογικές τοπολογίες, με την ατομική ως γραμμή αναφοράς.


Και οι δύο καμπύλες ανεβαίνουν απότομα στους πρώτους γύρους και έπειτα σταθεροποιούνται. Η ομοσπονδιακή τοπολογία έχει, επίσης, σαφώς *μικρότερη* τυπική απόκλιση μεταξύ seeds από την κεντρική, 0,18 έναντι 0,65. Μια πιθανή εξήγηση, που δεν ελέγχθηκε χωριστά, είναι ότι ο μέσος όρος των 21 τοπικών ενημερώσεων, καθεμία με δικά της δεδομένα και δική της τυχαία σειρά παρτίδων, εξομαλύνει τον θόρυβο της κάθε μίας.

### 4.6.2 Διασπορά της ατομικής επίδοσης μεταξύ ανθρώπων

Ο μέσος όρος 75,81 της ατομικής τοπολογίας κρύβει τη σημαντικότερη πληροφορία της. Το δεξί τμήμα του Σχήματος 4.4 δείχνει την επίδοση ανά συμμετέχοντα, η οποία κυμαίνεται από 65,49 για τον συμμετέχοντα 7 έως 85,97 για τον συμμετέχοντα 10, δηλαδή εύρος πάνω από 20 μονάδες.



**Σχήμα 4.3.** Ορθότητα, μέσος όρος 20 seeds. Ο οριζόντιος άξονας μετράει γύρους συνάθροισης για την ομοσπονδιακή και εποχές για την κεντρική. Η ομοσπονδιακή αξιολογείται σε κάθε γύρο και η κεντρική στις εποχές 10, 25, 50 και 100. Τα σημεία αυτά είναι μέρος της ρύθμισης του πειράματος, αφού η ενδιάμεση αξιολόγηση μετακινεί τη γεννήτρια τυχαίων αριθμών (Ενότητα 4.4). Η σκιασμένη ζώνη και οι μπάρες σφάλματος είναι  $\pm$  μία τυπική απόκλιση μεταξύ seeds. Η ατομική αξιολογείται μόνο στο τέλος της εκπαίδευσης, οπότε φαίνεται ως οριζόντια γραμμή στην τελική της τιμή, 75,81%. Η ζώνη της είναι  $\pm$  μία τυπική απόκλιση στις 420 εκτελέσεις και οφείλεται κυρίως στη διαφορά μεταξύ ανθρώπων (Ενότητα 4.6.2).




**Σχήμα 4.4.** Αριστερά: η κατανομή της ορθότητας για κάθε τοπολογία, σε 20 εκτελέσεις για την κεντρική και την ομοσπονδιακή και σε 420 για την ατομική. Η γραμμή μέσα σε κάθε κουτί είναι η διάμεσος και ο αριθμός κάτω από αυτό ο μέσος όρος. Δεξιά: η ατομική τοπολογία ανά συμμετέχοντα, μέσος όρος 20 seeds με  $\pm$  μία τυπική απόκλιση. Κανένας συμμετέχων μόνος του δεν πλησιάζει την επίδοση της ομοσπονδίας.

Η διασπορά αυτή αξίζει να αναλυθεί, γιατί οι ίδιες μετρήσεις δίνουν τρεις διαφορετικές τυπικές αποκλίσεις που σημαίνουν διαφορετικά πράγματα. Πάνω στις 420 μεμονωμένες εκτελέσεις, είναι 5,14. Πάνω στους 21 μέσους όρους ανά συμμετέχοντα, είναι 5,17. Πάνω στους 20 μέσους όρους ανά seed, είναι 0,15. Η τελευταία σύγκριση είναι η ουσιαστική, γιατί δείχνει ότι **η τυπική απόκλιση μεταξύ ανθρώπων είναι περίπου 34 φορές εκείνη μεταξύ seeds**. Η διαφορά επίδοσης μεταξύ δύο συμμετεχόντων δεν είναι θόρυβος αρχικοποίησης αλλά πραγματική ιδιότητα των ανθρώπων και των δεδομένων τους.

Εδώ γίνεται εμπειρικό το κίνητρο συμμετοχής που στην Ενότητα 2.3.5 δηλώθηκε μόνο θεωρητικά. Ο συμμετέχων 7, ο πιο αδύναμος μόνος του, περνά από 65,49 σε 94,11 συμμετέχοντας, κερδίζοντας σχεδόν 29 μονάδες. Ο συμμετέχων 10, όμως, ο ισχυρότερος μόνος του, κερδίζει πάνω από 8 μονάδες. **Κανένας από τους 21 δε βγαίνει χαμένος από τη συμμετοχή.**

### 4.6.3 Τοπικές εποχές έναντι γύρων συνάθροισης

Η ομοσπονδιακή τοπολογία εκπαιδεύει  $E = 1$  τοπική εποχή ανά γύρο και όχι περισσότερες. Θεωρητικά, περισσότερα τοπικά βήματα μεταξύ δύο συναθροίσεων σημαίνουν ισχυρότερο *client drift*, αφού ο καθένας απομακρύνεται περισσότερο προς το δικό του ελάχιστο, πριν προλάβει να διορθωθεί [14], [15]. Για να ελεγχθεί εμπειρικά η επιλογή, τέσσερις ρυθμίσεις δοκιμάστηκαν με *ίδιο συνολικό τοπικό υπολογιστικό κόστος*, δηλαδή ίδιο γινόμενο γύρων επί τοπικές εποχές, συγκεκριμένα  $100 \times 1$ ,  $50 \times 2$ ,  $20 \times 5$  και  $10 \times 10$ . Τα αποτελέσματα, σε 5 seeds, είναι  $94,10 \pm 0,13$ ,  $93,83 \pm 0,19$ ,  $93,44 \pm 0,16$  και  $93,03 \pm 0,13$  αντίστοιχα και φαίνονται στο Σχήμα 4.5.




**Σχήμα 4.5.** Τέσσερις συνδυασμοί γύρων και τοπικών εποχών με ίδιο συνολικό υπολογιστικό κόστος, στην ομοσπονδιακή τοπολογία. Μέσος όρος και τυπική απόκλιση 5 seeds.

Η πτώση είναι μονότονη και το συνολικό εύρος 1,07 μονάδες. Όσο αραιώνει η συνάθροιση, τόσο χειρότερο το αποτέλεσμα, με σταθερό υπολογιστικό κόστος, πράγμα που είναι η εμπειρική υπογραφή του *client drift*. Η σάρωση έγινε, όπως όλες οι μετρήσεις της εργασίας, στο σύνολο ελέγχου, γιατί η εργασία δεν κρατά χωριστό σύνολο επικύρωσης. Δεν αποτελεί, επομένως, ανεξάρτητη επιλογή υπερπαραμέτρου. Επιβεβαιώνει, όμως, ότι η τιμή που προβλέπει η θεωρία,  $E = 1$ , είναι και η καλύτερη από τις τέσσερις.

Η μελέτη αυτή εκτελέστηκε με 5 seeds και **δε** συγκρίνεται αριθμητικά με τα κύρια αποτελέσματα των 20 seeds. Χρησιμοποιείται μόνο για τη σύγκριση των τεσσάρων ρυθμίσεων, οι οποίες είναι αντιστοιχισμένες μεταξύ τους.

## 4.7 Ανάλυση Σφαλμάτων

Το Σχήμα 4.6 δείχνει τον πίνακα σύγχυσης της ομοσπονδιακής τοπολογίας, αθροισμένο και στα 20 seeds, δηλαδή  $20 \times 2947 = 58.940$  προβλέψεις.



**Σχήμα 4.6.** Αθροισμα 20 seeds, 58.940 προβλέψεις. Κάθε κελί δείχνει το ποσοστό της γραμμής και το απόλυτο πλήθος. Το ζεύγος SITTING και STANDING συγκεντρώνει σχεδόν τα μισά σφάλματα του μοντέλου.

Οι ανακλήσεις ανά κλάση είναι 99,18% για τη WALKING, 95,62% για τη WALKING\_UPSTAIRS, 91,26% για τη WALKING\_DOWNSTAIRS, 89,75% για τη SITTING, 93,07% για τη STANDING και 95,33% για τη LAYING.

**Το κεντρικό εύρημα είναι η συγκέντρωση των σφαλμάτων.** Από τα 3.474 συνολικά λάθη, τα 1.705 είναι ανταλλαγές μεταξύ SITTING και STANDING, δηλαδή το **49,1%** όλων των λαθών του μοντέλου προέρχεται από ένα και μόνο ζεύγος κλάσεων, από τα δεκαπέντε δυνατά. Συγκεκριμένα, 968 samples καθιστής στάσης ταξινομούνται ως όρθια και 737 το αντίστροφο.

Το εύρημα δεν είναι σφάλμα της υλοποίησης αλλά γνωστή ιδιότητα του προβλήματος. Οι δημιουργοί του συνόλου δεδομένων αναφέρουν την ίδια επικάλυψη και την αποδίδουν στη φυσική θέση της συσκευής πάνω στο σώμα [1]. Η σύγκριση των δύο εργασιών είναι διαφωτιστική. Με μηχανή διανυσμάτων υποστήριξης, εκείνοι αναφέρουν ανάκληση 88% για την καθιστή και 97% για την όρθια στάση, ενώ η παρούσα εργασία, με το δίκτυο και ομοσπονδιακή εκπαίδευση, βρίσκει 89,75% και 93,07%. Δεκατρία χρόνια αργότερα και με εντελώς διαφορετική μεθοδολογία, το σύνολο είναι το ίδιο.

Η εξήγηση δόθηκε στην Ενότητα 3.4.3, όπου οι δύο στάσεις διακρίνονται μόνο από την κλίση του κορμού ως προς τη συσκευή. Η διάκριση αυτή είναι εξ ορισμού εξαρτημένη από το άτομο, γιατί κάθε άνθρωπος κάθεται και στέκεται με ελαφρώς διαφορετική στάση και η συσκευή στη μέση καταγράφει αυτή τη διαφορά.

Αυτό ακριβώς κάνει το εύρημα γέφυρα προς το επόμενο κεφάλαιο. Αν το δυσκολότερο σύνολο του προβλήματος είναι και το πιο εξαρτημένο από το άτομο, τότε αναμένεται να είναι εκεί που οι συμμετέχοντες διαφωνούν περισσότερο μεταξύ τους. Η Ενότητα 5.7.2 το επιβεβαιώνει ποσοτικά.

Δύο δευτερεύουσες παρατηρήσεις. Πρώτον, οι δυναμικές δραστηριότητες μπερδεύονται μεταξύ τους αλλά καμία δεν ταξινομείται ποτέ ως στατική. Η αντίστροφη σύγχυση είναι σπάνια, αφού μόνο 37 samples καθιστής στάσης στα 20 seeds (0,4%) ταξινομούνται ως ανάβαση σκάλας. Ο διαχωρισμός κίνησης από ακινησία είναι, επομένως, σχεδόν πλήρης, όπως προέβλεπε η ανάλυση διαχωρισιμότητας της Ενότητας 3.4.3. Δεύτερον, η κλάση LAYING, παρά το γεγονός ότι είναι η ευκολότερη εννοιολογικά, έχει ανάκληση 95,33% με 502 λάθη προς την όρθια στάση, δηλαδή δεν είναι σχεδόν τέλεια στον πίνακα σύγχυσης.

## Κεφάλαιο 5

# Αποτίμηση της Συνεισφοράς των Συμμετεχόντων

Το κεφάλαιο απαντά στο δεύτερο και στο τρίτο ερευνητικό ερώτημα. Μέθοδος και αποτελέσματα παρουσιάζονται μαζί και όχι σε χωριστά κεφάλαια, γιατί κανένα από τα ευρήματα δε διαβάζεται χωρίς τους ελέγχους που το στηρίζουν.

Η πορεία του κεφαλαίου είναι η εξής. Ορίζονται πρώτα το παίγνιο και οι εκτιμητές που το λύνουν. Στη συνέχεια, δείχνεται ότι εννέα από τους 21 συμμετέχοντες λαμβάνουν αρνητική συνεισφορά. Το εύρημα αντέχει τέσσερις ελέγχους. Ακολουθεί η αναζήτηση του *τι* διακρίνει τους ανθρώπους που τη λαμβάνουν. Ένα δεύτερο παίγνιο, με επανεκπαίδευση στην κεντρική τοπολογία, επαληθεύει έπειτα αν η αρνητική συνεισφορά προέρχεται από τα δεδομένα ή από τη συνάθροιση. Το αποτέλεσμα δείχνει ότι γεννιέται κυρίως στη συνάθροιση. Ακολουθεί η ανάλυση αστοχίας (*failure analysis*), που επιστρέφει στο ομοσπονδιακό παίγνιο και αποσυνθέτει την αρνητική τιμή, ώστε να φανεί *πότε* εμφανίζεται μέσα στην εκπαίδευση, σε ποιες δραστηριότητες και *απέναντι σε ποιους* ανθρώπους. Η ίδια ανάλυση ελέγχει αν η αφαίρεση των συμμετεχόντων με αρνητική τιμή θα βελτίωνε το μοντέλο. Στη ρύθμιση αυτή, δεν το βελτιώνει με συνέπεια, οπότε οι συμμετέχοντες αυτοί μένουν. Το κεφάλαιο κλείνει με τον τρόπο που η συνεισφορά όλων, ακόμη και των αρνητικών, μετατρέπεται σε μερίδια ανταμοιβής. Η ροή της υλοποίησης κάθε παιγνίου δίνεται σε σχήμα, μετά την περιγραφή του (Σχήματα 5.2 και 5.7).

## 5.1 Το Παίγνιο ανά Γύρο Εκπαίδευσης

Για να εφαρμοστεί η Εξίσωση (2.11), χρειάζεται να οριστούν δύο πράγματα, ποιοι είναι οι παίκτες και ποια είναι η συνάρτηση αξίας. Εδώ ορίζεται ένα παίγνιο *ανά γύρο* ομοσπονδιακής εκπαίδευσης. Οι παίκτες είναι οι 21 συμμετέχοντες. Για γύρο  $t$  και συνασπισμό  $S \subseteq N$ ,

$$v_t(S) = \text{Acc}\left(\mathbf{w}_t + \sum_{k \in S} \frac{n_k}{n_S} \Delta_t^k\right), \quad (5.1)$$


δηλαδή η ορθότητα στο σύνολο ελέγχου του μοντέλου που θα προέκυπτε, αν σε εκείνον τον γύρο είχαν στείλει ενημέρωση *μόνο* οι συμμετέχοντες του  $S$ . Στον τύπο,  $\mathbf{w}_t$  είναι οι παράμετροι του καθολικού μοντέλου στην αρχή του γύρου και  $\Delta_t^k = \mathbf{w}_{t+1}^k - \mathbf{w}_t$  η ενημέρωση του συμμετέχοντα  $k$ , δηλαδή η διαφορά του τοπικού του μοντέλου από το  $\mathbf{w}_t$ . Το  $n_k/n_S$ , με  $n_S = \sum_{k \in S} n_k$ , είναι το βάρος του FedAvg περιορισμένο στον συνασπισμό. Για  $S = N$ , ο τύπος δίνει ακριβώς το  $\mathbf{w}_{t+1}$  της Εξίσωσης (2.10), αφού τα βάρη αθροίζονται στη μονάδα. Η αξία του κενού συνασπισμού  $v_t(\emptyset)$  είναι η ορθότητα του  $\mathbf{w}_t$  πριν από οποιαδήποτε ενημέρωση, οπότε το παίγνιο μετράει τι *προστίθεται* σε εκείνον τον γύρο.

Σε αντίθεση με τον κλασικό ορισμό της Ενότητας 2.3.1, λοιπόν, ο κενός συνασπισμός δεν έχει μηδενική αξία. Ούτε είναι εγγυημένο ότι η ένωση δύο συνασπισμών αξίζει τουλάχιστον όσο το άθροισμά τους, αφού ο FedAvg παίρνει μέσο όρο των ενημερώσεων και δεν τις προσθέτει. Ο τύπος του Shapley δε χρειάζεται καμία από τις δύο ιδιότητες, γιατί χρησιμοποιεί μόνο διαφορές  $v_t(S \cup \{i\}) - v_t(S)$ . Η αποδοτικότητα της Ενότητας 2.3.2 απλώς γράφεται  $\sum_{i \in N} \varphi_i = v_t(N) - v_t(\emptyset)$ . Ο κενός συνασπισμός αντιστοιχεί στο μοντέλο της αρχής του γύρου, όπως και στο GTG-Shapley [30].

Το καθοριστικό σημείο υλοποίησης είναι το γεγονός ότι η αποτίμηση της  $v_t(S)$  **δεν απαιτεί επανεκπαίδευση** (Σχήμα 5.1). Οι ενημερώσεις  $\Delta_t^k$  αποθηκεύονται κατά τη διάρκεια του γύρου και κάθε συνασπισμός αποτιμάται με μία σταθμισμένη πρόσθεση διανυσμάτων και ένα πέρασμα αξιολόγησης. Η τεχνική είναι δανεισμένη από το GTG-Shapley, το οποίο ανασυνθέτει τα ομοσπονδιακά μοντέλα από τις ενημερώσεις παραμέτρων, αντί να τα εκπαιδεύει ξανά για κάθε συνδυασμό συμμετεχόντων [30].

Η σημασία της φαίνεται από την τάξη μεγέθους. Ο ακριβής υπολογισμός με επανεκπαίδευση θα απαιτούσε  $2^{21} \approx 2,1$  εκατομμύρια πλήρεις ομοσπονδιακές εκπαιδεύσεις ανά seed, καθεμιά με 100 γύρους. Με ανασύνθεση, δε χρειάζεται καμία εκπαίδευση πέρα από την ίδια την ομοσπονδιακή. Κάθε αποτίμηση κοστίζει ένα πέρασμα αξιολόγησης, δηλαδή μία πρόβλεψη στα 2.947 samples του συνόλου ελέγχου. Ο αριθμός των αποτιμήσεων δίνεται στην Ενότητα 5.3.3.

Στον κώδικα η αποτίμηση εκτελείται μέσα στην ίδια την ομοσπονδιακή εκπαίδευση και όχι μετά από αυτήν. Κάθε seed ξεκινά από νέο δίκτυο με αρχικά βάρη από το seed και από μη-



**Σχήμα 5.1.** Η αποτίμηση της  $v_t(S)$ . Οι ενημερώσεις όλων των συμμετεχόντων αποθηκεύονται μία φορά ανά γύρο. Κάθε συνασπισμός ανασυντίθεται από αυτές με σταθμισμένη πρόσθεση και αποτιμάται με ένα πέρασμα αξιολόγησης. Η πλήρης επανεκπαίδευση, που θα απαιτούσε  $2^{21}$  ομοσπονδιακές εκπαιδεύσεις ανά seed, αποφεύγεται.

δενικό άθροισμα συνεισφοράς για κάθε συμμετέχοντα (βήμα 1 του Σχήματος 5.2). Σε κάθε γύρο, αφού εκπαιδευτούν τοπικά οι 21 συμμετέχοντες και πριν γίνει η συνάθροιση, κρατούνται αντίγραφα του  $\mathbf{w}_t$  και των 21 τοπικών μοντέλων (βήμα 2). Από αυτά στήνεται το παίγνιο του γύρου (βήμα 3). Τα αντίγραφα είναι απαραίτητα, γιατί η συνάθροιση γράφει τις νέες παραμέτρους πάνω στην ίδια μνήμη. Σε μια πρώτη εκδοχή του κώδικα, έλειπαν. Όλες οι ενημερώσεις  $\Delta_t^k$  έβγαιναν τότε μηδέν και μαζί τους όλες οι τιμές. Από τότε, ο κώδικας ελέγχει σε κάθε γύρο ότι οι ενημερώσεις δεν είναι όλες μηδέν και σταματά, αν είναι. Στον πρώτο γύρο κάθε seed, επαληθεύεται μία φορά ότι ο πλήρης συνασπισμός δίνει ακριβώς τις παραμέτρους  $\mathbf{w}_{t+1}$  του FedAvg.

Οι εκτιμητές της Ενότητας 5.2 ζητούν τις αξίες  $v_t(S)$  που χρειάζονται, με κάθε  $S$  να δίνεται ως διάνυσμα 21 θέσεων με 1 για τα μέλη του και 0 για τους υπόλοιπους. Οι τιμές του γύρου προστίθενται στο άθροισμα συνεισφοράς κάθε συμμετέχοντα και η εκπαίδευση συνεχίζει στον επόμενο γύρο. Επειδή η αποτίμηση δουλεύει μόνο σε αντίγραφα και με δική της γεννήτρια τυχαίων αριθμών, η εκπαίδευση προχωρά ακριβώς όπως στην ομοσπονδιακή τοπολογία του Κεφαλαίου 4. Πράγματι, η τελική ορθότητα ταυτίζεται με εκείνη σε 20 από τα 20 seeds. Από το ένα seed στο επόμενο δεν περνά τίποτα, ούτε βάρη ούτε τιμές, οπότε τα 20 seeds εκτελούνται παράλληλα σε ξεχωριστές διεργασίες και τα αποτελέσματά τους ενώνονται στο τέλος. Η πλήρης ροή, με τη σειρά των βημάτων, δίνεται στο Σχήμα 5.2, αφού οριστούν οι δύο εκτιμητές (Ενότητα 5.2.3).

Η συνολική τιμή κάθε συμμετέχοντα είναι το άθροισμα των τιμών του στους γύρους,  $\varphi_i = \sum_t \varphi_{i,t}$ . Είναι ο κανόνας της μεθόδου πολλών γύρων (MR), όπως την περιγράφει η εργασία του GTG-Shapley [30]. Το ίδιο το GTG-Shapley υπολογίζει, επίσης, μία τιμή ανά γύρο [30]. Εδώ οι τιμές των γύρων ενώνονται με τον ίδιο κανόνα. Επειδή το Shapley value ικανοποιεί την αποδοτικότητα σε κάθε γύρο, το άθροισμα  $\sum_i \varphi_i$  ισούται με τη βελτίωση

ορθότητας στους γύρους που αποτιμώνται (Ενότητα 5.3.1). Επομένως, το  $\varphi_i$  εκφράζεται στις ίδιες μονάδες με τη συνάρτηση αξίας.

**Η κλίμακα του  $\varphi$  και η κλίμακα της ορθότητας.** Η διάκριση χρειάζεται δήλωση, γιατί το κεφάλαιο αναφέρει και τα δύο. Η ορθότητα εδώ είναι *κλάσμα* στο  $[0, 1]$ , οπότε και το  $\varphi_i$  είναι κλάσμα. Τιμή  $\varphi_i = +0,40$  σημαίνει ότι οι τιμές του συμμετέχοντα ανά γύρο, αθροισμένες στους βαθμολογημένους γύρους, φτάνουν τις 0,40 σε απόλυτη κλίμακα ορθότητας, δηλαδή τις 40 ποσοστιαίες μονάδες *συσσωρευμένες στους γύρους αυτούς*. Το άθροισμα όλων,  $\sum_i \varphi_i \approx 0,80$ , αντιστοιχεί στις περίπου 80 ποσοστιαίες μονάδες που κέρδισε το μοντέλο από το αρχικό σημείο των γύρων αυτών μέχρι το τέλος. Το μέγεθος δεν είναι συγκρίσιμο με τις διαφορές ορθότητας του Κεφαλαίου 4, οι οποίες αφορούν ένα τελικό μοντέλο και αναφέρονται πάντα σε ποσοστιαίες μονάδες. Όπου παρακάτω εμφανίζονται διαφορές τελικών μοντέλων, όπως στην Ενότητα 5.7.4, η κλίμακα είναι εκείνη του Κεφαλαίου 4 και δηλώνεται ρητά.

**Το  $\varphi_i$  δεν είναι μερίδιο της βελτίωσης.** Η αποδοτικότητα δεσμεύει μόνο το *καθαρό* άθροισμα των τιμών, όχι το μέγεθος των όρων που το σχηματίζουν. Κατά τον KernelSHAP, οι 12 συμμετέχοντες με θετική τιμή αθροίζουν +2,862 και οι 9 με αρνητική −2,065. Η διαφορά τους είναι το καθαρό +0,797 της Ενότητας 5.3.1. Οι θετικές τιμές μόνες τους ξεπερνούν, δηλαδή, το τριπλάσιο της συνολικής βελτίωσης, οπότε δεν μπορούν να είναι κομμάτια της. Ο συμμετέχων 14, με  $\varphi = +0,404$ , δεν έφερε «το μισό» της ανόδου των 0,797. Συνεισέφερε 0,404 σε ένα σύνολο κινήσεων προς τα πάνω, που οι αρνητικές συνεισφορές ανείρεσαν σε μεγάλο βαθμό. Η αιτία είναι το γεγονός ότι μετά τους πρώτους γύρους οι δύο ομάδες σπρώχνουν το μοντέλο σε αντίθετες κατευθύνσεις (Ενότητα 5.7.1). Για τον ίδιο λόγο, η αναλογική κατανομή  $\varphi_i / \sum_j \varphi_j$  της Ενότητας 5.8 δίνει στους εννέα αρνητικούς συνολικό μερίδιο περίπου −259%, δηλαδή το άθροισμα των αρνητικών τιμών διαιρεμένο με το καθαρό άθροισμα. Γι' αυτό χρησιμοποιείται μόνο ως βάση σύγκρισης.

**Το σύνολο ελέγχου μέσα στη συνάρτηση αξίας.** Η συνάρτηση αξίας αποτιμάται στο σύνολο ελέγχου, όπως και στην εργασία από την οποία προέρχεται η τεχνική [30]. Δεν υπάρχει διαρροή προς την εκπαίδευση, γιατί τα 9 άτομα του συνόλου ελέγχου δε γίνονται ποτέ συμμετέχοντες και τα δεδομένα τους δεν επηρεάζουν καμία ενημέρωση. Αν, όμως, το  $\varphi$  χρησιμοποιηθεί για *απόφαση*, για παράδειγμα για αποκλεισμό συμμετέχοντα ή για κατανομή ανταμοιβής, τότε το σύνολο ελέγχου μπαίνει στον βρόχο απόφασης και παύει να είναι αμερόληπτος εκτιμητής γενίκευσης. Το ζήτημα επανέρχεται στην Ενότητα 6.2.

## 5.2 Οι Δύο Εκτιμητές

### 5.2.1 KernelSHAP

Ο πρώτος εκτιμητής είναι ο KernelSHAP, όπως υλοποιείται στη βιβλιοθήκη `shap`, με τους 21 συμμετέχοντες στη θέση των «χαρακτηριστικών». Η βιβλιοθήκη δέχεται μια συνάρτηση που παίρνει δυαδικά διανύσματα παρουσίας και επιστρέφει αριθμό. Εδώ της δίνεται η Εξίσωση (5.1). Στη συνέχεια, η βιβλιοθήκη λύνει το σταθμισμένο πρόβλημα ελαχίστων τετραγώνων με τον πυρήνα της Εξίσωσης (2.12) και επιστρέφει τα  $\varphi_{i,t}$  [20].

Η χρήση αυτή είναι θεμιτή αλλά όχι η συνήθης. Η Ενότητα 2.3.4 διέκρινε το Shapley value, το SHAP και τον KernelSHAP. Ο Πίνακας 5.1 δείχνει σημείο προς σημείο πού διαφέρει η χρήση εδώ από τη συνήθη.

|                      | SHAP (συνήθης χρήση)                                            | Αυτή η εργασία                                                                      |
|----------------------|-----------------------------------------------------------------|-------------------------------------------------------------------------------------|
| Παίκτες              | τα χαρακτηριστικά μίας εισόδου                                  | οι 21 συμμετέχοντες της ομοσπονδίας                                                 |
| Αξία συνασπισμού $S$ | η έξοδος του μοντέλου, με γνωστά μόνο τα χαρακτηριστικά του $S$ | η ορθότητα στο σύνολο ελέγχου του μοντέλου που χτίζεται από τις ενημερώσεις του $S$ |
| Αληθινές ετικέτες    | δε χρειάζονται                                                  | χρειάζονται                                                                         |
| Εύρος                | μία πρόβλεψη                                                    | ένα σύνολο ελέγχου, σε έναν γύρο                                                    |
| Τι λέει μία τιμή     | πόσο έσπρωξε το χαρακτηριστικό αυτήν την πρόβλεψη               | πόση ορθότητα πρόσθεσε ο συμμετέχων σε αυτόν τον γύρο                               |
| Από τη βιβλιοθήκη    | ολόκληρη η μέθοδος                                              | μόνο ο επιλυτής KernelSHAP                                                          |

**Πίνακας 5.1.** Ίδιος κανόνας, άλλο παίγνιο. Η τελευταία γραμμή δείχνει τι παίρνει η υλοποίηση από τη βιβλιοθήκη `shap`.

Η βιβλιοθήκη χρησιμοποιείται, επομένως, ως γενικός επιλυτής Shapley και όχι ως εργαλείο ερμηνείας χαρακτηριστικών. Το διάνυσμα παρουσίας έχει 21 θέσεις, μία για κάθε συμμετέχοντα. Ως σημείο αναφοράς δίνεται το διάνυσμα στο οποίο δε συμμετέχει κανείς, οπότε κάθε συνασπισμός που δοκιμάζει η βιβλιοθήκη αντιστοιχεί ακριβώς σε μία τιμή  $v_t(S)$ . Το μοντέλο και τα 561 χαρακτηριστικά δεν περνούν ποτέ στη βιβλιοθήκη και η  $v_t$  μετρά ορθότητα με τις αληθινές ετικέτες. Γι' αυτό οι τιμές του κεφαλαίου λέγονται τιμές Shapley ή  $\varphi$  αλλά ποτέ τιμές SHAP. Δείχνουν τη συνεισφορά κάθε συμμετέχοντα στην ορθότητα του μοντέλου και όχι το πώς ένα συγκεκριμένο χαρακτηριστικό επηρέασε μια πρόβλεψη. Στην Ενότητα 5.2.5 ελέγχεται αν ο επιλυτής αναπαράγει πράγματι τον ορισμό σε τέτοιο παίγνιο.

Ο αριθμός των δειγματοληπτούμενων συνασπισμών ορίστηκε σε 2.090 ανά γύρο, τιμή που προκύπτει από την προεπιλεγμένη πολιτική της βιβλιοθήκης για 21 παίκτες.

**Χωρίς επιλογή παικτών.** Η βιβλιοθήκη έχει μια παράμετρο, `ll_reg`, η οποία, πριν από την παλινδρόμηση, κρατά ένα υποσύνολο των παικτών και μηδενίζει τις τιμές των υπολοίπων. Η βιβλιοθήκη την ενεργοποιεί εξ ορισμού. Στο σχετικό άρθρο παρουσιάζεται ως ένας τρόπος για την εξαγωγή ακριβέστερων εκτιμήσεων με λιγότερες αποτιμήσεις του μοντέλου [20]. Εδώ είναι απενεργοποιημένη (`ll_reg=False`), για δύο λόγους. Πρώτον, ο ορισμός του KernelSHAP δεν έχει όρο κανονικοποίησης, αφού το Θεώρημα 2 του [20] ζητά  $\Omega(g) = 0$ , για να ανακτώνται οι τιμές Shapley. Δεύτερον, με 21 μόνο παίκτες, δεν υπάρχει λόγος να μείνει κάποιος χωρίς εκτίμηση. Όλες οι τιμές του ομοσπονδιακού παιγνίου υπολογίστηκαν χωρίς επιλογή παικτών.

### 5.2.2 GTG-Shapley

Ο δεύτερος εκτιμητής προέρχεται από το GTG-Shapley, σχεδιασμένο ειδικά για το ομοσπονδιακό πλαίσιο [30]. Δειγματοληπτεί μεταθέσεις των συμμετεχόντων και συσσωρεύει οριακές συνεισφορές, με δύο μηχανισμούς αποκοπής. Μια μετάθεση είναι μια σειρά άφιξης των 21 συμμετεχόντων, όπως οι σειρές του Σχήματος 2.2. Ο εκτιμητής ξεκινά από τον κενό συνασπισμό, προσθέτει τους συμμετέχοντες έναν έναν με αυτή τη σειρά και πιστώνει στον καθένα τη μεταβολή της αξίας τη στιγμή που μπαίνει. Ο μέσος όρος πάνω σε πολλές τυχαίες μεταθέσεις προσεγγίζει το Shapley value (Ενότητα 2.3.3). Το πλήθος των μεταθέσεων ανά γύρο είναι ο προϋπολογισμός του εκτιμητή, με ανώτατο όριο τις 100 στα κύρια αποτελέσματα. Ο εκτιμητής σταματά νωρίτερα, όταν οι τιμές του μεταβάλλονται λιγότερο από 5% κατά μέσο όρο στις 10 τελευταίες μεταθέσεις. Ο πρώτος μηχανισμός, η αποκοπή μεταξύ γύρων (*between-round truncation*), παραλείπει εντελώς τους γύρους στους οποίους η συνολική μεταβολή της αξίας είναι κάτω από ένα ορισμένο κατώφλι, με τη λογική ότι, αν ένας γύρος δεν επέφερε καμία μεταβολή, δεν υπάρχει και μερίδιο προς κατανομή. Ο δεύτερος, η αποκοπή μέσα στον γύρο (*within-round truncation*), σταματά μια μετάθεση, όταν η τρέχουσα αξία έχει πλησιάσει αρκετά την  $v_t(N)$  [30]. Εδώ, το όριο της απόστασης από την  $v_t(N)$  είναι 0,0001. Επειδή η ορθότητα αλλάζει σε βήματα του  $1/2.947 \approx 0,00034$ , το όριο ενεργοποιείται μόνο όταν ο συνασπισμός έχει ήδη ακριβώς την ορθότητα του πλήρους. Οι υπόλοιποι της σειράς παίρνουν τότε μηδέν, χωρίς νέα αποτίμηση.

**Η παραλλαγή GTG-Tib.** Το Algorithm 1 του [30] απαρτίζεται από **τρία** συστατικά, δηλαδή τους δύο παραπάνω μηχανισμούς αποκοπής και μια τρίτη πολιτική, την καθοδηγούμενη δειγματοληψία (*guided sampling*) της γραμμής 7, που γεμίζει τις  $m$  πρώτες θέσεις κάθε μετάθεσης με σταθερή κυκλική σειρά αντί για τυχαία, ώστε να μην τυχαίνει ένας συμμετέχων να βρίσκεται πάντα στο τέλος. Ο εκτιμητής των κύριων αποτελεσμάτων υλοποιεί τα **δύο** πρώτα και δειγματοληπτεί πλήρως τυχαίες μεταθέσεις. Αυτό αντιστοιχεί ακριβώς στην παραλλαγή που το ίδιο το άρθρο ονομάζει **GTG-Tib** [30]. Με το όνομα αυτό αναφέρεται στο εξής ο

εκτιμητής. Η επιλογή δηλώνεται ρητά, επειδή η μελέτη απαλοιφής του άρθρου βρίσκει ότι η καθοδηγούμενη δειγματοληψία βελτιώνει σημαντικά την ακρίβεια της εκτίμησης [30]. Ο ρόλος του εκτιμητή εδώ είναι να αποτελέσει *δεύτερη ανεξάρτητη διαδρομή* για διασταύρωση της κατάταξης, όχι για να είναι ο ακριβέστερος δυνατός. Η πλήρης εκδοχή με καθοδηγούμενη δειγματοληψία υλοποιήθηκε και αυτή. Η αποτίμησή της γίνεται στην Ενότητα 5.2.4.

Η αποκοπή δικαιολογείται, επειδή η οριακή συνεισφορά φθίνει καθώς μεγαλώνει ο συνασπισμός. Η ίδια λογική στηρίζει το *Truncated Monte Carlo Shapley* [19]. Το κατώφλι της αποκοπής μεταξύ γύρων ορίστηκε σε 0,001. Παραλείπεται, επομένως, κάθε γύρος που αλλάζει το πλήθος των σωστών προβλέψεων στο σύνολο ελέγχου κατά λιγότερο από τρεις. Στα δεδομένα της εργασίας, η αποκοπή αυτή παραλείπει 39 από τους 100 γύρους στο πρώτο seed, γιατί μετά την αρχική απότομη άνοδο της καμπύλης μάθησης, οι περισσότεροι γύροι μεταβάλλουν ελάχιστα την επίδοση. Οι γύροι που μένουν λέγονται στο εξής *βαθμολογημένοι*. Είναι 61 στο πρώτο seed, από 51 έως 74 ανά seed (65 κατά μέσο όρο) και 1.305 συνολικά στα 20 seeds. Μόνο σε αυτούς υπολογίζονται τιμές, από κάθε εκτιμητή.

### 5.2.3 Κοινή συνάρτηση αξίας

Οι δύο εκτιμητές βλέπουν **την ίδια** συνάρτηση αξίας, τους ίδιους γύρους, τις ίδιες αποθηκευμένες ενημερώσεις και την ίδια πύλη αποκοπής. Η μόνη διαφορά τους είναι ο *τρόπος* με τον οποίο πραγματοποιούν τη δειγματοληψία στον χώρο των συνασπισμών. Ο ένας χρησιμοποιεί σταθμισμένη παλινδρόμηση πάνω σε δείγμα συνασπισμών, ενώ ο άλλος μεταθέσεις και αποκοπή. Στον κώδικα, εκτελούνται ο ένας μετά τον άλλον, στο ίδιο παίγνιο του ίδιου γύρου (βήμα 3 του Σχήματος 5.2).

Αυτό κάνει τη σύγκρισή τους πληροφοριακή. Κάθε διαφορά στα  $\varphi$  είναι διαφορά *εκτίμησης* και όχι διαφορά ορισμού. Αν οι δύο συμφωνούν, η κατάταξη είναι ιδιότητα του παιγνίου και όχι παρενέργεια του αλγορίθμου. Η ανάγκη για τέτοιον έλεγχο δεν είναι θεωρητική, αφού σε προηγούμενη εκδοχή αυτής της εργασίας ένας εκτιμητής KernelSHAP με λίγους συνασπισμούς δεν είχε συγκλίνει. Χωρίς δεύτερο εκτιμητή, αυτό δε θα ήταν ορατό. Η βιβλιογραφία το αντιμετωπίζει ως υποχρέωση, ενσωματώνοντας τον έλεγχο σύγκλισης μέσα στον ίδιο τον αλγόριθμο [19].

Το Σχήμα 5.2 δείχνει τη ροή του ομοσπονδιακού παιγνίου με τη σειρά εκτέλεσης και συγκεντρώνει όσα περιγράφουν οι Ενότητες 5.1 και 5.2. Η πύλη (βήμα 3α) είναι η αποκοπή μεταξύ γύρων της Ενότητας 5.2.2. Εφαρμόζεται πριν από τους δύο εκτιμητές (3β και 3γ), οπότε ένας γύρος που δεν την περνά δεν αποτιμάται από κανέναν.

Στον κώδικα, όλα τα αρχεία βρίσκονται μέσα στον φάκελο `implementation/`, με την οργάνωση της Ενότητας 4.1. Ο βρόχος των seeds και των γύρων είναι η


`run_one_seed()` του `contribution/contribution.py` (βήματα 1, 3α, 3δ και 4). Μέσα της, η `observer()` κρατά τα αντίγραφα του βήματος 2 και η παράμετρος `eps_between` ορίζει την πύλη. Η `summarize()` του ίδιου αρχείου δίνει τους μέσους όρους και τη σύγκριση των εκτιμητών (βήμα 5). Η τοπική εκπαίδευση και η συνάθροιση του βήματος 2 είναι εκείνες της ομοσπονδιακής τοπολογίας, δηλαδή η `Client.update()` του `federated/fl/client.py`, η `Server.update()` του `federated/fl/server.py` και η `fedavg_aggregate()` του `federated/fl/aggregation/aggregate.py`. Το παίγνιο και οι εκτιμητές βρίσκονται στον υποφάκελο `contribution/sv/`. Την αξία  $v_t(S)$  τη δίνουν η `RoundGame` του `coalition.py` και η `CoalitionEvaluator` του `evaluate.py`, ενώ οι δύο εκτιμητές είναι οι `KernelShapEstimator` και `GtgShapleyEstimator` του `estimators.py`.

### 5.2.4 Καθοδηγούμενη δειγματοληψία μεταθέσεων

Ο εκτιμητής των κύριων αποτελεσμάτων παραλείπει το τρίτο συστατικό του GTG-Shapley, την καθοδηγούμενη δειγματοληψία. Η ενότητα μετρά τι κοστίζει η παράλειψη, ώστε να μην είναι απλή δήλωση. Η απάντηση, συνοπτικά, είναι ότι ανά γύρο η καθοδηγούμενη εκδοχή είναι σαφώς ακριβέστερη, ενώ στο άθροισμα των γύρων η διαφορά σχεδόν χάνεται και η κατάταξη των κύριων αποτελεσμάτων δεν αλλάζει.

**Τι αλλάζει η καθοδηγούμενη δειγματοληψία.** Σε μια τυχαία μετάθεση, κάθε συμμετέχων έχει την ίδια πιθανότητα να βρεθεί σε κάθε θέση. Σε λίγες μεταθέσεις, όμως, η ισορροπία δεν είναι εξασφαλισμένη. Με 100 τυχαίες μεταθέσεις, το πόσες φορές ένας συμμετέχων καταλαμβάνει την πρώτη θέση ακολουθεί διωνυμική κατανομή με μέσο 4,76. Στην πράξη, ένας συμμετέχων την κατέλαβε 2 φορές, ενώ ένας άλλος 11. Η καθοδηγούμενη δειγματοληψία γεμίζει τις  $m$  πρώτες θέσεις κάθε μετάθεσης με σταθερή κυκλική σειρά αντί για τυχαία, οπότε ο καθένας καταλαμβάνει την πρώτη θέση 4 ή 5 φορές, πάντα. Η ισορροπία έχει σημασία, γιατί οι πρώτες θέσεις είναι εκείνες που αποτιμώνται πραγματικά, αφού η αποκοπή μέσα στον γύρο μηδενίζει τη συνεισφορά των τελευταίων.

**Η υλοποίηση, με  $m = 2$  αντί για  $m = 1$ .** Το άρθρο περιγράφει την πολιτική με λόγια και δεν παραθέτει ούτε τιμή για το  $m$  ούτε σειρά απαρίθμησης του  $P(n, m)$ , παραπέμποντας στο αποθετήριο των συγγραφέων [30]. Ο κώδικας εκεί χρησιμοποιεί  $m = 1$ , δηλαδή η πρώτη θέση περνά με τη σειρά από όλους τους συμμετέχοντες, σε πλήρη περάσματα των  $n$  μεταθέσεων. Εδώ επιλέχθηκε  $m = 2$ , οπότε η απαρίθμηση είναι *ερμηνεία* του κανόνα από την παρούσα εργασία, με κριτήριο να υπηρετεί τον σκοπό που δηλώνει το άρθρο. Στην  $k$ -οστή



**Σχήμα 5.2.** Η αποτίμηση στο ομοσπονδιακό παίγνιο, με τη σειρά εκτέλεσης. Η μπλε γραμμή επιστρέφει στον επόμενο γύρο και η μωβ στο επόμενο seed. Το βήμα 3 δουλεύει σε αντίγραφα των μοντέλων και δεν αλλάζει την εκπαίδευση. Οι δύο εκτιμητές εκτελούνται ο ένας μετά τον άλλον, στο ίδιο παίγνιο του ίδιου γύρου. Τα διακεκομμένα βέλη δείχνουν πού ζητούν αξίες συνασπισμών.

μετάθεση, η πρώτη θέση δίνεται στον συμμετέχοντα  $k \bmod n$  και η δεύτερη σε μετατόπιση από αυτόν που αλλάζει κυκλικά σε κάθε βήμα, ενώ οι υπόλοιπες  $n - m$  θέσεις μένουν τυχαίες. Έτσι απαριθμούνται και τα 420 ζεύγη του  $P(21, 2)$  πριν από οποιαδήποτε επανάληψη. Μια λεξικογραφική απαρίθμηση θα ήταν λάθος, γιατί στις 100 μεταθέσεις ενός γύρου μόνο οι πέντε πρώτοι συμμετέχοντες θα έφταναν ποτέ στην πρώτη θέση. Για τον ίδιο λόγο, οι 100 μεταθέσεις καλύπτουν μόνο μέρος των 420 ζευγών, γι' αυτό η απαρίθμηση ξεκινά σε κάθε γύρο από τυχαίο σημείο της σειράς. Η επιλογή του  $m = 2$  ελέγχθηκε απέναντι στο  $m = 1$  στους τρεις γύρους του Πίνακα 5.2, με 100 μεταθέσεις και πρακτικά ίδιο αριθμό αποτιμήσεων. Σε κανέναν γύρο δεν έδωσε μεγαλύτερη απόκλιση από το ακριβές Shapley.

**Τι αλλάζει στη ροή του Σχήματος 5.2.** Από τα βήματα του σχήματος, η καθοδηγούμενη εκδοχή αλλάζει μόνο το 3γ. Οι δύο πρώτες θέσεις κάθε σειράς δεν κληρώνονται αλλά παίρνονται από την κυκλική απαρίθμηση της προηγούμενης παραγράφου, ενώ οι υπόλοιπες 19 μένουν τυχαίες. Η αποκοπή μέσα στον γύρο, το κριτήριο τερματισμού και το ανώτατο όριο των 100 μεταθέσεων δεν αλλάζουν. Στα 20 seeds, η εκδοχή υπολογίστηκε σε χωριστή εκτέλεση της ίδιας ροής, χωρίς το βήμα 3β και με την ίδια πύλη (βήμα 3α). Τα βήματα 1, 2, 4 και 5 μένουν ίδια.

**Ακρίβεια ανά γύρο.** Ο Πίνακας 5.2 συγκρίνει τις δύο εκδοχές σε τρεις γύρους με διαφορετικό μέγεθος  $v_t(N) - v_t(\emptyset)$ , με 50, 100 και 200 μεταθέσεις ανά γύρο και πέντε ανεξάρτητα τραβήγματα ανά κελί. Αναφορά είναι το ακριβές Shapley κάθε γύρου, από την Εξίσωση (2.11) με αποτίμηση και των  $2^{21}$  συνασπισμών (Ενότητα 5.2.5). Η καθοδηγούμενη εκδοχή είναι καλύτερη και στα εννέα κελιά, τόσο στη συμφωνία κατάταξης (Kendall  $\tau$ , Εξίσωση (2.7)) όσο και στη μέγιστη απόκλιση. Η μέγιστη απόκλιση της κυμαίνεται, επίσης, λιγότερο μεταξύ των τραβηγμάτων, όπως αναμένεται από τον μηχανισμό που επικαλείται το άρθρο. Στις 100 μεταθέσεις των κύριων αποτελεσμάτων, η μέγιστη απόκλιση μειώνεται κατά παράγοντα από 1,9 έως 5,6, με το μεγαλύτερο κέρδος στον γύρο 1. Τα διαστήματα  $\pm$  μιας τυπικής απόκλισης της μέγιστης απόκλισης δεν επικαλύπτονται σε κανέναν από τους τρεις γύρους. Το πλήθος των αποτιμήσεων μένει πρακτικά ίδιο, από  $-1,0$  έως  $+2,0\%$ .

**Ακρίβεια στο άθροισμα των γύρων.** Η ακρίβεια ανά γύρο δεν προεξοφλεί το αποτέλεσμα στο άθροισμα των γύρων, που είναι το μέγεθος το οποίο εξετάζεται τελικά. Αν τα σφάλματα των διαδοχικών γύρων είναι ανεξάρτητα, αλληλοαναιρούνται, ενώ, αν είναι συσχετισμένα, συσσωρεύονται. Μια πολιτική που επαναλαμβάνει την ίδια απαρίθμηση σε κάθε γύρο κινδυνεύει με το δεύτερο. Γι' αυτό ο πλήρης εκτιμητής εκτελέστηκε στα ίδια 20 seeds και στους ίδιους 1.305 βαθμολογημένους γύρους με τα κύρια αποτελέσματα, πάνω σε τροχιά εκπαίδευσης ίδια bit προς bit, οπότε η σύγκριση είναι πλήρως αντιστοιχισμένη. Για το άθροισμα δεν

| Γύρος | Μεταθέσεις | Kendall $\tau$    |                          | $\max  \Delta\varphi $ |                              |
|-------|------------|-------------------|--------------------------|------------------------|------------------------------|
|       |            | τυχαία            | καθοδηγούμενη            | τυχαία                 | καθοδηγούμενη                |
| 1     | 50         | $0,547 \pm 0,066$ | <b>0,813</b> $\pm 0,043$ | $0,03344 \pm 0,00583$  | <b>0,01200</b> $\pm 0,00299$ |
| 1     | 100        | $0,680 \pm 0,051$ | <b>0,901</b> $\pm 0,016$ | $0,02806 \pm 0,00568$  | <b>0,00499</b> $\pm 0,00046$ |
| 1     | 200        | $0,743 \pm 0,029$ | <b>0,926</b> $\pm 0,027$ | $0,01903 \pm 0,00349$  | <b>0,00400</b> $\pm 0,00084$ |
| 5     | 50         | $0,573 \pm 0,139$ | <b>0,764</b> $\pm 0,049$ | $0,00855 \pm 0,00353$  | <b>0,00500</b> $\pm 0,00081$ |
| 5     | 100        | $0,665 \pm 0,125$ | <b>0,836</b> $\pm 0,027$ | $0,00605 \pm 0,00136$  | <b>0,00324</b> $\pm 0,00128$ |
| 5     | 200        | $0,777 \pm 0,031$ | <b>0,870</b> $\pm 0,057$ | $0,00407 \pm 0,00077$  | <b>0,00188</b> $\pm 0,00054$ |
| 15    | 50         | $0,665 \pm 0,069$ | <b>0,815</b> $\pm 0,057$ | $0,01002 \pm 0,00306$  | <b>0,00490</b> $\pm 0,00061$ |
| 15    | 100        | $0,768 \pm 0,064$ | <b>0,859</b> $\pm 0,039$ | $0,00653 \pm 0,00124$  | <b>0,00287</b> $\pm 0,00102$ |
| 15    | 200        | $0,846 \pm 0,021$ | <b>0,884</b> $\pm 0,040$ | $0,00497 \pm 0,00143$  | <b>0,00187</b> $\pm 0,00019$ |

**Πίνακας 5.2.** Τυχαία έναντι καθοδηγούμενης δειγματοληψίας μεταθέσεων, 21 συμμετέχοντες, με αναφορά το ακριβές Shapley κάθε γύρου ( $2^{21}$  συνασπισμοί), στο seed 0. Οι μεταθέσεις είναι ο προϋπολογισμός ανά γύρο. Μέσος όρος  $\pm$  τυπική απόκλιση σε πέντε ανεξάρτητα τραβήγματα.

υπάρχει ακριβές Shapley, οπότε αναφορά είναι ο KernelSHAP. Οι τρεις εκτιμητές συγκρίνονται μαζί στον Πίνακα 5.4 της Ενότητας 5.3.2.

Στο άθροισμα, η καθοδηγούμενη εκδοχή υπερέχει με πολύ μικρότερο περιθώριο. Η μέση απόκλιση της από τον KernelSHAP είναι κατά 13,3% μικρότερη από εκείνη της τυχαίας. Ο αριθμός δε συγκρίνεται ευθέως με τον παράγοντα του Πίνακα 5.2, αφού έχει άλλη αναφορά και άλλο μέτρο. Δείχνει, όμως, ότι το μεγαλύτερο μέρος του πλεονεκτήματος χάνεται, επειδή ο θόρυβος της τυχαίας δειγματοληψίας αλληλοαναιρείται σε βάθος 1.305 γύρων. Αυτό που δε χάνεται είναι η **κατάταξη**. Η καθοδηγούμενη εκδοχή αναπαράγει τη σειρά του KernelSHAP και στα 210 ζεύγη συμμετεχόντων ( $\tau = 1,0000$ ), ενώ η τυχαία αντιστρέφει τέσσερα ( $\tau = 0,9619$ ), όλα ανάμεσα σε συμμετέχοντες με σχεδόν ίσες τιμές (Ενότητα 5.3.2). Το κόστος της βελτίωσης είναι 0,61% περισσότερες αποτιμήσεις, οπότε πρόκειται για κέρδος σχεδόν δωρεάν.

**Συμπέρασμα.** Η παράλειψη του τρίτου συστατικού κοστίζει λίγο στα κύρια αποτελέσματα. Η κατάταξη στην οποία καταλήγει ο πλήρης εκτιμητής είναι ακριβώς εκείνη του KernelSHAP, οπότε το τρίτο συστατικό *επιβεβαιώνει τα αποτελέσματα των επόμενων ενοτήτων*, αντί να τα μετακινεί. Μένει μία διαφωνία προσήμου. Ο συμμετέχων 13, με  $\varphi \approx 0$ , βγαίνει οριακά αρνητικός κατά τον KernelSHAP ( $-0,00253$ ) και οριακά θετικός και από τις δύο εκδοχές μεταθέσεων ( $+0,00756$  η τυχαία,  $+0,00498$  η καθοδηγούμενη). Η καθοδηγούμενη δειγματοληψία, δηλαδή, δεν τη διορθώνει, πράγμα που σημαίνει ότι η διαφωνία ανήκει στην οικογένεια των εκτιμητών μεταθέσεων και όχι στην πολιτική δειγματοληψίας. Για συμ-

μετέχοντα τόσο κοντά στο μηδέν, αυτό είναι αναμενόμενο και δεν επηρεάζει καμία από τις πολιτικές ανταμοιβής της Ενότητας 5.8.

### 5.2.5 Επαλήθευση με πλήρη απαρίθμηση

Η συμφωνία δύο εκτιμητών μεταξύ τους είναι ισχυρή ένδειξη αλλά δεν είναι απόδειξη. Και οι δύο θα μπορούσαν να αποκλίνουν από τον ορισμό της Εξίσωσης (2.11) με τον ίδιο τρόπο, αν το κοινό τους σημείο, η συνάρτηση αξίας ή η αντιστοίχιση παικτών, ενείχε το σφάλμα. Ούτε το αξίωμα της αποδοτικότητας αρκεί. Το κενό  $\sum_i \varphi_i - (v(N) - v(\emptyset))$  μένει της τάξης του  $10^{-16}$  σε κάθε seed αλλά το αξίωμα ικανοποιείται εξίσου καλά και από μια *λανθασμένη* κατανομή της ίδιας συνολικής αξίας.

Ο μόνος έλεγχος που δίνει οριστική απάντηση είναι η σύγκριση με το ακριβές Shapley, δηλαδή με την Εξίσωση (2.11) υπολογισμένη πάνω σε όλους τους συνασπισμούς. Έγινε με δύο τρόπους, που απαντούν σε διαφορετικά ερωτήματα.

**Στο ομοσπονδιακό παίγνιο, σε τρεις γύρους.** Για 21 παίκτες, η πλήρης απαρίθμηση απαιτεί  $2^{21}$  συνασπισμούς ανά γύρο. Έγινε για τους τρεις γύρους του Πίνακα 5.2, με την ίδια συνάρτηση αξίας που χρησιμοποιούν οι εκτιμητές. Δείχνει πόσο κοντά στον ορισμό φτάνει κάθε εκτιμητής με τον προϋπολογισμό του (Πίνακας 5.2 και Σχήμα 5.5). Για τους 1.305 βαθμολογημένους γύρους των 20 seeds θα χρειάζονταν περίπου 2,7 δισεκατομμύρια αποτιμήσεις. Γι' αυτό ακριβώς χρησιμοποιούνται εκτιμητές.

**Σε παίγνιο οκτώ παικτών, πλήρως.** Με οκτώ παίκτες οι συνασπισμοί είναι μόλις  $2^8 = 256$ , οπότε ο KernelSHAP μπορεί να τους δειγματοληπτήσει όλους. Εκεί ελέγχεται αν η υλοποίηση του εκτιμητή αναπαράγει τον ορισμό ακριβώς και όχι μόνο κατά προσέγγιση. Στο μικρό αυτό παίγνιο, η αξία ενός συνασπισμού είναι η ορθότητα ενός δικτύου που εκπαιδεύεται από την αρχή μόνο με τα δεδομένα των μελών του, οπότε κάθε συνασπισμός αποτιμάται ανεξάρτητα και η απαρίθμηση είναι καλά ορισμένη. Παίκτες ορίστηκαν οι οκτώ πρώτοι συμμετέχοντες κατά αύξοντα αναγνωριστικό, επιλογή ανεξάρτητη από το αποτέλεσμα. Στους οκτώ τυχαίνει να περιλαμβάνονται τέσσερις από τους εννέα συμμετέχοντες που λαμβάνουν αρνητική τιμή στο ομοσπονδιακό παίγνιο.

Στο παίγνιο των οκτώ, το ακριβές Shapley δίνει  $\sum_i \varphi_i = 0,753308$  με  $v(N) = 0,869698$  και  $v(\emptyset) = 0,116390$ . Ο Πίνακας 5.3 συγκρίνει τον KernelSHAP με αυτήν την τιμή αναφοράς, για αυξανόμενο πλήθος δειγματοληπτούμενων συνασπισμών.

Με πλήρη απαρίθμηση, ο KernelSHAP αναπαράγει τον ορισμό *στην ακρίβεια της μηχανής*. Η διαφορά των  $5 \times 10^{-16}$  είναι σφάλμα στρογγυλοποίησης κινητής υποδιαστολής και όχι

| Συνασπισμοί | $\max_i  \Delta\varphi_i $               | % του εύρους | Kendall $\tau$ |
|-------------|------------------------------------------|--------------|----------------|
| 32          | $2,195 \times 10^{-1}$                   | 29,1         | +0,214         |
| 64          | $9,932 \times 10^{-2}$                   | 13,2         | +0,643         |
| 128         | $2,293 \times 10^{-2}$                   | 3,0          | +0,643         |
| <b>256</b>  | <b><math>5,00 \times 10^{-16}</math></b> | <b>0,000</b> | <b>+1,000</b>  |

**Πίνακας 5.3.** Ο KernelSHAP απέναντι στην πλήρη απαρίθμηση, σε παίγνιο οκτώ παικτών. Η στήλη του εύρους εκφράζει τη μέγιστη απόκλιση ως ποσοστό του  $v(N) - v(\emptyset)$  και η τελευταία στήλη τη συμφωνία κατάταξης με το ακριβές Shapley. Στους 256 συνασπισμούς η δειγματοληψία γίνεται απαρίθμηση.

σφάλμα μεθόδου. Το συμπέρασμα είναι συγκεκριμένο. Τα βάρη του πυρήνα, η παλινδρόμηση και η αντιστοίχιση παικτών προς μεταβλητές είναι σωστά υλοποιημένα. Ο έλεγχος πραγματοποιήθηκε με την προεπιλογή της βιβλιοθήκης, δηλαδή με επιλογή παικτών (Ενότητα 5.2.1), η οποία σε αυτό το παίγνιο δε μηδένισε κανέναν παίκτη σε κανένα από τα τέσσερα μεγέθη δείγματος. Ο έλεγχος αφορά τον εκτιμητή και όχι τη συνάρτηση αξίας του ομοσπονδιακού παιγνίου, αφού έγινε σε άλλο παίγνιο. Το ίδιο ισχύει για τη σύγκριση με το ακριβές στους τρεις γύρους του Πίνακα 5.2, η οποία χρησιμοποιεί την ίδια συνάρτηση αξίας με τους εκτιμητές. Για τη συνάρτηση αξίας, ο άμεσος έλεγχος είναι ότι ο πλήρης συνασπισμός δίνει ακριβώς τις παραμέτρους του FedAvg (Ενότητα 5.1).

Αυτό που ο έλεγχος δεν αποδεικνύει πρέπει να δηλωθεί με την ίδια σαφήνεια. Ο έλεγχος δεν αποδεικνύει ότι οι 2.090 συνασπισμοί αρκούν, όταν οι παίκτες είναι 21. Για το ομοσπονδιακό παίγνιο το δείχνει η σύγκριση με το ακριβές Shapley στους τρεις γύρους (Σχήμα 5.5). Για το παίγνιο επανεκπαίδευσης το δείχνει η σύγκριση δύο ανεξάρτητων μισών των seeds (Ενότητα 5.6.3). Η στήλη του εύρους δείχνει, ωστόσο, πόσο γρήγορα πέφτει η απόκλιση, από 29,1% στους 32 συνασπισμούς σε 3,0% στους 128.


## 5.3 Αποτελέσματα της Αποτίμησης

### 5.3.1 Η κατανομή των τιμών

Το Σχήμα 5.3 δείχνει το βασικό αποτέλεσμα, σε 20 seeds.

Το άθροισμα είναι  $\sum_i \varphi_i = +0,79729$  και για τους τρεις εκτιμητές. Η ταύτιση των αθροισμάτων δεν είναι σύμπτωση αλλά συνέπεια του αξιώματος της αποδοτικότητας. Γι' αυτό λειτουργεί ως έλεγχος της υλοποίησης.

Το άθροισμα συνδέεται άμεσα με την ορθότητα 94,11% της ομοσπονδιακής τοπολογίας (Ενότητα 4.6.1). Σε κάθε γύρο, η  $v_t(\emptyset)$  είναι η ορθότητα του μοντέλου στην αρχή του γύ-



**Σχήμα 5.3.** Η συνεισφορά  $\phi$  κάθε συμμετέχοντα, σε μονάδες ορθότητας, μέσος όρος 20 seeds. Οι μπάρες είναι ο εκτιμητής KernelSHAP με  $\pm$  μία τυπική απόκλιση μεταξύ seeds, ενώ οι οριζόντιες παύλες είναι το GTG-Tib και τα σταυρουδάκια η πλήρης εκδοχή με καθοδηγούμενη δειγματοληψία (GTG guided). Οι δύο εκτιμητές μεταθέσεων δίνουν 8 αρνητικούς αντί για 9, γιατί διαφωνούν μόνο στον συμμετέχοντα 13, που είναι ο μόνος με τιμή μέσα στον θόρυβο.

ρου και η  $v_t(N)$  η ορθότητα στο τέλος του. Επομένως, το άθροισμα των  $v_t(N) - v_t(\emptyset)$  σε όλους τους γύρους είναι η τελική ορθότητα μείον την αρχική. Κατά μέσο όρο στα 20 seeds, το ανεκπαίδευτο αρχικό μοντέλο έχει ορθότητα 0,145 και το τελικό 0,941, άρα η συνολική άνοδος είναι 0,796. Οι τιμές  $\phi$ , όμως, καλύπτουν μόνο τους βαθμολογημένους γύρους. Οι γύροι που παρέλειψε η αποκοπή μετακίνησαν την ορθότητα συνολικά κατά  $-0,001$ , οπότε  $\sum_i \phi_i = 0,796 + 0,001 = 0,797$ . Με άλλα λόγια, η ομοσπονδιακή εκπαίδευση ανέβασε την ορθότητα από 14,5% σε 94,1% και το καθαρό άθροισμα των  $\phi$  είναι ακριβώς αυτή η άνοδος των περίπου 80 ποσοστιαίων μονάδων, χωρίς τους γύρους που παραλείφθηκαν.

Οι τιμές εκτείνονται από  $+0,404$  για τον συμμετέχοντα 14 έως  $-0,664$  για τον συμμετέχοντα 2. **Εννέα από τους 21 συμμετέχοντες έχουν αρνητική τιμή κατά τον KernelSHAP και οκτώ κατά καθέναν από τους δύο εκτιμητές μεταθέσεων, το GTG-Tib και την καθοδηγούμενη εκδοχή (Πίνακας 5.4).** Η μοναδική διαφορά είναι ο συμμετέχων 13, του οποίου η τιμή είναι  $-0,0025$  με τυπική απόκλιση 0,0488, δηλαδή σχεδόν είκοσι φορές μεγαλύτερη από την ίδια την τιμή. Πρόκειται για τον μόνο συμμετέχοντα που είναι ουσιαστικά μηδενικός. Το πρόσημό του, επομένως, δεν είναι ερμηνεύσιμο.


### 5.3.2 Συμφωνία εκτιμητών και σταθερότητα

Ο Πίνακας 5.4 συγκρίνει τους τρεις εκτιμητές, με αναφορά τον KernelSHAP, με τα μέτρα της Ενότητας 2.1.3. Η συμφωνία είναι υψηλή σε κάθε μέτρο. Για το GTG-Tib, ο συντελεστής

Pearson είναι 0,9997, ο Spearman 0,9935 και ο Kendall  $\tau = 0,9619$ , δηλαδή οι δύο εκτιμητές διαφωνούν στη σειρά μόνο σε 4 από τα 210 ζεύγη. Τα ζεύγη αυτά βρίσκονται σε δύο ομάδες γειτονικών θέσεων, τις θέσεις 3 και 4 και τις θέσεις 14 έως 16. Μέσα σε κάθε ομάδα, οι τιμές απέχουν λιγότερο από τη μέγιστη διαφορά των δύο εκτιμητών (0,0356). Οι πέντε πρώτοι είναι οι ίδιοι συμμετέχοντες, με τους 10 και 12 σε αντίστροφη σειρά. Η καθοδηγούμενη εκδοχή συμφωνεί ακόμη περισσότερο, με την ίδια κατάταξη σε όλα τα ζεύγη. Το αριστερό τμήμα του Σχήματος 5.4 δείχνει τη σύγκριση του KernelSHAP με το GTG-Tib.

| Εκτιμητής  | Αρνητικοί | Σύγκριση με τον KernelSHAP |        |                        |                        | Αποτιμήσεις |          |
|------------|-----------|----------------------------|--------|------------------------|------------------------|-------------|----------|
|            |           | $\tau$                     | $r$    | $\max  \Delta\varphi $ | μέση $ \Delta\varphi $ | ανά γύρο    | ανά seed |
| KernelSHAP | 9         | --                         | --     | --                     | --                     | 2.092       | 136.503  |
| GTG-Tib    | 8         | 0,9619                     | 0,9997 | 0,0356                 | 0,01113                | 1.555       | 101.431  |
| GTG guided | 8         | 1,0000                     | 0,9998 | 0,0308                 | 0,00965                | 1.564       | 102.053  |


**Πίνακας 5.4.** Οι τρεις εκτιμητές στο άθροισμα των 1.305 βαθμολογημένων γύρων, μέσοι όροι 20 seeds. Οι στήλες της σύγκρισης δίνουν τον Kendall  $\tau$  και τον Pearson  $r$  με τον KernelSHAP και τη μέγιστη και μέση απόλυτη διαφορά  $|\Delta\varphi|$  από αυτόν πάνω στους 21 συμμετέχοντες, αφού για το άθροισμα δεν υπάρχει ακριβές Shapley. Οι αποτιμήσεις είναι αποτιμήσεις της συνάρτησης αξίας. Το άθροισμα  $\sum_i \varphi_i = 0,79729$  είναι ίδιο και για τους τρεις.



**Σχήμα 5.4.** Αριστερά: οι δύο εκτιμητές δίνουν ουσιαστικά την ίδια τιμή σε κάθε συμμετέχοντα. Δεξιά: ο όγκος δεδομένων εξηγεί μόνο το 16% της διακύμανσης της συνεισφοράς. Κόκκινα τα σημεία με αρνητικό  $\varphi$ .

**Σύγκλιση ως προς το πλήθος των συνασπισμών.** Η συμφωνία αυτή δεν προκύπτει σε οποιοδήποτε υπολογιστικό κόστος. Το Σχήμα 5.5 δείχνει πώς πλησιάζουν οι δύο εκτιμητές το ακριβές Shapley, στους τρεις γύρους του Πίνακα 5.2, καθώς αυξάνεται ο αριθμός των

αποτιμήσεων. Αν και αμφότεροι παρουσιάζουν σύγκλιση, αυτή πραγματοποιείται με διαφορετικό ρυθμό και με διαφορετικό κόστος. Ο ρυθμός εξαρτάται από τον γύρο. Στους πρώτους γύρους, όπου η μεταβολή  $v_t(N) - v_t(\emptyset)$  είναι μεγάλη, η ίδια σχετική ακρίβεια είναι φθινότερη. Το σχήμα δείχνει και την πλήρη εκδοχή με καθοδηγούμενη δειγματοληψία, με τα σημεία του Πίνακα 5.2, αφού προέρχονται από την ίδια εκτέλεση.



**Σχήμα 5.5.** Η μέγιστη απόκλιση  $\max_i |\Delta\varphi_i|$  από το ακριβές Shapley του γύρου ( $2^{21}$  συνασπισμοί), ως ποσοστό της μεταβολής  $v_t(N) - v_t(\emptyset)$  του γύρου, όπως στον Πίνακα 5.3. Και οι δύο άξονες λογαριθμικοί. Για το GTG-Tib και την καθοδηγούμενη εκδοχή (GTG guided), κάθε σημείο είναι μέσος όρος πέντε τραβηγμάτων, όπως στον Πίνακα 5.2. Στον γύρο 15, η μεταβολή του γύρου είναι πολύ μικρή, οπότε στους μικρούς προϋπολογισμούς οι αποκλίσεις την ξεπερνούν.

Η σταθερότητα ως προς τα seeds ελέγχθηκε στο πρόσημο του  $\varphi$  κάθε seed χωριστά. Κατά τον KernelSHAP, 19 από τους 21 συμμετέχοντες έχουν το ίδιο πρόσημο με τον μέσο όρο τους σε 19 ή 20 από τα 20 seeds. Οι εξαιρέσεις είναι δύο. Ο συμμετέχων 6 κρατά το πρόσημό του σε 18 seeds και ο 13 σε 11. Επιπλέον, 16 από τους 21 έχουν  $|\varphi|$  μεγαλύτερο από τρεις τυπικές αποκλίσεις μεταξύ seeds, δηλαδή η τιμή τους ξεχωρίζει καθαρά από τον θόρυβο εκτίμησης. Οι πέντε που δεν περνούν το κριτήριο είναι οι 3, 6, 13, 16 και 19, δηλαδή οι πέντε με τη μικρότερη απόλυτη τιμή. Οι 3, 16 και 19 κρατούν το αρνητικό πρόσημό τους σε 19 ή 20 seeds, αλλά η τιμή τους δεν ξεχωρίζει καθαρά από τον θόρυβο.

### 5.3.3 Υπολογιστικό κόστος

Το κόστος μετριέται σε αποτιμήσεις της συνάρτησης αξίας και όχι σε χρόνο, γιατί ο χρόνος εξαρτάται από τον υπολογιστή και από το πόσες εκτελέσεις γίνονται ταυτόχρονα. Οι αριθμοί των δύο τελευταίων στηλών του Πίνακα 5.4 προκύπτουν ως εξής. Ο KernelSHAP αποτιμά σε κάθε βαθμολογημένο γύρο τους 2.090 δειγματοληπτούμενους συνασπισμούς και

τους δύο ακραίους, τον κενό και τον πλήρη, δηλαδή 2.092. Τα 20 seeds έχουν 1.305 βαθμολογημένους γύρους, δηλαδή 65,25 ανά seed κατά μέσο όρο, οπότε ο KernelSHAP εκτελεί  $2.092 \times 65,25 = 136.503$  αποτιμήσεις ανά seed. Το GTG-Tib δειγματοληπτεί έως 100 μεταθέσεις ανά γύρο και σε καθεμιά αποτιμά έναν συνασπισμό για κάθε νέα άφιξη, μέχρι η αξία να πλησιάσει αρκετά τη  $v_i(N)$ . Ένας συνασπισμός που έχει ήδη αποτιμηθεί σε προηγούμενη μετάθεση δεν αποτιμάται ξανά. Χρειάζεται, έτσι, κατά μέσο όρο 1.555 αποτιμήσεις ανά γύρο και 101.431 ανά seed. Η καθοδηγούμενη εκδοχή χρειάζεται σχεδόν όσες.

Η διατύπωση αυτού του αποτελέσματος απαιτεί προσοχή, γιατί το κόστος του KernelSHAP εξαρτάται ευθέως από τον αριθμό συνασπισμών που του ζητείται να δειγματοληπτήσει, ο οποίος είναι *παράμετρος*. Με μικρότερο προϋπολογισμό, ο ίδιος εκτιμητής κοστίζει λιγότερο από το GTG-Tib. Επομένως, η σωστή διατύπωση είναι ότι, *στον προεπιλεγμένο προϋπολογισμό της βιβλιοθήκης για 21 παίκτες*, ο εκτιμητής μεταθέσεων πετυχαίνει ουσιαστικά την ίδια κατάταξη με 26% λιγότερες αποτιμήσεις. Θα ήταν λάθος να ειπωθεί ότι «ο ένας είναι φθηνότερος», χωρίς αναφορά στον προϋπολογισμό.

Χρειάζεται, επίσης, να αποδοθεί το κέρδος στη σωστή αιτία. Δεν προέρχεται από πρόωρη σύγκλιση, αφού το κριτήριο της Εξίσωσης (10) του [30] ικανοποιείται μόλις σε **15 από τους 1.305** βαθμολογημένους γύρους των είκοσι seeds. Στους υπόλοιπους 1.290, ο εκτιμητής εξαντλεί το ανώτατο όριο των 100 μεταθέσεων, δηλαδή λειτουργεί στην πράξη με *σταθερό* προϋπολογισμό. Το κέρδος προέρχεται από δύο πηγές. Η πρώτη είναι το γεγονός ότι οι μεταθέσεις περνούν συχνά από τους ίδιους συνασπισμούς, κυρίως τους πολύ μικρούς και τους πολύ μεγάλους, που αποτιμώνται μία φορά. Η δεύτερη είναι η *αποκοπή μέσα στον γύρο*. Μαζί περιορίζουν τις αποτιμήσεις ανά γύρο από 2.092 σε 1.555 κατά μέσο όρο.

## 5.4 Έλεγχοι των Αρνητικών Τιμών

Πριν ερμηνευθεί το εύρημα των εννέα αρνητικών τιμών, πρέπει να επιβεβαιωθεί η εγκυρότητά του. Τέθηκε σε τέσσερις δοκιμασίες, καθεμιά από τις οποίες θα μπορούσε να το ακυρώσει.

**Έλεγχος 1: επιμονή στους γύρους.** Αν η αρνητική τιμή ήταν θόρυβος δειγματοληψίας, το πρόσημο θα άλλαζε από γύρο σε γύρο, γεγονός που δεν παρατηρείται. Στους 1.305 βαθμολογημένους γύρους των 20 seeds, όλοι οι εννέα έχουν αρνητική τιμή στους περισσότερους από αυτούς. Για τους επτά, το ποσοστό είναι από 79,2% έως 94,6%, με τον πιο αρνητικό, τον συμμετέχοντα 2, στο 94,2%. Χαμηλότερο είναι για τον 13 (71,1%) και τον 15 (57,8%). Για σύγκριση, ο συμμετέχων 14 είναι θετικός στο 99,8%. Το πρόσημο, επομένως, δεν αλλάζει τυχαία από γύρο σε γύρο.

**Έλεγχος 2: ανεξαρτησία από τη μετρική.** Η συνάρτηση αξίας *είναι* μια μετρική. Η Ενότητα 2.1.2 έδειξε ότι διαφορετικές μετρικές ανιχνεύουν διαφορετικές αλλαγές του πίνακα σύγχυσης [11]. Ίσως, λοιπόν, οι αρνητικές τιμές να είναι παρενέργεια της ορθότητας. Το πείραμα επαναλήφθηκε με macro-F1 στη θέση της ορθότητας, στα ίδια 20 seeds και με όλα τα υπόλοιπα ταυτόσημα. Κατά τον KernelSHAP, **κανένας συμμετέχων δεν αλλάζει πρόσημο**. Η συμφωνία κατάταξης μεταξύ των δύο μετρικών είναι  $\tau = 0,9619$ , ίδια και για τους δύο εκτιμητές. Οι πέντε πρώτες και οι πέντε τελευταίες θέσεις είναι ταυτόσημες. Κατά το GTG-Tib, αλλάζει πρόσημο ένας μόνο συμμετέχων, ξανά ο 13, που με την ορθότητα βρίσκεται οριακά πάνω από το μηδέν και με το macro-F1 κάτω από αυτό.

**Έλεγχος 3: ανεξαρτησία από τον εκτιμητή.** Το θέμα καλύφθηκε στην Ενότητα 5.3.2, όπου δύο αλγοριθμικά διαφορετικοί εκτιμητές συμφωνούν με  $\tau = 0,9619$  και δίνουν τα ίδια πρόσημα σε 20 από τους 21 συμμετέχοντες. Ο τρίτος εκτιμητής της Ενότητας 5.2.4, η πλήρης εκδοχή με καθοδηγούμενη δειγματοληψία, δίνει την *ίδια ακριβώς* κατάταξη με τον KernelSHAP και τα ίδια 20 από τα 21 πρόσημα, με τον συμμετέχοντα 13 να είναι ξανά ο μοναδικός που διαφωνεί.

**Έλεγχος 4: σταθερότητα στα seeds.** Καλύφθηκε, επίσης, στην Ενότητα 5.3.2. Οι οκτώ από τους εννέα αρνητικούς είναι αρνητικοί σε 19 ή 20 από τα 20 seeds. Εξαίρεση είναι ο 13, σε 11. Επιπλέον, 16 από τους 21 έχουν  $|\varphi| > 3\sigma$ . Από τους εννέα αρνητικούς, το κριτήριο το περνούν οι πέντε. Οι άλλοι τέσσερις, οι 3, 13, 16 και 19, είναι οι αρνητικοί με τη μικρότερη απόλυτη τιμή.

Οι έλεγχοι 2, 3 και 4 εντοπίζουν τον *ίδιο* μοναδικό ασταθή συμμετέχοντα, τον 13, ο οποίος είναι και ο μόνος με τιμή μέσα στον θόρυβο. Αυτή η σύμπτωση είναι από μόνη της ένδειξη ότι οι έλεγχοι μετρούν κάτι πραγματικό.

Επομένως, το εύρημα ευσταθεί και **οι αρνητικές τιμές δεν είναι σφάλμα εκτίμησης**. Αυτό συμφωνεί με τη βιβλιογραφία, όπου το αρνητικό πρόσημο είναι μέρος του ορισμού και όχι ανωμαλία. Για παράδειγμα, ο πίνακας συνεισφορών του ShapFed ορίζεται ρητά στο  $[-1, 1]^{n \times M}$  [28]. Η ίδια βιβλιογραφία δείχνει, μάλιστα, το αντίστροφο από το αναμενόμενο, ότι οι εκτιμητές Shapley *υποτιμούν συστηματικά* τους συμμετέχοντες με σπάνια δεδομένα [31].

Επειδή κάθε συμμετέχων εδώ είναι *ένα άτομο*, αρνητικό  $\varphi$  σημαίνει ότι η ενημέρωση αυτού του ανθρώπου, κατά μέσο όρο στους γύρους, μετακινεί το κοινό μοντέλο σε κατεύθυνση που το κάνει χειρότερο για τα 9 άτομα της αξιολόγησης. Δε σημαίνει κακά δεδομένα, σφάλμα μέτρησης ή κακόβουλη συμπεριφορά. Ούτε σημαίνει ότι ο συμμετέχων χάνει από τη συμμετοχή του, αφού και οι εννέα παίρνουν από την ομοσπονδία μοντέλο πολύ καλύτερο

από εκείνο που θα είχαν μόνοι τους (Ενότητα 4.6.2). Τον λόγο που συμβαίνει αυτό εξετάζουν οι Ενότητες 5.5 έως 5.7.

## 5.5 Μεγέθη που Σχετίζονται με τη Συνεισφορά

Οι εννέα συμμετέχοντες με αρνητική τιμή είναι οι  $\{2, 3, 5, 7, 11, 13, 15, 16, 19\}$ . Το ερώτημα αυτής της ενότητας είναι αν υπάρχει κάποιο μετρήσιμο χαρακτηριστικό τους που να προβλέπει το  $\varphi$ . Όλες οι συσχετίσεις που ακολουθούν υπολογίζονται πάνω στο  $\varphi$  των 20 seeds, δηλαδή αντιστοιχισμένες με τα αποτελέσματα των προηγούμενων ενοτήτων. Οι συσχετίσεις μετρώνται με τον συντελεστή Pearson  $r$  και την τιμή  $p$  της Ενότητας 2.1.3. Όλες αφορούν 21 παρατηρήσεις, οπότε η στατιστική ισχύς είναι περιορισμένη και καμία συσχέτιση δεν αποδεικνύει αιτία.

### 5.5.1 Όγκος δεδομένων, ετικέτες και ατομική επίδοση

Το αφελές μέτρο συνεισφοράς στη βιβλιογραφία είναι ο *όγκος δεδομένων*, δηλαδή απλώς το μέγεθος του συνόλου εκπαίδευσης [5], [6]. Στα δεδομένα της εργασίας, ο όγκος συσχετίζεται με το  $\varphi$  κατά  $r = +0,400$ , δηλαδή εξηγεί το 16,0% της διακύμανσης, όπως αποτυπώνεται στο δεξί τμήμα του Σχήματος 5.4. Η σχέση είναι θετική αλλά δεν περνά το όριο  $p < 0,05$  ( $p = 0,07$ ), αφού με 21 παρατηρήσεις το όριο απαιτεί  $|r|$  μεγαλύτερο από 0,43 περίπου (Ενότητα 2.1.3). Ακόμη κι αν ήταν πραγματική, θα άφηνε ανεξήγητα τα πέντε έκτα της διακύμανσης. Δεν είναι έκπληξη, αν αναλογιστεί κανείς ότι τα μεγέθη κυμαίνονται μόνο από 281 έως 409 samples.

Δύο ακόμη υποψήφιες εξηγήσεις δεν υποστηρίζονται από τα δεδομένα. Η *κατανομή ετικετών* δε φαίνεται να διαδραματίζει ρόλο, αφού η απόσταση ολικής μεταβολής της κατανομής κάθε συμμετέχοντα από τη συνολική, η ίδια με την Εξίσωση (3.3), δίνει  $r = +0,056$  ( $p = 0,81$ ). Αυτό ήταν αναμενόμενο μετά την Ενότητα 3.4.2. Το εύρημα είναι σημαντικό, γιατί δεν υποστηρίζει τη συνηθισμένη αφήγηση περί non-IID στις ετικέτες. Ούτε η *ποιότητα του δικού τους μοντέλου* εξηγεί κάτι, αφού η επίδοση στην ατομική τοπολογία δίνει  $r = +0,314$  ( $p = 0,17$ ), μη στατιστικά σημαντική. Ένας συμμετέχων μπορεί να εκπαιδεύει ένα καλό μοντέλο για τον εαυτό του και ταυτόχρονα να βλάπτει το συλλογικό.

### 5.5.2 Απόσταση κατανομής χαρακτηριστικών

Σε αντίθεση με τα προηγούμενα μεγέθη, η *απόσταση κατανομής χαρακτηριστικών* περνά το όριο  $p < 0,05$ . Μετρά πόσο διαφέρουν τα σήματα ενός συμμετέχοντα από εκείνα του

συνόλου ελέγχου στην ίδια δραστηριότητα. Για κάθε δραστηριότητα  $c$ , υπολογίζεται το μέσο διάνυσμα  $\mu_{i,c}$  των 561 χαρακτηριστικών του συμμετέχοντα  $i$  και το αντίστοιχο μέσο διάνυσμα  $\mu_{\text{test},c}$  του συνόλου ελέγχου. Η απόσταση είναι

$$d_i = \sum_{c=1}^6 w_c \|\mu_{i,c} - \mu_{\text{test},c}\|_2, \quad (5.2)$$

όπου  $\|\cdot\|_2$  η ευκλείδεια απόσταση και  $w_c$  το ποσοστό της δραστηριότητας  $c$  στο σύνολο ελέγχου. Η σύγκριση γίνεται χωριστά ανά δραστηριότητα, ώστε η απόσταση να μην εξαρτάται από το πόσο συχνά κάνει ο καθένας κάθε δραστηριότητα αλλά μόνο από το πώς την κάνει. Η συσχέτιση με το  $\varphi$  είναι  $r = -0,442$  ( $p = 0,045$ ). Η τιμή  $p$  δεν είναι διορθωμένη για τους πολλαπλούς ελέγχους της ενότητας, οπότε η σχέση διαβάζεται ως ένδειξη. Το πρόσημο έχει τη σωστή κατεύθυνση, δηλαδή όσο περισσότερο απέχουν τα σήματα κάποιου από εκείνα του συνόλου ελέγχου, τόσο μικρότερη η συνεισφορά του.

Η ποσότητα αυτή αντιστοιχεί σε αναγνωρισμένη κατηγορία ετερογένειας. Η ταξινομία του πεδίου την ονομάζει *ίδια ετικέτα, διαφορετικά χαρακτηριστικά*, εννοώντας ότι οι δεσμευμένες κατανομές  $P_i(x | y)$  μπορεί να διαφέρουν μεταξύ συμμετεχόντων, ακόμη και όταν η  $P(y)$  είναι κοινή [4]. Αυτό περιγράφει ακριβώς τη ρύθμιση της εργασίας, όπου όλοι εκτέλεσαν το ίδιο πρωτόκολλο έξι δραστηριοτήτων αλλά ο καθένας με τον δικό του τρόπο. Η περίπτωση διαφέρει από εκείνη των *Mavericks* της Ενότητας 2.4.3, οι οποίοι ορίζονται από τις ετικέτες [31], αφού εδώ η κατανομή ετικετών δεν εξηγεί τη συνεισφορά (Ενότητα 5.5.1).

**Απόσταση από όλους και όχι από το σύνολο ελέγχου.** Θα ήταν δελεαστικό να αποδοθεί η ερμηνεία ότι «το σύνολο ελέγχου είναι άτυχο για αυτούς τους ανθρώπους». Όμως, η ερμηνεία αυτή **δεν είναι έγκυρη**. Η απόσταση κάθε συμμετέχοντα από το σύνολο ελέγχου και η απόστασή του από τους υπόλοιπους 20 συμμετέχοντες συσχετίζονται μεταξύ τους κατά  $r = +0,987$ , δηλαδή είναι ουσιαστικά η ίδια μεταβλητή. Όσον αφορά τις μερικές συσχετίσεις, όταν η μία ελέγχεται για την άλλη, μηδενίζονται και οι δύο. Επομένως, όση σχέση υπάρχει αφορά την απόσταση από όλους και όχι ειδικά από το σύνολο ελέγχου.

### 5.5.3 Κατεύθυνση της ενημέρωσης

Όλα τα προηγούμενα μεγέθη περιγράφουν τα δεδομένα κάθε συμμετέχοντα. Το  $\varphi$ , όμως, αποτιμά την ενημέρωση που αυτά παράγουν. Γι' αυτό μετρήθηκε και πόσο συμφωνεί η ενημέρωση κάθε συμμετέχοντα με εκείνη των υπολοίπων. Σε κάθε γύρο, υπολογίζεται το συνημίτονο της γωνίας ανάμεσα στην ενημέρωση  $\Delta_t^i$  και στον σταθμισμένο μέσο όρο των ενημερώσεων των άλλων 20, με τα βάρη του FedAvg:

$$c_i = \frac{1}{T} \sum_{t=1}^T \cos(\Delta_t^i, \bar{\Delta}_t^{-i}), \quad \bar{\Delta}_t^{-i} = \frac{\sum_{j \neq i} n_j \Delta_t^j}{\sum_{j \neq i} n_j}, \quad (5.3)$$

όπου  $T = 100$  οι γύροι,  $n_j$  το πλήθος των samples του συμμετέχοντα  $j$  και  $\cos(\mathbf{a}, \mathbf{b}) = \langle \mathbf{a}, \mathbf{b} \rangle / (\|\mathbf{a}\|_2 \|\mathbf{b}\|_2)$ . Ο μέσος όρος των άλλων υπολογίζεται χωρίς τον  $i$ , ώστε κανείς να μη συγκρίνεται εν μέρει με τον εαυτό του. Τιμή +1 σημαίνει ίδια κατεύθυνση, 0 άσχετη και αρνητική τιμή αντίθετη. Το  $c_i$  υπολογίστηκε σε καθένα από τα 20 seeds, πάνω στην ίδια τροχιά εκπαίδευσης με τα κύρια αποτελέσματα, bit προς bit. Αναφέρεται ο μέσος όρος τους. Η μέτρηση **δε χρησιμοποιεί το σύνολο ελέγχου**.

Οι τιμές είναι μικρές για όλους, από  $-0,19$  έως  $+0,08$ , δηλαδή οι ενημερώσεις είναι σχεδόν κάθετες μεταξύ τους. Οι εννέα αρνητικοί, όμως, έχουν μέσο συνημίτονο  $-0,081$  και οι δώδεκα θετικοί  $+0,003$ . Η συσχέτιση με το  $\varphi$  είναι  $r = +0,580$  ( $p = 0,006$ ), η ισχυρότερη της ενότητας. Είναι θετική σε καθένα από τα 20 seeds χωριστά. Ο συμμετέχων 2 έχει το δεύτερο μικρότερο συνημίτονο από τους 21. Πρόκειται για τη γεωμετρική μορφή της απόκλισης των συμμετεχόντων της Ενότητας 2.2.3. Εδώ χρησιμοποιείται μόνο ως μέτρηση, αφού δεν εφαρμόζεται καμία διόρθωση της απόκλισης.

**Συμπέρασμα.** Ο Πίνακας 5.5 συγκεντρώνει τα πέντε μεγέθη. Κανένα δεν προβλέπει ικανοποιητικά τη συνεισφορά, καθώς ακόμη και το ισχυρότερο, η κατεύθυνση της ενημέρωσης, εξηγεί περίπου το ένα τρίτο της διακύμανσης του  $\varphi$ . Από τα μεγέθη των δεδομένων, η απόσταση χαρακτηριστικών εξηγεί λιγότερο από το ένα πέμπτο και ο όγκος δεδομένων το 16,0%.

Το πιο χαρακτηριστικό παράδειγμα είναι ο χειρότερος συμμετέχων. Ο συμμετέχων 2, με  $\varphi = -0,664$ , είναι κοντά στον μέσο όρο σε όλα τα στατιστικά των δεδομένων του εκτός από ένα (τελευταία στήλη του Πίνακα 5.5). Τον ξεχωρίζει μόνο το πλήθος των samples του, το δεύτερο μικρότερο από τους 21. Ο όγκος, όμως, δεν αρκεί για μια τόσο ακραία τιμή, αφού ο συμμετέχων 5, με τα λιγότερα samples από όλους, έχει  $\varphi = -0,242$ . Έχει, επίσης, το δεύτερο μικρότερο συνημίτονο, αλλά ούτε αυτό αρκεί, αφού ο συμμετέχων 18 έχει σχεδόν το ίδιο και θετική τιμή. Την ακραία τιμή του δεν την εξηγεί μόνο του κανένα από τα πέντε μεγέθη.

Το συμπέρασμα της ενότητας είναι, λοιπόν, ότι η αρνητική συνεισφορά σχετίζεται κυρίως με την κατεύθυνση της ενημέρωσης και λιγότερο με τα δεδομένα. Οι ενημερώσεις των εννέα

| Μέγεθος                   | Ενότητα | $r$ με το $\varphi$ | $p$   | $r^2$ | Συμμετέχων 2 |
|---------------------------|---------|---------------------|-------|-------|--------------|
| Όγκος δεδομένων           | 5.5.1   | +0,400              | 0,07  | 16,0% | -1,38        |
| Απόσταση ετικετών         | 5.5.1   | +0,056              | 0,81  | 0,3%  | +0,09        |
| Ατομική επίδοση           | 5.5.1   | +0,314              | 0,17  | 9,9%  | +0,17        |
| Απόσταση χαρακτηριστικών  | 5.5.2   | -0,442              | 0,045 | 19,5% | -0,50        |
| Κατεύθυνση της ενημέρωσης | 5.5.3   | +0,580              | 0,006 | 33,6% | -1,28        |

**Πίνακας 5.5.** Τα πέντε μεγέθη της Ενότητας 5.5, με τη συσχέτιση Pearson  $r$  με το  $\varphi$  στους 21 συμμετέχοντες, την τιμή  $p$  και το ποσοστό της διακύμανσης του  $\varphi$  που εξηγεί το καθένα ( $r^2$ ). Η τελευταία στήλη δίνει πόσες τυπικές αποκλίσεις απέχει ο συμμετέχων 2 από τον μέσο όρο των 21. Τα τέσσερα πρώτα μεγέθη αφορούν τα δεδομένα κάθε συμμετέχοντα και το τελευταίο την ενημέρωσή του.

αρνητικών απομακρύνονται, κατά μέσο όρο, από την κατεύθυνση των υπολοίπων. Επειδή ο FedAvg παίρνει μέσο όρο, μια τέτοια ενημέρωση τραβά το κοινό μοντέλο μακριά από εκεί όπου το πάνε οι περισσότεροι. Η κατεύθυνση, όμως, εξηγεί μόνο το ένα τρίτο της διακύμανσης και δεν αντικαθιστά την αποτίμηση. Αν η συνεισφορά ήταν προβλέψιμη από φθηνά μετρήσιμα μεγέθη, ο υπολογισμός Shapley θα ήταν πολυτέλεια, γεγονός που δεν ευσταθεί στα δεδομένα της εργασίας.

## 5.6 Επαλήθευση με Δεύτερο Παίγνιο στην Κεντρική Εκπαίδευση


Οι δύο προηγούμενες ενότητες έδειξαν ότι οι αρνητικές τιμές είναι πραγματικές και ότι κανένα φθηνό μέγεθος δεν τις προβλέπει πλήρως. Πριν αναλυθούν, η ενότητα αυτή επαληθεύει την προέλευσή τους με ένα δεύτερο παίγνιο που εφαρμόζεται στην κεντρική εκπαίδευση.

Ως εδώ, όλες οι τιμές προέρχονται από ένα παίγνιο, όπου η αξία ενός συνασπισμού είναι η επίδοση του μοντέλου που θα προέκυπτε από τις ενημερώσεις των μελών του. Επομένως, το ερώτημα που τίθεται είναι αν η αρνητική συνεισφορά προέρχεται από τα δεδομένα κάποιων ανθρώπων ή από τον τρόπο με τον οποίο οι ενημερώσεις συνενώνονται. Τα δύο έχουν εντελώς διαφορετικές συνέπειες. Το πρώτο θα σήμαινε ότι κάποιοι άνθρωποι συνεισφέρουν πράγματι λιγότερο, ενώ το δεύτερο ότι το πρόβλημα ανήκει στον αλγόριθμο και όχι στους ανθρώπους.

### 5.6.1 Ορισμός του παιγνίου

Για να απαντηθεί το προς διερεύνηση ζήτημα, ορίζεται δεύτερο παίγνιο με τους *ίδιους* 21 παίκτες αλλά διαφορετική συνάρτηση αξίας (Σχήμα 5.6). Η αξία ενός συνασπισμού  $S$  είναι η επίδοση ενός μοντέλου που εκπαιδεύεται *από την αρχή* κεντρικά, μόνο με τα δεδομένα των μελών του  $S$ . Η ομοσπονδιακή συνάθροιση απουσιάζει εντελώς. Ό,τι απομένει είναι η αξία των δεδομένων καθαυτών, δηλαδή το Data Shapley με επανεκπαίδευση, όπως ορίζεται στη βιβλιογραφία [19].

Το κόστος είναι η επανεκπαίδευση, που εδώ σημαίνει 41.840 εκπαιδεύσεις στα 20 seeds. Σε κάθε seed, ο KernelSHAP διαλέγει πρώτα 2.090 συνασπισμούς, όσους και στο ομοσπονδιακό παίγνιο. Οι εκπαιδεύσεις γίνονται με τον βρόχο και τις ρυθμίσεις της κεντρικής τοπολογίας (Ενότητα 4.3.1) και η αξία κάθε συνασπισμού είναι η ορθότητα του μοντέλου του στο σύνολο ελέγχου. Η ροή του υπολογισμού δίνεται στο Σχήμα 5.7. Τρεις αποφάσεις δηλώνονται ρητά. Όλοι οι συνασπισμοί εκπαιδεύονται με το *ίδιο* seed, ώστε οι διαφορές μεταξύ τους να μην περιέχουν διαφορά αρχικοποίησης. Ο κενός συνασπισμός αποτιμάται ως το αρχικοποιημένο και μη εκπαιδευμένο δίκτυο. Τέλος, κάθε συνασπισμός εκπαιδεύεται για τις ίδιες 100 εποχές, ανεξάρτητα από το πλήθος των δεδομένων του. Ως έλεγχος της υλοποίησης, ο συνασπισμός και των 21 αναπαράγει το αποθηκευμένο κεντρικό αποτέλεσμα σε 20 από τα 20 seeds, bit προς bit.



**Σχήμα 5.6.** Τα δύο παίγνια, ορισμένα πάνω στους ίδιους 21 παίκτες. Ό,τι αλλάζει είναι η σημασία του «χωρίς τον  $i$ » και, μαζί της, η αξία του κενού συνασπισμού. Η διαφορά αυτή εξηγεί γιατί η σύγκριση των δύο πρέπει να γίνει στην *κατάταξη* και όχι στο πρόσημο.

Στο παίγνιο αυτό χρησιμοποιείται ένας μόνο εκτιμητής, ο KernelSHAP, γιατί εδώ κάθε αποτίμηση είναι μια πλήρης εκπαίδευση και ένας δεύτερος εκτιμητής θα χρειαζόταν δικές του εκπαιδεύσεις. Το κενό που αφήνει η απουσία δεύτερου εκτιμητή καλύπτεται από δύο

ελέγχους. Ο πρώτος είναι η σύγκριση με τον ίδιο τον ορισμό. Το παίγνιο οκτώ παικτών της Ενότητας 5.2.5, όπου ο KernelSHAP αναπαράγει το ακριβές Shapley στην ακρίβεια της μηχανής, είναι ακριβώς αυτό το παίγνιο, περιορισμένο στους οκτώ πρώτους συμμετέχοντες. Δείχνει ότι ο εκτιμητής είναι σωστά υλοποιημένος. Ο δεύτερος είναι η σύγκριση δύο ανεξάρτητων μισών των seeds (Ενότητα 5.6.3), που δείχνει αν οι 2.090 συνασπισμοί αρκούν για 21 παίκτες. Ο KernelSHAP εκτελέστηκε εδώ με την προεπιλογή της βιβλιοθήκης, δηλαδή με επιλογή παικτών (Ενότητα 5.2.1), χωρίς επίδραση, αφού κανένα από τα 420  $\varphi$  δε βγήκε μηδέν.


Εδώ δεν υπάρχουν γύροι. Για κάθε seed στήνεται ένα μόνο παίγνιο και η παλινδρόμηση του KernelSHAP δίνει κατευθείαν την τιμή  $\varphi_i(s)$  του seed, χωρίς άθροισμα γύρων (βήμα 3 του Σχήματος 5.7). Οι εκπαιδεύσεις των συνασπισμών (βήμα 2) είναι ανεξάρτητες μεταξύ τους και μοιράζονται σε παράλληλες διεργασίες, ενώ τα seeds εκτελούνται το ένα μετά το άλλο. Επειδή χρειάζονται δεκάδες χιλιάδες εκπαιδεύσεις, η κεντρική εκπαίδευση καλείται μέσα από μια διαδρομή που παραλείπει ό,τι δε χρειάζεται, όταν ζητείται μόνο η τελική επίδοση, όπως η καταγραφή ανά εποχή και οι ενδιάμεσες αξιολογήσεις. Η παράλειψη δεν είναι αβλαβής εξ ορισμού, γιατί η αξιολόγηση καταναλώνει τυχειότητα (Ενότητα 4.4). Γι' αυτό ο πλήρης συνασπισμός συγκρίνεται με το αποθηκευμένο κεντρικό αποτέλεσμα σε κάθε seed.

Στον κώδικα, η επιλογή των συνασπισμών και η παλινδρόμηση (βήματα 1 και 3) γίνονται στη `run_seed()` του `contribution/data_shapley.py` και οι μέσοι όροι με τη σύγκριση της κατάταξης (βήμα 4) στη `summarize()` του ίδιου αρχείου. Η εκπαίδευση ανά συνασπισμό (βήμα 2) οργανώνεται από την `RetrainGame` του `contribution/sv/retrain_game.py`, που στέλνει κάθε εκπαίδευση στην `fast_holdout_predict()` του `centralized/fast_holdout.py`.


## 5.6.2 Αποτελέσματα

**Κανένας από τους 21 συμμετέχοντες δε λαμβάνει αρνητική τιμή.** Το εύρος είναι +0,0241 έως +0,0485, δηλαδή τα δεδομένα κάθε ανθρώπου αξίζουν από 2,4 έως 4,8 ποσοστιαίες μονάδες ορθότητας. Δε βρέθηκε ένδειξη ότι τα δεδομένα κάποιου βλάπτουν, όταν χρησιμοποιηθούν μέσα σε μια κοινή εκπαίδευση. Το Σχήμα 5.8 παρουσιάζει τα δύο παίγνια μαζί.

Η κατάταξη των δύο παιγνίων συμφωνεί ασθενώς, με  $\tau = 0,238$  (αριστερό τμήμα του Σχήματος 5.8). Έξι από τους εννέα συμμετέχοντες που είναι αρνητικοί στο ομοσπονδιακό παίγνιο βρίσκονται κάτω από τη διάμεσο και εδώ, οπότε υπάρχει πράγματι σήμα που συνδέει τα δύο. Όμως, το μεγαλύτερο μέρος της κατάταξης δε μεταφέρεται. Τα συγκεκριμένα παραδείγματα το αναδεικνύουν καθαρότερα από τον συντελεστή. Ο συμμετέχων 2, με διαφορά ο χειρότερος του ομοσπονδιακού παιγνίου ( $\varphi = -0,664$ , θέση 21 από 21), είναι *μεσαίος*



**Σχήμα 5.7.** Η αποτίμηση στο παίγνιο επανεκπαίδευσης. Το βήμα 2 γίνεται μία φορά για κάθε συνασπισμό και είναι το μόνο που εκπαιδεύει. Κάθε seed έχει ένα μόνο παίγνιο, οπότε η τιμή του seed βγαίνει κατευθείαν από την παλινδρόμηση.



**Σχήμα 5.8.** Αριστερά: η θέση κάθε συμμετέχοντα στο ομοσπονδιακό παίγνιο και στο παίγνιο επανεκπαίδευσης (centralized στο σχήμα). Με κόκκινο όσοι λαμβάνουν αρνητική τιμή στο ομοσπονδιακό. Δεξιά: οι δύο κατανομές των  $\varphi$  στον ίδιο άξονα. Το άθροισμα και ο μέσος είναι ουσιαστικά ταυτόσημα, η διασπορά όχι.

εδώ. Ο συμμετέχων 14, ο καλύτερος του ομοσπονδιακού παιγνίου, δε βρίσκεται κοντά στην κορυφή. Οι ακριβείς θέσεις τους δίνονται στον Πίνακα 5.6, μετά τον έλεγχο της ακρίβειας της Ενότητας 5.6.3. Επιπλέον, ο χειρότερος αυτού του παιγνίου είναι θετικός στο άλλο.

### 5.6.3 Ακρίβεια της εκτίμησης

Επειδή το παίγνιο αυτό δεν έχει δεύτερο εκτιμητή για διασταύρωση, η ακρίβεια ελέγχεται διαφορετικά. Τα 20 seeds χωρίζονται σε δύο ανεξάρτητα μισά και τα δύο αποτελέσματα συγκρίνονται μεταξύ τους. Ο έλεγχος αυτός είναι αναγκαίος, γιατί ο θόρυβος της στοχαστικής βελτιστοποίησης καθιστά τις κατατάξεις αποτίμησης ασυνεπείς μεταξύ εκτελέσεων [25].

Η μέση απόλυτη διαφορά ανάμεσα στα δύο μισά είναι 0,0027, ενώ ο θόρυβος των seeds από μόνος του θα προέβλεπε περίπου 0,0036. Η διαφορά είναι, δηλαδή, συμβατή με τον θόρυβο. Οι συντελεστές συσχέτισης ανάμεσα στα μισά είναι 0,811 κατά Pearson και 0,657 κατά Kendall. Σε κανένα από τα δύο μισά δεν εμφανίζεται αρνητική τιμή. Επιπροσθέτως, η ασθενής συμφωνία με το ομοσπονδιακό παίγνιο αναπαράγεται και στα δύο, με  $\tau = 0,219$  και 0,314 έναντι 0,238 συνολικά.

Σε αριθμούς, το εύρος των τιμών μεταξύ συμμετεχόντων είναι περίπου 0,024 και το τυπικό σφάλμα με 20 seeds 0,0022, δηλαδή 9% του εύρους. Από τα 210 ζεύγη συμμετεχόντων, τα 100 διαχωρίζονται στατιστικά. Για να υποχωρήσει το σφάλμα στο 10%, θα αρκούσαν 17 seeds, οπότε τα 20 ήταν επαρκής και όχι υπερβολική επιλογή.

Το συμπέρασμα του ελέγχου είναι διπλό. Το δεύτερο μέρος του είναι περιορισμός. Τα ποιοτικά συμπεράσματα είναι σταθερά αλλά η ακριβής θέση ενός μεμονωμένου συμμετέχοντα στην κατάταξη δεν είναι. Ο συμμετέχων 2 είναι 13ος και 15ος στα δύο μισά, σταθερά στη μέση, ενώ ο 14 είναι 8ος και 16ος. Γι' αυτό, στον Πίνακα 5.6, η θέση στο σύνολο των seeds συνοδεύεται από τη θέση σε κάθε μισό.

### 5.6.4 Συμπέρασμα

Ο Πίνακας 5.6 συγκεντρώνει τα δύο παίγνια.

Τα αποτελέσματα του δεύτερου παιγνίου διαβάζονται με μία επιφύλαξη, που αφορά το πρόσημο. Το γεγονός ότι κανείς δε βγαίνει αρνητικός εδώ δεν αποδεικνύει από μόνο του ότι τα δεδομένα όλων είναι καλά. Δείχνει, σε μεγάλο βαθμό, ότι το παίγνιο αυτό δύσκολα μπορεί να παραγάγει αρνητικό πρόσημο.

Ο λόγος βρίσκεται στον ίδιο τον ορισμό. Το  $\varphi$  είναι μέσος όρος οριακών συνεισφορών πάνω σε όλες τις σειρές άφιξης. Οι σειρές αυτές δεν είναι ισοδύναμες. Στο παίγνιο επανεκ-

|                               | Ομοσπονδιακό παίγνιο           | Παίγνιο επανεκπαίδευσης |
|-------------------------------|--------------------------------|-------------------------|
| Τι αποτιμά                    | την ενημέρωση                  | τα δεδομένα             |
| Αξία του κενού συνασπισμού    | το μοντέλο της αρχής του γύρου | ανεκπαίδευτο δίκτυο     |
| Εκπαιδεύσεις στα 20 seeds     | καμία επιπλέον                 | 41.840                  |
| $\sum_i \varphi_i$            | +0,797                         | +0,804                  |
| Μέσος όρος των $\varphi$      | +0,038                         | +0,038                  |
| Τυπική απόκλιση των $\varphi$ | 0,285                          | 0,0063                  |
| Εύρος                         | −0,664 έως +0,404              | +0,0241 έως +0,0485     |
| Αρνητικοί                     | 9                              | 0                       |
| Θέση του συμμετέχοντα 2       | 21                             | 15 (13 και 15)          |
| Θέση του συμμετέχοντα 14      | 1                              | 13 (8 και 16)           |
| Συμφωνία κατάταξης            | Kendall $\tau = 0,238$         |                         |

**Πίνακας 5.6.** Τα δύο παίγνια πάνω στους ίδιους 21 παίκτες, μέσοι όροι 20 seeds, εκτιμητής KernelSHAP. Η τυπική απόκλιση είναι μεταξύ των 21 συμμετεχόντων. Θέση 1 είναι η μεγαλύτερη τιμή. Στο παίγνιο επανεκπαίδευσης οι θέσεις δεν είναι σταθερές από seed σε seed, γι' αυτό σε παρένθεση δίνεται η θέση σε καθένα από τα δύο μισά των seeds (Ενότητα 5.6.3).

παίδευσης, όποιος φτάνει πρώτος μετατρέπει ένα μη εκπαιδευμένο δίκτυο σε λειτουργικό ταξινομητή. Η αξία της θέσης αυτής, μετρημένη χωριστά, είναι κατά μέσο όρο +0,612 και το μικρότερο είναι +0,505. Η αξία της τελευταίας θέσης, όπου το μοντέλο έχει ήδη δει τα δεδομένα είκοσι ανθρώπων, είναι κατά μέσο όρο +0,0030, με εύρος από −0,0070 έως +0,0207. Οι δύο θέσεις διαφέρουν κατά δύο τάξεις μεγέθους. Για να βγει αρνητικό  $\varphi$ , θα έπρεπε οι λίγες αρνητικές οριακές συνεισφορές των τελευταίων θέσεων να υπερκαλύψουν το μπόνους της πρώτης, κάτι πρακτικά αδύνατο. Στο ομοσπονδιακό παίγνιο, τέτοιο μπόνους υπάρχει μόνο στους πρώτους γύρους, γιατί κάθε συνασπισμός ενός γύρου ξεκινά από το μοντέλο της αρχής του γύρου, που μετά τους πρώτους γύρους είναι ήδη εκπαιδευμένο.

Ο αριθμός που το δείχνει με σαφήνεια είναι η σύγκριση των δύο κατανομών. Το άθροισμα των  $\varphi$  είναι ουσιαστικά το ίδιο (+0,797 έναντι +0,804), όπως και ο μέσος όρος (+0,038 και στα δύο). Η τυπική απόκλιση, όμως, διαφέρει κατά παράγοντα περίπου 45 (0,285 έναντι 0,0063). Ο μέσος όρος δεσμεύεται από το αξίωμα της αποδοτικότητας και δεν παρέχει πρόσθετη πληροφορία. Η πληροφορία βρίσκεται στο πώς μοιράζεται το άθροισμα ανάμεσα στους συμμετέχοντες. Το μέγεθος που πρέπει να συγκριθεί ανάμεσα στα δύο παίγνια είναι η **κατάταξη**, όχι το πρόσημο.

Με αυτήν την επιφύλαξη, το συμπέρασμα είναι το εξής. Δε βρέθηκε ένδειξη ότι τα δεδομένα κάποιου συμμετέχοντα είναι βλαβερά, ενώ υπάρχει ασθενές σήμα που συνδέει την ποιότητα των δεδομένων με την ομοσπονδιακή συνεισφορά. Το μεγαλύτερο μέρος της αρνητικής συνεισφοράς, όμως, *γεννιέται στη συνάθροιση*, γιατί ο FedAvg παίρνει μέσο όρο παραμέτρων από μοντέλα που εκπαιδεύτηκαν χωριστά, ενώ η κεντρική εκπαίδευση λύνει τις

ίδιες συγκρούσεις μέσα στην ίδια τη διαδικασία βελτιστοποίησης. Το  $\varphi$  του ομοσπονδιακού παιγνίου μετρά την αξία της *ενημέρωσης*, ενώ το  $\varphi$  αυτού εδώ μετρά την αξία των *δεδομένων*. Τα δύο μεγέθη έχουν το ίδιο όνομα αλλά διαφορετικό αντικείμενο. Γι' αυτό η ανάλυση αστοχίας της επόμενης ενότητας επιστρέφει στο ομοσπονδιακό παίγνιο, όπου γεννιέται η αρνητική τιμή.


## 5.7 Ανάλυση Αστοχίας

Αφού η αρνητική τιμή γεννιέται κυρίως στη συνάθροιση, η ανάλυση αστοχίας (*failure analysis*) μελετά το ίδιο το ομοσπονδιακό παίγνιο. Το  $\varphi_i$  είναι ένας αριθμός αλλά προκύπτει ως άθροισμα πάνω σε γύρους. Η ορθότητα από την οποία υπολογίζεται είναι, με τη σειρά της, σταθμισμένος μέσος όρος πάνω σε δραστηριότητες και πάνω σε άτομα της αξιολόγησης. Η ενότητα αποσυνθέτει πρώτα την τιμή κατά μήκος αυτών των τριών αξόνων, ώστε να φανεί *πότε* εμφανίζεται, *σε ποιες* δραστηριότητες και *απέναντι σε ποιους* ανθρώπους. Στη συνέχεια, εξετάζει αν αυτό που μετρήθηκε μπορεί να αξιοποιηθεί. Τα δύο μέρη αποτελούν ένα ενιαίο επιχείρημα, γιατί η αποσύνθεση δείχνει ότι η αρνητική τιμή εξαρτάται από το ποια άτομα βρίσκονται στο σύνολο ελέγχου. Ο έλεγχος της αξιοποίησης μετρά πόσο ισχυρή είναι αυτή η εξάρτηση.

### 5.7.1 Η αρνητική τιμή ανά γύρο

Η τιμή  $\varphi_i$  των προηγούμενων ενοτήτων είναι άθροισμα πάνω στους βαθμολογημένους γύρους κάθε seed, δηλαδή στους γύρους που κρατά η αποκοπή μεταξύ γύρων (Ενότητα 5.2.2), από 51 έως 74, με μέσο όρο 65. Ένα άθροισμα, όμως, κρύβει τη χρονική του δομή, αφού η ίδια συνολική τιμή προκύπτει είτε από σταθερή μικρή βλάβη σε όλη τη διάρκεια, είτε από έντονη βλάβη σε ένα μόνο διάστημα. Η διάκριση δεν είναι ακαδημαϊκή, γιατί καθορίζει αν η αρνητική συνεισφορά είναι ιδιότητα του συμμετέχοντα ή ιδιότητα της *φάσης* της εκπαίδευσης.

Επομένως, οι τιμές αναλύθηκαν ανά γύρο. Η εικόνα που προκύπτει έχει σαφή τομή (Σχήμα 5.9). Στους γύρους 1 έως 10, όσο η ορθότητα του κοινού μοντέλου ανεβαίνει από 59,3% στο τέλος του πρώτου γύρου σε 90,1% στο τέλος του δέκατου, οι εννέα συμμετέχοντες που τελικά λαμβάνουν αρνητική τιμή είναι, ως ομάδα, **θετικοί**, με μέση συνεισφορά +0,083 μονάδες και θετικό πρόσημο σε 19 από τα 20 seeds. Από τον ενδέκατο γύρο και μετά, το πρόσημο αντιστρέφεται και παραμένει αρνητικό σε **20 από τα 20** seeds, σε κάθε ομάδα γύρων που εξετάστηκε.



**Σχήμα 5.9.** Αριστερά: η τιμή ανά βαθμολογημένο γύρο, χωριστά για τις δύο ομάδες συμμετεχόντων, μέσος όρος 20 seeds. Μέχρι τον δέκατο γύρο και οι δύο είναι θετικές. Στην άκρη κάθε στήλης των αρνητικών, το πλήθος των seeds στα οποία η ομάδα βγαίνει κάτω από το μηδέν. Δεξιά: το άθροισμα και των 21, επίσης ανά βαθμολογημένο γύρο. Το άθροισμα με πρόσημο σβήνει μετά τον δέκατο γύρο, ενώ το άθροισμα των απόλυτων τιμών όχι. Και τα δύο πάνελ δείχνουν ρυθμό ανά γύρο, ώστε οι ομάδες γύρων άνισου πλάτους να συγκρίνονται μεταξύ τους.

Η ένταση της βλάβης δεν είναι σταθερή. Ο ρυθμός ανά γύρο είναι  $-0,049$  μονάδες στους γύρους 11 έως 25 και υποχωρεί σε  $-0,031$  στους γύρους 51 έως 100. Η βλάβη, δηλαδή, είναι *εντονότερη αμέσως μετά την τομή και εξασθενεί* καθώς η εκπαίδευση προχωρά. Η σύγκριση γίνεται με τον ρυθμό ανά γύρο και όχι με το άθροισμα κάθε ομάδας γύρων, γιατί οι ομάδες έχουν *άνισο πλάτος*. Η ομάδα 51 έως 100 έχει διπλάσιους βαθμολογημένους γύρους από την ομάδα 11 έως 25 και, επομένως, μεγαλύτερο άθροισμα ακόμη και με μικρότερο ρυθμό. Η σύγκριση των αθροισμάτων θα έδινε την εσφαλμένη εντύπωση ότι η βλάβη συγκεντρώνεται στο πλατό των τελευταίων γύρων, ενώ στην πραγματικότητα *ξεκινά* όταν το μοντέλο ξεπεράσει περίπου το 90% και είναι εντονότερη αμέσως μετά.

**Μεικτή και καθαρή κίνηση.** Το άθροισμα των τιμών όλων των συμμετεχόντων σε έναν γύρο είναι σχεδόν μηδενικό από τον ενδέκατο γύρο και μετά, σε 20 από τα 20 seeds. Αυτό δε σημαίνει ότι δε συμβαίνει τίποτα. Το άθροισμα των *απόλυτων* τιμών, δηλαδή η συνολική μάζα που μετακινείται ανεξαρτήτως κατεύθυνσης, είναι τουλάχιστον δεκαπλάσιο του αθροίσματος με πρόσημο. Εννέα συμμετέχοντες τραβούν το μοντέλο προς τη μία κατεύθυνση και δώδεκα προς την άλλη. Οι δύο δυνάμεις σχεδόν αλληλοεξουδετερώνονται. Στο πλατό, η ομοσπονδία δεν είναι ακίνητη αλλά βρίσκεται σε ισορροπία.

Δύο συμμετέχοντες ορίζουν τα άκρα αυτής της εικόνας. Ο συμμετέχων 2 είναι αρνητικός στο 100% των γύρων μετά τον δέκατο, χωρίς καμία εξαίρεση σε κανένα seed. Ο συμμετέχων 15 είναι η αντίστροφη περίπτωση. Βλάπτει κυρίως στους δέκα πρώτους γύρους, όπου είναι ο

πιο αρνητικός από τους εννέα. Μετά τον γύρο 25, η συνεισφορά του είναι σχεδόν μηδενική, οπότε η αρνητική του τιμή είναι κατάλοιπο της αρχικής φάσης και όχι χαρακτηριστικό της συμπεριφοράς του.

Το εύρημα αυτό αλλάζει τη διατύπωση του ερωτήματος. Δεν υπάρχουν απλώς συμμετέχοντες που βλάπτουν και συμμετέχοντες που βοηθούν αλλά συμμετέχοντες των οποίων η συνεισφορά *αλλάζει πρόσημο*, όταν το μοντέλο φτάσει σε ένα επίπεδο επίδοσης. Όσο το μοντέλο μαθαίνει ακόμα τη βασική διάκριση των δραστηριοτήτων, θετικά συνεισφέρουν και οι δύο ομάδες. Όταν, όμως, απομένουν μόνο τα λεπτά σύνορα μεταξύ γειτονικών δραστηριοτήτων, ορισμένοι αρχίζουν να εισάγουν αποκλίνουσες τάσεις. Οι δύο επόμενες υποενότητες εξετάζουν την κατεύθυνση αυτών των αποκλίσεων, αρχικά ανά δραστηριότητα και έπειτα ανά άτομο της αξιολόγησης.

### 5.7.2 Η αρνητική τιμή ανά δραστηριότητα

Μέχρι εδώ, η συνάρτηση αξίας ήταν βαθμωτή. Μπορεί, όμως, να γίνει διανυσματική, με μία συνιστώσα ανά δραστηριότητα, όπως στο ShapFed, όπου η συνάρτηση χρησιμότητας ορίζεται ως επίδοση ανά κλάση [28], ή στην αποτίμηση ανά ετικέτα για τους Mavericks [31]. Τότε, κάθε συμμετέχων παίρνει έξι τιμές αντί για μία και προκύπτει μια μήτρα  $21 \times 6$ .

**Πώς προκύπτουν οι έξι τιμές.** Στην πράξη αλλάζει μόνο η συνάρτηση αξίας της Εξίσωσης (5.1). Όλα τα υπόλοιπα μένουν ίδια, δηλαδή η εκπαίδευση, οι βαθμολογημένοι γύροι, οι συνασπισμοί και η ανασύνθεση των μοντέλων τους. Το μοντέλο κάθε συνασπισμού  $S$  ταξινομεί τα 2.947 samples του συνόλου ελέγχου όπως πριν. Αντί, όμως, να μετρηθεί το ποσοστό των σωστών σε όλο το σύνολο, μετριέται χωριστά σε κάθε δραστηριότητα, δηλαδή μετριέται η ανάκλησή της (Εξίσωση (2.2)). Η  $v_t(S)$  γίνεται έτσι διάνυσμα έξι αριθμών. Ο KernelSHAP χρησιμοποιεί τους ίδιους δειγματοληπτούμενους συνασπισμούς για τις έξι συνιστώσες και λύνει μία παλινδρόμηση για καθεμία, οπότε κάθε συμμετέχων παίρνει σε κάθε γύρο έξι τιμές, μία ανά δραστηριότητα. Οι τιμές αθροίζονται στους γύρους και οι μέσοι όροι των 20 seeds δίνουν τη μήτρα, όπως ακριβώς και η βαθμωτή τιμή. Η πύλη που αποφασίζει ποιοι γύροι βαθμολογούνται εφαρμόζεται στη σταθμισμένη μεταβολή των έξι συνιστωσών, η οποία ισούται με τη μεταβολή της ορθότητας, οπότε βαθμολογούνται οι ίδιοι γύροι με το κύριο αποτέλεσμα.

**Η αλλαγή στον κώδικα.** Η αλλαγή περιορίζεται σε τρεις κλάσεις του φακέλου `contribution/sv/`, στο βήμα 3 του Σχήματος 5.2. Η `CoalitionEvaluator`, που δίνει την αξία ενός συνασπισμού, παίρνει την παράμετρο `metric="per_class"` και επιστρέφει τις έξι ανακλήσεις στη θέση της ορθότητας. Η `ClasswiseRoundGame`

κληρονομεί την ανασύνθεση των μοντέλων από την RoundGame χωρίς καμία αλλαγή και ελέγχει μόνο ότι η αξία έχει έξι συνιστώσες. Η KernelShapClasswiseEstimator δίνει στη βιβλιοθήκη shap μια συνάρτηση που επιστρέφει πίνακα με μία γραμμή ανά συνασπισμό και μία στήλη ανά δραστηριότητα. Η βιβλιοθήκη λύνει τότε μία παλινδρόμηση ανά στήλη πάνω στους ίδιους συνασπισμούς. Κάθε μοντέλο συνασπισμού αξιολογείται μία φορά και όχι έξι, οπότε το κόστος μένει ουσιαστικά ίδιο με της βαθμωτής τιμής. Το ίδιο κάνει η GtgClasswiseEstimator για το GTG-Tib, όπου οι οριακές συνεισφορές αθροίζονται στοιχείο προς στοιχείο. Οι κλάσεις αυτές είναι ξεχωριστές από τις βαθμωτές, ώστε ο υπολογισμός του κύριου αποτελέσματος να μένει αμετάβλητος. Την εκτέλεση οδηγεί το `contribution/contribution_classwise.py`. Με `metric="per_subject"`, ο ίδιος κώδικας δίνει την ανάλυση ανά άτομο της Ενότητας 5.7.3.

Οι δύο αναλύσεις δένονται με μια ταυτότητα. Η ορθότητα γράφεται ως σταθμισμένος μέσος των ανακλήσεων,  $\text{Acc} = \sum_c w_c R_c$  με  $w_c = n_c/N$  το ποσοστό της κλάσης  $c$  στο σύνολο ελέγχου. Επειδή ο τύπος της Εξίσωσης (2.11) είναι γραμμικός ως προς τη συνάρτηση αξίας, έπεται ότι


$$\varphi_i(\text{Acc}) = \sum_{c=1}^6 w_c \varphi_i(R_c). \quad (5.4)$$

Η ταυτότητα αυτή *ελέγχθηκε αριθμητικά και δεν υποτέθηκε*. Για τον KernelSHAP, η μέγιστη απόκλιση μεταξύ των δύο πλευρών σε όλους τους 21 συμμετέχοντες είναι της τάξης του  $10^{-16}$ , δηλαδή σφάλμα στρογγυλοποίησης. Τα δύο αθροίσματα ταυτίζονται στο 0,79729. Για το GTG-Tib, η απόκλιση είναι μεγαλύτερη, 0,025, επειδή συσσωρεύει δύο ανεξάρτητα σφάλματα δειγματοληψίας, ένα από τον βαθμωτό και ένα από τον ανά κλάση υπολογισμό, ενώ ο KernelSHAP, δεδομένων των συνασπισμών, είναι γραμμικός ως προς τη συνάρτηση αξίας. Ο έλεγχος λειτουργεί ως ανεξάρτητη επαλήθευση και των δύο υλοποιήσεων.

Η μήτρα  $21 \times 6$  φαίνεται στο Σχήμα 5.10.

**Το εύρημα είναι ότι οι συμμετέχοντες δε βοηθούν ή βλάπτουν συνολικά.** Ελάχιστες γραμμές είναι ομοιόμορφα πράσινες ή κόκκινες. Αντιθέτως, σχεδόν κάθε γραμμή έχει και τα δύο χρώματα, δηλαδή ο ίδιος συμμετέχων βελτιώνει κάποιες δραστηριότητες και χειροτερεύει άλλες. Αυτό που μετρά το συνολικό  $\varphi$  είναι το υπόλοιπο.

Ο Πίνακας 5.7 δίνει τη μήτρα σε αριθμούς. Η δομή γίνεται ρητή στις συσχετίσεις μεταξύ στηλών. Τα τρία ζεύγη με την πιο αρνητική συσχέτιση είναι γειτονικές δραστηριότητες. Στο ζεύγος SITTING και STANDING, όποιος βελτιώνει τη μία χειροτερεύει σχεδόν ακριβώς ανάλογα την άλλη ( $r = -0,933$ ). Πρόκειται, δηλαδή, για μετακίνηση συνόρου απόφασης μεταξύ δύο γειτονικών κλάσεων και όχι για γενική βελτίωση ή βλάβη.



**Σχήμα 5.10.** Η συνεισφορά κάθε συμμετέχοντα σε κάθε δραστηριότητα, σε μονάδες ανάκλησης. Οι γραμμές είναι ταξινομημένες κατά φθίνον συνολικό  $\varphi$ . Πράσινο σημαίνει θετική και κόκκινο αρνητική συνεισφορά, όπως στο Σχήμα 5.3.

|               |        | Στο συνολικό $\varphi$ |      |                        |
|---------------|--------|------------------------|------|------------------------|
|               |        | Δραστηριότητα          | Τ.α. | 9 αρνητικοί 12 θετικοί |
| Ζεύγος στηλών | $r$    | WALK                   | 0,48 | -0,09 +0,23            |
| SIT, STAND    | -0,933 | WUP                    | 1,49 | -0,02 +0,13            |
| STAND, LAY    | -0,733 | W.DOWN                 | 1,72 | -0,90 +1,01            |
| WUP, W.DOWN   | -0,724 | SIT                    | 2,31 | -1,81 +1,95            |
| WALK, W.DOWN  | -0,317 | STAND                  | 1,39 | +1,02 -0,87            |
|               |        | LAY                    | 0,31 | -0,26 +0,41            |
|               |        | Σύνολο                 |      | -2,06 +2,86            |

**Πίνακας 5.7.** Η μήτρα του Σχήματος 5.10 σε αριθμούς, με τα ονόματα του σχήματος. Αριστερά, οι τέσσερις πιο αρνητικές συσχετίσεις Pearson μεταξύ των στηλών της, πάνω στους 21 συμμετέχοντες. Δεξιά, η τυπική απόκλιση (τ.α.) κάθε στήλης στους 21 συμμετέχοντες, σε μονάδες ανάκλησης. Οι δύο τελευταίες στήλες δίνουν το άθροισμα της στήλης για τις δύο ομάδες συμμετεχόντων, σταθμισμένο όπως στην Εξίσωση (5.4), ώστε το σύνολο να είναι το άθροισμα των  $\varphi$  κάθε ομάδας.

Η τυπική απόκλιση ανά δραστηριότητα το επιβεβαιώνει από άλλη οπτική. Οι συμμετέχοντες συμφωνούν σχεδόν απόλυτα στην κατάκλιση και στο βάδισμα, ενώ διαφωνούν έντονα στα δύο κλασικά ζεύγη σύγχυσης.

Η ίδια μήτρα δείχνει και από πού προέρχεται η αρνητική τιμή των εννέα. Με τη στάθμιση της Εξίσωσης (5.4), το άθροισμά τους,  $-2,06$  μονάδες, προέρχεται κυρίως από την καθιστή στάση και την κατάβαση σκάλας, ενώ στην όρθια στάση είναι θετικό. Οι δώδεκα θετικοί κάνουν το αντίστροφο. Οι δύο ομάδες επηρεάζουν, δηλαδή, τις ίδιες δραστηριότητες σε αντίθετες κατευθύνσεις. Με την ενημέρωση των εννέα, το μοντέλο αναγνωρίζει καλύτερα την όρθια στάση αλλά χειρότερα την καθιστή. Η απώλεια είναι μεγαλύτερη από το κέρδος.


**Αυτό κλείνει έναν κύκλο που άνοιξε στο Κεφάλαιο 3.** Οι δημιουργοί του συνόλου δεδομένων κατέγραψαν το 2013 τη σύγχυση SITTING και STANDING και την απέδωσαν στη φυσική θέση της συσκευής, προτείνοντας ως μελλοντική εργασία την αξιοποίηση χαρακτηριστικών του γυροσκοπίου [1]. Η Ενότητα 4.7 επιβεβαίωσε ότι το ίδιο ζεύγος παράγει το 49,1% των σφαλμάτων του μοντέλου. Επιπλέον, η ανάλυση Shapley δείχνει ότι εκεί ακριβώς διαφωνούν περισσότερο οι συμμετέχοντες. Δύο αναλύσεις της εργασίας, με διαφορετική μεθοδολογία, συγκλίνουν, λοιπόν, στο ίδιο σύνολο με τους δημιουργούς του συνόλου. Η δυσκολία ήταν ήδη γνωστή και η συνεισφορά της εργασίας αυτής δεν είναι η ανακάλυψή της αλλά η απάντηση στο *ποιος* την επιδεινώνει.

Οι δύο εκτιμητές συμφωνούν και σε αυτή τη μήτρα, με συντελεστή Pearson 1,0000 πάνω στα 126 κελιά και μέγιστη απόλυτη διαφορά 0,060.

### 5.7.3 Η αρνητική τιμή ανά άτομο της αξιολόγησης

Η ίδια ανάλυση επαναλαμβάνεται με διαφορετική αποσύνθεση. Αντί να χωριστεί η ορθότητα κατά δραστηριότητα, χωρίζεται κατά *άτομο* του συνόλου ελέγχου. Η συνάρτηση αξίας επιστρέφει τότε εννέα αριθμούς, την ορθότητα του μοντέλου του συνασπισμού πάνω στα samples καθενός από τους εννέα ανθρώπους της αξιολόγησης χωριστά. Το παίγνιο επιλύεται χωριστά για κάθε συνιστώσα. Το αποτέλεσμα είναι μήτρα  $21 \times 9$  (Σχήμα 5.11). Η μεθοδολογία είναι ταυτόσημη με εκείνη της προηγούμενης υποενότητας, όπως και η ταυτότητα που συνδέει τα μέρη με το σύνολο. Το  $\varphi$  της συνολικής ορθότητας ισούται με τον σταθμισμένο κατά πλήθος samples μέσο όρο των  $\varphi$  ανά άτομο, με απόκλιση της τάξης του  $10^{-16}$ . Σε κάθε γύρο ελέγχεται, επίσης, ότι ο ίδιος σταθμισμένος μέσος των εννέα τιμών της συνάρτησης αξίας δίνει την ορθότητα του πλήρους συνασπισμού, με ανοχή  $10^{-12}$ . Τα εννέα άτομα σημειώνονται  $S2$  έως  $S24$ , κατά το αναγνωριστικό τους στην πηγή.

Τρία πορίσματα προκύπτουν. Το καθένα περιορίζει μια πιθανή παρανόηση του προηγούμενου ευρήματος. Το Σχήμα 5.11 τα παρουσιάζει και τα τρία.



**Σχήμα 5.11.** Η μήτρα  $21 \times 9$  με τη συνεισφορά κάθε συμμετέχοντα προς κάθε άτομο του συνόλου ελέγχου, εκτιμητής KernelSHAP, μέσοι όροι 20 seeds. Οι συμμετέχοντες είναι ταξινομημένοι κατά φθίνον συνολικό  $\varphi$ , όπως στο Σχήμα 5.3. Η οριζόντια γραμμή χωρίζει τους 12 θετικούς από τους 9 αρνητικούς. Πράσινο σημαίνει θετική και κόκκινο αρνητική συνεισφορά, όπως στα Σχήματα 5.3 και 5.10. Καμία γραμμή κάτω από τη γραμμή διαχωρισμού δεν είναι ολόκληρη κόκκινη.

**Κανείς δε βλάπτει τους πάντες.** Κανένας από τους εννέα συμμετέχοντες με αρνητική συνολική τιμή δεν είναι αρνητικός και για τα εννέα άτομα της αξιολόγησης. Ο συμμετέχων 2, ο χειρότερος της συνολικής κατάταξης, είναι αρνητικός για επτά από τα εννέα άτομα και βοηθά δύο, με +1,146 για ένα από αυτά. Η αρνητική τιμή δεν είναι ιδιότητα του συμμετέχοντα απέναντι στον κόσμο αλλά απέναντι σε συγκεκριμένους ανθρώπους.

**Η βλάβη είναι στοχευμένη.** Ένα μόνο άτομο, το S20, απορροφά το 27,3% της αρνητικής συνεισφοράς των εννέα συμμετεχόντων, μετρημένης στην ορθότητα όλου του συνόλου ελέγχου, ενώ συνεισφέρει μόλις το 12,0% των samples. Δεν πρόκειται για υποβάθμιση μοιρασμένη ομοιόμορφα σε όλους αλλά για συγκεκριμένη αναντιστοιχία ανάμεσα σε συγκεκριμένους ανθρώπους.

**Τα άτομα δεν είναι εναλλάξιμα.** Η τυπική απόκλιση των 21 τιμών  $\varphi$  διαφέρει κατά παράγοντα 3,2 ανάμεσα στα άτομα της αξιολόγησης, από 0,870 για το πιο «απαιτητικό» έως 0,275 για το πιο ουδέτερο. Απέναντι σε κάποια άτομα, οι συμμετέχοντες ξεχωρίζουν έντονα μεταξύ τους, ενώ απέναντι σε άλλα σχεδόν καθόλου.

**Οι μονάδες της μήτρας.** Οι τιμές αυτής της μήτρας είναι μέσοι όροι 20 seeds. Σε κάθε seed, είναι αθροίσματα 51 έως 74 γύρων (65 κατά μέσο όρο) σε μονάδες ορθότητας του κάθε ατόμου, με αντισταθμίσεις θετικών και αρνητικών γύρων. Γι' αυτό μπορούν να ξεπερνούν τη μονάδα. Δε διαβάζονται ως ποσοστιαίες μονάδες που έχασε ή κέρδισε ένα άτομο στο τελικό μοντέλο.


Αφού το ποιος βγαίνει αρνητικός εξαρτάται και από το ποια άτομα βρίσκονται στο σύνολο ελέγχου, ένας έλεγχος που αποφασίζει και μετρά στους ίδιους ανθρώπους δεν μπορεί να κρίνει τι θα γινόταν με άλλους. Γι' αυτό ο έλεγχος της επόμενης υποενότητας κρατά ανθρώπους έξω από την απόφαση.

#### 5.7.4 Το πείραμα αφαίρεσης

Αν οι εννέα συμμετέχοντες με αρνητική τιμή βλάπτουν πράγματι το κοινό μοντέλο, η φυσική αντίδραση είναι να αφαιρεθούν από την ομοσπονδία. Η υποενότητα ελέγχει αν αυτό θα βελτιώνει το μοντέλο. Από την απάντηση εξαρτάται και τι γίνεται με αυτούς στη συνέχεια. Αν η αφαίρεση βοηθά, το πρόσημο του  $\varphi$  μπορεί να χρησιμοποιηθεί ως κριτήριο αποκλεισμού. Αν δε βοηθά, οι εννέα μένουν. Τότε το ερώτημα γίνεται πώς αποτιμάται σωστά και η δική τους συνεισφορά.

Ο προφανής έλεγχος είναι να αφαιρεθούν οι εννέα, να ξαναεκπαιδευτεί η ομοσπονδία με τους υπόλοιπους δώδεκα και να μετρηθεί η ορθότητα στο σύνολο ελέγχου. Το αποτέλεσμα του, όμως, είναι σε μεγάλο βαθμό αναμενόμενο. Οι εννέα χαρακτηρίστηκαν αρνητικοί ακριβώς επειδή οι ενημερώσεις τους υπονόμευαν την ορθότητα στα εννέα άτομα του συνόλου ελέγχου, οπότε η αφαίρεσή τους αναμένεται να τη βελτιώσει στα ίδια άτομα. Ο έλεγχος θα έκρινε την απόφαση με τα ίδια δεδομένα με τα οποία πάρθηκε, δηλαδή θα ήταν *κυκλικός*. Δε θα έλεγε τίποτα για το αν η αφαίρεση βοηθά έναν νέο άνθρωπο, το οποίο είναι και το ζητούμενο στην πράξη. Το ζήτημα εμφανίζεται και στη βιβλιογραφία της αποτίμησης δεδομένων. Πρόσφατη μελέτη αξιολογεί την επιλογή δεδομένων στο ίδιο σύνολο επικύρωσης με το οποίο υπολογίστηκαν οι τιμές, δηλώνοντας ότι το κάνει για να ευθυγραμμιστεί με τη θεωρητική της ανάλυση [26]. Επιπλέον, η αξία του Data Shapley ορίζεται μέσα από μια συνάρτηση που περιλαμβάνει τη μετρική αξιολόγησης [23], οπότε ορίζεται *ως προς* το σύνολο πάνω στο οποίο μετρήθηκε.

Για να αποφευχθεί η κυκλικότητα, το σύνολο ελέγχου μοιράζεται σε δύο ρόλους (Σχήμα 5.12). Τα εννέα άτομα χωρίζονται σε τρεις τριάδες. Για κάθε τριάδα, η αποτίμηση επαναλαμβάνεται από την αρχή με *μόνο* τα έξι υπόλοιπα άτομα και προκύπτει ένα νέο σύνολο αρνητικών συμμετεχόντων. Αυτοί αφαιρούνται, η ομοσπονδία ξαναεκπαιδεύεται και η ορθότητα μετριέται χωριστά στα έξι άτομα της απόφασης και στα τρία της τριάδας. Τα τρία δεν πήραν μέρος σε καμία απόφαση, οπότε παίζουν τον ρόλο νέων ανθρώπων. Η διαδικασία γίνεται για τις τρεις τριάδες και για 20 seeds.



**Σχήμα 5.12.** Τα εννέα άτομα του συνόλου ελέγχου, σε τρεις διαφορετικούς χωρισμούς. Σε κάθε τριάδα, η αποτίμηση γίνεται από την αρχή με τα έξι άτομα με συνεχές περίγραμμα. Η επίπτωση της αφαίρεσης μετριέται στα τρία με διακεκομμένο πορτοκαλί περίγραμμα, τα οποία δε συμμετείχαν σε καμία απόφαση.


Γίνονται δύο είδη αφαίρεσης σε κάθε τριάδα, με μέτρηση στα τρία άτομα που έμειναν έξω. Το πρώτο αφαιρεί μαζί όλους τους αρνητικούς της τριάδας και ελέγχει αν το μοντέλο βελτιώνεται. Το δεύτερο ελέγχει αν η *σειρά* της κατάταξης δείχνει ποιους θα έπρεπε να αφαιρέσει κανείς πρώτους. Αφαιρεί τους  $m$  χειρότερους ή τους  $m$  καλύτερους της κατάταξης που προέκυψε από τα έξι άτομα, για  $m = 3, 6, 9$  και  $12$ . Στη συνέχεια συγκρίνει τα δύο.

Δύο στοιχεία του σχεδιασμού προστατεύουν τη μέτρηση. Κάθε αφαίρεση των αρνητικών συγκρίνεται με *τυχαία* αφαίρεση ίδιου πλήθους συμμετεχόντων, ώστε να φανεί αν έχει σημασία *ποιοι* αφαιρούνται ή μόνο *πόσα* δεδομένα χάνονται. Επιπλέον, η εκτέλεση χωρίς καμία αφαίρεση αναπαράγει το αποθηκευμένο ομοσπονδιακό αποτέλεσμα σε 20 από τα 20 seeds, οπότε οι διαφορές που μετρώνται δεν οφείλονται σε αλλαγή του κώδικα.

Με έξι μόνο άτομα, βρίσκονται σχεδόν οι ίδιοι αρνητικοί συμμετέχοντες. Ο δείκτης Jaccard (το πλήθος των κοινών μελών δύο συνόλων προς το πλήθος της ένωσής τους) ανάμεσα στο σύνολο που προκύπτει από τα έξι άτομα και σε εκείνο των εννέα είναι 0,89, 1,00 και 0,89 για τις τρεις τριάδες. Επομένως, η ταυτοποίηση δεν αλλάζει ουσιαστικά και το μόνο ανοιχτό ερώτημα είναι αν η αφαίρεση βοηθά.

### 5.7.5 Αποτελέσματα της αφαίρεσης

Ο Πίνακας 5.8 και το Σχήμα 5.13 δίνουν τη μεταβολή της ορθότητας του τελικού μοντέλου, όταν αφαιρούνται οι αρνητικοί, χωριστά στα έξι άτομα της απόφασης και στα τρία νέα. Οι τιμές είναι ποσοστιαίες μονάδες, όπως στο Κεφάλαιο 4.



**Σχήμα 5.13.** Η επίδραση της αφαίρεσης, μέσος όρος 20 seeds, με τυπική απόκλιση μεταξύ seeds. Οι ανοιχτές γαλάζιες στήλες μετρούν στα έξι άτομα με τα οποία έγινε η αποτίμηση και είναι θετικές και στις τρεις τριάδες. Οι έγχρωμες μετρούν στα τρία άτομα που κρατήθηκαν έξω από κάθε απόφαση και αλλάζουν πρόσημο, πράσινες όπου η αφαίρεση βοηθά και κόκκινες όπου βλάπτει. Στην άκρη κάθε στήλης, το πλήθος των seeds με θετικό πρόσημο.

Στα έξι άτομα της απόφασης, η αφαίρεση βοηθά και στις τρεις τριάδες, όπως αναμενόταν. Στα τρία νέα άτομα, βοηθά μόνο στην τριάδα 0, κατά 1,26 μονάδες. Στις άλλες δύο βλάπτει, κατά 0,88 και 0,17 μονάδες. Στην τριάδα 1, βλάπτει σε *όλα* τα 20 seeds. Ως εκ τούτου, το

| Τριάδα | Στα 6 άτομα της αποτίμησης | Στα 3 άτομα εκτός απόφασης |
|--------|----------------------------|----------------------------|
| 0      | +0,37 (15/20)              | + <b>1,26</b> (20/20)      |
| 1      | +0,54 (19/20)              | − <b>0,88</b> (0/20)       |
| 2      | +0,57 (20/20)              | − <b>0,17</b> (3/20)       |


**Πίνακας 5.8.** Μεταβολή ορθότητας σε μονάδες, μέσος όρος 20 seeds. Σε παρένθεση το πλήθος των seeds με θετικό πρόσημο.

όφελος που φαίνεται στους ανθρώπους της απόφασης δε μεταφέρεται με συνέπεια σε νέους ανθρώπους.

Αυτό δε σημαίνει ότι η κατάταξη δεν περιέχει καμία πληροφορία. Στα τρία νέα άτομα, η αφαίρεση των αρνητικών είναι καλύτερη από την τυχαία αφαίρεση ίδιου πλήθους και στις τρεις τριάδες, κατά 2,58, 0,62 και 0,63 μονάδες. Η διαφορά, όμως, είναι ασθενής, αφού το πρόσημό της διατηρείται μόνο σε 13 έως 16 από τα 20 seeds, με τυπική απόκλιση 1,2 έως 2,2 μονάδες.

Η σειρά της κατάταξης δίνει μικτή εικόνα. Αυτό μετρά το δεύτερο είδος αφαίρεσης (Σχήμα 5.14). Αν η κατάταξη ήταν αξιόπιστο κριτήριο, η αφαίρεση των  $m$  χειρότερων θα βοηθούσε τα τρία νέα άτομα περισσότερο από την αφαίρεση των  $m$  καλύτερων, σε κάθε τριάδα και για κάθε  $m$ . Αυτό ισχύει μόνο στην τριάδα 2. Στις άλλες δύο, η αφαίρεση των τριών καλύτερων δίνει καλύτερη ορθότητα από την αφαίρεση των τριών χειρότερων. Για  $m = 6$  και  $m = 9$ , αντίθετα, η αφαίρεση των χειρότερων είναι η καλύτερη από τις δύο σε πέντε από τις έξι περιπτώσεις. Οι καμπύλες της αφαίρεσης των χειρότερων μένουν κοντά στην ορθότητα χωρίς αφαίρεση μέχρι το  $m = 9$  και πέφτουν στο  $m = 12$ , ενώ η αφαίρεση των καλύτερων κοστίζει νωρίτερα στις τριάδες 1 και 2. Η κατάταξη, δηλαδή, ξεχωρίζει ποιοι στηρίζουν το μοντέλο, χωρίς να δείχνει με συνέπεια ποιους συμφέρει να αφαιρέσει κανείς.

Δύο ακόμη παρατηρήσεις εξηγούν γιατί η εικόνα διαφέρει τόσο από τις τιμές  $\varphi$ . Πρώτον, η ομοσπονδία αντέχει την απώλεια πολλών συμμετεχόντων. Η αφαίρεση οκτώ έως εννέα από τους 21, που κρατούν το 36% έως 42% των samples εκπαίδευσης, κοστίζει το πολύ 0,88 μονάδες στα νέα άτομα. Δεύτερον, το άτομο  $S20$ , που απορροφούσε το 27,3% της αρνητικής συνεισφοράς των εννέα συμμετεχόντων ανά γύρο (Ενότητα 5.7.3), ανήκει στα τρία νέα άτομα της τριάδας 1, ακριβώς εκείνης όπου η αφαίρεση βλάπτει σε 20 από τα 20 seeds. Επομένως, η βλάβη που αθροίζεται γύρο με γύρο στο  $\varphi$  δε μεταφράζεται απαραίτητα σε βλάβη στο τελικό μοντέλο.



**Σχήμα 5.14.** Ορθότητα στα τρία άτομα που κρατήθηκαν έξω από την απόφαση, όταν αφαιρούνται οι  $m$  χειρότεροι ή οι  $m$  καλύτεροι συμμετέχοντες. Η διακεκομμένη γραμμή είναι η ορθότητα χωρίς καμία αφαίρεση. Όπου η πράσινη καμπύλη βρίσκεται πάνω από την κόκκινη, η αφαίρεση των καλύτερων ωφέλησε περισσότερο από την αφαίρεση των χειρότερων.

### 5.7.6 Συμπέρασμα

Στην περίπτωση της παρούσας εργασίας, **η αφαίρεση των συμμετεχόντων με αρνητική τιμή δεν έχει νόημα**. Οι αρνητικοί ταυτοποιούνται σταθερά, αφού βρίσκονται οι ίδιοι άνθρωποι με διαφορετικά υποσύνολα αξιολόγησης και σε 20 seeds. Η αφαίρεσή τους, όμως, βελτιώνει το μοντέλο μόνο για τους ανθρώπους με τους οποίους έγινε η αποτίμηση, ενώ για νέους ανθρώπους το χειροτερεύει σε δύο από τις τρεις τριάδες.

Το πόρισμα συμφωνεί με όσα ανέδειξαν το δεύτερο παίγνιο και η αποσύνθεση. Το παίγνιο επανεκπαίδευσης (Ενότητα 5.6) δε βρήκε ένδειξη ότι τα δεδομένα κάποιου συμμετέχοντα βλάπτουν. Η αποσύνθεση κατέδειξε ότι η αρνητική τιμή της ομάδας εμφανίζεται μόνο αφού το μοντέλο ξεπεράσει το 90%, σε συγκεκριμένα ζεύγη δραστηριοτήτων και απέναντι σε συγκεκριμένα άτομα της αξιολόγησης. Αρνητικό  $\varphi$ , επομένως, δε σημαίνει «κακά δεδομένα». Σημαίνει ότι η ενημέρωση αυτού του ανθρώπου δεν ταιριάζει με το συγκεκριμένο σύνολο ελέγχου, σε αυτή τη φάση της εκπαίδευσης. Η βιβλιογραφία της αποτίμησης δεδομένων καταλήγει σε συγγενές συμπέρασμα, αφού δείχνει ότι, χωρίς πρόσθετες συνθήκες στη συνάρτηση αξίας, το Data Shapley δεν εγγυάται επιλογή καλύτερη από την τυχαία. Καταγράφει, επίσης, ότι τα εμπειρικά ευρήματα του πεδίου είναι αντιφατικά [26]. Η μέτρηση της εργασίας δείχνει, επιπλέον, γιατί η επιλογή φαίνεται να πετυχαίνει, όταν ελέγχεται στο ίδιο σύνολο με την αποτίμηση.

Επομένως, οι εννέα συμμετέχοντες μένουν στην ομοσπονδία. Το ερώτημα που τίθεται δεν είναι ποιος πρέπει να αποκλειστεί αλλά πώς μεταφράζεται η μετρημένη συνεισφορά όλων,

ακόμη και των εννέα, σε μερίδια που σέβονται τη σειρά που μετρήθηκε, χωρίς να τιμωρούν το πρόσημο. Αυτό εξετάζει η επόμενη ενότητα.

## 5.8 Μερίδια Ανταμοιβής

### 5.8.1 Πολιτικές μεριδίων

Αφού οι εννέα συμμετέχοντες με αρνητική τιμή μένουν στην ομοσπονδία (Ενότητα 5.7.6), η συνεισφορά όλων πρέπει να μεταφραστεί σε μερίδια, για παράδειγμα μιας ανταμοιβής. Οι αρνητικές τιμές δημιουργούν εδώ άμεσο πρόβλημα, γιατί ένα αρνητικό μερίδιο δεν έχει νόημα. Εξετάστηκαν τέσσερις πολιτικές μετατροπής του  $\varphi$  σε μερίδια που αθροίζουν στη μονάδα (Πίνακας 5.9). Το σύνολο των τεσσάρων είναι κατασκευή της εργασίας. Δύο από αυτές, η αφινική μετατόπιση και η εκθετική κατανομή, έχουν βιβλιογραφική στήριξη και προτείνονται, ενώ οι άλλες δύο δηλώνονται ως βάσεις σύγκρισης.

Η «δικαιοσύνη» δεν ορίζεται εδώ, οπότε το κριτήριο επιλογής δεν είναι αυτή αλλά δύο μετρήσιμα μεγέθη. Το πρώτο είναι *πόση πληροφορία κατάταξης διατηρεί η πολιτική*. Μετριέται με το Kendall  $\tau$  μεταξύ του  $\varphi$  και των τελικών μεριδίων. Τιμή 1,000 σημαίνει ότι η πολιτική δεν αντέστρεψε ούτε εξίσωσε κανένα ζεύγος. Το δεύτερο είναι *πόσοι συμμετέχοντες μένουν χωρίς θετικό μερίδιο*, αφού το πόρισμα της Ενότητας 5.7.6 είναι ότι όλοι παραμένουν στην ομοσπονδία.

| Πολιτική                         | Ρόλος          | Χωρίς μερίδιο | Μερίδιο των 9 αρνητικών | $\tau$ |
|----------------------------------|----------------|---------------|-------------------------|--------|
| raw ( $\varphi / \sum \varphi$ ) | βάση σύγκρισης | 9             | −258,98%                | 1,000  |
| zero_clip                        | βάση σύγκρισης | 9             | 0,00%                   | 0,829  |
| affine [28]                      | <b>πρόταση</b> | 1             | 26,54%                  | 1,000  |
| exponential [41]                 | <b>πρόταση</b> | 0             | 27,51%                  | 1,000  |

**Πίνακας 5.9.** Τέσσερις πολιτικές μετατροπής της συνεισφοράς σε μερίδια. Η στήλη «Χωρίς μερίδιο» μετρά πόσοι από τους 21 παίρνουν μηδενικό ή αρνητικό μερίδιο. Το  $\tau$  δείχνει πόση πληροφορία κατάταξης διατηρείται. Η εκθετική με  $\beta = 1$ .

Η raw δείχνει γιατί χρειάζεται οποιαδήποτε παρέμβαση, αφού τα μερίδια των εννέα αρνητικών αθροίζουν σε −259%, αριθμός χωρίς ερμηνεία. Η zero\_clip, δηλαδή ο απλός μηδενισμός των αρνητικών, είναι η πιο προφανής λύση αλλά και η χειρότερη. Το  $\tau$  πέφτει στο 0,829, γιατί και οι εννέα αρνητικοί γίνονται *αδιάκριτοι* μεταξύ τους, οπότε τα 36 ζεύγη τους δε μετρούν ούτε ως σύμφωνα ούτε ως ασύμφωνα. Ο συμμετέχων 2, με  $\varphi = -0,664$  και σταθερό πρόσημο σε 94,2% των γύρων, εξισώνεται με τον συμμετέχοντα 13, του οποίου η


τιμή  $-0,0025$  βρίσκεται μέσα στον θόρυβο. Η πολιτική απορρίπτει ακριβώς την πληροφορία που το κεφάλαιο μέτρησε με τόσο κόστος.

### 5.8.2 Αφινική μετατόπιση και εκθετική κατανομή

Η πρώτη προτεινόμενη πολιτική είναι η αφινική μετατόπιση (*affine*), δανεισμένη από το ShapFed [28]. Η ιδέα είναι να μετατοπιστεί ολόκληρο το φάσμα των τιμών σε μη αρνητικό διάστημα, πριν από την κανονικοποίηση, αντί να αποκοπεί:

$$\gamma_i = \frac{1 + \tilde{\varphi}_i}{2}, \quad \bar{\gamma}_i = \frac{\gamma_i}{\sum_k \gamma_k}, \quad (5.5)$$

όπου  $\tilde{\varphi}_i$  η κλιμακωμένη στο  $[-1, 1]$  τιμή. Ο μετασχηματισμός  $(1 + x)/2$  στέλνει το  $[-1, 1]$  στο  $[0, 1]$ , διατηρώντας τη διάταξη, αφού είναι γνησίως αύξων. Η διαίρεση με το άθροισμα εξασφαλίζει  $\sum_i \bar{\gamma}_i = 1$ . Το αποτέλεσμα φαίνεται στο Σχήμα 5.15.



**Σχήμα 5.15.** Τα μερίδια κάθε συμμετέχοντα υπό τις τέσσερις πολιτικές, με τη σειρά του Σχήματος 5.3. Πάνω οι δύο βάσεις σύγκρισης και κάτω οι δύο προτεινόμενες πολιτικές, η καθεμία στη δική της κλίμακα, με τη διακεκομμένη γραμμή της ισοκατανομής. Η *raw* παράγει αρνητικά μερίδια, η *zero\_clip* μηδενίζει εννέα συμμετέχοντες, η αφινική [28] μόνο τον πιο ακραίο και η εκθετική [41] δίνει θετικό μερίδιο σε όλους.

**Κλιμάκωση του  $\varphi$  πριν από τη μετατόπιση.** Στην πρωτότυπη διατύπωση, το μέγεθος που μετατοπίζεται είναι συνημίτονο, φραγμένο εξ ορισμού στο  $[-1, 1]$ . Εδώ, το  $\varphi$  είναι διαφορά ορθότητας με εύρος από  $-0,664$  έως  $+0,404$ , οπότε απαιτείται κλιμάκωση πρώτα. Εδώ χρησιμοποιείται η  $\tilde{\varphi}_i = \varphi_i / \max_k |\varphi_k|$ . Δοκιμάστηκε και η γραμμική απεικόνιση του εύρους  $[\min_k \varphi_k, \max_k \varphi_k]$  στο  $[-1, 1]$ . Οι δύο δίνουν *ταυτόσημα* μερίδια στα δεδομένα της εργασίας. Αυτό δεν είναι σύμπτωση αλλά ταυτότητα, γιατί, μετά την κανονικοποίηση  $\sum \bar{\gamma} = 1$ , μόνο το σημείο μηδενισμού της κλίμακας επηρεάζει το αποτέλεσμα. Οι δύο κλιμακώσεις συμπίπτουν, όταν ο πιο ακραίος συμμετέχων είναι αρνητικός, όπως στην προκειμένη περίπτωση.

Η αφινική πολιτική δίνει στους εννέα αρνητικούς συνολικό μερίδιο 26,54%, δηλαδή λιγότερο από το  $9/21 = 42,9\%$  που θα τους αναλογούσε με ισοκατανομή αλλά όχι μηδέν. Διατηρεί  $\tau = 1,000$ , δηλαδή καμία σχετική θέση δεν αλλάζει. Έχει, όμως, μία παρενέργεια. Η κλιμάκωση στέλνει την πιο ακραία τιμή στο  $-1$  και η μετατόπιση  $(1+x)/2$  στέλνει το  $-1$  στο μηδέν. Όταν ο πιο ακραίος συμμετέχων είναι αρνητικός, όπως ο συμμετέχων 2 εδώ, μένει χωρίς μερίδιο, όχι επειδή το αποφάσισε η πολιτική αλλά λόγω της κλιμάκωσης.

**Εκθετική κατανομή.** Η δεύτερη προτεινόμενη πολιτική (*exponential*) δίνει σε κάθε συμμετέχοντα μερίδιο ανάλογο του εκθετικού της κλιμακωμένης συνεισφοράς του:

$$\bar{\gamma}_i = \frac{e^{\beta \tilde{\varphi}_i}}{\sum_k e^{\beta \tilde{\varphi}_k}}, \quad (5.6)$$

όπου  $\tilde{\varphi}_i$  η ίδια κλιμακωμένη τιμή με την αφινική και  $\beta \geq 0$  μια παράμετρος που ορίζει πόσο έντονα ανταμείβεται η υψηλότερη συνεισφορά. Η μορφή δεν είναι αυθαίρετη. Όταν για μια κατανομή είναι γνωστές μόνο κάποιες μέσες τιμές, η κατανομή μέγιστης εντροπίας έχει ακριβώς εκθετική μορφή. Ο Jaynes τη χαρακτηρίζει ως τη μόνη αμερόληπτη επιλογή, αφού οποιαδήποτε άλλη θα προϋπέθετε πληροφορία που δεν υπάρχει [41]. Σημειώνει, επίσης, ότι η κατανομή αυτή δίνει θετικό βάρος σε κάθε περίπτωση που δεν αποκλείεται ρητά από τη διαθέσιμη πληροφορία. Αυτό σημαίνει ότι κανείς δε μένει χωρίς μερίδιο, αφού η εκθετική συνάρτηση είναι πάντα θετική.

Το  $\beta$  έχει άμεση ανάγνωση. Με  $\beta = 1$ , ο λόγος των μεριδίων στα δύο άκρα της κλίμακας,  $\tilde{\varphi} = -1$  και  $\tilde{\varphi} = +1$ , είναι  $e^2 \approx 7,39$ . Στα δεδομένα της εργασίας, ο καλύτερος συμμετέχων παίρνει 5,0 φορές το μερίδιο του χειρότερου, ενώ οι εννέα αρνητικοί παίρνουν συνολικά 27,51%. Το  $\tau$  μένει 1,000. Το  $\beta$  αλλάζει μόνο την ένταση της ανταμοιβής και ποτέ τη σειρά. Με  $\beta = 0,5$ , οι εννέα αρνητικοί παίρνουν 34,67% και με  $\beta = 2$  παίρνουν 16,55%, με  $\tau = 1,000$  σε κάθε περίπτωση. Στο όριο  $\beta \rightarrow 0$ , η κατανομή γίνεται ισοκατανομή, ενώ για πολύ μεγάλο  $\beta$  ο καλύτερος παίρνει σχεδόν τα πάντα.

**Η ποινή με βάση το πρόσημο απορρίπτεται.** Οι δύο προτεινόμενες πολιτικές θα μπορούσαν να διαβαστούν ως απλή προτίμηση, με το σκεπτικό ότι είναι άβολο να δίνεται μηδενικό μερίδιο σε ανθρώπους που συμμετείχαν. Ο λόγος, όμως, είναι μετρημένος. Μια πολιτική που μηδενίζει ή τιμωρεί με κριτήριο το *πρόσημο* του  $\varphi$  υποθέτει ότι το αρνητικό πρόσημο δείχνει συνεισφορά που βλάπτει. Η Ενότητα 5.7.4 κατέδειξε ότι αυτό δεν ισχύει για νέους ανθρώπους, αφού σε δύο από τις τρεις τριάδες η αφαίρεση των αρνητικών *χειροτέρωσε* το μοντέλο για τα άτομα που δε συμμετείχαν στην αποτίμηση. Επομένως, μια ποινή με βάση το πρόσημο θα τιμωρούσε, δύο φορές στις τρεις, συνεισφορά που ωφελεί άτομα του συνόλου ελέγχου τα οποία έμειναν έξω από την αποτίμηση. Καμία από τις δύο προτεινόμενες πολιτικές δε χρησιμοποιεί το πρόσημο ως όριο. Αντιθέτως, και οι δύο κρατούν ολόκληρη τη σειρά που μετρήθηκε.

**Σύγκριση των δύο.** Η αφινική και η εκθετική διατηρούν τη σειρά του  $\varphi$  και δίνουν στους εννέα αρνητικούς σχεδόν το ίδιο συνολικό μερίδιο, 26,54% και 27,51%. Διαφέρουν σε δύο σημεία. Η αφινική είναι γραμμική, άρα διατηρεί τις σχετικές αποστάσεις των τιμών. Επιπλέον, δεν έχει ελεύθερη παράμετρο. Αφήνει, όμως, χωρίς μερίδιο τον πιο ακραίο αρνητικό. Η εκθετική δίνει θετικό μερίδιο σε όλους για κάθε  $\beta$ , με τίμημα μια παράμετρο που πρέπει να δηλωθεί. Αφού το πόρισμα της Ενότητας 5.7.6 είναι ότι και οι εννέα μένουν στην ομοσπονδία, η εκθετική είναι αυτή που το εφαρμόζει πλήρως.

### 5.8.3 Συνεισφορά και μερίδιο κάθε συμμετέχοντα

Ο Πίνακας 5.10 συγκεντρώνει το τελικό αποτέλεσμα της αποτίμησης. Για κάθε συμμετέχοντα, δίνει τη συνεισφορά του  $\varphi$  και το μερίδιο που του αναλογεί με τις δύο προτεινόμενες πολιτικές, με τη σειρά του Σχήματος 5.3. Κάθε μερίδιο δίνεται ως κλάσμα από 0 έως 1 και ως ποσοστό του συνόλου. Το κλάσμα είναι το  $\bar{\gamma}_i$  των Εξισώσεων (5.5) και (5.6). Οι βάσεις σύγκρισης *raw* και *zero\_clip* δεν επαναλαμβάνονται, αφού ο ρόλος τους εξαντλείται στον Πίνακα 5.9 και στο Σχήμα 5.15.

Με τις δύο προτεινόμενες πολιτικές, τα μερίδια ακολουθούν ακριβώς τη σειρά του  $\varphi$ . Με την αφινική, οι δώδεκα θετικοί παίρνουν από 4,79% έως 7,24% και οι εννέα αρνητικοί από 0% έως 4,49%. Το μηδέν αντιστοιχεί μόνο στον συμμετέχοντα 2. Με την εκθετική, οι θετικοί ανταμείβονται με 4,42% έως 7,63% και οι αρνητικοί με 1,53% έως 4,14%, οπότε μερίδιο παίρνει και ο συμμετέχων 2.

| Συμμετέχων     | Εθελοντής | Samples | Συνεισφορά |       | affine |        | exponential |        |
|----------------|-----------|---------|------------|-------|--------|--------|-------------|--------|
|                |           |         | $\varphi$  | τ.α.  | [0, 1] | %      | [0, 1]      | %      |
| 14             | 23        | 372     | 0,404      | 0,036 | 0,0724 | 7,24   | 0,0763      | 7,63   |
| 1              | 3         | 341     | 0,384      | 0,031 | 0,0711 | 7,11   | 0,0740      | 7,40   |
| 12             | 21        | 408     | 0,371      | 0,039 | 0,0702 | 7,02   | 0,0727      | 7,27   |
| 10             | 17        | 368     | 0,363      | 0,045 | 0,0697 | 6,97   | 0,0718      | 7,18   |
| 18             | 28        | 382     | 0,299      | 0,039 | 0,0653 | 6,53   | 0,0652      | 6,52   |
| 4              | 7         | 308     | 0,230      | 0,023 | 0,0607 | 6,07   | 0,0587      | 5,87   |
| 20             | 30        | 383     | 0,198      | 0,029 | 0,0585 | 5,85   | 0,0559      | 5,59   |
| 17             | 27        | 376     | 0,173      | 0,033 | 0,0568 | 5,68   | 0,0539      | 5,39   |
| 8              | 15        | 328     | 0,143      | 0,039 | 0,0547 | 5,47   | 0,0515      | 5,15   |
| 9              | 16        | 366     | 0,138      | 0,036 | 0,0544 | 5,44   | 0,0511      | 5,11   |
| 0              | 1         | 347     | 0,117      | 0,029 | 0,0530 | 5,30   | 0,0495      | 4,95   |
| 6              | 11        | 316     | 0,041      | 0,026 | 0,0479 | 4,79   | 0,0442      | 4,42   |
| 13             | 22        | 321     | -0,003     | 0,049 | 0,0449 | 4,49   | 0,0414      | 4,14   |
| 3              | 6         | 325     | -0,075     | 0,050 | 0,0400 | 4,00   | 0,0371      | 3,71   |
| 16             | 26        | 392     | -0,087     | 0,037 | 0,0392 | 3,92   | 0,0365      | 3,65   |
| 19             | 29        | 344     | -0,089     | 0,032 | 0,0390 | 3,90   | 0,0363      | 3,63   |
| 15             | 25        | 409     | -0,203     | 0,039 | 0,0313 | 3,13   | 0,0306      | 3,06   |
| 5              | 8         | 281     | -0,242     | 0,037 | 0,0286 | 2,86   | 0,0288      | 2,88   |
| 7              | 14        | 323     | -0,303     | 0,053 | 0,0245 | 2,45   | 0,0263      | 2,63   |
| 11             | 19        | 360     | -0,399     | 0,060 | 0,0180 | 1,80   | 0,0228      | 2,28   |
| 2              | 5         | 302     | -0,664     | 0,078 | 0,0000 | 0,00   | 0,0153      | 1,53   |
| Οι 9 αρνητικοί |           |         | -2,065     |       | 0,2654 | 26,54  | 0,2751      | 27,51  |
| Σύνολο         |           |         | 0,797      |       | 1,0000 | 100,00 | 1,0000      | 100,00 |

**Πίνακας 5.10.** Η συνεισφορά  $\varphi$  κάθε συμμετέχοντα (KernelSHAP, μέσος όρος και τυπική απόκλιση 20 seeds, σε μονάδες ορθότητας) και το μερίδιό του υπό τις δύο προτεινόμενες πολιτικές της Ενότητας 5.8.2, ως κλάσμα στο  $[0, 1]$  και ως ποσοστό. Οι βάσεις σύγκρισης δίνονται στον Πίνακα 5.9 και στο Σχήμα 5.15. Οι γραμμές είναι ταξινομημένες κατά φθίνον  $\varphi$  και η οριζόντια γραμμή χωρίζει τους 12 θετικούς από τους 9 αρνητικούς. Η στήλη *Εθελοντής* είναι ο αριθμός του ατόμου στην πηγή των δεδομένων.

## Κεφάλαιο 6

# Συμπεράσματα και Μελλοντική Εργασία

### 6.1 Απαντήσεις στα Ερευνητικά Ερωτήματα

Η εργασία έθεσε τρία ερωτήματα στην Ενότητα 1.3. Απαντώνται εδώ ένα προς ένα.

**Πρώτο ερώτημα, το κόστος της ομοσπονδιακής εκπαίδευσης.** Κοστίζει 0,83 ποσοστιαίες μονάδες έναντι της κεντρικής εκπαίδευσης, με 94,11% έναντι 94,94%. Η διαφορά έχει το ίδιο πρόσημο σε 17 από τα 20 seeds. Απέναντι στην ατομική εκπαίδευση, κερδίζει 18,30 ποσοστιαίες μονάδες. Η ομοσπονδιακή τοπολογία βρίσκεται, δηλαδή, πολύ πιο κοντά στο άνω από ό,τι στο κάτω όριο αναφοράς.

Το συμπέρασμα συνοδεύεται από μια επιφύλαξη που είναι μέρος του, δηλαδή ότι το μικρό κόστος αναμένεται σε αυτή τη ρύθμιση. Οι συμμετέχοντες είναι σχεδόν IID ως προς τις ετικέτες, με διάμεση απόσταση ολικής μεταβολής 0,0423 και καμία κλάση να λείπει από κανέναν.

**Δεύτερο ερώτημα, η αποτίμηση με Shapley σε ρεαλιστικό κόστος.** Ναι. Η ανασύνθεση των μοντέλων από αποθηκευμένες ενημερώσεις, αντί της επανεκπαίδευσης, αντικαθιστά 2,1 εκατομμύρια ομοσπονδιακές εκπαιδεύσεις ανά seed με περάσματα αξιολόγησης, χωρίς καμία εκπαίδευση πέρα από την ίδια την ομοσπονδιακή. Ανά seed, ο KernelSHAP χρειάζεται 136.503 περάσματα και το GTG-Tib 101.431.

Το ουσιαστικότερο μέρος της απάντησης δεν είναι το κόστος αλλά η σταθερότητα. Δύο αλγοριθμικά διαφορετικοί εκτιμητές, που βλέπουν την ίδια συνάρτηση αξίας, συμφωνούν με Kendall  $\tau = 0,9619$ , Pearson 0,9997 και τους ίδιους πέντε πρώτους συμμετέχοντες. Για 19 από τους 21 συμμετέχοντες, το πρόσημο μένει ίδιο σε 19 ή 20 από τα 20 seeds. Επιπλέον, 16 από τους 21 συμμετέχοντες έχουν τιμή μεγαλύτερη από τρεις τυπικές αποκλίσεις και οι υπόλοιποι πέντε είναι εκείνοι με τη μικρότερη απόλυτη τιμή. Στη συγκεκριμένη κλίμακα, με 21 συμμετέχοντες και πλήρη συμμετοχή, η αποτίμηση είναι αξιόπιστη. Όμως, το συμπέρασμα δεν επεκτείνεται αυτόματα σε μεγαλύτερες ομοσπονδίες.

**Τρίτο ερώτημα, η σημασία της αρνητικής συνεισφοράς.** Εννέα από τους 21 συμμετέχοντες έχουν αρνητικό  $\varphi$ . Το εύρημα άντεξε τέσσερις ελέγχους. Οι έλεγχοι αυτοί περιλαμβάνουν την επιμονή του αρνητικού προσήμου στους γύρους, η οποία φτάνει το 94% για τους δύο πιο αρνητικούς, την αμεταβλητότητα ως προς την επιλογή μετρικής, τη συμφωνία των δύο εκτιμητών, καθώς και τη σταθερότητα έναντι των seeds.

Τι σημαίνει, λοιπόν, αρνητική συνεισφορά; Ότι, αφού το μοντέλο έχει μάθει τα βασικά, η ενημέρωση του συμμετέχοντα δείχνει σε άλλη κατεύθυνση από εκείνη των υπολοίπων. Ο FedAvg παίρνει μέσο όρο, οπότε μια τέτοια ενημέρωση απομακρύνει το κοινό μοντέλο από εκεί όπου το πάνε οι περισσότεροι. Όποιος διαφέρει από τους υπόλοιπους διαφέρει εξίσου και από τα άτομα της αξιολόγησης (Ενότητα 5.5.2), οπότε, στον βαθμό που ισχύει αυτό, το μοντέλο βγαίνει λίγο χειρότερο για αυτά, κυρίως στην καθιστή στάση και στην κατάβαση σκάλας. Δε σημαίνει ότι τα δεδομένα του είναι κακά. Στο παίγνιο επανεκπαίδευσης, που αποτιμά τα ίδια δεδομένα χωρίς συνάθροιση, ο χειρότερος συμμετέχων του ομοσπονδιακού παιγνίου βρίσκεται στη μέση της κατάταξης και οι δύο κατατάξεις συμφωνούν μόνο ασθενώς.

Η κατεύθυνση της ενημέρωσης, μια μέτρηση που δε χρησιμοποιεί το σύνολο ελέγχου, δίνει μέσο συνημίτονο  $-0,081$  για τους εννέα έναντι  $+0,003$  για τους δώδεκα και συσχέτιση  $r = +0,580$  με το  $\varphi$ , την ισχυρότερη από όσες μετρήθηκαν. Αντίθετα, η απόσταση ολικής μεταβολής των ετικετών δε σχετίζεται με το  $\varphi$  ( $r = +0,056$ ) και η απόσταση χαρακτηριστικών από το σύνολο ελέγχου έχει μόνο ασθενή σχέση ( $r = -0,442$ ). Ο χειρότερος συμμετέχων είναι κοντά στον μέσο όρο σε όλα τα στατιστικά των δεδομένων του εκτός από τον όγκο. Ούτε ο όγκος ούτε η κατεύθυνση της ενημέρωσης εξηγούν μόνα τους την ακραία τιμή του. Ακόμη και η κατεύθυνση εξηγεί περίπου το ένα τρίτο της διακύμανσης, οπότε κανένα από τα φθηνά μεγέθη που εξετάστηκαν δεν αντικαθιστά την αποτίμηση.

Η προέλευση των αρνητικών τιμών επαληθεύτηκε με ένα δεύτερο παίγνιο στην κεντρική εκπαίδευση. Εκεί, η αξία ενός συνασπισμού υπολογίζεται με επανεκπαίδευση από τα δεδομένα του και όχι από τις ενημερώσεις του. Το παίγνιο αυτό δε δίνει αρνητική τιμή σε κανέναν από τους 21, αν και, όπως εξηγεί η Ενότητα 5.6.4, η μορφή του δύσκολα θα έδινε. Η συμφωνία των δύο κατατάξεων είναι ασθενής ( $\tau = 0,238$ ). Υπάρχει σήμα που συνδέει τα δύο. Το μεγαλύτερο μέρος της αρνητικής συνεισφοράς, όμως, γεννιέται στη *συνάθροιση* και όχι στα δεδομένα. Με άλλα λόγια, **το  $\varphi$  του ομοσπονδιακού παιγνίου μετρά την αξία της ενημέρωσης, όχι την αξία των δεδομένων.**

Στην ανάλυση αστοχίας, η αρνητική τιμή αποσυντέθηκε. Φάνηκε ότι ούτε αυτοί οι συμμετέχοντες βλάπτουν γενικά. Ως προς τον χρόνο, στους πρώτους δέκα γύρους οι ίδιοι εννέα είναι, ως ομάδα, *θετικοί* και το πρόσημο αντιστρέφεται μόνο αφού το μοντέλο ξεπεράσει περίπου το 90%. Ως προς τις δραστηριότητες, *μετακινούν σύνορα απόφασης* μεταξύ συγκεκριμένων ζευγών, κυρίως μεταξύ καθιστής και όρθιας στάσης ( $r = -0,933$  μεταξύ των δύο

στηλών), βελτιώνοντας τη μία κλάση όσο χειροτερεύουν την άλλη. Ως προς τα άτομα της αξιολόγησης, κανείς τους δε βλάπτει και τους εννέα ανθρώπους, ενώ ο χειρότερος από όλους ωφελεί δύο από αυτούς. Επιπλέον, ένα μόνο άτομο απορροφά το 27,3% της αρνητικής συνεισφοράς των εννέα συμμετεχόντων. Η αρνητική τιμή δεν είναι ιδιότητα ενός ανθρώπου αλλά *σχέση* ανάμεσα σε έναν άνθρωπο, μια φάση της εκπαίδευσης και ένα συγκεκριμένο σύνολο αξιολόγησης.

**Η αφαίρεση των αρνητικών συμμετεχόντων.** Το πόρισμα της ανάλυσης είναι ότι, στην περίπτωση της εργασίας, η αφαίρεση των συμμετεχόντων με αρνητική τιμή δεν έχει νόημα. Όταν οι αρνητικοί εντοπίζονται με έξι από τα εννέα άτομα του συνόλου ελέγχου και η επίπτωση της αφαίρεσής τους μετριέται στα υπόλοιπα τρία, το μοντέλο βελτιώνεται σε μία μόνο από τις τρεις τριάδες και χειροτερεύει στις άλλες δύο, σε μία από αυτές σε όλα τα 20 seeds. Μέσα στα έξι άτομα της αποτίμησης, η βελτίωση εμφανίζεται και στις τρεις τριάδες. Η *ταυτοποίηση* των αρνητικών είναι σταθερή, με δείκτη Jaccard από 0,89 έως 1,00. Η αφαίρεσή τους, όμως, βοηθά με συνέπεια μόνο τους ανθρώπους με τους οποίους μετρήθηκε. Η αποτίμηση με Shapley στέκει ως μέτρηση και όχι ως κριτήριο για το ποιος πρέπει να μείνει εκτός. Μετρά τι συνέβη σε μια συγκεκριμένη εκπαίδευση, απέναντι σε ένα συγκεκριμένο σύνολο αξιολόγησης.

Επομένως, οι εννέα μένουν στην ομοσπονδία και η συνεισφορά όλων μετατρέπεται σε μερίδια. Ο απλός μηδενισμός των αρνητικών τιμών είναι η χειρότερη επιλογή, γιατί καταστρέφει πληροφορία κατάταξης, ρίχνοντας το  $\tau$  από 1,000 σε 0,829 και εξισώνοντας έναν συμμετέχοντα με σταθερά αρνητική συνεισφορά με έναν του οποίου η τιμή βρίσκεται μέσα στον θόρυβο. Επιπλέον, μια ποινή με κριτήριο το *πρόσημο* θα τιμωρούσε, δύο φορές στις τρεις, συνεισφορά που ωφελεί άτομα του συνόλου ελέγχου τα οποία έμειναν έξω από την αποτίμηση. Η αφινική μετατόπιση και η εκθετική κατανομή δίνουν μη αρνητικά μερίδια χωρίς απώλεια κατάταξης. Οι θετικοί παίρνουν μεγαλύτερο μερίδιο από τους αρνητικούς (Πίνακας 5.10). Η αφινική αφήνει χωρίς μερίδιο μόνο τον πιο ακραίο αρνητικό, ως παρενέργεια της κλιμάκωσης, ενώ η εκθετική δίνει θετικό μερίδιο σε όλους. Γι' αυτό η εκθετική είναι η επιλογή που ταιριάζει στο πόρισμα παραμονής όλων. Πρόκειται για κανόνα κατανομής πάνω σε μετρημένες τιμές και όχι για μηχανισμό κινήτρων (Ενότητα 6.2).

**Το σύνορο καθιστής και όρθιας στάσης σε δύο αναλύσεις.** Η ανάλυση σφαλμάτων και η ανάλυση συνεισφοράς ανά δραστηριότητα, δύο διαφορετικές μεθοδολογίες, συγκλίνουν στο ίδιο σημείο, δηλαδή στο σύνορο μεταξύ καθιστής και όρθιας στάσης. Το σύνορο αυτό παράγει το 49,1% των σφαλμάτων και αποδίδεται από το 2013 στη φυσική θέση της συσκευής [1]. Η δυσκολία ήταν ήδη γνωστή. Παρόλο που η εργασία δεν την ανακάλυψε, πρόσθεσε την ταυτότητα των συμμετεχόντων που την επιδεινώνουν.

## 6.2 Περιορισμοί της Εργασίας

**Το σύνολο ελέγχου είναι εννέα άνθρωποι.** Παρά τα 2.947 samples, οι ανεξάρτητες μονάδες είναι εννέα. Κάθε δήλωση αβεβαιότητας σε αυτήν την εργασία αφορά τη διασπορά μεταξύ seeds και όχι τη γενίκευση σε νέους ανθρώπους. Η Ενότητα 5.7.4 έκανε ένα βήμα προς την ποσοτικοποίηση, εναλλάσσοντας ποια άτομα συμμετέχουν στην απόφαση και ποια στη μέτρηση. Το αποτέλεσμα ήταν ακριβώς ότι η γενίκευση δεν είναι δεδομένη. Η διαχωριστική γραμμή ανάμεσα στους 21 συμμετέχοντες και στα 9 άτομα αξιολόγησης, όμως, παρέμεινε σταθερή, γιατί είναι δοσμένη από την πηγή.

**Οι συμμετέχοντες είναι σχεδόν IID ως προς τις ετικέτες.** Το συμπέρασμα για το μικρό κόστος της αποκέντρωσης δεν μπορεί να μεταφερθεί χωρίς έλεγχο σε ρυθμίσεις με έντονη λοξότητα ετικετών.

**Μία αρχιτεκτονική, μη βελτιστοποιημένες υπερπαραμέτροι.** Δοκιμάστηκε ένα μόνο πολυεπίπεδο δίκτυο με σταθερές διαστάσεις κρυφών επιπέδων. Δεν έγινε αναζήτηση υπερπαραμέτρων και δεν είναι γνωστό σε ποιο βαθμό τα ευρήματα εξαρτώνται από τη συγκεκριμένη αρχιτεκτονική. Η Ενότητα 4.5 έδειξε, μάλιστα, ότι η λογιστική παλινδρόμηση, με περίπου 53 φορές λιγότερες παραμέτρους, δεν ξεχωρίζει από το δίκτυο ANN και ότι ένα γραμμικό SVM το ξεπερνά στο σύνολο ελέγχου αλλά δεν μπαίνει στην ομοσπονδία χωρίς αλλαγή του τρόπου εκπαίδευσής του. Το δίκτυο κρατήθηκε ως η αρχική σχεδίαση που υποστηρίζει και τις τρεις τοπολογίες και το παίγνιο συνεισφοράς, όχι επειδή χρειαζόταν η χωρητικότητά του. Από τις υπερπαραμέτρους της εκπαίδευσης, μόνο το  $E = 1$  της ομοσπονδιακής τοπολογίας στηρίχθηκε σε μέτρηση, η οποία έγινε στο σύνολο ελέγχου (Ενότητα 4.6.3).

**Η πηγή φέρει διαρροή προεπεξεργασίας.** Το δημοσιευμένο σύνολο έχει κλιμακωθεί με παραμέτρους που υπολογίστηκαν και από τα δεδομένα του συνόλου ελέγχου (Ενότητα 3.3.1), περίπτωση που η βιβλιογραφία καταγράφει ως διαρροή προεπεξεργασίας [35]. Η τυτικοποίηση της εργασίας την ακυρώνει αποδεδειγμένα αλλά η ακύρωση ισχύει μόνο όσο εφαρμόζεται. Κάθε σύγκριση με δημοσιευμένα αποτελέσματα που δεν κάνουν αυτό το βήμα δεν είναι αντιστοιχισμένη.

**Το σύνολο ελέγχου βρίσκεται μέσα στον βρόχο της αποτίμησης.** Η συνάρτηση αξίας αποτιμάται στο σύνολο ελέγχου, πρακτική συνήθης για μέτρηση [30]. Όταν, όμως, η τιμή χρησιμοποιείται για απόφαση, η πρακτική αυτή δημιουργεί εξάρτηση. Η εξάρτηση μετρήθηκε (Ενότητα 5.7.4) και αποδείχθηκε ουσιώδης. Ό,τι απομένει ως περιορισμός είναι ότι δε δοκιμάστηκε η εναλλακτική κατεύθυνση, δηλαδή η αποτίμηση χωρίς κανένα σύνολο επικύρωσης, στηριγμένη μόνο στις τοπικές ενημερώσεις [42].

**Η επαλήθευση με τον ορισμό αφορά τρεις γύρους.** Στο ομοσπονδιακό παίγνιο, η σύγκριση με το ακριβές Shapley έγινε σε τρεις γύρους ενός seed (Ενότητα 5.2.5) και όχι στους

1.305 βαθμολογημένους γύρους των 20 seeds. Για τους υπόλοιπους γύρους, το κενό καλύπτεται έμμεσα, από τη συμφωνία δύο αλγοριθμικά διαφορετικών εκτιμητών και από τη σταθερότητα του προσήμου στα 20 seeds (Ενότητα 5.3.2).

**Οι χρονοσειρές είναι εκτός εύρους.** Η εργασία χρησιμοποιεί αποκλειστικά τα 561 έτοιμα χαρακτηριστικά, που είναι η φυσική είσοδος του απλού πολυεπίπεδου δικτύου που επιλέχθηκε (Ενότητα 3.2). Τα ακατέργαστα σήματα δε δοκιμάστηκαν.

**Καμία τυπική εγγύηση ιδιωτικότητας.** Η εργασία δεν εφαρμόζει διαφορική ιδιωτικότητα ούτε ασφαλή συνάθροιση (Ενότητα 2.2.4). Οι επιμέρους ενημερώσεις είναι ορατές στον εξυπηρετητή, γιατί η αποτίμηση τις χρειάζεται για να ανασυνθέσει το μοντέλο κάθε συνασπισμού.

**Τα κίνητρα παραμένουν σε θεωρητικό επίπεδο.** Δε σχεδιάστηκε ούτε αξιολογήθηκε μηχανισμός. Το μόνο κίνητρο που μετρήθηκε είναι το γεγονός ότι κάθε συμμετέχων παίρνει καλύτερο μοντέλο από αυτό που θα είχε μόνος. Η βιβλιογραφία ξεχωρίζει ρητά τα δύο βήματα. Το Shapley value υιοθετείται συνήθως για την *αποτίμηση της συνεισφοράς*, ενώ η *κατανομή πληρωμών* αφορά παίγνια Stackelberg, δημοπρασίες, θεωρία συμβολαίων και μη κυρτή βελτιστοποίηση [5]. Η εργασία τοποθετείται αποκλειστικά στο πρώτο βήμα. Τα μερίδια της Ενότητας 5.8 δείχνουν τι θα προέκυπτε, αν κάποιος έχτιζε μηχανισμό πάνω στο μέτρο της εργασίας.

### 6.3 Κατευθύνσεις για Μελλοντική Εργασία

**Μηχανισμός κινήτρων πάνω στο μέτρο.** Το φυσικό επόμενο βήμα είναι να χτιστεί πάνω στο μέτρο συνεισφοράς ένας πραγματικός μηχανισμός, με στρατηγικές, κόστος συμμετοχής και ανάλυση ισορροπίας. Η βιβλιογραφία προσφέρει το πλαίσιο, με τη θεωρία συμβολαίων [27], τις δημοπρασίες και τα παίγνια Stackelberg [5], [6]. Το ανοιχτό ζήτημα είναι ότι, αν η αμοιβή εξαρτάται από μετρούμενη συνεισφορά, οι συμμετέχοντες αποκτούν κίνητρο να χειραγωγήσουν τη μέτρηση.

**Έλεγχος με εναλλαγή υποκειμένων.** Επανάληψη ολόκληρης της αποτίμησης με τρεις ή περισσότερους διαφορετικούς διαχωρισμούς των 30 ατόμων σε 21 συμμετέχοντες και 9 για αξιολόγηση. Αν οι ίδιοι άνθρωποι παραμένουν στις τελευταίες θέσεις της κατάταξης ανεξάρτητα από το ποιοι είναι στο σύνολο ελέγχου, ενισχύεται σημαντικά η ερμηνεία ότι η αρνητική τιμή ανήκει στην ενημέρωση και όχι στο σύνολο ελέγχου.

**Αποτίμηση χωρίς σύνολο επικύρωσης.** Η αποτίμηση της εργασίας χρειάζεται ένα σύνολο αξιολόγησης, για να μετρήσει πόσο βελτιώνει κάθε συνασπισμός το μοντέλο. Οι μέθοδοι που στηρίζονται μόνο στις τοπικές ενημερώσεις [42] αποτιμούν επίσης τη συνεισφορά,

χωρίς σύνολο αξιολόγησης, οπότε λύνουν εξ ορισμού το πρόβλημα του συνόλου ελέγχου μέσα στον βρόχο απόφασης. Το έργο τους είναι δυσκολότερο, αφού δεν μπορούν να μετρήσουν απευθείας τη βελτίωση και στηρίζονται σε έμμεσα μεγέθη. Η κατεύθυνση της ενημέρωσης της Ενότητας 5.5.3 είναι ένα τέτοιο μέγεθος και εξηγεί περίπου το ένα τρίτο της διακύμανσης του  $\varphi$ . Η σύγκριση τέτοιων μεθόδων με την αποτίμηση της εργασίας, πάνω στα ίδια δεδομένα, θα έδειχνε πόση από τη συνεισφορά μπορεί να αποτιμηθεί χωρίς σύνολο ελέγχου.

**Αποτίμηση υπό μηχανισμούς ιδιωτικότητας.** Ο θόρυβος της διαφορικής ιδιωτικότητας αλλάζει τις ενημερώσεις και η ασφαλής συνάθροιση τις κρύβει από τον εξυπηρετητή (Ενότητα 2.2.4). Το ερώτημα είναι αν η αποτίμηση μπορεί να γίνει πάνω σε ενημερώσεις με θόρυβο ή όταν ο εξυπηρετητής βλέπει μόνο αθροίσματα, χωρίς να χαθεί η σταθερότητα της κατάταξης που μετρήθηκε εδώ.

**Ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών.** Η ίδια αξιωματική βάση επιτρέπει τη διερεύνηση των *χαρακτηριστικών* που οδηγούν τις προβλέψεις, με το ενοποιητικό πλαίσιο των μεθόδων αφαίρεσης [22]. Θα συνδεόταν άμεσα με την απόσταση χαρακτηριστικών της Ενότητας 5.5.2. Σημειώνεται ότι μια τέτοια ανάλυση θα έπρεπε να λάβει υπόψη τις 21 στήλες-αντίγραφα της Ενότητας 3.3.2. Κάθε αντίγραφο μοιράζεται τη σημαντικότητα με το πρωτότυπό του, με αποτέλεσμα να εμφανίζονται και τα δύο υποτιμημένα.

**Χρονοσειρές και μάθηση αναπαράστασης.** Μοντέλα που δέχονται τα ακατέργαστα σήματα [2] θα επέτρεπαν να ελεγχθεί αν η κατάταξη συνεισφοράς είναι ιδιότητα των ανθρώπων ή της συγκεκριμένης αναπαράστασης. Είναι ο πιο άμεσος έλεγχος της σταθερότητας του κεντρικού ευρήματος της εργασίας.

## Βιβλιογραφία

- [1] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra και Jorge Luis Reyes-Ortiz. «A Public Domain Dataset for Human Activity Recognition Using Smartphones». Στο: *Proceedings of the 21st European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN)*. 2013. URL: <https://www.esann.org/sites/default/files/proceedings/legacy/es2013-84.pdf>.
- [2] Kaixuan Chen, Dalin Zhang, Lina Yao, Bin Guo, Zhiwen Yu και Yunhao Liu. *Deep Learning for Sensor-based Human Activity Recognition: Overview, Challenges and Opportunities*. 2021. arXiv: 2001.07416v2. URL: <https://arxiv.org/abs/2001.07416v2>. Δημοσιεύτηκε στο: *ACM Computing Surveys* 54.4 (2022). DOI: 10.1145/3447744.
- [3] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson και Blaise Agüera y Arcas. «Communication-Efficient Learning of Deep Networks from Decentralized Data». Στο: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 54. PMLR. 2017. URL: <https://proceedings.mlr.press/v54/mcmahan17a.html>.
- [4] Peter Kairouz κ.ά. *Advances and Open Problems in Federated Learning*. 2021. arXiv: 1912.04977v3. URL: <https://arxiv.org/abs/1912.04977v3>. Δημοσιεύτηκε στο: *Foundations and Trends in Machine Learning* 14.1–2 (2021). DOI: 10.1561/22000000083.
- [5] Rongfei Zeng, Chao Zeng, Xingwei Wang, Bo Li και Xiaowen Chu. *A Comprehensive Survey of Incentive Mechanism for Federated Learning*. 2021. arXiv: 2106.15406v1. URL: <https://arxiv.org/abs/2106.15406v1>.
- [6] Xuezhen Tu, Kun Zhu, Nguyen Cong Luong, Dusit Niyato, Yang Zhang και Juan Li. *Incentive Mechanisms for Federated Learning: From Economic and Game Theoretic Perspective*. 2021. arXiv: 2111.11850v1. URL: <https://arxiv.org/abs/2111.11850v1>. Δημοσιεύτηκε στο: *IEEE Transactions on Cognitive Communications and Networking* 8.3 (2022). DOI: 10.1109/TCCN.2022.3177522.

- [7] Pavlos Efraimidis. *Διπλωματικές Εργασίες*. Algorithms & Privacy Research Unit, DUTH. 2025. URL: <https://pefraimi.github.io/theses/>, accessed September 27th, 2026.
- [8] Ian Goodfellow, Yoshua Bengio και Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [9] Diederik P. Kingma και Jimmy Ba. *Adam: A Method for Stochastic Optimization*. 2017. arXiv: 1412.6980v9. URL: <https://arxiv.org/abs/1412.6980v9>. Δημοσιεύτηκε στο: *International Conference on Learning Representations (ICLR)*. 2015.
- [10] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever και Ruslan Salakhutdinov. «Dropout: A Simple Way to Prevent Neural Networks from Overfitting». Στο: *Journal of Machine Learning Research* 15:56 (2014). URL: <https://jmlr.org/papers/v15/srivastava14a.html>.
- [11] Marina Sokolova και Guy Lapalme. «A Systematic Analysis of Performance Measures for Classification Tasks». Στο: *Information Processing & Management* 45:4 (2009). DOI: 10.1016/j.ipm.2009.03.002. URL: <https://rali.iro.umontreal.ca/rali/sites/default/files/publis/SokolovaLapalme-JIPM09.pdf>.
- [12] scikit-learn developers. *Metrics and scoring: quantifying the quality of predictions*. scikit-learn 1.8.0 documentation, User Guide, Section 3.4. 2025. URL: [https://scikit-learn.org/1.8/modules/model\\_evaluation.html](https://scikit-learn.org/1.8/modules/model_evaluation.html), accessed September 28th, 2026.
- [13] Fabian Pedregosa κ.ά. «Scikit-learn: Machine Learning in Python». Στο: *Journal of Machine Learning Research* 12 (2011). URL: <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [14] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar και Virginia Smith. «Federated Optimization in Heterogeneous Networks». Στο: *Proceedings of Machine Learning and Systems (MLSys)*. Τόμ. 2. 2020. URL: [https://proceedings.mlsys.org/paper\\_files/paper/2020/hash/1f5fe83998a09396ebe6477d9475ba0c-Abstract.html](https://proceedings.mlsys.org/paper_files/paper/2020/hash/1f5fe83998a09396ebe6477d9475ba0c-Abstract.html).
- [15] Sai Praneeth Karimireddy, Satyen Kale, Mehryar Mohri, Sashank J. Reddi, Sebastian U. Stich και Ananda Theertha Suresh. «SCAFFOLD: Stochastic Controlled Averaging for Federated Learning». Στο: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Τόμ. 119. PMLR. 2020. URL: <https://proceedings.mlr.press/v119/karimireddy20a.html>.

- [16] Martín Abadi κ.ά. *Deep Learning with Differential Privacy*. 2016. arXiv: 1607.00133v2. URL: <https://arxiv.org/abs/1607.00133v2>. Προκαταρκτική έκδοση στο: *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security (CCS)*. 2016. DOI: 10.1145/2976749.2978318.
- [17] Lloyd S. Shapley. *A Value for n-Person Games*. P-295. RAND Corporation, 1952. DOI: 10.7249/P0295. URL: <https://www.rand.org/pubs/papers/P295.html>. Δημοσιεύτηκε στο: *Contributions to the Theory of Games (AM-28), Volume II*. Princeton University Press, 1953. DOI: 10.1515/9781400881970-018.
- [18] Ruoxi Jia κ.ά. «Towards Efficient Data Valuation Based on the Shapley Value». Στο: *Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 89. PMLR. 2019. URL: <https://proceedings.mlr.press/v89/jia19a.html>.
- [19] Amirata Ghorbani και James Zou. «Data Shapley: Equitable Valuation of Data for Machine Learning». Στο: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. Τόμ. 97. PMLR. 2019. URL: <https://proceedings.mlr.press/v97/ghorbani19c.html>.
- [20] Scott M. Lundberg και Su-In Lee. «A Unified Approach to Interpreting Model Predictions». Στο: *Advances in Neural Information Processing Systems (NeurIPS)*. Τόμ. 30. 2017. URL: [https://proceedings.neurips.cc/paper\\_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html](https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html).
- [21] Ian Covert και Su-In Lee. «Improving KernelSHAP: Practical Shapley Value Estimation Using Linear Regression». Στο: *Proceedings of the 24th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 130. PMLR. 2021. URL: <https://proceedings.mlr.press/v130/covert21a.html>.
- [22] Ian Covert, Scott M. Lundberg και Su-In Lee. «Explaining by Removing: A Unified Framework for Model Explanation». Στο: *Journal of Machine Learning Research* 22:209 (2021). URL: <https://jmlr.org/papers/v22/20-1316.html>.
- [23] Amirata Ghorbani, Michael P. Kim και James Zou. «A Distributional Framework for Data Valuation». Στο: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Τόμ. 119. PMLR. 2020. URL: <https://proceedings.mlr.press/v119/ghorbani20a.html>.
- [24] Xinyi Xu, Lingjuan Lyu, Xingjun Ma, Chenglin Miao, Chuan Sheng Foo και Bryan Kian Hsiang Low. «Gradient Driven Rewards to Guarantee Fairness in Collaborative Machine Learning». Στο: *Advances in Neural Information Processing Systems (NeurIPS)*. Τόμ. 34. 2021. URL: <https://proceedings.neurips>.

- [cc/paper/2021/hash/8682cc30db9c025ecd3fee433f8ab54c-Abstract.html](https://arxiv.org/abs/2021.07479).
- [25] Jiachen T. Wang και Ruoxi Jia. «Data Banzhaf: A Robust Data Valuation Framework for Machine Learning». Στο: *Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 206. PMLR. 2023. URL: <https://proceedings.mlr.press/v206/wang23e.html>.
- [26] Jiachen T. Wang, Tianji Yang, James Zou, Yongchan Kwon και Ruoxi Jia. «Rethinking Data Shapley for Data Selection Tasks: Misleads and Merits». Στο: *Proceedings of the 41st International Conference on Machine Learning (ICML)*. Τόμ. 235. PMLR. 2024. URL: <https://proceedings.mlr.press/v235/wang24cg.html>.
- [27] Jiawen Kang, Zehui Xiong, Dusit Niyato, Han Yu, Ying-Chang Liang και Dong In Kim. *Incentive Design for Efficient Federated Learning in Mobile Networks: A Contract Theory Approach*. 2019. arXiv: [1905.07479v2](https://arxiv.org/abs/1905.07479v2). URL: <https://arxiv.org/abs/1905.07479v2>. Δημοσιεύτηκε στο: *2019 IEEE VTS Asia Pacific Wireless Communications Symposium (APWCS)*. 2019. DOI: [10.1109/VTS-APWCS.2019.8851649](https://doi.org/10.1109/VTS-APWCS.2019.8851649).
- [28] Nurbek Tastan, Samar Fares, Toluwani Aremu, Samuel Horváth και Karthik Nandakumar. «Redefining Contributions: Shapley-Driven Federated Learning». Στο: *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24)*. 2024. DOI: [10.24963/ijcai.2024/554](https://doi.org/10.24963/ijcai.2024/554). URL: <https://www.ijcai.org/proceedings/2024/0554.pdf>.
- [29] Konstantin Sozinov, Vladimir Vlassov και Sarunas Girdzijauskas. «Human Activity Recognition Using Federated Learning». Στο: *2018 IEEE Intl Conf on Parallel & Distributed Processing with Applications, Ubiquitous Computing & Communications, Big Data & Cloud Computing, Social Computing & Networking, Sustainable Computing & Communications (ISPA/IUCC/BDCLOUD/SocialCom/SustainCom)*. 2018. DOI: [10.1109/BDCLOUD.2018.00164](https://doi.org/10.1109/BDCLOUD.2018.00164). URL: <https://people.kth.se/~sarunasg/Papers/Sozinov2018FederatedLearning.pdf>.
- [30] Zelei Liu, Yuanyuan Chen, Han Yu, Yang Liu και Lizhen Cui. *GTG-Shapley: Efficient and Accurate Participant Contribution Evaluation in Federated Learning*. 2021. arXiv: [2109.02053v1](https://arxiv.org/abs/2109.02053v1). URL: <https://arxiv.org/abs/2109.02053v1>. Δημοσιεύτηκε στο: *ACM Transactions on Intelligent Systems and Technology* 13.4 (2022). DOI: [10.1145/3501811](https://doi.org/10.1145/3501811).
- [31] Mengwei Yang, Ismat Jarin, Baturalp Buyukates, Salman Avestimehr και Athina Markopoulou. *Maverick-Aware Shapley Valuation for Client Selection in Federated Learning*. 2024. arXiv: [2405.12590v1](https://arxiv.org/abs/2405.12590v1). URL: <https://arxiv.org/abs/2405.12590v1>.

- [32] Jiyue Huang, Chi Hong, Lydia Y. Chen και Stefanie Roos. *Is Shapley Value fair? Improving Client Selection for Mavericks in Federated Learning*. 2021. arXiv: 2106.10734v1. URL: <https://arxiv.org/abs/2106.10734v1>.
- [33] Jorge Luis Reyes-Ortiz, Davide Anguita, Alessandro Ghio, Luca Oneto και Xavier Parra. *Human Activity Recognition Using Smartphones*. UCI Machine Learning Repository. 2013. DOI: 10.24432/C54S4K. URL: <https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>, accessed September 27th, 2026.
- [34] Jindong Wang, Yiqiang Chen, Shuji Hao, Xiaohui Peng και Lisha Hu. *Deep Learning for Sensor-based Activity Recognition: A Survey*. 2017. arXiv: 1707.03502v2. URL: <https://arxiv.org/abs/1707.03502v2>. Δημοσιεύτηκε στο: *Pattern Recognition Letters* 119 (2019). DOI: 10.1016/j.patrec.2018.02.010.
- [35] Sayash Kapoor και Arvind Narayanan. «Leakage and the reproducibility crisis in machine-learning-based science». Στο: *Patterns* 4.9 (2023). DOI: 10.1016/j.patter.2023.100804.
- [36] Artur Jordao, Antonio C. Nazare, Jessica Sena και William Robson Schwartz. *Human Activity Recognition Based on Wearable Sensor Data: A Standardization of the State-of-the-Art*. 2019. arXiv: 1806.05226v3. URL: <https://arxiv.org/abs/1806.05226v3>.
- [37] Akbar Dehghani, Omid Sarbishei, Tristan Glatard και Emad Shihab. «A Quantitative Comparison of Overlapping and Non-Overlapping Sliding Windows for Human Activity Recognition Using Inertial Sensors». Στο: *Sensors* 19.22 (2019). DOI: 10.3390/s19225026.
- [38] Jason Ansel κ.ά. *PyTorch 2: Faster Machine Learning Through Dynamic Python Bytecode Transformation and Graph Compilation*. 2024. URL: <https://docs.pytorch.org/assets/pytorch2-2.pdf>. Δημοσιεύτηκε στο: *Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS '24), Volume 2*. ACM, 2024. DOI: 10.1145/3620665.3640366.
- [39] Nikolaos Pavlidis. *Simple Federated Learning Example*. GitHub repository. 2023. URL: [https://github.com/nikopavl4/Simple\\_FL\\_Example](https://github.com/nikopavl4/Simple_FL_Example), accessed September 27th, 2026.
- [40] Léo Grinsztajn, Edouard Oyallon και Gaël Varoquaux. «Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?». Στο: *Advances in Neural Information Processing Systems 35 (NeurIPS), Datasets and Benchmarks Track*. 2022. DOI: 10.52202/068431-0037. URL: <https://>

- [//proceedings.neurips.cc/paper\\_files/paper/2022/hash/0378c7692da36807bdec87ab043cdadc-Abstract-Datasets\\_and\\_Benchmarks.html](https://proceedings.neurips.cc/paper_files/paper/2022/hash/0378c7692da36807bdec87ab043cdadc-Abstract-Datasets_and_Benchmarks.html).
- [41] E. T. Jaynes. «Information Theory and Statistical Mechanics». Στο: *Physical Review* 106.4 (1957). DOI: [10.1103/PhysRev.106.620](https://doi.org/10.1103/PhysRev.106.620). URL: <https://bayes.wustl.edu/etj/articles/theory.1.pdf>.
- [42] Meiyang Zhang, Huan Zhao, Sheldon Ebron και Kan Yang. *Towards Fair, Robust and Efficient Client Contribution Evaluation in Federated Learning*. 2024. arXiv: [2402.04409v1](https://arxiv.org/abs/2402.04409v1). URL: <https://arxiv.org/abs/2402.04409v1>. Δημοσιεύτηκε στο: *GLOBECOM 2024 – 2024 IEEE Global Communications Conference*. 2024. DOI: [10.1109/GLOBECOM52923.2024.10901033](https://doi.org/10.1109/GLOBECOM52923.2024.10901033).