

ΔΗΜΟΚΡΙΤΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΡΑΚΗΣ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ & ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

Αποτίμηση της συνεισφοράς χρηστών στην ομοσπονδιακή μάθηση

Evaluation of User Contributions in Federated Learning

Διπλωματική Εργασία

Δημήτριος Αναστασούδης
ΑΕΜ: 58085

Επιβλέπων:

Παύλος Εφραιμίδης

Algorithms & Privacy Research Unit (Euclid)

Ξάνθη, 2026

Ευχαριστίες

Η εκπόνηση της παρούσας διπλωματικής εργασίας δε θα ήταν εφικτή χωρίς την ουσιαστική υποστήριξη ανθρώπων που βρίσκονταν δίπλα μου καθ' όλη τη διάρκεια των σπουδών μου. Πρωτίστως, θα ήθελα να εκφράσω τη βαθύτατη ευγνωμοσύνη μου στους γονείς μου, για την αμέριστη αγάπη, υπομονή και ηθική στήριξη που μου πρόσφεραν σε κάθε βήμα αυτής της πορείας. Η εμπιστοσύνη τους στις ικανότητές μου και η αδιάλειπτη παρουσία τους αποτέλεσαν το σταθερό σημείο αναφοράς που μου επέτρεψε να ολοκληρώσω τις σπουδές μου με αφοσίωση και επιμονή. Τους ευχαριστώ από καρδιάς.

Ιδιαίτερες ευχαριστίες οφείλω στον επιβλέποντα καθηγητή μου, κ. Παύλο Εφραιμίδη, Καθηγητή του Τμήματος Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών του Δ.Π.Θ. και επικεφαλής του Algorithms & Privacy Research Unit (Euclid), για την επιστημονική καθοδήγηση, την άρτια εποπτεία και τις εύστοχες παρατηρήσεις που διαμόρφωσαν καθοριστικά την κατεύθυνση και την ποιότητα της εργασίας. Παράλληλα, θερμές ευχαριστίες εκφράζω και στον Δρ. Νικόλαο Παυλίδη, μέλος της ίδιας ερευνητικής ομάδας, για την πολύτιμη τεχνική βοήθεια, τις γόνιμες συζητήσεις και τη διάθεση του ερευνητικού υλικού που διευκόλυνε σημαντικά την υλοποίηση του πειραματικού μέρους της εργασίας.

Τέλος, εκφράζω την εκτίμησή μου στο Δημοκρίτειο Πανεπιστήμιο Θράκης και στο Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, για το ακαδημαϊκό περιβάλλον, τις ευκαιρίες και τις γνώσεις που μου έδωσαν στη διάρκεια των σπουδών μου.

Περίληψη

Η εργασία αντιμετωπίζει ένα πρόβλημα ταξινόμησης, την αναγνώριση ανθρώπινης δραστηριότητας από τους αισθητήρες ενός έξυπνου κινητού τηλεφώνου. Κάθε sample περιγράφει 2,56 δευτερόλεπτα κίνησης με 561 *features*. Το μοντέλο αναγνωρίζει ποια από τις έξι δραστηριότητες εκτελείται. Επειδή τα δεδομένα αυτά είναι προσωπικά, η εκπαίδευση γίνεται με ομοσπονδιακή μάθηση, όπου τα δεδομένα μένουν στη συσκευή κάθε *client* και ο *server* δεν μπορεί να κρίνει τι προσέφερε ο καθένας. Σε αυτό το πρόβλημα δίνει λύση η παρούσα εργασία, αποτιμώντας τη συνεισφορά των χρηστών.

Στο σύνολο δεδομένων UCI HAR, οι 21 εθελοντές του *training set* καταχωρούνται ως οι clients της ομοσπονδίας και 9 άλλοι άνθρωποι προορίζονται αποκλειστικά για την αξιολόγηση. Μετά από ελέγχους ακεραιότητας των δεδομένων, το ίδιο απλό νευρωνικό δίκτυο εκπαιδεύεται με τρεις τοπολογίες μάθησης σε 20 επαναλήψεις. Το *accuracy* της κεντρικής ανέρχεται σε 94,94%, της ομοσπονδιακής σε 94,11% και της ατομικής σε 75,81%, οπότε η αποκέντρωση κοστίζει 0,83 ποσοστιαίες μονάδες, ενώ η συνεργασία κερδίζει 18,30.

Η συνεισφορά αποτιμάται με το Shapley value, σε παίγνιο που ορίζεται σε κάθε επανάληψη (*round*) της ομοσπονδιακής εκπαίδευσης, όπου ως αξία μιας ομάδας clients ορίζεται το accuracy του μοντέλου που θα έβγαινε μόνο από τα *updates* της. Τα μοντέλα αυτά ανασυντίθενται από αποθηκευμένα updates, χωρίς επανεκπαίδευση. Δύο ανεξάρτητοι εκτιμητές, ο KernelSHAP και μια παραλλαγή του GTG-Shapley, συμφωνούν σχεδόν πλήρως στην κατάταξη.

Εννέα από τους 21 clients παίρνουν αρνητική τιμή, δηλαδή το update τους, κατά μέσο όρο στα rounds, κάνει το *global model* χειρότερο για τα άτομα της αξιολόγησης. Το εύρημα αντέχει τέσσερις ελέγχους. Κανένα απλό στατιστικό των δεδομένων δεν το προβλέπει πλήρως.

Σε ένα δεύτερο παίγνιο, όπου κάθε ομάδα αποτιμάται με ένα κεντρικό (*centralized*) μοντέλο, εκπαιδευμένο από την αρχή μόνο με τα δεδομένα της, κανείς δε βγαίνει αρνητικός και οι δύο κατατάξεις συμφωνούν ασθενώς, οπότε δε βρέθηκε ένδειξη ότι τα δεδομένα κάποιου client βλάπτουν. Για την ομάδα των εννέα, η αρνητική τιμή εμφανίζεται μόνο αφού το μοντέλο ξεπεράσει το 90%, κυρίως στο σύνορο καθιστής και όρθιας στάσης και απέναντι σε συγκεκριμένα άτομα της αξιολόγησης. Το σύνορο αυτό δίνει το 49,1% των σφαλμάτων. Όταν οι αρνητικοί εντοπίζονται με βάση έξι από τα εννέα άτομα της αξιολόγησης και αφαιρούνται, το μοντέλο βελτιώνεται για τα άλλα τρία σε μία μόνο από τις τρεις διαιρέσεις. Η

αφαίρεσή τους, επομένως, δεν έχει νόημα και μένουν στην ομοσπονδία. Η συνεισφορά όλων γίνεται μερίδια με δύο πολιτικές που κρατούν την κατάταξη, την αφινική μετατόπιση και την εκθετική κατανομή, από τις οποίες η δεύτερη δίνει θετικό μερίδιο σε όλους.

Λέξεις-κλειδιά: ομοσπονδιακή μάθηση, αναγνώριση ανθρώπινης δραστηριότητας, ταξινόμηση, Shapley value, KernelSHAP, αποτίμηση συνεισφοράς, αποτίμηση δεδομένων, UCI HAR

Abstract

This thesis addresses a classification problem, human activity recognition from the sensors of a smartphone. Each sample describes 2.56 seconds of movement through 561 features, and the model recognizes which of six activities is being performed. Because such data are personal, training uses federated learning, where the data stay on each client's device and the server cannot judge what each client contributed. The thesis responds to this problem by evaluating the contribution of the users.

On the UCI HAR dataset, the 21 volunteers of the training split become the clients of the federation and 9 other people are kept solely for evaluation. After integrity checks on the data, the same simple neural network is trained under three learning topologies over 20 repetitions. Centralized training reaches 94.94% accuracy, federated training 94.11% and individual training 75.81%, so decentralization costs 0.83 percentage points while collaboration gains 18.30.

Contribution is evaluated with the Shapley value, in a per-round game where the value of a group of clients is the accuracy of the model that their updates alone would produce. These models are rebuilt from stored updates, without retraining. Two independent estimators, KernelSHAP and a variant of GTG-Shapley, agree almost fully on the ranking.

Nine of the 21 clients receive a negative value, meaning that, on average over the rounds, their update makes the global model worse for the evaluation subjects. The finding survives four checks, and no simple statistic of the data fully predicts it.

In a second game, where each group is valued by a centralized model retrained from scratch on its own data only, no client is negative and the two rankings agree only weakly, so there is no indication that any client's data are harmful. For the group of nine, the negative value appears only after the model passes 90%, mainly at the boundary between sitting and standing, which accounts for 49.1% of the errors, and it is concentrated on particular evaluation subjects. When the negative clients are identified with six of the nine evaluation subjects and removed, the model improves for the other three in only one of the three splits. Removing them therefore does not make sense. They remain in the federation, and the contribution of all clients is turned into shares with two policies that keep the ranking, an affine shift and an exponential distribution, the second of which gives every client a positive share.

Keywords: federated learning, human activity recognition, classification, Shapley value, KernelSHAP, contribution evaluation, data valuation, UCI HAR

Περιεχόμενα

Ευχαριστίες **2**

Περίληψη **3**

Abstract **5**

Κατάλογος Σχημάτων **10**

Κατάλογος Πινάκων **12**

Κατάλογος Συντομογραφιών **14**

1 Εισαγωγή **15**

1.1 Αναγνώριση Δραστηριότητας, Ιδιωτικότητα και Ομοσπονδιακή Μάθηση . . 15

1.2 Το Πρόβλημα της Αποτίμησης της Συνεισφοράς 16

1.3 Ερευνητικά Ερωτήματα 16

1.4 Συνεισφορά της Εργασίας 17

1.5 Διάρθρωση της Εργασίας 17

2 Θεωρητικό Υπόβαθρο **19**

2.1 Νευρωνικά Δίκτυα Multilayer Perceptron 19

2.1.1 Δομή, εκπαίδευση και κανονικοποίηση 19

2.1.2 Μετρικές αξιολόγησης ταξινόμησης 20

2.1.3 Μέτρα συσχέτισης και συμφωνίας κατάταξης 22

2.2 Ομοσπονδιακή Μάθηση 24

2.2.1 Αρχιτεκτονική server και clients 24

2.2.2 Ο αλγόριθμος FedAvg 25
2.2.3 Ετερογένεια και client drift 26
2.2.4 Εγγυήσεις και όρια ιδιωτικότητας 26
2.3 Συνεργατικά Παίγνια και Αποτίμηση Συνεισφοράς 27
2.3.1 Συνεργατικά παίγνια και χαρακτηριστική συνάρτηση 27
2.3.2 Το Shapley value και τα τρία αξιώματα 27
2.3.3 Υπολογιστική πολυπλοκότητα και εκτιμητές 29
2.3.4 Shapley value, SHAP και συνάρτηση αξίας 30
2.3.5 Κίνητρα συμμετοχής στην ομοσπονδιακή μάθηση 32
2.4 Σχετική Βιβλιογραφία και Τοποθέτηση της Εργασίας 32
2.4.1 Ομοσπονδιακή μάθηση για αναγνώριση δραστηριότητας 32
2.4.2 Αποτίμηση συνεισφοράς στην ομοσπονδιακή μάθηση 33
2.4.3 Το κενό της βιβλιογραφίας που καλύπτει η εργασία 33

3 Δεδομένα, Έλεγχοι και Προεπεξεργασία 35
3.1 Το Σύνολο Δεδομένων UCI HAR 35
3.2 Από τα Σήματα των Αισθητήρων στα 561 Features 36
3.3 Έλεγχοι Ακεραιότητας των Δεδομένων 39
3.3.1 Διαρροή προεπεξεργασίας στην πηγή 40
3.3.2 Διπλότυπες στήλες 41
3.3.3 Επικάλυψη διαδοχικών samples 42
3.3.4 Ανίχνευση ακραίων τιμών 42
3.4 Διερευνητική Ανάλυση Δεδομένων 43
3.4.1 Ισορροπία κλάσεων 43
3.4.2 Κατάτμηση σε clients και ετερογένεια 44
3.4.3 Διαχωρισιμότητα κλάσεων 44
3.5 Προεπεξεργασία και Πρωτόκολλο Διαχωρισμού 48

4 Υλοποίηση και Σύγκριση των Τοπολογιών Μάθησης **49**

4.1 Οργάνωση του Λογισμικού 49

4.2 Αρχιτεκτονική και Υπερπαράμετροι του Δικτύου 51

4.3 Οι Τρεις Τοπολογίες Μάθησης 51

4.3.1 Κεντρική εκπαίδευση 51

4.3.2 Ομοσπονδιακή εκπαίδευση με FedAvg 52

4.3.3 Ατομική εκπαίδευση 53

4.4 Πειραματικό Πρωτόκολλο και Μετρήσεις 53

4.5 Σύγκριση του Δικτύου με Απλούστερα Μοντέλα 55

4.6 Σύγκριση των Τριών Τοπολογιών 57

4.6.1 Κόστος της αποκέντρωσης και όφελος της συνεργασίας 57

4.6.2 Διασπορά της ατομικής επίδοσης μεταξύ ανθρώπων 59

4.6.3 Local epochs έναντι rounds 60

4.7 Ανάλυση Σφαλμάτων 61

5 Αποτίμηση της Συνεισφοράς των Χρηστών **63**

5.1 Το Παίγνιο ανά Round Εκπαίδευσης 64

5.2 Οι Δύο Εκτιμητές 66

5.2.1 KernelSHAP 67

5.2.2 GTG-Shapley 68

5.2.3 Κοινή συνάρτηση αξίας 69

5.2.4 Guided sampling των μεταθέσεων 70

5.2.5 Επαλήθευση με πλήρη απαρίθμηση 74

5.3 Αποτελέσματα της Αποτίμησης 75

5.3.1 Η κατανομή των τιμών 75

5.3.2 Συμφωνία εκτιμητών και σταθερότητα 76

5.3.3 Υπολογιστικό κόστος 78

5.4 Έλεγχοι των Αρνητικών Τιμών 79

5.5 Μεγέθη που Σχετίζονται με τη Συνεισφορά 80
5.5.1 Όγκος δεδομένων, labels και ατομική επίδοση 81
5.5.2 Απόσταση κατανομής features 81
5.5.3 Κατεύθυνση του update 82
5.6 Επαλήθευση με Δεύτερο Παίγνιο στην Κεντρική Εκπαίδευση 84
5.6.1 Ορισμός του παιγνίου 84
5.6.2 Αποτελέσματα 86
5.6.3 Ακρίβεια της εκτίμησης 87
5.6.4 Συμπέρασμα 88
5.7 Failure Analysis 89
5.7.1 Η αρνητική τιμή ανά round 90
5.7.2 Η αρνητική τιμή ανά δραστηριότητα 92
5.7.3 Η αρνητική τιμή ανά άτομο της αξιολόγησης 95
5.7.4 Το πείραμα αφαίρεσης 97
5.7.5 Αποτελέσματα της αφαίρεσης 99
5.7.6 Συμπέρασμα 101
5.8 Μερίδια Ανταμοιβής 101
5.8.1 Πολιτικές μεριδίων 101
5.8.2 Αφινική μετατόπιση και εκθετική κατανομή 102
5.8.3 Συνεισφορά και μερίδιο κάθε client 105

6 Συμπεράσματα και Μελλοντική Εργασία 107

6.1 Απαντήσεις στα Ερευνητικά Ερωτήματα 107
6.2 Περιορισμοί της Εργασίας 110
6.3 Κατευθύνσεις για Μελλοντική Εργασία 111

Βιβλιογραφία 113

Κατάλογος Σχημάτων

2.1 Ένα round του FedAvg 25

2.2 Το Shapley value ως μέσος όρος σειρών άφιξης 29

3.1 Από τα σήματα στα features 36

3.2 Κατανομή δραστηριοτήτων ανά client 45

3.3 Διαχωρισιμότητα των έξι δραστηριοτήτων 46

3.4 Κίνηση έναντι βαρύτητας ανά δραστηριότητα 47

3.5 Ο αγωγός από τους εθελοντές στους clients 48

4.1 Η οργάνωση του λογισμικού 50

4.2 Το δίκτυο ANN απέναντι στο logistic regression 56

4.3 Καμπύλες μάθησης 58

4.4 Οι τρεις τοπολογίες και η διασπορά μεταξύ ανθρώπων 59

4.5 Local epochs έναντι rounds 60

4.6 Confusion matrix της ομοσπονδιακής τοπολογίας 61

5.1 Πώς αποτιμάται ένας συνασπισμός 65

5.2 Η ροή της αποτίμησης στο ομοσπονδιακό παίγνιο 71

5.3 Συνεισφορά ανά client 76

5.4 Συμφωνία εκτιμητών και ο όγκος ως υποκατάστατο 77

5.5 Σύγκλιση των εκτιμητών ανά round 78

5.6 Τα δύο παίγνια 85

5.7 Η ροή της αποτίμησης στο παίγνιο επανεκπαίδευσης 86

5.8 Η κατάταξη στα δύο παίγνια 87

5.9 Πότε εμφανίζεται η αρνητική συνεισφορά 91

5.10 Συνεισφορά ανά δραστηριότητα 93

5.11 Η μήτρα συνεισφοράς ανά άτομο αξιολόγησης 96

5.12 Ο σχεδιασμός που αποφεύγει την κυκλικότητα 98

5.13 Αφαίρεση των αρνητικών clients 99

5.14 Καμπύλες αφαίρεσης από τα δύο άκρα της κατάταξης 100

5.15 Μερίδια ανά πολιτική 103

Κατάλογος Πινάκων

2.1 Τα μέτρα συσχέτισης και συμφωνίας κατάταξης 24

3.1 Πώς διαβάζεται το όνομα ενός feature 38

3.2 Τρεις γραμμές του training set 38

3.3 Η κλίμακα των δεδομένων πριν και μετά την τυπικοποίηση 41

4.1 Το δίκτυο ANN απέναντι σε τρία απλούστερα μοντέλα 55

4.2 Σύγκριση των τριών τοπολογιών μάθησης 57

5.1 Το SHAP απέναντι στην αποτίμηση αυτής της εργασίας 67

5.2 Τυχαία δειγματοληψία έναντι guided sampling των μεταθέσεων 73

5.3 Σύγκριση του KernelSHAP με το ακριβές Shapley 75

5.4 Οι τρεις εκτιμητές στα 20 seeds 77

5.5 Τα μεγέθη που σχετίζονται με τη συνεισφορά 83

5.6 Τα δύο παίγνια με μια ματιά 88

5.7 Η μήτρα ανά δραστηριότητα σε αριθμούς 94

5.8 Αφαίρεση των αρνητικών clients 99

5.9 Πολιτικές κατανομής μεριδίων 102

5.10 Συνεισφορά και μερίδια ανά client 106

Κατάλογος Συντομογραφιών

Συντομογραφία	Ανάπτυξη	Απόδοση στα ελληνικά
Adam	Adaptive Moment Estimation	ο optimizer της εκπαίδευσης
ANN	Artificial Neural Network	τεχνητό νευρωνικό δίκτυο
CPU	Central Processing Unit	κεντρική μονάδα επεξεργασίας
F1	F1-score	αρμονικός μέσος του precision και του recall (το macro-F1 είναι ο μέσος όρος του στις κλάσεις)
FedAvg	Federated Averaging	ο αλγόριθμος aggregation των updates
FL	Federated Learning	ομοσπονδιακή μάθηση
GTG	Guided Truncation Gradient (GTG-Shapley)	εκτιμητής των Shapley values με αποκοπή
GTG-Tib	GTG-Shapley with within- and between-round truncation	η παραλλαγή του GTG-Shapley χωρίς το guided sampling
HAR	Human Activity Recognition	αναγνώριση ανθρώπινης δραστηριότητας
IID	Independent and Identically Distributed	ανεξάρτητα και ισόνομα κατανεμημένα
MLP	Multilayer Perceptron	δίκτυο εμπρόσθιας τροφοδότησης
MR	Multi-Round (evaluation)	αποτίμηση ανά round και άθροισμα των rounds
PCA	Principal Component Analysis	ανάλυση κύριων συνιστωσών
ReLU	Rectified Linear Unit	συνάρτηση ενεργοποίησης που μηδενίζει τις αρνητικές τιμές
SHA-256	Secure Hash Algorithm, 256 bit	συνάρτηση κατακερματισμού (αθροίσματα ελέγχου)
SHAP	SHapley Additive exPlanations	μέθοδος ερμηνείας με Shapley values και η βιβλιοθήκη `shap` που την υλοποιεί
SVM	Support Vector Machine	μηχανή διανυσμάτων υποστήριξης
TV	Total Variation (distance)	απόσταση ολικής μεταβολής
UCI	University of California, Irvine	το αποθετήριο του συνόλου δεδομένων
τ.α.		τυπική απόκλιση
Ετικέτες δραστηριοτήτων στα σχήματα		
WALK	WALKING	βάδισμα
W.UP	WALKING_UPSTAIRS	ανάβαση σκάλας
W.DOWN	WALKING_DOWNSTAIRS	κατάβαση σκάλας
SIT	SITTING	καθιστή στάση
STAND	STANDING	όρθια στάση
LAY	LAYING	κατάκλιση

Κεφάλαιο 1

Εισαγωγή

1.1 Αναγνώριση Δραστηριότητας, Ιδιωτικότητα και Ομοσπονδιακή Μάθηση

Η αναγνώριση ανθρώπινης δραστηριότητας (*Human Activity Recognition*, HAR) από αισθητήρες κινητών συσκευών είναι σήμερα ένα ώριμο πεδίο. Το επιταχυνσιόμετρο και το γυροσκόπιο ενός συνηθισμένου έξυπνου κινητού τηλεφώνου αρκούν, για να διακριθούν βασικές δραστηριότητες, όπως το βάδισμα, η ανάβαση σκάλας ή η καθιστή στάση [1]. Η βιβλιογραφία διαθέτει, επίσης, τόσο καθιερωμένα σύνολα δεδομένων όσο και εκτενείς ανασκοπήσεις των μεθόδων που χρησιμοποιούνται [1], [2]. Οι εφαρμογές εκτείνονται από τα έξυπνα σπίτια και την υγειονομική περίθαλψη μέχρι τη βιομηχανική παραγωγή [2].

Η ίδια η φύση αυτών των δεδομένων, όμως, δημιουργεί ένα πρόβλημα που δε λύνεται με καλύτερο μοντέλο. Ένα ίχνος επιτάχυνσης δεν είναι ανώνυμο αλλά καταγράφει πότε κινείται κανείς, πόσο συχνά σηκώνεται και με τι ρυθμό περπατά. Η κλασική συνταγή της μηχανικής μάθησης, δηλαδή η συγκέντρωση όλων των δεδομένων σε έναν *server* και η εκπαίδευση εκεί, απαιτεί ακριβώς τη μεταφορά αυτής της πληροφορίας έξω από τη συσκευή του χρήστη. Οι McMahan et al. επισημαίνουν ρητά το εμπόδιο, σημειώνοντας ότι τα δεδομένα αυτά είναι συχνά ευαίσθητα ως προς την ιδιωτικότητα, μεγάλα σε όγκο ή και τα δύο, πράγμα που μπορεί να καθιστά απαγορευτική την καταγραφή τους σε κέντρο δεδομένων και την εκεί εκπαίδευση [3].

Η ομοσπονδιακή μάθηση (*Federated Learning*, FL) προτάθηκε ως απάντηση σε αυτό ακριβώς το εμπόδιο. Αντί να ταξιδεύουν τα δεδομένα προς το μοντέλο, ταξιδεύει το μοντέλο προς τα δεδομένα. Κάθε *client* εκπαιδεύει τοπικά ένα αντίγραφο, στέλνει πίσω μόνο το *update* των παραμέτρων και στη συνέχεια ένας server συνθέτει τα updates σε ένα *global model* [3]. Το πεδίο έχει έκτοτε ωριμάσει σε αυτόνομη ερευνητική κατεύθυνση, με καταγεγραμμένες τις ανοιχτές του προκλήσεις σε ετερογένεια, επικοινωνία και ιδιωτικότητα [4]. Η παρούσα εργασία τοποθετείται σε αυτό το πλαίσιο, με τα υποκείμενα ενός συνόλου δεδομένων HAR στον ρόλο των clients.

1.2 Το Πρόβλημα της Αποτίμησης της Συνεισφοράς

Η αποκέντρωση λύνει ένα πρόβλημα και δημιουργεί ένα δεύτερο. Όταν ο server δε βλέπει ποτέ τα δεδομένα, δεν μπορεί και να τα κρίνει. Δεν ξέρει ποιος συνεισέφερε πληροφορία που βελτίωσε πραγματικά το global model, ποιος επανέλαβε ό,τι υπήρχε ήδη και ποιος το τράβηξε προς λάθος κατεύθυνση. Το μόνο που βλέπει είναι ένα διάνυσμα παραμέτρων ανά *round*.

Αυτό δεν είναι απλώς ένα λογιστικό κενό. Η συμμετοχή σε μια ομοσπονδία έχει κόστος για τον client, σε ενέργεια, σε υπολογιστικούς πόρους, σε εύρος ζώνης και στον χρόνο κατά τον οποίο η συσκευή απασχολείται. Η βιβλιογραφία των μηχανισμών κινήτρων ξεκινά από την παρατήρηση ότι, χωρίς κάποια μορφή αποζημίωσης ή αναγνώρισης, οι clients δεν έχουν λόγο να συμμετέχουν και η επίδοση του συστήματος υποβαθμίζεται όταν οι πόροι δεν επαρκούν [5]. Κάθε τέτοιος μηχανισμός, όποια μορφή και αν πάρει, προϋποθέτει ένα μέτρο, δηλαδή κάποιον τρόπο να αποδοθεί σε κάθε client ένας αριθμός που να αντιστοιχεί στη συνεισφορά του. Μια δεύτερη ανασκόπηση καταγράφει ως τέτοια μέτρα τον όγκο δεδομένων, τους διαθέσιμους υπολογιστικούς πόρους και το Shapley value [6].

Αντικείμενο της εργασίας είναι αυτό το μέτρο, όχι ο μηχανισμός που θα χτιζόταν πάνω του. Συγκεκριμένα, η εργασία εξετάζει αν η συνεισφορά κάθε client σε μια ομοσπονδιακή εκπαίδευση HAR μπορεί να αποτιμηθεί, με μια θεμελιωμένη έννοια της θεωρίας συνεργατικών παιγνίων, σε υπολογιστικό κόστος που να επιτρέπει την πραγματική εκτέλεση. Εξετάζει, επίσης, τι λέει το αποτέλεσμα για τους ίδιους τους ανθρώπους πίσω από τα δεδομένα.

1.3 Ερευνητικά Ερωτήματα

Η εργασία οργανώνεται γύρω από τρία ερωτήματα, καθένα από τα οποία απαντάται ρητά στην Ενότητα 6.1.

1. **Τι κοστίζει η ομοσπονδιακή εκπαίδευση σε *accuracy*;** Η σύγκριση γίνεται με δύο σημεία αναφοράς. Το πρώτο είναι η κεντρική εκπαίδευση, όπου όλα τα δεδομένα είναι διαθέσιμα μαζί. Το δεύτερο είναι η ατομική εκπαίδευση, όπου κάθε client μένει μόνος με τα δικά του. Οι τρεις αυτές ρυθμίσεις ονομάζονται στο εξής *τοπολογίες μάθησης*.

2. **Αποτιμάται η συνεισφορά κάθε client με Shapley σε ρεαλιστικό υπολογιστικό κόστος;** Ο ακριβής υπολογισμός είναι εκθετικός ως προς το πλήθος των παικτών. Το ερώτημα είναι αν οι διαθέσιμοι εκτιμητές δίνουν σταθερό και επαληθεύσιμο αποτέλεσμα στο μέγεθος παιγνίου της εργασίας.

3. **Τι σημαίνει αρνητική συνεισφορά;** Το ερώτημα έχει δύο μέρη. Το πρώτο είναι *τι ξεχωρίζει* τους clients που λαμβάνουν αρνητική τιμή. Το δεύτερο, το οποίο είναι και το

κρισιμότερο για κάθε πρακτική χρήση, είναι αν η τιμή αυτή είναι *αξιοποιήσιμη*. Με άλλα λόγια, το δεύτερο μέρος διερευνά αν η αρνητική συνεισφορά αποτυπώνει ιδιότητα των δεδομένων ενός ανθρώπου, η οποία μεταφέρεται εκτός του συνόλου στο οποίο μετρήθηκε, ή ιδιότητα του τρόπου με τον οποίο τα updates συναθροίζονται.

1.4 Συνεισφορά της Εργασίας

Η εργασία συνεισφέρει σε δύο σημεία.

1. **Μια ελεγχόμενη σύγκριση τριών τοπολογιών μάθησης.** Η κεντρική, η ομοσπονδιακή και η ατομική εκπαίδευση συγκρίνονται, ενώ όλες οι υπόλοιπες επιλογές μένουν κοινές, δηλαδή το ίδιο μοντέλο, ο ίδιος βρόχος εκπαίδευσης και το ίδιο *test set*. Έτσι, κάθε διαφορά μπορεί να αποδοθεί στον τρόπο εκπαίδευσης. Η σύγκριση δείχνει τι κοστίζει η αποκέντρωση και τι κερδίζει κάθε client από τη συνεργασία. Τα αποτελέσματα παρουσιάζονται στο Κεφάλαιο 4.

2. **Η αποτίμηση της συνεισφοράς κάθε client και η ανάλυση των αρνητικών τιμών.** Η συνεισφορά αποτιμάται με το Shapley value, με δύο ανεξάρτητους εκτιμητές που ελέγχονται μεταξύ τους και απέναντι στον ορισμό. Όπου η συνεισφορά βγαίνει αρνητική, ελέγχεται πρώτα ότι το γεγονός αυτό δεν οφείλεται σε σφάλμα εκτίμησης. Στη συνέχεια, ένα δεύτερο παίγνιο, όπου κάθε ομάδα clients αποτιμάται με ένα κεντρικό (*centralized*) μοντέλο εκπαιδευμένο από την αρχή με τα δεδομένα της, χωρίς updates και *aggregation*, ελέγχει αν τα δεδομένα των clients με αρνητική τιμή βλάπτουν και εκεί. Το *failure analysis* εξετάζει έπειτα πότε και πού εμφανίζεται η αρνητική τιμή και αν μπορεί να χρησιμοποιηθεί ως κριτήριο απόφασης. Τα αποτελέσματα παρουσιάζονται στο Κεφάλαιο 5.

1.5 Διάρθρωση της Εργασίας

Η διάρθρωση ακολουθεί τον οδηγό συγγραφής της ερευνητικής μονάδας Euclid [7]. Στο Κεφάλαιο 2 αναπτύσσεται το υπόβαθρο της εργασίας, δηλαδή τα δίκτυα *Multilayer Perceptron*, οι μετρικές αξιολόγησης, τα μέτρα συσχέτισης, η ομοσπονδιακή μάθηση, ο FedAvg και η θεωρία συνεργατικών παιγνίων, πάνω στην οποία εδράζεται η αποτίμηση συνεισφοράς. Στο τέλος του κεφαλαίου παρουσιάζονται η σχετική βιβλιογραφία και τα σημεία διαφοροποίησης της εργασίας από αυτήν.

Στο Κεφάλαιο 3 εισάγεται η έννοια της αναγνώρισης δραστηριότητας από αισθητήρες και παρουσιάζονται το σύνολο δεδομένων, οι έλεγχοι ακεραιότητας, η διερευνητική ανάλυση και

το πρωτόκολλο προεπεξεργασίας. Στο Κεφάλαιο 4 περιγράφονται η υλοποίηση, το μοντέλο και το πειραματικό πρωτόκολλο, συγκρίνονται οι τρεις τοπολογίες μάθησης και αναλύονται τα σφάλματα του μοντέλου. Στο Κεφάλαιο 5 αναπτύσσεται η αποτίμηση συνεισφοράς. Αρχικά ορίζεται το παίγνιο και παρουσιάζονται οι εκτιμητές. Έπονται οι αρνητικές τιμές και η ανάλυσή τους, ενώ στο τέλος υπολογίζονται τα μερίδια ανταμοιβής. Το Κεφάλαιο 6 αποτελεί σύνοψη, στην οποία δηλώνονται οι περιορισμοί και προτείνονται κατευθύνσεις συνέχειας.

Κεφάλαιο 2

Θεωρητικό Υπόβαθρο

Το κεφάλαιο αυτό εστιάζει αποκλειστικά στο θεωρητικό υπόβαθρο που χρειάζεται η υπόλοιπη εργασία. Ξεκινά παρουσιάζοντας το είδος του νευρωνικού δικτύου που χρησιμοποιείται, τις μετρικές με τις οποίες αποτιμάται και τα μέτρα συσχέτισης της ανάλυσης, συνεχίζει με την ομοσπονδιακή μάθηση και καταλήγει στη θεωρία των συνεργατικών παιγνίων, στην οποία θεμελιώνεται το μέτρο συνεισφοράς του Κεφαλαίου 5. Στην τελευταία ενότητα παρουσιάζονται η σχετική βιβλιογραφία και τα σημεία διαφοροποίησης της εργασίας από αυτήν.

2.1 Νευρωνικά Δίκτυα Multilayer Perceptron

2.1.1 Δομή, εκπαίδευση και κανονικοποίηση

Ένα δίκτυο *Multilayer Perceptron* (MLP), δηλαδή ένα πολυεπίπεδο δίκτυο εμπρόσθιας τροφοδότησης, μετατρέπει ένα διάνυσμα εισόδου σε μια πρόβλεψη μέσα από διαδοχικά επίπεδα. Κάθε επίπεδο παίρνει την έξοδο του προηγούμενου, σχηματίζει σταθμισμένα αθροίσματά της και εφαρμόζει στο αποτέλεσμα μια μη γραμμική συνάρτηση ενεργοποίησης. Τα βάρη αυτών των αθροισμάτων είναι οι παράμετροι που μαθαίνει το δίκτυο. Η μη γραμμικότητα είναι απαραίτητη, γιατί χωρίς αυτήν πολλά επίπεδα στη σειρά θα ισοδυναμούσαν με ένα μόνο γραμμικό επίπεδο. Μια συνηθισμένη επιλογή είναι η ReLU, που μηδενίζει τις αρνητικές τιμές και αφήνει τις θετικές ανέπαφες [8].

Σε πρόβλημα ταξινόμησης, το τελευταίο επίπεδο δίνει μία τιμή για κάθε κλάση και η συνάρτηση *softmax* τις μετατρέπει σε πιθανότητες που αθροίζονται στη μονάδα. Η εκπαίδευση προσαρμόζει τα βάρη, ώστε να μεγιστοποιείται η πιθανότητα σωστής κλάσης, ελαχιστοποιώντας το *cross-entropy* [8]. Για να γίνει αυτό, υπολογίζεται πώς μεταβάλλεται το σφάλμα ως προς κάθε βάρος με *backpropagation*, από την έξοδο προς την είσοδο [8]. Στη συνέχεια, τα βάρη μετακινούνται λίγο προς την κατεύθυνση που μειώνει το σφάλμα. Ο αλγόριθμος Adam, που χρησιμοποιείται σε αυτήν την εργασία, προσαρμόζει το μέγεθος αυτού του βήματος, χωριστά για κάθε παράμετρο [9].

Ένα δίκτυο με πολλές παραμέτρους μπορεί να απομνημονεύσει τα δεδομένα εκπαίδευσης, αντί να μάθει κάτι που γενικεύεται. Μια απλή άμυνα είναι το *dropout*, που κατά την εκπαίδευση απενεργοποιεί τυχαία ένα μέρος των μονάδων σε κάθε πέρασμα, ώστε καμία να μη στηρίζεται υπερβολικά σε συγκεκριμένες άλλες [10]. Κατά την αξιολόγηση, χρησιμοποιείται ολόκληρο το δίκτυο. Η αρχιτεκτονική που χρησιμοποιείται και οι τιμές των παραμέτρων της δίνονται στην Ενότητα 4.2.

2.1.2 Μετρικές αξιολόγησης ταξινόμησης

Η βάση κάθε μετρικής ταξινόμησης είναι το *confusion matrix* C, όπου το στοιχείο C_{ij} μετράει πόσα samples πραγματικής κλάσης i ταξινομήθηκαν ως κλάση j [11]. Τα διαγώνια στοιχεία είναι οι σωστές προβλέψεις και όλα τα υπόλοιπα είναι λάθη. Η θέση κάθε λάθους αποτυπώνει ποιο ακριβώς ζεύγος κλάσεων συγχέεται και γι' αυτό ο πίνακας αυτός διαβάζεται και ανεξάρτητα, όχι μόνο μέσα από τις παραγόμενες μετρικές ταξινόμησης.

Το *accuracy* είναι το κλάσμα των σωστών προβλέψεων προς το σύνολο:

$$\text{Acc} = \frac{\sum_{i=1}^{K} C_{ii}}{\sum_{i=1}^{K} \sum_{j=1}^{K} C_{ij}}, \tag{2.1}$$

όπου K το πλήθος των κλάσεων. Κινείται στο $[0, 1]$ και όσο μεγαλύτερο τόσο καλύτερα. Το μειονέκτημά του είναι το γεγονός ότι μετράει samples και όχι κλάσεις, οπότε μια κλάση με λίγα samples μπορεί να ταξινομείται συστηματικά λάθος, χωρίς το accuracy να το επισημάνει.

Για να αναδειχθεί τι συμβαίνει σε κάθε κλάση χωριστά, χρησιμοποιούνται δύο μεγέθη. Το *precision* της κλάσης i είναι το ποσοστό των προβλέψεων υπέρ της i που ήταν σωστές. Το *recall* είναι το ποσοστό των samples της i που βρέθηκαν:

$$P_i = \frac{C_{ii}}{\sum_{j=1}^{K} C_{ji}}, \qquad R_i = \frac{C_{ii}}{\sum_{j=1}^{K} C_{ij}}. \tag{2.2}$$

Και τα δύο έχουν στον αριθμητή τις σωστές προβλέψεις της κλάσης (C_{ii}) και διαφέρουν μόνο στον παρονομαστή. Το precision διαιρεί με το άθροισμα της στήλης i, δηλαδή με όσα samples το μοντέλο *ονόμασε* i. Επομένως, «τιμωρεί» τους ψευδείς συναγερμούς. Το recall διαιρεί με το άθροισμα της γραμμής i, δηλαδή με όσα samples *ήταν* i. Έτσι, «τιμωρεί» τις παραλείψεις. Ένα μοντέλο που σπάνια προβλέπει την κλάση i μπορεί να έχει υψηλό precision και χαμηλό recall, ενώ ένα μοντέλο που την προβλέπει πολύ συχνά μπορεί να έχει χαμηλό precision και υψηλό recall.

Το *F1-score* ενώνει τα δύο σε έναν αριθμό, ως αρμονικό τους μέσο:

$$F_{1,i} = \frac{2\,P_i\,R_i}{P_i + R_i}. \tag{2.3}$$

Ο αρμονικός μέσος προτιμάται από τον αριθμητικό, γιατί καθορίζεται κυρίως από τον μικρότερο από τους δύο όρους. Με precision 100% και recall 10%, για παράδειγμα, ο αριθμητικός μέσος θα ήταν 55%, ενώ το F1 είναι περίπου 18%. Μια κλάση δε σημειώνει, επομένως, καλό F1, αν αποτυγχάνει σε ένα από τα δύο. Το *macro-F1* είναι ο απλός μέσος όρος των $F_{1,i}$ της Εξίσωσης (2.3) πάνω στις K κλάσεις [12],

$$F_1^M = \frac{1}{K}\sum_{i=1}^{K} F_{1,i}, \tag{2.4}$$

οπότε κάθε κλάση μετράει το ίδιο, ανεξάρτητα από το πόσα samples έχει [11].

Στη συγκεκριμένη εργασία, κύρια μετρική είναι το accuracy. Το macro-F1 αναφέρεται δίπλα του για δύο λόγους. Ο πρώτος είναι ότι ένα υψηλό accuracy μπορεί να κρύβει μια κλάση που ταξινομείται συστηματικά λάθος, ενώ το macro-F1 θα την έδειχνε. Όταν οι δύο μετρικές δίνουν σχεδόν την ίδια τιμή, αυτό είναι ένδειξη ότι καμία κλάση δε μένει πίσω. Όταν αποκλίνουν, η απόκλιση δείχνει ότι κάποια κλάση υστερεί. Ο δεύτερος λόγος αφορά την αποτίμηση της συνεισφοράς, όπου η συνάρτηση αξίας είναι η ίδια μια μετρική. Οι Sokolova και Lapalme ονομάζουν μια μετρική αμετάβλητη, ως προς μια αλλαγή του confusion matrix, όταν η τιμή της δεν τροποποιείται, δηλαδή όταν *δεν ανιχνεύει* την αλλαγή [11]. Το accuracy είναι αμετάβλητο σε ανακατανομές μεταξύ κλάσεων, ενώ το precision, το recall και το F1 είναι ευαίσθητα στην ασυμμετρία της ταξινόμησης [11]. Γι' αυτό η αποτίμηση επαναλαμβάνεται και με το macro-F1, ώστε να φανεί αν τα συμπεράσματα εξαρτώνται από την επιλογή της μετρικής (Κεφάλαιο 5).

Ο υπολογισμός των μετρικών στην υλοποίηση γίνεται με τη βιβλιοθήκη scikit-learn [13].

2.1.3 Μέτρα συσχέτισης και συμφωνίας κατάταξης

Τα μέτρα συσχέτισης συγκρίνουν δύο σειρές μετρήσεων $x_1, \ldots, x_m$ και $y_1, \ldots, y_m$, όπου το x_i και το y_i αφορούν το ίδιο αντικείμενο i. Οι τρεις συντελεστές που ακολουθούν μετρούν, ο καθένας με διαφορετικό κριτήριο, πόσο κινούνται μαζί οι δύο σειρές και παίρνουν τιμές από -1 έως $+1$. Η τιμή p συνοδεύει έναν συντελεστή και δείχνει αν η σχέση που μετρήθηκε θα μπορούσε να οφείλεται σε τύχη.

Ο *συντελεστής Pearson* r μετρά πόσο κοντά σε μια ευθεία βρίσκονται τα σημεία (x_i, y_i), δηλαδή αν οι *τιμές* της μίας σειράς μεταβάλλονται αναλογικά με τις τιμές της άλλης. Ορίζεται ως

$$r = \frac{\sum_{i=1}^{m}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{m}(x_i - \bar{x})^2}\,\sqrt{\sum_{i=1}^{m}(y_i - \bar{y})^2}}, \tag{2.5}$$

όπου $\bar{x}$ και $\bar{y}$ οι μέσοι όροι των δύο σειρών. Ο αριθμητής αθροίζει γινόμενα αποκλίσεων από τον μέσο όρο. Ένας όρος του είναι θετικός, όταν το x_i και το y_i βρίσκονται από την ίδια πλευρά του μέσου όρου τους. Όταν βρίσκονται από αντίθετες πλευρές, είναι αρνητικός. Ο παρονομαστής διαιρεί με το μέγεθος των αποκλίσεων, ώστε το r να μην εξαρτάται από τις μονάδες μέτρησης. Στο $+1$ όλα τα σημεία πέφτουν πάνω σε μια ανοδική ευθεία, στο -1 πάνω σε μια καθοδική και στο 0 δεν υπάρχει γραμμική σχέση. Για τις σειρές $x = (1, 2, 3, 4)$ και $y = (2, 4, 6, 8)$, για παράδειγμα, $r = 1$, αφού κάθε y_i είναι διπλάσιο του x_i. Το τετράγωνο r^2 είναι το ποσοστό της διακύμανσης της μίας σειράς που εξηγεί η γραμμική σχέση με την άλλη. Με $r = 0{,}5$ εξηγείται το 25% της διακύμανσης και το 75% μένει ανεξήγητο.

Ο *συντελεστής Spearman* ρ μετρά αν η μία σειρά ανεβαίνει κάθε φορά που ανεβαίνει η άλλη, ακόμη κι αν η σχέση τους δεν είναι ευθεία. Κάθε τιμή αντικαθίσταται από τη θέση της μέσα στη σειρά της (1 για τη μικρότερη, 2 για την επόμενη κ.ο.κ.) και η Εξίσωση (2.5) εφαρμόζεται στις θέσεις. Όταν δεν υπάρχουν ίσες τιμές, το αποτέλεσμα γράφεται ως

$$\rho = 1 - \frac{6\sum_{i=1}^{m} d_i^2}{m\,(m^2 - 1)}, \tag{2.6}$$

όπου d_i η διαφορά των θέσεων του αντικειμένου i στις δύο σειρές. Όταν οι θέσεις ταυτίζονται, όλα τα d_i είναι μηδέν και $\rho = 1$. Ο αριθμητής μεγαλώνει όσο απομακρύνονται οι θέσεις και ο παρονομαστής είναι τέτοιος, ώστε $\rho = -1$, όταν η μία σειρά είναι η αντίστροφη της άλλης. Για τις σειρές $x = (1, 2, 3, 4)$ και $y = (1, 2, 4, 16)$, το y ανεβαίνει πάντα μαζί με το x και μάλιστα όλο και πιο απότομα. Οι θέσεις είναι ίδιες και στις δύο σειρές, οπότε $\rho = 1$, ενώ $r \approx 0{,}87$, αφού τα σημεία δε βρίσκονται σε ευθεία.

Ο *συντελεστής Kendall* τ μετρά συμφωνία *κατάταξης* και όχι τιμών. Εξετάζει όλα τα ζεύγη αντικειμένων. Ένα ζεύγος είναι *σύμφωνο*, όταν οι δύο σειρές βάζουν τα δύο αντικείμενα με την ίδια σειρά. Αν τα βάζουν με αντίθετη σειρά, είναι *ασύμφωνο*. Ο συντελεστής ορίζεται ως

$$\tau = \frac{(\text{σύμφωνα}) - (\text{ασύμφωνα})}{\binom{m}{2}}, \tag{2.7}$$

όπου $\binom{m}{2} = m(m-1)/2$ το πλήθος των ζευγών. Ένα ζεύγος με ίσες τιμές σε μία από τις δύο σειρές δεν είναι ούτε σύμφωνο ούτε ασύμφωνο. Η τιμή κινείται από -1, όταν η μία κατάταξη είναι η αντίστροφη της άλλης, έως $+1$, όταν οι δύο κατατάξεις ταυτίζονται. Στο 0 τα σύμφωνα και τα ασύμφωνα ζεύγη είναι ισάριθμα. Όταν δεν υπάρχουν ίσες τιμές, το $(1+\tau)/2$ είναι το ποσοστό των σύμφωνων ζευγών, οπότε ένα $\tau = 0{,}9$ σημαίνει ότι το 95% των ζευγών έχει την ίδια σειρά και στις δύο κατατάξεις. Αν, για παράδειγμα, δύο κριτές κατατάσσουν τρεις υποψηφίους ως (Α, Β, Γ) και (Α, Γ, Β), από τα τρία ζεύγη τα δύο είναι σύμφωνα (Α με Β και Α με Γ) και το ένα ασύμφωνο (Β με Γ), οπότε $\tau = (2-1)/3 \approx 0{,}33$. Όσο μεγαλώνει το m, τόσο λιγότερο μετρά κάθε ασύμφωνο ζεύγος. Με $m = 21$ υπάρχουν $\binom{21}{2} = 210$ ζεύγη και κάθε ασύμφωνο ζεύγος μειώνει το τ κατά $2/210 \approx 0{,}0095$ από το $+1$.

Η *τιμή* p συνοδεύει έναν συντελεστή c, δηλαδή ένα r, ένα ρ ή ένα τ. Είναι η πιθανότητα να μετρηθεί συσχέτιση τουλάχιστον τόσο ισχυρή όσο η μετρημένη, αν οι δύο σειρές δεν είχαν στην πραγματικότητα καμία σχέση,

$$p = \Pr\big(|c_0| \geq |c|\big), \tag{2.8}$$

όπου c_0 ο ίδιος συντελεστής για δύο ανεξάρτητες σειρές με το ίδιο πλήθος m. Μικρό p σημαίνει ότι μια τέτοια συσχέτιση δύσκολα θα προέκυπτε από τύχη. Συνήθως, ως όριο στατιστικής σημαντικότητας θεωρείται το $p < 0{,}05$, δηλαδή λιγότερο από μία πιθανότητα στις είκοσι. Το πόσο ισχυρή πρέπει να είναι μια συσχέτιση για να περάσει το όριο εξαρτάται από το m. Με $m = 21$ χρειάζεται $|r|$ μεγαλύτερο από $0{,}43$ περίπου, ενώ με $m = 100$ αρκεί $|r|$ μεγαλύτερο από $0{,}20$. Το p δεν είναι, επομένως, μέτρο της έντασης της σχέσης. Ούτε αποδεικνύει αιτία, αφού δύο σειρές μπορεί να κινούνται μαζί, επειδή εξαρτώνται και οι δύο από κάτι τρίτο.

Ο Πίνακας 2.1 συνοψίζει τα τέσσερα μεγέθη. Ποια τιμή είναι καλή εξαρτάται από το ερώτημα. Όταν δύο μέθοδοι μετρούν το ίδιο πράγμα, όπως δύο κριτές που βαθμολογούν τους ίδιους υποψηφίους, αναμένεται τιμή κοντά στο $+1$ και στους τρεις συντελεστές. Από αυτούς, ο Kendall είναι ο αυστηρότερος, γιατί μετρά κάθε ζεύγος που αλλάζει σειρά, ακόμη κι αν οι δύο τιμές του είναι σχεδόν ίσες. Όταν ελέγχεται αν ένα μέγεθος εξηγεί ένα άλλο, ζητείται συντελεστής μακριά από το 0 μαζί με $p < 0{,}05$. Ένας συντελεστής κοντά στο 0 ή ένα p πάνω από το όριο σημαίνει ότι τα δεδομένα δε στηρίζουν την εξήγηση. Τα μεγέθη διαβάζονται, τέλος, μαζί. Ένα υψηλό r με χαμηλότερο τ, για παράδειγμα, σημαίνει ότι οι τιμές συμφωνούν συνολικά, αλλά η σειρά αλλάζει ανάμεσα σε αντικείμενα με κοντινές τιμές.

Μέγεθος	**Τι μετρά**	**Εύρος**	**Πώς διαβάζεται μια τιμή**
Pearson r	πόσο κοντά σε μια ευθεία βρίσκονται τα ζεύγη τιμών	-1 έως $+1$	το r^2 είναι το ποσοστό της διακύμανσης που εξηγεί η γραμμική σχέση ($r = 0{,}5$ δίνει 25%)
Spearman ρ	αν η μία σειρά ανεβαίνει όταν ανεβαίνει η άλλη	-1 έως $+1$	$+1$ όταν οι θέσεις ταυτίζονται, όποιο κι αν είναι το σχήμα της σχέσης
Kendall τ	πόσα ζεύγη αντικειμένων έχουν την ίδια σειρά και στις δύο κατατάξεις	-1 έως $+1$	το $(1+\tau)/2$ είναι το ποσοστό των σύμφωνων ζευγών ($\tau = 0{,}9$ δίνει 95%)
Τιμή p	αν η μετρημένη συσχέτιση θα μπορούσε να οφείλεται σε τύχη	0 έως 1	κάτω από $0{,}05$ η συσχέτιση θεωρείται στατιστικά σημαντική

Πίνακας 2.1. Οι τρεις συντελεστές και η τιμή p. Οι συντελεστές είναι $+1$ σε πλήρη συμφωνία, -1 σε πλήρη αντιστροφή και 0 όταν δεν υπάρχει σχέση του είδους που μετρά ο καθένας.

2.2 Ομοσπονδιακή Μάθηση

2.2.1 Αρχιτεκτονική server και clients

Στην ομοσπονδιακή μάθηση ένα *global model* εκπαιδεύεται από πολλούς *clients* υπό τον συντονισμό ενός *server*, χωρίς τα δεδομένα εκπαίδευσης να φύγουν ποτέ από τη συσκευή στην οποία παρήχθησαν [3]. Ο server κρατά το τρέχον global model και, σε κάθε *round*, το στέλνει στους επιλεγμένους clients. Κάθε client εκπαιδεύει τοπικά για έναν συμφωνημένο αριθμό *local steps* και επιστρέφει τις ενημερωμένες παραμέτρους. Ο server τις συναθροίζει και το round κλείνει.

Η ρύθμιση αυτή φέρνει τρία χαρακτηριστικά που δεν εμφανίζονται στην κατανεμημένη εκπαίδευση μέσα σε κέντρο δεδομένων. Τα δεδομένα δεν είναι ισόνομα κατανεμημένα (*non-IID*), γιατί αντανακλούν τη συμπεριφορά συγκεκριμένων ανθρώπων. Δεν είναι ισομεγέθη, γιατί κανείς δεν ελέγχει πόσα samples θα παράγει ο καθένας. Τέλος, το πλήθος των clients μπορεί να είναι πολύ μεγαλύτερο από τον μέσο αριθμό samples ανά client [3].

Η βιβλιογραφία διακρίνει δύο βασικές ρυθμίσεις. Η *cross-device* αφορά πολύ μεγάλο πλήθος αναξιόπιστων συσκευών, ενώ η *cross-silo* λίγους σταθερούς οργανισμούς [4]. Η παρούσα εργασία βρίσκεται ανάμεσα στις δύο. Ως προς τη μηχανική, μοιάζει με τη δεύτερη, με λίγους clients, όλους διαθέσιμους σε κάθε round, ενώ ως προς τη σημασιολογία ακολουθεί την πρώτη, αφού κάθε client είναι ένα άτομο και όχι ένας οργανισμός. Η ακριβής ρύθμιση περιγράφεται στα Κεφάλαια 3 και 4.

2.2.2 Ο αλγόριθμος FedAvg

Ο βασικός αλγόριθμος της ομοσπονδιακής μάθησης είναι ο *Federated Averaging* (FedAvg). Ο στόχος που ελαχιστοποιείται είναι ο σταθμισμένος μέσος των τοπικών συναρτήσεων κόστους:

$$f(\mathbf{w}) = \sum_{k=1}^{K} \frac{n_k}{n} F_k(\mathbf{w}), \qquad n = \sum_{k=1}^{K} n_k, \tag{2.9}$$

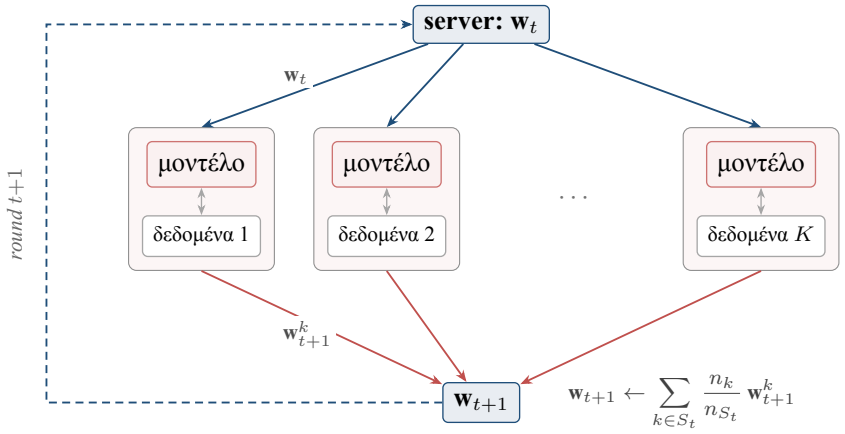
όπου K το πλήθος των clients, n_k το πλήθος samples του client k, n το συνολικό πλήθος και F_k το μέσο κόστος του k πάνω στα δικά του δεδομένα [3]. Τα βάρη n_k/n δεν είναι σχεδιαστική επιλογή αλλά συνέπεια του ορισμού, γιατί, αν συγκεντρώνονταν όλα τα δεδομένα, το μέσο κόστος θα ήταν ακριβώς αυτή η έκφραση.

Σε κάθε round t, κάθε επιλεγμένος client ξεκινά από το global model $\mathbf{w}_t$, εκτελεί E *local epochs* (πλήρη περάσματα πάνω στα τοπικά δεδομένα) με *batch size* B και παράγει $\mathbf{w}_{t+1}^k$. Ο server συνθέτει:

$$\mathbf{w}_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{n_{S_t}} \mathbf{w}_{t+1}^k, \tag{2.10}$$

όπου S_t το σύνολο των clients του round και $n_{S_t} = \sum_{k \in S_t} n_k$ το πλήθος των samples τους [3]. Ο αλγόριθμος ελέγχεται από τρεις παραμέτρους, δηλαδή το κλάσμα C των clients που υπολογίζουν σε κάθε round, τον αριθμό E των local epochs πάνω στα δεδομένα τους και το batch size B [3]. Η επιλογή τους στην παρούσα εργασία τεκμηριώνεται στις Ενότητες 4.2 και 4.3.2. Το E ελέγχεται, επιπλέον, εμπειρικά στην Ενότητα 4.6.3.

Το Σχήμα 2.1 συνοψίζει το round.



Σχήμα 2.1. Ένα round. Ο server εκπέμπει το global model, κάθε client το εκπαιδεύει E epochs πάνω στα δικά του δεδομένα και επιστρέφει *μόνο* τις παραμέτρους. Τα δεδομένα δε βγαίνουν ποτέ από το πλαίσιο του client. Ο σταθμισμένος μέσος δίνει το μοντέλο του επόμενου round.

Μεταξύ server και clients κινούνται μόνο παράμετροι μοντέλου, δηλαδή ένα διάνυσμα σταθερού μεγέθους ανεξάρτητο από το πλήθος των τοπικών samples. Αυτό είναι ταυτόχρονα

το πλεονέκτημα επικοινωνίας του σχήματος και ο λόγος για τον οποίο ο server δεν έχει καμία άμεση πρόσβαση στην ποιότητα των δεδομένων, πρόβλημα που πραγματεύεται το Κεφάλαιο 5.

2.2.3 Ετερογένεια και client drift

Η ετερογένεια σε ένα ομοσπονδιακό σύστημα έχει δύο ανεξάρτητες όψεις. Η *ετερογένεια συστημάτων* αφορά τις διαφορές στους πόρους των clients. Η *στατιστική ετερογένεια* αναφέρεται στις διαφορές στις κατανομές των δεδομένων τους [14]. Η παρούσα εργασία εκτελείται σε ομοιόμορφο υλικό, οπότε η πρώτη δεν εμφανίζεται. Η δεύτερη είναι το αντικείμενο.

Όταν οι τοπικές κατανομές διαφέρουν, τα τοπικά ελάχιστα των F_k δε συμπίπτουν. Κάθε client, εκτελώντας πολλά local steps, κινείται προς το δικό του ελάχιστο και όχι προς το ελάχιστο της Εξίσωσης (2.9). Οι Karimireddy et al. ονομάζουν το φαινόμενο *client drift* και το περιγράφουν ως απόκλιση που εισάγεται στα updates κάθε client, με αποτέλεσμα αργή και ασταθή σύγκλιση [15]. Ο μέσος όρος πολλών updates που δείχνουν προς διαφορετικές κατευθύνσεις είναι μικρότερος σε μέτρο και όχι απαραίτητα σωστός σε κατεύθυνση.

Δύο σημεία αυτής της ανάλυσης χρησιμοποιούνται αργότερα. Πρώτον, η απόκλιση *επιμένει* ακόμη και όταν χρησιμοποιούνται *full-batch gradients* και όταν όλοι οι clients συμμετέχουν σε κάθε round της εκπαίδευσης [15]. Αυτό σημαίνει ότι το *full participation* δεν κρύβει το φαινόμενο αλλά το απομονώνει, κάτι που αξιοποιείται στον σχεδιασμό της Ενότητας 4.3.2. Δεύτερον, όσο περισσότερα local steps μεσολαβούν μεταξύ δύο aggregations, τόσο μεγαλύτερη είναι η απόκλιση [15], πράγμα που ελέγχεται εμπειρικά στην Ενότητα 4.6.3. Το φαινόμενο επανέρχεται και στο Κεφάλαιο 5, στην ερμηνεία της συνεισφοράς των clients.

2.2.4 Εγγυήσεις και όρια ιδιωτικότητας

Η ομοσπονδιακή μάθηση περιορίζει την έκθεση των δεδομένων, αλλά δεν την εξαλείφει. Η αρχή της ελαχιστοποίησης δεδομένων ικανοποιείται από το γεγονός ότι τα ακατέργαστα δεδομένα δε φεύγουν ποτέ από τη συσκευή, όμως τα ίδια τα updates παραμέτρων φέρουν πληροφορία για τα δεδομένα που τα παρήγαγαν. Η ανασκόπηση του πεδίου δηλώνει ρητά ότι τα χαρακτηριστικά αυτά προσφέρουν σημαντικές πρακτικές βελτιώσεις ιδιωτικότητας έναντι της συγκέντρωσης όλων των δεδομένων, αλλά δεν αποτελούν εγγύηση [4].

Οι τυπικές εγγυήσεις απαιτούν πρόσθετους μηχανισμούς. Το *differential privacy* επιτυγχάνεται με ψαλίδισμα της συνεισφοράς κάθε παραδείγματος και προσθήκη βαθμονομημένου θορύβου στα gradients πριν από το update [16]. Το *secure aggregation* επιτρέπει στον server να μάθει μόνο το άθροισμα των updates και όχι τους επιμέρους όρους [4].

Καμία από τις δύο δεν υλοποιείται στην παρούσα εργασία και αυτό δηλώνεται ως όριο. Ο λόγος είναι το γεγονός ότι και οι δύο παρεμβαίνουν στα ίδια τα updates, αφού ο θόρυβος του differential privacy αλλάζει τα $\mathbf{w}_{t+1}^k$ και το secure aggregation τα κρύβει από τον server. Η αποτίμηση συνεισφοράς του Κεφαλαίου 5 στηρίζεται ακριβώς στο να είναι τα επιμέρους updates ορατά και ανασυνθέσιμα. Η αλληλεπίδραση των δύο απαιτήσεων είναι ανοιχτό ζήτημα και σημειώνεται στην Ενότητα 6.3.

2.3 Συνεργατικά Παίγνια και Αποτίμηση Συνεισφοράς

2.3.1 Συνεργατικά παίγνια και χαρακτηριστική συνάρτηση

Ένα συνεργατικό παίγνιο ορίζεται από ένα πεπερασμένο σύνολο παικτών N και μια *χαρακτηριστική συνάρτηση* v, η οποία αποδίδει σε κάθε υποσύνολο $S \subseteq N$ έναν πραγματικό αριθμό $v(S)$, δηλαδή την αξία που μπορεί να εξασφαλίσει ο συνασπισμός S δρώντας μόνος του. Στον κλασικό ορισμό, ο κενός συνασπισμός δεν αξίζει τίποτα ($v(\emptyset) = 0$) και η ένωση δύο ξένων συνασπισμών δεν αξίζει λιγότερο από το άθροισμά τους, $v(S \cup T) \geq v(S) + v(T)$ για $S \cap T = \emptyset$ [17].

Το ερώτημα που θέτει η θεωρία είναι ερώτημα κατανομής. Δεδομένης της v, ζητείται να εντοπιστεί πώς μοιράζεται η συνολική αξία $v(N)$ στους επιμέρους παίκτες με τρόπο που να μπορεί να υπερασπιστεί κανείς. Η απάντηση δεν είναι προφανής, γιατί η αξία ενός παίκτη εξαρτάται από το σύνολο στο οποίο συγκαταλέγεται. Ο ίδιος παίκτης μπορεί να είναι αναντικατάστατος σε έναν μικρό συνασπισμό και περιττός σε έναν μεγάλο που ήδη περιέχει κάποιον με πανομοιότυπα χαρακτηριστικά.

2.3.2 Το Shapley value και τα τρία αξιώματα

Ο Shapley προσέγγισε το πρόβλημα αξιωματικά. Αντί να προτείνει έναν τύπο και να τον δικαιολογήσει, διατύπωσε ιδιότητες που οφείλει να έχει κάθε λογική κατανομή και έδειξε ότι τις ικανοποιεί μία *μοναδική* συνάρτηση. Τα αξιώματα είναι **τρία** [17]:

1. **Συμμετρία.** Η κατανομή δεν εξαρτάται από τα ονόματα των παικτών. Αν μια μετάθεση των παικτών αφήνει τη v αναλλοίωτη, μεταθέτει αντίστοιχα και τις τιμές.
2. **Αποδοτικότητα.** Το άθροισμα των τιμών ισούται με τη συνολική αξία, $\sum_{i \in N} \varphi_i = v(N)$. Τίποτα δε χάνεται και τίποτα δε δημιουργείται κατά τη διανομή.
3. **Νόμος της άθροισης.** Η κατανομή είναι προσθετική ως προς το παίγνιο, δηλαδή $\varphi[v + w] = \varphi[v] + \varphi[w]$. Αν δύο παίγνια παίζονται μαζί, οι τιμές προστίθενται.

Η ιδιότητα του *μηδενικού παίκτη*, δηλαδή ότι όποιος δεν προσθέτει τίποτα σε κανέναν συνασπισμό παίρνει μηδέν, δεν είναι αξίωμα αλλά αποδεικνύεται ως Λήμμα 1 [17]. Το ίδιο ισχύει για τον *dummy* παίκτη, ο οποίος παίρνει ακριβώς $v(\{i\})$. Η ιδιότητα αυτή προκύπτει ως Πόρισμα 1 [17]. Η διάκριση έχει σημασία για τη σωστή παρουσίαση, γιατί πρόκειται για τρία αξιώματα από τα οποία παράγονται οι υπόλοιπες ιδιότητες και όχι για τέσσερα ισότιμα αξιώματα.

Η μοναδική συνάρτηση που τα ικανοποιεί δίνεται από το θεώρημα [17]:

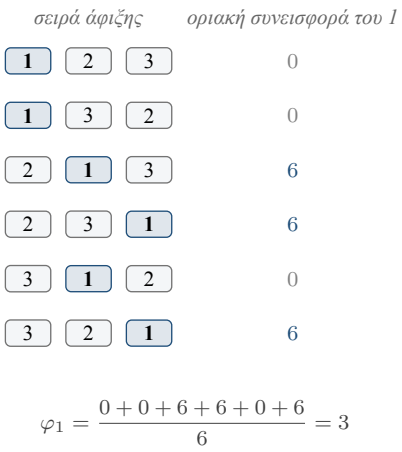
$$\varphi_i[v] \;=\; \sum_{S\subseteq N,\; i\in S} \gamma_n(s)\,\big[\,v(S) - v(S\setminus\{i\})\,\big], \qquad \gamma_n(s) = \frac{(s-1)!\,(n-s)!}{n!}, \tag{2.11}$$

όπου $n = |N|$ το πλήθος των παικτών, $s = |S|$ το μέγεθος του συνασπισμού και ο όρος $v(S) - v(S\setminus\{i\})$ η *οριακή συνεισφορά* του i στον S, δηλαδή η προσαύξηση της αξίας, λόγω της προσθήκης του.

Ο συντελεστής $\gamma_n(s)$ χρήζει επεξήγησης, γιατί εκεί εντοπίζεται όλη η ουσία. Έστω ότι οι n παίκτες μπαίνουν στο δωμάτιο ένας ένας, με τυχαία σειρά. Ο καθένας πιστώνεται το ποσό αύξησης της αξίας τη στιγμή της εισόδου του. Υπάρχουν $n!$ σειρές. Ο παίκτης i βρίσκει μπροστά του ακριβώς το σύνολο $S\setminus\{i\}$, όταν οι $s-1$ προηγούμενοι είναι αυτοί, με οποιαδήποτε σειρά μεταξύ τους ($(s-1)!$ τρόποι) και οι υπόλοιποι $n-s$ ακολουθούν, επίσης με οποιαδήποτε σειρά ($(n-s)!$ τρόποι). Άρα το $\gamma_n(s)$ είναι η *πιθανότητα* να συμβεί αυτό σε τυχαία σειρά. Το Shapley value είναι, λοιπόν, η *αναμενόμενη οριακή συνεισφορά* του παίκτη σε τυχαία σειρά άφιξης.

Ένα παράδειγμα με τρεις παίκτες κάνει τον τύπο εύληπτο (Σχήμα 2.2). Έστω ότι κανένας παίκτης μόνος του δεν αξίζει τίποτα, $v(\{1\}) = v(\{2\}) = v(\{3\}) = 0$, ότι οι παίκτες 1 και 2 μαζί παράγουν $v(\{1,2\}) = 6$, ότι ο 3 δε βοηθά κανέναν, $v(\{1,3\}) = v(\{2,3\}) = 0$ και ότι $v(\{1,2,3\}) = 6$. Απαριθμώντας και τις $3! = 6$ σειρές άφιξης, ο παίκτης 1 έχει μη μηδενική οριακή συνεισφορά στις σειρές $(2,1,3)$, $(2,3,1)$ και $(3,2,1)$, δηλαδή σε όσες φτάνει αφού έχει ήδη φτάσει ο 2. Σε καθεμιά από αυτές συνεισφέρει 6. Άρα $\varphi_1 = 3\cdot 6/6 = 3$. Συμμετρικά $\varphi_2 = 3$. Ο παίκτης 3 συνεισφέρει 0 σε κάθε σειρά, άρα $\varphi_3 = 0$, όπως προβλέπει το Λήμμα 1. Το άθροισμα $3+3+0 = 6$ ισούται με $v(N)$, όπως απαιτεί το Αξίωμα 2.

Το παράδειγμα αναδεικνύει και γιατί το Shapley value δεν ταυτίζεται με απλούστερα μέτρα. Το πιο προφανές εναλλακτικό είναι η αφαίρεση ενός παίκτη από το πλήρες σύνολο (*leave-one-out*), $v(N) - v(N\setminus\{i\})$. Εδώ δίνει $6-0=6$ για τον παίκτη 1, το ίδιο για τον 2 και $6-6=0$ για τον 3. Οι δύο πρώτοι παίρνουν ο καθένας ολόκληρη τη συνολική αξία και το άθροισμα γίνεται 12, ενώ υπάρχουν μόνο 6, για να μοιραστούν. Η αιτία είναι το γεγονός ότι, όταν δύο παίκτες είναι αλληλοσυμπληρωματικοί, καθένας φαίνεται αναντικατάστατος, αν κριθεί μόνο στο πλήρες σύνολο. Το Shapley value αποφεύγει τη διπλή μέτρηση, επειδή



Σχήμα 2.2. Το παράδειγμα των τριών παικτών, απαριθμημένο. Κάθε γραμμή είναι μία από τις $3! = 6$ σειρές άφιξης. Ο παίκτης 1 πιστώνεται το ποσό αύξησης της αξίας τη στιγμή της εισόδου του, δηλαδή 6 μόνο όταν ο παίκτης 2 έχει ήδη φτάσει. Η θέση του παίκτη 1 είναι επισημασμένη σε κάθε σειρά. Το φ_1 είναι ο μέσος όρος της δεξιάς στήλης.

σταθμίζει τη συνεισφορά σε *όλους* τους ενδιάμεσους συνασπισμούς. Γι' αυτό ικανοποιεί την αποδοτικότητα εξ ορισμού.

2.3.3 Υπολογιστική πολυπλοκότητα και εκτιμητές

Η Εξίσωση (2.11) αθροίζει πάνω σε όλα τα υποσύνολα, άρα απαιτεί 2^n αποτιμήσεις της v. Ήδη για είκοσι παίκτες αυτό ξεπερνά το ένα εκατομμύριο συνασπισμούς και, αν κάθε αποτίμηση σημαίνει εκπαίδευση ενός μοντέλου, το κόστος καθίσταται απαγορευτικό. Το ίδιο εμπόδιο εμφανίζεται σε κάθε εφαρμογή του Shapley στη μηχανική μάθηση, όπου κάθε κάτοχος δεδομένων μοντελοποιείται ως παίκτης σε συνασπιστικό παίγνιο [18].

Υπάρχουν δύο οικογένειες προσεγγίσεων. Η πρώτη εκμεταλλεύεται την ερμηνεία του Shapley ως αναμενόμενης τιμής και δειγματοληπτεί μεταθέσεις. Επιλέγονται τυχαίες σειρές και σε κάθε μία υπολογίζεται η οριακή συνεισφορά κάθε παίκτη. Ο μέσος όρος συγκλίνει στο φ_i. Ο αλγόριθμος *Truncated Monte Carlo Shapley* προσθέτει αποκοπή. Όταν η αξία ενός μεγάλου συνασπισμού έχει πλησιάσει αρκετά τη $v(N)$, οι υπόλοιπες οριακές συνεισφορές της σειράς θεωρούνται αμελητέες και δεν υπολογίζονται [19]. Ο βρόχος του αλγορίθμου, μάλιστα, τερματίζει με *κριτήριο σύγκλισης* και όχι με προκαθορισμένο πλήθος δειγμάτων, οπότε ο έλεγχος σύγκλισης είναι μέρος του αλγορίθμου και όχι προαιρετική προσθήκη [19].

Η δεύτερη οικογένεια διατυπώνει το πρόβλημα ως σταθμισμένη γραμμική παλινδρόμηση. Ο KernelSHAP δειγματοληπτεί συνασπισμούς, τους σταθμίζει με το *Shapley kernel*

$$\pi(S) = \frac{n-1}{\binom{n}{s}\, s\,(n-s)}, \tag{2.12}$$

όπου, όπως στην Εξίσωση (2.11), n το πλήθος των παικτών και $s = |S|$ το μέγεθος του δειγματοληπτημένου συνασπισμού. Στη συνέχεια, ο KernelSHAP λύνει ένα πρόβλημα ελαχίστων τετραγώνων, του οποίου οι συντελεστές είναι τα Shapley values [20]. Το Shapley kernel δίνει πολύ μεγάλο βάρος στους πολύ μικρούς και πολύ μεγάλους συνασπισμούς, ενώ τα δύο άκρα $s \in \{0, n\}$ παίρνουν άπειρο βάρος και επιβάλλουν ως περιορισμούς την $v(\emptyset)$ και την αποδοτικότητα [20].

Η διασπορά του εκτιμητή αυτού φθίνει αντιστρόφως ανάλογα με το πλήθος των δειγματοληπτημένων συνασπισμών, αποδεδειγμένα για μια αμερόληπτη παραλλαγή του και εμπειρικά για την αρχική μορφή. Η ιδιότητα αυτή επιτρέπει έναν ρητό κανόνα τερματισμού. Το δειγματοληπτικό σφάλμα παρακολουθείται και ο αλγόριθμος σταματά, όταν αυτό πέσει κάτω από ένα κατώφλι που ορίζεται ως μικρό ποσοστό του εύρους των εκτιμώμενων τιμών [21].

2.3.4 Shapley value, SHAP και συνάρτηση αξίας

Τρεις όροι μοιάζουν και πρέπει να κρατηθούν χωριστά.

- Το **Shapley value** είναι η έννοια της θεωρίας παιγνίων της Ενότητας 2.3.2, δηλαδή ένας κανόνας που μοιράζει την αξία *οποιουδήποτε* συνεργατικού παιγνίου στους παίκτες του.
- Το **SHAP** είναι μέθοδος ερμηνείας μοντέλων. Εφαρμόζει τον κανόνα σε ένα *συγκεκριμένο* παίγνιο, όπου παίκτες είναι τα *features* μίας εισόδου x και αξία ενός συνασπισμού S είναι η αναμενόμενη έξοδος του μοντέλου, όταν είναι γνωστά μόνο τα features του S [20].
- Ο **KernelSHAP** είναι αλγόριθμος *εκτίμησης*, η σταθμισμένη παλινδρόμηση της Ενότητας 2.3.3. Προτάθηκε στο ίδιο άρθρο με το SHAP αλλά ορίζεται για οποιαδήποτε συνάρτηση v, που δίνει μία τιμή σε κάθε συνασπισμό, όχι μόνο για το παίγνιο του SHAP [21].

Το SHAP εξηγεί πόσο ένα feature επηρεάζει την *έξοδο* του μοντέλου, χωρίς να χρειάζεται να ξέρει αν η πρόβλεψη είναι σωστή. Για να μετρηθεί πόσο κάτι βελτιώνει το *accuracy*, χρειάζεται συνάρτηση αξίας που συγκρίνει τις προβλέψεις με τα αληθινά *labels*, όπως η τιμή του *loss* του μοντέλου πάνω σε ένα σύνολο δεδομένων [21]. Την ίδια διάκριση κάνει και η ταξινόμηση των μεθόδων εξήγησης, ανάμεσα σε μεθόδους που εξηγούν μία πρόβλεψη και σε μεθόδους που εξηγούν το κόστος σε επίπεδο συνόλου δεδομένων [22].

Η παρούσα εργασία χρησιμοποιεί τον κανόνα και τον εκτιμητή αλλά όχι το παίγνιο του SHAP. Ορίζει δικό της παίγνιο, με παίκτες τους clients της ομοσπονδίας, γιατί σκοπός της

είναι η αποτίμηση της συνεισφοράς τους και όχι η ερμηνεία των προβλέψεων. Η συνάρτηση αξίας μετρά επίδοση με τα αληθινά labels. Κύρια μετρική είναι το accuracy. Ο ακριβής ορισμός του παιγνίου και ο τρόπος με τον οποίο χρησιμοποιείται ο εκτιμητής δίνονται στο Κεφάλαιο 5.

Η επιλογή της συνάρτησης αξίας δεν είναι τεχνική λεπτομέρεια. Τα αξιώματα εγγυώνται ότι η κατανομή μιας *δεδομένης* συνολικής αξίας είναι μοναδική αλλά η τιμή που αποδίδεται σε έναν παίκτη ορίζεται *ως προς* τη συνάρτηση αξίας. Στη διατύπωση του Data Shapley, η συνάρτηση αυτή περιλαμβάνει ρητά τον αλγόριθμο μάθησης και τη μετρική αξιολόγησης [23]. Μια άλλη μετρική, ένα άλλο *evaluation set* ή μια συνάρτηση αξίας που δε χρειάζεται κανένα τέτοιο σύνολο, όπως η ομοιότητα των updates των clients [24], ορίζουν άλλο παίγνιο και επομένως δίνουν άλλο φ. Τα αξιώματα δε λένε τίποτα για το πώς σχετίζονται οι τιμές δύο τέτοιων παιγνίων.

Από αυτό προκύπτουν τρία όρια, καταγεγραμμένα στη βιβλιογραφία.

Πρώτον, οι τιμές ισχύουν μόνο για τα σημεία του συνόλου στο οποίο υπολογίστηκαν. Το Data Shapley αποτιμά κάθε σημείο ως μέλος ενός συγκεκριμένου *training set* και δε δίνει τρόπο να κριθεί ένα σημείο εκτός αυτού. Η τιμή ενός σημείου μπορεί, μάλιστα, να μην έχει νόημα, αν το σημείο μεταφερθεί σε άλλο σύνολο [23]. Ο λόγος φαίνεται ήδη στην Ενότητα 2.3.1. Ένα σημείο που είναι περιττό ανάμεσα σε πολλά παρόμοιά του μπορεί να είναι πολύτιμο σε ένα σύνολο όπου αυτά λείπουν. Στην εργασία, η τιμή ενός client αφορά, επομένως, τη συγκεκριμένη ομοσπονδία και δε μεταφέρεται αυτούσια σε άλλη.

Δεύτερον, οι τιμές αλλάζουν από εκτέλεση σε εκτέλεση. Η αξία ενός συνασπισμού μετριέται εκπαιδεύοντας ένα μοντέλο. Η στοχαστική βελτιστοποίηση, όμως, δε δίνει το ίδιο μοντέλο σε κάθε εκτέλεση, αφού αλλάζουν η τυχαία αρχικοποίηση και η επιλογή των batches. Ο θόρυβος που προκύπτει μπορεί να είναι μεγαλύτερος από τις ίδιες τις τιμές, οπότε δύο εκτελέσεις του ίδιου αλγορίθμου αποτίμησης δίνουν διαφορετικές κατατάξεις και ο εντοπισμός δεδομένων χαμηλής ποιότητας από τις τιμές δυσκολεύει [25]. Στην εργασία, η σταθερότητα των τιμών ελέγχεται σε πολλές επαναλήψεις (Ενότητα 5.3.2).

Τρίτον, μια επιλογή δεδομένων με βάση το Data Shapley, δηλαδή η διατήρηση των σημείων με υψηλή τιμή και η απόρριψη όσων έχουν χαμηλή, δεν εγγυάται αποτέλεσμα καλύτερο από μια τυχαία επιλογή. Εγγύηση υπάρχει μόνο όταν η συνάρτηση χρησιμότητας ικανοποιεί πρόσθετες συνθήκες [26]. Ο λόγος είναι το γεγονός ότι διαφορετικές συναρτήσεις χρησιμότητας μπορεί να δίνουν ακριβώς τα ίδια Shapley values, οπότε οι τιμές μόνες τους δεν αρκούν για να κριθεί ποιο υποσύνολο δεδομένων είναι καλύτερο [26]. Αν, μάλιστα, η επιλογή ελεγχθεί στο ίδιο σύνολο με το οποίο υπολογίστηκαν οι τιμές, όπως κάνει η ίδια μελέτη για να ευθυγραμμιστεί με τη θεωρητική της ανάλυση [26], ο έλεγχος κινδυνεύει να είναι κυκλικός. Οι τιμές μετρούν ακριβώς πόσο βοήθησε κάθε σημείο σε αυτό το σύνολο,

οπότε ένα καλό αποτέλεσμα εκεί είναι εν μέρει αναμενόμενο και δε δείχνει ότι η επιλογή θα βοηθούσε και σε νέα δεδομένα.

Γι' αυτό, στην εργασία η αποτίμηση αντιμετωπίζεται ως *μέτρηση* του τι συνέβη σε μια συγκεκριμένη εκπαίδευση, απέναντι σε ένα συγκεκριμένο evaluation set. Το αν μπορεί να χρησιμοποιηθεί και ως *κριτήριο απόφασης* ελέγχεται χωριστά στο Κεφάλαιο 5, με αφαίρεση clients που κρίνεται σε άλλα άτομα από εκείνα με τα οποία εντοπίστηκαν.

2.3.5 Κίνητρα συμμετοχής στην ομοσπονδιακή μάθηση

Η συμμετοχή σε μια ομοσπονδία δεν είναι δωρεάν. Η τοπική εκπαίδευση καταναλώνει υπολογιστικούς πόρους, ενέργεια και εύρος ζώνης. Η βιβλιογραφία των μηχανισμών κινήτρων ξεκινά από την παραδοχή ότι οι clients είναι ορθολογικοί και μπορεί να μην είναι πρόθυμοι να συμμετάσχουν εξαιτίας αυτής ακριβώς της κατανάλωσης [6]. Χωρίς κάποια μορφή οικονομικής αποζημίωσης, οι ιδιοτελείς clients δεν έχουν λόγο να προσφέρουν [27].

Στην κατεύθυνση αυτή εμφανίζεται και το πρόβλημα του *free-riding*, όπου ένας client μπορεί να επωφεληθεί από το global model χωρίς να συνεισφέρει ουσιαστικά [28]. Επιπροσθέτως, χωρίς μέτρο συνεισφοράς, κανείς δεν μπορεί να τον ξεχωρίσει. Οι ανασκοπήσεις του πεδίου καταγράφουν το φάσμα των σχημάτων που έχουν προταθεί, από θεωρία συμβολαίων και δημοπρασίες μέχρι παίγνια Stackelberg, καθώς και τις ιδιότητες που τους ζητούνται [5], [6].

Τέσσερα κίνητρα εξετάζονται εδώ. Το πρώτο είναι η *αποκέντρωση* ως αξία καθαυτή, αφού τα ακατέργαστα δεδομένα δε φεύγουν από τη συσκευή, πράγμα που μειώνει την επιφάνεια έκθεσης [3], [4]. Το δεύτερο είναι το *μερίδιο ανταμοιβής*, όποια μορφή και αν πάρει. Το τρίτο είναι η *αναγνώριση της συνεισφοράς* ανεξάρτητα από πληρωμή. Το τέταρτο είναι το γεγονός ότι ο client παίρνει *καλύτερο μοντέλο από ό,τι θα είχε μόνος του*. Το τελευταίο μετριέται άμεσα σε αυτήν την εργασία και ποσοτικοποιείται στην Ενότητα 4.6.2.

2.4 Σχετική Βιβλιογραφία και Τοποθέτηση της Εργασίας

2.4.1 Ομοσπονδιακή μάθηση για αναγνώριση δραστηριότητας

Ο συνδυασμός ομοσπονδιακής μάθησης και αναγνώρισης δραστηριότητας έχει προφανές κίνητρο, αφού τα δεδομένα κίνησης παράγονται ήδη κατανεμημένα και σε προσωπικές συσκευές. Οι Sozinov et al. εκπαίδευσαν μοντέλα αναγνώρισης δραστηριότητας ομοσπονδιακά και αναφέρουν accuracy έως 89% έναντι 93% της κεντρικής εκπαίδευσης, μελετώντας

παράλληλα και την επίδραση clients με αλλοιωμένα δεδομένα [29]. Η ομοσπονδιακή εκπαίδευση υστερεί εκεί ελαφρώς, χωρίς η διαφορά να ακυρώνει τη χρησιμότητα του σχήματος. Η σύγκριση με τα αποτελέσματα αυτής της εργασίας γίνεται στην Ενότητα 4.6.1 και είναι μόνο ποιοτική, αφού τα σύνολα δεδομένων και τα μοντέλα διαφέρουν.

2.4.2 Αποτίμηση συνεισφοράς στην ομοσπονδιακή μάθηση

Η γραμμή εργασιών που αποτιμά δεδομένα με Shapley ξεκινά έξω από το FL. Το *Data Shapley* ορίζει την αξία ενός σημείου δεδομένων ως το Shapley value σε παίγνιο, όπου η συνάρτηση αξίας είναι η επίδοση του εκπαιδευμένου μοντέλου. Προτείνει, επίσης, εκτιμητές, για να γίνει υπολογίσιμο [19]. Παράλληλη εργασία μελετά πώς η αποτίμηση κλιμακώνεται σε μεγάλα σύνολα [18]. Και οι δύο μοιράζονται το ίδιο εμπόδιο, αφού κάθε αποτίμηση της v απαιτεί εκπαίδευση.

Στο ομοσπονδιακό πλαίσιο, σημαντική είναι η παρατήρηση ότι η εκπαίδευση δε χρειάζεται να επαναληφθεί. Το GTG-Shapley *ανασυνθέτει* τα ομοσπονδιακά μοντέλα από τα αποθηκευμένα updates παραμέτρων, αντί να εκπαιδεύει ξανά με διαφορετικούς συνδυασμούς clients [30]. Αυτό μετατρέπει το κόστος από εκπαιδεύσεις σε αποτιμήσεις και είναι η τεχνική στην οποία στηρίζεται και η υλοποίηση της εργασίας (Ενότητα 5.1).

Η αποτίμηση σε κάθε επανάληψη της ομοσπονδιακής εκπαίδευσης έχει και εννοιολογική βάση. Η ομοσπονδιακή εκπαίδευση γίνεται σε διαδοχικές επαναλήψεις, και η αξία των δεδομένων ενός client εξαρτάται από το πότε χρησιμοποιούνται στην εκπαίδευση, κάτι που το κλασικό Shapley value με επανεκπαίδευση δε λαμβάνει υπόψη. Γι' αυτό οι Wang et al. ορίζουν το *federated Shapley value* ως άθροισμα των τιμών κάθε επανάληψης [31]. Στην κεντρική εκπαίδευση, όπου τα δεδομένα ανακατεύονται, ο κλασικός ορισμός με επανεκπαίδευση ταιριάζει [31].

2.4.3 Το κενό της βιβλιογραφίας που καλύπτει η εργασία

Τα συστατικά που χρησιμοποιεί η εργασία υπάρχουν όλα στη βιβλιογραφία. Το Shapley value ως μέτρο αξίας δεδομένων [19] και ως μέτρο συνεισφοράς στο FL [30] είναι καθιερωμένο. Το ίδιο ισχύει για τον KernelSHAP ως εκτιμητή [20] και για την ανασύνθεση από αποθηκευμένα updates [30]. Η αντιμετώπιση των αρνητικών τιμών με αφινική μετατόπιση είναι δημοσιευμένη [28].

Αυτό που δεν εντοπίστηκε σε δημοσιευμένη εργασία, μετά από τρεις διαδοχικές αναζητήσεις, είναι ο *συνδυασμός*, δηλαδή η χρήση του KernelSHAP της βιβλιοθήκης `shap` με παίκτες τους clients ενός ομοσπονδιακού συστήματος, παράλληλα με έναν δεύτερο εκτιμητή

που βλέπει ακριβώς την ίδια συνάρτηση αξίας, ώστε η συμφωνία τους να ελέγχει ότι η κατάταξη δεν είναι παρενέργεια του αλγορίθμου. Ο συνδυασμός αυτός δηλώνεται ως συνεισφορά της εργασίας και όχι ως δάνειο.

Η εργασία εξετάζει, επίσης, γιατί κάποιοι clients λαμβάνουν χαμηλή ή αρνητική τιμή. Η βιβλιογραφία συνδέει, συνήθως, τη χαμηλή τιμή με την ετερογένεια των labels. Οι *Mavericks* είναι clients που κατέχουν αποκλειστικά μία ή περισσότερες κλάσεις και η επίδοση του μοντέλου υποβαθμίζεται χωρίς αυτούς [32]. Παρόλα αυτά, το Shapley value τους υποτιμά συστηματικά, με τιμή χαμηλότερη από εκείνη ενός μέσου client στο πρώτο στάδιο της εκπαίδευσης [33]. Το αν η χαμηλή ή αρνητική τιμή οφείλεται πάντα σε τέτοια ασυμμετρία labels ή και σε άλλες μορφές ετερογένειας εξετάζεται στο Κεφάλαιο 5.

Κεφάλαιο 3

Δεδομένα, Έλεγχοι και Προεπεξεργασία

Το κεφάλαιο αυτό παρουσιάζει τα δεδομένα της εργασίας. Ξεκινά από το πώς καταγράφεται η ανθρώπινη δραστηριότητα με αισθητήρες κινητών συσκευών και ορίζει το πρόβλημα ταξινόμησης που λύνει το μοντέλο. Έπειτα, εξηγεί πώς προκύπτουν τα features που δέχεται το μοντέλο ως είσοδο. Περιγράφει, επίσης, τους ελέγχους που έγιναν πριν χρησιμοποιηθεί το σύνολο, καθώς και τη διερευνητική ανάλυση. Κλείνει με την προεπεξεργασία και τον διαχωρισμό των δεδομένων.

3.1 Το Σύνολο Δεδομένων UCI HAR

Η αναγνώριση δραστηριότητας από φορητούς αισθητήρες στηρίζεται κυρίως σε δύο όργανα. Το *επιταχυνσιόμετρο* μετρά γραμμική επιτάχυνση σε τρεις άξονες, με συχνότητες δειγματοληψίας από δεκάδες έως εκατοντάδες Hz. Τοποθετείται συνήθως στη μέση, στον καρπό ή στον αστράγαλο. Το *γυροσκόπιο* μετρά προσανατολισμό και γωνιακή ταχύτητα [2]. Τα δύο μαζί περιγράφουν ικανοποιητικά την κίνηση, ώστε να ξεχωρίζουν δραστηριότητες που διαφέρουν είτε στον ρυθμό, είτε στη στάση του σώματος.

Το *Human Activity Recognition Using Smartphones* (UCI HAR) είναι δημόσιο σύνολο δεδομένων αυτού του τύπου, που συλλέχθηκε από 30 εθελοντές ηλικίας 19 έως 48 ετών. Κάθε εθελοντής φορούσε ένα Samsung Galaxy S II στη μέση και εκτέλεσε ένα πρωτόκολλο έξι δραστηριοτήτων, δύο φορές [1]. Οι δραστηριότητες είναι το βάδισμα, η ανάβαση σκάλας, η κατάβαση σκάλας, η καθιστή στάση, η όρθια στάση και η κατάκλιση [1]. Στα αρχεία του συνόλου φέρουν τα ονόματα WALKING, WALKING_UPSTAIRS, WALKING_DOWNSTAIRS, SITTING, STANDING και LAYING, με τα οποία αναφέρονται και στα επόμενα κεφάλαια. Στα σχήματα συντομεύονται σε WALK, W.UP, W.DOWN, SIT, STAND και LAY. Χωρίζονται φυσικά σε δύο ομάδες. Στις τρεις *δυναμικές* το σώμα μετακινείται, ενώ στις τρεις *στατικές* είναι ακίνητο σε κάποια στάση. Καταγράφηκαν το τριαξονικό επιταχυνσιόμετρο και το τριαξονικό γυροσκόπιο στα 50 Hz. Το πείραμα βιντεοσκοπήθηκε και τα *labels*, δηλαδή ποια δραστηριότητα εκτελούνταν κάθε στιγμή, μπήκαν με το χέρι από το βίντεο [34].

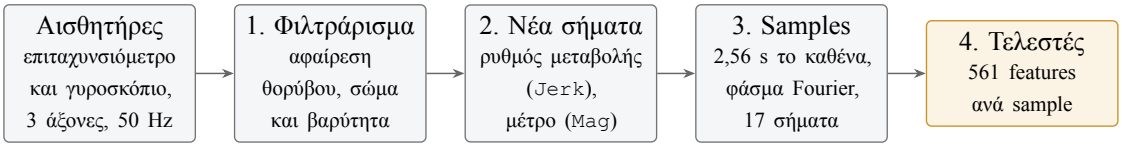
Πάνω σε αυτά τα δεδομένα, η εργασία λύνει ένα πρόβλημα *ταξινόμησης* (*classification*) σε έξι κλάσεις. Η καταγραφή κάθε εθελοντή κόβεται σε σύντομα κομμάτια σταθερής διάρκειας, τα *samples*. Κάθε sample έχει ως label τη δραστηριότητα που εκτελούσε ο εθελοντής εκείνη τη στιγμή. Το μοντέλο δέχεται την περιγραφή ενός sample και απαντά ποια από τις έξι δραστηριότητες είναι. Κάθε sample κρίνεται μόνο του, χωρίς να λαμβάνονται υπόψη τα προηγούμενα ή τα επόμενα. Από τι αποτελείται η περιγραφή ενός sample, δηλαδή η είσοδος του μοντέλου, εξηγεί η Ενότητα 3.2. Το σύνολο έχει συνολικά 10.299 samples, από τα οποία 7.352 στο *training set* και 2.947 στο *test set*.

Ο διαχωρισμός σε training και test set είναι κρίσιμο σημείο και δηλώνεται από τους δημιουργούς. Το 70% *των εθελοντών* επιλέχθηκε για την παραγωγή του training set και το 30% για το test set [34]. Ο διαχωρισμός είναι δηλαδή *ανά άτομο* και όχι ανά sample, με 21 ανθρώπους στο πρώτο και 9 στο δεύτερο, χωρίς κανένα άτομο να εμφανίζεται και στα δύο. Αυτό είναι το πιο σημαντικό δομικό χαρακτηριστικό του συνόλου για τους σκοπούς της εργασίας, γιατί καθιστά την αξιολόγηση *subject-independent*, δηλαδή το μοντέλο κρίνεται πάντα σε ανθρώπους που δεν έχει ξαναδεί.

Στην ομοσπονδιακή ρύθμιση της εργασίας, οι 21 εθελοντές του training set γίνονται οι 21 clients, ένας ανά άτομο. Στα σχήματα και στους πίνακες, οι clients αριθμούνται από 0 έως 20, κατά αύξοντα αριθμό εθελοντή. Η αντιστοιχία των δύο αριθμήσεων δίνεται στον Πίνακα 5.10. Τα μεγέθη τους κυμαίνονται από 281 έως 409 samples, με μέσο όρο 350 και συντελεστή μεταβλητότητας 0,099. Ο συντελεστής αυτός είναι η τυπική απόκλιση των μεγεθών διαιρεμένη με τον μέσο όρο τους, οπότε η τυπική απόκλιση είναι περίπου το 10% του μέσου μεγέθους και η ομοσπονδία είναι ισορροπημένη ως προς τον όγκο. Οι 9 εθελοντές του test set δε γίνονται ποτέ clients και τα δεδομένα τους δεν εισέρχονται ποτέ σε καμία εκπαίδευση.

3.2 Από τα Σήματα των Αισθητήρων στα 561 Features

Το μοντέλο δε βλέπει τα σήματα των αισθητήρων. Βλέπει 561 αριθμούς ανά sample, τα *features*, που υπολόγισαν οι δημιουργοί του συνόλου από τα σήματα σε τέσσερα βήματα [1]. Το Σχήμα 3.1 τα δείχνει συνοπτικά.



Σχήμα 3.1. Τα τέσσερα βήματα με τα οποία οι δημιουργοί του συνόλου μετέτρεψαν τα σήματα των αισθητήρων σε 561 features ανά sample. Το μοντέλο της εργασίας βλέπει μόνο το αποτέλεσμα του τελευταίου βήματος.

Στο πρώτο βήμα, τα σήματα του επιταχυνσιομέτρου και του γυροσκοπίου φιλτράρονται, ώστε να αφαιρεθεί ο θόρυβος. Έπειτα, το σήμα του επιταχυνσιομέτρου χωρίζεται σε δύο συνιστώσες. Η μία είναι η επιτάχυνση της βαρύτητας, ένα σχεδόν σταθερό διάνυσμα που δείχνει προς τα κάτω και του οποίου η κατεύθυνση στο σύστημα συντεταγμένων της συσκευής κωδικοποιεί τον *προσανατολισμό* της. Η άλλη είναι η επιτάχυνση του σώματος, δηλαδή η πραγματική κίνηση. Ο διαχωρισμός έγινε με βαθυπερατό φίλτρο, αφού η βαρύτητα είναι η συνιστώσα πολύ χαμηλής συχνότητας [1]. Γι' αυτό τα ονόματα πολλών features ξεκινούν από `tBodyAcc` ή από `tGravityAcc`. Η διάκριση των δύο αποδεικνύεται ουσιώδης στην Ενότητα 3.4.3.

Στο δεύτερο βήμα, υπολογίζονται από αυτά νέα σήματα. Η παράγωγος ως προς τον χρόνο δίνει πόσο απότομα αλλάζει η κίνηση (*Jerk*). Το μέτρο του διανύσματος των τριών αξόνων δίνει την ένταση της κίνησης ανεξάρτητα από την κατεύθυνσή της (*Magnitude*) [1].

Στο τρίτο βήμα, κάθε σήμα κόβεται σε samples των 2,56 δευτερολέπτων, δηλαδή 128 μετρήσεων, με επικάλυψη 50% μεταξύ διαδοχικών. Η διάρκεια επιλέχθηκε, ώστε κάθε sample να περιέχει τουλάχιστον έναν πλήρη κύκλο βαδίσματος, δηλαδή δύο βήματα, ακόμη και για άνθρωπο που περπατά αργά [1]. Μέσα σε κάθε sample υπολογίζεται και ο μετασχηματισμός Fourier ορισμένων σημάτων, ο οποίος δείχνει με ποιους ρυθμούς επαναλαμβάνεται η κίνηση. Προκύπτουν, έτσι, 17 σήματα, στο πεδίο του χρόνου και στο πεδίο της συχνότητας [1].

Στο τέταρτο βήμα, κάθε σήμα κάθε sample συνοψίζεται με ένα σύνολο *τελεστών*, δηλαδή συναρτήσεων που παίρνουν τις τιμές του σήματος μέσα στο sample και δίνουν έναν ή λίγους αριθμούς, όπως η μέση τιμή, η τυπική απόκλιση ή η ενέργεια. Κάθε συνδυασμός σήματος, άξονα και τελεστή δίνει ένα feature και συνολικά προκύπτουν 561 [1]. Από αυτά, τα 265 υπολογίζονται στο πεδίο του χρόνου, τα 289 στο πεδίο της συχνότητας και τα 7 είναι γωνίες μεταξύ διανυσμάτων. Τέλος, κάθε στήλη κλιμακώθηκε στο διάστημα $[-1, 1]$ [34], βήμα που εξετάζεται ξανά στην Ενότητα 3.3.1.

Το όνομα κάθε feature περιγράφει ακριβώς αυτά τα βήματα. Ο Πίνακας 3.1 δίνει τα μέρη του. Για παράδειγμα, το `tBodyAccMag-mean()` είναι η μέση τιμή (`mean()`) του μέτρου (`Mag`) της επιτάχυνσης του σώματος (`BodyAcc`) στο πεδίο του χρόνου (`t`). Αντίστοιχα, το `tGravityAcc-mean()-Y` είναι η μέση τιμή της βαρύτητας, στον άξονα Y της συσκευής.

Το σύνολο διανέμεται ως αρχεία κειμένου με την ίδια σειρά γραμμών, όπου κάθε γραμμή αντιστοιχεί σε ένα sample [34]. Η γραμμή n του `X_train.txt` περιέχει τα 561 features του sample n, δηλαδή το διάνυσμα εισόδου $\mathbf{x}_n \in \mathbb{R}^{561}$. Η ίδια γραμμή του `y_train.txt` περιέχει το label $y_n \in \{1, \ldots, 6\}$, δηλαδή τον κωδικό της δραστηριότητας. Στην ίδια γραμμή του `subject_train.txt` βρίσκεται ο αριθμός του εθελοντή, από 1 έως 30. Τα αρχεία του test set έχουν την ίδια μορφή. Ο Πίνακας 3.2 δείχνει τρεις γραμμές του ίδιου εθελοντή.

Μέρη του ονόματος	
`t`, `f`	πεδίο του χρόνου ή της συχνότητας (μετά τον μετασχηματισμό Fourier)
`Body`, `Gravity`	κίνηση του σώματος ή βαρύτητα
`Acc`, `Gyro`	επιταχυνσιόμετρο ή γυροσκόπιο
`Jerk`	ρυθμός μεταβολής του σήματος (παράγωγος ως προς τον χρόνο)
`Mag`	μέτρο του διανύσματος των τριών αξόνων
`-X`, `-Y`, `-Z`	άξονας της συσκευής
Τελεστές	
`mean()`, `std()`	μέση τιμή, τυπική απόκλιση
`mad()`	διάμεση απόλυτη απόκλιση
`max()`, `min()`	μέγιστη και ελάχιστη τιμή
`iqr()`	ενδοτεταρτημοριακό εύρος
`sma()`	*signal magnitude area*, μέτρο της συνολικής έντασης του σήματος
`energy()`	άθροισμα τετραγώνων διά το πλήθος των τιμών
`entropy()`	εντροπία του σήματος
`arCoeff()`	συντελεστές αυτοπαλινδρόμησης, δηλαδή πόσο εξαρτάται κάθε τιμή από τις τέσσερις προηγούμενες
`correlation()`	συσχέτιση μεταξύ δύο αξόνων του ίδιου σήματος
`maxInds()`	η συχνότητα με το μεγαλύτερο πλάτος
`meanFreq()`	σταθμισμένη μέση συχνότητα
`skewness()`, `kurtosis()`	ασυμμετρία και κύρτωση του φάσματος
`bandsEnergy()`	ενέργεια σε ζώνες συχνοτήτων
`angle()`	γωνία μεταξύ δύο διανυσμάτων, για παράδειγμα της μέσης βαρύτητας με έναν άξονα

Πίνακας 3.1. Τα μέρη του ονόματος ενός feature και οι τελεστές που εφαρμόζονται στα σήματα, κατά την τεκμηρίωση του συνόλου [34] και τον κατάλογο των δημιουργών [1].

x_1	x_{42}	x_{201}		y	εθελοντής
`tBodyAcc-mean()-X`	`tGravityAcc-mean()-Y`	`tBodyAccMag-mean()`	$\cdots$		
0,2820	−0,2459	−0,2246	$\cdots$	1 (WALKING)	1
0,1445	0,0425	−0,5544	$\cdots$	4 (SITTING)	1
0,4035	0,7747	−0,9051	$\cdots$	6 (LAYING)	1

Πίνακας 3.2. Τρεις γραμμές του training set, όλες του εθελοντή 1 (γραμμές 79, 28 και 52 των αρχείων), με τρία από τα 561 features στην κλίμακα της πηγής. Η στήλη y είναι το label που πρέπει να προβλέψει το μοντέλο. Ο αριθμός του εθελοντή δε δίνεται στο μοντέλο.

Στις τρεις αυτές γραμμές φαίνονται, ήδη, διαφορές μεταξύ των δραστηριοτήτων. Το μέτρο της επιτάχυνσης του σώματος (x_{201}) είναι μεγαλύτερο στο βάδισμα από ό,τι στις δύο στάσεις. Η βαρύτητα στον άξονα Y (x_{42}) παίρνει πολύ διαφορετική τιμή στην κατάκλιση. Η Ενότητα 3.4.3 δείχνει ότι το ίδιο ισχύει σε όλο το σύνολο.

Με αυτούς τους συμβολισμούς, το πρόβλημα ταξινόμησης της Ενότητας 3.1 είναι να μάθει το μοντέλο, από τα ζεύγη $(\mathbf{x}_n, y_n)$ του training set, μια συνάρτηση f που να αντιστοιχίζει κάθε διάνυσμα $\mathbf{x}$ σε μία από τις έξι δραστηριότητες. Το μοντέλο κρίνεται από το πόσο συχνά ισχύει $f(\mathbf{x}_n) = y_n$ στο test set, δηλαδή από το accuracy της Εξίσωσης (2.1). Ο αριθμός του εθελοντή δε δίνεται ποτέ στο μοντέλο. Χρησιμοποιείται μόνο για να οριστεί σε ποιον client ανήκει κάθε sample και ποια samples ανήκουν στο test set.

Εκτός από τον πίνακα των features, το σύνολο περιέχει και τον φάκελο `Inertial Signals`, με τα σήματα κάθε sample ως 128 διαδοχικές μετρήσεις σε εννέα κανάλια, δηλαδή τρεις άξονες για τη συνολική επιτάχυνση, την επιτάχυνση του σώματος και τη γωνιακή ταχύτητα [34]. Τέτοια σήματα είναι η είσοδος των μεθόδων βαθιάς μάθησης, οι οποίες μαθαίνουν μόνες τους τα features, αντί να τα δέχονται έτοιμα [35]. Η εργασία επέλεξε από την αρχή ένα απλό δίκτυο MLP (Ενότητα 2.1), για το οποίο φυσική είσοδος είναι ένα διάνυσμα, όπως το $\mathbf{x}_n$. Έτσι, ο φάκελος αυτός δε χρησιμοποιήθηκε.

3.3 Έλεγχοι Ακεραιότητας των Δεδομένων

Πριν χρησιμοποιηθεί το σύνολο, ελέγχθηκε. Δεν υπάρχουν ελλείπουσες τιμές ούτε άπειρα σε κανένα από τα δύο υποσύνολα, καμία στήλη δεν είναι σταθερή και καμία γραμμή του test set δεν επαναλαμβάνεται στο training set (0 από 2.947, έλεγχος πάνω στα 561 features). Οι υπόλοιποι έλεγχοι αφορούν την κλιμάκωση της πηγής, τις στήλες που επαναλαμβάνονται, την επικάλυψη διαδοχικών samples και τις ακραίες τιμές. Περιγράφονται στις επόμενες υποενότητες.

3.3.1 Διαρροή προεπεξεργασίας στην πηγή

Όπως αναφέρθηκε στην Ενότητα 3.2, οι δημιουργοί κλιμάκωσαν κάθε στήλη του πίνακα στο διάστημα $[-1, 1]$. Η συνήθης μέθοδος για κάτι τέτοιο είναι η κλιμάκωση *min-max*,

$$x' = 2\,\frac{x - m}{M - m} - 1, \tag{3.1}$$

όπου m και M η ελάχιστη και η μέγιστη τιμή της στήλης. Η τιμή m γίνεται -1, η M γίνεται $+1$ και όλες οι υπόλοιπες πέφτουν ανάμεσα. Το γεγονός ότι κάθε στήλη του πίνακα φτάνει ακριβώς το -1 και το $+1$ δείχνει κλιμάκωση αυτού του τύπου.

Το ερώτημα είναι από ποια δεδομένα υπολογίστηκαν τα m και M. Ο κανόνας είναι ότι κάθε παράμετρος προεπεξεργασίας υπολογίζεται μόνο από το training set, γιατί το test set παριστάνει ανθρώπους που το μοντέλο δεν έχει δει. Αν τα m και M υπολογιστούν και από το test set, τότε η πληροφορία από αυτό περνά στις τιμές που βλέπει το μοντέλο κατά την εκπαίδευση. Η βιβλιογραφία ονομάζει την περίπτωση *[L1.2] Pre-processing on training and test set*, δηλαδή χρήση ολόκληρου του συνόλου δεδομένων για βήματα προεπεξεργασίας [36].

Αν τα m και M είχαν υπολογιστεί μόνο από το training set, οι τιμές -1 και $+1$ θα εμφανίζονταν μόνο σε samples του training set. Ο έλεγχος των αρχείων δείχνει ότι και οι 561 στήλες φτάνουν ακριβώς το -1 και το $+1$, όταν τα δύο σύνολα θεωρηθούν μαζί. Επιπλέον, σε **109 στήλες** το $+1$ και σε **95 στήλες** το -1 το δίνει sample του *test set*. Επομένως, τα m και M υπολογίστηκαν και από αυτό.

Η εργασία δε χρησιμοποιεί τις τιμές, όπως δίνονται, αλλά τις τυπικοποιεί ξανά με μέσο μ και τυπική απόκλιση σ υπολογισμένα μόνο από το training set (Εξίσωση (3.4), Ενότητα 3.5) και αυτό αρκεί για να εξαφανιστεί η διαρροή. Η min-max της Εξίσωσης (3.1) απλώς μετατοπίζει και τεντώνει κάθε στήλη, δηλαδή $x' = ax + b$ με $a > 0$. Μετά από αυτήν την αλλαγή, ο μέσος της στήλης γίνεται $a\mu + b$ και η τυπική της απόκλιση $a\sigma$, οπότε η τυπικοποίηση δίνει

$$\frac{x' - (a\mu + b)}{a\sigma} = \frac{ax + b - a\mu - b}{a\sigma} = \frac{x - \mu}{\sigma}. \tag{3.2}$$

Τα a και b, δηλαδή το μόνο σημείο, όπου μπήκε το test set, απαλείφονται και το αποτέλεσμα είναι το ίδιο, σαν να μην είχε γίνει καμία min-max. Ένας αριθμητικός έλεγχος, με τυχαίες στήλες και τυχαία μετατόπιση και τέντωμα στην καθεμία πριν από την τυπικοποίηση, δίνει διαφορά το μέγιστο $2{,}7 \cdot 10^{-15}$, δηλαδή μόνο στρογγυλοποίηση.

Το αποτέλεσμα φαίνεται και στα ίδια τα δεδομένα, στον Πίνακα 3.3. Στην κλίμακα της πηγής, τόσο το training set όσο και το test set εκτείνονται ακριβώς από -1 έως $+1$, αφού η κλιμάκωση έγινε πάνω στην ένωσή τους. Μετά την τυπικοποίηση της εργασίας, το training set έχει μέσο 0 και τυπική απόκλιση 1, με διαφορά μόνο στο πέμπτο δεκαδικό από την αριθ-

μητική απλής ακρίβειας. Αυτό περιμένει κανείς, αφού τα μ και σ υπολογίστηκαν ακριβώς από αυτό. Το test set έχει μέσο $-0{,}01111$ και τυπική απόκλιση $0{,}92136$, δηλαδή κοντά αλλά όχι ακριβώς 0 και 1, όπως αναμένεται για ανθρώπους που δε συμμετείχαν στον υπολογισμό. Το εύρος δεν περιορίζεται πλέον στο $[-1, 1]$, γιατί η τυπικοποίηση μετρά κάθε τιμή σε τυπικές αποκλίσεις από τον μέσο και οι ακραίες τιμές της Ενότητας 3.3.4 απέχουν από αυτόν πολλές τυπικές αποκλίσεις.

	Κλίμακα της πηγής		Μετά την τυπικοποίηση	
	training set	test set	training set	test set
Μέσος όρος	$-0{,}5084$	$-0{,}5093$	$+0{,}00002$	$-0{,}01111$
Τυπική απόκλιση	$0{,}2837$	$0{,}2667$	$1{,}00000$	$0{,}92136$
Ελάχιστη τιμή	-1	-1	$-24{,}07$	$-12{,}33$
Μέγιστη τιμή	$+1$	$+1$	$+34{,}19$	$+19{,}43$

Πίνακας 3.3. Μέσος όρος όλων των τιμών, μέση τυπική απόκλιση των 561 στηλών και εύρος, στο training set και στο test set. Στην πηγή τα δύο σύνολα μοιράζονται την ίδια κλιμάκωση. Μετά την τυπικοποίηση μόνο το training set έχει μέσο 0 και τυπική απόκλιση 1, γιατί μόνο από αυτό υπολογίστηκαν τα μ και σ.

Αν τα μ και σ είχαν υπολογιστεί από την ένωση των δύο συνόλων, δηλαδή με το ίδιο λάθος που έκανε η πηγή, το training set δε θα είχε μέσο 0 και τυπική απόκλιση 1 αλλά $+0{,}0035$ και $1{,}021$ αντιστοίχως. Οι τιμές του πίνακα αποδεικνύουν, επομένως, ότι η τυπικοποίηση δεν είδε το test set. Η Εξίσωση (3.2), εξάλλου, δείχνει ότι η κλιμάκωση της πηγής απαλείφεται. Τα δύο μαζί σημαίνουν ότι στα δεδομένα που βλέπει το μοντέλο δεν έχει μείνει διαρροή. Προϋπόθεση αναγκαία είναι η τυπικοποίηση να εφαρμόζεται πάντα, αφού ένα πείραμα χωρίς αυτήν θα κληρονομούσε τη διαρροή της πηγής.

3.3.2 Διπλότυπες στήλες

Η σύγκριση κάθε στήλης με κάθε άλλη βρήκε 21 στήλες που είναι ακριβή αντίγραφα άλλων. Οι 8 από αυτές εξηγούνται εύκολα. Σε κάθε σήμα μέτρου (`Mag`) το `mean()` ταυτίζεται με το `sma()`, γιατί το μέτρο δεν παίρνει ποτέ αρνητικές τιμές και ο μέσος όρος των απόλυτων τιμών του συμπίπτει με τον απλό μέσο όρο. Οι άλλες 13 δεν εξηγούνται το ίδιο εύκολα. Ολόκληρη η οικογένεια `tGravityAccMag` είναι ίδια με την `tBodyAccMag`, ενώ η βαρύτητα και η κίνηση του σώματος είναι διαφορετικά μεγέθη, με συσχέτιση Pearson (Εξίσωση (2.5)) μόλις $r = 0{,}026$ στον άξονα X. Το πιθανότερο είναι ότι πρόκειται για σφάλμα κατά την κατασκευή του πίνακα.

Για την εργασία οι στήλες αυτές δεν έχουν ουσιαστική συνέπεια. Δεν προσθέτουν πληροφορία, απλώς δίνουν στο δίκτυο 21 εισόδους που επαναλαμβάνουν άλλες και κρατήθηκαν,

ώστε η είσοδος να είναι ακριβώς ο δημοσιευμένος πίνακας. Θα είχαν σημασία μόνο σε ανάλυση της σημαντικότητας κάθε feature, όπου δύο ίδιες στήλες μοιράζονται τη σημαντικότητά τους. Τέτοια ανάλυση, όμως, δε γίνεται σε αυτήν την εργασία.

Κάτι ανάλογο ισχύει για τα ονόματα των features `bandsEnergy()`. Σε αυτά, 42 ονόματα εμφανίζονται τρεις φορές, μία για κάθε άξονα, χωρίς ο άξονας να γράφεται στο όνομα, οπότε 126 στήλες έχουν ονόματα που επαναλαμβάνονται, ενώ οι τιμές τους διαφέρουν. Ούτε αυτό επηρεάζει την εργασία, αφού το μοντέλο δε βλέπει ονόματα. Για να μπορεί, πάντως, κάθε στήλη να αναφερθεί χωριστά, η υλοποίηση δίνει σε καθεμία μοναδικό όνομα στο αρχείο `feature_names.csv`.

3.3.3 Επικάλυψη διαδοχικών samples

Τα samples κατασκευάστηκαν με επικάλυψη 50%, δηλαδή κάθε sample μοιράζεται τα μισά του δεδομένα με το προηγούμενο και τα άλλα μισά με το επόμενο. Ο έλεγχος στα ακατέργαστα αρχεία επιβεβαιώνει ότι 6.752 από τα 7.072 ελεγμένα διαδοχικά ζεύγη παρουσιάζουν ακριβή επικάλυψη, δηλαδή 95,5%.

Η συνέπεια είναι ότι τα samples *δεν είναι ανεξάρτητα*. Δύο διαδοχικά samples του ίδιου ανθρώπου στην ίδια δραστηριότητα είναι σχεδόν το ίδιο δεδομένο. Αυτός ο τύπος διαρροής καταγράφεται, επίσης, στη βιβλιογραφία ως *[L3.2] Nonindependence between train and test samples* [36]. Στον επίσημο διαχωρισμό σε training και test set δεν εκδηλώνεται, επειδή αυτός είναι ανά άτομο και δύο διαδοχικά samples ανήκουν πάντα στον ίδιο άνθρωπο.

Εκδηλώνεται, όμως, σε κάθε *εσωτερικό* διαχωρισμό. Αν τα samples ενός client χωριστούν τυχαία σε ένα training set και ένα *validation set*, τα δύο μέρη θα περιέχουν επικαλυπτόμενα ζεύγη και η μέτρηση στο δεύτερο θα είναι αισιόδοξη. Η βιβλιογραφία το διατυπώνει ρητά για τα πρωτόκολλα HAR, σημειώνοντας ότι ένα τέτοιο σχήμα είναι έντονα μεροληπτικό, επειδή ένα sample i και το $i + 1$ μπορούν να βρεθούν σε διαφορετικά τμήματα [37]. Επιπλέον, το φαινομενικό όφελος της επικάλυψης εξαφανίζεται, όταν η αξιολόγηση γίνεται σε επίπεδο ατόμου [38]. Η υλοποίηση δεν κάνει κανέναν τέτοιο εσωτερικό διαχωρισμό (Ενότητα 3.5), οπότε το φαινόμενο δεν αγγίζει τις μετρήσεις της εργασίας.

3.3.4 Ανίχνευση ακραίων τιμών

Έγινε, επίσης, ανίχνευση ακραίων τιμών (*outlier detection*). Μια τιμή θεωρήθηκε ακραία, όταν απέχει περισσότερο από τρεις τυπικές αποκλίσεις από τον μέσο της στήλης της, δηλαδή όταν $|\tilde{x}_j| > 3$ στην τυπικοποιημένη κλίμακα της Εξίσωσης (3.4). Για σύγκριση σε πίνακα ίδιου μεγέθους με τυχαίες τιμές από κανονική κατανομή, ακραίες είναι περίπου το 0,27%

των τιμών και καμία γραμμή δεν έχει πάνω από 8. Στο training set, ακραίες είναι το 0,98% των τιμών. Επιπλέον, 449 samples, δηλαδή το 6,11%, έχουν ταυτόχρονα 21 ή περισσότερες τέτοιες τιμές. Στο test set, το αντίστοιχο ποσοστό είναι 4,28%.

Τα samples αυτά δεν είναι σκόρπια. Συγκεντρώνονται στις δυναμικές δραστηριότητες, κυρίως στην κατάβαση σκάλας, όπου είναι το 22,5% των samples της, ενώ στην όρθια στάση δεν υπάρχει κανένα. Συγκεντρώνονται, επίσης, σε λίγους ανθρώπους, αφού τρεις από τους 21 clients έχουν το 55,9% από αυτά.

Κανένα sample και κανένας client δεν αφαιρέθηκε, για τρεις λόγους. Πρώτον, οι τιμές αυτές δε μοιάζουν με σφάλματα μέτρησης αλλά με το ίδιο το φαινόμενο. Τα σφάλματα μέτρησης θα ήταν σκόρπια σε όλα τα δεδομένα, ενώ η κατάβαση σκάλας παράγει πραγματικά απότομες επιταχύνσεις και κάποιοι άνθρωποι κινούνται πιο απότομα από άλλους. Δεύτερον, ένα κατώφλι αφαίρεσης θα έκοβε κυρίως μία δραστηριότητα και συγκεκριμένους ανθρώπους, δηλαδή ακριβώς τις διαφορές μεταξύ clients που θέλει να μετρήσει η αποτίμηση της συνεισφοράς (Κεφάλαιο 5). Αν κάποιος client βλάπτει το μοντέλο, αυτό πρέπει να το δείξει η αποτίμηση και όχι να αποφασιστεί εκ των προτέρων. Ούτε υπάρχει client που να αποτελείται, κυρίως, από τέτοια samples, αφού ακόμη και στους δύο με το υψηλότερο ποσοστό είναι περίπου το 26% των δεδομένων τους. Τρίτον, όλες οι συγκρίσεις της εργασίας γίνονται πάνω στα ίδια ακριβώς δεδομένα, οπότε ό,τι προσθέτουν τα samples αυτά, το προσθέτουν εξίσου σε κάθε τοπολογία.

3.4 Διερευνητική Ανάλυση Δεδομένων

Η διερευνητική ανάλυση εξετάζει τρία πράγματα, πόσο ισορροπημένες είναι οι κλάσεις, πόσο διαφέρουν οι clients μεταξύ τους και πόσο καθαρά ξεχωρίζουν οι δραστηριότητες στον χώρο των features.

3.4.1 Ισορροπία κλάσεων

Οι έξι δραστηριότητες εκπροσωπούνται σχεδόν εξίσου. Στο training set η πολυπληθέστερη κλάση (LAYING, 1.407 samples) είναι μόλις 1,43 φορές η λιγότερο πολυπληθής (WALKING_DOWNSTAIRS, 986). Η κανονικοποιημένη εντροπία της κατανομής είναι 0,9956, όπου το 1 αντιστοιχεί σε τέλεια ισορροπία.

Η εντροπία αυτή ορίζεται ως $H / \log K$, όπου $H = -\sum_k p_k \log p_k$ η εντροπία Shannon της κατανομής των κλάσεων, p_k το ποσοστό της κλάσης k και $K = 6$. Η διαίρεση με $\log K$ φέρνει τη μετρική στο $[0, 1]$, ανεξάρτητα από το πλήθος των κλάσεων. Τιμή 0,9956 σημαίνει ότι η απόσταση από την ομοιόμορφη κατανομή είναι αμελητέα.

Η πρακτική συνέπεια είναι ότι δεν εφαρμόζεται καμία επαναδειγματοληψία, ούτε στάθμιση κλάσεων και ότι το accuracy και το macro-F1 αναμένεται να κινούνται μαζί, πράγμα που επιβεβαιώνεται στην Ενότητα 4.6.

3.4.2 Κατάτμηση σε clients και ετερογένεια

Η κατάτμηση σε clients δεν είναι τεχνητή, αφού κάθε ένας από τους 21 clients *είναι* ένας από τους 21 εθελοντές του training set. Δε γίνεται καμία συνθετική κατασκευή non-IID κατανομών, κάτι που είναι συνήθης πρακτική στη βιβλιογραφία του FL [4].

Το ερώτημα είναι πόσο ετερογενής είναι αυτή η φυσική κατάτμηση. Η μορφή ετερογένειας που εξετάζεται εδώ είναι η *λοξότητα κατανομής labels* (*label distribution skew*), δηλαδή το πόσο διαφέρουν οι περιθώριες κατανομές $P_i(y)$ μεταξύ clients, ακόμη και όταν η $P(x \mid y)$ είναι κοινή [4]. Ποσοτικοποιείται με την απόσταση ολικής μεταβολής (*total variation*) της κατανομής κάθε client από τη συνολική:

$$\mathrm{TV}(p_i, \bar{p}) = \tfrac{1}{2} \sum_{k=1}^{K} \left| p_{i,k} - \bar{p}_k \right|, \tag{3.3}$$

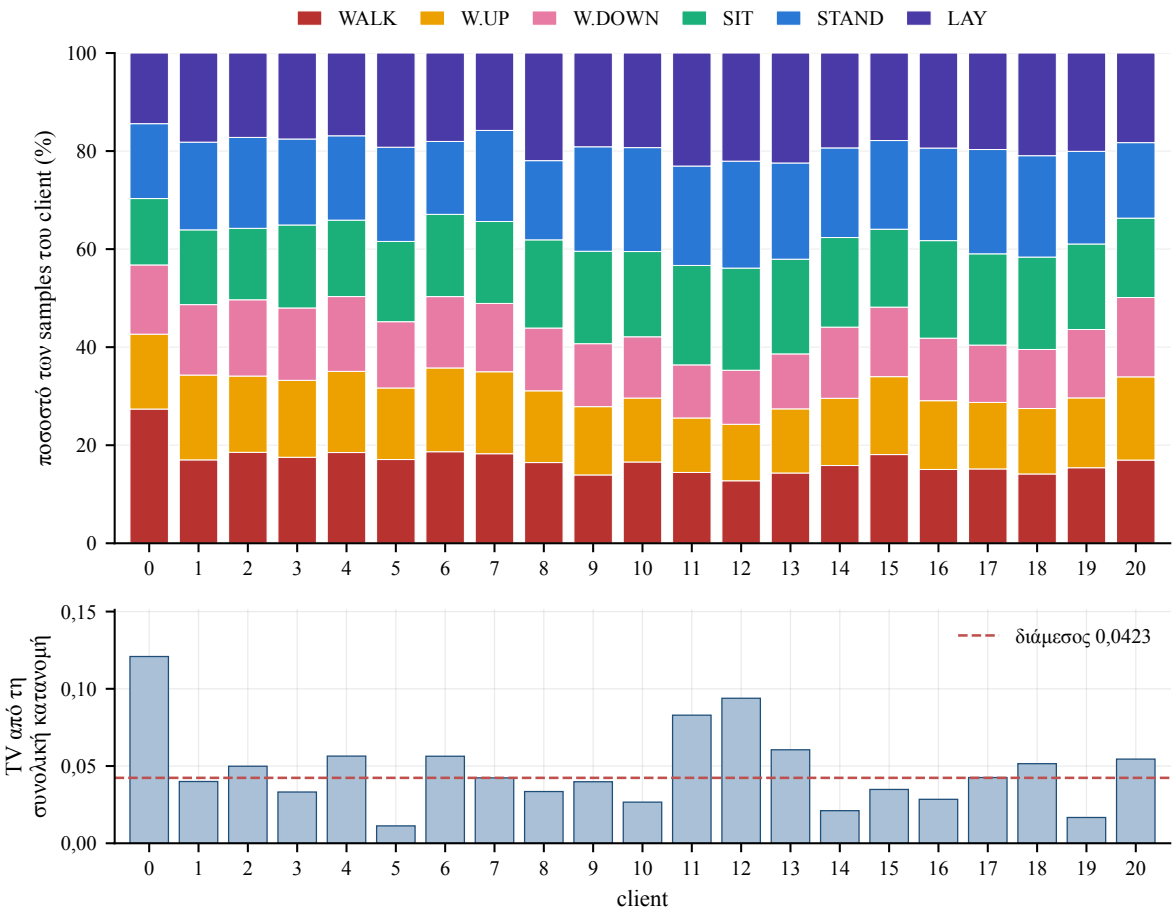
όπου $p_{i,k}$ το ποσοστό της κλάσης k στα δεδομένα του client i και $\bar{p}_k$ το αντίστοιχο ποσοστό σε όλο το training set, δηλαδή στους 21 clients μαζί. Ο συντελεστής $\frac{1}{2}$ υπάρχει, ώστε η μετρική να κινείται στο $[0, 1]$, αφού το άθροισμα των απόλυτων διαφορών δύο κατανομών δεν ξεπερνά ποτέ το 2. Τιμή 0 σημαίνει ταυτόσημες κατανομές και τιμή 1 σημαίνει ότι οι δύο κατανομές δεν έχουν καμία κοινή κλάση.

Στα δεδομένα της εργασίας, η διάμεση τιμή είναι $0{,}0423$ και η μέγιστη $0{,}1209$, ενώ δεν υπάρχει κανένα ζεύγος client και κλάσης που να λείπει, αφού κάθε client έχει samples και από τις έξι δραστηριότητες. Το Σχήμα 3.2 το δείχνει ανά client.

Με αυτά τα νούμερα η ομοσπονδία είναι *σχεδόν IID ως προς τα labels*. Αυτό δεν είναι αδυναμία του πειράματος αλλά ιδιότητα του συνόλου. Η συνέπειά της για τη σύγκριση των τοπολογιών συζητείται στην Ενότητα 4.6.1. Η ετερογένεια αυτού του συνόλου δεδομένων δε βρίσκεται στο *τι* κάνει ο καθένας αλλά στο *πώς* το κάνει, αφού όλοι εκτέλεσαν το ίδιο πρωτόκολλο. Ενυπάρχει, δηλαδή, στη μορφή του σήματος, όχι στα labels. Το Κεφάλαιο 5 βρίσκει εκεί μια ασθενή σχέση με την αρνητική συνεισφορά, ενώ με τα labels καμία.

3.4.3 Διαχωρισιμότητα κλάσεων

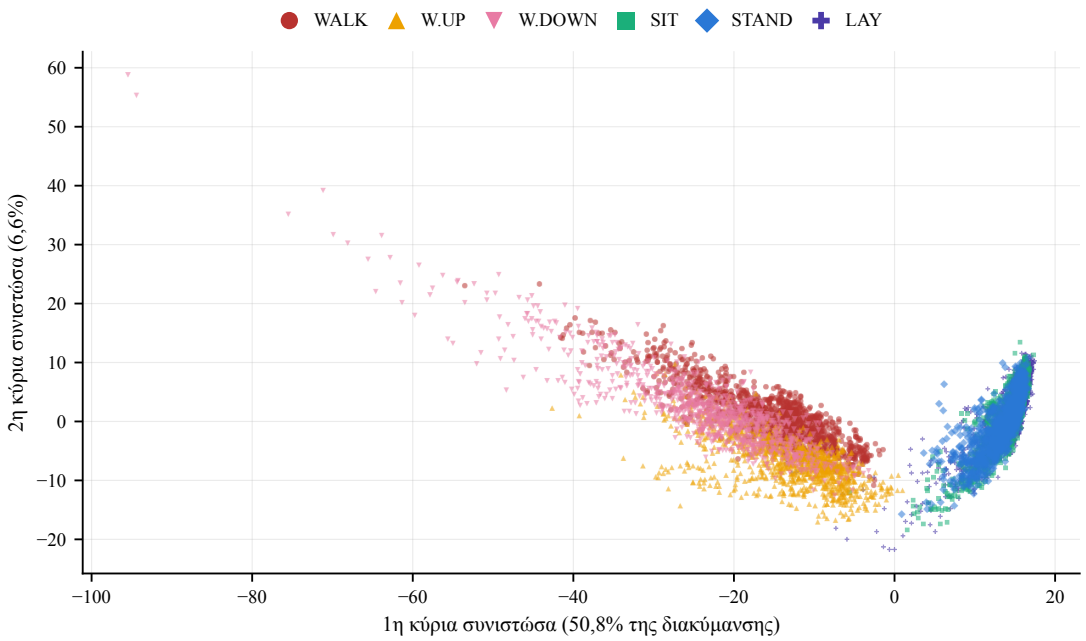
Πριν από οποιαδήποτε εκπαίδευση, αξίζει να φανεί πόσο δύσκολο είναι το πρόβλημα, δηλαδή αν τα samples των έξι δραστηριοτήτων σχηματίζουν χωριστές ομάδες στον χώρο των



Σχήμα 3.2. Πάνω: η σύνθεση των δεδομένων κάθε client ανά δραστηριότητα. Κάτω: η απόσταση ολικής μεταβολής της κατανομής του καθενός από εκείνη ολόκληρου του training set. Καμία κλάση δε λείπει από κανέναν. Η διάμεση απόσταση είναι 0,0423.

561 features. Ένας χώρος 561 διαστάσεων δε σχεδιάζεται απευθείας, γι' αυτό χρησιμοποιείται η ανάλυση κύριων συνιστωσών (*Principal Component Analysis*, PCA). Η PCA βρίσκει τις κατευθύνσεις του χώρου κατά μήκος των οποίων τα samples διαφέρουν περισσότερο μεταξύ τους. Η πρώτη κύρια συνιστώσα είναι η κατεύθυνση της μεγαλύτερης διακύμανσης. Η δεύτερη είναι η κατεύθυνση της μεγαλύτερης διακύμανσης που απομένει, κάθετη στην πρώτη. Αν κάθε sample προβληθεί στις δύο πρώτες, προκύπτει μια εικόνα δύο διαστάσεων που κρατά όσο το δυνατόν περισσότερη από τη διαφοροποίηση των samples. Εδώ η PCA εφαρμόστηκε στα 7.352 samples του training set, μετά την τυπικοποίηση της Ενότητας 3.5, χωρίς τα labels, τα οποία χρησιμοποιούνται μόνο για το χρώμα των σημείων. Οι δύο πρώτες συνιστώσες κρατούν μαζί το 57,4% της διακύμανσης και η πρώτη μόνη της το 50,8%.

Η προβολή δείχνει καθαρά τη δομή του προβλήματος (Σχήμα 3.3). Οι τρεις δυναμικές δραστηριότητες σχηματίζουν μια περιοχή και οι τρεις στατικές μια άλλη, με σαφή διαχωρισμό μεταξύ των δύο ομάδων. Μέσα σε κάθε ομάδα, όμως, οι δραστηριότητες επικαλύπτονται.

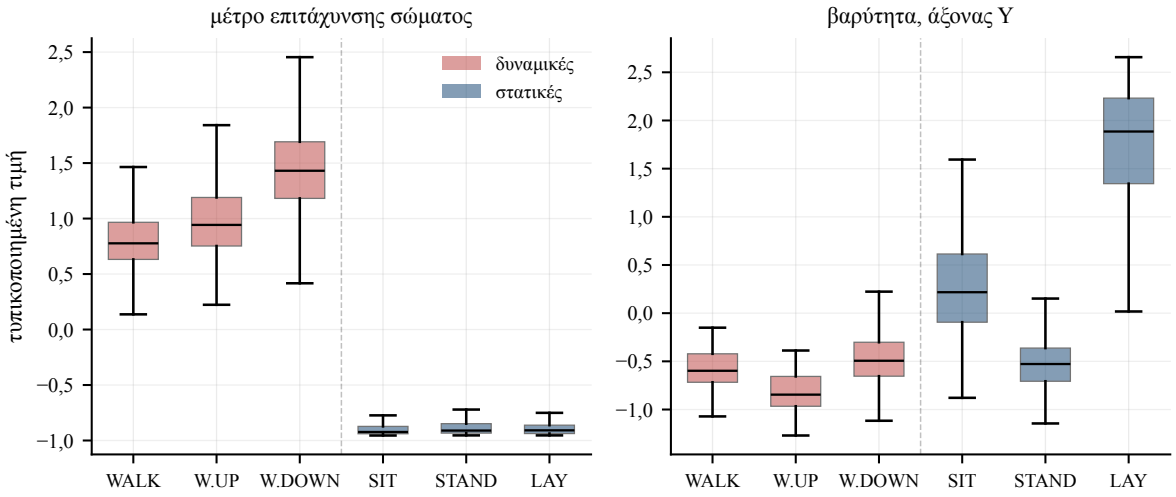


Σχήμα 3.3. Προβολή στις δύο πρώτες κύριες συνιστώσες. Ο διαχωρισμός των δυναμικών από τις στατικές δραστηριότητες είναι καθαρός, ενώ μέσα σε κάθε ομάδα οι κλάσεις επικαλύπτονται.

Το φαινόμενο ποσοτικοποιείται με το *silhouette coefficient*, το οποίο για κάθε σημείο συγκρίνει τη μέση απόσταση από τα σημεία της δικής του ομάδας με τη μέση απόσταση από τα σημεία της κοντινότερης ξένης ομάδας και κινείται στο $[-1, 1]$. Τιμές κοντά στο 1 σημαίνουν συμπαγείς και καλά διαχωρισμένες ομάδες, ενώ τιμές κοντά στο 0 σημαίνουν επικαλυπτόμενες. Με τις έξι δραστηριότητες ως ομάδες, η τιμή είναι $0{,}031$ στον πλήρη χώρο, δηλαδή πρακτικά μηδενική. Με δύο μόνο ομάδες, δυναμικές έναντι στατικών, ανεβαίνει στο $0{,}396$.

Η αντίθεση των δύο αριθμών είναι το ουσιαστικό εύρημα και προαναγγέλλει την ανάλυση σφαλμάτων της Ενότητας 4.7, γιατί δείχνει ότι το πρόβλημα δεν είναι η εύκολη διάκριση κίνησης από ακινησία αλλά η διάκριση μέσα σε κάθε ομάδα. Το χαμηλό silhouette coefficient των έξι κλάσεων δε σημαίνει απαραίτητα ότι το πρόβλημα είναι δύσκολο για έναν ταξινομητή. Το silhouette coefficient μετρά μόνο αποστάσεις, ενώ ένας ταξινομητής μπορεί να μάθει σύνορα ανάμεσα σε ομάδες που δεν είναι συμπαγείς.

Η αιτία φαίνεται στο Σχήμα 3.4, με δύο από τα έτοιμα features. Το μέτρο της επιτάχυνσης του σώματος χωρίζει τις δυναμικές από τις στατικές δραστηριότητες αλλά μέσα στις στατικές σχεδόν δεν αλλάζει. Και οι τρεις στάσεις είναι ακίνητες, άρα η συνιστώσα κίνησης είναι σχεδόν μηδενική και ό,τι απομένει για να τις ξεχωρίσει είναι η κλίση του κορμού, δηλαδή η κατεύθυνση της βαρύτητας ως προς τη συσκευή. Η κατάκλιση ξεχωρίζει καθαρά, γιατί εκεί αλλάζει ο προσανατολισμός ολόκληρου του κορμού. Η καθιστή και η όρθια στάση διαφέρουν πολύ λιγότερο και με επικάλυψη, αφού η κλίση της μέσης ανάμεσά τους είναι μικρή και διαφέρει από άνθρωπο σε άνθρωπο.



Σχήμα 3.4. Δύο από τα 561 features, στο training set και σε τυποποιημένη κλίμακα (Ενότητα 3.5). Αριστερά, το μέσο μέτρο της επιτάχυνσης του σώματος (`tBodyAccMag-mean()`) χωρίζει τις δυναμικές από τις στατικές δραστηριότητες. Δεξιά, η μέση συνιστώσα της βαρύτητας στον άξονα Y (`tGravityAcc-mean()-Y`) ξεχωρίζει την κατάκλιση και, με επικάλυψη, την καθιστή από την όρθια στάση. Τα κουτιά περιέχουν το μεσαίο μισό των samples κάθε δραστηριότητας, η γραμμή μέσα τους είναι η διάμεσος. Οι κεραίες φτάνουν έως 1,5 φορές το ενδοτεταρτημοριακό εύρος. Οι ακραίες τιμές πέρα από αυτό (Ενότητα 3.3.4) δε σχεδιάζονται.

Οι δημιουργοί του συνόλου καταγράφουν την ίδια επικάλυψη και την αποδίδουν στη φυσική θέση της συσκευής πάνω στο σώμα [1]. Το ίδιο ζεύγος επανέρχεται στην ανάλυση σφαλμάτων της Ενότητας 4.7.

3.5 Προεπεξεργασία και Πρωτόκολλο Διαχωρισμού

Η προεπεξεργασία περιλαμβάνει ένα μόνο βήμα, την τυπικοποίηση z-score ανά feature,

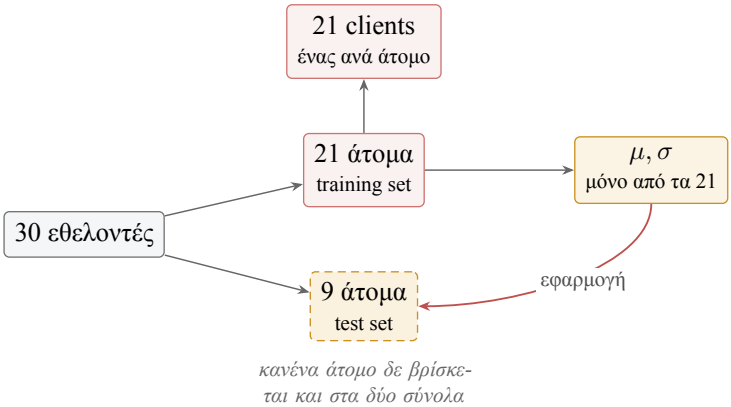
$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j}, \tag{3.4}$$

όπου μ_j και σ_j ο μέσος και η τυπική απόκλιση της στήλης j υπολογισμένα *αποκλειστικά* από το training set. Οι λόγοι αναπτύχθηκαν στην Ενότητα 3.3.1. Το βήμα ακυρώνει τη διαρροή της πηγής και ταυτόχρονα φέρνει όλα τα features σε συγκρίσιμη κλίμακα, πράγμα που διευκολύνει την εκπαίδευση.

Ο διαχωρισμός γίνεται σε δύο επίπεδα, το καθένα με δικό του σκοπό. Το Σχήμα 3.5 τα δείχνει μαζί με το σημείο όπου υπολογίζονται οι παράμετροι της τυπικοποίησης.

Το πρώτο είναι ο *διαχωρισμός ατόμων*. Οι 21 εθελοντές του επίσημου training set γίνονται οι clients και οι 9 του test set παραμένουν αποκλειστικά για αξιολόγηση. Κανένα άτομο δεν εμφανίζεται και στις δύο πλευρές, οπότε κάθε αξιολόγηση γίνεται σε ανθρώπους των οποίων τα δεδομένα δε χρησιμοποιήθηκαν ποτέ στην εκπαίδευση.

Το δεύτερο είναι η *κατάτμηση σε clients*, η οποία συμπίπτει με το πρώτο, αφού αντιστοιχεί ένας client σε κάθε άτομο, χωρίς τυχαίο μοίρασμα samples. Η επιλογή αυτή είναι ουσιώδης για το Κεφάλαιο 5, γιατί κάνει την ερώτηση «πόσο συνεισέφερε ο client i» ταυτόσημη με την ερώτηση «πόσο συνεισέφερε αυτός ο άνθρωπος». Με τυχαίο μοίρασμα η ερώτηση θα έχανε το νόημά της.



Σχήμα 3.5. Ο χωρισμός είναι δοσμένος από την πηγή και είναι *ανά άτομο*, οπότε κανένας άνθρωπος δεν εμφανίζεται και στα δύο σύνολα. Οι παράμετροι της τυπικοποίησης υπολογίζονται αποκλειστικά από τα 21 άτομα του training set και έπειτα εφαρμόζονται και στα εννέα του test set.

Δε γίνεται κανένας εσωτερικός διαχωρισμός μέσα στους clients. Η εργασία δε χρησιμοποιεί validation set και κάθε client εκπαιδεύεται σε όλα τα samples του.

Κεφάλαιο 4

Υλοποίηση και Σύγκριση των Τοπολογιών Μάθησης

Το κεφάλαιο περιγράφει το λογισμικό, το μοντέλο και τις τρεις τοπολογίες μάθησης. Στη συνέχεια, τις συγκρίνει. Απαντά έτσι στο πρώτο ερευνητικό ερώτημα, δηλαδή στο τι κοστίζει η ομοσπονδιακή εκπαίδευση σε accuracy σε σχέση, αφενός, με την κεντρική και, αφετέρου, με την ατομική. Η αρχή που διέπει την υλοποίηση είναι ότι κάθε διαφορά μεταξύ των τοπολογιών πρέπει να είναι *σκόπιμη* και οτιδήποτε δεν είναι σκόπιμο μοιράζεται.

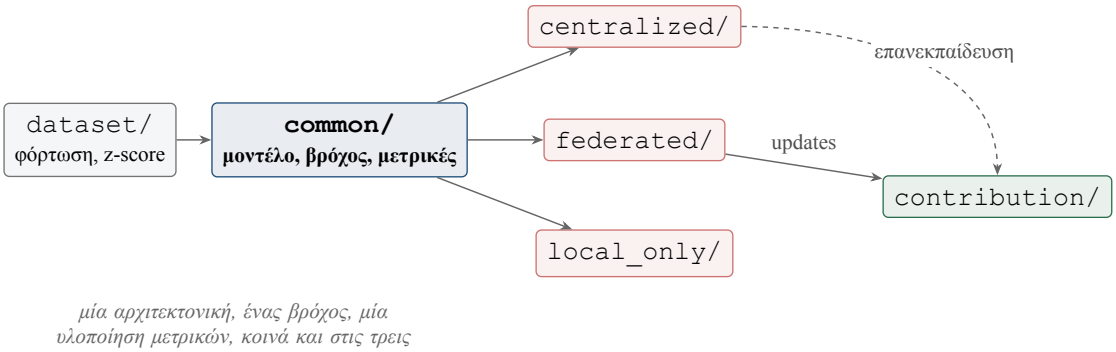
Μετά την υλοποίηση, περιγράφεται το πειραματικό πρωτόκολλο. Ακολουθεί ένας έλεγχος για το αν το δίκτυο ταιριάζει στο πρόβλημα, με σύγκριση απέναντι σε απλούστερα μοντέλα. Έπειτα, συγκρίνονται οι τρεις τοπολογίες. Το κεφάλαιο κλείνει με την ανάλυση των σφαλμάτων του μοντέλου, η οποία οδηγεί στο Κεφάλαιο 5.

4.1 Οργάνωση του Λογισμικού

Η υλοποίηση είναι γραμμένη σε Python. Τα δίκτυα υλοποιούνται με τη βιβλιοθήκη PyTorch [39], οι μετρικές με το scikit-learn [13] (Ενότητα 2.1.2) και ο KernelSHAP με τη βιβλιοθήκη `shap` [20] (Ενότητα 5.2.1). Τα αποτελέσματα αναπαράγονται με τις εκδόσεις των βιβλιοθηκών που δηλώνει το αρχείο απαιτήσεων του κώδικα.

Η οργάνωση σε υπομονάδες ακολουθεί το σχήμα ενός υπάρχοντος αποθετηρίου αναφοράς για ομοσπονδιακή μάθηση [40], με έναν φάκελο ανά ρόλο (Σχήμα 4.1). Ο φάκελος `dataset` αφορά τη φόρτωση και την προεπεξεργασία και ο `common` ό,τι μοιράζονται όλες οι τοπολογίες. Υπάρχει επίσης από ένας φάκελος για κάθε τοπολογία (`centralized`, `federated`, `local_only`). Η αποτίμηση της συνεισφοράς του Κεφαλαίου 5 έχει δικό της φάκελο (`contribution`). Η ροή της δίνεται στα Σχήματα 5.2 και 5.7.

Η κρίσιμη απόφαση βρίσκεται στο τι περιέχει το `common`, δηλαδή *μία* αρχιτεκτονική μοντέλου, *ένας* βρόχος εκπαίδευσης και *μία* υλοποίηση μετρικών, τα οποία «καλούν» και οι τρεις τοπολογίες. Ο λόγος είναι μεθοδολογικός. Αν ο κεντρικός και ο ομοσπονδιακός κώδι-



Σχήμα 4.1. Ένας φάκελος ανά ρόλο. Ό,τι πρέπει να είναι κοινό ζει στο `common` και «καλείται» από τις τρεις τοπολογίες, ώστε καμία διαφορά μεταξύ τους να μην οφείλεται σε αποκλίνοντα αντίγραφα κώδικα. Η αποτίμηση συνεισφοράς διαβάζει τα updates της ομοσπονδιακής και, για το δεύτερο παίγνιο, καλεί την κεντρική εκπαίδευση.

κας είχαν ο καθένας το δικό του αντίγραφο του βρόχου εκπαίδευσης, τα δύο αντίγραφα θα απέκλιναν και τότε η σύγκριση «κεντρική έναντι ομοσπονδιακής» θα μετρούσε τη διαφορά των αντιγράφων και όχι τη διαφορά των τοπολογιών.

Δύο αποφάσεις της ομοσπονδιακής εκπαίδευσης έχουν δικό τους αρχείο στον φάκελο `federated/fl/`. Το `selectors.py` αποφασίζει ποιοι συμμετέχουν σε κάθε round και ο φάκελος `aggregation/` πώς ενώνονται τα updates τους. Στα κύρια πειράματα συμμετέχουν όλοι, ενώ στο πείραμα αφαίρεσης της Ενότητας 5.7.4 όλοι εκτός από μια λίστα clients.

Η είσοδος δεδομένων είναι ενοποιημένη σε δύο επίπεδα. Τα ακατέργαστα αρχεία διαβάζονται μία φορά, τυπικοποιούνται και γράφονται στον δίσκο ως παραδοτέο σύνολο μαζί με αρχείο προέλευσης. Από εκεί και πέρα, κάθε πείραμα φορτώνει το παραδοτέο. Κάθε φόρτωση επαληθεύει αθροίσματα ελέγχου SHA-256 σε 26 αρχεία πηγής και 9 αρχεία εξόδου και, αν κάποιο αρχείο έχει αλλάξει, σταματά, αντί να προχωρήσει με άγνωστα δεδομένα. Κάθε αρχείο αποτελεσμάτων κρατά επιπλέον το αποτύπωμα των δεδομένων από τα οποία παρήχθη. Ο έλεγχος έχει σημασία για τα πειράματα του Κεφαλαίου 5, που διαρκούν ώρες και διαβάζουν το ίδιο παραδοτέο με τα κύρια πειράματα. Αν το σύνολο άλλαζε ανάμεσα σε δύο εκτελέσεις, τα δύο αποτελέσματα θα έπαυαν να είναι συγκρίσιμα χωρίς κανένα ορατό σημάδι.

4.2 Αρχιτεκτονική και Υπερπαράμετροι του Δικτύου

Το μοντέλο είναι ένα απλό τεχνητό νευρωνικό δίκτυο (*Artificial Neural Network*, ANN), συγκεκριμένα ένα δίκτυο MLP (Ενότητα 2.1) με δύο κρυφά επίπεδα, διαστάσεων $561 \to 256 \to 128 \to 6$, με ReLU και dropout μετά από κάθε κρυφό επίπεδο και γραμμικό επίπεδο εξόδου έξι μονάδων. Στο εξής αναφέρεται ως «το δίκτυο» και, όπου συγκρίνεται με άλλα μοντέλα, ως «δίκτυο ANN», όπως και στα σχήματα. Το συνολικό πλήθος εκπαιδεύσιμων παραμέτρων είναι $(561 \cdot 256 + 256) + (256 \cdot 128 + 128) + (128 \cdot 6 + 6) = 177.542$.

Το πλήρως συνδεδεμένο δίκτυο επιλέχθηκε ως η απλούστερη αρχιτεκτονική που ταιριάζει στην αναπαράσταση. Ο άξονας της εισόδου δεν είναι ούτε χρόνος, ούτε χώρος αλλά δείκτης feature. Μια συνέλιξη πάνω του θα υπέθετε ότι γειτονικοί δείκτες είναι σχετικοί, υπόθεση που δεν ισχύει, αφού το feature υπ' αριθμόν 40, μια συσχέτιση αξόνων της επιτάχυνσης του σώματος, δεν έχει καμία φυσική γειτνίαση με το 41, τη μέση τιμή της βαρύτητας. Το πλήρως συνδεδεμένο δίκτυο δεν κάνει τέτοια υπόθεση.

Οι υπερπαράμετροι δηλώνονται ως *σταθερές, χωρίς αναζήτηση*. Αυτό είναι περιορισμός και καταγράφεται ως τέτοιος στην Ενότητα 6.2, αλλά δύο από τις τιμές δεν είναι αυθαίρετες. Το *learning rate* 10^{-3} του Adam είναι ακριβώς η προτεινόμενη προεπιλογή του αρχικού άρθρου, το οποίο αναφέρει ότι καλές προεπιλεγμένες ρυθμίσεις για τα προβλήματα που δοκιμάστηκαν είναι $\alpha = 0{,}001$ [9]. Το dropout $0{,}3$ αντιστοιχεί σε πιθανότητα *διατήρησης* $p = 0{,}7$, αφού η υλοποίηση του PyTorch παραμετροποιείται με την πιθανότητα *απόρριψης*. Το αρχικό άρθρο δείχνει ότι το σφάλμα είναι επίπεδο για $0{,}4 \le p \le 0{,}8$ [10]. Η τιμή βρίσκεται, δηλαδή, μέσα στο επίπεδο τμήμα της καμπύλης. Δε βελτιστοποιήθηκε αλλά ούτε επιλέχθηκε τυχαία.

Οι υπόλοιπες σταθερές είναι το batch size 64, το cross-entropy ως loss function, ο Adam ως *optimizer* και οι διαστάσεις των κρυφών επιπέδων 256 και 128.

4.3 Οι Τρεις Τοπολογίες Μάθησης

4.3.1 Κεντρική εκπαίδευση

Η κεντρική τοπολογία είναι το άνω όριο αναφοράς. Όλα τα δεδομένα των 21 clients συγκεντρώνονται σε ένα σύνολο 7.352 samples και εκπαιδεύεται ένα μοντέλο για 100 *epochs*. Δεν υπάρχει έννοια client σε αυτή τη ρύθμιση. Η αξιολόγηση γίνεται στο κοινό test set των 2.947 samples.

Η εκπαίδευση γίνεται με την *ίδια* συνάρτηση που χρησιμοποιεί κάθε client στην ομοσπονδιακή τοπολογία, με το ίδιο batch size, τον ίδιο optimizer και το ίδιο learning rate (Ενό-

τητα 4.2). Οι δύο τοπολογίες διαφέρουν, επομένως, στο πού βρίσκονται τα δεδομένα και στο πώς ενώνονται τα updates, όχι στον βρόχο εκπαίδευσης. Η διαφορά αυτή έχει συνέπεια. Εδώ τα samples ανακατεύονται σε κάθε epoch, οπότε κάθε batch περιέχει samples πολλών ανθρώπων και κάθε βήμα του optimizer βλέπει ένα μείγμα του πληθυσμού. Στην ομοσπονδιακή τοπολογία, αντίθετα, κάθε local update προέρχεται από έναν μόνο client και το μείγμα σχηματίζεται μόνο στο aggregation. Από αυτή τη διαφορά προκύπτει το *client drift* της Ενότητας 2.2.3, όταν τα δεδομένα των clients διαφέρουν μεταξύ τους.

Ο χαρακτηρισμός «άνω όριο» περιγράφει ρόλο αναφοράς, όχι εγγύηση. Τίποτα δεν αποκλείει την ομοσπονδιακή τοπολογία να φτάσει ή να ξεπεράσει την κεντρική σε κάποιο seed, δηλαδή σε κάποια επανάληψη με άλλη τιμή εκκίνησης της γεννήτριας τυχαίων αριθμών.

4.3.2 Ομοσπονδιακή εκπαίδευση με FedAvg

Η ομοσπονδιακή τοπολογία υλοποιεί τον FedAvg κατά το πρότυπο του αρχικού άρθρου [3]. Σε κάθε round, ο server στέλνει τις τρέχουσες παραμέτρους σε όλους τους clients, ο καθένας εκπαιδεύει για ένα local epoch πάνω στα δικά του δεδομένα και ο server συναθροίζει με βάρη ανάλογα του πλήθους samples κάθε client, σύμφωνα με την Εξίσωση (2.10).

Χρησιμοποιείται *full participation*, που σημαίνει ότι και οι 21 clients εκπαιδεύουν και στέλνουν update σε κάθε round ($C = 1$). Η επιλογή αυτή δεν είναι απλοποίηση που κρύβει τα δύσκολα. Αντιθέτως, όπως αναφέρθηκε στην Ενότητα 2.2.3, η απόκλιση των clients επιμένει ακόμη και όταν συμμετέχουν όλοι σε κάθε round [15], οπότε το full participation *απομονώνει* το φαινόμενο, αντί να το συγκαλύπτει. Υπάρχει και μια δεύτερη, πρακτική συνέπεια, που αφορά άμεσα το Κεφάλαιο 5. Όταν όλοι συμμετέχουν πάντα, το παίγνιο κάθε round έχει πάντα τους ίδιους 21 παίκτες και οι τιμές είναι αθροίσιμες στα rounds, χωρίς διόρθωση για διαφορετική συχνότητα συμμετοχής.

Δύο σημεία της υλοποίησης αξίζει να δηλωθούν, επειδή διαφέρουν από προφανείς εναλλακτικές. Πρώτον, κάθε client κρατά *ανεξάρτητο αντίγραφο* του μοντέλου. Σε υλοποιήσεις, όπου όλοι οι clients μοιράζονται το ίδιο αντικείμενο δικτύου, η «ομοσπονδία» εκφυλίζεται σε σειριακή εκπαίδευση, όπου ο καθένας συνεχίζει από εκεί που σταμάτησε ο προηγούμενος, πράγμα που αλλάζει εντελώς τη σημασιολογία του αλγορίθμου. Δεύτερον, οι εσωτερικές καταστάσεις του Adam κάθε client *διατηρούνται* μεταξύ rounds. Αυτό είναι σχεδιαστική επιλογή και όχι το μόνο δυνατό, αφού η εναλλακτική θα ήταν ο μηδενισμός τους σε κάθε round. Δηλώνεται εδώ, ώστε το πείραμα να είναι αναπαραγώγιμο.

4.3.3 Ατομική εκπαίδευση

Η ατομική τοπολογία είναι το κάτω όριο αναφοράς και απαντά στο ερώτημα «τι θα είχε ο καθένας, αν έμενε μόνος». Κάθε ένας από τους 21 clients εκπαιδεύει δικό του μοντέλο αποκλειστικά στα δικά του δεδομένα, για 100 epochs και χωρίς καμία επικοινωνία. Αξιολογείται στο *ίδιο* κοινό test set των 2.947 samples με τις άλλες δύο τοπολογίες.

Η ταύτιση του evaluation set είναι αυτό που κάνει τη σύγκριση έγκυρη. Αν κάθε client αξιολογούνταν σε δικό του κρατημένο τμήμα, οι αριθμοί δε θα ήταν συγκρίσιμοι μεταξύ τους, ούτε με τις άλλες τοπολογίες, γιατί το καθένα θα ήταν διαφορετικής δυσκολίας. Επειδή κάθε client εκπαιδεύεται και αξιολογείται σε 20 διαφορετικές αρχικοποιήσεις, η τοπολογία αυτή παράγει $21 \times 20 = 420$ εκτελέσεις.

4.4 Πειραματικό Πρωτόκολλο και Μετρήσεις

Όλα τα πειράματα εκτελούνται με 20 διαφορετικά seeds (0 έως 19) και αναφέρονται ως μέσος όρος με την τυπική απόκλισή τους. Ο υπολογισμός γίνεται σε CPU, ώστε τα αποτελέσματα να είναι ντετερμινιστικά και αναπαραγώγιμα. Ο υπολογιστικός προϋπολογισμός είναι *σταθερός και αντιστοιχισμένος*, με 100 epochs για την κεντρική και την ατομική τοπολογία και 100 rounds επί ένα local epoch για την ομοσπονδιακή. Δε χρησιμοποιείται validation set και δεν εφαρμόζεται πρόωρος τερματισμός, οπότε κάθε τοπολογία εκπαιδεύεται για ολόκληρο τον προϋπολογισμό.

Όλες οι μετρήσεις γίνονται στο κοινό test set των 2.947 samples, τα οποία προέρχονται από 9 ανθρώπους που δεν εμφανίζονται ποτέ στην εκπαίδευση. Η αξιολόγηση είναι επομένως *subject-independent*, το πρωτόκολλο δηλαδή που η βιβλιογραφία των μεθόδων αναγνώρισης δραστηριότητας θεωρεί μη παραπλανητικό [37], [38]. Αναφέρονται δύο μετρικές, το accuracy (Εξίσωση (2.1)) και το macro-F1 (Εξίσωση (2.4)), για λόγους που εξηγούνται στην Ενότητα 2.1.2. Επειδή οι έξι κλάσεις είναι σχεδόν ισορροπημένες (Ενότητα 3.4.1), οι δύο αναμένεται να κινούνται μαζί και αναφέρονται και οι δύο ακριβώς για να φαίνεται ότι όντως κινούνται.

Η τυπική απόκλιση μεταξύ seeds. Η τιμή που ακολουθεί το $\pm$ είναι η **τυπική απόκλιση μεταξύ των 20 εκτελέσεων**. Μετράει δηλαδή πόσο κουνιέται το αποτέλεσμα, όταν αλλάζουν οι τυχαίες αρχικές τιμές των παραμέτρων του δικτύου (η αρχικοποίηση των βαρών), η τυχαία σειρά με την οποία τα samples μοιράζονται σε batches των 64 σε κάθε epoch και οι μονάδες που απενεργοποιεί τυχαία το dropout, ενώ τα δεδομένα μένουν ίδια. **Δεν** είναι διάστημα εμπιστοσύνης και **δε** λέει πόσο θα άλλαζε το αποτέλεσμα σε άλλους ανθρώπους. Η διάκριση

είναι ουσιώδης, γιατί το test set περιέχει 2.947 samples αλλά μόνο 9 ανεξάρτητα άτομα. Τα samples του ίδιου ατόμου είναι, επιπλέον, συσχετισμένα, τόσο επειδή προέρχονται από τον ίδιο άνθρωπο, όσο και επειδή επικαλύπτονται κατά 50% (Ενότητα 3.3.3). Ένα διάστημα εμπιστοσύνης που θα υπολόγιζε τα 2.947 samples ως ανεξάρτητα θα ήταν πολύ στενότερο από το πραγματικό. Η αβεβαιότητα γενίκευσης σε νέους ανθρώπους δεν ποσοτικοποιείται εδώ και δηλώνεται ως περιορισμός στην Ενότητα 6.2.

Η τελική τιμή και όχι η καλύτερη. Όλα τα νούμερα που ακολουθούν είναι η επίδοση στο *τέλος* του προϋπολογισμού, δηλαδή στο epoch ή στο round 100. Δεν είναι **ποτέ** η καλύτερη τιμή που εμφανίστηκε κατά τη διάρκεια. Η διάκριση δεν είναι τυπική, αφού στην ομοσπονδιακή τοπολογία η καλύτερη τιμή κάθε seed εμφανίζεται σε διαφορετικό round (από το 33ο έως το 89ο) και κατά μέσο όρο είναι $94{,}50$, δηλαδή σχεδόν $0{,}40$ μονάδες πάνω από την τελική. Η αναφορά της θα ήταν, όμως, επιλογή πάνω στο test set, αφού το «ποιο round ήταν το καλύτερο» καθορίζεται από 100 αξιολογήσεις σε αυτό ακριβώς το σύνολο. Η τελική τιμή είναι η μόνη που δεν εμπεριέχει τέτοια επιλογή.

Ζευγαρωτή σύγκριση ανά seed. Η σύγκριση μεταξύ τοπολογιών γίνεται πάντα *ζευγαρωτά*. Για κάθε seed s υπολογίζεται η διαφορά των δύο τοπολογιών. Αναφέρεται ο μέσος όρος των διαφορών μαζί με το πλήθος των seeds στα οποία η διαφορά έχει το ίδιο πρόσημο. Αυτό είναι πιο πληροφοριακό από τη σύγκριση δύο ανεξάρτητων μέσων όρων, γιατί απομονώνει τη μεταβλητότητα που οφείλεται στην αρχικοποίηση. Δεν αναφέρεται στατιστικό ελέγχου υπόθεσης, γιατί οι 20 εκτελέσεις δεν είναι ανεξάρτητα δείγματα από πληθυσμό ατόμων αλλά επαναλήψεις πάνω στα ίδια δεδομένα.

Συγκρίσιμα μόνο τα αντιστοιχισμένα αποτελέσματα. Κατά την ανάπτυξη, βρέθηκε ότι ίδιο seed και ίδιο πλήθος epochs αλλά με διαφορετικά σημεία ενδιάμεσης αξιολόγησης δίνουν διαφορετικό αποτέλεσμα, επειδή η αξιολόγηση καταναλώνει τυχαιότητα και μετακινεί τη γεννήτρια. Δύο αριθμοί είναι επομένως συγκρίσιμοι, μόνο αν παρήχθησαν από ταυτόσημη ρύθμιση, κανόνας που εφαρμόζεται σε όλες τις συγκρίσεις της εργασίας. Για τον ίδιο λόγο, κάθε αριθμός του κειμένου καταγράφεται σε μητρώο μαζί με το αποθηκευμένο αποτέλεσμα από το οποίο προέρχεται. Ένας αυτόματος έλεγχος εντοπίζει κάθε αριθμό χωρίς δηλωμένη προέλευση. Η προσέγγιση αυτή απαντά στην καταγεγραμμένη διαπίστωση ότι η διαρροή και τα προβλήματα αναπαραγωγιμότητας έχουν οδηγήσει σε υπερβολικά αισιόδοξα συμπεράσματα σε δημοσιεύσεις δεκαεπτά επιστημονικών πεδίων [36].

4.5 Σύγκριση του Δικτύου με Απλούστερα Μοντέλα

Πριν συγκριθούν οι τρεις τοπολογίες μεταξύ τους, χρειάζεται να είναι γνωστό πόση από την επίδοση οφείλεται στο *μοντέλο*. Όλες οι συγκρίσεις που ακολουθούν κρατούν την αρχιτεκτονική σταθερή, οπότε, αν το συγκεκριμένο δίκτυο ANN ήταν υπερβολικά ισχυρό ή υπερβολικά αδύναμο για το πρόβλημα, η επιλογή θα μετέφερε συστηματικό σφάλμα σε κάθε επόμενο νούμερο.

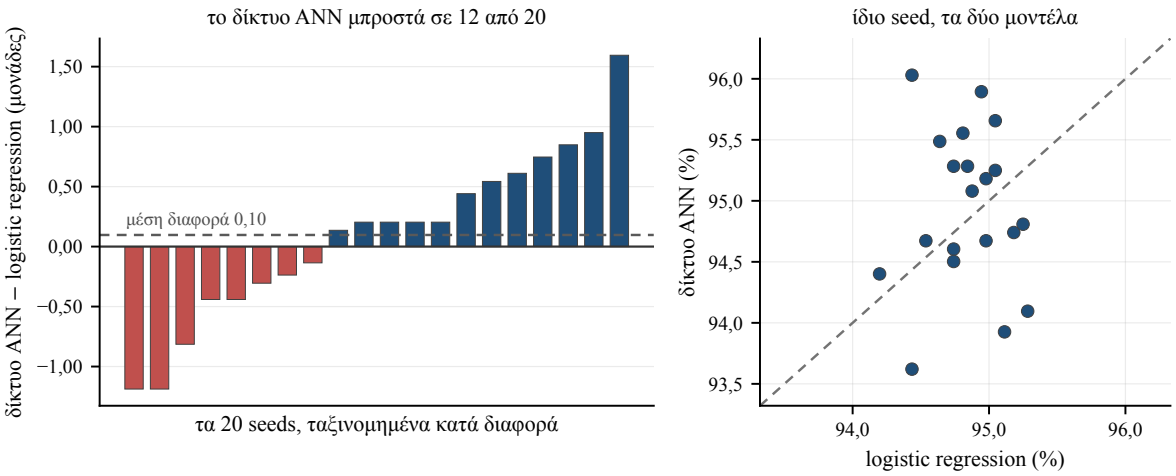
Για τον σκοπό αυτό, εκπαιδεύτηκαν κεντρικά, εκτός από το δίκτυο ANN, τρία απλούστερα μοντέλα, συγκεκριμένα το **logistic regression**, ένα **linear SVM** (*Support Vector Machine*) και ένα **Random Forest**. Το logistic regression είναι το *ίδιο* μοντέλο χωρίς τα κρυφά επίπεδα, δηλαδή ένα μοναδικό γραμμικό επίπεδο $561 \to 6$ με 3.372 παραμέτρους έναντι των 177.542 του δικτύου ANN. Εκπαιδεύεται με τον ίδιο βρόχο και τον ίδιο optimizer. Το SVM και το Random Forest προέρχονται από τη βιβλιοθήκη scikit-learn [13] και εκτελούνται με τις προεπιλεγμένες ρυθμίσεις της. Και τα τέσσερα βλέπουν τα ίδια 20 seeds και το ίδιο test set. Κανένα δε ρυθμίστηκε, ώστε η σύγκριση να μη μετράει τη διαφορά στην προσπάθεια ρύθμισης. Τα αποτελέσματα δίνονται στον Πίνακα 4.1.

Μοντέλο	**Παράμετροι**	**Accuracy (%)**	**macro-F1 (%)**
Δίκτυο ANN 561→256→128→6	177.542	$94{,}94 \pm 0{,}65$	$94{,}88 \pm 0{,}67$
Logistic regression 561→6	3.372	$94{,}84 \pm 0{,}29$	$94{,}86 \pm 0{,}29$
Linear SVM	3.372	$96{,}17 \pm 0{,}00$	$96{,}22 \pm 0{,}00$
Random Forest	100 δέντρα	$92{,}63 \pm 0{,}23$	$92{,}43 \pm 0{,}23$

Πίνακας 4.1. Κεντρική εκπαίδευση, 20 seeds, κοινό test set. Το $\pm$ είναι τυπική απόκλιση μεταξύ seeds. Κανένα μοντέλο δε ρυθμίστηκε. Το linear SVM δίνει την ίδια πρόβλεψη σε όλα τα seeds, γι' αυτό η τυπική απόκλισή του είναι μηδέν.

Ισοπαλία με το logistic regression. Η διαφορά των $0{,}10$ μονάδων από το δίκτυο ANN δεν αντέχει τον ζευγαρωτό έλεγχο. Η τυπική απόκλιση της διαφοράς ανά seed είναι $0{,}71$ μονάδες, το εύρος της πάει από $-1{,}19$ έως $+1{,}59$ και το δίκτυο ANN υπερτερεί σε **12 από τα 20** seeds (Σχήμα 4.2). Με το κριτήριο της σταθερότητας του προσήμου, που εφαρμόζεται σε κάθε σύγκριση αυτού του κεφαλαίου, τα δύο μοντέλα **δεν ξεχωρίζουν με συνέπεια**. Το logistic regression θα μπορούσε, επίσης, να μπει στην ομοσπονδία χωρίς καμία αλλαγή, αφού εκπαιδεύεται με τον ίδιο βρόχο. Ο λόγος που δεν επιλέχθηκε, λοιπόν, δεν είναι ότι υστερεί. Δεν έδωσε, όμως, και λόγο να εγκαταλειφθεί η αρχική σχεδίαση, αφού η ισοπαλία σημαίνει ότι η επιλογή του δικτύου δεν κοστίζει accuracy.

Το αποτέλεσμα αυτό αφορά τα δεδομένα και όχι το δίκτυο. Τα 561 features δεν είναι ακατέργαστο σήμα αλλά στατιστικά μεγέθη υπολογισμένα από ειδικούς πάνω στο σήμα, στο



Σχήμα 4.2. Αριστερά: η διαφορά των δύο μοντέλων στο ίδιο seed, ταξινομημένη. Σε οκτώ από τα 20 seeds είναι αρνητική. Δεξιά: τα δύο μοντέλα στον ίδιο άξονα, ένα σημείο ανά seed. Η διαγώνιος είναι η ισοπαλία. Τα σημεία πέφτουν και στις δύο πλευρές της.

πεδίο του χρόνου και της συχνότητας [1], δηλαδή ένα μεγάλο μέρος της εργασίας που θα ανέθετε κανείς σε κρυφά επίπεδα έχει ήδη γίνει, πριν φτάσουν τα δεδομένα στο μοντέλο. Όταν αυτό συμβαίνει, οι κλάσεις γίνονται σε μεγάλο βαθμό γραμμικά διαχωρίσιμες και η πρόσθετη χωρητικότητα δεν έχει πού να αποδώσει. Η παρατήρηση ότι σε πινακοειδή δεδομένα τα νευρωνικά δίκτυα δεν έχουν αυτονόητο προβάδισμα είναι καταγεγραμμένη κανονικότητα και όχι ιδιαιτερότητα αυτού του συνόλου [41].

Το linear SVM, υψηλότερο αλλά εκτός ομοσπονδίας. Το SVM δίνει το μεγαλύτερο accuracy, 96,17%, κατά μέσο όρο 1,23 μονάδες πάνω από το δίκτυο ANN και πάνω από αυτό και στα 20 seeds. Η υπεροχή αφορά τα εννέα άτομα του test set και δεν είναι γνωστό αν μεταφέρεται σε άλλους ανθρώπους (Ενότητα 4.4). Ο λόγος που δεν υιοθετείται είναι ο τρόπος εκπαίδευσής του. Ο *solver* του, το LibLinear [13], παίρνει ολόκληρο το training set σε μία κλήση και επιστρέφει μία λύση, γι' αυτό και η πρόβλεψη είναι ίδια σε όλα τα seeds. Με τις προεπιλογές, μάλιστα, σταματά στο όριο των 1.000 επαναλήψεων, χωρίς να δηλώσει σύγκλιση. Ο FedAvg, αντίθετα, συνδυάζει *stochastic gradient descent* τοπικά σε κάθε client με μέσο όρο των μοντέλων στον server [3]. Για να μπει στην ομοσπονδία, το SVM θα έπρεπε να ξαναγραφτεί ως μοντέλο που εκπαιδεύεται με gradient descent πάνω στο δικό του loss function. Αυτό γίνεται αλλά είναι άλλη διαδικασία εκπαίδευσης και δεν είναι αυτός ο σκοπός της εργασίας.

Το Random Forest, χαμηλότερο και χωρίς παραμέτρους για μέσο όρο. Το Random Forest είναι το ασθενέστερο από τα τέσσερα, κατά μέσο όρο 2,3 μονάδες κάτω από το δίκτυο ANN και κάτω από αυτό και στα 20 seeds. Η βιβλιογραφία βρίσκει τα δέντρα ισχυρότερα σε πινακοειδή δεδομένα μεσαίου μεγέθους, με ρυθμισμένες υπερπαραμέτρους [41], ενώ εδώ, με τις προεπιλογές, έρχεται τελευταίο. Έχει επιπλέον δομικό εμπόδιο. Ο FedAvg ενώνει τα

μοντέλα των clients με σταθμισμένο μέσο όρο των παραμέτρων τους [3], ενώ ένα σύνολο δέντρων αποφάσεων δεν έχει διάνυσμα παραμέτρων πάνω στο οποίο να οριστεί μέσος όρος. Χωρίς update παραμέτρων ανά client, δεν ορίζεται ούτε το παίγνιο του Κεφαλαίου 5.

Ο λόγος που κρατιέται το δίκτυο. Ο λόγος δεν είναι ότι ταξινομεί καλύτερα, αφού το SVM το ξεπερνά στο test set και το logistic regression το φτάνει. Το ερώτημα της εργασίας, όμως, δεν είναι ποιος ταξινομητής πετυχαίνει το μεγαλύτερο accuracy. Και οι τρεις τοπολογίες, όπως και ολόκληρο το παίγνιο του Κεφαλαίου 5, απαιτούν μοντέλο που εκπαιδεύεται με gradient descent και παράγει *update παραμέτρων ανά client*, το οποίο ο FedAvg συνενώνει με σταθμισμένο μέσο όρο [3]. Από τα τέσσερα μοντέλα, όπως εκπαιδεύτηκαν εδώ, το κάνουν μόνο το δίκτυο ANN και το logistic regression. Αυτά τα δύο δεν ξεχωρίζουν σε accuracy. Κρατήθηκε το δίκτυο, που ήταν η αρχική σχεδίαση της εργασίας. Είναι και μία από τις μορφές μοντέλου με τις οποίες παρουσιάστηκε ο ίδιος ο FedAvg, ένα MLP με δύο κρυφά επίπεδα και ενεργοποίηση ReLU [3].

Το εύρημα καταγράφεται, πάντως, ως αποτέλεσμα και επανέρχεται στους περιορισμούς (Ενότητα 6.2). Για *αυτό* το πρόβλημα, με *αυτήν* την αναπαράσταση, ένα μοντέλο με περίπου 53 φορές λιγότερες παραμέτρους θα αρκούσε.

4.6 Σύγκριση των Τριών Τοπολογιών

Ο Πίνακας 4.2 συνοψίζει το βασικό αποτέλεσμα της σύγκρισης.

Τοπολογία μάθησης	**Accuracy (%)**	**macro-F1 (%)**	**Εκτελέσεις**
Κεντρική (100 epochs)	$94{,}94 \pm 0{,}65$	$94{,}88 \pm 0{,}67$	20
Ομοσπονδιακή (100×1)	$94{,}11 \pm 0{,}18$	$94{,}14 \pm 0{,}18$	20
Ατομική (100 epochs)	$75{,}81 \pm 5{,}14$	$74{,}86 \pm 5{,}84$	420

Πίνακας 4.2. Οι τρεις τοπολογίες μάθησης, 20 seeds, κοινό test set 2.947 samples. Το $\pm$ είναι τυπική απόκλιση μεταξύ εκτελέσεων.

4.6.1 Κόστος της αποκέντρωσης και όφελος της συνεργασίας

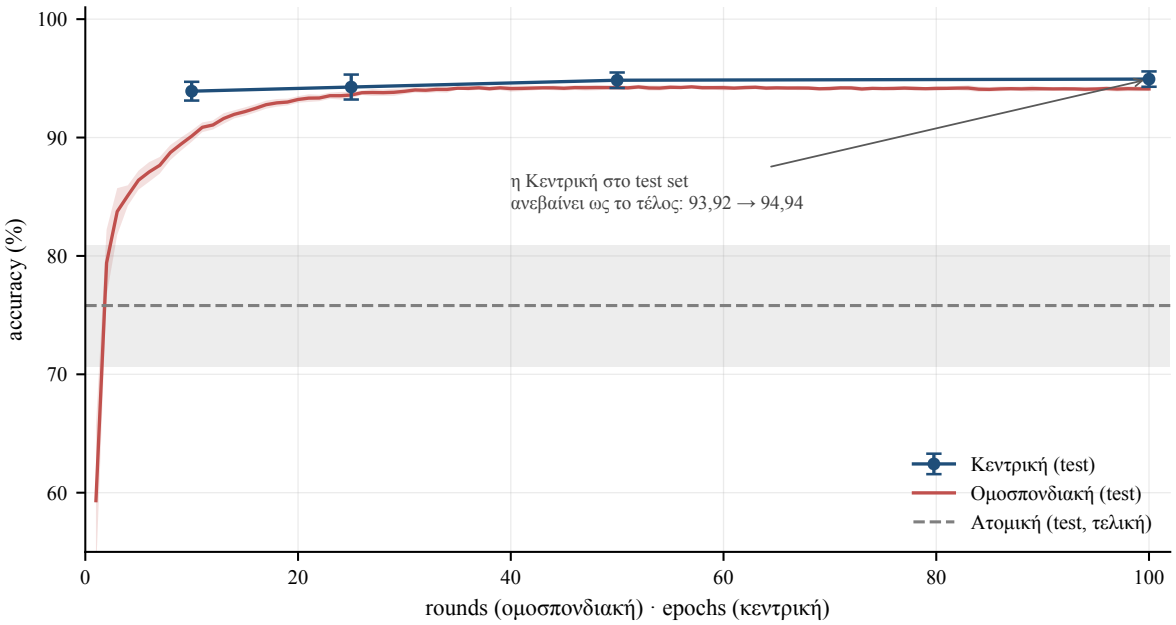
Το πρώτο εύρημα είναι ότι **το κόστος της αποκέντρωσης είναι μικρό**. Η ζευγαρωτή διαφορά κεντρικής μείον ομοσπονδιακής είναι $+0{,}83$ μονάδες, με θετικό πρόσημο σε 17 από τα 20 seeds. Η ομοσπονδιακή τοπολογία φτάνει, δηλαδή, περίπου το 99,1% της επίδοσης που θα είχε η συγκέντρωση όλων των δεδομένων, χωρίς κανένα δεδομένο να φύγει από τη συσκευή του.

Η ερμηνεία πρέπει να είναι προσεκτική. Το αποτέλεσμα αυτό *αναμένεται* σε αυτή τη ρύθμιση και δεν πρέπει να παρουσιαστεί ως έκπληξη, γιατί, όπως έδειξε η Ενότητα 3.4.2, οι clients είναι σχεδόν IID ως προς τα labels, με διάμεση απόσταση ολικής μεταβολής $0{,}0423$ και καμία κλάση να λείπει από κανέναν. Ο FedAvg δυσκολεύεται, όταν οι κατανομές labels αποκλίνουν έντονα [15], πράγμα που εδώ δε συμβαίνει. Ένα αντίστοιχο πείραμα με συνθετικά κατασκευασμένη λοξότητα labels θα αναμενόταν να δώσει μεγαλύτερο χάσμα.

Το δεύτερο εύρημα είναι ότι **το όφελος της συνεργασίας είναι μεγάλο**. Η ομοσπονδιακή τοπολογία ξεπερνά την ατομική κατά $18{,}30$ μονάδες. Ένας client που μένει μόνος με τα δικά του 281 έως 409 samples φτάνει κατά μέσο όρο $75{,}81$, ενώ συμμετέχοντας στην ομοσπονδία παίρνει μοντέλο με $94{,}11$.

Η σύγκριση με τη βιβλιογραφία γίνεται μόνο ποιοτικά και αφορά το κόστος της αποκέντρωσης. Οι Sozinov et al. αναφέρουν 89% για την ομοσπονδιακή έναντι 93% για την κεντρική εκπαίδευση [29] αλλά σε διαφορετικό σύνολο δεδομένων και με διαφορετικά μοντέλα, οπότε οι αριθμοί δεν είναι αντιστοιχίσιμοι. Ό,τι συμφωνεί είναι το πρόσημο του χάσματος, δηλαδή ότι η ομοσπονδιακή εκπαίδευση υστερεί λίγο.

Το Σχήμα 4.3 δείχνει πώς φτάνουν εκεί οι δύο συλλογικές τοπολογίες, με την ατομική ως γραμμή αναφοράς.

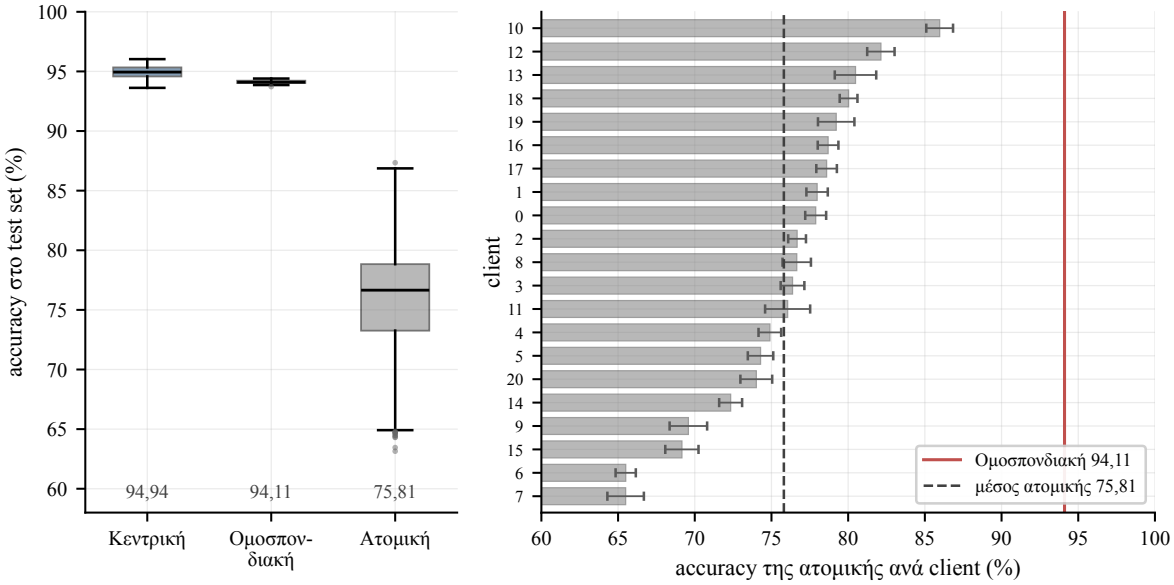


Σχήμα 4.3. Accuracy, μέσος όρος 20 seeds. Ο οριζόντιος άξονας μετράει rounds για την ομοσπονδιακή και epochs για την κεντρική. Η ομοσπονδιακή αξιολογείται σε κάθε round και η κεντρική στα epochs 10, 25, 50 και 100. Τα σημεία αυτά είναι μέρος της ρύθμισης του πειράματος, αφού η ενδιάμεση αξιολόγηση μετακινεί τη γεννήτρια τυχαίων αριθμών (Ενότητα 4.4). Η σκιασμένη ζώνη και οι μπάρες σφάλματος είναι $\pm$ μία τυπική απόκλιση μεταξύ seeds. Η ατομική αξιολογείται μόνο στο τέλος της εκπαίδευσης, οπότε φαίνεται ως οριζόντια γραμμή στην τελική της τιμή, $75{,}81\%$. Η ζώνη της είναι $\pm$ μία τυπική απόκλιση στις 420 εκτελέσεις και οφείλεται κυρίως στη διαφορά μεταξύ ανθρώπων (Ενότητα 4.6.2).

Και οι δύο καμπύλες ανεβαίνουν απότομα στα πρώτα rounds και έπειτα σταθεροποιούνται. Η ομοσπονδιακή τοπολογία έχει, επίσης, σαφώς *μικρότερη* τυπική απόκλιση μεταξύ seeds από την κεντρική, $0{,}18$ έναντι $0{,}65$. Μια πιθανή εξήγηση, που δεν ελέγχθηκε χωριστά, είναι ότι ο μέσος όρος των 21 local updates, καθένα με δικά του δεδομένα και δική του τυχαία σειρά batches, εξομαλύνει τον θόρυβο του καθενός.

4.6.2 Διασπορά της ατομικής επίδοσης μεταξύ ανθρώπων

Ο μέσος όρος $75{,}81$ της ατομικής τοπολογίας κρύβει τη σημαντικότερη πληροφορία της. Το δεξί τμήμα του Σχήματος 4.4 δείχνει την επίδοση ανά client, η οποία κυμαίνεται από $65{,}49$ για τον client 7 έως $85{,}97$ για τον client 10, δηλαδή εύρος πάνω από 20 μονάδες.



Σχήμα 4.4. Αριστερά: η κατανομή του accuracy για κάθε τοπολογία, σε 20 εκτελέσεις για την κεντρική και την ομοσπονδιακή και σε 420 για την ατομική. Η γραμμή μέσα σε κάθε κουτί είναι η διάμεσος και ο αριθμός κάτω από αυτό ο μέσος όρος. Δεξιά: η ατομική τοπολογία ανά client, μέσος όρος 20 seeds με $\pm$ μία τυπική απόκλιση. Κανένας client μόνος του δεν πλησιάζει την επίδοση της ομοσπονδίας.

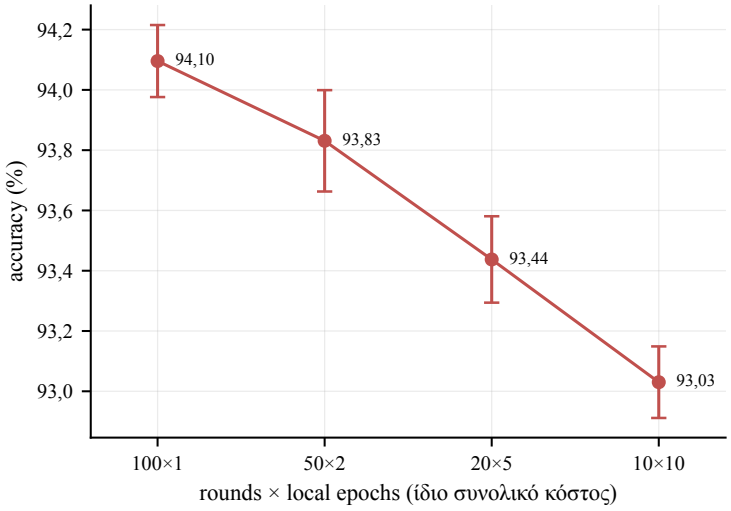
Η διασπορά αυτή αξίζει να αναλυθεί, γιατί οι ίδιες μετρήσεις δίνουν τρεις διαφορετικές τυπικές αποκλίσεις που σημαίνουν διαφορετικά πράγματα. Πάνω στις 420 μεμονωμένες εκτελέσεις, είναι $5{,}14$. Πάνω στους 21 μέσους όρους ανά client, είναι $5{,}17$. Πάνω στους 20 μέσους όρους ανά seed, είναι $0{,}15$. Η τελευταία σύγκριση είναι η ουσιαστική, γιατί δείχνει ότι **η τυπική απόκλιση μεταξύ ανθρώπων είναι περίπου 34 φορές εκείνη μεταξύ seeds**. Η διαφορά επίδοσης μεταξύ δύο clients δεν είναι θόρυβος αρχικοποίησης αλλά πραγματική ιδιότητα των ανθρώπων και των δεδομένων τους.

Εδώ γίνεται εμπειρικό το κίνητρο συμμετοχής που στην Ενότητα 2.3.5 δηλώθηκε μόνο θεωρητικά. Ο client 7, ο πιο αδύναμος μόνος του, περνά από $65{,}49$ σε $94{,}11$ συμμετέχοντας,

κερδίζοντας σχεδόν 29 μονάδες. Ο client 10, όμως, ο ισχυρότερος μόνος του, κερδίζει πάνω από 8 μονάδες. **Κανένας από τους 21 δε βγαίνει χαμένος από τη συμμετοχή**.

4.6.3 Local epochs έναντι rounds

Η ομοσπονδιακή τοπολογία εκπαιδεύει $E = 1$ local epoch ανά round και όχι περισσότερα. Θεωρητικά, περισσότερα local steps μεταξύ δύο aggregations σημαίνουν ισχυρότερο *client drift*, αφού ο καθένας απομακρύνεται περισσότερο προς το δικό του ελάχιστο, πριν προλάβει να διορθωθεί [14], [15]. Για να ελεγχθεί εμπειρικά η επιλογή, τέσσερις ρυθμίσεις δοκιμάστηκαν με *ίδιο συνολικό τοπικό υπολογιστικό κόστος*, δηλαδή ίδιο γινόμενο rounds επί local epochs, συγκεκριμένα 100×1, 50×2, 20×5 και 10×10. Τα αποτελέσματα, σε 5 seeds, είναι $94{,}10 \pm 0{,}13$, $93{,}83 \pm 0{,}19$, $93{,}44 \pm 0{,}16$ και $93{,}03 \pm 0{,}13$ αντίστοιχα και φαίνονται στο Σχήμα 4.5.



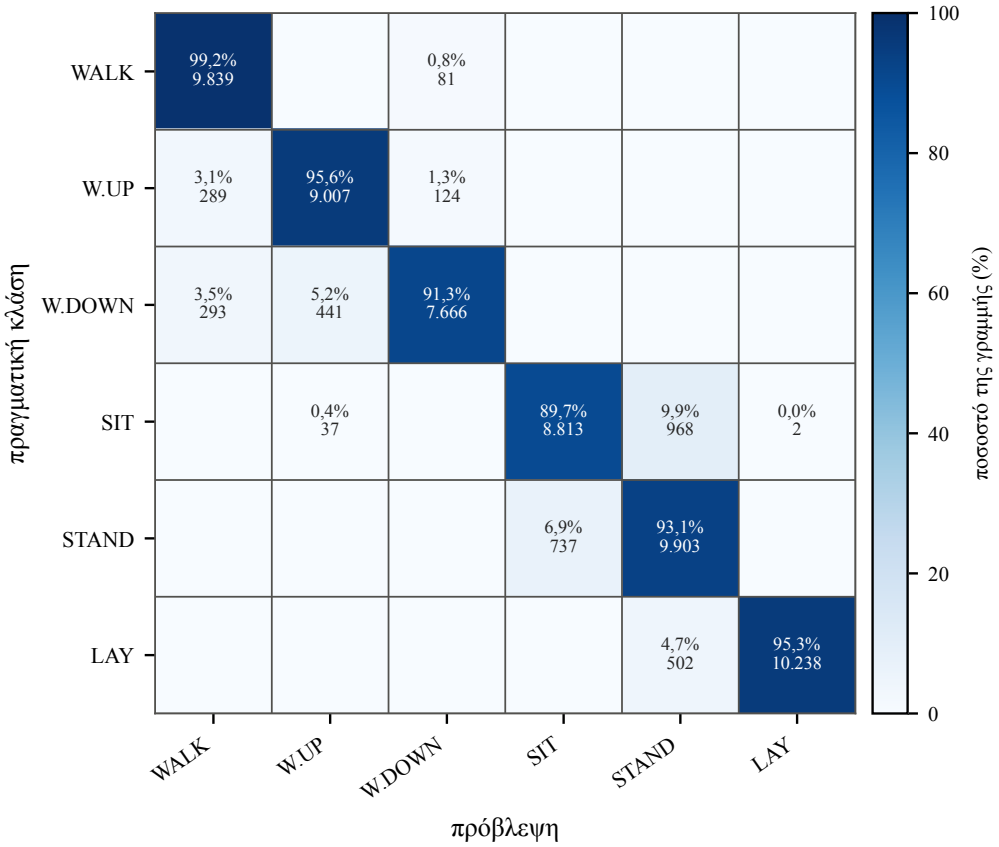
Σχήμα 4.5. Τέσσερις συνδυασμοί rounds και local epochs με ίδιο συνολικό υπολογιστικό κόστος, στην ομοσπονδιακή τοπολογία. Μέσος όρος και τυπική απόκλιση 5 seeds.

Η πτώση είναι μονότονη και το συνολικό εύρος $1{,}07$ μονάδες. Όσο αραιώνει το aggregation, τόσο χειρότερο το αποτέλεσμα, με σταθερό υπολογιστικό κόστος, πράγμα που είναι η εμπειρική υπογραφή του *client drift*. Η σάρωση έγινε, όπως όλες οι μετρήσεις της εργασίας, στο test set, γιατί η εργασία δεν κρατά χωριστό validation set. Δεν αποτελεί, επομένως, ανεξάρτητη επιλογή υπερπαραμέτρου. Επιβεβαιώνει, όμως, ότι η τιμή που προβλέπει η θεωρία, $E = 1$, είναι και η καλύτερη από τις τέσσερις.

Η μελέτη αυτή εκτελέστηκε με 5 seeds και **δε** συγκρίνεται αριθμητικά με τα κύρια αποτελέσματα των 20 seeds. Χρησιμοποιείται μόνο για τη σύγκριση των τεσσάρων ρυθμίσεων, οι οποίες είναι αντιστοιχισμένες μεταξύ τους.

4.7 Ανάλυση Σφαλμάτων

Το Σχήμα 4.6 δείχνει το confusion matrix της ομοσπονδιακής τοπολογίας, αθροισμένο και στα 20 seeds, δηλαδή $20 \times 2947 = 58.940$ προβλέψεις.



Σχήμα 4.6. Άθροισμα 20 seeds, 58.940 προβλέψεις. Κάθε κελί δείχνει το ποσοστό της γραμμής και το απόλυτο πλήθος. Το ζεύγος SITTING και STANDING συγκεντρώνει σχεδόν τα μισά σφάλματα του μοντέλου.

Οι τιμές recall ανά κλάση είναι 99,18% για τη WALKING, 95,62% για τη WALKING_UPSTAIRS, 91,26% για τη WALKING_DOWNSTAIRS, 89,75% για τη SITTING, 93,07% για τη STANDING και 95,33% για τη LAYING.

Το κεντρικό εύρημα είναι η συγκέντρωση των σφαλμάτων. Από τα 3.474 συνολικά λάθη, τα 1.705 είναι ανταλλαγές μεταξύ SITTING και STANDING, δηλαδή το **49**,**1**% όλων των λαθών του μοντέλου προέρχεται από ένα και μόνο ζεύγος κλάσεων, από τα δεκαπέντε δυνατά. Συγκεκριμένα, 968 samples καθιστής στάσης ταξινομούνται ως όρθια και 737 το αντίστροφο.

Το εύρημα δεν είναι σφάλμα της υλοποίησης αλλά γνωστή ιδιότητα του προβλήματος. Οι δημιουργοί του συνόλου δεδομένων αναφέρουν την ίδια επικάλυψη και την αποδίδουν στη φυσική θέση της συσκευής πάνω στο σώμα [1]. Η σύγκριση των δύο εργασιών είναι διαφωτιστική. Με SVM, εκείνοι αναφέρουν recall 88% για την καθιστή και 97% για την

όρθια στάση, ενώ η παρούσα εργασία, με το δίκτυο και ομοσπονδιακή εκπαίδευση, βρίσκει $89{,}75\%$ και $93{,}07\%$. Δεκατρία χρόνια αργότερα και με εντελώς διαφορετική μεθοδολογία, το σύνορο είναι το ίδιο.

Η εξήγηση δόθηκε στην Ενότητα 3.4.3, όπου οι δύο στάσεις διακρίνονται μόνο από την κλίση του κορμού ως προς τη συσκευή. Η διάκριση αυτή είναι εξ ορισμού εξαρτημένη από το άτομο, γιατί κάθε άνθρωπος κάθεται και στέκεται με ελαφρώς διαφορετική στάση και η συσκευή στη μέση καταγράφει αυτή τη διαφορά.

Αυτό ακριβώς κάνει το εύρημα γέφυρα προς το επόμενο κεφάλαιο. Αν το δυσκολότερο σύνορο του προβλήματος είναι και το πιο εξαρτημένο από το άτομο, τότε αναμένεται να είναι εκεί που οι clients διαφωνούν περισσότερο μεταξύ τους. Η Ενότητα 5.7.2 το επιβεβαιώνει ποσοτικά.

Δύο δευτερεύουσες παρατηρήσεις. Πρώτον, οι δυναμικές δραστηριότητες μπερδεύονται μεταξύ τους αλλά καμία δεν ταξινομείται ποτέ ως στατική. Η αντίστροφη σύγχυση είναι σπάνια, αφού μόνο 37 samples καθιστής στάσης στα 20 seeds ($0{,}4\%$) ταξινομούνται ως ανάβαση σκάλας. Ο διαχωρισμός κίνησης από ακινησία είναι, επομένως, σχεδόν πλήρης, όπως προέβλεπε η ανάλυση διαχωρισιμότητας της Ενότητας 3.4.3. Δεύτερον, η κλάση LAYING, παρά το γεγονός ότι είναι η ευκολότερη εννοιολογικά, έχει recall $95{,}33\%$ με 502 λάθη προς την όρθια στάση, δηλαδή *δεν* είναι σχεδόν τέλεια στο confusion matrix.

Κεφάλαιο 5

Αποτίμηση της Συνεισφοράς των Χρηστών

Το κεφάλαιο απαντά στο δεύτερο και στο τρίτο ερευνητικό ερώτημα. Μέθοδος και αποτελέσματα παρουσιάζονται μαζί και όχι σε χωριστά κεφάλαια, γιατί κανένα από τα ευρήματα δε διαβάζεται χωρίς τους ελέγχους που το στηρίζουν.

Η πορεία του κεφαλαίου είναι η εξής. Ορίζονται πρώτα το παίγνιο και οι εκτιμητές που το λύνουν. Στη συνέχεια, δείχνεται ότι εννέα από τους 21 clients λαμβάνουν αρνητική συνεισφορά. Το εύρημα αντέχει τέσσερις ελέγχους. Ακολουθεί η αναζήτηση του *τι* διακρίνει τους ανθρώπους που τη λαμβάνουν. Ένα δεύτερο παίγνιο, όπου κάθε ομάδα clients αποτιμάται με επανεκπαίδευση ενός κεντρικού (*centralized*) μοντέλου, εξετάζει έπειτα αν τα δεδομένα των clients με αρνητική τιμή βλάπτουν και εκεί. Δε βρέθηκε τέτοια ένδειξη. Ακολουθεί το *failure analysis*, που επιστρέφει στο ομοσπονδιακό παίγνιο και αποσυνθέτει την αρνητική τιμή, ώστε να φανεί *πότε* εμφανίζεται μέσα στην εκπαίδευση, σε ποιες δραστηριότητες και *απέναντι σε ποιους* ανθρώπους. Η ίδια ανάλυση ελέγχει αν η αφαίρεση των clients με αρνητική τιμή θα βελτίωνε το μοντέλο. Στη ρύθμιση αυτή, δεν το βελτιώνει με συνέπεια, οπότε οι clients αυτοί μένουν. Το κεφάλαιο κλείνει με τον τρόπο που η συνεισφορά όλων, ακόμη και των αρνητικών, μετατρέπεται σε μερίδια ανταμοιβής. Η ροή της υλοποίησης κάθε παιγνίου δίνεται σε σχήμα, μετά την περιγραφή του (Σχήματα 5.2 και 5.7).

5.1 Το Παίγνιο ανά Round Εκπαίδευσης

Για να εφαρμοστεί η Εξίσωση (2.11), χρειάζεται να οριστούν δύο πράγματα, ποιοι είναι οι παίκτες και ποια είναι η συνάρτηση αξίας. Εδώ ορίζεται ένα παίγνιο *ανά round* ομοσπονδιακής εκπαίδευσης. Οι παίκτες είναι οι 21 clients. Για round t και συνασπισμό $S \subseteq N$,

$$v_t(S) \;=\; \mathrm{Acc}\Big(\mathbf{w}_t + \textstyle\sum_{k\in S} \frac{n_k}{n_S}\, \Delta_t^k\Big), \tag{5.1}$$

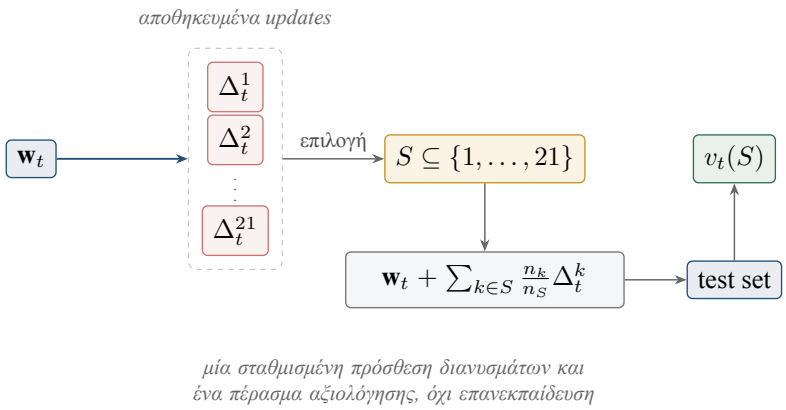
δηλαδή το accuracy στο test set του μοντέλου που θα προέκυπτε, αν σε εκείνο το round είχαν στείλει update *μόνο* οι clients του S. Στον τύπο, $\mathbf{w}_t$ είναι οι παράμετροι του global model στην αρχή του round και $\Delta_t^k = \mathbf{w}_{t+1}^k - \mathbf{w}_t$ το update του client k, δηλαδή η διαφορά του τοπικού του μοντέλου από το $\mathbf{w}_t$. Το n_k/n_S, με $n_S = \sum_{k\in S} n_k$, είναι το βάρος του FedAvg περιορισμένο στον συνασπισμό. Για $S = N$, ο τύπος δίνει ακριβώς το $\mathbf{w}_{t+1}$ της Εξίσωσης (2.10), αφού τα βάρη αθροίζονται στη μονάδα. Η αξία του κενού συνασπισμού $v_t(\emptyset)$ είναι το accuracy του $\mathbf{w}_t$ πριν από οποιοδήποτε update, οπότε το παίγνιο μετράει τι *προστίθεται* σε εκείνο το round.

Σε αντίθεση με τον κλασικό ορισμό της Ενότητας 2.3.1, λοιπόν, ο κενός συνασπισμός δεν έχει μηδενική αξία. Ούτε είναι εγγυημένο ότι η ένωση δύο συνασπισμών αξίζει τουλάχιστον όσο το άθροισμά τους, αφού ο FedAvg παίρνει μέσο όρο των updates και δεν τα προσθέτει. Ο τύπος του Shapley δε χρειάζεται καμία από τις δύο ιδιότητες, γιατί χρησιμοποιεί μόνο διαφορές $v_t(S \cup \{i\}) - v_t(S)$. Η αποδοτικότητα της Ενότητας 2.3.2 απλώς γράφεται $\sum_{i\in N} \varphi_i \;=\; v_t(N) - v_t(\emptyset)$. Ο κενός συνασπισμός αντιστοιχεί στο μοντέλο της αρχής του round, όπως και στο GTG-Shapley [30].

Το καθοριστικό σημείο υλοποίησης είναι το γεγονός ότι η αποτίμηση της $v_t(S)$ **δεν απαιτεί επανεκπαίδευση** (Σχήμα 5.1). Τα updates Δ_t^k αποθηκεύονται κατά τη διάρκεια του round και κάθε συνασπισμός αποτιμάται με μία σταθμισμένη πρόσθεση διανυσμάτων και ένα πέρασμα αξιολόγησης. Η τεχνική είναι δανεισμένη από το GTG-Shapley, το οποίο ανασυνθέτει τα ομοσπονδιακά μοντέλα από τα updates παραμέτρων, αντί να τα εκπαιδεύει ξανά για κάθε συνδυασμό clients [30].

Η σημασία της φαίνεται από την τάξη μεγέθους. Ο ακριβής υπολογισμός με επανεκπαίδευση θα απαιτούσε $2^{21} \approx 2{,}1$ εκατομμύρια πλήρεις ομοσπονδιακές εκπαιδεύσεις ανά seed, καθεμιά με 100 rounds. Με ανασύνθεση, δε χρειάζεται καμία εκπαίδευση πέρα από την ίδια την ομοσπονδιακή. Κάθε αποτίμηση κοστίζει ένα πέρασμα αξιολόγησης, δηλαδή μία πρόβλεψη στα 2.947 samples του test set. Ο αριθμός των αποτιμήσεων δίνεται στην Ενότητα 5.3.3.

Στον κώδικα η αποτίμηση εκτελείται μέσα στην ίδια την ομοσπονδιακή εκπαίδευση και όχι μετά από αυτήν. Κάθε seed ξεκινά από νέο δίκτυο με αρχικά βάρη από το seed και από μηδενικό άθροισμα συνεισφοράς για κάθε client (βήμα 1 του Σχήματος 5.2). Σε κάθε round,



Σχήμα 5.1. Η αποτίμηση της $v_t(S)$. Τα updates όλων των clients αποθηκεύονται μία φορά ανά round. Κάθε συνασπισμός ανασυντίθεται από αυτά με σταθμισμένη πρόσθεση και αποτιμάται με ένα πέρασμα αξιολόγησης. Η πλήρης επανεκπαίδευση, που θα απαιτούσε 2^{21} ομοσπονδιακές εκπαιδεύσεις ανά seed, αποφεύγεται.

αφού εκπαιδευτούν τοπικά οι 21 clients και πριν γίνει το aggregation, κρατιούνται αντίγραφα του $\mathbf{w}_t$ και των 21 τοπικών μοντέλων (βήμα 2). Από αυτά στήνεται το παίγνιο του round (βήμα 3). Τα αντίγραφα είναι απαραίτητα, γιατί το aggregation γράφει τις νέες παραμέτρους πάνω στην ίδια μνήμη. Σε μια πρώτη εκδοχή του κώδικα, έλειπαν. Όλα τα updates Δ_t^k έβγαιναν τότε μηδέν και μαζί τους όλες οι τιμές. Από τότε, ο κώδικας ελέγχει σε κάθε round ότι τα updates δεν είναι όλα μηδέν και σταματά, αν είναι. Στο πρώτο round κάθε seed, επαληθεύεται μία φορά ότι ο πλήρης συνασπισμός δίνει ακριβώς τις παραμέτρους $\mathbf{w}_{t+1}$ του FedAvg.

Οι εκτιμητές της Ενότητας 5.2 ζητούν τις αξίες $v_t(S)$ που χρειάζονται, με κάθε S να δίνεται ως διάνυσμα 21 θέσεων με 1 για τα μέλη του και 0 για τους υπόλοιπους. Οι τιμές του round προστίθενται στο άθροισμα συνεισφοράς κάθε client και η εκπαίδευση συνεχίζει στο επόμενο round. Επειδή η αποτίμηση δουλεύει μόνο σε αντίγραφα και με δική της γεννήτρια τυχαίων αριθμών, η εκπαίδευση προχωρά ακριβώς όπως στην ομοσπονδιακή τοπολογία του Κεφαλαίου 4. Πράγματι, το τελικό accuracy ταυτίζεται με εκείνο σε 20 από τα 20 seeds. Από το ένα seed στο επόμενο δεν περνά τίποτα, ούτε βάρη ούτε τιμές, οπότε τα 20 seeds εκτελούνται παράλληλα σε ξεχωριστές διεργασίες και τα αποτελέσματά τους ενώνονται στο τέλος. Η πλήρης ροή, με τη σειρά των βημάτων, δίνεται στο Σχήμα 5.2, αφού οριστούν οι δύο εκτιμητές (Ενότητα 5.2.3).

Η συνολική τιμή κάθε client είναι το άθροισμα των τιμών του στα rounds, $\varphi_i = \sum_t \varphi_{i,t}$. Είναι ο κανόνας της μεθόδου πολλών rounds (MR), όπως την περιγράφει η εργασία του GTG-Shapley [30]. Αντιστοιχεί και στον ορισμό του federated Shapley value [31], όπου η αξία των δεδομένων εξαρτάται από το round στο οποίο χρησιμοποιούνται (Ενότητα 2.4.2). Ο ορισμός επιτρέπει να συμμετέχει σε κάθε round διαφορετικό υποσύνολο clients. Στην εργασία αυτή συμμετέχουν όλοι, οπότε καταλήγει στο παίγνιο του round. Το ίδιο το GTG-Shapley υπολογίζει, επίσης, μία τιμή ανά round [30]. Εδώ οι τιμές των rounds ενώνονται με τον ίδιο κανόνα. Επειδή το Shapley value ικανοποιεί την αποδοτικότητα σε κάθε round, το άθροισμα $\sum_i \varphi_i$

ισούται με τη βελτίωση accuracy στα rounds που αποτιμώνται (Ενότητα 5.3.1). Επομένως, το φ_i εκφράζεται στις ίδιες μονάδες με τη συνάρτηση αξίας.

Η κλίμακα του φ και η κλίμακα του accuracy. Η διάκριση χρειάζεται δήλωση, γιατί το κεφάλαιο αναφέρει και τα δύο. Το accuracy εδώ είναι *κλάσμα* στο $[0, 1]$, οπότε και το φ_i είναι κλάσμα. Τιμή $\varphi_i = +0{,}40$ σημαίνει ότι οι τιμές του client ανά round, αθροισμένες στα *scored rounds*, φτάνουν τις $0{,}40$ σε απόλυτη κλίμακα accuracy, δηλαδή τις 40 ποσοστιαίες μονάδες *συσσωρευμένες στα rounds αυτά*. Το άθροισμα όλων, $\sum_i \varphi_i \approx 0{,}80$, αντιστοιχεί στις περίπου 80 ποσοστιαίες μονάδες που κέρδισε το μοντέλο από το αρχικό σημείο των rounds αυτών μέχρι το τέλος. Το μέγεθος δεν είναι συγκρίσιμο με τις διαφορές accuracy του Κεφαλαίου 4, οι οποίες αφορούν *ένα* τελικό μοντέλο και αναφέρονται πάντα σε ποσοστιαίες μονάδες. Όπου παρακάτω εμφανίζονται διαφορές τελικών μοντέλων, όπως στην Ενότητα 5.7.4, η κλίμακα είναι εκείνη του Κεφαλαίου 4 και δηλώνεται ρητά.

Το φ_i δεν είναι μερίδιο της βελτίωσης. Η αποδοτικότητα δεσμεύει μόνο το *καθαρό* άθροισμα των τιμών, όχι το μέγεθος των όρων που το σχηματίζουν. Κατά τον KernelSHAP, οι 12 clients με θετική τιμή αθροίζουν $+2{,}862$ και οι 9 με αρνητική $-2{,}065$. Η διαφορά τους είναι το καθαρό $+0{,}797$ της Ενότητας 5.3.1. Οι θετικές τιμές μόνες τους ξεπερνούν, δηλαδή, το τριπλάσιο της συνολικής βελτίωσης, οπότε δεν μπορούν να είναι κομμάτια της. Ο client 14, με $\varphi = +0{,}404$, δεν έφερε «το μισό» της ανόδου των $0{,}797$. Συνεισέφερε $0{,}404$ σε ένα σύνολο κινήσεων προς τα πάνω, που οι αρνητικές συνεισφορές αναίρεσαν σε μεγάλο βαθμό. Η αιτία είναι το γεγονός ότι μετά τα πρώτα rounds οι δύο ομάδες σπρώχνουν το μοντέλο σε αντίθετες κατευθύνσεις (Ενότητα 5.7.1). Για τον ίδιο λόγο, η αναλογική κατανομή $\varphi_i / \sum_j \varphi_j$ της Ενότητας 5.8 δίνει στους εννέα αρνητικούς συνολικό μερίδιο περίπου -259%, δηλαδή το άθροισμα των αρνητικών τιμών διαιρεμένο με το καθαρό άθροισμα. Γι' αυτό χρησιμοποιείται μόνο ως βάση σύγκρισης.

Το test set μέσα στη συνάρτηση αξίας. Η συνάρτηση αξίας αποτιμάται στο test set, όπως και στην εργασία από την οποία προέρχεται η τεχνική [30]. Δεν υπάρχει διαρροή προς την εκπαίδευση, γιατί τα 9 άτομα του test set δε γίνονται ποτέ clients και τα δεδομένα τους δεν επηρεάζουν κανένα update. Αν, όμως, το φ χρησιμοποιηθεί για *απόφαση*, για παράδειγμα για αποκλεισμό client ή για κατανομή ανταμοιβής, τότε το test set μπαίνει στον βρόχο απόφασης και παύει να είναι αμερόληπτος εκτιμητής γενίκευσης. Το ζήτημα επανέρχεται στην Ενότητα 6.2.

5.2 Οι Δύο Εκτιμητές

5.2.1 KernelSHAP

Ο πρώτος εκτιμητής είναι ο KernelSHAP, όπως υλοποιείται στη βιβλιοθήκη `shap`, με τους 21 clients στη θέση των «features». Η βιβλιοθήκη δέχεται μια συνάρτηση που παίρνει δυαδικά διανύσματα παρουσίας και επιστρέφει αριθμό. Εδώ της δίνεται η Εξίσωση (5.1). Στη συνέχεια, η βιβλιοθήκη λύνει το σταθμισμένο πρόβλημα ελαχίστων τετραγώνων με το Shapley kernel της Εξίσωσης (2.12) και επιστρέφει τα $\varphi_{i,t}$ [20].

Η χρήση αυτή είναι θεμιτή αλλά όχι η συνήθης. Η Ενότητα 2.3.4 διέκρινε το Shapley value, το SHAP και τον KernelSHAP. Ο Πίνακας 5.1 δείχνει σημείο προς σημείο πού διαφέρει η χρήση εδώ από τη συνήθη.

	SHAP (συνήθης χρήση)	**Αυτή η εργασία**
Παίκτες	τα features μίας εισόδου	οι 21 clients της ομοσπονδίας
Αξία συνασπισμού S	η έξοδος του μοντέλου, με γνωστά μόνο τα features του S	το accuracy στο test set του μοντέλου που χτίζεται από τα updates του S
Αληθινά labels	δε χρειάζονται	χρειάζονται
Εύρος	μία πρόβλεψη	ένα test set, σε ένα round
Τι λέει μία τιμή	πόσο έσπρωξε το feature αυτήν την πρόβλεψη	πόσο accuracy πρόσθεσε ο client σε αυτό το round
Από τη βιβλιοθήκη	ολόκληρη η μέθοδος	μόνο ο solver KernelSHAP

Πίνακας 5.1. Ίδιος κανόνας, άλλο παίγνιο. Η τελευταία γραμμή δείχνει τι παίρνει η υλοποίηση από τη βιβλιοθήκη `shap`.

Η βιβλιοθήκη χρησιμοποιείται, επομένως, ως γενικός solver Shapley και όχι ως εργαλείο ερμηνείας features. Το διάνυσμα παρουσίας έχει 21 θέσεις, μία για κάθε client. Ως σημείο αναφοράς δίνεται το διάνυσμα στο οποίο δε συμμετέχει κανείς, οπότε κάθε συνασπισμός που δοκιμάζει η βιβλιοθήκη αντιστοιχεί ακριβώς σε μία τιμή $v_t(S)$. Το μοντέλο και τα 561 features δεν περνούν ποτέ στη βιβλιοθήκη και η v_t μετρά accuracy με τα αληθινά labels. Γι' αυτό οι τιμές του κεφαλαίου λέγονται Shapley values ή φ αλλά ποτέ SHAP values. Δείχνουν τη συνεισφορά κάθε client στο accuracy του μοντέλου και όχι το πώς ένα συγκεκριμένο feature επηρέασε μια πρόβλεψη. Στην Ενότητα 5.2.5 ελέγχεται αν ο solver αναπαράγει πράγματι τον ορισμό σε τέτοιο παίγνιο.

Ο αριθμός των δειγματοληπτούμενων συνασπισμών ορίστηκε σε 2.090 ανά round, τιμή που προκύπτει από την προεπιλεγμένη πολιτική της βιβλιοθήκης για 21 παίκτες.

Χωρίς επιλογή παικτών. Η βιβλιοθήκη έχει μια παράμετρο, `l1_reg`, η οποία, πριν από την παλινδρόμηση, κρατά ένα υποσύνολο των παικτών και μηδενίζει τις τιμές των υπολοίπων.

Η βιβλιοθήκη την ενεργοποιεί εξ ορισμού. Στο σχετικό άρθρο παρουσιάζεται ως ένας τρόπος για την εξαγωγή ακριβέστερων εκτιμήσεων με λιγότερες αποτιμήσεις του μοντέλου [20]. Εδώ είναι απενεργοποιημένη (`l1_reg=False`), για δύο λόγους. Πρώτον, ο ορισμός του KernelSHAP δεν έχει όρο κανονικοποίησης, αφού το Θεώρημα 2 του [20] ζητά $\Omega(g) = 0$, για να ανακτώνται τα Shapley values. Δεύτερον, με 21 μόνο παίκτες, δεν υπάρχει λόγος να μείνει κάποιος χωρίς εκτίμηση. Όλες οι τιμές του ομοσπονδιακού παιγνίου υπολογίστηκαν χωρίς επιλογή παικτών.

5.2.2 GTG-Shapley

Ο δεύτερος εκτιμητής προέρχεται από το GTG-Shapley, σχεδιασμένο ειδικά για το ομοσπονδιακό πλαίσιο [30]. Δειγματοληπτεί μεταθέσεις των clients και συσσωρεύει οριακές συνεισφορές, με δύο μηχανισμούς αποκοπής. Μια μετάθεση είναι μια σειρά άφιξης των 21 clients, όπως οι σειρές του Σχήματος 2.2. Ο εκτιμητής ξεκινά από τον κενό συνασπισμό, προσθέτει τους clients έναν έναν με αυτή τη σειρά και πιστώνει στον καθένα τη μεταβολή της αξίας τη στιγμή που μπαίνει. Ο μέσος όρος πάνω σε πολλές τυχαίες μεταθέσεις προσεγγίζει το Shapley value (Ενότητα 2.3.3). Το πλήθος των μεταθέσεων ανά round είναι ο προϋπολογισμός του εκτιμητή, με ανώτατο όριο τις 100 στα κύρια αποτελέσματα. Ο εκτιμητής σταματά νωρίτερα, όταν οι τιμές του μεταβάλλονται λιγότερο από 5% κατά μέσο όρο στις 10 τελευταίες μεταθέσεις. Ο πρώτος μηχανισμός, η αποκοπή μεταξύ rounds (*between-round truncation*), παραλείπει εντελώς τα rounds στα οποία η συνολική μεταβολή της αξίας είναι κάτω από ένα ορισμένο κατώφλι, με τη λογική ότι, αν ένα round δεν επέφερε καμία μεταβολή, δεν υπάρχει και μερίδιο προς κατανομή. Ο δεύτερος, η αποκοπή μέσα στο round (*within-round truncation*), σταματά μια μετάθεση, όταν η τρέχουσα αξία έχει πλησιάσει αρκετά την $v_t(N)$ [30]. Εδώ, το όριο της απόστασης από την $v_t(N)$ είναι $0{,}0001$. Επειδή το accuracy αλλάζει σε βήματα του $1/2.947 \approx 0{,}00034$, το όριο ενεργοποιείται μόνο όταν ο συνασπισμός έχει ήδη ακριβώς το accuracy του πλήρους. Οι υπόλοιποι της σειράς παίρνουν τότε μηδέν, χωρίς νέα αποτίμηση.

Η παραλλαγή GTG-Tib. Το Algorithm 1 του [30] απαρτίζεται από **τρία** συστατικά, δηλαδή τους δύο παραπάνω μηχανισμούς αποκοπής και μια τρίτη πολιτική, το *guided sampling* της γραμμής 7, που γεμίζει τις m πρώτες θέσεις κάθε μετάθεσης με σταθερή κυκλική σειρά αντί για τυχαία, ώστε να μην τυχαίνει ένας client να βρίσκεται πάντα στο τέλος. Ο εκτιμητής των κύριων αποτελεσμάτων υλοποιεί τα **δύο** πρώτα και δειγματοληπτεί πλήρως τυχαίες μεταθέσεις. Αυτό αντιστοιχεί ακριβώς στην παραλλαγή που το ίδιο το άρθρο ονομάζει **GTG-Tib** [30]. Με το όνομα αυτό αναφέρεται στο εξής ο εκτιμητής. Η επιλογή δηλώνεται ρητά, επειδή η μελέτη απαλοιφής του άρθρου βρίσκει ότι το guided sampling βελτιώνει σημαντικά την ακρίβεια της εκτίμησης [30]. Ο ρόλος του εκτιμητή εδώ είναι να αποτελέσει *δεύτερη ανε-*

ξάρτητη διαδρομή για διασταύρωση της κατάταξης, όχι για να είναι ο ακριβέστερος δυνατός. Η πλήρης εκδοχή με guided sampling υλοποιήθηκε και αυτή. Η αποτίμησή της γίνεται στην Ενότητα 5.2.4.

Η αποκοπή δικαιολογείται, επειδή η οριακή συνεισφορά φθίνει καθώς μεγαλώνει ο συνασπισμός. Η ίδια λογική στηρίζει το *Truncated Monte Carlo Shapley* [19]. Το κατώφλι της αποκοπής μεταξύ rounds ορίστηκε σε $0{,}001$. Παραλείπεται, επομένως, κάθε round που αλλάζει το πλήθος των σωστών προβλέψεων στο test set κατά λιγότερο από τρεις. Στα δεδομένα της εργασίας, η αποκοπή αυτή παραλείπει 39 από τα 100 rounds στο πρώτο seed, γιατί μετά την αρχική απότομη άνοδο της καμπύλης μάθησης, τα περισσότερα rounds μεταβάλλουν ελάχιστα την επίδοση. Τα rounds που μένουν λέγονται στο εξής *scored rounds*. Είναι 61 στο πρώτο seed, από 51 έως 74 ανά seed (65 κατά μέσο όρο) και 1.305 συνολικά στα 20 seeds. Μόνο σε αυτά υπολογίζονται τιμές, από κάθε εκτιμητή.

5.2.3 Κοινή συνάρτηση αξίας

Οι δύο εκτιμητές βλέπουν **την ίδια** συνάρτηση αξίας, τα ίδια rounds, τα ίδια αποθηκευμένα updates και την ίδια πύλη αποκοπής. Η μόνη διαφορά τους είναι ο *τρόπος* με τον οποίο πραγματοποιούν τη δειγματοληψία στον χώρο των συνασπισμών. Ο ένας χρησιμοποιεί σταθμισμένη παλινδρόμηση πάνω σε δείγμα συνασπισμών, ενώ ο άλλος μεταθέσεις και αποκοπή. Στον κώδικα, εκτελούνται ο ένας μετά τον άλλον, στο ίδιο παίγνιο του ίδιου round (βήμα 3 του Σχήματος 5.2).

Αυτό κάνει τη σύγκρισή τους πληροφοριακή. Κάθε διαφορά στα φ είναι διαφορά *εκτίμησης* και όχι διαφορά ορισμού. Αν οι δύο συμφωνούν, η κατάταξη είναι ιδιότητα του παιγνίου και όχι παρενέργεια του αλγορίθμου. Η ανάγκη για τέτοιον έλεγχο δεν είναι θεωρητική, αφού σε προηγούμενη εκδοχή αυτής της εργασίας ένας εκτιμητής KernelSHAP με λίγους συνασπισμούς δεν είχε συγκλίνει. Χωρίς δεύτερο εκτιμητή, αυτό δε θα ήταν ορατό. Η βιβλιογραφία το αντιμετωπίζει ως υποχρέωση, ενσωματώνοντας τον έλεγχο σύγκλισης μέσα στον ίδιο τον αλγόριθμο [19].

Το Σχήμα 5.2 δείχνει τη ροή του ομοσπονδιακού παιγνίου με τη σειρά εκτέλεσης και συγκεντρώνει όσα περιγράφουν οι Ενότητες 5.1 και 5.2. Η πύλη (βήμα 3α) είναι η αποκοπή μεταξύ rounds της Ενότητας 5.2.2. Εφαρμόζεται πριν από τους δύο εκτιμητές (3β και 3γ), οπότε ένα round που δεν την περνά δεν αποτιμάται από κανέναν.

Στον κώδικα, όλα τα αρχεία βρίσκονται μέσα στον φάκελο `implementation/`, με την οργάνωση της Ενότητας 4.1. Ο βρόχος των seeds και των rounds είναι η `run_one_seed()` του `contribution/contribution.py` (βήματα 1, 3α, 3δ και 4). Μέσα της, η `observer()` κρατά τα αντίγραφα του βήματος 2 και η παρά-

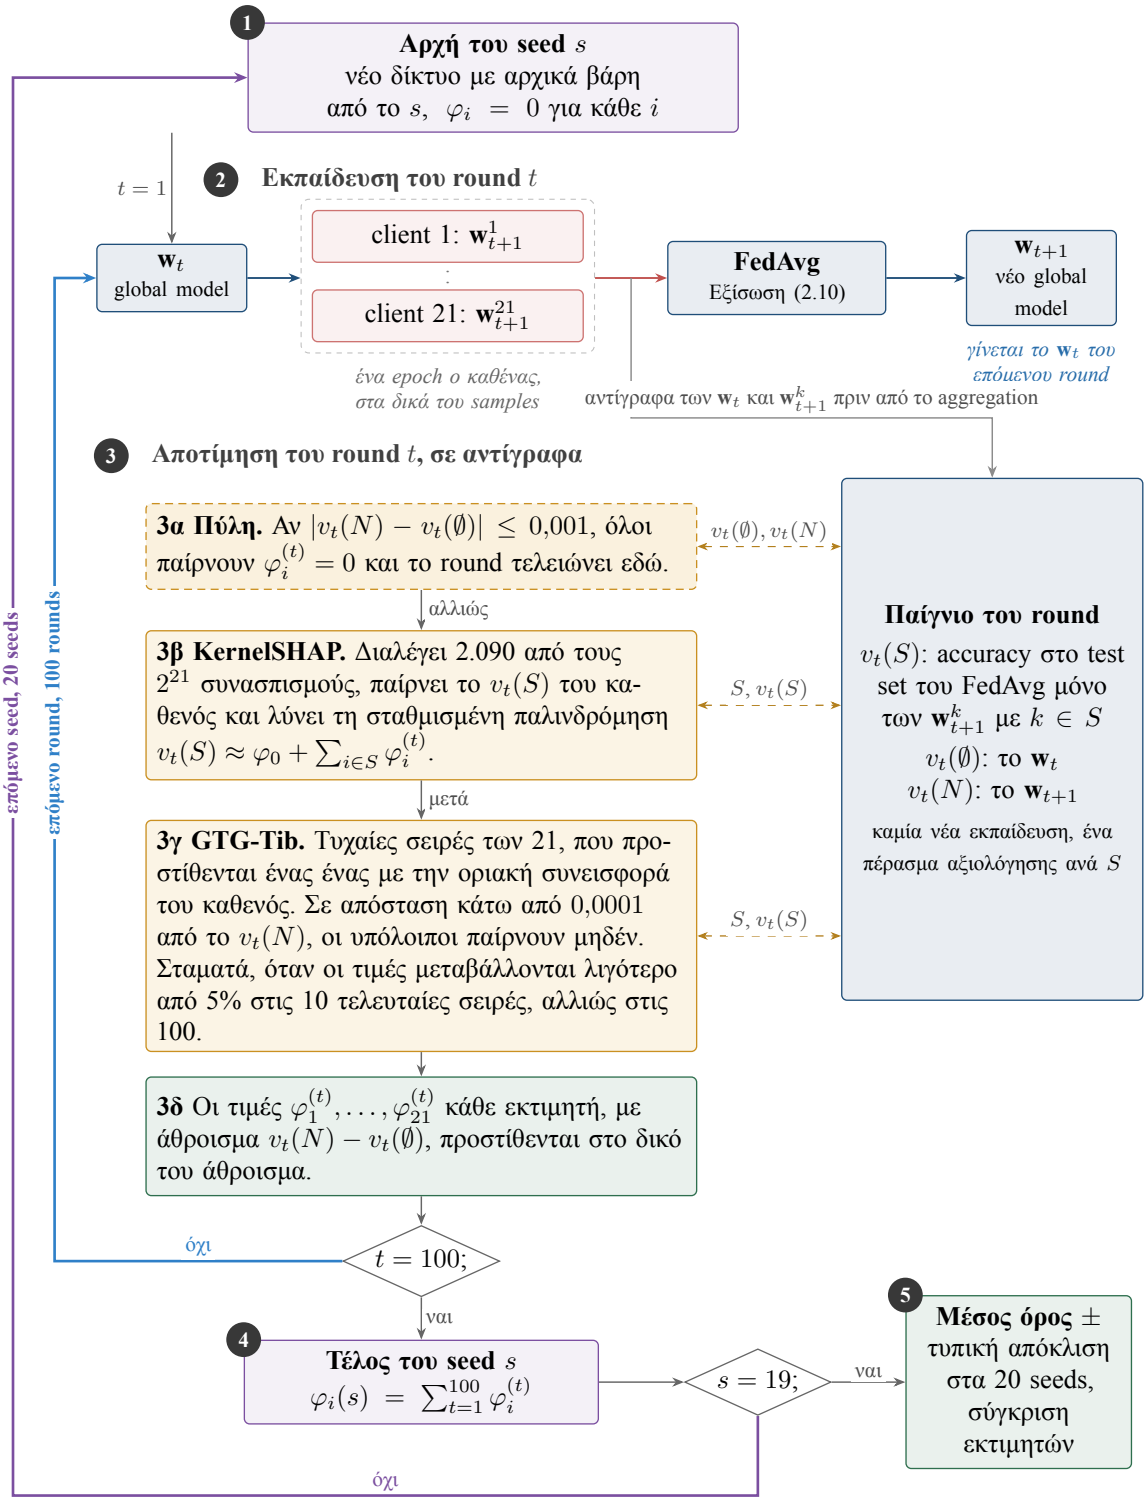
μετρος `eps_between` ορίζει την πύλη. Η `summarize()` του ίδιου αρχείου δίνει τους μέσους όρους και τη σύγκριση των εκτιμητών (βήμα 5). Η τοπική εκπαίδευση και το aggregation του βήματος 2 είναι εκείνα της ομοσπονδιακής τοπολογίας, δηλαδή η `Client.update()` του `federated/fl/client.py`, η `Server.update()` του `federated/fl/server.py` και η `fedavg_aggregate()` του `federated/fl/aggregation/aggregate.py`. Το παίγνιο και οι εκτιμητές βρίσκονται στον υποφάκελο `contribution/sv/`. Την αξία $v_t(S)$ τη δίνουν η `RoundGame` του `coalition.py` και η `CoalitionEvaluator` του `evaluate.py`, ενώ οι δύο εκτιμητές είναι οι `KernelShapEstimator` και `GtgShapleyEstimator` του `estimators.py`.

5.2.4 Guided sampling των μεταθέσεων

Ο εκτιμητής των κύριων αποτελεσμάτων παραλείπει το τρίτο συστατικό του GTG-Shapley, το guided sampling. Η ενότητα μετρά τι κοστίζει η παράλειψη, ώστε να μην είναι απλή δήλωση. Η απάντηση, συνοπτικά, είναι ότι ανά round η εκδοχή με guided sampling είναι σαφώς ακριβέστερη, ενώ στο άθροισμα των rounds η διαφορά σχεδόν χάνεται και η κατάταξη των κύριων αποτελεσμάτων δεν αλλάζει.

Τι αλλάζει το guided sampling. Σε μια τυχαία μετάθεση, κάθε client έχει την ίδια πιθανότητα να βρεθεί σε κάθε θέση. Σε λίγες μεταθέσεις, όμως, η ισορροπία δεν είναι εξασφαλισμένη. Με 100 τυχαίες μεταθέσεις, το πόσες φορές ένας client καταλαμβάνει την πρώτη θέση ακολουθεί διωνυμική κατανομή με μέσο $4{,}76$. Στην πράξη, ένας client την κατέλαβε 2 φορές, ενώ ένας άλλος 11. Το guided sampling γεμίζει τις m πρώτες θέσεις κάθε μετάθεσης με σταθερή κυκλική σειρά αντί για τυχαία, οπότε ο καθένας καταλαμβάνει την πρώτη θέση 4 ή 5 φορές, πάντα. Η ισορροπία έχει σημασία, γιατί οι πρώτες θέσεις είναι εκείνες που αποτιμώνται πραγματικά, αφού η αποκοπή μέσα στο round μηδενίζει τη συνεισφορά των τελευταίων.

Η υλοποίηση, με $m = 2$ αντί για $m = 1$. Το άρθρο περιγράφει την πολιτική με λόγια και δεν παραθέτει ούτε τιμή για το m ούτε σειρά απαρίθμησης του $P(n, m)$, παραπέμποντας στο αποθετήριο των συγγραφέων [30]. Ο κώδικας εκεί χρησιμοποιεί $m = 1$, δηλαδή η πρώτη θέση περνά με τη σειρά από όλους τους clients, σε πλήρη περάσματα των n μεταθέσεων. Εδώ επιλέχθηκε $m = 2$, οπότε η απαρίθμηση είναι *ερμηνεία* του κανόνα από την παρούσα εργασία, με κριτήριο να υπηρετεί τον σκοπό που δηλώνει το άρθρο. Στην k-οστή μετάθεση, η πρώτη θέση δίνεται στον client $k \bmod n$ και η δεύτερη σε μετατόπιση από αυτόν που αλλάζει κυκλικά σε κάθε βήμα, ενώ οι υπόλοιπες $n - m$ θέσεις μένουν τυχαίες. Έτσι απαριθμούνται



Σχήμα 5.2. Η αποτίμηση στο ομοσπονδιακό παίγνιο, με τη σειρά εκτέλεσης. Η μπλε γραμμή επιστρέφει στο επόμενο round και η μωβ στο επόμενο seed. Το βήμα 3 δουλεύει σε αντίγραφα των μοντέλων και δεν αλλάζει την εκπαίδευση. Οι δύο εκτιμητές εκτελούνται ο ένας μετά τον άλλον, στο ίδιο παίγνιο του ίδιου round. Τα διακεκομμένα βέλη δείχνουν πού ζητούν αξίες συνασπισμών.

και τα 420 ζεύγη του $P(21, 2)$ πριν από οποιαδήποτε επανάληψη. Μια λεξικογραφική απαρίθμηση θα ήταν λάθος, γιατί στις 100 μεταθέσεις ενός round μόνο οι πέντε πρώτοι clients θα έφταναν ποτέ στην πρώτη θέση. Για τον ίδιο λόγο, οι 100 μεταθέσεις καλύπτουν μόνο μέρος των 420 ζευγών, γι' αυτό η απαρίθμηση ξεκινά σε κάθε round από τυχαίο σημείο της σειράς. Η επιλογή του $m = 2$ ελέγχθηκε απέναντι στο $m = 1$ στα τρία rounds του Πίνακα 5.2, με 100 μεταθέσεις και πρακτικά ίδιο αριθμό αποτιμήσεων. Σε κανένα round δεν έδωσε μεγαλύτερη απόκλιση από το ακριβές Shapley.

Τι αλλάζει στη ροή του Σχήματος 5.2. Από τα βήματα του σχήματος, η εκδοχή με guided sampling αλλάζει μόνο το 3γ. Οι δύο πρώτες θέσεις κάθε σειράς δεν κληρώνονται αλλά παίρνονται από την κυκλική απαρίθμηση της προηγούμενης παραγράφου, ενώ οι υπόλοιπες 19 μένουν τυχαίες. Η αποκοπή μέσα στο round, το κριτήριο τερματισμού και το ανώτατο όριο των 100 μεταθέσεων δεν αλλάζουν. Στα 20 seeds, η εκδοχή υπολογίστηκε σε χωριστή εκτέλεση της ίδιας ροής, χωρίς το βήμα 3β και με την ίδια πύλη (βήμα 3α). Τα βήματα 1, 2, 4 και 5 μένουν ίδια.

Ακρίβεια ανά round. Ο Πίνακας 5.2 συγκρίνει τις δύο εκδοχές σε τρία rounds με διαφορετικό μέγεθος $v_t(N) - v_t(\emptyset)$, με 50, 100 και 200 μεταθέσεις ανά round και πέντε ανεξάρτητα τραβήγματα ανά κελί. Αναφορά είναι το ακριβές Shapley κάθε round, από την Εξίσωση (2.11) με αποτίμηση και των 2^{21} συνασπισμών (Ενότητα 5.2.5). Η εκδοχή με guided sampling είναι καλύτερη και στα εννέα κελιά, τόσο στη συμφωνία κατάταξης (Kendall τ, Εξίσωση (2.7)) όσο και στη μέγιστη απόκλιση. Η μέγιστη απόκλισή της κυμαίνεται, επίσης, λιγότερο μεταξύ των τραβηγμάτων, όπως αναμένεται από τον μηχανισμό που επικαλείται το άρθρο. Στις 100 μεταθέσεις των κύριων αποτελεσμάτων, η μέγιστη απόκλιση μειώνεται κατά παράγοντα από $1{,}9$ έως $5{,}6$, με το μεγαλύτερο κέρδος στο round 1. Τα διαστήματα $\pm$ μιας τυπικής απόκλισης της μέγιστης απόκλισης δεν επικαλύπτονται σε κανέναν από τα τρία rounds. Το πλήθος των αποτιμήσεων μένει πρακτικά ίδιο, από $-1{,}0$ έως $+2{,}0\%$.

Ακρίβεια στο άθροισμα των rounds. Η ακρίβεια ανά round δεν προεξοφλεί το αποτέλεσμα στο *άθροισμα* των rounds, που είναι το μέγεθος το οποίο εξετάζεται τελικά. Αν τα σφάλματα των διαδοχικών rounds είναι ανεξάρτητα, αλληλοαναιρούνται, ενώ, αν είναι συσχετισμένα, συσσωρεύονται. Μια πολιτική που επαναλαμβάνει την ίδια απαρίθμηση σε κάθε round κινδυνεύει με το δεύτερο. Γι' αυτό ο πλήρης εκτιμητής εκτελέστηκε στα ίδια 20 seeds και στα ίδια 1.305 scored rounds με τα κύρια αποτελέσματα, πάνω σε τροχιά εκπαίδευσης ίδια bit προς bit, οπότε η σύγκριση είναι πλήρως αντιστοιχισμένη. Για το άθροισμα δεν υπάρχει ακριβές Shapley, οπότε αναφορά είναι ο KernelSHAP. Οι τρεις εκτιμητές συγκρίνονται μαζί στον Πίνακα 5.4 της Ενότητας 5.3.2.

		Kendall τ		max $\lvert\Delta\varphi\rvert$	
Round	Μεταθέσεις	τυχαία	guided	τυχαία	guided
1	50	$0{,}547 \pm 0{,}066$	$\mathbf{0{,}813} \pm 0{,}043$	$0{,}03344 \pm 0{,}00583$	$\mathbf{0{,}01200} \pm 0{,}00299$
1	100	$0{,}680 \pm 0{,}051$	$\mathbf{0{,}901} \pm 0{,}016$	$0{,}02806 \pm 0{,}00568$	$\mathbf{0{,}00499} \pm 0{,}00046$
1	200	$0{,}743 \pm 0{,}029$	$\mathbf{0{,}926} \pm 0{,}027$	$0{,}01903 \pm 0{,}00349$	$\mathbf{0{,}00400} \pm 0{,}00084$
5	50	$0{,}573 \pm 0{,}139$	$\mathbf{0{,}764} \pm 0{,}049$	$0{,}00855 \pm 0{,}00353$	$\mathbf{0{,}00500} \pm 0{,}00081$
5	100	$0{,}665 \pm 0{,}125$	$\mathbf{0{,}836} \pm 0{,}027$	$0{,}00605 \pm 0{,}00136$	$\mathbf{0{,}00324} \pm 0{,}00128$
5	200	$0{,}777 \pm 0{,}031$	$\mathbf{0{,}870} \pm 0{,}057$	$0{,}00407 \pm 0{,}00077$	$\mathbf{0{,}00188} \pm 0{,}00054$
15	50	$0{,}665 \pm 0{,}069$	$\mathbf{0{,}815} \pm 0{,}057$	$0{,}01002 \pm 0{,}00306$	$\mathbf{0{,}00490} \pm 0{,}00061$
15	100	$0{,}768 \pm 0{,}064$	$\mathbf{0{,}859} \pm 0{,}039$	$0{,}00653 \pm 0{,}00124$	$\mathbf{0{,}00287} \pm 0{,}00102$
15	200	$0{,}846 \pm 0{,}021$	$\mathbf{0{,}884} \pm 0{,}040$	$0{,}00497 \pm 0{,}00143$	$\mathbf{0{,}00187} \pm 0{,}00019$

Πίνακας 5.2. Τυχαία δειγματοληψία έναντι guided sampling των μεταθέσεων, 21 clients, με αναφορά το ακριβές Shapley κάθε round (2^{21} συνασπισμοί), στο seed 0. Οι μεταθέσεις είναι ο προϋπολογισμός ανά round. Μέσος όρος $\pm$ τυπική απόκλιση σε πέντε ανεξάρτητα τραβήγματα.

Στο άθροισμα, η εκδοχή με guided sampling υπερέχει με πολύ μικρότερο περιθώριο. Η μέση απόκλισή της από τον KernelSHAP είναι κατά $13{,}3\%$ μικρότερη από εκείνη της τυχαίας. Ο αριθμός δε συγκρίνεται ευθέως με τον παράγοντα του Πίνακα 5.2, αφού έχει άλλη αναφορά και άλλο μέτρο. Δείχνει, όμως, ότι το μεγαλύτερο μέρος του πλεονεκτήματος χάνεται, επειδή ο θόρυβος της τυχαίας δειγματοληψίας αλληλοαναιρείται σε βάθος 1.305 rounds. Αυτό που δε χάνεται είναι η **κατάταξη**. Η εκδοχή με guided sampling αναπαράγει τη σειρά του KernelSHAP και στα 210 ζεύγη clients ($\tau = 1{,}0000$), ενώ η τυχαία αντιστρέφει τέσσερα ($\tau = 0{,}9619$), όλα ανάμεσα σε clients με σχεδόν ίσες τιμές (Ενότητα 5.3.2). Το κόστος της βελτίωσης είναι $0{,}61\%$ περισσότερες αποτιμήσεις, οπότε πρόκειται για κέρδος σχεδόν δωρεάν.

Συμπέρασμα. Η παράλειψη του τρίτου συστατικού κοστίζει λίγο στα κύρια αποτελέσματα. Η κατάταξη στην οποία καταλήγει ο πλήρης εκτιμητής είναι ακριβώς εκείνη του KernelSHAP, οπότε το τρίτο συστατικό *επιβεβαιώνει* τα αποτελέσματα των επόμενων ενοτήτων, αντί να τα μετακινεί. Μένει μία διαφωνία προσήμου. Ο client 13, με $\varphi \approx 0$, βγαίνει οριακά αρνητικός κατά τον KernelSHAP ($-0{,}00253$) και οριακά θετικός και από τις δύο εκδοχές μεταθέσεων ($+0{,}00756$ η τυχαία, $+0{,}00498$ η εκδοχή με guided sampling). Το guided sampling, δηλαδή, δεν τη διορθώνει, πράγμα που σημαίνει ότι η διαφωνία ανήκει στην οικογένεια των εκτιμητών μεταθέσεων και όχι στην πολιτική δειγματοληψίας. Για client τόσο κοντά στο μηδέν, αυτό είναι αναμενόμενο και δεν επηρεάζει καμία από τις πολιτικές αντιμοιβής της Ενότητας 5.8.

5.2.5 Επαλήθευση με πλήρη απαρίθμηση

Η συμφωνία δύο εκτιμητών μεταξύ τους είναι ισχυρή ένδειξη αλλά δεν είναι απόδειξη. Και οι δύο θα μπορούσαν να αποκλίνουν από τον ορισμό της Εξίσωσης (2.11) με τον ίδιο τρόπο, αν το κοινό τους σημείο, η συνάρτηση αξίας ή η αντιστοίχιση παικτών, ενείχε το σφάλμα. Ούτε το αξίωμα της αποδοτικότητας αρκεί. Το κενό $\sum_i \varphi_i - (v(N) - v(\emptyset))$ μένει της τάξης του 10^{-16} σε κάθε seed αλλά το αξίωμα ικανοποιείται εξίσου καλά και από μια *λανθασμένη* κατανομή της ίδιας συνολικής αξίας.

Ο μόνος έλεγχος που δίνει οριστική απάντηση είναι η σύγκριση με το ακριβές Shapley, δηλαδή με την Εξίσωση (2.11) υπολογισμένη πάνω σε όλους τους συνασπισμούς. Έγινε με δύο τρόπους, που απαντούν σε διαφορετικά ερωτήματα.

Στο ομοσπονδιακό παίγνιο, σε τρία rounds. Για 21 παίκτες, η πλήρης απαρίθμηση απαιτεί 2^{21} συνασπισμούς ανά round. Έγινε για τα τρία rounds του Πίνακα 5.2, με την ίδια συνάρτηση αξίας που χρησιμοποιούν οι εκτιμητές. Δείχνει πόσο κοντά στον ορισμό φτάνει κάθε εκτιμητής με τον προϋπολογισμό του (Πίνακας 5.2 και Σχήμα 5.5). Για τα 1.305 scored rounds των 20 seeds θα χρειάζονταν περίπου $2{,}7$ δισεκατομμύρια αποτιμήσεις. Γι' αυτό ακριβώς χρησιμοποιούνται εκτιμητές.

Σε παίγνιο οκτώ παικτών, πλήρως. Με οκτώ παίκτες οι συνασπισμοί είναι μόλις $2^8 = 256$, οπότε ο KernelSHAP μπορεί να τους δειγματοληπτήσει όλους. Εκεί ελέγχεται αν η υλοποίηση του εκτιμητή αναπαράγει τον ορισμό ακριβώς και όχι μόνο κατά προσέγγιση. Στο μικρό αυτό παίγνιο, η αξία ενός συνασπισμού είναι το accuracy ενός δικτύου που εκπαιδεύεται από την αρχή μόνο με τα δεδομένα των μελών του, οπότε κάθε συνασπισμός αποτιμάται ανεξάρτητα και η απαρίθμηση είναι καλά ορισμένη. Παίκτες ορίστηκαν οι οκτώ πρώτοι clients κατά αύξοντα αναγνωριστικό, επιλογή ανεξάρτητη από το αποτέλεσμα. Στους οκτώ τυχαίνει να περιλαμβάνονται τέσσερις από τους εννέα clients που λαμβάνουν αρνητική τιμή στο ομοσπονδιακό παίγνιο.

Στο παίγνιο των οκτώ, το ακριβές Shapley δίνει $\sum_i \varphi_i = 0{,}753308$ με $v(N) = 0{,}869698$ και $v(\emptyset) = 0{,}116390$. Ο Πίνακας 5.3 συγκρίνει τον KernelSHAP με αυτήν την τιμή αναφοράς, για αυξανόμενο πλήθος δειγματοληπτούμενων συνασπισμών.

Με πλήρη απαρίθμηση, ο KernelSHAP αναπαράγει τον ορισμό *στην ακρίβεια της μηχανής*. Η διαφορά των 5×10^{-16} είναι σφάλμα στρογγυλοποίησης κινητής υποδιαστολής και όχι σφάλμα μεθόδου. Το συμπέρασμα είναι συγκεκριμένο. Τα βάρη του Shapley kernel, η παλινδρόμηση και η αντιστοίχιση παικτών προς μεταβλητές είναι σωστά υλοποιημένα. Ο έλεγχος πραγματοποιήθηκε με την προεπιλογή της βιβλιοθήκης, δηλαδή με επιλογή παικτών (Ενότητα 5.2.1), η οποία σε αυτό το παίγνιο δε μηδένισε κανέναν παίκτη σε κανένα από τα

Συνασπισμοί	$\max_i \lvert\Delta\varphi_i\rvert$	% του εύρους	Kendall τ
32	$2{,}195 \times 10^{-1}$	29,1	+0,214
64	$9{,}932 \times 10^{-2}$	13,2	+0,643
128	$2{,}293 \times 10^{-2}$	3,0	+0,643
256	$\mathbf{5{,}00 \times 10^{-16}}$	**0,000**	**+1,000**

Πίνακας 5.3. Ο KernelSHAP απέναντι στην πλήρη απαρίθμηση, σε παίγνιο οκτώ παικτών. Η στήλη του εύρους εκφράζει τη μέγιστη απόκλιση ως ποσοστό του $v(N) - v(\emptyset)$ και η τελευταία στήλη τη συμφωνία κατάταξης με το ακριβές Shapley. Στους 256 συνασπισμούς η δειγματοληψία γίνεται απαρίθμηση.

τέσσερα μεγέθη δείγματος. Ο έλεγχος αφορά τον εκτιμητή και όχι τη συνάρτηση αξίας του ομοσπονδιακού παιγνίου, αφού έγινε σε άλλο παίγνιο. Το ίδιο ισχύει για τη σύγκριση με το ακριβές στα τρία rounds του Πίνακα 5.2, η οποία χρησιμοποιεί την ίδια συνάρτηση αξίας με τους εκτιμητές. Για τη συνάρτηση αξίας, ο άμεσος έλεγχος είναι ότι ο πλήρης συνασπισμός δίνει ακριβώς τις παραμέτρους του FedAvg (Ενότητα 5.1).

Αυτό που ο έλεγχος *δεν* αποδεικνύει πρέπει να δηλωθεί με την ίδια σαφήνεια. Ο έλεγχος δεν αποδεικνύει ότι οι 2.090 συνασπισμοί αρκούν, όταν οι παίκτες είναι 21. Για το ομοσπονδιακό παίγνιο το δείχνει η σύγκριση με το ακριβές Shapley στα τρία rounds (Σχήμα 5.5). Για το παίγνιο επανεκπαίδευσης του κεντρικού μοντέλου (Ενότητα 5.6) το δείχνει η σύγκριση δύο ανεξάρτητων μισών των seeds (Ενότητα 5.6.3). Η στήλη του εύρους δείχνει, ωστόσο, πόσο γρήγορα πέφτει η απόκλιση, από $29{,}1\%$ στους 32 συνασπισμούς σε $3{,}0\%$ στους 128.

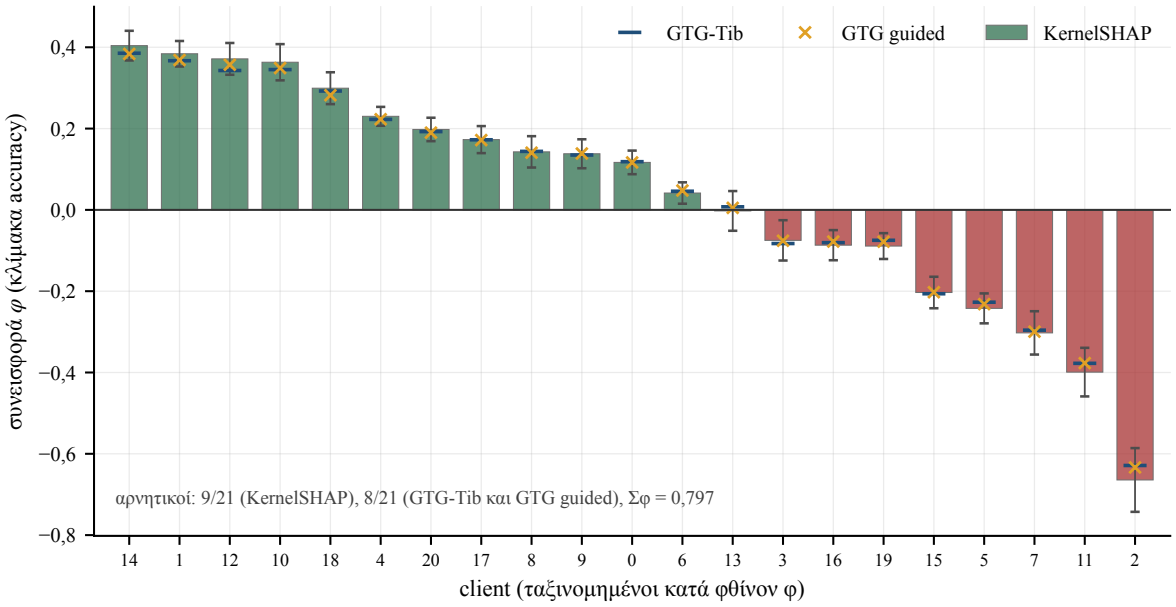
5.3 Αποτελέσματα της Αποτίμησης

5.3.1 Η κατανομή των τιμών

Το Σχήμα 5.3 δείχνει το βασικό αποτέλεσμα, σε 20 seeds.

Το άθροισμα είναι $\sum_i \varphi_i = +0{,}79729$ και για τους τρεις εκτιμητές. Η ταύτιση των αθροισμάτων δεν είναι σύμπτωση αλλά συνέπεια του αξιώματος της αποδοτικότητας. Γι' αυτό λειτουργεί ως έλεγχος της υλοποίησης.

Το άθροισμα συνδέεται άμεσα με το accuracy $94{,}11\%$ της ομοσπονδιακής τοπολογίας (Ενότητα 4.6.1). Σε κάθε round, η $v_t(\emptyset)$ είναι το accuracy του μοντέλου στην αρχή του round και η $v_t(N)$ το accuracy στο τέλος του. Επομένως, το άθροισμα των $v_t(N) - v_t(\emptyset)$ σε όλα τα rounds είναι το τελικό accuracy μείον το αρχικό. Κατά μέσο όρο στα 20 seeds, το ανεκπαίδευτο αρχικό μοντέλο έχει accuracy $0{,}145$ και το τελικό $0{,}941$, άρα η συνολική άνοδος είναι $0{,}796$. Οι τιμές φ, όμως, καλύπτουν μόνο τα scored rounds. Τα rounds που παρέλειψε η απο-



Σχήμα 5.3. Η συνεισφορά φ κάθε client, σε μονάδες accuracy, μέσος όρος 20 seeds. Οι μπάρες είναι ο εκτιμητής KernelSHAP με $\pm$ μία τυπική απόκλιση μεταξύ seeds, ενώ οι οριζόντιες παύλες είναι το GTG-Tib και τα σταυρουδάκια η πλήρης εκδοχή με guided sampling (GTG guided). Οι δύο εκτιμητές μεταθέσεων δίνουν 8 αρνητικούς αντί για 9, γιατί διαφωνούν μόνο στον client 13, που είναι ο μόνος με τιμή μέσα στον θόρυβο.

κοπή μετακίνησαν το accuracy συνολικά κατά $-0{,}001$, οπότε $\sum_i \varphi_i = 0{,}796 + 0{,}001 = 0{,}797$. Με άλλα λόγια, η ομοσπονδιακή εκπαίδευση ανέβασε το accuracy από $14{,}5\%$ σε $94{,}1\%$ και το καθαρό άθροισμα των φ είναι ακριβώς αυτή η άνοδος των περίπου 80 ποσοστιαίων μονάδων, χωρίς τα rounds που παραλείφθηκαν.

Οι τιμές εκτείνονται από $+0{,}404$ για τον client 14 έως $-0{,}664$ για τον client 2. **Εννέα από τους 21 clients έχουν αρνητική τιμή** κατά τον KernelSHAP και οκτώ κατά καθέναν από τους δύο εκτιμητές μεταθέσεων, το GTG-Tib και την εκδοχή με guided sampling (Πίνακας 5.4). Η μοναδική διαφορά είναι ο client 13, του οποίου η τιμή είναι $-0{,}0025$ με τυπική απόκλιση $0{,}0488$, δηλαδή σχεδόν είκοσι φορές μεγαλύτερη από την ίδια την τιμή. Πρόκειται για τον μόνο client που είναι ουσιαστικά μηδενικός. Το πρόσημό του, επομένως, δεν είναι ερμηνεύσιμο.

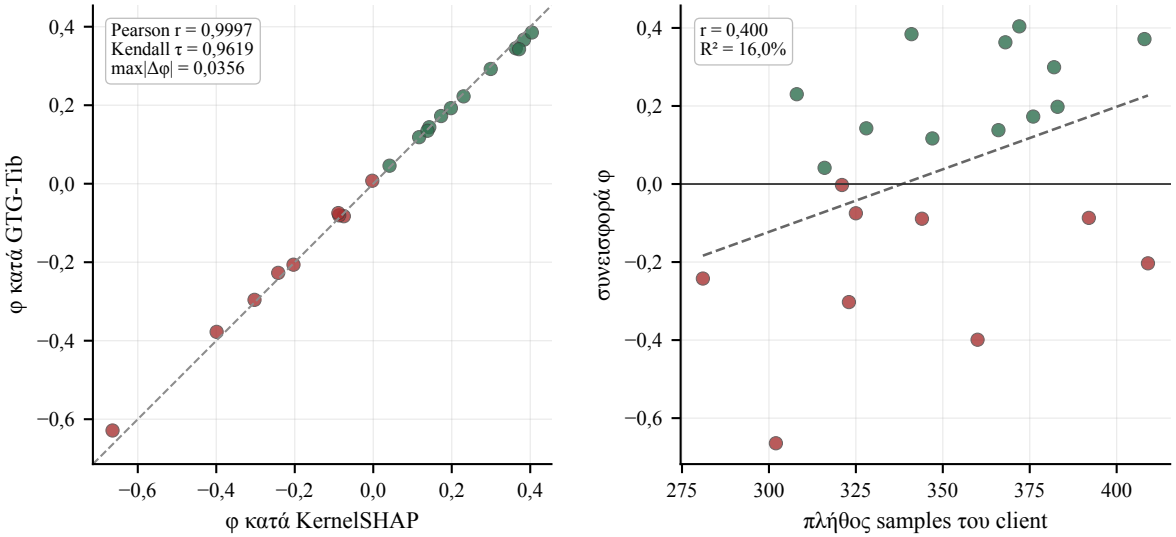
5.3.2 Συμφωνία εκτιμητών και σταθερότητα

Ο Πίνακας 5.4 συγκρίνει τους τρεις εκτιμητές, με αναφορά τον KernelSHAP, με τα μέτρα της Ενότητας 2.1.3. Η συμφωνία είναι υψηλή σε κάθε μέτρο. Για το GTG-Tib, ο συντελεστής Pearson είναι $0{,}9997$, ο Spearman $0{,}9935$ και ο Kendall $\tau = 0{,}9619$, δηλαδή οι δύο εκτιμητές διαφωνούν στη σειρά μόνο σε 4 από τα 210 ζεύγη. Τα ζεύγη αυτά βρίσκονται σε δύο ομάδες γειτονικών θέσεων, τις θέσεις 3 και 4 και τις θέσεις 14 έως 16. Μέσα σε κάθε ομάδα, οι τιμές απέχουν λιγότερο από τη μέγιστη διαφορά των δύο εκτιμητών ($0{,}0356$). Οι πέντε πρώτοι

είναι οι ίδιοι clients, με τους 10 και 12 σε αντίστροφη σειρά. Η εκδοχή με guided sampling συμφωνεί ακόμη περισσότερο, με την ίδια κατάταξη σε όλα τα ζεύγη. Το αριστερό τμήμα του Σχήματος 5.4 δείχνει τη σύγκριση του KernelSHAP με το GTG-Tib.

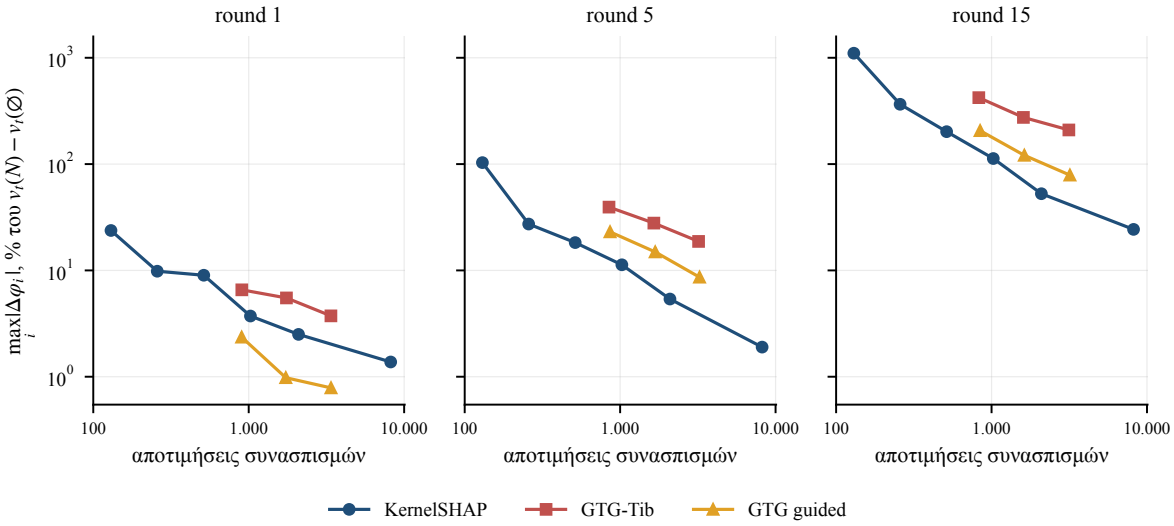
		Σύγκριση με τον KernelSHAP				Αποτιμήσεις	
Εκτιμητής	Αρνητικοί	τ	r	max $\lvert\Delta\varphi\rvert$	μέση $\lvert\Delta\varphi\rvert$	ανά round	ανά seed
KernelSHAP	9	--	--	--	--	2.092	136.503
GTG-Tib	8	0,9619	0,9997	0,0356	0,01113	1.555	101.431
GTG guided	8	1,0000	0,9998	0,0308	0,00965	1.564	102.053

Πίνακας 5.4. Οι τρεις εκτιμητές στο άθροισμα των 1.305 scored rounds, μέσοι όροι 20 seeds. Οι στήλες της σύγκρισης δίνουν τον Kendall τ και τον Pearson r με τον KernelSHAP και τη μέγιστη και μέση απόλυτη διαφορά $|\Delta\varphi|$ από αυτόν πάνω στους 21 clients, αφού για το άθροισμα δεν υπάρχει ακριβές Shapley. Οι αποτιμήσεις είναι αποτιμήσεις της συνάρτησης αξίας. Το άθροισμα $\sum_i \varphi_i = 0{,}79729$ είναι ίδιο και για τους τρεις.



Σχήμα 5.4. Αριστερά: οι δύο εκτιμητές δίνουν ουσιαστικά την ίδια τιμή σε κάθε client. Δεξιά: ο όγκος δεδομένων εξηγεί μόνο το 16% της διακύμανσης της συνεισφοράς. Κόκκινα τα σημεία με αρνητικό φ.

Σύγκλιση ως προς το πλήθος των συνασπισμών. Η συμφωνία αυτή δεν προκύπτει σε οποιοδήποτε υπολογιστικό κόστος. Το Σχήμα 5.5 δείχνει πώς πλησιάζουν οι δύο εκτιμητές το ακριβές Shapley, στα τρία rounds του Πίνακα 5.2, καθώς αυξάνεται ο αριθμός των αποτιμήσεων. Αν και αμφότεροι παρουσιάζουν σύγκλιση, αυτή πραγματοποιείται με διαφορετικό ρυθμό και με διαφορετικό κόστος. Ο ρυθμός εξαρτάται από το round. Στα πρώτα rounds, όπου η μεταβολή $v_t(N) - v_t(\emptyset)$ είναι μεγάλη, η ίδια σχετική ακρίβεια είναι φθηνότερη. Το σχήμα δείχνει και την πλήρη εκδοχή με guided sampling, με τα σημεία του Πίνακα 5.2, αφού προέρχονται από την ίδια εκτέλεση.



Σχήμα 5.5. Η μέγιστη απόκλιση $\max_i |\Delta\varphi_i|$ από το ακριβές Shapley του round (2^{21} συνασπισμοί), ως ποσοστό της μεταβολής $v_t(N) - v_t(\emptyset)$ του round, όπως στον Πίνακα 5.3. Και οι δύο άξονες λογαριθμικοί. Για το GTG-Tib και την εκδοχή με guided sampling (GTG guided), κάθε σημείο είναι μέσος όρος πέντε τραβηγμάτων, όπως στον Πίνακα 5.2. Στο round 15, η μεταβολή του round είναι πολύ μικρή, οπότε στους μικρούς προϋπολογισμούς οι αποκλίσεις την ξεπερνούν.

Η σταθερότητα ως προς τα seeds ελέγχθηκε στο πρόσημο του φ κάθε seed χωριστά. Κατά τον KernelSHAP, 19 από τους 21 clients έχουν το ίδιο πρόσημο με τον μέσο όρο τους σε 19 ή 20 από τα 20 seeds. Οι εξαιρέσεις είναι δύο. Ο client 6 κρατά το πρόσημό του σε 18 seeds και ο 13 σε 11. Επιπλέον, 16 από τους 21 έχουν $|\varphi|$ μεγαλύτερο από τρεις τυπικές αποκλίσεις μεταξύ seeds, δηλαδή η τιμή τους ξεχωρίζει καθαρά από τον θόρυβο εκτίμησης. Οι πέντε που δεν περνούν το κριτήριο είναι οι 3, 6, 13, 16 και 19, δηλαδή οι πέντε με τη μικρότερη απόλυτη τιμή. Οι 3, 16 και 19 κρατούν το αρνητικό πρόσημό τους σε 19 ή 20 seeds, αλλά η τιμή τους δεν ξεχωρίζει καθαρά από τον θόρυβο.

5.3.3 Υπολογιστικό κόστος

Το κόστος μετριέται σε αποτιμήσεις της συνάρτησης αξίας και όχι σε χρόνο, γιατί ο χρόνος εξαρτάται από τον υπολογιστή και από το πόσες εκτελέσεις γίνονται ταυτόχρονα. Οι αριθμοί των δύο τελευταίων στηλών του Πίνακα 5.4 προκύπτουν ως εξής. Ο KernelSHAP αποτιμά σε κάθε scored round τους 2.090 δειγματοληπτούμενους συνασπισμούς και τους δύο ακραίους, τον κενό και τον πλήρη, δηλαδή 2.092. Τα 20 seeds έχουν 1.305 scored rounds, δηλαδή 65,25 ανά seed κατά μέσο όρο, οπότε ο KernelSHAP εκτελεί $2.092 \times 65{,}25 = 136.503$ αποτιμήσεις ανά seed. Το GTG-Tib δειγματοληπτεί έως 100 μεταθέσεις ανά round και σε καθεμιά αποτιμά έναν συνασπισμό για κάθε νέα άφιξη, μέχρι η αξία να πλησιάσει αρκετά τη $v_t(N)$. Ένας συνασπισμός που έχει ήδη αποτιμηθεί σε προηγούμενη μετάθεση δεν αποτι-

μάται ξανά. Χρειάζεται, έτσι, κατά μέσο όρο 1.555 αποτιμήσεις ανά round και 101.431 ανά seed. Η εκδοχή με guided sampling χρειάζεται σχεδόν όσες.

Η διατύπωση αυτού του αποτελέσματος απαιτεί προσοχή, γιατί το κόστος του KernelSHAP εξαρτάται ευθέως από τον αριθμό συνασπισμών που του ζητείται να δειγματοληπτήσει, ο οποίος είναι *παράμετρος*. Με μικρότερο προϋπολογισμό, ο ίδιος εκτιμητής κοστίζει λιγότερο από το GTG-Tib. Επομένως, η σωστή διατύπωση είναι ότι, *στον προεπιλεγμένο προϋπολογισμό της βιβλιοθήκης για 21 παίκτες*, ο εκτιμητής μεταθέσεων πετυχαίνει ουσιαστικά την ίδια κατάταξη με 26% λιγότερες αποτιμήσεις. Θα ήταν λάθος να ειπωθεί ότι «ο ένας είναι φθηνότερος», χωρίς αναφορά στον προϋπολογισμό.

Χρειάζεται, επίσης, να αποδοθεί το κέρδος στη σωστή αιτία. **Δεν** προέρχεται από πρόωρη σύγκλιση, αφού το κριτήριο της Εξίσωσης (10) του [30] ικανοποιείται μόλις σε **15 από τα 1.305** scored rounds των είκοσι seeds. Στους υπόλοιπους 1.290, ο εκτιμητής εξαντλεί το ανώτατο όριο των 100 μεταθέσεων, δηλαδή λειτουργεί στην πράξη με *σταθερό* προϋπολογισμό. Το κέρδος προέρχεται από δύο πηγές. Η πρώτη είναι το γεγονός ότι οι μεταθέσεις περνούν συχνά από τους ίδιους συνασπισμούς, κυρίως τους πολύ μικρούς και τους πολύ μεγάλους, που αποτιμώνται μία φορά. Η δεύτερη είναι η *αποκοπή μέσα στο round*. Μαζί περιορίζουν τις αποτιμήσεις ανά round από 2.092 σε 1.555 κατά μέσο όρο.

5.4 Έλεγχοι των Αρνητικών Τιμών

Πριν ερμηνευθεί το εύρημα των εννέα αρνητικών τιμών, πρέπει να επιβεβαιωθεί η εγκυρότητά του. Τέθηκε σε τέσσερις δοκιμασίες, καθεμιά από τις οποίες θα μπορούσε να το ακυρώσει.

Έλεγχος 1: επιμονή στα rounds. Αν η αρνητική τιμή ήταν θόρυβος δειγματοληψίας, το πρόσημο θα άλλαζε από round σε round, γεγονός που δεν παρατηρείται. Στα 1.305 scored rounds των 20 seeds, όλοι οι εννέα έχουν αρνητική τιμή στους περισσότερους από αυτούς. Για τους επτά, το ποσοστό είναι από $79{,}2\%$ έως $94{,}6\%$, με τον πιο αρνητικό, τον client 2, στο $94{,}2\%$. Χαμηλότερο είναι για τον 13 ($71{,}1\%$) και τον 15 ($57{,}8\%$). Για σύγκριση, ο client 14 είναι θετικός στο $99{,}8\%$. Το πρόσημο, επομένως, δεν αλλάζει τυχαία από round σε round.

Έλεγχος 2: ανεξαρτησία από τη μετρική. Η συνάρτηση αξίας *είναι* μια μετρική. Η Ενότητα 2.1.2 έδειξε ότι διαφορετικές μετρικές ανιχνεύουν διαφορετικές αλλαγές του confusion matrix [11]. Ίσως, λοιπόν, οι αρνητικές τιμές να είναι παρενέργεια του accuracy. Το πείραμα επαναλήφθηκε με macro-F1 στη θέση του accuracy, στα ίδια 20 seeds και με όλα τα υπόλοιπα ταυτόσημα. Κατά τον KernelSHAP, **κανένας client δεν αλλάζει πρόσημο**. Η συμφωνία κα-

τάταξης μεταξύ των δύο μετρικών είναι $\tau = 0{,}9619$, ίδια και για τους δύο εκτιμητές. Οι πέντε πρώτες και οι πέντε τελευταίες θέσεις είναι ταυτόσημες. Κατά το GTG-Tib, αλλάζει πρόσημο ένας μόνο client, ξανά ο 13, που με το accuracy βρίσκεται οριακά πάνω από το μηδέν και με το macro-F1 κάτω από αυτό.

Έλεγχος 3: ανεξαρτησία από τον εκτιμητή. Το θέμα καλύφθηκε στην Ενότητα 5.3.2, όπου δύο αλγοριθμικά διαφορετικοί εκτιμητές συμφωνούν με $\tau = 0{,}9619$ και δίνουν τα ίδια πρόσημα σε 20 από τους 21 clients. Ο τρίτος εκτιμητής της Ενότητας 5.2.4, η πλήρης εκδοχή με guided sampling, δίνει την *ίδια ακριβώς* κατάταξη με τον KernelSHAP και τα ίδια 20 από τα 21 πρόσημα, με τον client 13 να είναι ξανά ο μοναδικός που διαφωνεί.

Έλεγχος 4: σταθερότητα στα seeds. Καλύφθηκε, επίσης, στην Ενότητα 5.3.2. Οι οκτώ από τους εννέα αρνητικούς είναι αρνητικοί σε 19 ή 20 από τα 20 seeds. Εξαίρεση είναι ο 13, σε 11. Επιπλέον, 16 από τους 21 έχουν $|\varphi| > 3\sigma$. Από τους εννέα αρνητικούς, το κριτήριο το περνούν οι πέντε. Οι άλλοι τέσσερις, οι 3, 13, 16 και 19, είναι οι αρνητικοί με τη μικρότερη απόλυτη τιμή.

Οι έλεγχοι 2, 3 και 4 εντοπίζουν τον *ίδιο* μοναδικό ασταθή client, τον 13, ο οποίος είναι και ο μόνος με τιμή μέσα στον θόρυβο. Αυτή η σύμπτωση είναι από μόνη της ένδειξη ότι οι έλεγχοι μετρούν κάτι πραγματικό.

Επομένως, το εύρημα ευσταθεί και **οι αρνητικές τιμές δεν είναι σφάλμα εκτίμησης**. Αυτό συμφωνεί με τη βιβλιογραφία, όπου το αρνητικό πρόσημο είναι μέρος του ορισμού και όχι ανωμαλία. Για παράδειγμα, ο πίνακας συνεισφορών του ShapFed ορίζεται ρητά στο $[-1, 1]^{n \times M}$ [28]. Η ίδια βιβλιογραφία δείχνει, μάλιστα, το αντίστροφο από το αναμενόμενο, ότι οι εκτιμητές Shapley *υποτιμούν συστηματικά* τους clients με σπάνια δεδομένα [32].

Επειδή κάθε client εδώ είναι *ένα άτομο*, αρνητικό φ σημαίνει ότι το update αυτού του ανθρώπου, κατά μέσο όρο στα rounds, μετακινεί το global model σε κατεύθυνση που το κάνει χειρότερο για τα 9 άτομα της αξιολόγησης. Δε σημαίνει κακά δεδομένα, σφάλμα μέτρησης ή κακόβουλη συμπεριφορά. Ούτε σημαίνει ότι ο client χάνει από τη συμμετοχή του, αφού και οι εννέα παίρνουν από την ομοσπονδία μοντέλο πολύ καλύτερο από εκείνο που θα είχαν μόνοι τους (Ενότητα 4.6.2). Τον λόγο που συμβαίνει αυτό εξετάζουν οι Ενότητες 5.5 έως 5.7.

5.5 Μεγέθη που Σχετίζονται με τη Συνεισφορά

Οι εννέα clients με αρνητική τιμή είναι οι $\{2, 3, 5, 7, 11, 13, 15, 16, 19\}$. Το ερώτημα αυτής της ενότητας είναι αν υπάρχει κάποιο μετρήσιμο χαρακτηριστικό τους που να προβλέπει

το φ. Όλες οι συσχετίσεις που ακολουθούν υπολογίζονται πάνω στο φ των 20 seeds, δηλαδή αντιστοιχισμένες με τα αποτελέσματα των προηγούμενων ενοτήτων. Οι συσχετίσεις μετρώνται με τον συντελεστή Pearson r και την τιμή p της Ενότητας 2.1.3. Όλες αφορούν 21 παρατηρήσεις, οπότε η στατιστική ισχύς είναι περιορισμένη και καμία συσχέτιση δεν αποδεικνύει αιτία.

5.5.1 Όγκος δεδομένων, labels και ατομική επίδοση

Το αφελές μέτρο συνεισφοράς στη βιβλιογραφία είναι ο *όγκος δεδομένων*, δηλαδή απλώς το μέγεθος του training set [5], [6]. Στα δεδομένα της εργασίας, ο όγκος συσχετίζεται με το φ κατά $r = +0{,}400$, δηλαδή εξηγεί το $16{,}0\%$ της διακύμανσης, όπως αποτυπώνεται στο δεξί τμήμα του Σχήματος 5.4. Η σχέση είναι θετική αλλά δεν περνά το όριο $p < 0{,}05$ ($p = 0{,}07$), αφού με 21 παρατηρήσεις το όριο απαιτεί $|r|$ μεγαλύτερο από $0{,}43$ περίπου (Ενότητα 2.1.3). Ακόμη κι αν ήταν πραγματική, θα άφηνε ανεξήγητα τα πέντε έκτα της διακύμανσης. Δεν είναι έκπληξη, αν αναλογιστεί κανείς ότι τα μεγέθη κυμαίνονται μόνο από 281 έως 409 samples.

Δύο ακόμη υποψήφιες εξηγήσεις δεν υποστηρίζονται από τα δεδομένα. Η *κατανομή labels* δε φαίνεται να διαδραματίζει ρόλο, αφού η απόσταση ολικής μεταβολής της κατανομής κάθε client από εκείνη ολόκληρου του training set, η ίδια με την Εξίσωση (3.3), δίνει $r = +0{,}056$ ($p = 0{,}81$). Αυτό ήταν αναμενόμενο μετά την Ενότητα 3.4.2. Το εύρημα είναι σημαντικό, γιατί δεν υποστηρίζει τη συνηθισμένη αφήγηση περί non-IID στα labels. Ούτε η *ποιότητα του δικού τους μοντέλου* εξηγεί κάτι, αφού η επίδοση στην ατομική τοπολογία δίνει $r = +0{,}314$ ($p = 0{,}17$), μη στατιστικά σημαντική. Ένας client μπορεί να εκπαιδεύει ένα καλό μοντέλο για τον εαυτό του και ταυτόχρονα να βλάπτει το συλλογικό.

5.5.2 Απόσταση κατανομής features

Σε αντίθεση με τα προηγούμενα μεγέθη, η *απόσταση κατανομής features* περνά το όριο $p < 0{,}05$. Μετρά πόσο διαφέρουν τα σήματα ενός client από εκείνα του test set *στην ίδια δραστηριότητα*. Για κάθε δραστηριότητα c, υπολογίζεται το μέσο διάνυσμα $\boldsymbol{\mu}_{i,c}$ των 561 features του client i και το αντίστοιχο μέσο διάνυσμα $\boldsymbol{\mu}_{\text{test},c}$ του test set. Η απόσταση είναι

$$d_i = \sum_{c=1}^{6} w_c \left\| \boldsymbol{\mu}_{i,c} - \boldsymbol{\mu}_{\text{test},c} \right\|_2, \tag{5.2}$$

όπου $\|\cdot\|_2$ η ευκλείδεια απόσταση και w_c το ποσοστό της δραστηριότητας c στο test set. Η σύγκριση γίνεται χωριστά ανά δραστηριότητα, ώστε η απόσταση να μην εξαρτάται από το *πόσο* συχνά κάνει ο καθένας κάθε δραστηριότητα αλλά μόνο από το *πώς* την κάνει. Η συσχέτιση με το φ είναι $r = -0{,}442$ ($p = 0{,}045$). Η τιμή p δεν είναι διορθωμένη για τους

πολλαπλούς ελέγχους της ενότητας, οπότε η σχέση διαβάζεται ως ένδειξη. Το πρόσημο έχει τη σωστή κατεύθυνση, δηλαδή όσο περισσότερο απέχουν τα σήματα κάποιου από εκείνα του test set, τόσο μικρότερη η συνεισφορά του.

Η ποσότητα αυτή αντιστοιχεί σε αναγνωρισμένη κατηγορία ετερογένειας. Η ταξινομία του πεδίου την ονομάζει *same label, different features*, εννοώντας ότι οι δεσμευμένες κατανομές $P_i(x \mid y)$ μπορεί να διαφέρουν μεταξύ clients, ακόμη και όταν η $P(y)$ είναι κοινή [4]. Αυτό περιγράφει ακριβώς τη ρύθμιση της εργασίας, όπου όλοι εκτέλεσαν το ίδιο πρωτόκολλο έξι δραστηριοτήτων αλλά ο καθένας με τον δικό του τρόπο. Η περίπτωση διαφέρει από εκείνη των *Mavericks* της Ενότητας 2.4.3, οι οποίοι ορίζονται από τα labels [32], αφού εδώ η κατανομή labels δεν εξηγεί τη συνεισφορά (Ενότητα 5.5.1).

Απόσταση από όλους και όχι από το test set. Θα ήταν δελεαστικό να αποδοθεί η ερμηνεία ότι «το test set είναι άτυχο για αυτούς τους ανθρώπους». Όμως, η ερμηνεία αυτή **δεν είναι έγκυρη**. Η απόσταση κάθε client από το test set και η απόστασή του από τους υπόλοιπους 20 clients συσχετίζονται μεταξύ τους κατά $r = +0{,}987$, δηλαδή είναι ουσιαστικά η ίδια μεταβλητή. Όσον αφορά τις μερικές συσχετίσεις, όταν η μία ελέγχεται για την άλλη, μηδενίζονται και οι δύο. Επομένως, όση σχέση υπάρχει αφορά την απόσταση από όλους και όχι ειδικά από το test set.

5.5.3 Κατεύθυνση του update

Όλα τα προηγούμενα μεγέθη περιγράφουν τα *δεδομένα* κάθε client. Το φ, όμως, αποτιμά το *update* που αυτά παράγουν. Γι' αυτό μετρήθηκε και πόσο συμφωνεί το update κάθε client με εκείνο των υπολοίπων. Σε κάθε round, υπολογίζεται το συνημίτονο της γωνίας ανάμεσα στο update Δ_t^i και στον σταθμισμένο μέσο όρο των updates των άλλων 20, με τα βάρη του FedAvg:

$$c_i = \frac{1}{T}\sum_{t=1}^{T} \cos\!\left(\Delta_t^i,\, \bar{\Delta}_t^{-i}\right), \qquad \bar{\Delta}_t^{-i} = \frac{\sum_{j\neq i} n_j \Delta_t^j}{\sum_{j\neq i} n_j}, \tag{5.3}$$

όπου $T = 100$ τα rounds, n_j το πλήθος των samples του client j και $\cos(\mathbf{a},\mathbf{b}) = \langle \mathbf{a},\mathbf{b}\rangle / (\|\mathbf{a}\|_2 \|\mathbf{b}\|_2)$. Ο μέσος όρος των άλλων υπολογίζεται χωρίς τον i, ώστε κανείς να μη συγκρίνεται εν μέρει με τον εαυτό του. Τιμή $+1$ σημαίνει ίδια κατεύθυνση, 0 άσχετη και αρνητική τιμή αντίθετη. Το c_i υπολογίστηκε σε καθένα από τα 20 seeds, πάνω στην ίδια τροχιά εκπαίδευσης με τα κύρια αποτελέσματα, bit προς bit. Αναφέρεται ο μέσος όρος τους. Η μέτρηση **δε χρησιμοποιεί το test set**.

Οι τιμές είναι μικρές για όλους, από $-0{,}19$ έως $+0{,}08$, δηλαδή τα updates είναι σχεδόν κάθετα μεταξύ τους. Οι εννέα αρνητικοί, όμως, έχουν μέσο συνημίτονο $-0{,}081$ και οι δώδεκα θετικοί $+0{,}003$. Η συσχέτιση με το φ είναι $r = +0{,}580$ ($p = 0{,}006$), η ισχυρότερη

της ενότητας. Είναι θετική σε καθένα από τα 20 seeds χωριστά. Ο client 2 έχει το δεύτερο μικρότερο συνημίτονο από τους 21. Πρόκειται για τη γεωμετρική μορφή της απόκλισης των clients της Ενότητας 2.2.3. Εδώ χρησιμοποιείται μόνο ως μέτρηση, αφού δεν εφαρμόζεται καμία διόρθωση της απόκλισης.

Συμπέρασμα. Ο Πίνακας 5.5 συγκεντρώνει τα πέντε μεγέθη. Κανένα δεν προβλέπει ικανοποιητικά τη συνεισφορά, καθώς ακόμη και το ισχυρότερο, η κατεύθυνση του update, εξηγεί περίπου το ένα τρίτο της διακύμανσης του φ. Από τα μεγέθη των δεδομένων, η απόσταση features εξηγεί λιγότερο από το ένα πέμπτο και ο όγκος δεδομένων το $16{,}0\%$.

Μέγεθος	Ενότητα	r με το φ	p	r^2	Client 2
Όγκος δεδομένων	5.5.1	$+0{,}400$	$0{,}07$	$16{,}0\%$	$-1{,}38$
Απόσταση labels	5.5.1	$+0{,}056$	$0{,}81$	$0{,}3\%$	$+0{,}09$
Ατομική επίδοση	5.5.1	$+0{,}314$	$0{,}17$	$9{,}9\%$	$+0{,}17$
Απόσταση features	5.5.2	$-0{,}442$	$0{,}045$	$19{,}5\%$	$-0{,}50$
Κατεύθυνση του update	5.5.3	$+0{,}580$	$0{,}006$	$33{,}6\%$	$-1{,}28$

Πίνακας 5.5. Τα πέντε μεγέθη της Ενότητας 5.5, με τη συσχέτιση Pearson r με το φ στους 21 clients, την τιμή p και το ποσοστό της διακύμανσης του φ που εξηγεί το καθένα (r^2). Η τελευταία στήλη δίνει πόσες τυπικές αποκλίσεις απέχει ο client 2 από τον μέσο όρο των 21. Τα τέσσερα πρώτα μεγέθη αφορούν τα δεδομένα κάθε client και το τελευταίο το update του.

Το πιο χαρακτηριστικό παράδειγμα είναι ο χειρότερος client. Ο client 2, με $\varphi = -0{,}664$, είναι κοντά στον μέσο όρο σε όλα τα στατιστικά των δεδομένων του εκτός από ένα (τελευταία στήλη του Πίνακα 5.5). Τον ξεχωρίζει μόνο το πλήθος των samples του, το δεύτερο μικρότερο από τους 21. Ο όγκος, όμως, δεν αρκεί για μια τόσο ακραία τιμή, αφού ο client 5, με τα λιγότερα samples από όλους, έχει $\varphi = -0{,}242$. Έχει, επίσης, το δεύτερο μικρότερο συνημίτονο, αλλά ούτε αυτό αρκεί, αφού ο client 18 έχει σχεδόν το ίδιο και θετική τιμή. Την ακραία τιμή του δεν την εξηγεί μόνο του κανένα από τα πέντε μεγέθη.

Το συμπέρασμα της ενότητας είναι, λοιπόν, ότι η αρνητική συνεισφορά σχετίζεται κυρίως με την *κατεύθυνση του update* και λιγότερο με τα δεδομένα. Τα updates των εννέα αρνητικών απομακρύνονται, κατά μέσο όρο, από την κατεύθυνση των υπολοίπων. Επειδή ο FedAvg παίρνει μέσο όρο, ένα τέτοιο update τραβά το global model μακριά από εκεί όπου το πάνε οι περισσότεροι. Η κατεύθυνση, όμως, εξηγεί μόνο το ένα τρίτο της διακύμανσης και δεν αντικαθιστά την αποτίμηση. Αν η συνεισφορά ήταν προβλέψιμη από φθηνά μετρήσιμα μεγέθη, ο υπολογισμός Shapley θα ήταν πολυτέλεια, γεγονός που δεν ευσταθεί στα δεδομένα της εργασίας.

5.6 Επαλήθευση με Δεύτερο Παίγνιο στην Κεντρική Εκπαίδευση

Οι δύο προηγούμενες ενότητες έδειξαν ότι οι αρνητικές τιμές είναι πραγματικές και ότι κανένα φθηνό μέγεθος δεν τις προβλέπει πλήρως. Πριν αναλυθούν, η ενότητα αυτή τις εξετάζει με ένα δεύτερο παίγνιο, το παίγνιο επανεκπαίδευσης, όπου το μοντέλο που αποτιμάται είναι το κεντρικό (*centralized*) και όχι το ομοσπονδιακό.

Ως εδώ, όλες οι τιμές προέρχονται από ένα παίγνιο, όπου η αξία ενός συνασπισμού είναι η επίδοση του μοντέλου που θα προέκυπτε από τα *updates* των μελών του. Επομένως, το ερώτημα που τίθεται είναι αν τα *δεδομένα* των clients με αρνητική τιμή βλάπτουν και έξω από τη συγκεκριμένη ομοσπονδιακή εκπαίδευση, όταν εκπαιδεύουν ένα κεντρικό μοντέλο. Τα δύο ενδεχόμενα έχουν διαφορετικές συνέπειες. Το πρώτο θα σήμαινε ότι κάποιοι άνθρωποι συνεισφέρουν πράγματι λιγότερο, ενώ το δεύτερο ότι η αρνητική τιμή αφορά τη συγκεκριμένη εκπαίδευση και όχι τους ανθρώπους.

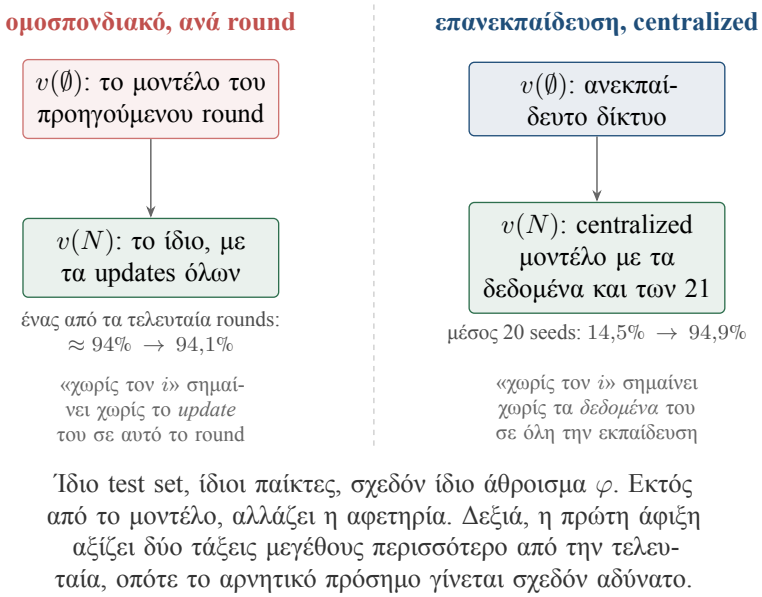
5.6.1 Ορισμός του παιγνίου

Για να απαντηθεί το προς διερεύνηση ζήτημα, ορίζεται δεύτερο παίγνιο με τους *ίδιους* 21 παίκτες αλλά διαφορετική συνάρτηση αξίας (Σχήμα 5.6). Η αξία ενός συνασπισμού S είναι η επίδοση ενός *κεντρικού* (*centralized*) μοντέλου, που εκπαιδεύεται *από την αρχή* μόνο με τα δεδομένα των clients του S, συγκεντρωμένα σε ένα training set. Δεν εκτελείται ομοσπονδιακή εκπαίδευση, οπότε δεν υπάρχουν updates ούτε aggregation. Η αξία που μετριέται είναι εκείνη των δεδομένων για ένα κεντρικό μοντέλο, δηλαδή το Data Shapley με επανεκπαίδευση, όπως ορίζεται στη βιβλιογραφία [19].

Πέρα από το μοντέλο, τα δύο παίγνια διαφέρουν και στο πότε μετριέται η αξία. Στο ομοσπονδιακό παίγνιο μετριέται σε κάθε round, με αφετηρία το μοντέλο της αρχής του round, ενώ εδώ στο τέλος μιας εκπαίδευσης που ξεκινά από ανεκπαίδευτο δίκτυο. Κάθε παίγνιο ακολουθεί τον ορισμό του πλαισίου του. Η ομοσπονδιακή εκπαίδευση προχωρά round προς round, και η αξία των δεδομένων εξαρτάται από το πότε χρησιμοποιούνται [31]. Στην κεντρική εκπαίδευση τα δεδομένα ανακατεύονται, οπότε η σειρά δεν παίζει ρόλο και ο ορισμός με επανεκπαίδευση ταιριάζει [31].

Το κόστος είναι η επανεκπαίδευση, που εδώ σημαίνει 41.840 εκπαιδεύσεις στα 20 seeds. Σε κάθε seed, ο KernelSHAP διαλέγει πρώτα 2.090 συνασπισμούς, όσους και στο ομοσπονδιακό παίγνιο. Οι εκπαιδεύσεις γίνονται με τον βρόχο και τις ρυθμίσεις της κεντρικής τοπολογίας (Ενότητα 4.3.1) και η αξία κάθε συνασπισμού είναι το accuracy του μοντέλου του στο test set. Η ροή του υπολογισμού δίνεται στο Σχήμα 5.7. Τρεις αποφάσεις δηλώνονται ρητά.

Όλοι οι συνασπισμοί εκπαιδεύονται με το *ίδιο* seed, ώστε οι διαφορές μεταξύ τους να μην περιέχουν διαφορά αρχικοποίησης. Ο κενός συνασπισμός αποτιμάται ως το αρχικοποιημένο και μη εκπαιδευμένο δίκτυο. Τέλος, κάθε συνασπισμός εκπαιδεύεται για τα ίδια 100 epochs, ανεξάρτητα από το πλήθος των δεδομένων του. Ως έλεγχος της υλοποίησης, ο συνασπισμός και των 21 αναπαράγει το αποθηκευμένο κεντρικό αποτέλεσμα σε 20 από τα 20 seeds, bit προς bit.



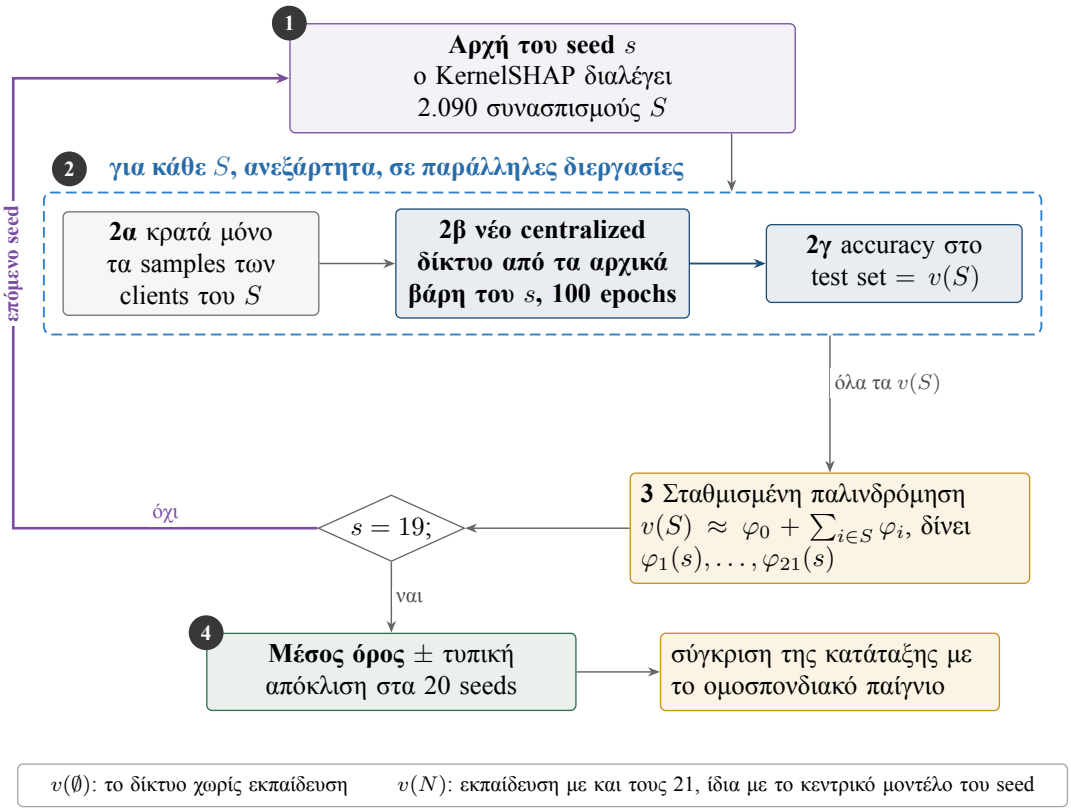
Σχήμα 5.6. Τα δύο παίγνια, ορισμένα πάνω στους ίδιους 21 παίκτες. Αριστερά αποτιμάται το ομοσπονδιακό μοντέλο και δεξιά ένα centralized μοντέλο, που εκπαιδεύεται από την αρχή για κάθε συνασπισμό. Μαζί με το μοντέλο αλλάζει η σημασία του «χωρίς τον i» και, μαζί της, η αξία του κενού συνασπισμού. Η διαφορά αυτή εξηγεί γιατί η σύγκριση των δύο πρέπει να γίνει στην *κατάταξη* και όχι στο πρόσημο.

Στο παίγνιο αυτό χρησιμοποιείται *ένας* μόνο εκτιμητής, ο KernelSHAP, γιατί εδώ κάθε αποτίμηση είναι μια πλήρης εκπαίδευση και ένας δεύτερος εκτιμητής θα χρειαζόταν δικές του εκπαιδεύσεις. Το κενό που αφήνει η απουσία δεύτερου εκτιμητή καλύπτεται από δύο ελέγχους. Ο πρώτος είναι η σύγκριση με τον ίδιο τον ορισμό. Το παίγνιο οκτώ παικτών της Ενότητας 5.2.5, όπου ο KernelSHAP αναπαράγει το ακριβές Shapley στην ακρίβεια της μηχανής, είναι ακριβώς αυτό το παίγνιο, περιορισμένο στους οκτώ πρώτους clients. Δείχνει ότι ο εκτιμητής είναι σωστά υλοποιημένος. Ο δεύτερος είναι η σύγκριση δύο ανεξάρτητων μισών των seeds (Ενότητα 5.6.3), που δείχνει αν οι 2.090 συνασπισμοί αρκούν για 21 παίκτες. Ο KernelSHAP εκτελέστηκε εδώ με την προεπιλογή της βιβλιοθήκης, δηλαδή με επιλογή παικτών (Ενότητα 5.2.1), χωρίς επίδραση, αφού κανένα από τα 420 φ δε βγήκε μηδέν.

Εδώ δεν υπάρχουν rounds. Για κάθε seed στήνεται ένα μόνο παίγνιο και η παλινδρόμηση του KernelSHAP δίνει κατευθείαν την τιμή $\varphi_i(s)$ του seed, χωρίς άθροισμα rounds (βήμα 3 του Σχήματος 5.7). Οι εκπαιδεύσεις των συνασπισμών (βήμα 2) είναι ανεξάρτητες μεταξύ τους και μοιράζονται σε παράλληλες διεργασίες, ενώ τα seeds εκτελούνται το ένα μετά το

άλλο. Επειδή χρειάζονται δεκάδες χιλιάδες εκπαιδεύσεις, η κεντρική εκπαίδευση καλείται μέσα από μια διαδρομή που παραλείπει ό,τι δε χρειάζεται, όταν ζητείται μόνο η τελική επίδοση, όπως η καταγραφή ανά epoch και οι ενδιάμεσες αξιολογήσεις. Η παράλειψη δεν είναι αβλαβής εξ ορισμού, γιατί η αξιολόγηση καταναλώνει τυχαιότητα (Ενότητα 4.4). Γι' αυτό ο πλήρης συνασπισμός συγκρίνεται με το αποθηκευμένο κεντρικό αποτέλεσμα σε κάθε seed.

Στον κώδικα, η επιλογή των συνασπισμών και η παλινδρόμηση (βήματα 1 και 3) γίνονται στη `run_seed()` του `contribution/data_shapley.py` και οι μέσοι όροι με τη σύγκριση της κατάταξης (βήμα 4) στη `summarize()` του ίδιου αρχείου. Η εκπαίδευση ανά συνασπισμό (βήμα 2) οργανώνεται από την `RetrainGame` του `contribution/sv/retrain_game.py`, που στέλνει κάθε εκπαίδευση στην `fast_holdout_predict()` του `centralized/fast_holdout.py`.

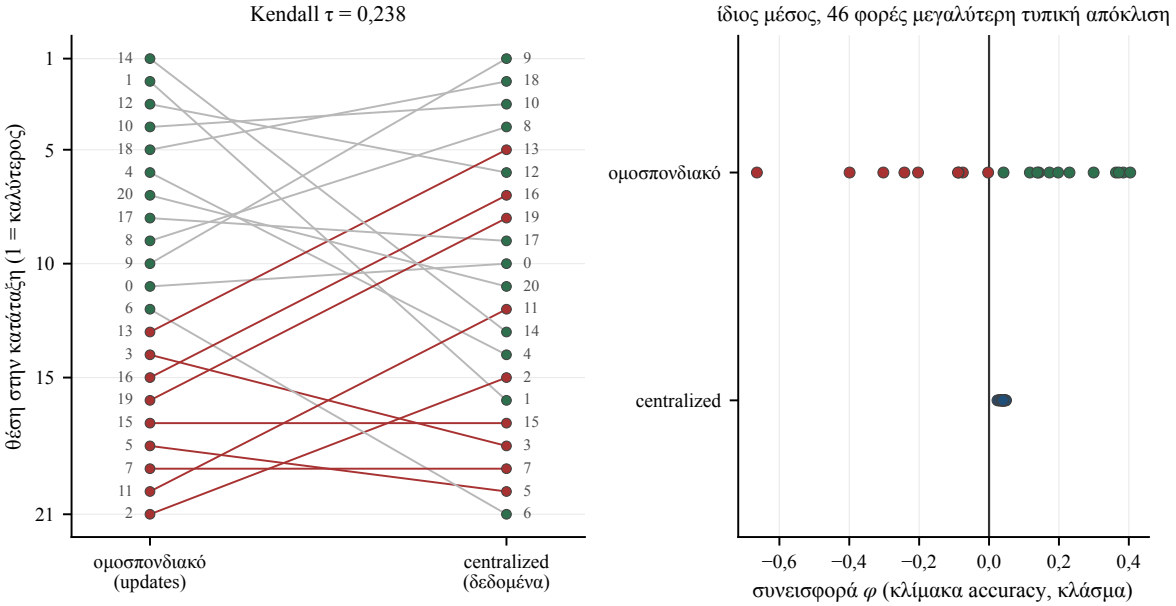


Σχήμα 5.7. Η αποτίμηση στο παίγνιο επανεκπαίδευσης. Το βήμα 2 γίνεται μία φορά για κάθε συνασπισμό και είναι το μόνο που εκπαιδεύει, πάντα ένα centralized μοντέλο με τα δεδομένα των clients του συνασπισμού. Κάθε seed έχει ένα μόνο παίγνιο, οπότε η τιμή του seed βγαίνει κατευθείαν από την παλινδρόμηση.

5.6.2 Αποτελέσματα

Κανένας από τους 21 clients δε λαμβάνει αρνητική τιμή. Το εύρος είναι $+0{,}0241$ έως $+0{,}0485$, δηλαδή τα δεδομένα κάθε ανθρώπου αξίζουν από $2{,}4$ έως $4{,}8$ ποσοστιαίες μονάδες

accuracy. Δε βρέθηκε ένδειξη ότι τα δεδομένα κάποιου βλάπτουν, όταν χρησιμοποιηθούν μέσα σε μια κοινή εκπαίδευση. Το Σχήμα 5.8 παρουσιάζει τα δύο παίγνια μαζί.



Σχήμα 5.8. Αριστερά: η θέση κάθε client στο ομοσπονδιακό παίγνιο και στο παίγνιο επανεκπαίδευσης του κεντρικού μοντέλου (centralized στο σχήμα). Με κόκκινο όσοι λαμβάνουν αρνητική τιμή στο ομοσπονδιακό. Δεξιά: οι δύο κατανομές των φ στον ίδιο άξονα. Το άθροισμα και ο μέσος είναι ουσιαστικά ταυτόσημα, η διασπορά όχι.

Η κατάταξη των δύο παιγνίων συμφωνεί ασθενώς, με $\tau = 0{,}238$ (αριστερό τμήμα του Σχήματος 5.8). Έξι από τους εννέα clients που είναι αρνητικοί στο ομοσπονδιακό παίγνιο βρίσκονται κάτω από τη διάμεσο και εδώ, οπότε υπάρχει πράγματι σήμα που συνδέει τα δύο. Όμως, το μεγαλύτερο μέρος της κατάταξης δε μεταφέρεται. Τα συγκεκριμένα παραδείγματα το αναδεικνύουν καθαρότερα από τον συντελεστή. Ο client 2, με διαφορά ο χειρότερος του ομοσπονδιακού παιγνίου ($\varphi = -0{,}664$, θέση 21 από 21), είναι *μεσαίος* εδώ. Ο client 14, ο καλύτερος του ομοσπονδιακού παιγνίου, δε βρίσκεται κοντά στην κορυφή. Οι ακριβείς θέσεις τους δίνονται στον Πίνακα 5.6, μετά τον έλεγχο της ακρίβειας της Ενότητας 5.6.3. Επιπλέον, ο χειρότερος αυτού του παιγνίου είναι θετικός στο άλλο.

5.6.3 Ακρίβεια της εκτίμησης

Επειδή το παίγνιο αυτό δεν έχει δεύτερο εκτιμητή για διασταύρωση, η ακρίβεια ελέγχεται διαφορετικά. Τα 20 seeds χωρίζονται σε δύο ανεξάρτητα μισά και τα δύο αποτελέσματα συγκρίνονται μεταξύ τους. Ο έλεγχος αυτός είναι αναγκαίος, γιατί ο θόρυβος της στοχαστικής βελτιστοποίησης καθιστά τις κατατάξεις αποτίμησης ασυνεπείς μεταξύ εκτελέσεων [25].

Η μέση απόλυτη διαφορά ανάμεσα στα δύο μισά είναι $0{,}0027$, ενώ ο θόρυβος των seeds από μόνος του θα προέβλεπε περίπου $0{,}0036$. Η διαφορά είναι, δηλαδή, συμβατή με τον

θόρυβο. Οι συντελεστές συσχέτισης ανάμεσα στα μισά είναι $0{,}811$ κατά Pearson και $0{,}657$ κατά Kendall. Σε κανένα από τα δύο μισά δεν εμφανίζεται αρνητική τιμή. Επιπροσθέτως, η ασθενής συμφωνία με το ομοσπονδιακό παίγνιο αναπαράγεται και στα δύο, με $\tau = 0{,}219$ και $0{,}314$ έναντι $0{,}238$ συνολικά.

Σε αριθμούς, το εύρος των τιμών μεταξύ clients είναι περίπου $0{,}024$ και το τυπικό σφάλμα με 20 seeds $0{,}0022$, δηλαδή 9% του εύρους. Από τα 210 ζεύγη clients, τα 100 διαχωρίζονται στατιστικά. Για να υποχωρήσει το σφάλμα στο 10%, θα αρκούσαν 17 seeds, οπότε τα 20 ήταν επαρκής και όχι υπερβολική επιλογή.

Το συμπέρασμα του ελέγχου είναι διπλό. Το δεύτερο μέρος του είναι περιορισμός. Τα *ποιοτικά* συμπεράσματα είναι σταθερά αλλά η ακριβής θέση ενός μεμονωμένου client στην κατάταξη δεν είναι. Ο client 2 είναι 13ος και 15ος στα δύο μισά, σταθερά στη μέση, ενώ ο 14 είναι 8ος και 16ος. Γι' αυτό, στον Πίνακα 5.6, η θέση στο σύνολο των seeds συνοδεύεται από τη θέση σε κάθε μισό.

5.6.4 Συμπέρασμα

Ο Πίνακας 5.6 συγκεντρώνει τα δύο παίγνια.

	Ομοσπονδιακό παίγνιο	**Παίγνιο επανεκπαίδευσης**
Μοντέλο που αποτιμάται	το ομοσπονδιακό	centralized, ένα ανά S
Πότε μετριέται η αξία	σε κάθε round	στο τέλος της εκπαίδευσης
Αξία του κενού συνασπισμού	το μοντέλο της αρχής του round	ανεκπαίδευτο δίκτυο
Εκπαιδεύσεις στα 20 seeds	καμία επιπλέον	41.840
$\sum_i \varphi_i$	$+0{,}797$	$+0{,}804$
Μέσος όρος των φ	$+0{,}038$	$+0{,}038$
Τυπική απόκλιση των φ	$0{,}285$	$0{,}0063$
Εύρος	$-0{,}664$ έως $+0{,}404$	$+0{,}0241$ έως $+0{,}0485$
Αρνητικοί	9	0
Θέση του client 2	21	15 (13 και 15)
Θέση του client 14	1	13 (8 και 16)
Συμφωνία κατάταξης	Kendall $\tau = 0{,}238$	

Πίνακας 5.6. Τα δύο παίγνια πάνω στους ίδιους 21 παίκτες, μέσοι όροι 20 seeds, εκτιμητής KernelSHAP. Η τυπική απόκλιση είναι μεταξύ των 21 clients. Θέση 1 είναι η μεγαλύτερη τιμή. Στο παίγνιο επανεκπαίδευσης οι θέσεις δεν είναι σταθερές από seed σε seed, γι' αυτό σε παρένθεση δίνεται η θέση σε καθένα από τα δύο μισά των seeds (Ενότητα 5.6.3).

Τα αποτελέσματα του δεύτερου παιγνίου διαβάζονται με μία επιφύλαξη, που αφορά το πρόσημο. Το γεγονός ότι κανείς δε βγαίνει αρνητικός εδώ *δεν* αποδεικνύει από μόνο του ότι τα δεδομένα όλων είναι καλά. Δείχνει, σε μεγάλο βαθμό, ότι το παίγνιο αυτό δύσκολα μπορεί να παραγάγει αρνητικό πρόσημο.

Ο λόγος βρίσκεται στον ίδιο τον ορισμό. Το φ είναι μέσος όρος οριακών συνεισφορών πάνω σε *όλες* τις σειρές άφιξης. Οι σειρές αυτές δεν είναι ισοδύναμες. Στο παίγνιο επανεκπαίδευσης, όποιος φτάνει πρώτος μετατρέπει ένα μη εκπαιδευμένο δίκτυο σε λειτουργικό ταξινομητή. Η αξία της θέσης αυτής, μετρημένη χωριστά, είναι κατά μέσο όρο $+0{,}612$ και το μικρότερο είναι $+0{,}505$. Η αξία της τελευταίας θέσης, όπου το μοντέλο έχει ήδη δει τα δεδομένα είκοσι ανθρώπων, είναι κατά μέσο όρο $+0{,}0030$, με εύρος από $-0{,}0070$ έως $+0{,}0207$. Οι δύο θέσεις διαφέρουν κατά δύο τάξεις μεγέθους. Για να βγει αρνητικό φ, θα έπρεπε οι λίγες αρνητικές οριακές συνεισφορές των τελευταίων θέσεων να υπερκαλύψουν το μπόνους της πρώτης, κάτι πρακτικά αδύνατο. Στο ομοσπονδιακό παίγνιο, τέτοιο μπόνους υπάρχει μόνο στα πρώτα rounds, γιατί κάθε συνασπισμός ενός round ξεκινά από το μοντέλο της αρχής του round, που μετά τα πρώτα rounds είναι ήδη εκπαιδευμένο.

Ο αριθμός που το δείχνει με σαφήνεια είναι η σύγκριση των δύο κατανομών. Το άθροισμα των φ είναι ουσιαστικά το ίδιο ($+0{,}797$ έναντι $+0{,}804$), όπως και ο μέσος όρος ($+0{,}038$ και στα δύο). Η τυπική απόκλιση, όμως, διαφέρει κατά παράγοντα περίπου 45 ($0{,}285$ έναντι $0{,}0063$). Ο μέσος όρος δεσμεύεται από το αξίωμα της αποδοτικότητας και δεν παρέχει πρόσθετη πληροφορία. Η πληροφορία βρίσκεται στο πώς μοιράζεται το άθροισμα ανάμεσα στους clients. Το μέγεθος που πρέπει να συγκριθεί ανάμεσα στα δύο παίγνια είναι η **κατάταξη**, όχι το πρόσημο.

Με αυτήν την επιφύλαξη, το συμπέρασμα είναι το εξής. Δε βρέθηκε ένδειξη ότι τα δεδομένα κάποιου client είναι βλαβερά, ενώ υπάρχει ασθενές σήμα που συνδέει την ποιότητα των δεδομένων με την ομοσπονδιακή συνεισφορά. Το μεγαλύτερο μέρος της κατάταξης, όμως, δε μεταφέρεται από το ένα παίγνιο στο άλλο. Η συνεισφορά ενός client στην ομοσπονδιακή εκπαίδευση δεν ταυτίζεται με την αξία των ίδιων δεδομένων σε κεντρική εκπαίδευση, και τα δύο μεγέθη, παρότι έχουν το ίδιο όνομα, απαντούν σε διαφορετικό ερώτημα. Γι' αυτό το failure analysis της επόμενης ενότητας επιστρέφει στο ομοσπονδιακό παίγνιο, όπου εμφανίζεται η αρνητική τιμή.

5.7 Failure Analysis

Το *failure analysis* μελετά το ίδιο το ομοσπονδιακό παίγνιο. Το φ_i είναι ένας αριθμός αλλά προκύπτει ως άθροισμα πάνω σε rounds. Το accuracy από το οποίο υπολογίζεται είναι, με τη σειρά του, σταθμισμένος μέσος όρος πάνω σε δραστηριότητες και πάνω σε άτομα της

αξιολόγησης. Η ενότητα αποσυνθέτει πρώτα την τιμή κατά μήκος αυτών των τριών αξόνων, ώστε να φανεί *πότε* εμφανίζεται, *σε ποιες* δραστηριότητες και *απέναντι σε ποιους* ανθρώπους. Στη συνέχεια, εξετάζει αν αυτό που μετρήθηκε μπορεί να αξιοποιηθεί. Τα δύο μέρη αποτελούν ένα ενιαίο επιχείρημα, γιατί η αποσύνθεση δείχνει ότι η αρνητική τιμή εξαρτάται από το ποια άτομα βρίσκονται στο test set. Ο έλεγχος της αξιοποίησης μετρά πόσο ισχυρή είναι αυτή η εξάρτηση.

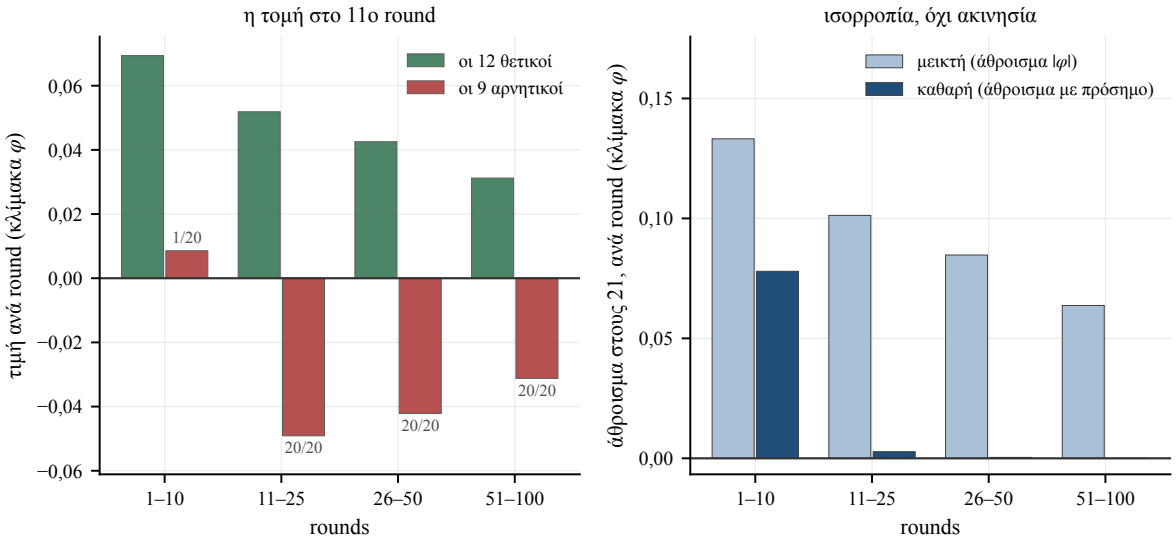
5.7.1 Η αρνητική τιμή ανά round

Η τιμή φ_i των προηγούμενων ενοτήτων είναι άθροισμα πάνω στα scored rounds κάθε seed, δηλαδή στα rounds που κρατά η αποκοπή μεταξύ rounds (Ενότητα 5.2.2), από 51 έως 74, με μέσο όρο 65. Ένα άθροισμα, όμως, κρύβει τη χρονική του δομή, αφού η ίδια συνολική τιμή προκύπτει είτε από σταθερή μικρή βλάβη σε όλη τη διάρκεια, είτε από έντονη βλάβη σε ένα μόνο διάστημα. Η διάκριση δεν είναι ακαδημαϊκή, γιατί καθορίζει αν η αρνητική συνεισφορά είναι ιδιότητα του client ή ιδιότητα της *φάσης* της εκπαίδευσης.

Επομένως, οι τιμές αναλύθηκαν ανά round. Η εικόνα που προκύπτει έχει σαφή τομή (Σχήμα 5.9). Στα rounds 1 έως 10, όσο το accuracy του global model ανεβαίνει από $59{,}3\%$ στο τέλος του πρώτου round σε $90{,}1\%$ στο τέλος του δέκατου, οι εννέα clients που τελικά λαμβάνουν αρνητική τιμή είναι, ως ομάδα, **θετικοί**, με μέση συνεισφορά $+0{,}083$ μονάδες και θετικό πρόσημο σε 19 από τα 20 seeds. Από το ενδέκατο round και μετά, το πρόσημο αντιστρέφεται και παραμένει αρνητικό σε **20 από τα 20** seeds, σε κάθε ομάδα rounds που εξετάστηκε.

Η ένταση της βλάβης δεν είναι σταθερή. Ο ρυθμός ανά round είναι $-0{,}049$ μονάδες στα rounds 11 έως 25 και υποχωρεί σε $-0{,}031$ στα rounds 51 έως 100. Η βλάβη, δηλαδή, είναι *εντονότερη αμέσως μετά* την τομή και εξασθενεί καθώς η εκπαίδευση προχωρά. Η σύγκριση γίνεται με τον ρυθμό ανά round και όχι με το άθροισμα κάθε ομάδας rounds, γιατί οι ομάδες έχουν *άνισο πλάτος*. Η ομάδα 51 έως 100 έχει διπλάσια scored rounds από την ομάδα 11 έως 25 και, επομένως, μεγαλύτερο άθροισμα ακόμη και με μικρότερο ρυθμό. Η σύγκριση των αθροισμάτων θα έδινε την εσφαλμένη εντύπωση ότι η βλάβη συγκεντρώνεται στο πλατό των τελευταίων rounds, ενώ στην πραγματικότητα *ξεκινά* όταν το μοντέλο ξεπεράσει περίπου το 90% και είναι εντονότερη αμέσως μετά.

Μεικτή και καθαρή κίνηση. Το άθροισμα των τιμών όλων των clients σε ένα round είναι σχεδόν μηδενικό από το ενδέκατο round και μετά, σε 20 από τα 20 seeds. Αυτό δε σημαίνει ότι δε συμβαίνει τίποτα. Το άθροισμα των *απόλυτων* τιμών, δηλαδή η συνολική μάζα που μετακινείται ανεξαρτήτως κατεύθυνσης, είναι τουλάχιστον δεκαπλάσιο του αθροίσματος με πρόσημο. Εννέα clients τραβούν το μοντέλο προς τη μία κατεύθυνση και δώδεκα προς την



Σχήμα 5.9. Αριστερά: η τιμή ανά scored round, χωριστά για τις δύο ομάδες clients, μέσος όρος 20 seeds. Μέχρι το δέκατο round και οι δύο είναι θετικές. Στην άκρη κάθε στήλης των αρνητικών, το πλήθος των seeds στα οποία η ομάδα βγαίνει κάτω από το μηδέν. Δεξιά: το άθροισμα και των 21, επίσης ανά scored round. Το άθροισμα με πρόσημο σβήνει μετά το δέκατο round, ενώ το άθροισμα των απόλυτων τιμών όχι. Και τα δύο πάνελ δείχνουν ρυθμό ανά round, ώστε οι ομάδες rounds άνισου πλάτους να συγκρίνονται μεταξύ τους.

άλλη. Οι δύο δυνάμεις σχεδόν αλληλοεξουδετερώνονται. Στο πλατό, η ομοσπονδία δεν είναι ακίνητη αλλά βρίσκεται σε ισορροπία.

Δύο clients ορίζουν τα άκρα αυτής της εικόνας. Ο client 2 είναι αρνητικός στο 100% των rounds μετά το δέκατο, χωρίς καμία εξαίρεση σε κανένα seed. Ο client 15 είναι η αντίστροφη περίπτωση. Βλάπτει κυρίως στα δέκα πρώτα rounds, όπου είναι ο πιο αρνητικός από τους εννέα. Μετά το round 25, η συνεισφορά του είναι σχεδόν μηδενική, οπότε η αρνητική του τιμή είναι κατάλοιπο της αρχικής φάσης και όχι χαρακτηριστικό της συμπεριφοράς του.

Το εύρημα αυτό αλλάζει τη διατύπωση του ερωτήματος. Δεν υπάρχουν απλώς clients που βλάπτουν και clients που βοηθούν αλλά clients των οποίων η συνεισφορά *αλλάζει πρόσημο*, όταν το μοντέλο φτάσει σε ένα επίπεδο επίδοσης. Όσο το μοντέλο μαθαίνει ακόμα τη βασική διάκριση των δραστηριοτήτων, θετικά συνεισφέρουν και οι δύο ομάδες. Όταν, όμως, απομένουν μόνο τα λεπτά σύνορα μεταξύ γειτονικών δραστηριοτήτων, ορισμένοι αρχίζουν να εισάγουν αποκλίνουσες τάσεις. Οι δύο επόμενες υποενότητες εξετάζουν την κατεύθυνση αυτών των αποκλίσεων, αρχικά ανά δραστηριότητα και έπειτα ανά άτομο της αξιολόγησης.

5.7.2 Η αρνητική τιμή ανά δραστηριότητα

Μέχρι εδώ, η συνάρτηση αξίας ήταν βαθμωτή. Μπορεί, όμως, να γίνει διανυσματική, με μία συνιστώσα ανά δραστηριότητα, όπως στο ShapFed, όπου η συνάρτηση χρησιμότητας ορίζεται ως επίδοση ανά κλάση [28], ή στην αποτίμηση ανά label για τους Mavericks [32]. Τότε, κάθε client παίρνει έξι τιμές αντί για μία και προκύπτει μια μήτρα 21×6.

Πώς προκύπτουν οι έξι τιμές. Στην πράξη αλλάζει μόνο η συνάρτηση αξίας της Εξίσωσης (5.1). Όλα τα υπόλοιπα μένουν ίδια, δηλαδή η εκπαίδευση, τα scored rounds, οι συνασπισμοί και η ανασύνθεση των μοντέλων τους. Το μοντέλο κάθε συνασπισμού S ταξινομεί τα 2.947 samples του test set όπως πριν. Αντί, όμως, να μετρηθεί το ποσοστό των σωστών σε όλο το σύνολο, μετριέται χωριστά σε κάθε δραστηριότητα, δηλαδή μετριέται το recall της (Εξίσωση (2.2)). Η $v_t(S)$ γίνεται έτσι διάνυσμα έξι αριθμών. Ο KernelSHAP χρησιμοποιεί τους ίδιους δειγματοληπτούμενους συνασπισμούς για τις έξι συνιστώσες και λύνει μία παλινδρόμηση για καθεμία, οπότε κάθε client παίρνει σε κάθε round έξι τιμές, μία ανά δραστηριότητα. Οι τιμές αθροίζονται στα rounds και οι μέσοι όροι των 20 seeds δίνουν τη μήτρα, όπως ακριβώς και η βαθμωτή τιμή. Η πύλη που αποφασίζει ποια rounds βαθμολογούνται εφαρμόζεται στη σταθμισμένη μεταβολή των έξι συνιστωσών, η οποία ισούται με τη μεταβολή του accuracy, οπότε βαθμολογούνται τα ίδια rounds με το κύριο αποτέλεσμα.

Η αλλαγή στον κώδικα. Η αλλαγή περιορίζεται σε τρεις κλάσεις του φακέλου `contribution/sv/`, στο βήμα 3 του Σχήματος 5.2. Η `CoalitionEvaluator`, που δίνει την αξία ενός συνασπισμού, παίρνει την παράμετρο `metric="per_class"` και επιστρέφει τις έξι τιμές recall στη θέση του accuracy. Η `ClasswiseRoundGame` κληρονομεί την ανασύνθεση των μοντέλων από την `RoundGame` χωρίς καμία αλλαγή και ελέγχει μόνο ότι η αξία έχει έξι συνιστώσες. Η `KernelShapClasswiseEstimator` δίνει στη βιβλιοθήκη `shap` μια συνάρτηση που επιστρέφει πίνακα με μία γραμμή ανά συνασπισμό και μία στήλη ανά δραστηριότητα. Η βιβλιοθήκη λύνει τότε μία παλινδρόμηση ανά στήλη πάνω στους ίδιους συνασπισμούς. Κάθε μοντέλο συνασπισμού αξιολογείται μία φορά και όχι έξι, οπότε το κόστος μένει ουσιαστικά ίδιο με της βαθμωτής τιμής. Το ίδιο κάνει η `GtgClasswiseEstimator` για το GTG-Tib, όπου οι οριακές συνεισφορές αθροίζονται στοιχείο προς στοιχείο. Οι κλάσεις αυτές είναι ξεχωριστές από τις βαθμωτές, ώστε ο υπολογισμός του κύριου αποτελέσματος να μένει αμετάβλητος. Την εκτέλεση οδηγεί το `contribution/contribution_classwise.py`. Με `metric="per_subject"`, ο ίδιος κώδικας δίνει την ανάλυση ανά άτομο της Ενότητας 5.7.3.

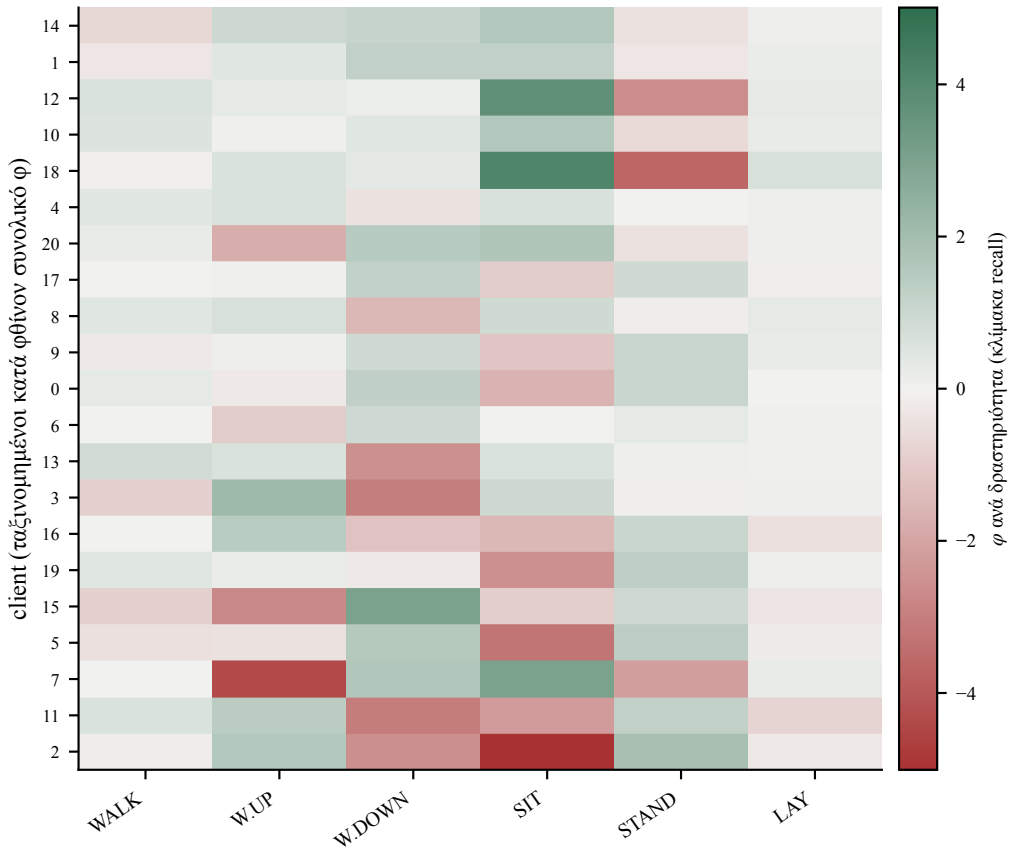
Οι δύο αναλύσεις δένονται με μια ταυτότητα. Το accuracy γράφεται ως σταθμισμένος μέσος των τιμών recall, $\text{Acc} = \sum_c w_c R_c$ με $w_c = n_c/N$ το ποσοστό της κλάσης c στο test

set. Επειδή ο τύπος της Εξίσωσης (2.11) είναι γραμμικός ως προς τη συνάρτηση αξίας, έπεται ότι

$$\varphi_i(\text{Acc}) \;=\; \sum_{c=1}^{6} w_c\, \varphi_i(R_c). \tag{5.4}$$

Η ταυτότητα αυτή *ελέγχθηκε αριθμητικά και δεν υποτέθηκε*. Για τον KernelSHAP, η μέγιστη απόκλιση μεταξύ των δύο πλευρών σε όλους τους 21 clients είναι της τάξης του 10^{-16}, δηλαδή σφάλμα στρογγυλοποίησης. Τα δύο αθροίσματα ταυτίζονται στο $0{,}79729$. Για το GTG-Tib, η απόκλιση είναι μεγαλύτερη, $0{,}025$, επειδή συσσωρεύει δύο ανεξάρτητα σφάλματα δειγματοληψίας, ένα από τον βαθμωτό και ένα από τον ανά κλάση υπολογισμό, ενώ ο KernelSHAP, δεδομένων των συνασπισμών, είναι γραμμικός ως προς τη συνάρτηση αξίας. Ο έλεγχος λειτουργεί ως ανεξάρτητη επαλήθευση και των δύο υλοποιήσεων.

Η μήτρα 21×6 φαίνεται στο Σχήμα 5.10.



Σχήμα 5.10. Η συνεισφορά κάθε client σε κάθε δραστηριότητα, σε μονάδες recall. Οι γραμμές είναι ταξινομημένες κατά φθίνον συνολικό φ. Πράσινο σημαίνει θετική και κόκκινο αρνητική συνεισφορά, όπως στο Σχήμα 5.3.

Το εύρημα είναι ότι οι clients δε βοηθούν ή βλάπτουν συνολικά. Ελάχιστες γραμμές είναι ομοιόμορφα πράσινες ή κόκκινες. Αντιθέτως, σχεδόν κάθε γραμμή έχει και τα δύο χρώματα, δηλαδή ο ίδιος client βελτιώνει κάποιες δραστηριότητες και χειροτερεύει άλλες. Αυτό που μετρά το συνολικό φ είναι το υπόλοιπο.

Ο Πίνακας 5.7 δίνει τη μήτρα σε αριθμούς. Η δομή γίνεται ρητή στις συσχετίσεις μεταξύ στηλών. Τα τρία ζεύγη με την πιο αρνητική συσχέτιση είναι γειτονικές δραστηριότητες. Στο ζεύγος SITTING και STANDING, όποιος βελτιώνει τη μία χειροτερεύει σχεδόν ακριβώς ανάλογα την άλλη ($r = -0{,}933$). Πρόκειται, δηλαδή, για *μετακίνηση συνόρου απόφασης* μεταξύ δύο γειτονικών κλάσεων και όχι για γενική βελτίωση ή βλάβη.

Ζεύγος στηλών	r
SIT, STAND	$-0{,}933$
STAND, LAY	$-0{,}733$
W.UP, W.DOWN	$-0{,}724$
WALK, W.DOWN	$-0{,}317$

		Στο συνολικό φ	
Δραστηριότητα	Τ.α.	9 αρνητικοί	12 θετικοί
WALK	0,48	$-0{,}09$	$+0{,}23$
W.UP	1,49	$-0{,}02$	$+0{,}13$
W.DOWN	1,72	$-0{,}90$	$+1{,}01$
SIT	2,31	$-1{,}81$	$+1{,}95$
STAND	1,39	$+1{,}02$	$-0{,}87$
LAY	0,31	$-0{,}26$	$+0{,}41$
Σύνολο		$-2{,}06$	$+2{,}86$

Πίνακας 5.7. Η μήτρα του Σχήματος 5.10 σε αριθμούς, με τα ονόματα του σχήματος. Αριστερά, οι τέσσερις πιο αρνητικές συσχετίσεις Pearson μεταξύ των στηλών της, πάνω στους 21 clients. Δεξιά, η τυπική απόκλιση (τ.α.) κάθε στήλης στους 21 clients, σε μονάδες recall. Οι δύο τελευταίες στήλες δίνουν το άθροισμα της στήλης για τις δύο ομάδες clients, σταθμισμένο όπως στην Εξίσωση (5.4), ώστε το σύνολο να είναι το άθροισμα των φ κάθε ομάδας.

Η τυπική απόκλιση ανά δραστηριότητα το επιβεβαιώνει από άλλη οπτική. Οι clients συμφωνούν σχεδόν απόλυτα στην κατάκλιση και στο βάδισμα, ενώ διαφωνούν έντονα στα δύο κλασικά ζεύγη σύγχυσης.

Η ίδια μήτρα δείχνει και από πού προέρχεται η αρνητική τιμή των εννέα. Με τη στάθμιση της Εξίσωσης (5.4), το άθροισμά τους, $-2{,}06$ μονάδες, προέρχεται κυρίως από την καθιστή στάση και την κατάβαση σκάλας, ενώ στην όρθια στάση είναι θετικό. Οι δώδεκα θετικοί κάνουν το αντίστροφο. Οι δύο ομάδες επηρεάζουν, δηλαδή, τις ίδιες δραστηριότητες σε αντίθετες κατευθύνσεις. Με το update των εννέα, το μοντέλο αναγνωρίζει καλύτερα την όρθια στάση αλλά χειρότερα την καθιστή. Η απώλεια είναι μεγαλύτερη από το κέρδος.

Αυτό κλείνει έναν κύκλο που άνοιξε στο Κεφάλαιο 3. Οι δημιουργοί του συνόλου δεδομένων κατέγραψαν το 2013 τη σύγχυση SITTING και STANDING και την απέδωσαν στη φυσική θέση της συσκευής, προτείνοντας ως μελλοντική εργασία την αξιοποίηση features του γυροσκοπίου [1]. Η Ενότητα 4.7 επιβεβαίωσε ότι το ίδιο ζεύγος παράγει το $49{,}1\%$ των σφαλμάτων του μοντέλου. Επιπλέον, η ανάλυση Shapley δείχνει ότι εκεί ακριβώς διαφωνούν περισσότερο οι clients. Δύο αναλύσεις της εργασίας, με διαφορετική μεθοδολογία, συγκλίνουν, λοιπόν, στο ίδιο σύνορο με τους δημιουργούς του συνόλου. Η δυσκολία ήταν ήδη

γνωστή και η συνεισφορά της εργασίας αυτής δεν είναι η ανακάλυψή της αλλά η απάντηση στο *ποιος* την επιδεινώνει.

Οι δύο εκτιμητές συμφωνούν και σε αυτή τη μήτρα, με συντελεστή Pearson $1{,}0000$ πάνω στα 126 κελιά και μέγιστη απόλυτη διαφορά $0{,}060$.

5.7.3 Η αρνητική τιμή ανά άτομο της αξιολόγησης

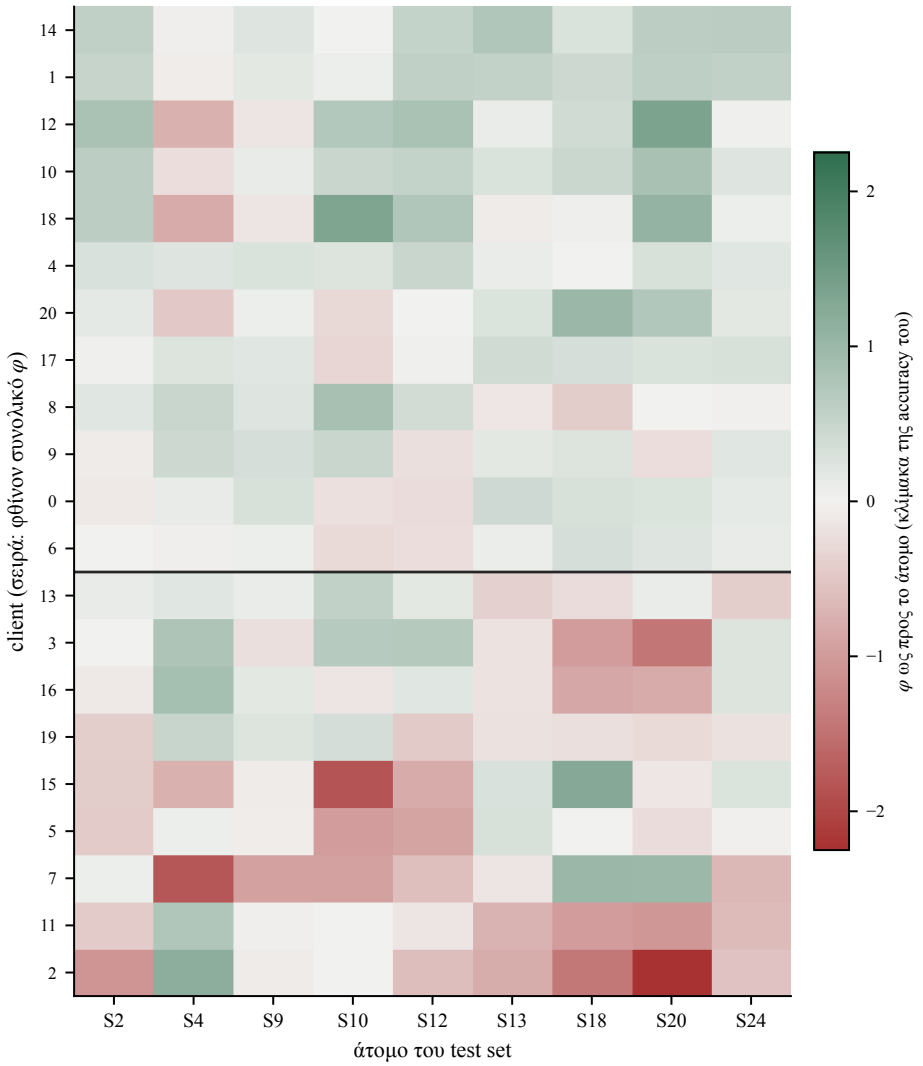
Η ίδια ανάλυση επαναλαμβάνεται με διαφορετική αποσύνθεση. Αντί να χωριστεί το accuracy κατά δραστηριότητα, χωρίζεται κατά *άτομο* του test set. Η συνάρτηση αξίας επιστρέφει τότε εννέα αριθμούς, το accuracy του μοντέλου του συνασπισμού πάνω στα samples καθενός από τους εννέα ανθρώπους της αξιολόγησης χωριστά. Το παίγνιο επιλύεται χωριστά για κάθε συνιστώσα. Το αποτέλεσμα είναι μήτρα 21×9 (Σχήμα 5.11). Η μεθοδολογία είναι ταυτόσημη με εκείνη της προηγούμενης υποενότητας, όπως και η ταυτότητα που συνδέει τα μέρη με το σύνολο. Το φ του συνολικού accuracy ισούται με τον σταθμισμένο κατά πλήθος samples μέσο όρο των φ ανά άτομο, με απόκλιση της τάξης του 10^{-16}. Σε κάθε round ελέγχεται, επίσης, ότι ο ίδιος σταθμισμένος μέσος των εννέα τιμών της συνάρτησης αξίας δίνει το accuracy του πλήρους συνασπισμού, με ανοχή 10^{-12}. Τα εννέα άτομα σημειώνονται $S2$ έως $S24$, κατά το αναγνωριστικό τους στην πηγή.

Τρία πορίσματα προκύπτουν. Το καθένα περιορίζει μια πιθανή παρανόηση του προηγούμενου ευρήματος. Το Σχήμα 5.11 τα παρουσιάζει και τα τρία.

Κανείς δε βλάπτει τους πάντες. Κανένας από τους εννέα clients με αρνητική συνολική τιμή δεν είναι αρνητικός και για τα εννέα άτομα της αξιολόγησης. Ο client 2, ο χειρότερος της συνολικής κατάταξης, είναι αρνητικός για επτά από τα εννέα άτομα και *βοηθά* δύο, με $+1{,}146$ για ένα από αυτά. Η αρνητική τιμή δεν είναι ιδιότητα του client απέναντι στον κόσμο αλλά απέναντι σε συγκεκριμένους ανθρώπους.

Η βλάβη είναι στοχευμένη. Ένα μόνο άτομο, το $S20$, απορροφά το $27{,}3\%$ της αρνητικής συνεισφοράς των εννέα clients, μετρημένης στο accuracy όλου του test set, ενώ συνεισφέρει μόλις το $12{,}0\%$ των samples. Δεν πρόκειται για υποβάθμιση μοιρασμένη ομοιόμορφα σε όλους αλλά για συγκεκριμένη αναντιστοιχία ανάμεσα σε συγκεκριμένους ανθρώπους.

Τα άτομα δεν είναι εναλλάξιμα. Η τυπική απόκλιση των 21 τιμών φ διαφέρει κατά παράγοντα $3{,}2$ ανάμεσα στα άτομα της αξιολόγησης, από $0{,}870$ για το πιο «απαιτητικό» έως $0{,}275$ για το πιο ουδέτερο. Απέναντι σε κάποια άτομα, οι clients ξεχωρίζουν έντονα μεταξύ τους, ενώ απέναντι σε άλλα σχεδόν καθόλου.



Σχήμα 5.11. Η μήτρα 21×9 με τη συνεισφορά κάθε client προς κάθε άτομο του test set, εκτιμητής KernelSHAP, μέσοι όροι 20 seeds. Οι clients είναι ταξινομημένοι κατά φθίνον *συνολικό* φ, όπως στο Σχήμα 5.3. Η οριζόντια γραμμή χωρίζει τους 12 θετικούς από τους 9 αρνητικούς. Πράσινο σημαίνει θετική και κόκκινο αρνητική συνεισφορά, όπως στα Σχήματα 5.3 και 5.10. Καμία γραμμή κάτω από τη γραμμή διαχωρισμού δεν είναι ολόκληρη κόκκινη.

Οι μονάδες της μήτρας. Οι τιμές αυτής της μήτρας είναι μέσοι όροι 20 seeds. Σε κάθε seed, είναι αθροίσματα 51 έως 74 rounds (65 κατά μέσο όρο) σε μονάδες accuracy *του κάθε ατόμου*, με αντισταθμίσεις θετικών και αρνητικών rounds. Γι' αυτό μπορούν να ξεπερνούν τη μονάδα. Δε διαβάζονται ως ποσοστιαίες μονάδες που έχασε ή κέρδισε ένα άτομο στο τελικό μοντέλο.

Αφού το ποιος βγαίνει αρνητικός εξαρτάται και από το ποια άτομα βρίσκονται στο test set, ένας έλεγχος που αποφασίζει και μετρά στους *ίδιους* ανθρώπους δεν μπορεί να κρίνει τι θα γινόταν με άλλους. Γι' αυτό ο έλεγχος της επόμενης υποενότητας κρατά ανθρώπους έξω από την απόφαση.

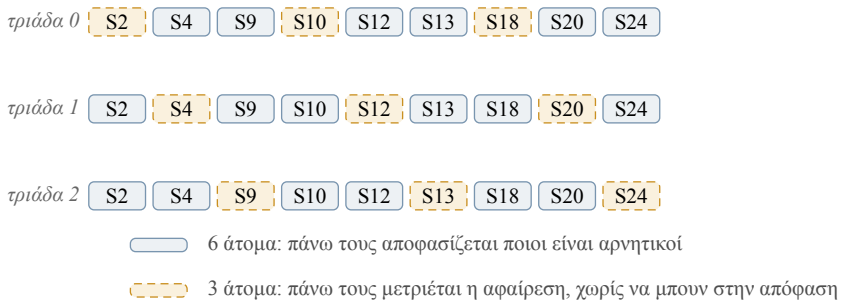
5.7.4 Το πείραμα αφαίρεσης

Αν οι εννέα clients με αρνητική τιμή βλάπτουν πράγματι το global model, η φυσική αντίδραση είναι να αφαιρεθούν από την ομοσπονδία. Η υποενότητα ελέγχει αν αυτό θα βελτίωνε το μοντέλο. Από την απάντηση εξαρτάται και τι γίνεται με αυτούς στη συνέχεια. Αν η αφαίρεση βοηθά, το πρόσημο του φ μπορεί να χρησιμοποιηθεί ως κριτήριο αποκλεισμού. Αν δε βοηθά, οι εννέα μένουν. Τότε το ερώτημα γίνεται πώς αποτιμάται σωστά και η δική τους συνεισφορά.

Ο προφανής έλεγχος είναι να αφαιρεθούν οι εννέα, να ξαναεκπαιδευτεί η ομοσπονδία με τους υπόλοιπους δώδεκα και να μετρηθεί το accuracy στο test set. Το αποτέλεσμά του, όμως, είναι σε μεγάλο βαθμό αναμενόμενο. Οι εννέα χαρακτηρίστηκαν αρνητικοί ακριβώς επειδή τα updates τους υπονόμευαν το accuracy στα εννέα άτομα του test set, οπότε η αφαίρεσή τους αναμένεται να το βελτιώσει στα ίδια άτομα. Ο έλεγχος θα έκρινε την απόφαση με τα ίδια δεδομένα με τα οποία πάρθηκε, δηλαδή θα ήταν *κυκλικός*. Δε θα έλεγε τίποτα για το αν η αφαίρεση βοηθά έναν νέο άνθρωπο, το οποίο είναι και το ζητούμενο στην πράξη. Το ζήτημα εμφανίζεται και στη βιβλιογραφία της αποτίμησης δεδομένων. Πρόσφατη μελέτη αξιολογεί την επιλογή δεδομένων στο ίδιο validation set με το οποίο υπολογίστηκαν οι τιμές, δηλώνοντας ότι το κάνει για να ευθυγραμμιστεί με τη θεωρητική της ανάλυση [26]. Επιπλέον, η αξία του Data Shapley ορίζεται μέσα από μια συνάρτηση που περιλαμβάνει τη μετρική αξιολόγησης [23], οπότε ορίζεται *ως προς* το σύνολο πάνω στο οποίο μετρήθηκε.

Για να αποφευχθεί η κυκλικότητα, το test set μοιράζεται σε δύο ρόλους (Σχήμα 5.12). Τα εννέα άτομα χωρίζονται σε τρεις τριάδες. Για κάθε τριάδα, η αποτίμηση γίνεται με *μόνο* τα έξι υπόλοιπα άτομα. Δε χρειάζεται νέα εκτίμηση, γιατί, λόγω της ταυτότητας της Ενότητας 5.7.3, η τιμή κάθε client ως προς το accuracy στα έξι άτομα είναι ο σταθμισμένος κατά πλήθος samples μέσος όρος των έξι αντίστοιχων στηλών της μήτρας 21×9 (Σχήμα 5.11). Έτσι, προκύπτει ένα νέο σύνολο αρνητικών clients για κάθε τριάδα. Αυτοί αφαιρούνται, η ομοσπονδία ξαναεκπαιδεύεται και το accuracy μετριέται χωριστά στα έξι άτομα της απόφα-

σης και στα τρία της τριάδας. Η συνεισφορά των clients στο accuracy των τριών δεν μπαίνει ούτε στην αποτίμηση ούτε στην επιλογή των clients που αφαιρούνται, οπότε τα τρία παίζουν τον ρόλο νέων ανθρώπων. Τα τρία επηρεάζουν μόνο την επιλογή των scored rounds, αφού η αποκοπή μεταξύ rounds (Ενότητα 5.2.2) κρίνεται από τη συνολική μεταβολή του accuracy σε όλο το test set και όχι από τις τιμές των clients. Οι τιμές της μήτρας είναι μέσοι όροι όλων των seeds, οπότε οι αρνητικοί clients κάθε τριάδας είναι οι ίδιοι σε κάθε seed. Η επανεκπαίδευση και η μέτρηση γίνονται για τις τρεις τριάδες και για 20 seeds.



Σχήμα 5.12. Τα εννέα άτομα του test set, σε τρεις διαφορετικούς χωρισμούς. Σε κάθε τριάδα, οι αρνητικοί clients κρίνονται μόνο από τη συνεισφορά τους στα έξι άτομα με συνεχές περίγραμμα. Η επίπτωση της αφαίρεσης μετριέται στα τρία με διακεκομμένο πορτοκαλί περίγραμμα, τα οποία μένουν έξω από την απόφαση.

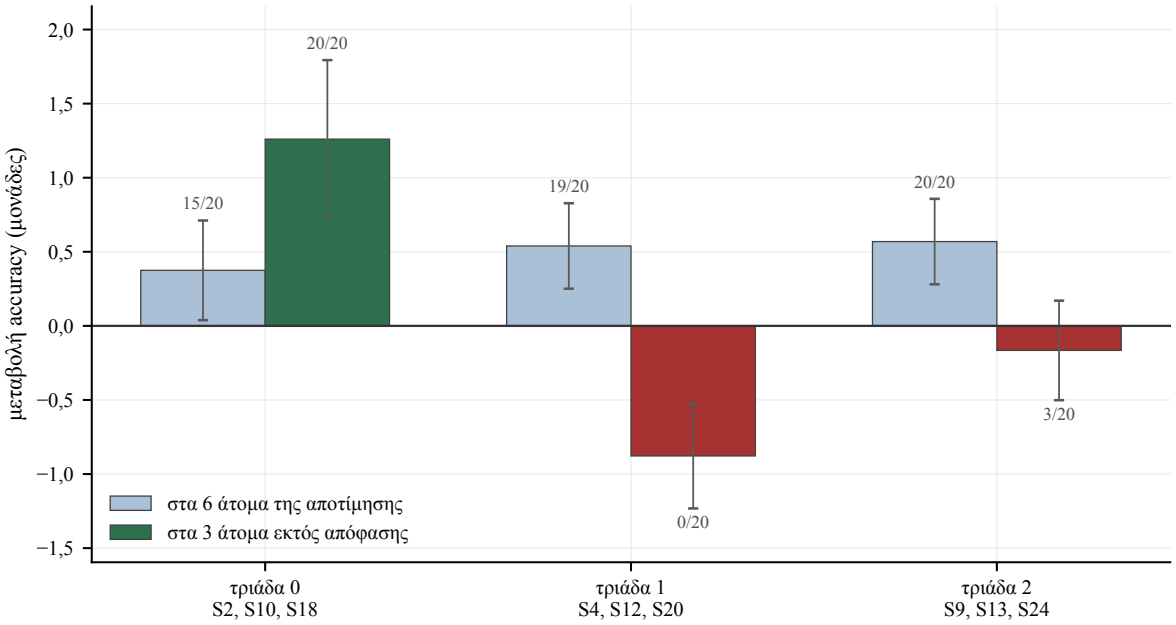
Γίνονται δύο είδη αφαίρεσης σε κάθε τριάδα, με μέτρηση στα τρία άτομα που έμειναν έξω. Το πρώτο αφαιρεί μαζί όλους τους αρνητικούς της τριάδας και ελέγχει αν το μοντέλο βελτιώνεται. Το δεύτερο ελέγχει αν η *σειρά* της κατάταξης δείχνει ποιους θα έπρεπε να αφαιρέσει κανείς πρώτους. Αφαιρεί τους m χειρότερους ή τους m καλύτερους της κατάταξης που προέκυψε από τα έξι άτομα, για $m = 3$, 6, 9 και 12. Στη συνέχεια συγκρίνει τα δύο.

Δύο στοιχεία του σχεδιασμού προστατεύουν τη μέτρηση. Κάθε αφαίρεση των αρνητικών συγκρίνεται με *τυχαία* αφαίρεση ίδιου πλήθους clients, ώστε να φανεί αν έχει σημασία *ποιοι* αφαιρούνται ή μόνο *πόσα* δεδομένα χάνονται. Επιπλέον, η εκτέλεση χωρίς καμία αφαίρεση αναπαράγει το αποθηκευμένο ομοσπονδιακό αποτέλεσμα σε 20 από τα 20 seeds, οπότε οι διαφορές που μετρώνται δεν οφείλονται σε αλλαγή του κώδικα.

Με έξι μόνο άτομα, βρίσκονται σχεδόν οι ίδιοι αρνητικοί clients. Ο δείκτης Jaccard (το πλήθος των κοινών μελών δύο συνόλων προς το πλήθος της ένωσής τους) ανάμεσα στο σύνολο που προκύπτει από τα έξι άτομα και σε εκείνο των εννέα είναι $0{,}89$, $1{,}00$ και $0{,}89$ για τις τρεις τριάδες. Επομένως, η ταυτοποίηση δεν αλλάζει ουσιαστικά και το μόνο ανοιχτό ερώτημα είναι αν η αφαίρεση βοηθά.

5.7.5 Αποτελέσματα της αφαίρεσης

Ο Πίνακας 5.8 και το Σχήμα 5.13 δίνουν τη μεταβολή του accuracy του τελικού μοντέλου, όταν αφαιρούνται οι αρνητικοί, χωριστά στα έξι άτομα της απόφασης και στα τρία νέα. Οι τιμές είναι ποσοστιαίες μονάδες, όπως στο Κεφάλαιο 4.



Σχήμα 5.13. Η επίδραση της αφαίρεσης, μέσος όρος 20 seeds, με τυπική απόκλιση μεταξύ seeds. Οι ανοιχτές γαλάζιες στήλες μετρούν στα έξι άτομα με τα οποία έγινε η αποτίμηση και είναι θετικές και στις τρεις τριάδες. Οι έγχρωμες μετρούν στα τρία άτομα που κρατήθηκαν έξω από την απόφαση και αλλάζουν πρόσημο, πράσινες όπου η αφαίρεση βοηθά και κόκκινες όπου βλάπτει. Στην άκρη κάθε στήλης, το πλήθος των seeds με θετικό πρόσημο.

Τριάδα	Στα 6 άτομα της αποτίμησης	Στα 3 άτομα εκτός απόφασης
0	$+0{,}37$ (15/20)	$+\mathbf{1{,}26}$ (20/20)
1	$+0{,}54$ (19/20)	$-\mathbf{0{,}88}$ (0/20)
2	$+0{,}57$ (20/20)	$-\mathbf{0{,}17}$ (3/20)

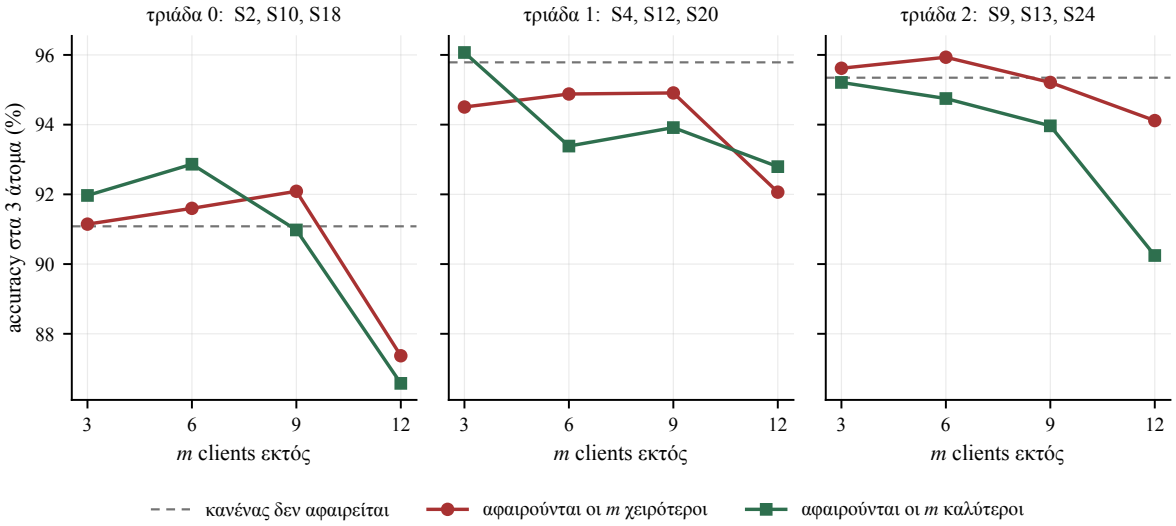
Πίνακας 5.8. Μεταβολή accuracy σε μονάδες, μέσος όρος 20 seeds. Σε παρένθεση το πλήθος των seeds με θετικό πρόσημο.

Στα έξι άτομα της απόφασης, η αφαίρεση βοηθά και στις τρεις τριάδες, όπως αναμενόταν. Στα τρία νέα άτομα, βοηθά μόνο στην τριάδα 0, κατά $1{,}26$ μονάδες. Στις άλλες δύο βλάπτει, κατά $0{,}88$ και $0{,}17$ μονάδες. Στην τριάδα 1, βλάπτει σε *όλα* τα 20 seeds. Ως εκ τούτου, το όφελος που φαίνεται στους ανθρώπους της απόφασης δε μεταφέρεται με συνέπεια σε νέους ανθρώπους.

Αυτό δε σημαίνει ότι η κατάταξη δεν περιέχει καμία πληροφορία. Στα τρία νέα άτομα, η αφαίρεση των αρνητικών είναι καλύτερη από την τυχαία αφαίρεση ίδιου πλήθους και στις

τρεις τριάδες, κατά 2,58, 0,62 και 0,63 μονάδες. Η διαφορά, όμως, είναι ασθενής, αφού το πρόσημό της διατηρείται μόνο σε 13 έως 16 από τα 20 seeds, με τυπική απόκλιση 1,2 έως 2,2 μονάδες.

Η σειρά της κατάταξης δίνει μικτή εικόνα. Αυτό μετρά το δεύτερο είδος αφαίρεσης (Σχήμα 5.14). Αν η κατάταξη ήταν αξιόπιστο κριτήριο, η αφαίρεση των m χειρότερων θα βοηθούσε τα τρία νέα άτομα περισσότερο από την αφαίρεση των m καλύτερων, σε κάθε τριάδα και για κάθε m. Αυτό ισχύει μόνο στην τριάδα 2. Στις άλλες δύο, η αφαίρεση των τριών *καλύτερων* δίνει καλύτερο accuracy από την αφαίρεση των τριών χειρότερων. Για $m = 6$ και $m = 9$, αντίθετα, η αφαίρεση των χειρότερων είναι η καλύτερη από τις δύο σε πέντε από τις έξι περιπτώσεις. Οι καμπύλες της αφαίρεσης των χειρότερων μένουν κοντά στο accuracy χωρίς αφαίρεση μέχρι το $m = 9$ και πέφτουν στο $m = 12$, ενώ η αφαίρεση των καλύτερων κοστίζει νωρίτερα στις τριάδες 1 και 2. Η κατάταξη, δηλαδή, ξεχωρίζει ποιοι στηρίζουν το μοντέλο, χωρίς να δείχνει με συνέπεια ποιους συμφέρει να αφαιρέσει κανείς.



Σχήμα 5.14. Accuracy στα τρία άτομα που κρατήθηκαν έξω από την απόφαση, όταν αφαιρούνται οι m χειρότεροι ή οι m καλύτεροι clients. Η διακεκομμένη γραμμή είναι το accuracy χωρίς καμία αφαίρεση. Όπου η πράσινη καμπύλη βρίσκεται πάνω από την κόκκινη, η αφαίρεση των καλύτερων ωφέλησε περισσότερο από την αφαίρεση των χειρότερων.

Δύο ακόμη παρατηρήσεις εξηγούν γιατί η εικόνα διαφέρει τόσο από τις τιμές φ. Πρώτον, η ομοσπονδία αντέχει την απώλεια πολλών clients. Η αφαίρεση οκτώ έως εννέα από τους 21, που κρατούν το 36% έως 42% των samples του training set, κοστίζει το πολύ 0,88 μονάδες στα νέα άτομα. Δεύτερον, το άτομο $S20$, που απορροφούσε το 27,3% της αρνητικής συνεισφοράς των εννέα clients ανά round (Ενότητα 5.7.3), ανήκει στα τρία νέα άτομα της τριάδας 1, ακριβώς εκείνης όπου η αφαίρεση βλάπτει σε 20 από τα 20 seeds. Επομένως, η βλάβη που αθροίζεται round με round στο φ δε μεταφράζεται απαραίτητα σε βλάβη στο τελικό μοντέλο.

5.7.6 Συμπέρασμα

Στην περίπτωση της παρούσας εργασίας, **η αφαίρεση των clients με αρνητική τιμή δεν έχει νόημα**. Οι αρνητικοί ταυτοποιούνται σταθερά, αφού βρίσκονται σχεδόν οι ίδιοι clients με διαφορετικά υποσύνολα του test set και στα 20 seeds του κύριου αποτελέσματος (Ενότητα 5.3.2). Η αφαίρεσή τους, όμως, βελτιώνει το μοντέλο μόνο για τους ανθρώπους με τους οποίους έγινε η αποτίμηση, ενώ για νέους ανθρώπους το χειροτερεύει σε δύο από τις τρεις τριάδες.

Το πόρισμα συμφωνεί με όσα ανέδειξαν το δεύτερο παίγνιο και η αποσύνθεση. Το παίγνιο επανεκπαίδευσης του κεντρικού μοντέλου (Ενότητα 5.6) δε βρήκε ένδειξη ότι τα δεδομένα κάποιου client βλάπτουν. Η αποσύνθεση κατέδειξε ότι η αρνητική τιμή της ομάδας εμφανίζεται μόνο αφού το μοντέλο ξεπεράσει το 90%, σε συγκεκριμένα ζεύγη δραστηριοτήτων και απέναντι σε συγκεκριμένα άτομα της αξιολόγησης. Αρνητικό φ, επομένως, δε σημαίνει «κακά δεδομένα». Σημαίνει ότι το update αυτού του ανθρώπου δεν ταιριάζει με το συγκεκριμένο test set, σε αυτή τη φάση της εκπαίδευσης. Η βιβλιογραφία της αποτίμησης δεδομένων καταλήγει σε συγγενές συμπέρασμα, αφού δείχνει ότι, χωρίς πρόσθετες συνθήκες στη συνάρτηση αξίας, το Data Shapley δεν εγγυάται επιλογή καλύτερη από την τυχαία. Καταγράφει, επίσης, ότι τα εμπειρικά ευρήματα του πεδίου είναι αντιφατικά [26]. Η μέτρηση της εργασίας δείχνει, επιπλέον, γιατί η επιλογή φαίνεται να πετυχαίνει, όταν ελέγχεται στο ίδιο σύνολο με την αποτίμηση.

Επομένως, οι εννέα clients μένουν στην ομοσπονδία. Το ερώτημα που τίθεται δεν είναι ποιος πρέπει να αποκλειστεί αλλά πώς μεταφράζεται η μετρημένη συνεισφορά *όλων*, ακόμη και των εννέα, σε μερίδια που σέβονται τη σειρά που μετρήθηκε, χωρίς να τιμωρούν το πρόσημο. Αυτό εξετάζει η επόμενη ενότητα.

5.8 Μερίδια Ανταμοιβής

5.8.1 Πολιτικές μεριδίων

Αφού οι εννέα clients με αρνητική τιμή μένουν στην ομοσπονδία (Ενότητα 5.7.6), η συνεισφορά όλων πρέπει να μεταφραστεί σε μερίδια, για παράδειγμα μιας ανταμοιβής. Οι αρνητικές τιμές δημιουργούν εδώ άμεσο πρόβλημα, γιατί ένα αρνητικό μερίδιο δεν έχει νόημα. Εξετάστηκαν τέσσερις πολιτικές μετατροπής του φ σε μερίδια που αθροίζουν στη μονάδα (Πίνακας 5.9). Το σύνολο των τεσσάρων είναι κατασκευή της εργασίας. Δύο από αυτές, η αφινική μετατόπιση και η εκθετική κατανομή, έχουν βιβλιογραφική στήριξη και προτείνονται, ενώ οι άλλες δύο δηλώνονται ως βάσεις σύγκρισης.

Η «δικαιοσύνη» δεν ορίζεται εδώ, οπότε το κριτήριο επιλογής δεν είναι αυτή αλλά δύο μετρήσιμα μεγέθη. Το πρώτο είναι *πόση πληροφορία κατάταξης διατηρεί η πολιτική*. Μετριέται με το Kendall τ μεταξύ του φ και των τελικών μεριδίων. Τιμή $1{,}000$ σημαίνει ότι η πολιτική δεν αντέστρεψε ούτε εξίσωσε κανένα ζεύγος. Το δεύτερο είναι *πόσοι clients μένουν χωρίς θετικό μερίδιο*, αφού το πόρισμα της Ενότητας 5.7.6 είναι ότι όλοι παραμένουν στην ομοσπονδία.

Πολιτική	**Ρόλος**	**Χωρίς μερίδιο**	**Μερίδιο των 9 αρνητικών**	τ
raw ($\varphi / \sum \varphi$)	βάση σύγκρισης	9	$-258{,}98\%$	$1{,}000$
zero_clip	βάση σύγκρισης	9	$0{,}00\%$	$0{,}829$
affine [28]	**πρόταση**	1	$26{,}54\%$	$1{,}000$
exponential [42]	**πρόταση**	0	$27{,}51\%$	$1{,}000$

Πίνακας 5.9. Τέσσερις πολιτικές μετατροπής της συνεισφοράς σε μερίδια. Η στήλη «Χωρίς μερίδιο» μετρά πόσοι από τους 21 παίρνουν μηδενικό ή αρνητικό μερίδιο. Το τ δείχνει πόση πληροφορία κατάταξης διατηρείται. Η εκθετική με $\beta = 1$.

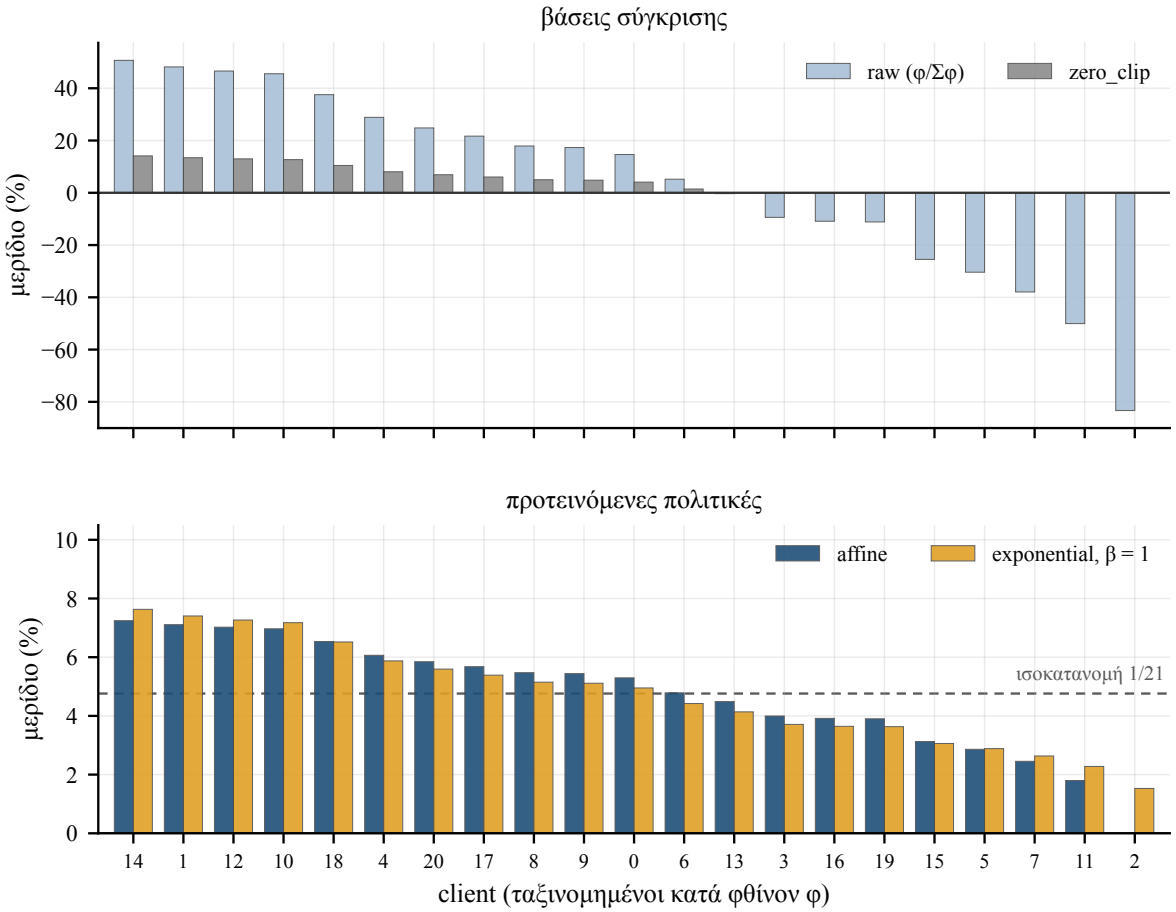
Η `raw` δείχνει γιατί χρειάζεται οποιαδήποτε παρέμβαση, αφού τα μερίδια των εννέα αρνητικών αθροίζουν σε -259%, αριθμός χωρίς ερμηνεία. Η `zero_clip`, δηλαδή ο απλός μηδενισμός των αρνητικών, είναι η πιο προφανής λύση αλλά και η χειρότερη. Το τ πέφτει στο $0{,}829$, γιατί και οι εννέα αρνητικοί γίνονται *αδιάκριτοι* μεταξύ τους, οπότε τα 36 ζεύγη τους δε μετρούν ούτε ως σύμφωνα ούτε ως ασύμφωνα. Ο client 2, με $\varphi = -0{,}664$ και σταθερό πρόσημο σε $94{,}2\%$ των rounds, εξισώνεται με τον client 13, του οποίου η τιμή $-0{,}0025$ βρίσκεται μέσα στον θόρυβο. Η πολιτική απορρίπτει ακριβώς την πληροφορία που το κεφάλαιο μέτρησε με τόσο κόστος.

5.8.2 Αφινική μετατόπιση και εκθετική κατανομή

Η πρώτη προτεινόμενη πολιτική είναι η αφινική μετατόπιση (`affine`), δανεισμένη από το ShapFed [28]. Η ιδέα είναι να μετατοπιστεί ολόκληρο το φάσμα των τιμών σε μη αρνητικό διάστημα, *πριν* από την κανονικοποίηση, αντί να αποκοπεί:

$$\gamma_i = \frac{1 + \tilde{\varphi}_i}{2}, \qquad \bar{\gamma}_i = \frac{\gamma_i}{\sum_k \gamma_k}, \tag{5.5}$$

όπου $\tilde{\varphi}_i$ η κλιμακωμένη στο $[-1, 1]$ τιμή. Ο μετασχηματισμός $(1 + x)/2$ στέλνει το $[-1, 1]$ στο $[0, 1]$, διατηρώντας τη διάταξη, αφού είναι γνησίως αύξων. Η διαίρεση με το άθροισμα εξασφαλίζει $\sum_i \bar{\gamma}_i = 1$. Το αποτέλεσμα φαίνεται στο Σχήμα 5.15.



Σχήμα 5.15. Τα μερίδια κάθε client υπό τις τέσσερις πολιτικές, με τη σειρά του Σχήματος 5.3. Πάνω οι δύο βάσεις σύγκρισης και κάτω οι δύο προτεινόμενες πολιτικές, η καθεμία στη δική της κλίμακα, με τη διακεκομμένη γραμμή της ισοκατανομής. Η `raw` παράγει αρνητικά μερίδια, η `zero_clip` μηδενίζει εννέα clients, η αφινική [28] μόνο τον πιο ακραίο και η εκθετική [42] δίνει θετικό μερίδιο σε όλους.

Κλιμάκωση του φ πριν από τη μετατόπιση. Στην πρωτότυπη διατύπωση, το μέγεθος που μετατοπίζεται είναι συνημίτονο, φραγμένο εξ ορισμού στο $[-1, 1]$. Εδώ, το φ είναι διαφορά accuracy με εύρος από $-0{,}664$ έως $+0{,}404$, οπότε απαιτείται κλιμάκωση πρώτα. Εδώ χρησιμοποιείται η $\tilde{\varphi}_i = \varphi_i / \max_k |\varphi_k|$. Δοκιμάστηκε και η γραμμική απεικόνιση του εύρους $[\min_k \varphi_k, \max_k \varphi_k]$ στο $[-1, 1]$. Οι δύο δίνουν *ταυτόσημα* μερίδια στα δεδομένα της εργασίας. Αυτό δεν είναι σύμπτωση αλλά ταυτότητα, γιατί, μετά την κανονικοποίηση $\sum \bar{\gamma} = 1$, μόνο το σημείο μηδενισμού της κλίμακας επηρεάζει το αποτέλεσμα. Οι δύο κλιμακώσεις συμπίπτουν, όταν ο πιο ακραίος client είναι αρνητικός, όπως στην προκειμένη περίπτωση.

Η αφινική πολιτική δίνει στους εννέα αρνητικούς συνολικό μερίδιο $26{,}54\%$, δηλαδή λιγότερο από το $9/21 = 42{,}9\%$ που θα τους αναλογούσε με ισοκατανομή αλλά όχι μηδέν. Διατηρεί $\tau = 1{,}000$, δηλαδή καμία σχετική θέση δεν αλλάζει. Έχει, όμως, μία παρενέργεια. Η κλιμάκωση στέλνει την πιο ακραία τιμή στο -1 και η μετατόπιση $(1 + x)/2$ στέλνει το -1 στο μηδέν. Όταν ο πιο ακραίος client είναι αρνητικός, όπως ο client 2 εδώ, μένει χωρίς μερίδιο, όχι επειδή το αποφάσισε η πολιτική αλλά λόγω της κλιμάκωσης.

Εκθετική κατανομή. Η δεύτερη προτεινόμενη πολιτική (`exponential`) δίνει σε κάθε client μερίδιο ανάλογο του εκθετικού της κλιμακωμένης συνεισφοράς του:

$$\bar{\gamma}_i = \frac{e^{\beta \tilde{\varphi}_i}}{\sum_k e^{\beta \tilde{\varphi}_k}}, \tag{5.6}$$

όπου $\tilde{\varphi}_i$ η ίδια κλιμακωμένη τιμή με την αφινική και $\beta \geq 0$ μια παράμετρος που ορίζει πόσο έντονα ανταμείβεται η υψηλότερη συνεισφορά. Η μορφή δεν είναι αυθαίρετη. Όταν για μια κατανομή είναι γνωστές μόνο κάποιες μέσες τιμές, η κατανομή μέγιστης εντροπίας έχει ακριβώς εκθετική μορφή. Ο Jaynes τη χαρακτηρίζει ως τη μόνη αμερόληπτη επιλογή, αφού οποιαδήποτε άλλη θα προϋπέθετε πληροφορία που δεν υπάρχει [42]. Σημειώνει, επίσης, ότι η κατανομή αυτή δίνει θετικό βάρος σε κάθε περίπτωση που δεν αποκλείεται ρητά από τη διαθέσιμη πληροφορία. Αυτό σημαίνει ότι κανείς δε μένει χωρίς μερίδιο, αφού η εκθετική συνάρτηση είναι πάντα θετική.

Το β έχει άμεση ανάγνωση. Με $\beta = 1$, ο λόγος των μεριδίων στα δύο άκρα της κλίμακας, $\tilde{\varphi} = -1$ και $\tilde{\varphi} = +1$, είναι $e^2 \approx 7{,}39$. Στα δεδομένα της εργασίας, ο καλύτερος client παίρνει $5{,}0$ φορές το μερίδιο του χειρότερου, ενώ οι εννέα αρνητικοί παίρνουν συνολικά $27{,}51\%$. Το τ μένει $1{,}000$. Το β αλλάζει μόνο την ένταση της ανταμοιβής και ποτέ τη σειρά. Με $\beta = 0{,}5$, οι εννέα αρνητικοί παίρνουν $34{,}67\%$ και με $\beta = 2$ παίρνουν $16{,}55\%$, με $\tau = 1{,}000$ σε κάθε περίπτωση. Στο όριο $\beta \to 0$, η κατανομή γίνεται ισοκατανομή, ενώ για πολύ μεγάλο β ο καλύτερος παίρνει σχεδόν τα πάντα.

Η ποινή με βάση το πρόσημο απορρίπτεται. Οι δύο προτεινόμενες πολιτικές θα μπορούσαν να διαβαστούν ως απλή προτίμηση, με το σκεπτικό ότι είναι άβολο να δίνεται μηδενικό μερίδιο σε clients που συμμετείχαν. Ο λόγος, όμως, είναι μετρημένος. Μια πολιτική που μηδενίζει ή τιμωρεί με κριτήριο το *πρόσημο* του φ υποθέτει ότι το αρνητικό πρόσημο δείχνει συνεισφορά που βλάπτει. Η Ενότητα 5.7.4 κατέδειξε ότι αυτό δεν ισχύει για νέους ανθρώπους, αφού σε δύο από τις τρεις τριάδες η αφαίρεση των αρνητικών *χειροτέρευσε* το μοντέλο για τα άτομα που έμειναν έξω από την απόφαση. Επομένως, μια ποινή με βάση το πρόσημο θα τιμωρούσε, δύο φορές στις τρεις, συνεισφορά που ωφελεί άτομα του test set τα οποία έμειναν έξω από την απόφαση. Καμία από τις δύο προτεινόμενες πολιτικές δε χρησιμοποιεί το πρόσημο ως όριο. Αντιθέτως, και οι δύο κρατούν ολόκληρη τη σειρά που μετρήθηκε.

Σύγκριση των δύο. Η αφινική και η εκθετική διατηρούν τη σειρά του φ και δίνουν στους εννέα αρνητικούς σχεδόν το ίδιο συνολικό μερίδιο, $26{,}54\%$ και $27{,}51\%$. Διαφέρουν σε δύο σημεία. Η αφινική είναι γραμμική, άρα διατηρεί τις σχετικές αποστάσεις των τιμών. Επιπλέον, δεν έχει ελεύθερη παράμετρο. Αφήνει, όμως, χωρίς μερίδιο τον πιο ακραίο αρνητικό. Η εκθετική δίνει θετικό μερίδιο σε όλους για κάθε β, με τίμημα μια παράμετρο που πρέπει να δηλωθεί. Αφού το πόρισμα της Ενότητας 5.7.6 είναι ότι και οι εννέα μένουν στην ομοσπονδία, η εκθετική είναι αυτή που το εφαρμόζει πλήρως.

5.8.3 Συνεισφορά και μερίδιο κάθε client

Ο Πίνακας 5.10 συγκεντρώνει το τελικό αποτέλεσμα της αποτίμησης. Για κάθε client, δίνει τη συνεισφορά του φ και το μερίδιο που του αναλογεί με τις δύο προτεινόμενες πολιτικές, με τη σειρά του Σχήματος 5.3. Κάθε μερίδιο δίνεται ως κλάσμα από 0 έως 1 και ως ποσοστό του συνόλου. Το κλάσμα είναι το $\bar{\gamma}_i$ των Εξισώσεων (5.5) και (5.6). Οι βάσεις σύγκρισης `raw` και `zero_clip` δεν επαναλαμβάνονται, αφού ο ρόλος τους εξαντλείται στον Πίνακα 5.9 και στο Σχήμα 5.15.

Με τις δύο προτεινόμενες πολιτικές, τα μερίδια ακολουθούν ακριβώς τη σειρά του φ. Με την αφινική, οι δώδεκα θετικοί παίρνουν από $4{,}79\%$ έως $7{,}24\%$ και οι εννέα αρνητικοί από 0% έως $4{,}49\%$. Το μηδέν αντιστοιχεί μόνο στον client 2. Με την εκθετική, οι θετικοί ανταμείβονται με $4{,}42\%$ έως $7{,}63\%$ και οι αρνητικοί με $1{,}53\%$ έως $4{,}14\%$, οπότε μερίδιο παίρνει και ο client 2.

			Συνεισφορά		affine		exponential	
Client	**Εθελοντής**	**Samples**	φ	**τ.α.**	**[0, 1]**	**%**	**[0, 1]**	**%**
14	23	372	0,404	0,036	0,0724	7,24	0,0763	7,63
1	3	341	0,384	0,031	0,0711	7,11	0,0740	7,40
12	21	408	0,371	0,039	0,0702	7,02	0,0727	7,27
10	17	368	0,363	0,045	0,0697	6,97	0,0718	7,18
18	28	382	0,299	0,039	0,0653	6,53	0,0652	6,52
4	7	308	0,230	0,023	0,0607	6,07	0,0587	5,87
20	30	383	0,198	0,029	0,0585	5,85	0,0559	5,59
17	27	376	0,173	0,033	0,0568	5,68	0,0539	5,39
8	15	328	0,143	0,039	0,0547	5,47	0,0515	5,15
9	16	366	0,138	0,036	0,0544	5,44	0,0511	5,11
0	1	347	0,117	0,029	0,0530	5,30	0,0495	4,95
6	11	316	0,041	0,026	0,0479	4,79	0,0442	4,42
13	22	321	−0,003	0,049	0,0449	4,49	0,0414	4,14
3	6	325	−0,075	0,050	0,0400	4,00	0,0371	3,71
16	26	392	−0,087	0,037	0,0392	3,92	0,0365	3,65
19	29	344	−0,089	0,032	0,0390	3,90	0,0363	3,63
15	25	409	−0,203	0,039	0,0313	3,13	0,0306	3,06
5	8	281	−0,242	0,037	0,0286	2,86	0,0288	2,88
7	14	323	−0,303	0,053	0,0245	2,45	0,0263	2,63
11	19	360	−0,399	0,060	0,0180	1,80	0,0228	2,28
2	5	302	−0,664	0,078	0,0000	0,00	0,0153	1,53
Οι 9 αρνητικοί			−2,065		0,2654	26,54	0,2751	27,51
Σύνολο			0,797		1,0000	100,00	1,0000	100,00

Πίνακας 5.10. Η συνεισφορά φ κάθε client (KernelSHAP, μέσος όρος και τυπική απόκλιση 20 seeds, σε μονάδες accuracy) και το μερίδιό του υπό τις δύο προτεινόμενες πολιτικές της Ενότητας 5.8.2, ως κλάσμα στο $[0, 1]$ και ως ποσοστό. Οι βάσεις σύγκρισης δίνονται στον Πίνακα 5.9 και στο Σχήμα 5.15. Οι γραμμές είναι ταξινομημένες κατά φθίνον φ και η οριζόντια γραμμή χωρίζει τους 12 θετικούς από τους 9 αρνητικούς. Η στήλη *Εθελοντής* είναι ο αριθμός του ατόμου στην πηγή των δεδομένων.

Κεφάλαιο 6

Συμπεράσματα και Μελλοντική Εργασία

6.1 Απαντήσεις στα Ερευνητικά Ερωτήματα

Η εργασία έθεσε τρία ερωτήματα στην Ενότητα 1.3. Απαντώνται εδώ ένα προς ένα.

Πρώτο ερώτημα, το κόστος της ομοσπονδιακής εκπαίδευσης. Κοστίζει $0{,}83$ ποσοστιαίες μονάδες έναντι της κεντρικής εκπαίδευσης, με $94{,}11\%$ έναντι $94{,}94\%$. Η διαφορά έχει το ίδιο πρόσημο σε 17 από τα 20 seeds. Απέναντι στην ατομική εκπαίδευση, κερδίζει $18{,}30$ ποσοστιαίες μονάδες. Η ομοσπονδιακή τοπολογία βρίσκεται, δηλαδή, πολύ πιο κοντά στο άνω από ό,τι στο κάτω όριο αναφοράς.

Το συμπέρασμα συνοδεύεται από μια επιφύλαξη που είναι μέρος του, δηλαδή ότι το μικρό κόστος *αναμένεται* σε αυτή τη ρύθμιση. Οι clients είναι σχεδόν IID ως προς τα labels, με διάμεση απόσταση ολικής μεταβολής $0{,}0423$ και καμία κλάση να λείπει από κανέναν.

Δεύτερο ερώτημα, η αποτίμηση με Shapley σε ρεαλιστικό κόστος. Ναι. Η ανασύνθεση των μοντέλων από αποθηκευμένα updates, αντί της επανεκπαίδευσης, αντικαθιστά $2{,}1$ εκατομμύρια ομοσπονδιακές εκπαιδεύσεις ανά seed με περάσματα αξιολόγησης, χωρίς καμία εκπαίδευση πέρα από την ίδια την ομοσπονδιακή. Ανά seed, ο KernelSHAP χρειάζεται 136.503 περάσματα και το GTG-Tib 101.431.

Το ουσιαστικότερο μέρος της απάντησης δεν είναι το κόστος αλλά η *σταθερότητα*. Δύο αλγοριθμικά διαφορετικοί εκτιμητές, που βλέπουν την ίδια συνάρτηση αξίας, συμφωνούν με Kendall $\tau = 0{,}9619$, Pearson $0{,}9997$ και τους ίδιους πέντε πρώτους clients. Για 19 από τους 21 clients, το πρόσημο μένει ίδιο σε 19 ή 20 από τα 20 seeds. Επιπλέον, 16 από τους 21 clients έχουν τιμή μεγαλύτερη από τρεις τυπικές αποκλίσεις και οι υπόλοιποι πέντε είναι εκείνοι με τη μικρότερη απόλυτη τιμή. Στη συγκεκριμένη κλίμακα, με 21 clients και full participation, η αποτίμηση είναι αξιόπιστη. Όμως, το συμπέρασμα δεν επεκτείνεται αυτόματα σε μεγαλύτερες ομοσπονδίες.

Τρίτο ερώτημα, η σημασία της αρνητικής συνεισφοράς. Εννέα από τους 21 clients έχουν αρνητικό φ. Το εύρημα άντεξε τέσσερις ελέγχους. Οι έλεγχοι αυτοί περιλαμβάνουν την επιμονή του αρνητικού προσήμου στα rounds, η οποία φτάνει το 94% για τους δύο πιο αρνητικούς, την αμεταβλητότητα ως προς την επιλογή μετρικής, τη συμφωνία των δύο εκτιμητών, καθώς και τη σταθερότητα έναντι των seeds.

Τι σημαίνει, λοιπόν, αρνητική συνεισφορά; Ότι, αφού το μοντέλο έχει μάθει τα βασικά, το update του client δείχνει σε άλλη κατεύθυνση από εκείνη των υπολοίπων. Ο FedAvg παίρνει μέσο όρο, οπότε ένα τέτοιο update απομακρύνει το global model από εκεί όπου το πάνε οι περισσότεροι. Όποιος διαφέρει από τους υπόλοιπους διαφέρει εξίσου και από τα άτομα της αξιολόγησης (Ενότητα 5.5.2), οπότε, στον βαθμό που ισχύει αυτό, το μοντέλο βγαίνει λίγο χειρότερο για αυτά, κυρίως στην καθιστή στάση και στην κατάβαση σκάλας. Δε σημαίνει ότι τα δεδομένα του είναι κακά. Στο παίγνιο επανεκπαίδευσης, που αποτιμά τα ίδια δεδομένα με ένα κεντρικό μοντέλο, χωρίς aggregation, ο χειρότερος client του ομοσπονδιακού παιγνίου βρίσκεται στη μέση της κατάταξης και οι δύο κατατάξεις συμφωνούν μόνο ασθενώς.

Η κατεύθυνση του update, μια μέτρηση που δε χρησιμοποιεί το test set, δίνει μέσο συνημίτονο $-0{,}081$ για τους εννέα έναντι $+0{,}003$ για τους δώδεκα και συσχέτιση $r = +0{,}580$ με το φ, την ισχυρότερη από όσες μετρήθηκαν. Αντίθετα, η απόσταση ολικής μεταβολής των labels δε σχετίζεται με το φ ($r = +0{,}056$) και η απόσταση features από το test set έχει μόνο ασθενή σχέση ($r = -0{,}442$). Ο χειρότερος client είναι κοντά στον μέσο όρο σε όλα τα στατιστικά των δεδομένων του εκτός από τον όγκο. Ούτε ο όγκος ούτε η κατεύθυνση του update εξηγούν μόνα τους την ακραία τιμή του. Ακόμη και η κατεύθυνση εξηγεί περίπου το ένα τρίτο της διακύμανσης, οπότε κανένα από τα φθηνά μεγέθη που εξετάστηκαν δεν αντικαθιστά την αποτίμηση.

Οι αρνητικές τιμές εξετάστηκαν και με ένα δεύτερο παίγνιο, το παίγνιο επανεκπαίδευσης. Εκεί, η αξία ενός συνασπισμού είναι το accuracy ενός κεντρικού (*centralized*) μοντέλου, που εκπαιδεύεται από την αρχή με τα δεδομένα του, και όχι του μοντέλου που βγαίνει από τα updates του. Το παίγνιο αυτό δε δίνει αρνητική τιμή σε *κανέναν* από τους 21, αν και, όπως εξηγεί η Ενότητα 5.6.4, η μορφή του δύσκολα θα έδινε. Η συμφωνία των δύο κατατάξεων είναι ασθενής ($\tau = 0{,}238$). Υπάρχει σήμα που συνδέει τα δύο, αλλά το μεγαλύτερο μέρος της κατάταξης δε μεταφέρεται. Δε βρέθηκε, επομένως, ένδειξη ότι τα δεδομένα κάποιου client βλάπτουν, και η αρνητική τιμή αφορά τη συνεισφορά του στη συγκεκριμένη ομοσπονδιακή εκπαίδευση.

Στο failure analysis, η αρνητική τιμή αποσυντέθηκε. Φάνηκε ότι ούτε αυτοί οι clients βλάπτουν γενικά. Ως προς τον χρόνο, στα πρώτα δέκα rounds οι ίδιοι εννέα είναι, ως ομάδα, *θετικοί* και το πρόσημο αντιστρέφεται μόνο αφού το μοντέλο ξεπεράσει περίπου το 90%. Ως προς τις δραστηριότητες, *μετακινούν σύνορα απόφασης* μεταξύ συγκεκριμένων ζευγών, κυρίως μεταξύ καθιστής και όρθιας στάσης ($r = -0{,}933$ μεταξύ των δύο στηλών), βελτιώνο-

ντας τη μία κλάση όσο χειροτερεύουν την άλλη. Ως προς τα άτομα της αξιολόγησης, κανείς τους δε βλάπτει και τους εννέα ανθρώπους, ενώ ο χειρότερος από όλους ωφελεί δύο από αυτούς. Επιπλέον, ένα μόνο άτομο απορροφά το $27{,}3\%$ της αρνητικής συνεισφοράς των εννέα clients. Η αρνητική τιμή δεν είναι ιδιότητα ενός ανθρώπου αλλά *σχέση* ανάμεσα σε έναν άνθρωπο, μια φάση της εκπαίδευσης και ένα συγκεκριμένο evaluation set.

Η αφαίρεση των αρνητικών clients. Το πόρισμα της ανάλυσης είναι ότι, στην περίπτωση της εργασίας, η αφαίρεση των clients με αρνητική τιμή δεν έχει νόημα. Όταν οι αρνητικοί εντοπίζονται με έξι από τα εννέα άτομα του test set και η επίπτωση της αφαίρεσής τους μετριέται στα υπόλοιπα τρία, το μοντέλο βελτιώνεται σε μία μόνο από τις τρεις τριάδες και χειροτερεύει στις άλλες δύο, σε μία από αυτές σε όλα τα 20 seeds. Μέσα στα έξι άτομα της αποτίμησης, η βελτίωση εμφανίζεται και στις τρεις τριάδες. Η *ταυτοποίηση* των αρνητικών είναι σταθερή, με δείκτη Jaccard από $0{,}89$ έως $1{,}00$. Η αφαίρεσή τους, όμως, βοηθά με συνέπεια μόνο τους ανθρώπους με τους οποίους μετρήθηκε. Η αποτίμηση με Shapley στέκει ως μέτρηση και όχι ως κριτήριο για το ποιος πρέπει να μείνει εκτός. Μετρά τι συνέβη σε μια συγκεκριμένη εκπαίδευση, απέναντι σε ένα συγκεκριμένο evaluation set.

Επομένως, οι εννέα μένουν στην ομοσπονδία και η συνεισφορά όλων μετατρέπεται σε μερίδια. Ο απλός μηδενισμός των αρνητικών τιμών είναι η χειρότερη επιλογή, γιατί καταστρέφει πληροφορία κατάταξης, ρίχνοντας το τ από $1{,}000$ σε $0{,}829$ και εξισώνοντας έναν client με σταθερά αρνητική συνεισφορά με έναν του οποίου η τιμή βρίσκεται μέσα στον θόρυβο. Επιπλέον, μια ποινή με κριτήριο το *πρόσημο* θα τιμωρούσε, δύο φορές στις τρεις, συνεισφορά που ωφελεί άτομα του test set τα οποία έμειναν έξω από την απόφαση. Η αφινική μετατόπιση και η εκθετική κατανομή δίνουν μη αρνητικά μερίδια χωρίς απώλεια κατάταξης. Οι θετικοί παίρνουν μεγαλύτερο μερίδιο από τους αρνητικούς (Πίνακας 5.10). Η αφινική αφήνει χωρίς μερίδιο μόνο τον πιο ακραίο αρνητικό, ως παρενέργεια της κλιμάκωσης, ενώ η εκθετική δίνει θετικό μερίδιο σε όλους. Γι' αυτό η εκθετική είναι η επιλογή που ταιριάζει στο πόρισμα παραμονής όλων. Πρόκειται για κανόνα κατανομής πάνω σε μετρημένες τιμές και όχι για μηχανισμό κινήτρων (Ενότητα 6.2).

Το σύνορο καθιστής και όρθιας στάσης σε δύο αναλύσεις. Η ανάλυση σφαλμάτων και η ανάλυση συνεισφοράς ανά δραστηριότητα, δύο διαφορετικές μεθοδολογίες, συγκλίνουν στο ίδιο σημείο, δηλαδή στο σύνορο μεταξύ καθιστής και όρθιας στάσης. Το σύνορο αυτό παράγει το $49{,}1\%$ των σφαλμάτων και αποδίδεται από το 2013 στη φυσική θέση της συσκευής [1]. Η δυσκολία ήταν ήδη γνωστή. Παρόλο που η εργασία δεν την ανακάλυψε, πρόσθεσε την ταυτότητα των clients που την επιδεινώνουν.

6.2 Περιορισμοί της Εργασίας

Το test set είναι εννέα άνθρωποι. Παρά τα 2.947 samples, οι ανεξάρτητες μονάδες είναι εννέα. Κάθε δήλωση αβεβαιότητας σε αυτήν την εργασία αφορά τη διασπορά μεταξύ seeds και *όχι* τη γενίκευση σε νέους ανθρώπους. Η Ενότητα 5.7.4 έκανε ένα βήμα προς την ποσοτικοποίηση, εναλλάσσοντας ποια άτομα συμμετέχουν στην απόφαση και ποια στη μέτρηση. Το αποτέλεσμα ήταν ακριβώς ότι η γενίκευση *δεν* είναι δεδομένη. Η διαχωριστική γραμμή ανάμεσα στους 21 clients και στα 9 άτομα αξιολόγησης, όμως, παρέμεινε σταθερή, γιατί είναι δοσμένη από την πηγή.

Οι clients είναι σχεδόν IID ως προς τα labels. Το συμπέρασμα για το μικρό κόστος της αποκέντρωσης δεν μπορεί να μεταφερθεί χωρίς έλεγχο σε ρυθμίσεις με έντονη λοξότητα labels.

Μία αρχιτεκτονική, μη βελτιστοποιημένες υπερπαράμετροι. Δοκιμάστηκε ένα μόνο MLP με σταθερές διαστάσεις κρυφών επιπέδων. Δεν έγινε αναζήτηση υπερπαραμέτρων και δεν είναι γνωστό σε ποιο βαθμό τα ευρήματα εξαρτώνται από τη συγκεκριμένη αρχιτεκτονική. Η Ενότητα 4.5 έδειξε, μάλιστα, ότι το logistic regression, με περίπου 53 φορές λιγότερες παραμέτρους, δεν ξεχωρίζει από το δίκτυο ANN και ότι ένα linear SVM το ξεπερνά στο test set αλλά δεν μπαίνει στην ομοσπονδία χωρίς αλλαγή του τρόπου εκπαίδευσής του. Το δίκτυο κρατήθηκε ως η αρχική σχεδίαση που υποστηρίζει και τις τρεις τοπολογίες και το παίγνιο συνεισφοράς, όχι επειδή χρειαζόταν η χωρητικότητά του. Από τις υπερπαραμέτρους της εκπαίδευσης, μόνο το $E = 1$ της ομοσπονδιακής τοπολογίας στηρίχθηκε σε μέτρηση, η οποία έγινε στο test set (Ενότητα 4.6.3).

Η πηγή φέρει διαρροή προεπεξεργασίας. Το δημοσιευμένο σύνολο έχει κλιμακωθεί με παραμέτρους που υπολογίστηκαν και από τα δεδομένα του test set (Ενότητα 3.3.1), περίπτωση που η βιβλιογραφία καταγράφει ως διαρροή προεπεξεργασίας [36]. Η τυπικοποίηση της εργασίας την ακυρώνει αποδεδειγμένα αλλά η ακύρωση ισχύει μόνο όσο εφαρμόζεται. Κάθε σύγκριση με δημοσιευμένα αποτελέσματα που δεν κάνουν αυτό το βήμα δεν είναι αντιστοιχισμένη.

Το test set βρίσκεται μέσα στον βρόχο της αποτίμησης. Η συνάρτηση αξίας αποτιμάται στο test set, πρακτική συνήθης για *μέτρηση* [30]. Όταν, όμως, η τιμή χρησιμοποιείται για *απόφαση*, η πρακτική αυτή δημιουργεί εξάρτηση. Η εξάρτηση μετρήθηκε (Ενότητα 5.7.4) και αποδείχθηκε ουσιώδης. Ό,τι απομένει ως περιορισμός είναι ότι δε δοκιμάστηκε η εναλλακτική κατεύθυνση, δηλαδή η αποτίμηση που δε χρειάζεται κανένα evaluation set και στηρίζεται μόνο στα local updates [43].

Η επαλήθευση με τον ορισμό αφορά τρία rounds. Στο ομοσπονδιακό παίγνιο, η σύγκριση με το ακριβές Shapley έγινε σε τρία rounds ενός seed (Ενότητα 5.2.5) και όχι στα

1.305 scored rounds των 20 seeds. Για τα υπόλοιπα rounds, το κενό καλύπτεται έμμεσα, από τη συμφωνία δύο αλγοριθμικά διαφορετικών εκτιμητών και από τη σταθερότητα του προσήμου στα 20 seeds (Ενότητα 5.3.2).

Οι χρονοσειρές είναι εκτός εύρους. Η εργασία χρησιμοποιεί αποκλειστικά τα 561 έτοιμα features, που είναι η φυσική είσοδος του απλού MLP που επιλέχθηκε (Ενότητα 3.2). Τα ακατέργαστα σήματα δε δοκιμάστηκαν.

Καμία τυπική εγγύηση ιδιωτικότητας. Η εργασία δεν εφαρμόζει differential privacy ούτε secure aggregation (Ενότητα 2.2.4). Τα επιμέρους updates είναι ορατά στον server, γιατί η αποτίμηση τα χρειάζεται για να ανασυνθέσει το μοντέλο κάθε συνασπισμού.

Τα κίνητρα παραμένουν σε θεωρητικό επίπεδο. Δε σχεδιάστηκε ούτε αξιολογήθηκε μηχανισμός. Το μόνο κίνητρο που μετρήθηκε είναι το γεγονός ότι κάθε client παίρνει καλύτερο μοντέλο από αυτό που θα είχε μόνος. Η βιβλιογραφία ξεχωρίζει ρητά τα δύο βήματα. Το Shapley value υιοθετείται συνήθως για την *αποτίμηση της συνεισφοράς*, ενώ η *κατανομή πληρωμών* αφορά παίγνια Stackelberg, δημοπρασίες, θεωρία συμβολαίων και μη κυρτή βελτιστοποίηση [5]. Η εργασία τοποθετείται αποκλειστικά στο πρώτο βήμα. Τα μερίδια της Ενότητας 5.8 δείχνουν τι θα προέκυπτε, αν κάποιος έχτιζε μηχανισμό πάνω στο μέτρο της εργασίας.

6.3 Κατευθύνσεις για Μελλοντική Εργασία

Μηχανισμός κινήτρων πάνω στο μέτρο. Το φυσικό επόμενο βήμα είναι να χτιστεί πάνω στο μέτρο συνεισφοράς ένας πραγματικός μηχανισμός, με στρατηγικές, κόστος συμμετοχής και ανάλυση ισορροπίας. Η βιβλιογραφία προσφέρει το πλαίσιο, με τη θεωρία συμβολαίων [27], τις δημοπρασίες και τα παίγνια Stackelberg [5], [6]. Το ανοιχτό ζήτημα είναι ότι, αν η αμοιβή εξαρτάται από μετρούμενη συνεισφορά, οι clients αποκτούν κίνητρο να χειραγωγήσουν τη μέτρηση.

Έλεγχος με εναλλαγή υποκειμένων. Επανάληψη ολόκληρης της αποτίμησης με τρεις ή περισσότερους διαφορετικούς διαχωρισμούς των 30 ατόμων σε 21 clients και 9 για αξιολόγηση. Αν οι ίδιοι άνθρωποι παραμένουν στις τελευταίες θέσεις της κατάταξης ανεξάρτητα από το ποιοι είναι στο test set, ενισχύεται σημαντικά η ερμηνεία ότι η αρνητική τιμή ανήκει στο update και όχι στο test set.

Αποτίμηση μόνο από τα updates. Η αποτίμηση της εργασίας χρειάζεται ένα evaluation set, εδώ το test set, για να μετρήσει πόσο βελτιώνει κάθε συνασπισμός το μοντέλο. Οι μέθοδοι που στηρίζονται μόνο στα local updates [43] αποτιμούν, επίσης, τη συνεισφορά αλλά χωρίς κανένα evaluation set, οπότε λύνουν εξ ορισμού το πρόβλημα του test set μέσα στον βρόχο

απόφασης. Το έργο τους είναι δυσκολότερο, αφού δεν μπορούν να μετρήσουν απευθείας τη βελτίωση και στηρίζονται σε έμμεσα μεγέθη. Η κατεύθυνση του update της Ενότητας 5.5.3 είναι ένα τέτοιο μέγεθος και εξηγεί περίπου το ένα τρίτο της διακύμανσης του φ. Η σύγκριση τέτοιων μεθόδων με την αποτίμηση της εργασίας, πάνω στα ίδια δεδομένα, θα έδειχνε πόση από τη συνεισφορά μπορεί να αποτιμηθεί χωρίς test set.

Αποτίμηση υπό μηχανισμούς ιδιωτικότητας. Ο θόρυβος του differential privacy αλλάζει τα updates και το secure aggregation τα κρύβει από τον server (Ενότητα 2.2.4). Το ερώτημα είναι αν η αποτίμηση μπορεί να γίνει πάνω σε updates με θόρυβο ή όταν ο server βλέπει μόνο αθροίσματα, χωρίς να χαθεί η σταθερότητα της κατάταξης που μετρήθηκε εδώ.

Ερμηνευσιμότητα σε επίπεδο features. Η ίδια αξιωματική βάση επιτρέπει τη διερεύνηση των *features* που οδηγούν τις προβλέψεις, με το ενοποιητικό πλαίσιο των μεθόδων αφαίρεσης [22]. Θα συνδεόταν άμεσα με την απόσταση features της Ενότητας 5.5.2. Σημειώνεται ότι μια τέτοια ανάλυση θα έπρεπε να λάβει υπόψη τις 21 στήλες-αντίγραφα της Ενότητας 3.3.2. Κάθε αντίγραφο μοιράζεται τη σημαντικότητα με το πρωτότυπό του, με αποτέλεσμα να εμφανίζονται και τα δύο υποτιμημένα.

Χρονοσειρές και μάθηση αναπαράστασης. Μοντέλα που δέχονται τα ακατέργαστα σήματα [2] θα επέτρεπαν να ελεγχθεί αν η κατάταξη συνεισφοράς είναι ιδιότητα των ανθρώπων ή της συγκεκριμένης αναπαράστασης. Είναι ο πιο άμεσος έλεγχος της σταθερότητας του κεντρικού ευρήματος της εργασίας.

Βιβλιογραφία

[1] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra και Jorge Luis Reyes-Ortiz. «A Public Domain Dataset for Human Activity Recognition Using Smartphones». Στο: *Proceedings of the 21st European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN)*. 2013. URL: https://www.esann.org/sites/default/files/proceedings/legacy/es2013-84.pdf.

[2] Kaixuan Chen, Dalin Zhang, Lina Yao, Bin Guo, Zhiwen Yu και Yunhao Liu. *Deep Learning for Sensor-based Human Activity Recognition: Overview, Challenges and Opportunities*. 2021. arXiv: 2001.07416v2. URL: https://arxiv.org/abs/2001.07416v2. Δημοσιεύτηκε στο: *ACM Computing Surveys* 54.4 (2022). DOI: 10.1145/3447744.

[3] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson και Blaise Agüera y Arcas. «Communication-Efficient Learning of Deep Networks from Decentralized Data». Στο: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 54. PMLR. 2017. URL: https://proceedings.mlr.press/v54/mcmahan17a.html.

[4] Peter Kairouz κ.ά. *Advances and Open Problems in Federated Learning*. 2021. arXiv: 1912.04977v3. URL: https://arxiv.org/abs/1912.04977v3. Δημοσιεύτηκε στο: *Foundations and Trends in Machine Learning* 14.1–2 (2021). DOI: 10.1561/2200000083.

[5] Rongfei Zeng, Chao Zeng, Xingwei Wang, Bo Li και Xiaowen Chu. *A Comprehensive Survey of Incentive Mechanism for Federated Learning*. 2021. arXiv: 2106.15406v1. URL: https://arxiv.org/abs/2106.15406v1.

[6] Xuezhen Tu, Kun Zhu, Nguyen Cong Luong, Dusit Niyato, Yang Zhang και Juan Li. *Incentive Mechanisms for Federated Learning: From Economic and Game Theoretic Perspective*. 2021. arXiv: 2111.11850v1. URL: https://arxiv.org/abs/2111.11850v1. Δημοσιεύτηκε στο: *IEEE Transactions on Cognitive Communications and Networking* 8.3 (2022). DOI: 10.1109/TCCN.2022.3177522.

[7] Pavlos Efraimidis. *Διπλωματικές Εργασίες*. Algorithms & Privacy Research Unit, DUTH. 2025. URL: https://pefraimi.github.io/theses/, accessed September 27th, 2026.

[8] Ian Goodfellow, Yoshua Bengio και Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: https://www.deeplearningbook.org/.

[9] Diederik P. Kingma και Jimmy Ba. *Adam: A Method for Stochastic Optimization*. 2017. arXiv: 1412.6980v9. URL: https://arxiv.org/abs/1412.6980v9. Δημοσιεύτηκε στο: *International Conference on Learning Representations (ICLR)*. 2015.

[10] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever και Ruslan Salakhutdinov. «Dropout: A Simple Way to Prevent Neural Networks from Overfitting». Στο: *Journal of Machine Learning Research* 15.56 (2014). URL: https://jmlr.org/papers/v15/srivastava14a.html.

[11] Marina Sokolova και Guy Lapalme. «A Systematic Analysis of Performance Measures for Classification Tasks». Στο: *Information Processing & Management* 45.4 (2009). DOI: 10.1016/j.ipm.2009.03.002. URL: https://rali.iro.umontreal.ca/rali/sites/default/files/publis/SokolovaLapalme-JIPM09.pdf.

[12] scikit-learn developers. *Metrics and scoring: quantifying the quality of predictions*. scikit-learn 1.8.0 documentation, User Guide, Section 3.4. 2025. URL: https://scikit-learn.org/1.8/modules/model_evaluation.html, accessed September 28th, 2026.

[13] Fabian Pedregosa κ.ά. «Scikit-learn: Machine Learning in Python». Στο: *Journal of Machine Learning Research* 12 (2011). URL: https://jmlr.org/papers/v12/pedregosa11a.html.

[14] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar και Virginia Smith. «Federated Optimization in Heterogeneous Networks». Στο: *Proceedings of Machine Learning and Systems (MLSys)*. Τόμ. 2. 2020. URL: https://proceedings.mlsys.org/paper_files/paper/2020/hash/1f5fe83998a09396ebe6477d9475ba0c-Abstract.html.

[15] Sai Praneeth Karimireddy, Satyen Kale, Mehryar Mohri, Sashank J. Reddi, Sebastian U. Stich και Ananda Theertha Suresh. «SCAFFOLD: Stochastic Controlled Averaging for Federated Learning». Στο: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Τόμ. 119. PMLR. 2020. URL: https://proceedings.mlr.press/v119/karimireddy20a.html.

[16] Martín Abadi κ.ά. *Deep Learning with Differential Privacy*. 2016. arXiv: 1607.00133v2. URL: https://arxiv.org/abs/1607.00133v2. Προκαταρκτική έκδοση στο: *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security (CCS)*. 2016. DOI: 10.1145/2976749.2978318.

[17] Lloyd S. Shapley. *A Value for n-Person Games*. P-295. RAND Corporation, 1952. DOI: 10.7249/P0295. URL: https://www.rand.org/pubs/papers/P295.html. Δημοσιεύτηκε στο: *Contributions to the Theory of Games (AM-28), Volume II*. Princeton University Press, 1953. DOI: 10.1515/9781400881970-018.

[18] Ruoxi Jia κ.ά. «Towards Efficient Data Valuation Based on the Shapley Value». Στο: *Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 89. PMLR. 2019. URL: https://proceedings.mlr.press/v89/jia19a.html.

[19] Amirata Ghorbani και James Zou. «Data Shapley: Equitable Valuation of Data for Machine Learning». Στο: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. Τόμ. 97. PMLR. 2019. URL: https://proceedings.mlr.press/v97/ghorbani19c.html.

[20] Scott M. Lundberg και Su-In Lee. «A Unified Approach to Interpreting Model Predictions». Στο: *Advances in Neural Information Processing Systems (NeurIPS)*. Τόμ. 30. 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.

[21] Ian Covert και Su-In Lee. «Improving KernelSHAP: Practical Shapley Value Estimation Using Linear Regression». Στο: *Proceedings of the 24th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 130. PMLR. 2021. URL: https://proceedings.mlr.press/v130/covert21a.html.

[22] Ian Covert, Scott M. Lundberg και Su-In Lee. «Explaining by Removing: A Unified Framework for Model Explanation». Στο: *Journal of Machine Learning Research* 22.209 (2021). URL: https://jmlr.org/papers/v22/20-1316.html.

[23] Amirata Ghorbani, Michael P. Kim και James Zou. «A Distributional Framework for Data Valuation». Στο: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Τόμ. 119. PMLR. 2020. URL: https://proceedings.mlr.press/v119/ghorbani20a.html.

[24] Xinyi Xu, Lingjuan Lyu, Xingjun Ma, Chenglin Miao, Chuan Sheng Foo και Bryan Kian Hsiang Low. «Gradient Driven Rewards to Guarantee Fairness in Collaborative Machine Learning». Στο: *Advances in Neural Information Processing Systems (NeurIPS)*. Τόμ. 34. 2021. URL: https://proceedings.neurips.

cc/paper/2021/hash/8682cc30db9c025ecd3fee433f8ab54c-Abstract.html.

[25] Jiachen T. Wang και Ruoxi Jia. «Data Banzhaf: A Robust Data Valuation Framework for Machine Learning». Στο: *Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Τόμ. 206. PMLR. 2023. URL: https://proceedings.mlr.press/v206/wang23e.html.

[26] Jiachen T. Wang, Tianji Yang, James Zou, Yongchan Kwon και Ruoxi Jia. «Rethinking Data Shapley for Data Selection Tasks: Misleads and Merits». Στο: *Proceedings of the 41st International Conference on Machine Learning (ICML)*. Τόμ. 235. PMLR. 2024. URL: https://proceedings.mlr.press/v235/wang24cg.html.

[27] Jiawen Kang, Zehui Xiong, Dusit Niyato, Han Yu, Ying-Chang Liang και Dong In Kim. *Incentive Design for Efficient Federated Learning in Mobile Networks: A Contract Theory Approach*. 2019. arXiv: 1905.07479v2. URL: https://arxiv.org/abs/1905.07479v2. Δημοσιεύτηκε στο: *2019 IEEE VTS Asia Pacific Wireless Communications Symposium (APWCS)*. 2019. DOI: 10.1109/VTS-APWCS.2019.8851649.

[28] Nurbek Tastan, Samar Fares, Toluwani Aremu, Samuel Horváth και Karthik Nandakumar. «Redefining Contributions: Shapley-Driven Federated Learning». Στο: *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24)*. 2024. DOI: 10.24963/ijcai.2024/554. URL: https://www.ijcai.org/proceedings/2024/0554.pdf.

[29] Konstantin Sozinov, Vladimir Vlassov και Sarunas Girdzijauskas. «Human Activity Recognition Using Federated Learning». Στο: *2018 IEEE Intl Conf on Parallel & Distributed Processing with Applications, Ubiquitous Computing & Communications, Big Data & Cloud Computing, Social Computing & Networking, Sustainable Computing & Communications (ISPA/IUCC/BDCloud/SocialCom/SustainCom)*. 2018. DOI: 10.1109/BDCloud.2018.00164. URL: https://people.kth.se/~sarunasg/Papers/Sozinov2018FederatedLearning.pdf.

[30] Zelei Liu, Yuanyuan Chen, Han Yu, Yang Liu και Lizhen Cui. *GTG-Shapley: Efficient and Accurate Participant Contribution Evaluation in Federated Learning*. 2021. arXiv: 2109.02053v1. URL: https://arxiv.org/abs/2109.02053v1. Δημοσιεύτηκε στο: *ACM Transactions on Intelligent Systems and Technology* 13.4 (2022). DOI: 10.1145/3501811.

[31] Tianhao Wang, Johannes Rausch, Ce Zhang, Ruoxi Jia και Dawn Song. *A Principled Approach to Data Valuation for Federated Learning*. 2020. arXiv: 2009.06192v1. URL: https://arxiv.org/abs/2009.06192v1. Δημοσιεύτηκε στο:

Federated Learning, Lecture Notes in Computer Science. Springer, 2020. DOI: 10.1007/978-3-030-63076-8_11.

[32] Mengwei Yang, Ismat Jarin, Baturalp Buyukates, Salman Avestimehr και Athina Markopoulou. *Maverick-Aware Shapley Valuation for Client Selection in Federated Learning*. 2024. arXiv: 2405.12590v1. URL: https://arxiv.org/abs/2405.12590v1.

[33] Jiyue Huang, Chi Hong, Lydia Y. Chen και Stefanie Roos. *Is Shapley Value fair? Improving Client Selection for Mavericks in Federated Learning*. 2021. arXiv: 2106.10734v1. URL: https://arxiv.org/abs/2106.10734v1.

[34] Jorge Luis Reyes-Ortiz, Davide Anguita, Alessandro Ghio, Luca Oneto και Xavier Parra. *Human Activity Recognition Using Smartphones*. UCI Machine Learning Repository. 2013. DOI: 10.24432/C54S4K. URL: https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones, accessed September 27th, 2026.

[35] Jindong Wang, Yiqiang Chen, Shuji Hao, Xiaohui Peng και Lisha Hu. *Deep Learning for Sensor-based Activity Recognition: A Survey*. 2017. arXiv: 1707.03502v2. URL: https://arxiv.org/abs/1707.03502v2. Δημοσιεύτηκε στο: *Pattern Recognition Letters* 119 (2019). DOI: 10.1016/j.patrec.2018.02.010.

[36] Sayash Kapoor και Arvind Narayanan. «Leakage and the reproducibility crisis in machine-learning-based science». Στο: *Patterns* 4.9 (2023). DOI: 10.1016/j.patter.2023.100804.

[37] Artur Jordao, Antonio C. Nazare, Jessica Sena και William Robson Schwartz. *Human Activity Recognition Based on Wearable Sensor Data: A Standardization of the State-of-the-Art*. 2019. arXiv: 1806.05226v3. URL: https://arxiv.org/abs/1806.05226v3.

[38] Akbar Dehghani, Omid Sarbishei, Tristan Glatard και Emad Shihab. «A Quantitative Comparison of Overlapping and Non-Overlapping Sliding Windows for Human Activity Recognition Using Inertial Sensors». Στο: *Sensors* 19.22 (2019). DOI: 10.3390/s19225026.

[39] Jason Ansel κ.ά. *PyTorch 2: Faster Machine Learning Through Dynamic Python Bytecode Transformation and Graph Compilation*. 2024. URL: https://docs.pytorch.org/assets/pytorch2-2.pdf. Δημοσιεύτηκε στο: *Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS '24), Volume 2*. ACM, 2024. DOI: 10.1145/3620665.3640366.

[40] Nikolaos Pavlidis. *Simple Federated Learning Example*. GitHub repository. 2023. URL: https://github.com/nikopavl4/Simple_FL_Example, accessed September 27th, 2026.

[41] Léo Grinsztajn, Edouard Oyallon και Gaël Varoquaux. «Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?» Στο: *Advances in Neural Information Processing Systems 35 (NeurIPS), Datasets and Benchmarks Track*. 2022. DOI: 10.52202/068431-0037. URL: https://proceedings.neurips.cc/paper_files/paper/2022/hash/0378c7692da36807bdec87ab043cdadc-Abstract-Datasets_and_Benchmarks.html.

[42] E. T. Jaynes. «Information Theory and Statistical Mechanics». Στο: *Physical Review* 106.4 (1957). DOI: 10.1103/PhysRev.106.620. URL: https://bayes.wustl.edu/etj/articles/theory.1.pdf.

[43] Meiying Zhang, Huan Zhao, Sheldon Ebron και Kan Yang. *Towards Fair, Robust and Efficient Client Contribution Evaluation in Federated Learning*. 2024. arXiv: 2402.04409v1. URL: https://arxiv.org/abs/2402.04409v1. Δημοσιεύτηκε στο: *GLOBECOM 2024 – 2024 IEEE Global Communications Conference*. 2024. DOI: 10.1109/GLOBECOM52923.2024.10901033.