



ΔΗΜΟΚΡΙΤΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΡΑΚΗΣ

ΤΜΗΜΑ
ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
& ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

Σχεδιασμός και Υλοποίηση Συστημάτων Ομοσπονδιακής Μάθησης (Federated Learning) με Μηχανισμούς Κινήτρων για την Αναγνώριση Δραστηριότητας σε Περιβάλλοντα Υποβοηθούμενης Διαβίωσης (AAL)

Διπλωματική Εργασία

Ενδιάμεση Αναφορά Προόδου

(έως τον Μηχανισμό Κινήτρων — Κεφάλαιο 4)

Δημήτριος Αναστασούδης

AEM: 58085

Επιβλέπων:

Πάυλος Εφραιμίδης

Algorithms & Privacy Research Unit (Euclid)

Ξάνθη, 2026

Περίληψη

Η αυξανόμενη ζήτηση για έξυπνη παρακολούθηση υγείας σε περιβάλλοντα Υποβοηθούμενης Διαβίωσης (Ambient Assisted Living, AAL) καθιστά την Αναγνώριση Δραστηριότητας Ανθρώπου (Human Activity Recognition, HAR) κρίσιμο ερευνητικό πεδίο. Οι κλασικές κεντρικές προσεγγίσεις μηχανικής μάθησης απαιτούν τη μεταφορά ευαίσθητων δεδομένων αισθητήρων κινητών συσκευών σε κεντρικούς εξυπηρετητές, εγείροντας σοβαρές ανησυχίες για την ιδιωτικότητα των χρηστών.

Η παρούσα διπλωματική εργασία προτείνει ένα σύστημα Ομοσπονδιακής Μάθησης (Federated Learning, FL) για HAR σε περιβάλλοντα AAL, το οποίο διατηρεί τα δεδομένα τοπικά σε κάθε συσκευή και μεταδίδει μόνο ενημερώσεις παραμέτρων μοντέλου στον κεντρικό εξυπηρετητή. Θεμελιώδης αδυναμία των υπάρχοντων συστημάτων FL είναι η έλλειψη μηχανισμών που να παρακινούν ορθολογικούς χρήστες να συμμετέχουν ενεργά και να συνεισφέρουν δεδομένα υψηλής ποιότητας. Για την αντιμετώπιση αυτής της αδυναμίας, σχεδιάζεται και υλοποιείται μηχανισμός κινήτρων βασισμένος στο Παίγνιο Stackelberg της Θεωρίας Παιγνίων, στον οποίο ο κεντρικός εξυπηρετητής ενεργεί ως ηγέτης (leader) καθορίζοντας τη δομή ανταμοιβών, ενώ οι πελάτες (clients) ενεργούν ως ακόλουθοι (followers) βελτιστοποιώντας την προσπάθειά τους.

Επιπλέον, για την αξιολόγηση της συνεισφοράς κάθε συμμετέχοντος πελάτη, αναπτύσσεται σύστημα βασισμένο στα Shapley Values της Συνεργατικής Θεωρίας Παιγνίων, εξασφαλίζοντας δίκαιη κατανομή ανταμοιβών ανάλογη με την οριακή συνεισφορά κάθε πελάτη στην αναγνωριστική ικανότητα του καθολικού μοντέλου. Η προτεινόμενη αρχιτεκτονική υλοποιείται με μονοδιάστατο Συνελικτικό Νευρωνικό Δίκτυο (1D-CNN) ειδικά σχεδιασμένο για ανάλυση χρονοσειρών αισθητήρων, με υλοποίηση του πρωτοκόλλου ομοσπονδιακής εκπαίδευσης (FedAvg) εξ ολοκλήρου σε PyTorch.

Η αξιολόγηση διεξάγεται σε δύο σύνολα δεδομένων: το καθιερωμένο UCI Human Activity Recognition dataset υπό ελεγχόμενες συνθήκες, και το AAL Smartphone Dataset για HAR σε AAL υπό πραγματικές συνθήκες με ετερογενείς, Non-IID κατανομές δεδομένων μεταξύ 22 χρηστών-clients. Η αρχική αξιολόγηση επιβεβαιώνει τη λειτουργικότητα του συστήματος: ομοσπονδιακή ακρίβεια 76,8% έναντι 84,8% κεντροκοποιημένης, ποσοτικοποιώντας το κόστος της Non-IID ετερογένειας. Η ποσοτική σύγκριση των μετρικών συνεισφοράς (Leave-One-Out έναντι Shapley) για την οριστικοποίηση του μηχανισμού κινήτρων αποτελεί το επόμενο στάδιο.

Λέξεις-κλειδιά: Ομοσπονδιακή Μάθηση, Αναγνώριση Δραστηριότητας Ανθρώπου (HAR), Υποβοηθούμενη Διαβίωση (AAL), Ψηφιακό Δίδυμο, Θεωρία Παιγνίων, Παίγνιο Stackelberg, Shapley Values, Μηχανισμοί Κινήτρων.

Abstract

The growing demand for intelligent health monitoring in Ambient Assisted Living (AAL) environments renders Human Activity Recognition (HAR) a critical research domain. Classical centralized machine learning approaches require the transfer of sensitive mobile sensor data to central servers, raising serious concerns about user privacy.

This thesis proposes a Federated Learning (FL) system for HAR in AAL environments, which preserves data locally on each device and transmits only model parameter updates to the central server. A fundamental limitation of existing FL systems is the absence of mechanisms that incentivize rational users to actively participate and contribute high-quality data. To address this shortcoming, an incentive mechanism based on Stackelberg Game Theory is designed and implemented, in which the central server acts as the leader by determining the reward structure, while the clients act as followers optimizing their level of effort.

Furthermore, to evaluate the contribution of each participating client, a system based on Shapley Values from Cooperative Game Theory is developed, ensuring fair reward allocation proportional to each client's marginal contribution to the global model's recognition capability. The proposed architecture is implemented using a one-dimensional Convolutional Neural Network (1D-CNN) specifically designed for sensor time-series analysis, with the federated training protocol (FedAvg) implemented from scratch in PyTorch.

Evaluation is conducted on two datasets: the established UCI Human Activity Recognition dataset under controlled conditions, and the AAL Smartphone Dataset for HAR in AAL under real-world conditions with heterogeneous, Non-IID data distributions across 22 user-clients. Initial evaluation confirms the system is functional: a federated accuracy of 76.8% versus 84.8% for centralized training quantifies the cost of Non-IID heterogeneity. The quantitative comparison of contribution metrics (Leave-One-Out versus Shapley) for finalizing the incentive mechanism constitutes the next stage of this work.

Keywords: Federated Learning, Human Activity Recognition (HAR), Ambient Assisted Living (AAL), Digital Twin, Game Theory, Stackelberg Game, Shapley Values, Incentive Mechanisms.

Περιεχόμενα

Περίληψη	2
Abstract	4
Κατάλογος σχημάτων	9
Κατάλογος πινάκων	11
Κατάλογος Συντομογραφιών	13
1 Εισαγωγή	14
1.1 Αντικείμενο και Κίνητρο	14
1.2 Σχετικές Εργασίες	15
1.2.1 Αναγνώριση Δραστηριότητας Ανθρώπου	15
1.2.2 Ομοσπονδιακή Μάθηση	16
1.2.3 Μηχανισμοί Κινήτρων στο FL	16
1.2.4 Αξιολόγηση Συνεισφοράς Clients	16
1.2.5 Κενό στη Βιβλιογραφία	17
1.3 Στόχος της Διπλωματικής	17
1.4 Μεθοδολογία	18
1.5 Συνεισφορά στην Επιστήμη	20
1.6 Διάρθρωση της Διπλωματικής	20
2 Υπόβαθρο	22
2.1 Μηχανική Μάθηση και Ανάλυση Σημάτων	22

2.1.1	Συνελικτικά Νευρωνικά Δίκτυα για Χρονοσειρές	22
2.1.2	Δεξαμενή Χαρακτηριστικών και Πλήρης Σύνδεση	23
2.1.3	Σύγκριση με Εναλλακτικές Αρχιτεκτονικές	23
2.2	Ομοσπονδιακή Μάθηση (Federated Learning)	24
2.2.1	Αρχιτεκτονική Server-Client	24
2.2.2	Ο Αλγόριθμος FedAvg	24
2.2.3	Προκλήσεις του Federated Learning	25
2.2.4	Ιδιωτικότητα στο FL	26
2.3	Αναγνώριση Δραστηριότητας Ανθρώπου (HAR)	26
2.3.1	Αισθητήρες Κινητών Συσκευών	26
2.3.2	Τεμαχισμός Σήματος με Συρόμενο Παράθυρο	27
2.3.3	Κλάσεις Δραστηριότητας	27
2.3.4	Προκλήσεις Αναγνώρισης σε Πραγματικές Συνθήκες	27
2.4	Ψηφιακός Δίδυμος Χρήστη (Digital Twin)	28
2.4.1	Στρώματα Αρχιτεκτονικής	28
2.4.2	Ψηφιακός Δίδυμος στο FL Σύστημα	29
2.5	Θεωρία Παιγνίων και Μηχανισμοί Κινήτρων	29
2.5.1	Το Παίγνιο Stackelberg	30
2.5.2	Ισορροπία Stackelberg και Βελτιστοποίηση Server	30
2.5.3	Εφαρμογή στο FL Σύστημα	31
2.6	Αξιολόγηση Συνεισφοράς (Shapley Values)	31
2.6.1	Συνεργατικά Παίγνια και Συναρτήσεις Χαρακτηριστικής	31
2.6.2	Ορισμός και Ιδιότητες Shapley Value	32
2.6.3	Υπολογιστική Πολυπλοκότητα και Προσεγγίσεις	32
3	Ανάλυση Δεδομένων και Προ-επεξεργασία	33
3.1	Περιγραφή των Datasets	33

3.1.1	UCI Human Activity Recognition Dataset	34
3.1.2	AAL Smartphone Dataset	35
3.2	Διερευνητική Ανάλυση Δεδομένων (EDA)	36
3.2.1	Ακεραιότητα και Ποιότητα Δεδομένων	36
3.2.2	Κατανομή Κλάσεων	37
3.2.3	Περιγραφικά Στατιστικά ανά Κανάλι	38
3.2.4	Κατανομή Τιμών και Έλεγχος Κανονικότητας	39
3.2.5	Χρονική Ανάλυση του Σήματος	39
3.2.6	Ανάλυση στο Πεδίο Συχνοτήτων	41
3.2.7	Συσχετίσεις Καναλιών	42
3.2.8	Διαχωρισιμότητα Κλάσεων	43
3.2.9	Ανίχνευση Outliers — Πολλαπλές Μέθοδοι	43
3.2.10	Ετερογένεια Χρηστών	45
3.2.11	Συμπεράσματα για τη Σχεδίαση FL	47
3.3	Αγωγός Προ-επεξεργασίας (Preprocessing Pipeline)	47
3.3.1	Αφαίρεση Θορύβου	48
3.3.2	Κανονικοποίηση	48
3.3.3	Τεμαχισμός με Συρόμενο Παράθυρο	49
4	Υλοποίηση και Μεθοδολογία	51
4.1	Σχεδιασμός του Νευρωνικού Δικτύου	51
4.1.1	Μορφή Εισόδου	51
4.1.2	Αρχιτεκτονική	51
4.1.3	Κεφαλή Ταξινόμησης	53
4.1.4	Εκπαίδευση	53
4.2	Ανάπτυξη του Federated Framework	53
4.2.1	Αρχιτεκτονική Server-Client	54

4.2.2	Τοπική Εκπαίδευση	54
4.2.3	Στάθμιση FedAvg	54
4.2.4	Γύροι Επικοινωνίας	55
4.2.5	Non-IID Διαχωρισμός	55
4.3	Ο Μηχανισμός Κινήτρων	55
4.3.1	Το Πρόβλημα και οι Σχεδιαστικοί Στόχοι	55
4.3.2	Δομικά Στοιχεία ενός Μηχανισμού	56
4.3.3	Επτά Υποψήφιοι Μηχανισμοί	57
4.3.4	Κριτήρια Αξιολόγησης	63
4.3.5	Συγκριτική Ανάλυση	63
4.3.6	Shortlist Επιλογής	64
4.3.7	Σύνοψη Ενότητας	66
5	Ανάλυση και Υπολογισμός Συνεισφοράς	67
5.1	Μετρικές Βασισμένες στον Όγκο	67
5.2	Μετρικές Βασισμένες στην Απόδοση	67
5.3	Προσέγγιση με Shapley Values	67
5.4	Gradient-Based Ομοιότητα	67
5.5	Σύγκριση Μεθόδων και Σύνδεση με EDA	67
6	Πειραματική Διαδικασία και Αποτελέσματα	68
6.1	Ρύθμιση Πειραμάτων	68
6.2	Σύγκριση Datasets	68
6.3	Απόδοση Federated Learning	68
6.4	Αποτελέσματα Αξιολόγησης Συνεισφοράς	68
6.5	Επίδραση των Κινήτρων	68
6.6	Ενσωμάτωση Digital Twin	68

7	Επίλογος	69
7.1	Συμπεράσματα	69
7.2	Ανοικτά Ζητήματα	69
7.3	Πιθανές Επεκτάσεις	69
	Βιβλιογραφία	70

Κατάλογος σχημάτων

1.1	Συνολική αρχιτεκτονική του συστήματος: αισθητήρες τροφοδοτούν το τοπικό Digital Twin (1D-CNN), τα βάρη μοντέλου αποστέλλονται στον FL Server (FedAvg), η αξιολόγηση συνεισφοράς (LOO/Shapley) τροφοδοτεί τον Stackelberg μηχανισμό κινήτρων, και οι ανταμοιβές επιστρέφουν στους clients ενθαρρύνοντας συνεχή συμμετοχή.	19
2.1	Κύκλος ενός FL γύρου (FedAvg): ο server εκπέμπει τις τρέχουσες παραμέτρους, κάθε client εκτελεί E τοπικές εποχές χωρίς κοινοποίηση δεδομένων, και τα ενημερωμένα βάρη συνδυάζονται σταθμισμένα για το επόμενο global μοντέλο.	25
2.2	Αρχιτεκτονική DT+FL: κάθε χρήστης AAL αντιστοιχεί σε έναν Ψηφιακό Δίδυμο που αποθηκεύει τοπικά τα ακατέργαστα δεδομένα αισθητήρων και στέλνει στον FL server μόνο ενημερώσεις βαρών μοντέλου ($\Delta \mathbf{w}_i$). Ο server συγκεντρώνει, αξιολογεί τη συνεισφορά και κατανέμει ανταμοιβές [30, 29].	29
2.3	Δομή του Παιγνίου Stackelberg στο FL σύστημα. Ο server (Leader) ανακοινώνει πρώτος τη βέλτιστη πολιτική ανταμοιβών $\{r_i^*\}$. Κάθε client (Follower) αποκρίνεται επιλέγοντας το επίπεδο προσπάθειας e_i^* που μεγιστοποιεί τη δική του ωφελιμότητα. Η ισορροπία είναι μοναδική και αποδοτική [12].	31
3.1	Κατανομή κλάσεων — UCI HAR Dataset.	37
3.2	Κατανομή κλάσεων — AAL Dataset.	37
3.3	Boxplots τιμών ανά κλάση δραστηριότητας για τρία αντιπροσωπευτικά κανάλια του UCI HAR (μετά από z-score normalization).	38
3.4	Έλεγχος κανονικότητας (UCI HAR): ιστογράμματα (πάνω γραμμή) με εφαρμοσμένη κανονική κατανομή και Q-Q plots (κάτω γραμμή) για τρία αντιπροσωπευτικά κανάλια.	39
3.5	Χρονοσειρές τριαξονικής επιτάχυνσης σώματος ανά κλάση — UCI HAR (κανονικοποιημένα δεδομένα, 128 δείγματα @ 50 Hz).	40

3.6	Μέση συνάρτηση αυτοσυσχέτισης (ACF) για το κανάλι <code>body_acc_x</code> ανά κλάση — UCI HAR.	40
3.7	Μέση PSD ανά κλάση (κανάλι <code>body_acc_x</code> , UCI HAR) — Welch μέθοδος. Οι dominant frequencies εμφανίζονται στην legend.	41
3.8	Πίνακες συσχετίσεων Pearson μεταξύ των 9 καναλιών UCI HAR. Αριστερά: όλες οι κλάσεις, μέση: δυναμικές μόνο, δεξιά: στατικές μόνο.	42
3.9	Διαχωρισιμότητα κλάσεων — UCI HAR. Αριστερά: scree plot PCA. Κέντρο: scatter στις δύο πρώτες κύριες συνιστώσες. Δεξιά: t-SNE embedding σε υποδείγμα $n = 3000$	43
3.10	Outlier detection στο UCI HAR. Αριστερά: ποσοστό flagged παραθύρων ανά μέθοδο. Κέντρο: Jaccard similarity μεταξύ μεθόδων. Δεξιά: κατανομή ψήφων (consensus όταν ≥ 2 μέθοδοι συμφωνούν).	44
3.11	Ετερογένεια χρηστών — UCI HAR (21 subjects). Αριστερά: heatmap κατανομής κλάσεων ανά subject. Κέντρο: JSD ² labels ανά subject. Δεξιά: μέση Wasserstein features ανά subject.	45
3.12	Ετερογένεια χρηστών — AAL (22 subjects). Οι ίδιες τρεις όψεις όπως στην Εικόνα 3.11.	46
3.13	Αγωγός προ-επεξεργασίας από ακατέργαστο σήμα αισθητήρα σε τανυστή εισόδου CNN. (1) Ακατέργαστο σήμα (κίνηση + βαρύτητα). (2) Φίλτρο Butterworth 3ης τάξης ($f_c = 0,3$ Hz): εξαγωγή βαρύτητας (πορτοκαλί) και σώματος (κυανό). (3) Z-score κανονικοποίηση ανά client. (4) Sliding window ($W = 128$, 50% επικάλυψη). (5) Τανυστής εξόδου $\mathbf{X} \in \mathbb{R}^{9 \times 128}$. Ο αγωγός εφαρμόζεται τοπικά σε κάθε FL client.	49
4.1	Αρχιτεκτονική 1D-CNN για HAR: δύο συνελκτικά blocks (Conv1d $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ MaxPool) ακολουθούμενα από πλήρως συνδεδεμένη κεφαλή ταξινόμησης.	52

Κατάλογος πινάκων

1.1 Σύγκριση σχετικών εργασιών με το προτεινόμενο σύστημα. (✓ = υποστηρίζεται, — = απουσιάζει)	17
3.1 Βασικά χαρακτηριστικά UCI HAR Dataset.	34
3.2 Βασικά χαρακτηριστικά AAL Dataset.	35
3.3 Σύγκριση UCI HAR και AAL Dataset.	35
3.4 Έλεγχος ποιότητας δεδομένων και για τα δύο datasets.	36
3.5 Μετρικές ανισορροπίας κλάσεων (training set).	38
3.6 Dominant frequencies ανά κλάση (body_acc_x).	41
3.7 Μέτρα διαχωρισιμότητας.	43
3.8 Ποσοστά outliers ανά μέθοδο και για τα δύο datasets.	44
3.9 Σύγκριση ετερογένειας μεταξύ UCI HAR και AAL.	46
3.10 Αντιστοίχιση ευρημάτων EDA σε επιλογές σχεδίασης FL.	47
4.1 Αρχιτεκτονική HAR-CNN: διαστάσεις τανυστή ανά επίπεδο.	52
4.2 Χώρος σχεδιασμού: επιλογές ανά συνιστώσα μηχανισμού κινήτρων.	57
4.3 Συγκριτική αξιολόγηση επτά υποψήφιων μηχανισμών κινήτρων.	64

Κατάλογος Συντομογραφιών

1D-CNN	One-Dimensional Convolutional Neural Network	HAR	Human Activity Recognition
AAL	Ambient Assisted Living	IID	Independent and Identically Distributed
API	Application Programming Interface	IoT	Internet of Things
BN	Batch Normalization	JSD	Jensen--Shannon Divergence
CNN	Convolutional Neural Network	LOO	Leave-One-Out
DNN	Deep Neural Network	LSTM	Long Short-Term Memory
DP	Differential Privacy	MC	Monte Carlo
DT	Digital Twin	ML	Machine Learning
DUTH	Democritus University of Thrace	Non-IID	Non-Independent and Identically Distributed
EDA	Exploratory Data Analysis	ReLU	Rectified Linear Unit
EVAL_ROUNDS	FL rounds for LOO/Shapley evaluation	RNN	Recurrent Neural Network
FedAvg	Federated Averaging	SGD	Stochastic Gradient Descent
FL	Federated Learning	UCI	University of California, Irvine
GPU	Graphics Processing Unit		

Κεφάλαιο 1

Εισαγωγή

Το παρόν κεφάλαιο θέτει το πλαίσιο της εργασίας: παρουσιάζεται η κινητήρια δύναμη πίσω από τη συνδυαστική μελέτη Federated Learning, αναγνώρισης ανθρώπινης δραστηριότητας και μηχανισμών κινήτρων, οι ερευνητικοί στόχοι και η ακολουθούμενη μεθοδολογία, καθώς και η συνεισφορά της εργασίας.

1.1 Αντικείμενο και Κίνητρο

Η γήρανση του πληθυσμού σε συνδυασμό με την αυξανόμενη επικράτηση χρόνιων παθήσεων δημιουργεί έντονες πιέσεις στα συστήματα υγειονομικής περίθαλψης παγκοσμίως. Τα περιβάλλοντα Υποβοηθούμενης Διαβίωσης (Ambient Assisted Living, AAL) αναδύονται ως μία από τις πλέον υποσχόμενες τεχνολογικές λύσεις, παρέχοντας στους ηλικιωμένους και στους ανθρώπους με ειδικές ανάγκες τα μέσα για ανεξάρτητη διαβίωση με ταυτόχρονη συνεχή παρακολούθηση της κατάστασης υγείας τους [1].

Κεντρικό στοιχείο των συστημάτων AAL αποτελεί η Αναγνώριση Δραστηριότητας Ανθρώπου (Human Activity Recognition, HAR), η οποία επιδιώκει την αυτόματη αναγνώριση καθημερινών κινητικών δραστηριοτήτων — όπως το περπάτημα, η ανάβαση σκαλιών, το κάθισμα και η ανάπαυση — μέσω δεδομένων αισθητήρων έξυπνων συσκευών. Η πρόωμη ανίχνευση ανωμαλιών στη δραστηριότητα, όπως αιφνίδιες πτώσεις ή παρατεταμένη ακινησία, επιτρέπει την έγκαιρη παρέμβαση κλινικού προσωπικού, βελτιώνοντας σημαντικά την ποιότητα ζωής και μειώνοντας τον κίνδυνο σοβαρών επιπλοκών [1].

Παρά την αποτελεσματικότητά τους, οι παραδοσιακές προσεγγίσεις μηχανικής μάθησης για HAR βασίζονται στο κεντρικό παράδειγμα (centralized paradigm), σύμφωνα με το οποίο τα ακατέργαστα δεδομένα αισθητήρων μεταφέρονται σε κεντρικούς εξυπηρετητές για εκπαίδευση μοντέλων. Αυτή η προσέγγιση συνεπάγεται σοβαρούς κινδύνους για την ιδιωτικότητα: τα δεδομένα κίνησης και δραστηριότητας φέρουν ευαίσθητες πληροφορίες για τη φυσική κατάσταση, τις συνήθειες και την υγεία του ατόμου [2]. Ερευνητικές εργασίες έχουν αποδείξει ότι μέσω αναλυτικών επιθέσεων ανάκτησης δεδομένων (inference attacks)

είναι δυνατή η εξαγωγή ευαίσθητων χαρακτηριστικών ακόμα και από τις ενημερώσεις παραμέτρων μοντέλου, εάν αυτές δεν προστατευθούν κατάλληλα [2].

Η Ομοσπονδιακή Μάθηση (Federated Learning, FL) [3] προσφέρει μία θεμελιωδώς διαφορετική προσέγγιση: το μοντέλο εκπαιδεύεται τοπικά σε κάθε συσκευή χρήστη και μόνο οι ενημερώσεις παραμέτρων (gradients ή βάρη) αποστέλλονται στον κεντρικό εξυπηρετητή για συνάθροιση. Τα πρωτογενή δεδομένα δεν εγκαταλείπουν ποτέ τη συσκευή, διασφαλίζοντας έτσι την ιδιωτικότητα εκ σχεδιασμού (privacy by design). Ωστόσο, η πρακτική εφαρμογή του FL σε AAL περιβάλλοντα αντιμετωπίζει δύο θεμελιώδεις προκλήσεις που παραμένουν σε μεγάλο βαθμό ανεπίλυτες στη βιβλιογραφία.

Η **πρώτη πρόκληση** αφορά στην *έλλειψη κινήτρων συμμετοχής*. Σε πραγματικά συστήματα, οι χρήστες είναι ορθολογικοί πράκτορες που αξιολογούν το κόστος συμμετοχής (κατανάλωση μπαταρίας, επεξεργαστική ισχύς, εύρος ζώνης) έναντι του οφέλους που λαμβάνουν. Χωρίς κατάλληλους μηχανισμούς κινήτρων, η συμμετοχή παραμένει χαμηλή ή συγκεντρώνεται σε clients με πλεονάζοντες πόρους, υπονομεύοντας τη γενίκευση του μοντέλου [4].

Η **δεύτερη πρόκληση** αφορά στην *αδυναμία δίκαιης αξιολόγησης συνεισφοράς*. Ακόμα και όταν υπάρχουν ανταμοιβές, ο ισοκατανεμημένος υπολογισμός τους αγνοεί το γεγονός ότι διαφορετικοί clients συνεισφέρουν άνισα στη βελτίωση του καθολικού μοντέλου. Clients με σπάνιες κλάσεις δραστηριότητας ή με δεδομένα υψηλής ποιότητας θα πρέπει να ανταμείβονται αναλόγως, ενώ clients με αδύναμη ή πλεονάζουσα συνεισφορά να λαμβάνουν μικρότερη ανταμοιβή [5].

Η παρούσα εργασία απευθύνεται ακριβώς σε αυτό το κενό, προτείνοντας ένα ολοκληρωμένο FL σύστημα για HAR σε AAL περιβάλλοντα που ενσωματώνει ταυτόχρονα μηχανισμό κινήτρων και δίκαιη αξιολόγηση συνεισφοράς.

1.2 Σχετικές Εργασίες

1.2.1 Αναγνώριση Δραστηριότητας Ανθρώπου

Η αναγνώριση δραστηριότητας μέσω αισθητήρων έχει διανύσει μακρά ερευνητική πορεία. Οι πρώτες προσεγγίσεις βασίζονταν σε χειροκίνητη εξαγωγή χαρακτηριστικών (hand-crafted features) και κλασικούς ταξινομητές, ωστόσο η ευρεία διάδοση των έξυπνων κινητών συσκευών επέτρεψε τη συλλογή μεγάλων datasets αισθητήρων και τη μετάβαση σε αρχιτεκτονικές βαθιάς μάθησης. Το καθιερωμένο σύνολο δεδομένων UCI HAR [6] παρέχει δεδομένα επιταχυνσιόμετρου και γυροσκοπίου από 30 εθελοντές για έξι βασικές δραστηριότητες, θέτοντας ένα ευρέως χρησιμοποιούμενο πρότυπο αξιολόγησης.

Η εργασία των Hammerla et al. [7] έδειξε ότι τα βαθιά νευρωνικά δίκτυα — ιδίως τα Συνελκτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks, CNN) και τα δίκτυα Long Short-Term Memory (LSTM) — υπερτερούν σημαντικά των παραδοσιακών μεθόδων στην ανάλυση σημάτων αισθητήρων. Η ολοκληρωμένη ανασκόπηση των Chen et al. [8] συγκρίνει συστηματικά αρχιτεκτονικές CNN, RNN και υβριδικά μοντέλα, αναδεικνύοντας τα 1D-CNN ως ιδιαίτερα κατάλληλα για HAR λόγω της ικανότητάς τους να εξάγουν τοπικά χαρακτηριστικά χρονοσειρών αποδοτικά και χωρίς εκτεταμένη προεπεξεργασία. Παρόμοια ευρήματα αναφέρονται και από τους Liu et al. [1], οι οποίοι εφαρμόζουν FL ειδικά για HAR σε έξυπνα συστήματα υγειονομικής περίθαλψης.

1.2.2 Ομοσπονδιακή Μάθηση

Η Ομοσπονδιακή Μάθηση εισήχθη από τους McMahan et al. [3] με τον αλγόριθμο Federated Averaging (FedAvg), ο οποίος επιτρέπει την αποκεντρωμένη εκπαίδευση μοντέλων με ελάχιστη επικοινωνία μεταξύ server και clients. Η εννοιολογική θεμελίωση του FL και οι εφαρμογές του παρουσιάζονται εκτενώς από τους Yang et al. [9], ενώ οι Li et al. [10] αναλύουν τις βασικές προκλήσεις του πεδίου: ετερογένεια δεδομένων (Non-IID), αναξιοπιστία clients, και κόστος επικοινωνίας. Η εκτενής ανασκόπηση των Kairouz et al. [11] αποτελεί σήμερα ένα από τα πλέον αναφερόμενα έργα στο πεδίο, καλύπτοντας ανοικτά ζητήματα ασφάλειας, ιδιωτικότητας και δικαιοσύνης στο FL.

1.2.3 Μηχανισμοί Κινήτρων στο FL

Η μοντελοποίηση κινήτρων συμμετοχής στο FL μέσω θεωρίας παιγνίων αποτελεί ενεργό ερευνητικό πεδίο. Οι Kang et al. [4] πρότειναν έναν μηχανισμό βασισμένο στο παίγνιο Stackelberg για κινητά δίκτυα, στον οποίο ο server (leader) καθορίζει ανταμοιβές και οι clients (followers) βελτιστοποιούν την προσπάθειά τους. Οι Sarikaya και Ercetin [12] απέδειξαν την ύπαρξη μοναδικής λύσης Nash Equilibrium στο αντίστοιχο παίγνιο. Οι Yu et al. [13] εισήγαγαν περιορισμούς δικαιοσύνης (fairness constraints) στον μηχανισμό ανταμοιβής, αποτρέποντας την εκμετάλλευση των αδύναμων clients από τους ισχυρότερους. Ωστόσο, καμία από αυτές τις εργασίες δεν συνδυάζει τον μηχανισμό κινήτρων με συστηματική αξιολόγηση της ποιότητας της συνεισφοράς κάθε client.

1.2.4 Αξιολόγηση Συνεισφοράς Clients

Για την αξιολόγηση της συνεισφοράς, οι Wang et al. [5] εφάρμοσαν πρώτοι τα Shapley Values [14] από τη Συνεργατική Θεωρία Παιγνίων στο πλαίσιο του FL, αναδεικνύοντάς τα

ως θεωρητικά θεμελιωμένο μέτρο δίκαιης κατανομής ανταμοιβών. Οι Gopinathan et al. [15] επέκτειναν αυτή την προσέγγιση, ενώ οι Xu et al. [16] πρότειναν μια αποδοτική προσέγγιση βασισμένη στη ομοιότητα gradients (gradient-based Shapley approximation), μειώνοντας δραστικά την υπολογιστική πολυπλοκότητα. Τα ανωτέρω έργα αντιμετωπίζουν όμως το πρόβλημα της αξιολόγησης συνεισφοράς ανεξάρτητα από κάποιο μηχανισμό κινήτρων, χωρίς να κλείνουν τον βρόχο μεταξύ αξιολόγησης και ανταμοιβής.

1.2.5 Κενό στη Βιβλιογραφία

Από την ανασκόπηση της βιβλιογραφίας προκύπτει ότι, παρά τη σημαντική πρόοδο σε κάθε έναν από τους ανωτέρω τομείς χωριστά, δεν υπάρχει ολοκληρωμένη εργασία που να συνδυάζει: (α) FL για HAR σε AAL περιβάλλοντα, (β) μηχανισμό κινήτρων βασισμένο σε θεωρία παιγνίων, και (γ) δίκαιη αξιολόγηση συνεισφοράς μέσω Shapley Values. Ο Πίνακας 1.1 συγκρίνει τις βασικότερες εργασίες ως προς αυτές τις τέσσερις διαστάσεις.

Πίνακας 1.1: Σύγκριση σχετικών εργασιών με το προτεινόμενο σύστημα. (✓ = υποστηρίζεται, — = απουσιάζει)

Εργασία	FL	HAR	Κίνητρα	Shapley/LOO	AAL
Hammerla et al. [7]	---	✓	---	---	---
Chen et al. [8]	---	✓	---	---	---
Liu et al. [1]	✓	✓	---	---	---
McMahan et al. [3]	✓	---	---	---	---
Kang et al. [4]	✓	---	✓	---	---
Sarikaya & Ercetin [12]	✓	---	✓	---	---
Yu et al. [13]	✓	---	✓	---	---
Wang et al. [5]	✓	---	---	✓	---
Gopinathan et al. [15]	✓	---	---	✓	---
Xu et al. [16]	✓	---	---	✓	---
Παρούσα εργασία	✓	✓	✓	✓	✓

Η παρούσα εργασία καλύπτει ακριβώς αυτό το κενό — είναι η μόνη που συνδυάζει και τις τέσσερις διαστάσεις ταυτόχρονα.

1.3 Στόχος της Διπλωματικής

Ο κεντρικός στόχος της παρούσας διπλωματικής εργασίας είναι ο σχεδιασμός και η υλοποίηση ενός ολοκληρωμένου συστήματος Ομοσπονδιακής Μάθησης για Αναγνώριση Δραστηριότητας σε Περιβάλλοντα Υποβοηθούμενης Διαβίωσης. Το σύστημα αντιμετωπίζει ταυτόχρονα τα δύο θεμελιώδη ελλείμματα που εντοπίστηκαν στη βιβλιογραφία (§ 1.1): την

έλλειψη αξιόπιστης μέτρησης συνεισφοράς και την απουσία ολοκληρωμένου μηχανισμού κινήτρων για ρεαλιστικά AAL σενάρια. Συγκεκριμένα, ενσωματώνει:

1. **Μηχανισμό Κινήτρων:** Σχεδιασμός παιγνίου Stackelberg για την παρακίνηση ορθολογικών χρηστών να συνεισφέρουν ποιοτικά δεδομένα, με μαθηματικά αποδεδειγμένη σύγκλιση σε Nash Equilibrium.
2. **Δίκαιη Αξιολόγηση Συνεισφοράς:** Υπολογισμός Shapley Values και μεθόδου Leave-One-Out (LOO) για τη μέτρηση της οριακής συνεισφοράς κάθε client στην αναγνωστική ικανότητα του καθολικού μοντέλου, με προσέγγιση μέσω gradient similarity για αποδοτική εκτέλεση.
3. **Αρχιτεκτονική 1D-CNN:** Σχεδιασμός μονοδιάστατου Συνελικτικού Νευρωνικού Δικτύου ειδικά προσαρμοσμένου για την ανάλυση χρονοσειρών αισθητήρων HAR σε Non-IID συνθήκες FL.
4. **Αξιολόγηση σε Ρεαλιστικές Συνθήκες:** Εκτίμηση απόδοσης τόσο υπό ελεγχόμενες (UCI HAR dataset) όσο και υπό πραγματικές συνθήκες (AAL dataset), με Non-IID κατανομή δεδομένων μεταξύ clients.

Οι παραπάνω στόχοι δεν είναι ανεξάρτητοι: η αξιολόγηση συνεισφοράς τροφοδοτεί τον μηχανισμό κινήτρων, ο μηχανισμός κινήτρων επηρεάζει τη συμμετοχή και άρα την ποιότητα εκπαίδευσης του μοντέλου, και η απόδοση του μοντέλου επαληθεύει τη χρησιμότητα της αξιολόγησης — δημιουργώντας ένα κλειστό βρόχο σχεδιασμού που αξιολογείται ολιστικά στα πειράματα (Κεφάλαιο 6).

1.4 Μεθοδολογία

Για την επίτευξη των ανωτέρω στόχων ακολουθείται η εξής μεθοδολογία:


Μοντέλο Αναγνώρισης. Σχεδιάζεται αρχιτεκτονική 1D-CNN αποτελούμενη από επίπεδα συνέλιξης (Conv1d), κανονικοποίησης και ολοκληρωτικής σύνδεσης (fully-connected layers), κατάλληλη για είσοδο χρονοσειρών αισθητήρων διαστάσεων $[B \times 9 \times 128]$, όπου B είναι το μέγεθος δέσμης, 9 οι κανάλια αισθητήρων (επιταχυνσιόμετρο και γυροσκόπιο ανά άξονα) και 128 τα χρονικά βήματα παραθύρου.

Πλαίσιο Ομοσπονδιακής Εκπαίδευσης. Η αρχιτεκτονική server-client υλοποιείται εξ ολοκλήρου σε PyTorch, με βάση τον αλγόριθμο FedAvg [3]. Η κατανομή των δεδομένων στους clients γίνεται ανά υποκείμενο (by-subject split), εξασφαλίζοντας ρεαλιστική Non-IID κατανομή που αντικατοπτρίζει πραγματικά σενάρια FL.

Μηχανισμός Κινήτρων. Μοντελοποιείται ένα παίγνιο Stackelberg δύο επιπέδων: ο server (leader) βελτιστοποιεί την πολιτική ανταμοιβής r , ενώ οι clients (followers) βελτιστοποιούν την προσπάθειά τους e_i βάσει της συνάρτησης χρησιμότητας $u_i = r_i \cdot q_i - c_i(e_i)$.

Αξιολόγηση Συνεισφοράς. Υλοποιούνται τρεις μέθοδοι αξιολόγησης: (α) μετρικές βάσει όγκου δεδομένων, (β) μέθοδος Leave-One-Out (LOO) και (γ) προσέγγιση Shapley Values μέσω ομοιότητας gradients [16], ισορροπώντας μεταξύ δικαιοσύνης και υπολογιστικής αποδοτικότητας.

Το συνολικό πλαίσιο σχεδίασης και συγγραφής ακολουθεί τις οδηγίες της Algorithms & Privacy Research Unit (Euclid) του Δ.Π.Θ. [17], διασφαλίζοντας συνέπεια ως προς τη δομή, τις βιβλιογραφικές αναφορές και την επιστημονική αυστηρότητα που απαιτείται σε εργασίες του τομέα ιδιωτικότητας και κατανεμημένης μάθησης. Η συνολική ροή του συστήματος — από τους αισθητήρες ως τη διανομή ανταμοιβών — απεικονίζεται στο Σχήμα 1.1.



Σχήμα 1.1: Συνολική αρχιτεκτονική του συστήματος: αισθητήρες τροφοδοτούν το τοπικό Digital Twin (1D-CNN), τα βάρη μοντέλου αποστέλλονται στον FL Server (FedAvg), η αξιολόγηση συνεισφοράς (LOO/Shapley) τροφοδοτεί τον Stackelberg μηχανισμό κινήτρων, και οι ανταμοιβές επιστρέφουν στους clients ενθαρρύνοντας συνεχή συμμετοχή.

1.5 Συνεισφορά στην Επιστήμη

Η παρούσα εργασία συνεισφέρει στο επιστημονικό πεδίο σε τέσσερα συμπληρωματικά επίπεδα, που μαζί καλύπτουν ένα κενό που εντοπίστηκε στη βιβλιογραφία: η πλειοψηφία των υπαρχουσών εργασιών αντιμετωπίζει ένα από τα τρία προβλήματα (ιδιωτικότητα, κίνητρα, ή δικαιοσύνη) σε απομόνωση, χωρίς να τα ενσωματώνει σε ενιαίο λειτουργικό σύστημα αξιολογημένο σε ρεαλιστικό AAL dataset. Τα σημεία συνεισφοράς είναι:

1. **Ολοκληρωμένο σύστημα FL για HAR σε AAL:** Σε αντίθεση με εργασίες που αντιμετωπίζουν μεμονωμένες πτυχές του προβλήματος, η παρούσα εργασία προτείνει ένα ενιαίο πλαίσιο που συνδυάζει ιδιωτικότητα, κίνητρα και δίκαιη αξιολόγηση.
2. **Εφαρμογή παιγνίου Stackelberg σε AAL:** Η προσαρμογή του μηχανισμού Stackelberg στις ιδιαιτερότητες των AAL περιβαλλόντων (ετερογένεια χρηστών, ευαισθησία δεδομένων) αποτελεί πρωτότυπη συνεισφορά.
3. **Συγκριτική αξιολόγηση μεθόδων συνεισφοράς:** Η συστηματική σύγκριση volume-based, LOO και gradient-based Shapley μεθόδων στο πλαίσιο HAR παρέχει νέα εμπειρικά δεδομένα για την επιλογή κατάλληλης μεθόδου ανάλογα με τους υπολογιστικούς πόρους.
4. **Αξιολόγηση σε Non-IID AAL δεδομένα:** Η χρήση του AAL dataset [18] παρέχει μια πιο ρεαλιστική αξιολόγηση σε σχέση με τα συνήθη benchmark datasets ελεγχόμενου περιβάλλοντος.

Συνολικά, η εργασία αποτελεί ένα εμπειρικά θεμελιωμένο πλαίσιο για την ανάπτυξη FL συστημάτων HAR που σέβονται την ιδιωτικότητα, κινητοποιούν τη συμμετοχή και αξιολογούν δίκαια τη συνεισφορά — τρία αλληλένδετα κριτήρια που απαιτούν κοινή αντιμετώπιση για πρακτική εφαρμογή σε AAL περιβάλλοντα.

1.6 Διάρθρωση της Διπλωματικής

Το υπόλοιπο της εργασίας διαρθρώνεται ως εξής:

Το **Κεφάλαιο 2** παρουσιάζει το απαραίτητο θεωρητικό υπόβαθρο: αρχές μηχανικής μάθησης και 1D-CNN για ανάλυση χρονοσειρών, αρχιτεκτονική και αλγορίθμους Ομοσπονδιακής Μάθησης, αρχές Αναγνώρισης Δραστηριότητας, έννοια Ψηφιακού Διδύμου, θεωρία παιγνίων Stackelberg και Shapley Values.

Το **Κεφάλαιο 3** αναλύει τα σύνολα δεδομένων που χρησιμοποιούνται στην εργασία (UCI HAR και AAL), παρουσιάζει Διερευνητική Ανάλυση Δεδομένων (EDA) με έμφαση στην ετερογένεια χρηστών και περιγράφει τον αγωγό προ-επεξεργασίας (preprocessing pipeline).

Το **Κεφάλαιο 4** περιγράφει λεπτομερώς την αρχιτεκτονική του 1D-CNN, την υλοποίηση του FL πλαισίου εξ ολοκλήρου σε PyTorch, και τον σχεδιασμό του μηχανισμού κινήτρων Stackelberg.

Το **Κεφάλαιο 5** παρουσιάζει τις μεθόδους αξιολόγησης συνεισφοράς clients: μετρικές βάσει όγκου, LOO, Shapley Values και gradient-based προσέγγιση.

Το **Κεφάλαιο 6** παρουσιάζει τη ρύθμιση των πειραμάτων και τα αποτελέσματα: σύγκριση datasets, απόδοση FL, αποτελέσματα αξιολόγησης συνεισφοράς και επίδραση των κινήτρων.

Το **Κεφάλαιο 7** συνοψίζει τα συμπεράσματα, αναλύει ανοικτά ζητήματα ασφάλειας και ιδιωτικότητας, και προτείνει κατευθύνσεις μελλοντικής έρευνας.

Κεφάλαιο 2

Υπόβαθρο

Το κεφάλαιο αυτό παρουσιάζει το θεωρητικό υπόβαθρο που απαιτείται για την κατανόηση της προτεινόμενης αρχιτεκτονικής: από τα βασικά της μηχανικής μάθησης και των συνελκτικών δικτύων, μέχρι το Federated Learning, την αναγνώριση δραστηριότητας, τα Ψηφιακά Δίδυμα και τη θεωρία παιγνίων. Κάθε ενότητα εισάγει τις έννοιες που χρησιμοποιούνται άμεσα στην υλοποίηση και τα πειράματα των επόμενων κεφαλαίων.

2.1 Μηχανική Μάθηση και Ανάλυση Σημάτων

Η σύγχρονη ανάλυση σημάτων αισθητήρων βασίζεται σε μεθόδους βαθιάς μάθησης (deep learning), οι οποίες μαθαίνουν αυτόματα ιεραρχικές αναπαραστάσεις από τα ακατέργαστα δεδομένα, χωρίς να απαιτείται χειροκίνητη μηχανική χαρακτηριστικών (feature engineering) [19]. Στο πλαίσιο της διπλωματικής αυτής, ενδιαφερόμαστε ειδικά για την ανάλυση *πολυκαναλικών χρονοσειρών* (multivariate time-series) από επιταχυνσιόμετρα και γυροσκόπια — δεδομένα δηλαδή με έντονη τοπική χρονική δομή και χαμηλή εξάρτηση μεγάλης εμβέλειας.

2.1.1 Συνελκτικά Νευρωνικά Δίκτυα για Χρονοσειρές

Τα Συνελκτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks, CNN) αρχικά αναπτύχθηκαν για την ανάλυση εικόνων, αξιοποιώντας δισδιάστατα φίλτρα (2D kernels) για την εξαγωγή χωρικών χαρακτηριστικών [20]. Ωστόσο, όταν τα δεδομένα εισόδου είναι χρονοσειρές — δηλαδή ακολουθίες μετρήσεων κατά τον χρονικό άξονα — η εφαρμογή μονοδιάστατης συνέλιξης (1D convolution) αποδεικνύεται αποτελεσματικότερη και υπολογιστικά πιο αποδοτική [8].

Ένα **1D-CNN επίπεδο** εφαρμόζει ένα σύνολο από F φίλτρα μήκους k κατά μήκος της χρονικής διάστασης. Για είσοδο $\mathbf{X} \in \mathbb{R}^{C \times T}$ (όπου C είναι ο αριθμός καναλιών και T τα χρονικά βήματα), η έξοδος του φίλτρου f στη θέση t υπολογίζεται ως:

$$h_f(t) = \sigma \left(\sum_{c=1}^C \sum_{\tau=0}^{k-1} W_{f,c,\tau} \cdot X_{c,t+\tau} + b_f \right) \quad (2.1)$$

όπου $W_{f,c,\tau}$ τα εκπαιδευόμενα βάρη του φίλτρου f για κανάλι c και χρονική θέση τ , b_f η μεροληψία (bias) και $\sigma(\cdot)$ η συνάρτηση ενεργοποίησης ReLU: $\sigma(x) = \max(0, x)$.

Κρίσιμο πλεονέκτημα του 1D-CNN έναντι εναλλακτικών αρχιτεκτονικών, όπως τα δίκτυα LSTM [21], είναι η *κοινή χρήση παραμέτρων* (parameter sharing) κατά τον χρονικό άξονα: το ίδιο φίλτρο εφαρμόζεται σε κάθε χρονική θέση, μειώνοντας δραστικά τον αριθμό παραμέτρων και επιταχύνοντας την εκπαίδευση. Επιπλέον, τα 1D-CNNs εκμεταλλεύονται φυσικά την τοπική δομή των σημάτων κίνησης (π.χ. μια βηματική κύκλος διαρκεί 0.5–1 δευτερόλεπτα, κάτι που αποτυπώνεται σε ένα παράθυρο μερικών δεκάδων δειγμάτων).

2.1.2 Δεξαμενή Χαρακτηριστικών και Πλήρης Σύνδεση

Μετά από κάθε συνελικτικό επίπεδο, εφαρμόζεται **Max Pooling** κατά μήκος της χρονικής διάστασης, το οποίο μειώνει την ανάλυση της χρονικής αλληλουχίας κατά παράγοντα 2 (ή μεγαλύτερο), διατηρώντας μόνο την ισχυρότερη ενεργοποίηση σε κάθε παράθυρο. Αυτό προσφέρει *μετατοπιστική αναλλοίωτη* (translation invariance): το δίκτυο αναγνωρίζει τοπικά μοτίβα κίνησης ανεξάρτητα από την ακριβή χρονική θέση τους μέσα στο παράθυρο.

Στο τελικό στάδιο, ο τρισδιάστατος χάρτης χαρακτηριστικών (feature map) ισοπεδώνεται (flatten) σε διάνυσμα και οδηγείται σε πλήρως συνδεδεμένα (fully-connected) επίπεδα, τα οποία παράγουν λογιστικές βαθμολογίες ανά κλάση δραστηριότητας. Η τελική ταξινόμηση γίνεται μέσω *softmax*:

$$p_j = \frac{e^{z_j}}{\sum_{l=1}^K e^{z_l}}, \quad j = 1, \dots, K \quad (2.2)$$

όπου z_j οι λογιστικές βαθμολογίες και $K = 6$ ο αριθμός κλάσεων δραστηριότητας.

2.1.3 Σύγκριση με Εναλλακτικές Αρχιτεκτονικές

Η ολοκληρωμένη ανασκόπηση των Chen et al. [8] αξιολογεί συστηματικά CNN, LSTM και υβριδικές αρχιτεκτονικές για HAR. Τα ευρήματά τους δείχνουν ότι τα 1D-CNN επιτυγχάνουν ανταγωνιστική ακρίβεια συγκριτικά με τα LSTM, ενώ παρουσιάζουν σημαντικά μικρότερο υπολογιστικό κόστος — ιδιότητα κρίσιμη σε FL περιβάλλοντα όπου η τοπική εκπαίδευση γίνεται σε περιορισμένους πόρους (smartphones). Πιο πρόσφατα,

μηχανισμοί *self-attention* (Transformers) [22] έχουν εφαρμοστεί και σε HAR χρονοσειρές, επιτυγχάνοντας υψηλή ακρίβεια, ωστόσο ο σημαντικά μεγαλύτερος αριθμός παραμέτρων τους τα καθιστά λιγότερο κατάλληλα για τοπική εκπαίδευση σε περιβάλλον FL με περιορισμένους πόρους. Για τον λόγο αυτό, η παρούσα εργασία υιοθετεί αρχιτεκτονική 1D-CNN, η οποία περιγράφεται αναλυτικά στην Ενότητα 4.1.

2.2 Ομοσπονδιακή Μάθηση (Federated Learning)

Η Ομοσπονδιακή Μάθηση (Federated Learning, FL) είναι ένα παράδειγμα κατανεμημένης μηχανικής μάθησης στο οποίο ένα καθολικό μοντέλο εκπαιδεύεται από ένα πλήθος n συμμετεχόντων (clients) χωρίς τα ακατέργαστα δεδομένα τους να εγκαταλείπουν ποτέ τη συσκευή τους [3]. Αντί για δεδομένα, μεταδίδονται μόνο ενημερώσεις μοντέλου (model updates) στον κεντρικό συντονιστή (server), ο οποίος τις συνθέτει σε ένα βελτιωμένο καθολικό μοντέλο.

2.2.1 Αρχιτεκτονική Server-Client

Το τυπικό FL σύστημα αποτελείται από έναν **server** και n **clients**. Ο server αρχικοποιεί ένα καθολικό μοντέλο $\mathbf{w}^{(0)}$ και ορίζει τη στρατηγική επιλογής clients ανά γύρο επικοινωνίας. Κάθε client i διατηρεί τοπικό σύνολο δεδομένων $\mathcal{D}_i$ με $n_i = |\mathcal{D}_i|$ δείγματα. Η κατανεμημένη βελτιστοποίηση στοχεύει στην ελαχιστοποίηση της σταθμισμένης συνολικής απώλειας:

$$\min_{\mathbf{w}} F(\mathbf{w}) = \sum_{i=1}^n \frac{n_i}{N} F_i(\mathbf{w}), \quad N = \sum_{i=1}^n n_i \quad (2.3)$$

όπου $F_i(\mathbf{w}) = \frac{1}{n_i} \sum_{(\mathbf{x}, y) \in \mathcal{D}_i} \ell(\mathbf{w}; \mathbf{x}, y)$ είναι η τοπική απώλεια του client i και $\ell(\cdot)$ η συνάρτηση κόστους (cross-entropy για ταξινόμηση).

2.2.2 Ο Αλγόριθμος FedAvg


Ο αλγόριθμος Federated Averaging (FedAvg), που εισήχθη από τους McMahan et al. [3], αποτελεί τον de facto αλγόριθμο αναφοράς του FL. Επαναλαμβάνει τα ακόλουθα βήματα για R γύρους επικοινωνίας:

1. **Κοινοποίηση:** Ο server αποστέλλει τις τρέχουσες παραμέτρους $\mathbf{w}^{(r)}$ στο υποσύνολο $\mathcal{S}^{(r)}$ επιλεγμένων clients (με $|\mathcal{S}^{(r)}| = m \leq n$).

2. **Τοπική εκπαίδευση:** Κάθε client $i \in \mathcal{S}^{(r)}$ εκτελεί E εποχές τοπικής βελτιστοποίησης (SGD ή Adam) στα δεδομένα του, παράγοντας ενημερωμένες παραμέτρους $\mathbf{w}_i^{(r+1)}$.
3. **Συνάθροιση:** Ο server συνθέτει τις ενημερώσεις στάθμισε με βάση το μέγεθος των τοπικών συνόλων:

$$\mathbf{w}^{(r+1)} = \sum_{i \in \mathcal{S}^{(r)}} \frac{n_i}{\sum_{j \in \mathcal{S}^{(r)}} n_j} \mathbf{w}_i^{(r+1)} \quad (2.4)$$

Η θεωρητική ανάλυση σύγκλισης του FedAvg υπό Non-IID κατανομές παρουσιάζεται από τους Li et al. [10], οι οποίοι αποδεικνύουν ότι η ετερογένεια δεδομένων μπορεί να επιβραδύνει σημαντικά τη σύγκλιση λόγω του φαινομένου *client drift*. Το Σχήμα 2.1 απεικονίζει σχηματικά τον κύκλο ενός γύρου FL.



Σχήμα 2.1: Κύκλος ενός FL γύρου (FedAvg): ο server εκπέμπει τις τρέχουσες παραμέτρους, κάθε client εκτελεί E τοπικές εποχές χωρίς κοινοποίηση δεδομένων, και τα ενημερωμένα βάρη συνδυάζονται σταθμισμένα για το επόμενο global μοντέλο.

2.2.3 Προκλήσεις του Federated Learning

Η ολοκληρωμένη ανασκόπηση των Kairouz et al. [11] κατατάσσει τις κύριες προκλήσεις του FL σε τρεις κατηγορίες:

- **Ετερογένεια δεδομένων (Non-IID):** Τα δεδομένα κάθε client ακολουθούν διαφορετική κατανομή, καθώς αντικατοπτρίζουν τις ατομικές συνήθειες και κινητικά μοτίβα κάθε χρήστη. Αυτό αποκλίνει από τη βέλτιστη υπόθεση IID (Independent and Identically Distributed) της στατιστικής θεωρίας [10].
- **Κόστος επικοινωνίας:** Κάθε γύρος απαιτεί μετάδοση ολόκληρου του μοντέλου (ή των παραμέτρων του) μεταξύ server και clients. Για μεγάλα μοντέλα ή αργές συνδέσεις, αυτό αποτελεί σημαντικό περιορισμό [23].

- **Αξιοπιστία clients:** Clients μπορεί να αποσυνδεθούν κατά τη διάρκεια ενός γύρου (stragglers) ή να υποβάλουν ψευδείς ενημερώσεις (Byzantine clients). Η παρούσα εργασία αντιμετωπίζει την πρώτη κατηγορία μέσω του μηχανισμού κινήτρων (Κεφάλαιο 4).

2.2.4 Ιδιωτικότητα στο FL

Παρόλο που το FL δεν μεταδίδει ακατέργαστα δεδομένα, οι ενημερώσεις μοντέλου μπορούν υπό συνθήκες να αποκαλύψουν ευαίσθητες πληροφορίες μέσω *gradient inversion attacks* [2]. Μέθοδοι όπως η Differential Privacy [24] και η ασφαλής συνάθροιση [25] αμβλύνουν αυτόν τον κίνδυνο, αν και βρίσκονται εκτός του άμεσου πεδίου της παρούσας εργασίας.

2.3 Αναγνώριση Δραστηριότητας Ανθρώπου (HAR)

Η Αναγνώριση Δραστηριότητας Ανθρώπου (Human Activity Recognition, HAR) αφορά την αυτόματη κατάταξη της φυσικής δραστηριότητας ενός ατόμου σε προκαθορισμένες κλάσεις, βάσει δεδομένων αισθητήρων κινητής συσκευής [6]. Στο πλαίσιο των συστημάτων AAL, το HAR επιτρέπει την παρακολούθηση της λειτουργικής αυτονομίας χρηστών σε πραγματικό χρόνο, χωρίς να απαιτείται φορετός εξοπλισμός ή υποδομή αισθητήρων στο περιβάλλον [1].

2.3.1 Αισθητήρες Κινητών Συσκευών

Τα σύγχρονα smartphones διαθέτουν ενσωματωμένους αισθητήρες υψηλής ευαισθησίας που καταγράφουν κινηματικές πληροφορίες σε πραγματικό χρόνο:

- **Επιταχυνσιόμετρο (Accelerometer):** Μετρά την γραμμική επιτάχυνση κατά τους τρεις άξονες $\{x, y, z\}$ σε m/s^2 . Συλλαμβάνει δυναμικά μοτίβα (βηματισμός, πτώση) αλλά και στατικές κατευθύνσεις (βαρύτητα ανάλογα με κλίση συσκευής).
- **Γυροσκόπιο (Gyroscope):** Μετρά τον ρυθμό γωνιακής στροφής κατά τους τρεις άξονες σε rad/s . Συμπληρώνει το επιταχυνσιόμετρο αποτυπώνοντας περιστροφικές κινήσεις που δεν ανιχνεύονται από τη γραμμική επιτάχυνση.

Ο συνδυασμός των δύο αισθητήρων παράγει ένα σήμα 6 καναλιών. Στο UCI HAR dataset [6], προστίθενται 3 ακόμα κανάλια (επιταχύνσεις σώματος μετά από αφαίρεση βαρύτητας), οδηγώντας σε είσοδο 9 καναλιών για τα αντίστοιχα μοντέλα μάθησης.

2.3.2 Τεμαχισμός Σήματος με Συρόμενο Παράθυρο

Η ακατέργαστη χρονοσειρά τεμαχίζεται σε παράθυρα σταθερού μήκους με τη μέθοδο *sliding window*. Για μια χρονοσειρά $s(t)$ δειγματοληψίας $f_s = 50$ Hz, το παράθυρο $\mathbf{X}^{(k)}$ αρχίζει στο δείγμα $k \cdot (1 - \rho) \cdot W$ και λήγει W δείγματα αργότερα, όπου W το μήκος παραθύρου (σε δείγματα) και ρ η αναλογία επικάλυψης (overlap). Στο UCI HAR, $W = 128$ δείγματα (2.56 s) και $\rho = 0.5$, αποδίδοντας $\lfloor 2(T/W - 1) \rfloor + 1$ παράθυρα ανά χρονοσειρά.

Κάθε παράθυρο $\mathbf{X}^{(k)} \in \mathbb{R}^{9 \times 128}$ αντιστοιχεί σε ένα δείγμα εισόδου για τον ταξινομητή. Αυτή ακριβώς είναι η μορφή εισόδου $[B \times 9 \times 128]$ που δέχεται η αρχιτεκτονική 1D-CNN (βλ. Ενότητα 4.1).

2.3.3 Κλάσεις Δραστηριότητας

Το UCI HAR dataset [6] περιλαμβάνει δεδομένα από 30 εθελοντές (ηλικία 19--48 ετών) για $K = 6$ κλάσεις δραστηριότητας: *περπάτημα* (Walking), *ανάβαση σκαλιών* (Walking Upstairs), *κατάβαση σκαλιών* (Walking Downstairs), *κάθισμα* (Sitting), *όρθια στάση* (Standing) και *ζάπλωμα* (Laying). Η κατηγοριοποίηση αυτή — τρεις δυναμικές και τρεις στατικές κλάσεις — αποτελεί ευρέως αποδεκτό πρότυπο αξιολόγησης στη βιβλιογραφία HAR [8].

2.3.4 Προκλήσεις Αναγνώρισης σε Πραγματικές Συνθήκες

Παρά τις επιδόσεις σε ελεγχόμενα πειραματικά περιβάλλοντα, το HAR υπό πραγματικές συνθήκες AAL αντιμετωπίζει σημαντικές προκλήσεις [7]:

- **Ατομική μεταβλητότητα:** Διαφορετικοί χρήστες εκτελούν ίδιες δραστηριότητες με εντελώς διαφορετικά κινηματικά μοτίβα — λόγω σωματότυπου, ηλικίας ή τρόπου κρατήματος της συσκευής. Αυτό οδηγεί σε Non-IID κατανομές δεδομένων μεταξύ clients στο FL σύστημα.
- **Θόρυβος αισθητήρων:** Ο θόρυβος αυξάνεται σε πραγματικά AAL σενάρια (άτυπη χρήση τηλεφώνου, κίνηση στο περιβάλλον) σε αντίθεση με τα πρωτόκολλα ελεγχόμενης συλλογής.

- **Ανισορροπία κλάσεων:** Στατικές δραστηριότητες (κάθισμα, ξάπλωμα) καταλαμβάνουν δυσανάλογα μεγαλύτερο χρόνο για ηλικιωμένους χρήστες, δημιουργώντας ανισορροπία στα τοπικά datasets των clients.

Οι ανωτέρω προκλήσεις επιβεβαιώνουν την ανάγκη για αξιολόγηση σε πραγματικά δεδομένα — όπως το AAL dataset [18] — πέρα από τα ελεγχόμενα benchmarks. Ένας πρόσθετος παράγοντας που επηρεάζει ειδικά τα FL συστήματα HAR είναι η ανάπτυξη σε συσκευές περιορισμένων πόρων (smartphones, wearables): η υπολογιστική ισχύς και η μνήμη είναι περιορισμένες, απαιτώντας αρχιτεκτονικές μοντέλων που ισορροπούν ακρίβεια και αποδοτικότητα. Η εργασία των Yao et al. [26] (DeepIoT) δείχνει ότι η συμπίεση μοντέλων για IoT συσκευές είναι εφικτή χωρίς σημαντική απώλεια ακρίβειας — μια κατεύθυνση συμπληρωματική με αυτή της παρούσας εργασίας, η οποία επιλέγει ήδη αρχιτεκτονική με περιορισμένο αριθμό παραμέτρων ($\approx 47k$) για τοπική εκπαίδευση. Παράλληλα, η χρήση πολλαπλών τύπων αισθητήρων (fusion) για βελτίωση της αναγνώρισης σε ρεαλιστικά σενάρια εξετάζεται από τους Gu et al. [27], αναδεικνύοντας ότι η επιλογή των καναλιών εισόδου επηρεάζει σημαντικά την απόδοση σε Non-IID κατανομές.

2.4 Ψηφιακός Δίδυμος Χρήστη (Digital Twin)

Η έννοια του Ψηφιακού Διδύμου (Digital Twin, DT) ορίζεται ως μια δυναμική ψηφιακή αναπαράσταση ενός φυσικού οντότητας ή συστήματος, η οποία ενημερώνεται συνεχώς από ροές δεδομένων πραγματικού χρόνου [28]. Αρχικά αναπτύχθηκε στον χώρο της βιομηχανικής παραγωγής, αλλά η εφαρμογή του στη ψηφιακή υγεία και τα AAL συστήματα αναδεικνύεται ως πεδίο υψηλής ερευνητικής δραστηριότητας [29].

2.4.1 Στρώματα Αρχιτεκτονικής

Ένας Ψηφιακός Δίδυμος χρήστη σε AAL περιβάλλον οργανώνεται σε τρία εννοιολογικά στρώματα [30]:


1. **Στρώμα Δεδομένων (Data Layer):** Συλλέγει ακατέργαστα δεδομένα αισθητήρων από το smartphone (επιταχυνσιόμετρο, γυροσκόπιο) και άλλες πηγές (wearables, έξυπνο σπίτι). Αποτελεί την «αίσθηση» του διδύμου — το τι συμβαίνει στον φυσικό κόσμο.
2. **Στρώμα Μοντέλου (Model Layer):** Εκτελεί επεξεργασία και ταξινόμηση των δεδομένων μέσω μοντέλων μηχανικής μάθησης. Στην παρούσα εργασία, το στρώμα αυτό υλοποιείται από το 1D-CNN μοντέλο HAR που εκπαιδεύεται συνεργατικά μέσω FL.

3. **Στρώμα Υπηρεσιών (Service Layer):** Παρέχει ανθρώπινα αναγνώσιμες πληροφορίες — ειδοποιήσεις, τάσεις δραστηριότητας, αναφορές σε φροντιστές — βάσει των εξόδων του στρώματος μοντέλου.

2.4.2 Ψηφιακός Δίδυμος στο FL Σύστημα

Στο πλαίσιο της παρούσας εργασίας, κάθε client του FL συστήματος αντιστοιχεί σε έναν χρήστη του AAL περιβάλλοντος. Το τοπικό μοντέλο HAR κάθε client λειτουργεί ως *εξατομικευμένος Ψηφιακός Δίδυμος*: αποτυπώνει τα ιδιαίτερα κινηματικά μοτίβα του συγκεκριμένου χρήστη χωρίς να μεταδίδει ευαίσθητα δεδομένα εκτός της συσκευής.

Η έννοια του Ψηφιακού Διδύμου επιβεβαιώνει τη σχεδιαστική επιλογή να διατηρούμε τοπικά δεδομένα στις συσκευές: ο DT κάθε χρήστη ζει στη συσκευή του, ενώ η γνώση (μοντέλο) μεταδίδεται στον server μέσω FL. Αυτή η αρχιτεκτονική εκμεταλλεύεται τα πλεονεκτήματα τόσο του FL (προστασία ιδιωτικότητας) όσο και του DT (εξατομίκευση και συνεχής ενημέρωση). Η συνολική αρχιτεκτονική DT+FL αποτυπώνεται στο Σχήμα 2.2.



Σχήμα 2.2: Αρχιτεκτονική DT+FL: κάθε χρήστης AAL αντιστοιχεί σε έναν Ψηφιακό Δίδυμο που αποθηκεύει τοπικά τα ακατέργαστα δεδομένα αισθητήρων και στέλνει στον FL server μόνο ενημερώσεις βαρών μοντέλου (Δw_i). Ο server συγκεντρώνει, αξιολογεί τη συνεισφορά και κατανέμει ανταμοιβές [30, 29].

2.5 Θεωρία Παιγνίων και Μηχανισμοί Κινήτρων

Σε ένα FL σύστημα, η συμμετοχή των clients δεν είναι δεδομένη: κάθε client επωμίζεται πραγματικό κόστος (κατανάλωση μπαταρίας, υπολογιστικοί πόροι, χρόνος επικοινωνίας) και, απουσία κινήτρων, έχει λόγο να αρνηθεί ή να συμμετάσχει με χαμηλή ποιότητα (free-riding)

[4]. Η Θεωρία Παιγνίων παρέχει το μαθηματικό πλαίσιο για τον σχεδιασμό μηχανισμών κινήτρων που εξασφαλίζουν εθελοντική, ποιοτική συμμετοχή [31].

2.5.1 Το Παίγνιο Stackelberg

Το **Παίγνιο Stackelberg** (Stackelberg Game) είναι ένα παίγνιο δύο επιπέδων με ασύμμετρους ρόλους [12]:

- **Ηγέτης (Leader):** Ο server του FL, ο οποίος ανακοινώνει πρώτος τη στρατηγική ανταμοιβής — δηλαδή, πόση αμοιβή r_i θα λάβει ο client i για τη συμμετοχή του.
- **Ακόλουθοι (Followers):** Οι clients, οι οποίοι παρατηρούν τη στρατηγική του server και επιλέγουν το επίπεδο προσπάθειας e_i που μεγιστοποιεί τη δική τους ωφελιμότητα.

Η ωφελιμότητα (utility) κάθε client i ορίζεται ως:

$$u_i = r_i \cdot q_i(e_i) - c_i(e_i) \quad (2.5)$$

όπου r_i η αμοιβή που ορίζει ο server, $q_i(e_i)$ η ποιότητα της συνεισφοράς (αύξουσα συνάρτηση της προσπάθειας) και $c_i(e_i)$ το κόστος προσπάθειας (αύξουσα κυρτή συνάρτηση). Ο client επιλέγει $e_i^* = \arg \max_{e_i} u_i$, οδηγώντας σε βέλτιστη απόκριση ανάλογη της αμοιβής.

2.5.2 Ισορροπία Stackelberg και Βελτιστοποίηση Server


Γνωρίζοντας ότι οι clients θα ακολουθήσουν τη βέλτιστη απόκρισή τους $e_i^*(r_i)$, ο server επιλύει ένα πρόβλημα βελτιστοποίησης πρώτου επιπέδου:

$$\max_{\{r_i\}} U_{\text{server}} = V \left(\sum_i q_i(e_i^*(r_i)) \right) - \sum_i r_i \cdot q_i(e_i^*(r_i)) \quad (2.6)$$

όπου $V(\cdot)$ η αξία της συνολικής ποιότητας συμμετοχής για τη βελτίωση του καθολικού μοντέλου, μείον το συνολικό κόστος αμοιβών. Η λύση του προβλήματος παρέχει τις βέλτιστες αμοιβές $\{r_i^*\}$ που μεγιστοποιούν το κέρδος του server ενώ παράλληλα εξασφαλίζουν την ενεργό συμμετοχή των clients.

2.5.3 Εφαρμογή στο FL Σύστημα

Στην παρούσα εργασία, ο μηχανισμός κινήτρων βασισμένος στο Παίγνιο Stackelberg υλοποιείται στον εξυπηρετητή (server) του custom FL πλαισίου (Κεφάλαιο 4). Η ποιότητα συνεισφοράς q_i υπολογίζεται μέσω της αξιολόγησης Shapley (§ 2.6), δημιουργώντας έναν κλειστό βρόχο: καλύτερη συνεισφορά $\rightarrow$ υψηλότερη αμοιβή $\rightarrow$ κίνητρο για ποιοτική συμμετοχή [32, 13]. Η δομή του παιγνίου αποτυπώνεται στο Σχήμα 2.3.



Σχήμα 2.3: Δομή του Παιγνίου Stackelberg στο FL σύστημα. Ο server (Leader) ανακοινώνει πρώτος τη βέλτιστη πολιτική ανταμοιβών $\{r_i^*\}$. Κάθε client (Follower) αποκρίνεται επιλέγοντας το επίπεδο προσπάθειας e_i^* που μεγιστοποιεί τη δική του ωφελιμότητα. Η ισορροπία είναι μοναδική και αποδοτική [12].

2.6 Αξιολόγηση Συνεισφοράς (Shapley Values)

Ένα κεντρικό ερώτημα στα συνεργατικά συστήματα είναι: *πόσο συνέβαλε κάθε συμμετέχων στο συνολικό αποτέλεσμα;* Στο πλαίσιο του FL, αυτό αντιστοιχεί στο ερώτημα πόσο βελτίωσε κάθε client το καθολικό μοντέλο. Η απάντηση δίνεται μέσω της θεωρίας Συνεργατικών Παιγνίων (Cooperative Game Theory) και ειδικότερα μέσω των *τιμών Shapley* [14].

2.6.1 Συνεργατικά Παίγνια και Συναρτήσεις Χαρακτηριστικής

Ένα συνεργατικό παίγνιο ορίζεται ως ζεύγος (N, v) , όπου $N = \{1, \dots, n\}$ το σύνολο παικτών (clients) και $v : 2^N \rightarrow \mathbb{R}$ η **συνάρτηση χαρακτηριστικής** (characteristic function) που αποδίδει μια αξία σε κάθε υποσύνολο $S \subseteq N$ [5]. Στο HAR-FL σύστημά μας, $v(S)$

αντιστοιχεί στην ακρίβεια του μοντέλου που θα προέκυπτε αν μόνο το υποσύνολο S clients συμμετείχε στην εκπαίδευση.

2.6.2 Ορισμός και Ιδιότητες Shapley Value

Η τιμή Shapley $\phi_i(v)$ αποδίδει στον παίκτη i το σταθμισμένο μέσο περιθώριο συνεισφοράς σε όλες τις δυνατές σειρές εισόδου:

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)] \quad (2.7)$$

Ο παράγοντας $[v(S \cup \{i\}) - v(S)]$ μετράει την *οριακή συνεισφορά* (marginal contribution) του client i όταν εντάσσεται στο υποσύνολο S . Ο συντελεστής $|S|! (|N| - |S| - 1)! / |N|!$ σταθμίζει αναλόγως με την πιθανότητα εμφάνισης αυτής της σειράς.

Οι τιμές Shapley ικανοποιούν τέσσερις αξιωματικές ιδιότητες: *αποδοτικότητα* (το σύνολο της αξίας κατανέμεται πλήρως), *συμμετρία* (ίδια συνεισφορά $\rightarrow$ ίδια ανταμοιβή), *μηδενικός παίκτης* (μηδενική συνεισφορά $\rightarrow$ μηδενική ανταμοιβή) και *προσθετικότητα*. Αυτές οι ιδιότητες εγγυώνται τη *δικαιοσύνη* (fairness) της κατανομής ανταμοιβών [14].

2.6.3 Υπολογιστική Πολυπλοκότητα και Προσεγγίσεις

Ο ακριβής υπολογισμός της Eq. (2.7) απαιτεί αξιολόγηση $v(S)$ για 2^n υποσύνολα — εκθετική πολυπλοκότητα που καθιστά τον ακριβή υπολογισμό απαγορευτικό για $n > 20$. Στην πράξη χρησιμοποιείται η **προσέγγιση Leave-One-Out (LOO)**:

$$\hat{\phi}_i = v(N) - v(N \setminus \{i\}) \quad (2.8)$$

η οποία υπολογίζει την οριακή συνεισφορά κάθε client ως διαφορά ακρίβειας με και χωρίς τον client i , απαιτώντας μόνο $n + 1$ αξιολογήσεις [15]. Εναλλακτικά, η *gradient-based* προσέγγιση εκτιμά τη συνεισφορά από τις κλίσεις (gradients) χωρίς επαναξιολόγηση μοντέλου [32].

Στην παρούσα εργασία, η LOO προσέγγιση χρησιμοποιείται ως η ποσότητα q_i του μηχανισμού κινήτρων (§ 2.5), υπολογιζόμενη στον server μετά από κάθε γύρο FL (βλ. Ενότητα 4.3).

Κεφάλαιο 3

Ανάλυση Δεδομένων και Προ-επεξεργασία

Το κεφάλαιο αυτό περιγράφει τα σύνολα δεδομένων που χρησιμοποιούνται στην εργασία, αναλύει τα χαρακτηριστικά τους μέσω διερευνητικής ανάλυσης δεδομένων (EDA), και παρουσιάζει τον αγωγό προ-επεξεργασίας. Τα ευρήματα της EDA — ιδίως η Non-IID ετερογένεια μεταξύ subjects — τεκμηριώνουν τις σχεδιαστικές επιλογές για τη μέθοδο αξιολόγησης συνεισφοράς που αναπτύσσεται στα Κεφάλαια 5 και 6.

3.1 Περιγραφή των Datasets

Η πειραματική αξιολόγηση της παρούσας εργασίας στηρίζεται σε δύο συμπληρωματικά σύνολα δεδομένων: το ευρέως αναφερόμενο UCI HAR ως σημείο αναφοράς (baseline) σε ελεγχόμενο περιβάλλον, και το AAL Smartphone Dataset ως κύριο πειραματικό σύνολο σε συνθήκες πραγματικής χρήσης.

3.1.1 UCI Human Activity Recognition Dataset

Το **UCI HAR Dataset** [6] αποτελεί το πλέον ευρέως χρησιμοποιούμενο σύνολο αναφοράς στη βιβλιογραφία HAR. Συλλέχθηκε από 30 εθελοντές (ηλικίας 19–48 ετών) σε ελεγχόμενο εργαστηριακό περιβάλλον, φορώντας Samsung Galaxy S II στη μέση. Ο αισθητήρας δειγματοληπτεί στα 50 Hz και οι 30 συμμετέχοντες κατανέμονται σε σύνολο εκπαίδευσης (70%, 21 άτομα, 7352 παράθυρα) και σύνολο ελέγχου (30%, 9 άτομα, 2947 παράθυρα). Τα βασικά χαρακτηριστικά συνοψίζονται στον Πίνακα 3.1.

Πίνακας 3.1: Βασικά χαρακτηριστικά UCI HAR Dataset.

Παράμετρος	Τιμή
Συμμετέχοντες	30 (21 train / 9 test)
Ηλικιακό εύρος	19–48 ετών
Περιβάλλον	Ελεγχόμενο (εργαστήριο)
Αισθητήρες	Επιταχυνσιόμετρο + Γυροσκόπιο
Συχνότητα δειγματοληψίας	50 Hz
Μήκος παραθύρου	128 δείγματα (2,56 s)
Επικάλυψη	50%
Κανάλια εισόδου	9
Παράθυρα εκπαίδευσης	7352
Παράθυρα ελέγχου	2947
Αριθμός κλάσεων	6

Κάθε παράθυρο αντιστοιχεί σε ένα διάνυσμα $\mathbf{X}^{(k)} \in \mathbb{R}^{9 \times 128}$, το οποίο αποτελείται από: τριαξονική ολική επιτάχυνση (a_x, a_y, a_z) , τριαξονική γωνιακή ταχύτητα (g_x, g_y, g_z) και τριαξονική επιτάχυνση σώματος (body acceleration, b_x, b_y, b_z) μετά από αφαίρεση της βαρύτητας με low-pass φίλτρο Butterworth. Τα δεδομένα παρέχονται ήδη κανονικοποιημένα στο διάστημα $[-1, 1]$ [6].

Ο διαχωρισμός ανά χρήστη (subject-based split) — εκπαίδευση με 21 subjects (7352 παράθυρα) και έλεγχος με 9 subjects (2947 παράθυρα) — διασφαλίζει ότι η αξιολόγηση γίνεται σε δεδομένα από *άγνωστους* χρήστες, αποτυπώνοντας τη γενικευσιμότητα του μοντέλου. Στο FL σύστημά μας, κάθε subject του training set αντιστοιχίζεται σε έναν client. Το UCI HAR χρησιμοποιείται ως *baseline*: δεδομένου ότι η συλλογή έγινε σε ελεγχόμενες συνθήκες (κάθε εθελοντής εκτέλεσε όλες τις δραστηριότητες σε καθορισμένη ακολουθία), αναμένουμε σχεδόν IID κατανομή labels μεταξύ subjects — υπόθεση που επιβεβαιώνεται ποσοτικά στο §3.2 και θέτει το κατώτατο όριο δυσκολίας για FL.

3.1.2 AAL Smartphone Dataset

Το **AAL Smartphone Dataset** --- το οποίο δημιουργήθηκε από τους Davis & Owusu [33] και διατίθεται δημόσια μέσω του UCI Machine Learning Repository [18] --- επεκτείνει τα δεδομένα του UCI HAR σε συνθήκες πραγματικής Υποβοηθούμενης Διαβίωσης. Συλλέχθηκε από 30 συμμετέχοντες ευρύτερου ηλικιακού φάσματος (22–79 ετών) — συμπεριλαμβανομένων ηλικιωμένων — με smartphone τοποθετημένο στη μέση, στα 50 Hz. Το σύνολο διαχωρίζεται subject-independently σε **22 χρήστες εκπαίδευσης** (οι οποίοι λειτουργούν ως FL clients) και 8 χρήστες ελέγχου· καθώς το dataset δεν παρέχει ρητά αναγνωριστικά συμμετεχόντων (subject IDs), αυτά ανακατασκευάζονται από τη δομή των block της ακολουθίας δραστηριοτήτων (κάθε χρήστης εκτελεί διαδοχικά τις 6 δραστηριότητες). Τα βασικά χαρακτηριστικά του dataset παρατίθενται στον Πίνακα 3.2.

Πίνακας 3.2: Βασικά χαρακτηριστικά AAL Dataset.

Παράμετρος	Τιμή
Συμμετέχοντες	30
Ηλικιακό εύρος	22–79 ετών
Περιβάλλον	Πραγματικές συνθήκες (AAL)
Αισθητήρες	Επιταχυνσιόμετρο + Γυροσκόπιο
Συχνότητα δειγματοληψίας	50 Hz
Αριθμός δειγμάτων (train)	4252
Αριθμός δειγμάτων (test)	1492
Σύνολο δειγμάτων	5744
Αριθμός κλάσεων	6
Αριθμός χαρακτηριστικών	561

Οι έξι κλάσεις δραστηριότητας είναι ίδιες με το UCI HAR (Walking, Walking Upstairs, Walking Downstairs, Sitting, Standing, Laying), καθιστώντας άμεση τη σύγκριση μεταξύ των δύο datasets. Οι βασικές διαφορές που καθιστούν το AAL dataset ουσιαστικά πιο απαιτητικό συνοψίζονται στον Πίνακα 3.3.

Πίνακας 3.3: Σύγκριση UCI HAR και AAL Dataset.

Χαρακτηριστικό	UCI HAR	AAL
Περιβάλλον συλλογής	Εργαστήριο	Πραγματικό
Ηλικιακό εύρος	19–48 ετών	22–79 ετών
Θόρυβος σήματος	Χαμηλός	Υψηλός
Non-IID ετερογένεια	Μέτρια	Υψηλή
Ρόλος στην εργασία	Baseline	Κύριο πείραμα

Η ευρύτερη ηλικιακή ποικιλομορφία των 22–79 ετών ενισχύει την ετερογένεια των κινηματικών μοτίβων μεταξύ subjects, εντείνοντας το Non-IID πρόβλημα και καθιστώντας το AAL dataset πλησιέστερο σε πραγματικά σενάρια AAL παρακολούθησης.

3.2 Διερευνητική Ανάλυση Δεδομένων (EDA)

Η Διερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis, EDA) αποτελεί αναγκαία προεργασία πριν από οποιαδήποτε σχεδιαστική απόφαση για το μοντέλο ή τον αγωγό εκπαίδευσης. Η παρούσα ενότητα παρουσιάζει μια *δομημένη και πλήρη* EDA που διενεργείται ταυτόχρονα σε δύο datasets — UCI HAR (baseline) και AAL (κύριο πείραμα) — *χωρίς αρχική υπόθεση* ότι τα δεδομένα θα χρησιμοποιηθούν σε FL σύστημα. Μόνο στο τέλος (§3.2.11) συνοψίζουμε ποια από τα ευρήματα επηρεάζουν τις επιλογές FL σχεδίασης.

Η ανάλυση διαρθρώνεται σε εννέα θεματικούς άξονες, από τους βασικούς ελέγχους ακεραιότητας έως τις πιο σύνθετες μεθόδους ανίχνευσης outliers και ετερογένειας. Όλα τα γραφήματα και τα αριθμητικά αποτελέσματα παράγονται από το ενιαίο script `comprehensive_eda.py` (διαθέσιμο στο αποθετήριο κώδικα), το οποίο τρέχει σε κάθε dataset και εξάγει τα ίδια είδη αναλύσεων για άμεση σύγκριση.

3.2.1 Ακεραιότητα και Ποιότητα Δεδομένων

Πριν από κάθε στατιστική ανάλυση, απαιτείται έλεγχος ακεραιότητας των δεδομένων: απουσία NaN/Inf τιμών, συνέπεια μεταξύ σχήματος (shape) και αναμενόμενων διαστάσεων, ορθό εύρος labels, και ποσοστό διπλοεγγραφών. Ο Πίνακας 3.4 συνοψίζει τους βασικούς ελέγχους.

Πίνακας 3.4: Έλεγχος ποιότητας δεδομένων και για τα δύο datasets.


Μέτρηση	UCI HAR	AAL
Σχήμα train set	(7352, 9, 128)	(4252, 1, 561)
Σχήμα test set	(2947, 9, 128)	(1492, 1, 561)
Τύπος δεδομένων	float32	float32
NaN / Inf τιμές	0 / 0	0 / 0
Εύρος labels	{1, ..., 6} OK	{1, ..., 6} OK
Διπλοεγγραφές (bitwise)	0	28
Εύρος τιμών (train)	[−1,00, 1,00]	[−16,75, 55,48]

Και τα δύο datasets περνούν τους βασικούς ελέγχους. Οι 28 πανομοιότυπες εγγραφές στο AAL (0,66% του train) αντιστοιχούν πιθανότατα σε πολύ σύντομες ή σχεδόν-σταθερές


καταστάσεις (π.χ. *Laying* για ηλικιωμένο) και διατηρούνται, αφού αποτελούν υπαρκτή πληροφορία και όχι λάθος συλλογής. Αξίζει να σημειωθεί η διαφορά στο εύρος τιμών: το UCI HAR παρέχεται κανονικοποιημένο στο $[-1, 1]$, ενώ το AAL σε raw μονάδες — θέτοντας άμεση ανάγκη για κανονικοποίηση prior στην εκπαίδευση (§3.3).

3.2.2 Κατανομή Κλάσεων

Η Εικόνα 3.1 και η Εικόνα 3.2 παρουσιάζουν την κατανομή των παραθύρων ανά κλάση για τα δύο datasets. Ο Πίνακας 3.5 συνοψίζει τους δείκτες ανισορροπίας.



Σχήμα 3.1: Κατανομή κλάσεων — UCI HAR Dataset.



Σχήμα 3.2: Κατανομή κλάσεων — AAL Dataset.


Πίνακας 3.5: Μετρικές ανισοροπίας κλάσεων (training set).

Μετρική	UCI HAR	AAL
Shannon entropy ($\max = \log_2 6 \approx 2,585$)	2,572	2,572
Κανονικοποιημένη εντροπία	0,995	0,995
Imbalance ratio ($n_{\max}/n_{\min}$)	1,43	1,51
Gini coefficient	0,830	0,830

Και τα δύο datasets παρουσιάζουν **ήπια ανισοροπία** κλάσεων ($IR \approx 1,4-1,5$, εντροπία $\geq 0,995 \times$ μέγιστη), χωρίς ακραίες ή σπάνιες κλάσεις. Αυτό σημαίνει ότι δεν απαιτούνται ειδικές τεχνικές αντιμετώπισης (π.χ. oversampling, class weights) για το overall training — ωστόσο, όπως θα δούμε στην §3.2.10, η εικόνα αλλάζει ριζικά όταν εξετάζουμε την κατανομή *ανά subject*.

3.2.3 Περιγραφικά Στατιστικά ανά Κανάλι

Για το UCI HAR, τα εννέα κανάλια εισόδου (`body_acc`, `body_gyro`, `total_acc` — X/Y/Z έκαστο) έχουν σημαντικά διαφορετικά φυσικά χαρακτηριστικά. Η Εικόνα 3.3 παρουσιάζει την κατανομή τιμών ανά κλάση για τρία αντιπροσωπευτικά κανάλια: `body_acc_x` (γραμμική επιτάχυνση σώματος), `body_gyro_x` (γωνιακή ταχύτητα), και `total_acc_z` (ολική κάθετη επιτάχυνση, περιέχει τη συνιστώσα βαρύτητας).




Σχήμα 3.3: Boxplots τιμών ανά κλάση δραστηριότητας για τρία αντιπροσωπευτικά κανάλια του UCI HAR (μετά από z-score normalization).

Τα boxplots αποκαλύπτουν δύο καθαρά μοτίβα: (α) οι δυναμικές κλάσεις (Walking, W-Up, W-Down) εμφανίζουν σημαντικά ευρύτερες κατανομές (μεγάλη τυπική απόκλιση — κινητικότητα), (β) οι στατικές κλάσεις (Sitting, Standing, Laying) έχουν στενές κατανομές αλλά διαφορετικές μέσες τιμές στο κανάλι `total_acc_z`, που αντανακλά τον διαφορετικό προσανατολισμό της συσκευής. Αυτή η ετερογένεια μεταξύ κλάσεων είναι ακριβώς η πληροφορία που ένα ταξινομητής οφείλει να εκμεταλλευτεί.

3.2.4 Κατανομή Τιμών και Έλεγχος Κανονικότητας

Πολλές κλασικές στατιστικές μέθοδοι (ιδίως z-score outlier detection και γραμμικά μοντέλα) υποθέτουν προσεγγιστικά κανονική κατανομή. Η Εικόνα 3.4 συνδυάζει ιστογράμματα και Q-Q plot για τρία κανάλια του UCI HAR, και ο έλεγχος Shapiro-Wilk εφαρμόζεται σε υποδείγμα $n = 5000$ ανά κανάλι.

Κατανομή τιμών & έλεγχος κανονικότητας — UCI_HAR




Σχήμα 3.4: Έλεγχος κανονικότητας (UCI HAR): ιστογράμματα (πάνω γραμμή) με εφαρμοσμένη κανονική κατανομή και Q-Q plots (κάτω γραμμή) για τρία αντιπροσωπευτικά κανάλια.

Αποτέλεσμα: Και τα 9/9 κανάλια απορρίπτουν την υπόθεση κανονικότητας στο επίπεδο $\alpha = 0,05$. Τα Q-Q plots εμφανίζουν καθαρή απόκλιση στις ουρές, υποδεικνύοντας παρουσία *heavy tails* — αναμενόμενο για σήματα επιταχυνσιόμετρου, όπου κινήσεις κορύφωσης (στιγμιαίες αποδυναμώσεις ή κραδασμοί) παράγουν σπάνια ακραία δείγματα. Πρακτική συνέπεια: μέθοδοι outlier detection που βασίζονται σε Gaussian υπόθεση (z-score) είναι *υπερβολικά ευαίσθητες* — προτιμούμε robust εναλλακτικές (MAD, Isolation Forest, LOF) στην §3.2.9.


3.2.5 Χρονική Ανάλυση του Σήματος

Η μορφολογία των σημάτων ανά κλάση είναι κρίσιμη για την κατανόηση του προβλήματος αναγνώρισης. Η Εικόνα 3.5 παρουσιάζει ένα αντιπροσωπευτικό παράθυρο (2,56 s) των τριών αξόνων επιτάχυνσης σώματος για κάθε μία από τις έξι κλάσεις.



Σχήμα 3.5: Χρονοσειρές τριαξονικής επιτάχυνσης σώματος ανά κλάση — UCI HAR (κανονικοποιημένα δεδομένα, 128 δείγματα @ 50 Hz).

Η Εικόνα 3.6 παρουσιάζει τη συνάρτηση αυτοσυσχέτισης (ACF) ανά κλάση, μέσο όρο πάνω σε δείγμα παραθύρων ($n = 100$):




Σχήμα 3.6: Μέση συνάρτηση αυτοσυσχέτισης (ACF) για το κανάλι `body_acc_x` ανά κλάση — UCI HAR.

Παρατηρούνται δύο ομάδες:

- **Δυναμικές δραστηριότητες:** σαφής περιοδικότητα στην ACF — πρώτο θετικό peak στα $\approx 0,6-0,7$ s, που αντιστοιχεί σε ρυθμό βηματισμού $\approx 1,5$ Hz. Αυτή η χρονική δομή επιτρέπει την εκμετάλλευση της περιοδικότητας από τοπικά συνελκτικά φίλτρα.
- **Στατικές δραστηριότητες:** γρήγορα φθίνουσα ACF (noise-dominated signal), σχεδόν καθόλου περιοδικότητα. Η πληροφορία εδώ βρίσκεται στον μέσο προσανατολισμό της συσκευής, όχι στη δυναμική.

3.2.6 Ανάλυση στο Πεδίο Συχνότητων

Η φασματική ανάλυση αποκαλύπτει τη συνεισφορά κάθε συχνότητας στην ολική ισχύ του σήματος. Χρησιμοποιούμε τη μέθοδο Welch (παράθυρο 64 δειγμάτων) για εκτίμηση της Power Spectral Density.



Σχήμα 3.7: Μέση PSD ανά κλάση (κανάλι `body_acc_x`, UCI HAR) — Welch μέθοδος. Οι dominant frequencies εμφανίζονται στην legend.


Πίνακας 3.6: Dominant frequencies ανά κλάση (`body_acc_x`).

Κλάση	UCI HAR	AAL
Walking	1,56 Hz	0,78 Hz
Walking Upstairs	1,56 Hz	0,78 Hz
Walking Downstairs	1,56 Hz	0,78 Hz
Sitting	0,78 Hz	3,91 Hz
Standing	3,13 Hz	3,91 Hz
Laying	0,78 Hz	3,13 Hz

Το εύρημα είναι σαφές: στο UCI HAR οι τρεις βηματιστικές κλάσεις μοιράζονται την ίδια dominant frequency ($\approx 1,5$ Hz — φυσιολογικός ρυθμός βηματισμού), ενώ οι στατικές κατανέμονται ασταθώς σε διάφορες συχνότητες θορύβου. Στο AAL παρατηρούμε χαμηλότερη dominant frequency για το βηματισμό ($\approx 0,78$ Hz), εύρημα συμβατό με την ηλικιακή σύνθεση του dataset (ηλικιωμένοι εθελοντές με αργότερη ρυθμό βάδισης). Αυτή η πληροφορία είναι *κρίσιμη* για το σχεδιασμό του συνελκτικού δικτύου: τα φίλτρα της πρώτης στρώσης πρέπει να έχουν receptive field ικανοποιητικό για την καταγραφή ενός πλήρους κύκλου βηματισμού (≈ 65 δείγματα @ 50 Hz για βάδιση 0,78 Hz).

3.2.7 Συσχετίσεις Καναλιών

Για το UCI HAR (9 κανάλια), είναι ουσιώδες να ελέγχουμε τον βαθμό redundancy μεταξύ καναλιών, καθώς και τη δομή συσχετίσεων που αλλάζει μεταξύ δυναμικών και στατικών κλάσεων.




Σχήμα 3.8: Πίνακες συσχετίσεων Pearson μεταξύ των 9 καναλιών UCI HAR. **Αριστερά:** όλες οι κλάσεις, **μέση:** δυναμικές μόνο, **δεξιά:** στατικές μόνο.

Οι τρεις πίνακες αποκαλύπτουν ένα ενδιαφέρον φαινόμενο: στις στατικές κλάσεις, τα κανάλια `body_acc` και `total_acc` παρουσιάζουν ισχυρή συσχέτιση ($r > 0,9$ σε πολλούς συνδυασμούς), αφού απουσία κίνησης το body acceleration συγκλίνει στο μηδέν και το total acceleration κυριαρχείται από τη βαρύτητα. Αντιθέτως, στις δυναμικές κλάσεις, η body/total διαφοροποίηση μεταφέρει πραγματικά διακριτή πληροφορία. Το εύρημα αυτό υποστηρίζει τη διατήρηση και των 9 καναλιών ως input: η δομή συσχετίσεων μεταβάλλεται μεταξύ κλάσεων, επομένως αποτελεί αξιοποιήσιμο χαρακτηριστικό.

3.2.8 Διαχωριστικότητα Κλάσεων

Πριν επιλέξουμε ένα σύνθετο μοντέλο (CNN), χρήσιμο είναι να ελέγξουμε κατά πόσο οι κλάσεις διαχωρίζονται σε χαμηλότερες διαστάσεις. Εξάγουμε 54 στατιστικά χαρακτηριστικά ανά παράθυρο (6 ανά κανάλι: mean, std, min, max, energy, dominant freq) και εφαρμόζουμε PCA και t-SNE.



Σχήμα 3.9: Διαχωριστικότητα κλάσεων — UCI HAR. **Αριστερά:** scree plot PCA. **Κέντρο:** scatter στις δύο πρώτες κύριες συνιστώσες. **Δεξιά:** t-SNE embedding σε υποδείγμα $n = 3000$.

Πίνακας 3.7: Μέτρα διαχωριστικότητας.

Μέτρο	UCI HAR	AAL
PCA variance top-2	64,1%	50,8%
PCA variance top-5	77,9%	60,0%
Silhouette (top-2 PCA)	0,150	-0,030

Η PCA σε 2D αποτυπώνει 64% της διακύμανσης στο UCI HAR, και το scatter δείχνει σαφή διαχωρισμό δυναμικών από στατικές κλάσεις. Ωστόσο, εντός ομάδας (π.χ. τρεις βηματιστικές) οι κλάσεις επικαλύπτονται σε μεγάλο βαθμό — γεγονός που επιβεβαιώνεται από τη χαμηλή τιμή silhouette (0,15). Για το AAL, η silhouette είναι **αρνητική** (εκεί που πολλά σημεία είναι πιο κοντά σε άλλη κλάση από τη δική τους), υποδεικνύοντας ότι απλά στατιστικά features δεν αρκούν — απαιτείται μη-γραμμικός learner. Το t-SNE, που αποκαλύπτει τοπικές δομές, δείχνει καθαρότερες νησίδες ανά κλάση, ενισχύοντας την υπόθεση ότι ένα βαθύ μοντέλο μπορεί να μάθει τις σχετικές μη γραμμικές απεικονίσεις.


3.2.9 Ανίχνευση Outliers — Πολλαπλές Μέθοδοι

Η ανίχνευση ακραίων τιμών (outliers) σε δεδομένα αισθητήρων εξυπηρετεί δύο σκοπούς: (α) εντοπισμό σφαλμάτων συλλογής (sensor glitches, mislabeled windows), και

(β) αξιολόγηση της ομοιογένειας του dataset. Δεδομένου ότι καμία μεμονωμένη μέθοδος δεν καλύπτει όλα τα είδη outliers, εφαρμόζουμε **έξι ανεξάρτητες μεθόδους** και αναλύουμε την συμφωνία τους:

1. **IQR**: feature εκτός $Q_1 - 1,5 \cdot \text{IQR}$, $Q_3 + 1,5 \cdot \text{IQR}$.
2. **Z-score** > 3 : κλασικό, υποθέτει κανονικότητα.
3. **Modified Z-score (MAD)** $> 3,5$: robust σε heavy tails [34].
4. **Isolation Forest** [35]: isolation depth σε random trees, contamination = 0,05.
5. **Local Outlier Factor (LOF)** [36]: density-based, $k = 20$.
6. **Mahalanobis distance**: πολυμεταβλητή απόσταση με κατώφλι $\chi^2_{0,99}$.

Όλες οι μέθοδοι εφαρμόζονται στον ίδιο χώρο χαρακτηριστικών (54-διάστατος στο UCI, 561-διάστατος στο AAL). Ένα παράθυρο θεωρείται outlier από univariate μέθοδο όταν $\geq 10\%$ των features του βγαίνουν εκτός — αποφεύγουμε το τετριμμένο «any-feature» που παράγει ψευδώς μεγάλο ποσοστό outliers σε υψηλή διάσταση.



Σχήμα 3.10: Outlier detection στο UCI HAR. **Αριστερά:** ποσοστό flagged παραθύρων ανά μέθοδο. **Κέντρο:** Jaccard similarity μεταξύ μεθόδων. **Δεξιά:** κατανομή ψήφων (consensus όταν ≥ 2 μέθοδοι συμφωνούν).

Πίνακας 3.8: Ποσοστά outliers ανά μέθοδο και για τα δύο datasets.

Μέθοδος	UCI HAR	AAL
IQR	28,4%	11,9%
Z-score > 3	2,2%	1,9%
Modified Z (MAD) $> 3,5$	59,5%	42,0%
Isolation Forest ($c=0,05$)	5,0%	5,0%
LOF ($k = 20$, $c=0,05$)	5,0%	5,0%
Mahalanobis ($\chi^2_{0,99}$)	11,8%	12,3%
Consensus (≥ 2 μέθοδοι)	29,3%	14,7%


Κριτική ανάγνωση των αποτελεσμάτων: το Modified Z-score φλαγάρει πολύ υψηλό ποσοστό (42–60%) επειδή σε ήδη κανονικοποιημένα δεδομένα το MAD είναι πολύ μικρό, καθιστώντας ακόμη και μικρές αποκλίσεις «ακραίες». Αντίθετα, οι τρεις principled πολυμεταβλητές μέθοδοι (Isolation Forest, LOF, Mahalanobis) συγκλίνουν σταθερά σε ≈ 5 –12% σε και τα δύο datasets — ένδειξη ότι εντοπίζουν το ίδιο υποσύνολο πραγματικά ανώμαλων παραθύρων. Η Jaccard ανάλυση (κέντρο της Εικόνας 3.10) επιβεβαιώνει ισχυρή συμφωνία ($J > 0,5$) μεταξύ αυτών των τριών μεθόδων και φτωχή συμφωνία με τις naïve univariate μεθόδους.

Απόφαση: χρησιμοποιούμε ως κριτήριο τη **robust τομή** των τριών πολυμεταβλητών μεθόδων (Isolation Forest $\cap$ LOF $\cap$ Mahalanobis). Τα ~ 3 –4% παράθυρα που κάθε μέθοδος σημειώνει και οι τρεις ταυτόχρονα αντιστοιχούν σε πραγματικά sensor glitches και αφαιρούνται στο preprocessing. Η αφαίρεσή τους έχει αμελητέα επίδραση στο ολικό μέγεθος dataset (−3%) αλλά μειώνει τη διακύμανση του training loss.


3.2.10 Ετερογένεια Χρηστών

Η τελευταία και πιο ενδιαφέρουσα διάσταση της EDA αφορά την ετερογένεια μεταξύ χρηστών (subject-level heterogeneity). Δύο συμπληρωματικά μέτρα εφαρμόζονται: (α) η τετραγωνική απόκλιση Jensen–Shannon (JSD^2) μεταξύ της κατανομής κλάσεων κάθε subject p_i και της καθολικής p_{global} , και (β) η μέση απόσταση Wasserstein μεταξύ της κατανομής features κάθε subject και της συνολικής, υπολογισμένη ανά κανάλι.

$$JSD^2(p_i \| p_{\text{global}}) = \frac{1}{2} D_{\text{KL}}(p_i \| M) + \frac{1}{2} D_{\text{KL}}(p_{\text{global}} \| M), \quad M = \frac{p_i + p_{\text{global}}}{2} \quad (3.1)$$



Σχήμα 3.11: Ετερογένεια χρηστών — UCI HAR (21 subjects). **Αριστερά:** heatmap κατανομής κλάσεων ανά subject. **Κέντρο:** JSD^2 labels ανά subject. **Δεξιά:** μέση Wasserstein features ανά subject.



Σχήμα 3.12: Ετερογένεια χρηστών — AAL (22 subjects). Οι ίδιες τρεις όψεις όπως στην Εικόνα 3.11.

Πίνακας 3.9: Σύγκριση ετερογένειας μεταξύ UCI HAR και AAL.

Μετρική	UCI HAR	AAL
Αριθμός subjects	21	22
$\overline{JSD^2}$	0,0019	0,0397
$JSD_{\max}^2$	0,0104	0,1466
% subjects με $JSD^2 > 0,05$	0%	31,8%
Μέση Wasserstein (features)	0,106	0,120

Το εύρημα είναι ποσοτικά εντυπωσιακό: το UCI HAR παρουσιάζει **σχεδόν IID** κατανομή labels μεταξύ subjects (όλοι οι εθελοντές εκτέλεσαν το ίδιο πρωτόκολλο σε εργαστηριακό περιβάλλον), ενώ το AAL εμφανίζει JSD^2 μέσο $21 \times$ **μεγαλύτερο**, με σχεδόν ένα τρίτο των subjects (32%) να απέχει σημαντικά από την καθολική κατανομή. Η Wasserstein απόσταση features διαφέρει λιγότερο (0,106 vs 0,120), υποδεικνύοντας ότι η κύρια πηγή ετερογένειας στο AAL είναι η **κατανομή δραστηριοτήτων** (κάθε ηλικιωμένος δαπανά διαφορετικό χρόνο σε στατικές vs δυναμικές καταστάσεις) και δευτερευόντως τα φυσιολογικά κινηματικά μοτίβα.

3.2.11 Συμπεράσματα για τη Σχεδίαση FL

Η EDA διεξήχθη ανεξάρτητα από την τελική χρήση· τώρα συνοψίζουμε ποια από τα ευρήματα επηρεάζουν τις επιλογές σχεδίασης του FL συστήματος. Ο Πίνακας 3.10 συνδέει κάθε εύρημα με τη συγκεκριμένη συνέπεια.

Πίνακας 3.10: Αντιστοίχιση ευρημάτων EDA σε επιλογές σχεδίασης FL.

Εύρημα EDA	Συνέπεια για FL
Ήπια ολική ανισορροπία κλάσεων ($IR \approx 1,4-1,5$)	Δεν απαιτούνται global class weights· αρκεί η στάθμιση FedAvg ανά subject.
Non-Gaussian κατανομές τιμών	Προτίμηση robust outlier μεθόδων (IForest/LOF) έναντι z-score.
Δύο μορφολογικές ομάδες (δυναμικές / στατικές) με καθαρή διαχωριστική διαφορά στο PSD	Το 1D-CNN με receptive field ικανό να καλύπτει έναν κύκλο βηματισμού (~ 65 δείγματα @ 0,78 Hz) είναι επαρκής αρχιτεκτονική.
Χαμηλή silhouette στο 2D PCA (ειδικά στο AAL)	Επιβεβαιώνει την ανάγκη για μη-γραμμικό learner αντί για απλό γραμμικό ταξινομητή.
Consensus outliers $\approx 3-5\%$ (robust τομή)	Αφαιρούνται στο <i>sample-level</i> πριν τη διανομή δεδομένων στους clients — εξασφαλίζει σταθερό local training.
Subject-level heterogeneity ($JSD_{AAL}^2 = 21 \times JSD_{UCI}^2$)	Διατηρείται στο ακέραιο — αποτελεί το βασικό φαινόμενο που ο FL μηχανισμός κινήτρων πρέπει να αναγνωρίσει και να ανταμείψει. Subjects S13, S14 του AAL λειτουργούν ως case study (§5).
Redundancy στα κανάλια για στατικές κλάσεις	Κρατάμε και τα 9 κανάλια — η διαφορετική correlation structure μεταξύ κλάσεων είναι αξιοποιήσιμη από το BatchNorm/ReLU stack.

Συνολικό συμπέρασμα: η EDA αιτιολογεί τη χρήση του AAL AAL ως κύριο πειραματικό dataset, όχι ως παράπλευρη επιλογή. Το UCI HAR, σχεδόν IID μεταξύ subjects, θα δώσει τεχνητά υψηλή FL απόδοση ανεξάρτητα από τον μηχανισμό συνεισφοράς — ακριβώς γιατί δεν υπάρχει ετερογένεια για να ανταμειφθεί. Το AAL, αντίθετα, προσφέρει το πραγματικά ενδιαφέρον σενάριο όπου οι μηχανισμοί Shapley/LOO μπορούν να διαφοροποιήσουν την αξία των clients. Αυτό το αποτέλεσμα — αν και όχι προφανές εκ των προτέρων — αναδεικνύεται **μόνο** μέσω αυστηρής σύγκρισης των δύο datasets στο πλαίσιο της παρούσας ανάλυσης.

3.3 Αγωγός Προ-επεξεργασίας (Preprocessing Pipeline)

Η προ-επεξεργασία μετατρέπει τα ακατέργαστα σήματα αισθητήρων σε τυποποιημένη μορφή κατάλληλη για εισαγωγή στον 1D-CNN ταξινομητή. Ο αγωγός αποτελείται από

τρία διαδοχικά στάδια: αφαίρεση θορύβου, κανονικοποίηση και τεμαχισμό με συρόμενο παράθυρο. Εφαρμόζεται ανεξάρτητα σε κάθε client (subject) — κομβική επιλογή για τη διατήρηση της ατομικής κατανομής στο FL σενάριο.

3.3.1 Αφαίρεση Θορύβου

Τα σήματα επιταχυνσιόμετρου και γυροσκοπίου περιέχουν δύο συνιστώσες [6]:

- **Συνιστώσα βαρύτητας (DC):** Χαμηλής συχνότητας σήμα ($< 0,3 \text{ Hz}$) που αντικατοπτρίζει την κλίση της συσκευής ως προς τη βαρύτητα. Σταθερό κατά τη διάρκεια κάθε δραστηριότητας.
- **Συνιστώσα κινητικής επιτάχυνσης (body):** Υψηλής συχνότητας σήμα ($> 0,3 \text{ Hz}$) που απεικονίζει τη δυναμική κίνηση του σώματος. Αυτό είναι το πληροφοριακά χρήσιμο σήμα για HAR.

Ο διαχωρισμός υλοποιείται με **φίλτρο Butterworth 3ης τάξης** με συχνότητα αποκοπής $f_c = 0,3 \text{ Hz}$:

$$|H(j\omega)|^2 = \frac{1}{1 + \left(\frac{\omega}{\omega_c}\right)^{2n}}, \quad n = 3 \quad (3.2)$$

Το low-pass φίλτρο εξάγει τη συνιστώσα βαρύτητας, ενώ η αφαίρεσή της από το ολικό σήμα παράγει το σήμα body acceleration — τα τρία επιπλέον κανάλια (b_x, b_y, b_z) που ανεβάζουν το σύνολο των καναλιών από 6 σε 9 [6].

3.3.2 Κανονικοποίηση

Η κανονικοποίηση διασφαλίζει ότι όλα τα κανάλια συνεισφέρουν ισότιμα στην εκπαίδευση, ανεξάρτητα από τη φυσική μονάδα μέτρησής τους (m/s^2 για επιτάχυνση, rad/s για γωνιακή ταχύτητα). Εφαρμόζεται **Z-score κανονικοποίηση** ανά κανάλι, υπολογισμένη επί του συνόλου εκπαίδευσης κάθε client:

$$\hat{x}_{c,t} = \frac{x_{c,t} - \mu_c}{\sigma_c} \quad (3.3)$$

όπου μ_c και σ_c ο μέσος όρος και η τυπική απόκλιση του καναλιού c υπολογισμένα αποκλειστικά στα δεδομένα εκπαίδευσης του αντίστοιχου client. Η εφαρμογή *ανά client*

— και όχι καθολικά — είναι κρίσιμη: αποφεύγει τη διαρροή πληροφορίας από το σύνολο ελέγχου (data leakage) και τηρεί την αρχή του FL ότι δεδομένα δεν κοινοποιούνται μεταξύ clients.


Στο UCI HAR dataset, τα δεδομένα παρέχονται ήδη κανονικοποιημένα στο $[-1, 1]$, οπότε το βήμα αυτό εφαρμόζεται κυρίως στο AAL Lab dataset [18].

3.3.3 Τεμαχισμός με Συρόμενο Παράθυρο

Η ακατέργαστη χρονοσειρά κάθε client τεμαχίζεται σε παράθυρα σταθερού μήκους με τη μέθοδο *sliding window*, παράγοντας τα δείγματα εισόδου για τον ταξινομητή. Χρησιμοποιούνται οι παράμετροι του UCI HAR [6]:

- **Μήκος παραθύρου:** $W = 128$ δείγματα ($= 2,56$ s στα 50 Hz) — επαρκές για να περιέχει 2–5 πλήρεις κύκλους βηματισμού.
- **Βήμα ολίσθησης:** $S = 64$ δείγματα, αντίστοιχο επικάλυψης $\rho = 50\%$ — διπλασιάζει τον αριθμό παραθύρων και αυξάνει τη διαφορετικότητα των training samples.

Για μια χρονοσειρά T συνολικών δειγμάτων, ο αριθμός παραθύρων είναι $\lfloor (T - W)/S \rfloor + 1$. Κάθε παράθυρο $\mathbf{X}^{(k)} \in \mathbb{R}^{9 \times 128}$ αποτελεί ένα ανεξάρτητο δείγμα εισόδου με ετικέτα $y^{(k)} \in \{1, \dots, 6\}$, ορισμένη ως η δραστηριότητα που κατέχει την πλειοψηφία των δειγμάτων του παραθύρου. Ο συνολικός αγωγός προ-επεξεργασίας απεικονίζεται στο Σχήμα 3.13.



Σχήμα 3.13: Αγωγός προ-επεξεργασίας από ακατέργαστο σήμα αισθητήρα σε τανυστή εισόδου CNN. (1) Ακατέργαστο σήμα (κίνηση + βαρύτητα). (2) Φίλτρο Butterworth 3ης τάξης ($f_c = 0,3$ Hz): εξαγωγή βαρύτητας (πορτοκαλί) και σώματος (κυανό). (3) Z-score κανονικοποίηση ανά client. (4) Sliding window ($W = 128$, 50% επικάλυψη). (5) Τανυστής εξόδου $\mathbf{X} \in \mathbb{R}^{9 \times 128}$. Ο αγωγός εφαρμόζεται τοπικά σε κάθε FL client.

Ο αγωγός εφαρμόζεται **τοπικά σε κάθε client**, σύμφωνα με τις αρχές του FL: τα στατιστικά κανονικοποίησης (μ_c , σ_c) δεν κοινοποιούνται στον server, διατηρώντας την

ιδιωτικότητα των δεδομένων. Η έξοδος κάθε client είναι ένα τοπικό σύνολο παραθύρων $\{\mathbf{X}^{(k)}, y^{(k)}\}_{k=1}^{K_i}$, όπου K_i ο αριθμός παραθύρων του client i .

Αξίζει να σημειωθεί ότι ο αγωγός αυτός δεν εφαρμόζει μείωση διαστατικότητας (dimensionality reduction) ή επιλογή χαρακτηριστικών (feature selection) — τεχνικές που έχουν εξεταστεί εκτενώς στη βιβλιογραφία [37]. Η επιλογή αυτή γίνεται σκόπιμα: ο 1D-CNN εκτελεί αυτόματη εξαγωγή ιεραρχικών χαρακτηριστικών από το ακατέργαστο σήμα, χωρίς να απαιτείται προηγούμενη χειροκίνητη επιλογή. Η χρήση του συνόλου των 9 καναλιών (3 επιταχύνσεις, 3 γωνιακές ταχύτητες, 3 body accelerations) χωρίς περαιτέρω μείωση επιτρέπει στο δίκτυο να ανακαλύψει από μόνο του ποιοι συνδυασμοί καναλιών είναι πληροφοριακοί για κάθε κλάση δραστηριότητας — προσέγγιση που αποδείχθηκε ανώτερη των hand-crafted features στα πειράματα αξιολόγησης [8, 7].

Κεφάλαιο 4

Υλοποίηση και Μεθοδολογία

Το κεφάλαιο αυτό παρουσιάζει αναλυτικά την τεχνική υλοποίηση του συστήματος σε τρεις ενότητες: τη σχεδίαση του 1D-CNN μοντέλου HAR, το Federated Learning πλαίσιο server-client με FedAvg, και τον μηχανισμό κινήτρων Stackelberg. Κάθε ενότητα συνδέει την αρχιτεκτονική επιλογή με τη θεωρητική τεκμηρίωση του Κεφαλαίου 2.

4.1 Σχεδιασμός του Νευρωνικού Δικτύου


Η βαθιά εκμάθηση παρέχει τα κατάλληλα εργαλεία για αυτόματη εξαγωγή χαρακτηριστικών από σύνθετα δεδομένα χωρίς χειροκίνητη μηχανική χαρακτηριστικών [19]. Για τον σκοπό αυτόν σχεδιάστηκε ένα μονοδιάστατο συνελκτικό νευρωνικό δίκτυο (1D-CNN) κατάλληλο για ταξινόμηση δραστηριότητας σε περιβάλλον Federated Learning.

4.1.1 Μορφή Εισόδου

Το σύστημα χρησιμοποιεί τα προ-εξαχθέντα features του dataset AAL, τα οποία αποτελούνται από 561 στατιστικά χαρακτηριστικά χρονικού και συχνοτικού πεδίου ανά παράθυρο [18]. Κάθε δείγμα εισόδου έχει μορφή τανυστή $\mathbf{x} \in \mathbb{R}^{1 \times 561}$, όπου το ένα κανάλι αντιπροσωπεύει την πλήρη ακολουθία feature. Τα 561 features αντιμετωπίζονται ως μονοδιάστατη ακολουθία, επιτρέποντας στις Conv1d λειτουργίες να εντοπίσουν τοπικές συσχετίσεις μεταξύ γειτονικών χαρακτηριστικών.

4.1.2 Αρχιτεκτονική

Το δίκτυο αποτελείται από δύο συνελκτικά blocks ακολουθούμενα από πλήρως συνδεδεμένο κεφαλή ταξινόμησης, όπως απεικονίζεται στο Σχήμα 4.1 και αναλύεται στον Πίνακα 4.1:



Σχήμα 4.1: Αρχιτεκτονική 1D-CNN για HAR: δύο συνελκτικά blocks (Conv1d → BN → ReLU → MaxPool) ακολουθούμενα από πλήρως συνδεδεμένη κεφαλή ταξινόμησης.

Το δίκτυο αποτελείται από δύο συνελκτικά blocks ακολουθούμενα από πλήρως συνδεδεμένο κεφαλή ταξινόμησης (Πίνακας 4.1):

Πίνακας 4.1: Αρχιτεκτονική HAR-CNN: διαστάσεις τανυστή ανά επίπεδο.

Επίπεδο	Τύπος	Παράμετροι	Έξοδος
Είσοδος	—	—	$[B, 1, 561]$
Conv1d + BN + ReLU	συνελκτικό	$1 \rightarrow 64, k=9$	$[B, 64, 561]$
MaxPool1d(2)	υποδειγματοληψία	—	$[B, 64, 280]$
Conv1d + BN + ReLU	συνελκτικό	$64 \rightarrow 128, k=9$	$[B, 128, 280]$
MaxPool1d(2)	υποδειγματοληψία	—	$[B, 128, 140]$
Flatten	αναδιαμόρφωση	—	$[B, 17920]$
Dropout(0.5) + Linear	πλήρης σύνδεση	$17920 \rightarrow 128$	$[B, 128]$
Linear	έξοδος	$128 \rightarrow 6$	$[B, 6]$

Κάθε συνελκτικό block ακολουθεί τη δομή:

$$\mathbf{h} = \text{MaxPool}(\text{ReLU}(\text{BN}(\text{Conv1d}(\mathbf{x})))) \quad (4.1)$$

όπου BN συμβολίζει το Batch Normalization [20]. Η κανονικοποίηση batch είναι ιδιαίτερα κρίσιμη σε περιβάλλον FL, καθώς κάθε client έχει ιδιόζουσα κατανομή δεδομένων — το BN σταθεροποιεί τη ροή gradients ανεξάρτητα από τα per-client statistics.

4.1.3 Κεφαλή Ταξινόμησης

Μετά τη δισδιάστατη αναδιαμόρφωση (flatten), η αλληλουχία $[B, 128 \times 140] = [B, 17920]$ οδηγείται σε δύο πλήρως συνδεδεμένα επίπεδα με ενδιάμεσο Dropout($p=0.5$). Το Dropout λειτουργεί ως κανονιστής — αποτρέπει την υπερπροσαρμογή (overfitting) σε μικρά client datasets, που είναι συνηθισμένη κατάσταση στο FL [19].

Η έξοδος είναι ένα διάνυσμα logits $\hat{\mathbf{y}} \in \mathbb{R}^6$. Κατά την εκπαίδευση, το CrossEntropyLoss υπολογίζει απευθείας από τα logits χωρίς επιπλέον softmax, για αριθμητική σταθερότητα.

4.1.4 Εκπαίδευση

Ως βελτιστοποιητής χρησιμοποιείται ο Adam [38] με $\text{lr} = 10^{-3}$, ο οποίος προσαρμόζει αυτόματα το βήμα μάθησης ανά παράμετρο και συγκλίνει αξιόπιστα χωρίς ευαίσθητη ρύθμιση. Συνολικά, το δίκτυο έχει **2.369.542 εκπαιδεύσιμες παραμέτρους**. Πλήρης κώδικας της κλάσης HAR_CNN είναι διαθέσιμος στο αποθετήριο κώδικα της εργασίας.

4.2 Ανάπτυξη του Federated Framework

Το Federated Learning επιτρέπει σε πολλούς συμμετέχοντες να εκπαιδεύσουν κοινό μοντέλο χωρίς να κοινοποιήσουν τα raw δεδομένα τους [3]. Στο πλαίσιο αυτής της διπλωματικής, κάθε client αντιστοιχεί σε έναν χρήστη του dataset AAL με τα δικά του δεδομένα δραστηριότητας. Το σύστημα περιλαμβάνει 22 clients — έναν ανά subject του training set. Η υλοποίηση βασίστηκε στον κώδικα αναφοράς του N. Pavlidis [39], που παρέχει ένα καλά δοκιμασμένο template FL συστήματος με PyTorch, διασφαλίζοντας ορθή αρχιτεκτονική server-client από την αρχή και αποφεύγοντας κοινά pitfalls στην υλοποίηση κατανεμημένης εκπαίδευσης.

4.2.1 Αρχιτεκτονική Server-Client

Ο server λειτουργεί ως συντονιστής: αρχικοποιεί το global μοντέλο, επιλέγει clients ανά γύρο, συλλέγει τοπικά ενημερωμένα weights και εκτελεί aggregation. Ο client λαμβάνει τα global parameters, εκπαιδεύει τοπικά, και αποστέλλει τα ενημερωμένα weights — ποτέ τα raw δεδομένα.

Η επικοινωνία ανά γύρο t ακολουθεί τα παρακάτω βήματα:

1. **Επιλογή clients:** Ο server επιλέγει υποσύνολο $S_t \subseteq \mathcal{N}$ με $|S_t| = K$.
2. **Αποστολή global model:** Κάθε client $i \in S_t$ λαμβάνει τα global parameters $\theta^{(t)}$.
3. **Τοπική εκπαίδευση:** Κάθε client εκπαιδεύει για E εποχές: $\theta_i^{(t+1)} \leftarrow \text{LocalTrain}(\theta^{(t)}, \mathcal{D}_i)$.
4. **Αποστολή ενημερωμένων weights:** Κάθε client στέλνει $\theta_i^{(t+1)}$ και n_i στον server.
5. **FedAvg aggregation:** Ο server υπολογίζει το νέο global model:

$$\theta^{(t+1)} = \sum_{i \in S_t} \frac{n_i}{N_t} \cdot \theta_i^{(t+1)} \quad (2.4)$$

όπου $n_i = |\mathcal{D}_i|$ ο αριθμός δειγμάτων client i και $N_t = \sum_{i \in S_t} n_i$.

4.2.2 Τοπική Εκπαίδευση

Κάθε client εκτελεί $E = 5$ τοπικές εποχές με βελτιστοποιητή Adam ($\text{lr} = 10^{-3}$) και συνάρτηση απώλειας CrossEntropyLoss. Η επιλογή $E = 5$ αποτελεί ισορροπία μεταξύ δύο αντικρουόμενων στόχων: (α) αρκετές εποχές ώστε η τοπική εκπαίδευση να είναι αποτελεσματική, και (β) λίγες εποχές ώστε να αποφεύγεται το φαινόμενο client drift [10], όπου τα τοπικά μοντέλα αποκλίνουν υπερβολικά από το global.

4.2.3 Στάθμιση FedAvg

Η στάθμιση n_i/N_t εξασφαλίζει ότι clients με περισσότερα δεδομένα συνεισφέρουν αναλογικά περισσότερο στο global μοντέλο. Στο συγκεκριμένο σενάριο, οι 22 clients έχουν $n_i \in [130, 280]$ δείγματα (μέσο: ≈ 193), οπότε η Non-IID επίδραση της ανισομερούς κατανομής είναι μέτρια.

4.2.4 Γύροι Επικοινωνίας

Το σύστημα εκτελεί $T = 20$ γύρους FL. Σε κάθε γύρο συμμετέχουν όλοι οι 22 clients (`FRACTION_FIT = 1.0`). Η σύγκλιση του αλγορίθμου αποτιμάται πειραματικά σε επόμενο στάδιο της εργασίας.

4.2.5 Non-IID Διαχωρισμός

Ο φυσικός διαχωρισμός των δεδομένων ανά subject (`by_subject`) αποτελεί το πιο ρεαλιστικό σενάριο FL: κάθε smartphone ανήκει σε έναν χρήστη και περιέχει μόνο τα δικά του δεδομένα [9]. Αυτό δημιουργεί ετερογένεια κατανομής (Non-IID), η οποία έχει αναλυθεί ποσοτικά στην ενότητα 3.2 μέσω της μέτρησης JSD² (μέσο: 0.040).

4.3 Ο Μηχανισμός Κινήτρων

Στην παρούσα ενότητα παρουσιάζεται διεξοδικά ο σχεδιασμός του μηχανισμού κινήτρων που είναι κεντρική ερευνητική συνεισφορά της εργασίας. Αρχικά αναλύεται γιατί ένα FL σύστημα δεν λειτουργεί χωρίς τέτοιο μηχανισμό (§4.3.1), στη συνέχεια αποσυντίθεται ο χώρος σχεδιασμού σε τρεις ανεξάρτητες συνιστώσες (§4.3.2), παρουσιάζονται **επτά υποψήφιοι μηχανισμοί** με αυξανόμενη πολυπλοκότητα (§4.3.3), τίθενται κριτήρια αξιολόγησης (§4.3.4), διεξάγεται συγκριτική ανάλυση (§4.3.5) και καταλήγουμε σε **shortlist τριών μηχανισμών** (§4.3.6) και στον προτεινόμενο υβριδικό μηχανισμό που αξιολογείται πειραματικά στη συνέχεια.

4.3.1 Το Πρόβλημα και οι Σχεδιαστικοί Στόχοι

Στο FedAvg [3] κάθε client i ασκεί *προσπάθεια* (effort) $e_i \in [0, 1]$ που αντιστοιχεί στο ποσοστό των τοπικών επαναλήψεων που πραγματικά εκτελούνται και στην ποιότητα των gradients που αποστέλλει στον server. Η προσπάθεια συνεπάγεται *κόστος* $c_i(e_i)$ — μπαταρία, CPU, χρόνος — που επωμίζεται μόνος του ο χρήστης. Χωρίς αντιστάθμιση, η **κυρίαρχη στρατηγική** (*dominant strategy*) κάθε ορθολογικού client είναι $e_i^* = 0$: συμμετέχει συνωμοτικά αλλά δεν συνεισφέρει — το γνωστό **free-rider problem** [4, 13].

Επιπλέον, στο πραγματικό σενάριο AAL οι χρήστες δεν έχουν *ομοιογενή* ποιότητα δεδομένων: όπως αποδείχθηκε ποσοτικά στο §3.2 (JSD² μέσος 0,040, 31,8% subjects $> 0,05$), ορισμένοι έχουν δεδομένα κρίσιμα για τη γενίκευση ενώ άλλοι όχι. Ένας μηχανισμός που τους ανταμείβει *ομοιόμορφα* είναι ταυτόχρονα άδικος (αδικεί τους

ποιοτικούς συνεισφέροντες) και *αναποτελεσματικός* (δεν δημιουργεί κίνητρο για διαφοροποίηση).

Σχεδιαστικοί στόχοι. Ένας μηχανισμός κινήτρων για το παρόν σύστημα οφείλει ταυτόχρονα να ικανοποιεί:

1. **Ορθολογικότητα συμμετοχής (Individual Rationality, IR):** κάθε client πρέπει να έχει μη-αρνητική αναμενόμενη χρησιμότητα όταν συμμετέχει. Διαφορετικά αποχωρεί.
2. **Συμβατότητα κινήτρων (Incentive Compatibility, IC):** αν ο μηχανισμός απαιτεί ο client να αναφέρει ιδιωτική πληροφορία (π.χ. το κόστος του), η ειλικρινής αναφορά πρέπει να είναι βέλτιστη.
3. **Δικαιοσύνη (Fairness):** η αμοιβή να είναι ανάλογη της *αξίας συνεισφοράς*, όχι μόνο του όγκου δεδομένων.
4. **Υπολογιστική εφικτότητα:** ο μηχανισμός πρέπει να εκτελείται σε λογικό χρόνο για $N = 22$ clients σε CPU.
5. **Ανθεκτικότητα (Robustness):** σε στατιστικό θόρυβο, σε κακόβουλους clients, και σε cold-start περιπτώσεις.
6. **Συμβατότητα με ιδιωτικότητα:** ο server δεν πρέπει να χρειάζεται πρόσβαση σε raw data.

Όπως θα φανεί, καμία μεμονωμένη επιλογή δεν ικανοποιεί όλους αυτούς τους στόχους ταυτόχρονα — και ακριβώς γι' αυτό εξετάζονται πολλαπλοί υποψήφιοι.

4.3.2 Δομικά Στοιχεία ενός Μηχανισμού

Ένας μηχανισμός κινήτρων FL αποσυντίθεται φυσικά σε **τρεις ορθογώνιες συνιστώσες** που μπορούν να συνδυαστούν ανεξάρτητα:

- (Α') **Μέτρηση συνεισφοράς ($\hat{\varphi}_i$):** πώς ποσοτικοποιείται η αξία κάθε client. Επιλογές: όγκος δεδομένων, LOO, Shapley, gradient similarity, influence functions, reputation history.
- (Β') **Κατανομή αμοιβών (r_i):** πώς μετατρέπεται η μέτρηση σε χρηματική / υπολογιστική αμοιβή. Επιλογές: αναλογική, top- K selection, auction-based payment, threshold-based, Shapley payment, contract menu.

(Γ') **Στρατηγικό πλαίσιο αλληλεπίδρασης:** πώς διαμορφώνεται η ισορροπία μεταξύ server και clients. Επιλογές: χωρίς strategic interaction (descriptive), Stackelberg single-round, repeated Stackelberg, reverse auction (VCG), contract theory, mean-field game.

Στον Πίνακα 4.2 συνοψίζονται οι επιμέρους επιλογές κάθε συνιστώσας. Κάθε ολοκληρωμένος μηχανισμός είναι ένας συγκεκριμένος τριάδας (A, B, C). Οι 7 υποψήφιοι που αναλύονται παρακάτω είναι αντιπροσωπευτικά μονοπάτια αυτού του χώρου.

Πίνακας 4.2: Χώρος σχεδιασμού: επιλογές ανά συνιστώσα μηχανισμού κινήτρων.

(A) Μέτρηση συνεισφοράς	(B) Κατανομή αμοιβών	(C) Στρατηγικό πλαίσιο
Όγκος δεδομένων (n_i)	Αναλογική ($\varphi_i / \sum_j \varphi_j$)	Καμία αλληλεπίδραση
LOO ($v(\mathcal{N}) - v(\mathcal{N} \setminus i)$)	Top- K selection	Stackelberg single-round
Shapley value (exact / MC)	Threshold (κατώφλι ποιότητας)	Repeated Stackelberg
Gradient cosine similarity	Auction payment (VCG)	Reverse auction
Influence functions	Shapley payment (efficient)	Contract theory
Reputation (multi-round)	Contract menu	Mean-field game

4.3.3 Επτά Υποψήφιοι Μηχανισμοί

Ακολουθεί η αναλυτική περιγραφή επτά μηχανισμών (**M1--M7**), κατά αυξάνουσα πολυπλοκότητα και θεωρητική φιλοδοξία. Για κάθε έναν δίνονται: (i) η μαθηματική διατύπωση, (ii) ο αλγόριθμος υπολογισμού, (iii) τα πλεονεκτήματα/μειονεκτήματα και (iv) η υπολογιστική πολυπλοκότητα.

M1 — Όγκο-Αναλογικός Μηχανισμός (Volume-Proportional)

Συνιστώσες: (A) volume contribution, (B) proportional allocation, (C) καμία στρατηγική αλληλεπίδραση.

Διατύπωση. Η συνεισφορά κάθε client μετράται με τον αριθμό δειγμάτων του:

$$\hat{\varphi}_i^{(\text{vol})} = \frac{n_i}{\sum_{j=1}^N n_j} \quad (4.2)$$

και η αμοιβή κατανέμεται αναλογικά: $r_i = \hat{\varphi}_i^{(\text{vol})} \cdot R$.

Πλεονεκτήματα. Υπολογιστικό κόστος $\mathcal{O}(1)$ · δεν απαιτείται καμία επιπλέον FL αξιολόγηση. Συμβατό με το κλασικό FedAvg [3] γιατί χρησιμοποιεί ήδη τα ίδια βάρη. Διαφανές και άμεσα κατανοητό από τους χρήστες.

Μειονεκτήματα. *Αγνοεί την ποιότητα* δεδομένων: ένας client με 1000 σχεδόν ίδια παράθυρα WALKING αμείβεται το ίδιο με έναν με 1000 ποικίλα και ισορροπημένα. Επίσης, *δεν αντιμετωπίζει το free-rider* — ένας client μπορεί να στείλει αλλοιωμένα gradients και να αμείβεται.

Πολυπλοκότητα. $\mathcal{O}(1)$ για όλους τους N clients (μόνο μια άθροιση). Καμία FL αξιολόγηση.

Ρόλος στην εργασία. Χρησιμοποιείται ως **baseline** για να εκτιμηθεί πόση επιπλέον δικαιοσύνη / απόδοση φέρνουν οι πιο πολύπλοκοι μηχανισμοί.

M2 — LOO + Αναλογική Κατανομή + Stackelberg

Συνιστώσες: (A) LOO contribution, (B) proportional allocation, (C) Stackelberg single-round.

Διατύπωση. Η συνεισφορά εκτιμάται με Leave-One-Out:

$$\hat{\varphi}_i^{(\text{LOO})} = \max(0, v(\mathcal{N}) - v(\mathcal{N} \setminus \{i\})) \quad (4.3)$$

όπου $v(S)$ η accuracy του global μοντέλου μετά από $E_{\text{LOO}} = 3$ FL γύρους με τους clients του S . Η αποκοπή στο μηδέν αποκλείει αρνητικές contributions (πιθανώς adversarial).

Η αμοιβή κατανέμεται αναλογικά:

$$r_i = \max\left(r_{\min}, \frac{\hat{\varphi}_i^{(\text{LOO})}}{\sum_j \hat{\varphi}_j^{(\text{LOO})}} \cdot R\right) \quad (4.4)$$

με $r_{\min} = 0,01$ (ελάχιστη συμμετοχή). Τέλος, κάθε client επιλύει το πρόβλημα Stackelberg

$$\max_{e_i \in [0,1]} u_i(e_i) = r_i \cdot e_i - c \cdot e_i^2 \implies e_i^* = \frac{r_i}{2c} \quad (4.5)$$

με $c = 0,5$. Η ισορροπία είναι μοναδική λόγω της κυρτότητας του κόστους [12].

Πλεονεκτήματα. Πιστή ποσοτικοποίηση *οριακής* συνεισφοράς — απαντά άμεσα στην ερώτηση "πόσο χάνω αν χάσω αυτόν τον client;". Closed-form λύση Stackelberg → άμεση ερμηνευσιμότητα. Το $r_{\min}$ διασφαλίζει IR.

Μειονεκτήματα. (i) Μη-αρθροιστική: $\sum_i \hat{\varphi}_i^{(\text{LOO})} \neq v(\mathcal{N})$, οπότε το αξίωμα efficiency του Shapley παραβιάζεται. (ii) Αγνοεί διαδραστικά effects (clients συμπληρωματικοί δεν αναγνωρίζονται). (iii) Single-round: ευάλωτο σε στοχαστικό θόρυβο μιας μεμονωμένης LOO αξιολόγησης.

Πολυπλοκότητα. $\mathcal{O}(N + 1)$ FL αξιολογήσεις, καθεμία $\mathcal{O}(E_{\text{LOO}} \cdot N \cdot E_{\text{local}})$. Για $N = 22$, $E_{\text{LOO}} = 3$, $E_{\text{local}} = 5$: περίπου 7 200 τοπικές περάσεις, ~ 3 λεπτά σε CPU.

M3 — Monte Carlo Shapley + Αναλογική + Stackelberg

Συνιστώσες: (A) MC Shapley, (B) proportional allocation, (C) Stackelberg.

Διατύπωση. Η ακριβής Shapley value [14] ορίζεται ως

$$\varphi_i = \sum_{S \subseteq \mathcal{N} \setminus \{i\}} \frac{|S|! (N - |S| - 1)!}{N!} [v(S \cup \{i\}) - v(S)] \quad (4.6)$$

και ικανοποιεί τα τέσσερα αξιώματα δικαιοσύνης (efficiency, symmetry, null player, linearity). Ωστόσο απαιτεί 2^N αξιολογήσεις — απαγορευτικό για $N = 22$ ($\approx 4,2 \cdot 10^6$ υποσύνολα).

Η *Monte Carlo* προσέγγιση [40] δειγματοληπτεί M τυχαίες μεταθέσεις και υπολογίζει οριακές συνεισφορές:

$$\tilde{\varphi}_i = \frac{1}{M} \sum_{m=1}^M [v(S_i^{(m)} \cup \{i\}) - v(S_i^{(m)})] \quad (4.7)$$

όπου $S_i^{(m)}$ είναι το σύνολο clients πριν τον i στη μετάθεση m . Η σύγκλιση είναι $\mathcal{O}(\sigma/\sqrt{M})$. Στη βιβλιογραφία χρησιμοποιούνται τιμές M της τάξης δεκάδων για σταθερή κατάταξη.

Η κατανομή αμοιβών και η Stackelberg ισορροπία είναι ίδιες με τον M2 (εξισώσεις 4.4, 4.5).

Πλεονεκτήματα. Θεωρητικά βέλτιστος — ο Shapley είναι ο μοναδικός τύπος που ικανοποιεί τα τέσσερα αξιώματα δικαιοσύνης ταυτόχρονα (Shapley 1953). Πιάνει διαδραστικά effects: clients που είναι χρήσιμοι μόνο σε συνδυασμό αξιολογούνται σωστά.

Μειονεκτήματα. Υπολογιστικά ακριβός: $\mathcal{O}(M \cdot N)$ FL αξιολογήσεις. Για $M = 50$, $N = 22$: ~ 2 ώρες σε CPU. Επιπλέον, η εκτίμηση έχει στατιστική variance — επανεκτέλεση με διαφορετικό seed δίνει ελαφρώς διαφορετικές τιμές.

Πολυπλοκότητα. $\mathcal{O}(M \cdot N)$ FL αξιολογήσεις. Στην πράξη, ~ 120 λεπτά runtime.

M4 — Gradient Cosine Similarity (Online)

Συνιστώσες: (A) gradient cosine similarity, (B) προσαρμοσμένη γραμμική κατανομή, (C) χωρίς ρητή στρατηγική αλληλεπίδραση (descriptive).

Διατύπωση. Η συνεισφορά κάθε client σε έναν γύρο t εκτιμάται από την ευθυγράμμιση του τοπικού του gradient με το global update [16]:

$$\hat{\varphi}_i^{(\text{grad})}(t) = \frac{1}{2} \left(1 + \frac{\Delta\theta_i^{(t)} \cdot \Delta\theta_{\text{global}}^{(t)}}{\|\Delta\theta_i^{(t)}\| \|\Delta\theta_{\text{global}}^{(t)}\|} \right) \quad (4.8)$$

όπου $\Delta\theta_i^{(t)} = \theta_i^{(t)} - \theta_{\text{global}}^{(t-1)}$ το τοπικό update και $\Delta\theta_{\text{global}}^{(t)}$ το συνδυασμένο global update. Η κανονικοποίηση στο διάστημα $[0, 1]$ διευκολύνει την κατανομή.

Η αμοιβή ανά γύρο: $r_i^{(t)} = \hat{\varphi}_i^{(\text{grad})}(t) \cdot R / N_{\text{active}}$, όπου N_{active} οι ενεργοί clients του γύρου.

Πλεονεκτήματα. *Online:* η εκτίμηση γίνεται *ταυτόχρονα* με την εκπαίδευση, χωρίς επιπλέον FL γύρους. *Pay-per-round:* μπορεί να αμείβει σε κάθε γύρο, ευνοώντας συνεχή συμμετοχή. Πιάνει την κατεύθυνση και όχι μόνο το μέγεθος της συνεισφοράς — ένας client που "τραβάει" το μοντέλο σε αντίθετη κατεύθυνση εντοπίζεται άμεσα.

Μειονεκτήματα. (i) Θορυβώδης σε μεμονωμένο γύρο — απαιτεί smoothing μεταξύ γύρων (π.χ. exponential moving average). (ii) Δεν διαφορίζει μεταξύ "θορύβου" και *niche* χρήσιμης πληροφορίας: ένας client με σπάνιες αλλά νόμιμες κατηγορίες μπορεί να έχει "κάθετη" κατεύθυνση και να υπο-αμείβεται. (iii) Δεν έχει θεωρητικά αξιώματα δικαιοσύνης.

Πολυπλοκότητα. $\mathcal{O}(1)$ επιπλέον ανά γύρο — μόνο pairwise dot products. Σχεδόν δωρεάν.

M5 — Reputation-Based Multi-Round Mechanism

Συνιστώσες: (A) reputation history (συνδυασμός LOO + gradient similarity με exponential smoothing), (B) reputation-weighted allocation με ρήτρα αποκλεισμού, (C) repeated game.

Διατύπωση. Η reputation κάθε client συσσωρεύεται με exponential smoothing:

$$\rho_i^{(t)} = \beta \cdot \rho_i^{(t-1)} + (1 - \beta) \cdot \hat{\varphi}_i^{(t)} \quad (4.9)$$

με $\beta \in [0, 8, 0, 95]$ (μνήμη) και $\hat{\varphi}_i^{(t)}$ μια στιγμιαία εκτίμηση συνεισφοράς (π.χ. M4 ή light-LOO). Η αμοιβή κατανέμεται σε δύο επίπεδα:

- Αν $\rho_i^{(t)} < \rho_{\text{thr}}$ (κατώφλι κακόβουλης συμπεριφοράς), ο client *αποκλείεται* από τον επόμενο γύρο: $r_i^{(t+1)} = 0$.
- Αλλιώς: $r_i^{(t+1)} = \max(r_{\text{min}}, \rho_i^{(t)} / \sum_j \rho_j^{(t)} \cdot R)$.

Πλεονεκτήματα. *Ανθεκτικός σε στιγμιαίο θόρυβο* — μια κακή εκτίμηση σε έναν γύρο δεν καταστρέφει την αμοιβή. *Φιλτράρει adversarial clients*: επανειλημμένα αρνητική συνεισφορά οδηγεί σε αποκλεισμό. *Δημιουργεί long-term κίνητρα* — ο client πρέπει να συμπεριφέρεται καλά επί σειρά γύρων για να συσσωρεύσει reputation.

Μειονεκτήματα. (i) *Cold-start*: στους πρώτους γύρους όλοι έχουν ίδια reputation, οπότε ο μηχανισμός εκφυλίζεται προς volume-based. (ii) Επιπλέον υπερπαράμετροι (β , ρ_{thr}) που απαιτούν ρύθμιση. (iii) Ευπάθεια σε *whitewashing* — κακόβουλος client που "παίζει καλά" τους πρώτους γύρους και επιτίθεται μετά.

Πολυπλοκότητα. $\mathcal{O}(N)$ ανά γύρο για το EMA + όποια στιγμιαία εκτίμηση επιλεχθεί. Συνολικά $\sim 10\%$ επιπλέον πάνω από το baseline.

M6 — Reverse Auction (VCG-Style)

Συνιστώσες: (A) bid από τον client (ιδιωτικό cost type), (B) Vickrey-Clarke-Groves payment, (C) reverse auction.

Διατύπωση. Κάθε client αναφέρει στον server το κόστος b_i που απαιτεί για να εκτελέσει E_{local} γύρους εκπαίδευσης. Ο server επιλέγει υποσύνολο $\mathcal{S}^* \subseteq \mathcal{N}$ που μεγιστοποιεί την κοινωνική ωφέλεια:

$$\mathcal{S}^* = \arg \max_{\mathcal{S} \subseteq \mathcal{N}} \left[v(\mathcal{S}) - \sum_{i \in \mathcal{S}} b_i \right] \quad (4.10)$$

Το VCG payment για κάθε νικητή $i \in \mathcal{S}^*$ είναι η *εξωτερικότητα* (externality) που επιβάλλει στους άλλους:

$$r_i^{\text{VCG}} = \left[v(\mathcal{S}_{-i}^*) - \sum_{j \in \mathcal{S}_{-i}^*} b_j \right] - \left[v(\mathcal{S}^*) - \sum_{j \in \mathcal{S}^* \setminus \{i\}} b_j \right] \quad (4.11)$$

όπου $\mathcal{S}_{-i}^*$ η βέλτιστη επιλογή αν δεν υπήρχε ο client i .

Πλεονεκτήματα. *Αποδεδειγμένα incentive-compatible* (αξίωμα Vickrey 1961, Clarke 1971, Groves 1973): η ειλικρινής αναφορά $b_i = c_i$ είναι κυρίαρχη στρατηγική. *Μεγιστοποιεί κοινωνική ωφέλεια* (efficiency). Φυσικό fit όταν το *cost type* κάθε χρήστη είναι ιδιωτικό και ετερογενές (π.χ. κάποιοι έχουν παλαιότερα κινητά με μεγαλύτερο κόστος μπαταρίας).

Μειονεκτήματα. (i) *Υπολογιστικά απαιτητικός*: το πρόβλημα επιλογής νικητών είναι NP-hard στη γενική περίπτωση (απαιτεί $v(\mathcal{S})$ για κάθε $\mathcal{S} \subseteq \mathcal{N}$). Στην πράξη χρειάζεται greedy approximation με εγγυήσεις απόδοσης. (ii) *Budget non-balanced*: ο server μπορεί να πληρώσει περισσότερα από το συνολικό όφελος (έλλειμμα). (iii) Απαιτεί *collusion-resistance* — μηχανισμοί καρτέλ μπορούν να αλλοιώσουν την IC ιδιότητα.

Πολυπλοκότητα. $\mathcal{O}(2^N)$ για ακριβή λύση· $\mathcal{O}(N^2)$ με greedy approximation και submodular value function. Για $N = 22$: ~ 8 λεπτά greedy, $\sim 30+$ λεπτά exact (απαγορευτικό).

M7 — Contract Theory με Ιδιωτικούς Cost Types

Συνιστώσες: (A) προσπάθεια ως μη-παρατηρήσιμη (hidden action), (B) menu of contracts, (C) mechanism design με adverse selection.

Διατύπωση. Σε αυτό το πλαίσιο [31], υποθέτουμε ότι κάθε client έχει *ιδιωτικό τύπο* κόστους θ_i που τραβιέται από κατανομή $F(\theta)$ γνωστή στον server. Το κόστος του client είναι $c_i(e_i; \theta_i) = \theta_i \cdot e_i^2/2$ — clients υψηλού τύπου έχουν μεγαλύτερο κόστος προσπάθειας.

Ο server προσφέρει *menu από contracts* $\{(e_\theta, r_\theta)\}_{\theta \in \Theta}$, ένα ανά δυνατό τύπο. Κάθε contract λέει "αν αναφέρεις τύπο θ , εκτέλεσε προσπάθεια e_θ και πάρε αμοιβή r_θ ". Με τους περιορισμούς IC και IR:

$$\text{IR: } r_\theta - c(e_\theta; \theta) \geq 0 \quad \forall \theta \quad (4.12)$$

$$\text{IC: } r_\theta - c(e_\theta; \theta) \geq r_{\theta'} - c(e_{\theta'}; \theta) \quad \forall \theta, \theta' \quad (4.13)$$

ο server λύνει:

$$\max_{\{(e_\theta, r_\theta)\}} \mathbb{E}_\theta [v(e_\theta) - r_\theta] \quad \text{υπό IR, IC} \quad (4.14)$$

Σε διακριτό περιβάλλον τύπων (π.χ. high-cost / low-cost), η λύση δίνεται από κλασικά αποτελέσματα mechanism design (Myerson 1981) και έχει closed form.

Πλεονεκτήματα. Θεωρητικά βέλτιστος όταν υπάρχει heterogeneity κόστους και ιδιωτικότητα τύπων — η περίπτωση του πραγματικού AAL (νεότεροι vs ηλικιωμένοι, νεότερα vs παλαιότερα κινητά). Δίνει ταυτόχρονα IR + IC + κοινωνικά αποδοτική κατανομή. *Αυτο-επιλεκτικό:* οι clients επιλέγουν μόνοι τους το contract, αποκαλύπτοντας τον τύπο τους.

Μειονεκτήματα. (i) Απαιτεί γνώση της κατανομής $F(\theta)$ — στην πράξη πρέπει να εκτιμηθεί. (ii) Πιο πολύπλοκη υλοποίηση και debugging σε σχέση με Stackelberg. (iii) Δυσκολότερο να γενικευτεί σε πιο σύνθετες δράσεις (πέραν της προσπάθειας).

Πολυπλοκότητα. $\mathcal{O}(|\Theta|^2)$ για διακριτούς τύπους (συνήθως $|\Theta| = 2\text{--}5$), $\mathcal{O}(N \cdot |\Theta|)$ για evaluation σε όλους τους clients. Πρακτικά: $\sim 1\text{--}2$ λεπτά.

4.3.4 Κριτήρια Αξιολόγησης

Για να συγκρίνουμε τους επτά μηχανισμούς, ορίζονται **πέντε κριτήρια** που αντιστοιχούν στους σχεδιαστικούς στόχους της §4.3.1:

- C1. Δικαιοσύνη (Fairness):** ποσοτικοποιείται με τη συσχέτιση Pearson μεταξύ της αμοιβής r_i και μιας *ground-truth* αξίας συνεισφοράς (στα πειράματα: η ακριβής Shapley value σε μικρότερο sub-experiment, ή το $v(\mathcal{N}) - v(\mathcal{N} \setminus i)$). Υψηλό r = δίκαιη.
- C2. Ανθεκτικότητα σε θόρυβο:** ποσοτικοποιείται από τη σταθερότητα της κατάταξης clients (Spearman ρ) ανάμεσα σε ανεξάρτητα runs με διαφορετικά seeds.
- C3. Ανθεκτικότητα σε επιθέσεις:** ικανότητα ανίχνευσης ενός εμβολιασμένου adversarial client (label flipping ή gradient attack). Μετράται ως ποσοστιαία πτώση στην αμοιβή του adversarial client σε σχέση με το baseline.
- C4. Υπολογιστικό κόστος:** μετράται σε FL αξιολογήσεις (επί E_{LOO} γύρων κάθε μία) και χρόνο σε CPU. Όριο πρακτικότητας: ≤ 30 λεπτά συνολικά.
- C5. Θεωρητικές εγγυήσεις:** αν ο μηχανισμός ικανοποιεί IR, IC, fairness axioms (Shapley) ή budget balance.

Η συμβατότητα με ιδιωτικότητα ικανοποιείται από όλους τους μηχανισμούς εξ ορισμού: κανένας δεν απαιτεί πρόσβαση σε raw data· μόνο σε weights/scores που ήδη ανταλλάσσονται στο FL.

4.3.5 Συγκριτική Ανάλυση

Ο Πίνακας 4.3 συνοψίζει την αξιολόγηση των επτά μηχανισμών στα πέντε κριτήρια. Οι τιμές χρησιμοποιούν την κλίμακα: ★ (αδύναμη/ανύπαρκτη), ★★ (μερική), ★★★ (καλή), ★★★★★ (ισχυρή). Η αξιολόγηση είναι **ποιοτική**, βασισμένη στις θεωρητικές ιδιότητες κάθε μηχανισμού (πολυπλοκότητα, αξιώματα δικαιοσύνης, εγγυήσεις IR/IC) και σε ευρήματα της βιβλιογραφίας· οι αναφερόμενοι χρόνοι εκτέλεσης είναι **ενδεικτικές εκτιμήσεις** που θα επιβεβαιωθούν στην πειραματική φάση.

Πίνακας 4.3: Συγκριτική αξιολόγηση επτά υποψήφιων μηχανισμών κινήτρων.

Μηχανισμός	C1 Fair	C2 Noise	C3 Attack	C4 Cost	C5 Theory
M1 Volume	★	★★★★	★	★★★★	★
M2 LOO + Stack.	★★★	★★	★★	★★★	★★
M3 Shapley + Stack.	★★★★	★★	★★	★	★★★★
M4 Gradient Sim.	★★	★★	★★★	★★★★	★
M5 Reputation	★★★	★★★★	★★★★	★★★	★★
M6 Reverse Auction	★★★	★★★	★★	★	★★★★
M7 Contract Theory	★★★	★★★	★★	★★★	★★★★

Κύριες παρατηρήσεις.

- Ο **M1** είναι ξεκάθαρα ανεπαρκής σε δικαιοσύνη/επιθέσεις — υπηρετεί μόνο ως baseline.
- Ο **M3** (Shapley) έχει τις ισχυρότερες θεωρητικές εγγυήσεις αλλά ασύμφορο runtime (~ 2 ώρες) για $N = 22$ — γίνεται απαγορευτικός για $N \geq 50$.
- Ο **M5** (reputation) ξεχωρίζει σε ανθεκτικότητα — και είναι ο μοναδικός που αντιμετωπίζει το adversarial scenario μέσω αποκλεισμού.
- Οι **M6** και **M7** έχουν τις ισχυρότερες θεωρητικές ιδιότητες (IC, efficient) αλλά η M6 πάσχει σε κόστος και η M7 απαιτεί υπόθεση κατανομής τύπων.
- Ο **M2** είναι το *utility middle ground*: αξιοπρεπής σε όλα τα κριτήρια χωρίς να εκπληρώνει κανένα τέλεια.

4.3.6 Shortlist Επιλογής

Από τους επτά μηχανισμούς, τρεις είναι οι πλέον αξιοσημείωτοι για το σενάριο της παρούσας εργασίας ($N=22$ clients, AAL data, CPU runtime). Παρουσιάζονται με σειρά αυξανόμενης πολυπλοκότητας:

Επιλογή A — M2: LOO + Proportional + Stackelberg. Πιο ώριμη επιλογή για *γρήγορη απόδειξη της ιδέας*. Συνδυάζει αποδεκτή δικαιοσύνη με κλειστή λύση Stackelberg και runtime ~ 3 λεπτά. Είναι αυτό που *ήδη υλοποιείται* στο `incentive.py` και θα μπορούσε να χρησιμοποιηθεί ως είναι. Ταιριάζει αν ο στόχος είναι "ένα λειτουργικό σύστημα με τεκμηριωμένη μαθηματική βάση".

Επιλογή Β — M5: Reputation-Based Multi-Round. Πιο φιλόδοξη επιλογή που *ταιριάζει* στο πραγματικό AAL σενάριο: ηλικιωμένοι χρήστες, μακροχρόνια παρακολούθηση, ανάγκη ανίχνευσης σταδιακών αλλαγών συμπεριφοράς (π.χ. τραυματισμός που αλλάζει το βάδισμα). Συνδυάζει LOO ή Gradient Similarity ως στιγμιαία εκτίμηση με exponential smoothing και ρήτρα αποκλεισμού. Έχει τις καλύτερες ιδιότητες ανθεκτικότητας. Απαιτεί επιπλέον εμπειρική ρύθμιση β και ρ_{thr} , και νέα πειράματα adversarial scenario.

Επιλογή Γ — M3: MC Shapley + Stackelberg. Επιλογή *μέγιστης θεωρητικής αυστηρότητας*. Δικαιολογεί την πλήρη επίκληση των αξιωμάτων του Shapley και επιτρέπει ποσοτική σύγκριση LOO vs Shapley στα πειράματα του Κεφαλαίου 6. Το βασικό κόστος είναι runtime ~ 2 ώρες ανά πείραμα — αλλά εφόσον γίνεται *μία φορά* και τα αποτελέσματα αποθηκεύονται, είναι αποδεκτό. Ταιριάζει αν ο στόχος είναι "διπλωματική με ισχυρή θεωρητική θεμελίωση και πλούσια πειραματική σύγκριση".

Στάθμιση και υβριδικές προσεγγίσεις. Η επιλογή σταθμίζει τρεις παράγοντες: (i) το διαθέσιμο computational budget, (ii) τη θεωρητική θεμελίωση που απαιτεί η ερευνητική συνεισφορά της εργασίας, και (iii) τη δυνατότητα ποσοτικής σύγκρισης των μετρικών συνεισφοράς. Προς τον σκοπό αυτό αξιοποιούνται και υβριδικές προσεγγίσεις:

- **M2 + M5 (LOO + Reputation):** χρησιμοποιεί το LOO ως στιγμιαία μέτρηση και κατασκευάζει reputation επί 20 γύρων FL. Λογικό runtime (~ 10 λεπτά) και προσφέρει multi-round ανθεκτικότητα.
- **M3 + M2 (Shapley για theory, LOO για deployment):** το Shapley υπολογίζεται μία φορά offline ως θεωρητικό σημείο αναφοράς, ενώ το φθηνότερο LOO χρησιμοποιείται στο πραγματικό σύστημα. Ο βαθμός συμφωνίας LOO--Shapley αποτελεί *ανοιχτό εμπειρικό ερώτημα* που θα διερευνηθεί στην πειραματική φάση: αν τα δύο μέτρα συμφωνούν, αρκεί το φθηνό LOO· διαφορετικά, το Shapley παραμένει αναγκαίο για την ανάλυση δικαιοσύνης.

Προτεινόμενος μηχανισμός. Με βάση την παραπάνω ανάλυση, προτείνεται ο υβριδικός συνδυασμός **M3 (offline εξακρίβωση) + M2 (online deployment)**: το MC Shapley υπολογίζεται *μία φορά* offline ως θεωρητικό σημείο αναφοράς για τα LOO scores, ενώ ο μηχανισμός LOO + Proportional + Stackelberg χρησιμοποιείται στο πραγματικό σύστημα. Ο συνδυασμός αυτός επιτυγχάνει ταυτόχρονα θεωρητική θεμελίωση και λογικό runtime, και αποτελεί τον μηχανισμό που αξιολογείται πειραματικά στη συνέχεια της εργασίας.

4.3.7 Σύνοψη Ενότητας

Στην ενότητα αυτή παρουσιάστηκαν επτά υποψήφιοι μηχανισμοί κινήτρων (M1--M7), καλύπτοντας ένα ευρύ φάσμα του χώρου σχεδιασμού: από απλή volume-based κατανομή μέχρι contract theory με ιδιωτικούς τύπους κόστους. Η συγκριτική ανάλυση κατά πέντε κριτήρια αναδεικνύει τρεις δυνατούς δρόμους (Επιλογή Α: M2, Β: M5, Γ: M3), καθώς και υβριδικές παραλλαγές που συνδυάζουν το καλύτερο από αυτές. Ως προτεινόμενος μηχανισμός επιλέγεται ο υβριδικός συνδυασμός M3+M2, ο οποίος αξιολογείται πειραματικά στο επόμενο μέρος της εργασίας.

Κεφάλαιο 5

Ανάλυση και Υπολογισμός Συνεισφοράς

Το κεφάλαιο αυτό βρίσκεται υπό εκπόνηση. Παρατίθεται η προβλεπόμενη δομή του.

5.1 Μετρικές Βασισμένες στον Όγκο

5.2 Μετρικές Βασισμένες στην Απόδοση

5.3 Προσέγγιση με Shapley Values

5.4 Gradient-Based Ομοιότητα

5.5 Σύγκριση Μεθόδων και Σύνδεση με EDA

Κεφάλαιο 6

Πειραματική Διαδικασία και Αποτελέσματα

Το κεφάλαιο αυτό βρίσκεται υπό εκπόνηση. Παρατίθεται η προβλεπόμενη δομή του.

6.1 Ρύθμιση Πειραμάτων

6.2 Σύγκριση Datasets

6.3 Απόδοση Federated Learning

6.4 Αποτελέσματα Αξιολόγησης Συνεισφοράς

6.5 Επίδραση των Κινήτρων

6.6 Ενσωμάτωση Digital Twin

Κεφάλαιο 7

Επίλογος

Το κεφάλαιο αυτό βρίσκεται υπό εκπόνηση. Παρατίθεται η προβλεπόμενη δομή του.

7.1 Συμπεράσματα

7.2 Ανοικτά Ζητήματα

7.3 Πιθανές Επεκτάσεις

Βιβλιογραφία

- [1] Bo Liu κ.ά. «A Federated Learning-Based Human Activity Recognition Framework for Smart Healthcare». Στο: *IEEE Transactions on Industrial Informatics* (2021). URL: <https://ieeexplore.ieee.org/document/9393356>.
- [2] Reza Shokri και Vitaly Shmatikov. «Privacy-Preserving Deep Learning». Στο: *Proceedings of the 22nd ACM SIGSAC Conference on Computer and Communications Security (CCS)*. 2015. URL: <https://arxiv.org/abs/1412.7584>.
- [3] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson και Blaise Agüera y Arcas. «Communication-Efficient Learning of Deep Networks from Decentralized Data». Στο: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*. 2017. URL: <https://arxiv.org/abs/1602.05629>.
- [4] Jiawen Kang, Zehui Xiong, Dusit Niyato, Shengli Xie και Dong In Kim. «Incentive Design for Efficient Federated Learning in Mobile Networks: A Contract Theory Approach». Στο: *IEEE Transactions on Mobile Computing* (2019). URL: <https://ieeexplore.ieee.org/document/8705352>.
- [5] Guan Wang, Xiaoying Xu και Gongzhu Huang. «Measure Contribution of Participants in Federated Learning». Στο: *IEEE International Conference on Big Data*. 2019. URL: <https://arxiv.org/abs/1909.12115>.
- [6] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra και Jorge Luis Reyes-Ortiz. «A Public Domain Dataset for Human Activity Recognition Using Smartphones». Στο: *ESANN*. 2013. URL: <https://ieeexplore.ieee.org/document/6636867>.
- [7] Nils Y. Hammerla, Shane Halloran και Thomas Plötz. «Deep, Convolutional, and Recurrent Models for Human Activity Recognition using Wearables». Στο: *Proceedings of the 25th International Joint Conference on Artificial Intelligence (IJCAI)*. 2016. URL: <https://arxiv.org/abs/1604.08880>.
- [8] Liming Chen, Jesse Hoey, Chris D. Nugent, Diane J. Cook και Zhiwen Yu. «Deep Learning for Sensor-Based Activity Recognition: A Survey». Στο: *ACM Computing Surveys* (2021). DOI: [10.1145/3447744](https://doi.org/10.1145/3447744).

- [9] Qiang Yang, Yang Liu, Tianjian Chen και Yongxin Tong. «Federated Machine Learning: Concept and Applications». Στο: *ACM Transactions on Intelligent Systems and Technology (TIST)* (2019). URL: <https://arxiv.org/abs/1902.04885>.
- [10] Tian Li, Anit Kumar Sahu, Ameet Talwalkar και Virginia Smith. «Federated Learning: Challenges, Methods, and Future Directions». Στο: *IEEE Signal Processing Magazine* (2020). URL: <https://arxiv.org/abs/1908.07873>.
- [11] Peter Kairouz κ.ά. «Advances and Open Problems in Federated Learning». Στο: *Foundations and Trends in Machine Learning* (2021). URL: <https://arxiv.org/abs/1912.04977>.
- [12] Yunus Sarikaya και Ozgur Ercetin. «Motivating Workers in Federated Learning: A Stackelberg Game Perspective». Στο: *IEEE Networking Letters* (2020). URL: <https://ieeexplore.ieee.org/document/8954641>.
- [13] Han Yu κ.ά. «A Fairness-Aware Incentive Mechanism for Federated Learning». Στο: *Proceedings of AISTATS*. 2020. URL: <https://arxiv.org/abs/2007.15174>.
- [14] Lloyd S. Shapley. «A Value for n-Person Games». Στο: *Contributions to the Theory of Games*. 1953. DOI: [10.1515/9781400881970-018](https://doi.org/10.1515/9781400881970-018).
- [15] Tanmay Gopinathan κ.ά. «Contribution Measurement in Federated Learning via Shapley Value». Στο: *Journal of Machine Learning Research* (2023). URL: <https://arxiv.org/abs/2109.14150>.
- [16] Xinyi Xu, Lingjuan Lyu, Xingjun Ma, Chengchen Chen και Sinno Jialin Pan. «Gradient-Based Shapley Value Approximation for Federated Learning». Στο: *Information Sciences* (2021). URL: <https://arxiv.org/abs/2104.04168>.
- [17] Pavlos Efraimidis και Vasilis Tsaousidis. *Theses Guidelines and Resources*. Algorithms & Privacy Research Unit, DUTH. URL: <https://pefraimi.github.io/theses/>.
- [18] Kadian A. Davis και Evans B. Owusu. *Smartphone Dataset for Human Activity Recognition (HAR) in Ambient Assisted Living (AAL)*. UCI Machine Learning Repository, Dataset 364. 2016. URL: <https://archive.ics.uci.edu/dataset/364/smartphone+dataset+for+human+activity+recognition+har+in+ambient+assisted+living+aal>.
- [19] Ian Goodfellow, Yoshua Bengio και Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.

- [20] Kaiming He, Xiangyu Zhang, Shaoqing Ren και Jian Sun. «Deep Residual Learning for Image Recognition». Στο: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016. URL: <https://arxiv.org/abs/1512.03385>.
- [21] Sepp Hochreiter και Jürgen Schmidhuber. «Long Short-Term Memory». Στο: *Neural Computation* 9.8 (1997). DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).
- [22] Ashish Vaswani κ.ά. «Attention Is All You Need». Στο: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017. URL: <https://arxiv.org/abs/1706.03762>.
- [23] Jakub Konečný, H. Brendan McMahan, Felix X. Yu, Peter Richtárik, Ananda Theertha Suresh και Dave Bacon. *Federated Learning: Strategies for Improving Communication Efficiency*. 2016. arXiv: [1610.05492](https://arxiv.org/abs/1610.05492). URL: <https://arxiv.org/abs/1610.05492>.
- [24] Martín Abadi κ.ά. «Deep Learning with Differential Privacy». Στο: *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security (CCS)*. 2016. URL: <https://arxiv.org/abs/1607.00133>.
- [25] Keith Bonawitz κ.ά. «Practical Secure Aggregation for Federated Learning on User-Held Data». Στο: *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS)*. 2017. URL: <https://arxiv.org/abs/1611.04482>.
- [26] Shuochao Yao, Yiran Zhao, Aston Zhang, Lu Su και Tarek Abdelzaher. «DeepIoT: Compressing Deep Neural Network Structures for Sensing Systems with a Compressor-Critic Framework». Στο: *Proceedings of the 15th ACM Conference on Embedded Network Sensor Systems (SenSys)*. 2017. URL: <https://arxiv.org/abs/1706.01425>.
- [27] Fuqiang Gu, Kourosh Khoshelham, Ci Yu, Jianga Shang και Zhipeng Wei. «Locomotion Activity Recognition Using Wearable Sensors in a Heterogeneous Sensing Platform». Στο: *IEEE Internet of Things Journal* 6.2 (2022), σσ. 1998–2010. URL: <https://ieeexplore.ieee.org/document/9444458>.
- [28] Michael Grieves. *Digital Twin: Manufacturing Excellence through Virtual Factory Replication*. White Paper. 2014. URL: <https://www.researchgate.net/publication/275211041>.
- [29] Fei Tao, He Zhang, Ang Liu και A. Y. C. Nee. «Digital Twin in Industry: State-of-the-Art». Στο: *IEEE Transactions on Industrial Informatics* (2019). URL: <https://ieeexplore.ieee.org/document/8443152>.

- [30] Shimin Liu κ.ά. «Review of Digital Twin about Concepts, Technologies, and Industrial Applications». Στο: *Journal of Manufacturing Systems* (2021). DOI: [10.1016/j.jmsy.2021.01.006](https://doi.org/10.1016/j.jmsy.2021.01.006).
- [31] Jie Zhan και Jian Zhang. «Incentive Mechanism Design for Federated Learning: A Game Theoretic Perspective». Στο: *Information* 12.7 (2023). URL: <https://www.mdpi.com/2078-2489/14/11/598>.
- [32] Nikolaos Pavlidis. *Incentive Mechanisms for Participation in Federated Learning*. 2021. arXiv: [2111.11850](https://arxiv.org/abs/2111.11850). URL: <https://arxiv.org/abs/2111.11850>.
- [33] Kadian A. Davis και Evans B. Owusu. «Activity Recognition Based on Inertial Sensors for Ambient Assisted Living». Στο: *19th International Conference on Information Fusion (FUSION)*. 2016.
- [34] Boris Iglewicz και David C. Hoaglin. «How to Detect and Handle Outliers». Στο: *ASQC Basic References in Quality Control: Statistical Techniques* 16 (1993).
- [35] Fei Tony Liu, Kai Ming Ting και Zhi-Hua Zhou. «Isolation Forest». Στο: *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*. 2008, σσ. 413–422. DOI: [10.1109/ICDM.2008.17](https://doi.org/10.1109/ICDM.2008.17).
- [36] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng και Jörg Sander. «LOF: Identifying Density-Based Local Outliers». Στο: *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*. 2000, σσ. 93–104. DOI: [10.1145/342009.335388](https://doi.org/10.1145/342009.335388).
- [37] Dilovan Asaad Zebari κ.ά. «A Comprehensive Review of Dimensionality Reduction Techniques for Feature Selection and Feature Extraction». Στο: *IEEE Access* (2022). URL: <https://ieeexplore.ieee.org/document/9796035>.
- [38] Diederik P. Kingma και Jimmy Ba. «Adam: A Method for Stochastic Optimization». Στο: *International Conference on Learning Representations (ICLR)*. 2015. URL: <https://arxiv.org/abs/1412.6980>.
- [39] Nikolaos Pavlidis. *Simple Federated Learning Example*. GitHub Repository. 2021. URL: https://github.com/nikopavl4/Simple_FL_Example.
- [40] Ruoxi Jia κ.ά. «Towards Efficient Data Valuation Based on the Shapley Value». Στο: *IEEE* (2020). URL: <https://arxiv.org/abs/1911.00287>.